

摘要：

国联民生报告认为，算力基础设施化正推动产业向“按智能效用计价”跃迁，Token运营有望成为高景气主线。GPU涨价折射算力供给偏紧，国内Token调用量两年增千倍印证需求非线性爆发，云厂商密集调价则表明景气度已向下游传导。掌握重要数据集、能够稳定生产低幻觉、高专业价值Token的厂商，有望建立自身护城河，进而提升长期利润空间。

当算力逐渐成为基础设施之后，产业链下一阶段具备高回报潜力的环节会是什么？

国联民生证券最新报告认为，产业链正从“卖算力资源”向“按智能效用计价”的更高价值形态跃迁，Token运营赛道有望成为下一个高景气投资主线。

AI算力需求持续超预期扩张，GPU租赁价格普遍上涨，三大运营商加速布局Token运营生态。Token运营的本质，是将非标智能服务转化为标准化、可交易的效用商品，推动产业从“卖算力资源”、“卖模型API”升级为“按智能效用计价”，为产业链各方提供统一的价值度量与分润框架。

从价值传导逻辑看：AI Agent驱动Token需求爆发 → 算力持续涨价 → 算力商品化 → 价值重心从“卖GPU”转向“卖Token” → 最终延伸至“Token运营”。Token运营方的核心竞争力在于资源整合与生态协同，其长期价值量有望超越传统算力租赁模式。运营商与平台方有望成为AI时代新的价值中枢。

Token"通胀"持续验证：GPU租赁价格全面上行

算力供需紧张格局正在被一系列硬数据反复确认。

在英伟达2027财年第一财季财报电话会上，首席财务官科莱特·克雷斯（Colette Kress）明确表示，今年以来H100芯片的租赁价格已上涨20%，A100芯片的云端定价涨幅接近15%，且在GPU折旧年限之外，客户依然能产生盈利性收入。云计算服务商Nebius则宣布将H100 GPU的按需租赁价格从每小时2.95美元上调至每小时3.85美元。

需求端的数据同样引人瞩目。根据报告援引人民日报报道，国内日均Token调用量从2024年初的1000亿，攀升至2025年底的100万亿，再到2026年3月已达140万亿，两年多时间增长超千倍。AI Agent应用的爆发是这一非线性增长的核心驱动力。

图1：Nebius 对 GPU 算力租赁的价格（此次价格调整之前）

Item	vCPUs	RAM, GB	Preemptible, GPU-hour	On-demand, GPU-hour
NVIDIA GB300 NVL72	112	800	—	Contact us
NVIDIA HGX B300	24	346	\$3.40	\$6.10
NVIDIA GB200 NVL72	112	800	—	Contact us
NVIDIA HGX B200	20	224	\$2.90	\$5.50
NVIDIA HGX H200	16	200	\$1.45	\$3.50
NVIDIA HGX H100	16	200	\$1.25	\$2.95
NVIDIA RTX PRO 6000	24	218	\$0.95	\$1.80
NVIDIA L40S with Intel CPU	16-192	96-1152	from \$0.90	from \$1.82
NVIDIA L40S with AMD CPU	8-40	32-160	from \$0.74	from \$1.55

资料来源：NEBIUS 官网，国联民生证券研究所

国内头部云厂商的“涨价潮”进一步印证了需求端的景气度：

- 阿里云：自今年3月以来多轮调价，算力卡服务上涨5%至34%，CPFS智算版存储上涨30%，DDoS防护月95模式普遍上涨20%至50%，大模型MU单元服务涨幅约2%至7%；
- 腾讯云：自2026年5月9日起对AI算力相关产品服务价格均上调5%；
- 百度智能云：自2026年4月18日起对AI算力相关产品服务价格上调约5%至30%，并行文件存储等产品价格上调30%，部分模型甚至出现调用限流。

表1：阿里云近期涨价相关公告梳理

公告发布时间	产品类别	生效时间	核心调整内容	调整幅度
2026/3/18	AI 算力/存储	2026-04-18 00:00 全地域生效	1. 平头哥真武 810E 等算力卡相关服务调价；2. CPFS（智算版）存储服务调价	1. 算力卡服务上涨 5% - 34%；2. CPFS 智算版上涨 30%
2026/4/13	大数据开发（DataWorks）	2026-04-14 至 2026-04-23 全地域逐步生效	1. 标准版、专业版取消每日 API 调用数量限制；2. 调整月免费调用额度，超出部分按量付费	1. 标准版月免费额度：10 万次/月；2. 专业版月免费额度：50 万次/月；3. 基础版/企业版政策不变，QPS 限制不变
2026/4/15	网络安全（DDoS 防护）	2026-07-15 00:00 生效	调整 DDoS 原生防护 2.0、境内外高防的弹性带宽、弹性 QPS 定价	1. 月 95 模式普遍上涨 20%-50%；2. 部分日 95 模式下调（原生防护日 95 降 50%），其余日 95 小幅上涨
2026/4/15	大模型服务（百炼平台）	2026-05-15 00:00 生效（以实际变更为准）	调整 MU3/MU4/MU5 模型单元的包年包月、按量计费单价	涨幅约 2% - 7%不等

资料来源：阿里云官网，国联民生证券研究所梳理

Token运营：算力租赁"下一站"的三重逻辑

Token运营并非算力的简单二次销售，而是一次商业模式的根本性升级，其底层逻辑由三个维度支撑：

供给端标准化：Token化运营能够将不同架构、不同厂商、不同节点的异构算力统一转化为标准化的Token供给。用户无需关心底层硬件型号和集群部署细节，只需按需购买对应数量的Token即可调用大模型服务，大幅降低用算门槛，同时通过动态调度提升算力资源利用率。

商业价值升级：商业模式从"一次性卖硬件资源"升级为"持续运营智能服务"。通过算力与模型的智能匹配降低用户单位Token消耗，并延伸出分层定价、套餐订阅等多元盈利模式，将一次性算力收入转化为高粘性的持续运营收入。

产业趋势切换：行业已从算力基础设施建设阶段转向算力高效调度运营阶段。Token作为AI价值流转的核心载体，正逐步成为行业内较普遍认可的统一标准。算力租赁企业向下延伸Token运营服务，既能盘活已有算力资源的变现潜力，也能对接快速增长的AI推理、训练需求。

Token运营的长期竞争壁垒在于"行业数据积累—大模型训练优化—高质量Token输出—用户反馈迭代"的闭环能力。掌握重要数据集、能够稳定生产低幻觉、高专业价值Token的厂商，有望建立自身护城河，进而提升长期利润空间。

政策与需求双轮驱动，Token运营进入快速发展窗口

政策层面，国家将算力网纳入与水网、新型电网、通信网、城市地下管网、物流网并列的"六张网"重点规划。据国家发改委测算，今年"六张网"及相关领域的投资规模将超过7万亿元。工信部、国家数据局同步启动"模数共振"行动，明确支持Token技术赋能钢铁、工业母机等20个重点工业行业。

国家数据局还就《关于推进行业高质量数据集建设行动的实施方案（征求意见稿）》公开征求意见，明确提出探索词元交易等新型数据集交易模式，构建以词元为基础、可量化、可定价的数据集价值体系。

三大运营商全面入局，Token生态格局初现

三大运营商已完成智算底座布局，成为Token产业的核心参与者，各自形成差异化的竞争策略：

中国电信 明确“All in Token”战略，发布Token套餐，并完成三大运营商首个百亿级Token工厂集采（不含税规模约164.51亿元），智算总规模达91 EFLOPS，八大枢纽互访时延低于12毫秒。Token套餐覆盖自研星辰大模型、DeepSeek、GLM等国内主流大模型，面向C端最低1元可购40万Token，最低包月9.9元含1000万Token；中小微企业AI应用起步成本从传统的50至100万元降至千元级。中国电信已落地内部AI应用超250个，实现降本超20亿元。

中国移动 以算力基建为核心，发布Token运营生态体系及应用生态联盟，承诺开放万亿级Token体验包。其核心平台MoMA首创Token集约化运营模式，支持“成本优先/效果优先/均衡优先”三种模式智能匹配最优模型，端到端时延低于1分钟。中国移动明确提出“十五五”期末算力服务和智能服务收入翻番的目标。

中国联通 主打“Agent+Token+AI云”模式，智算规模45 EFLOPS，建成7个百兆瓦级AIDC园区。

2026年，三大运营商均计划在总资本开支下降的背景下，提升算力投资占比，资源全面向智能算力业务倾斜。

图4：以三大运营商为例，智能服务交易自身的价值已经开始凸显



资料来源：人民日报报、中国工业报官方公众号，国联民生证券研究所

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



VIP会员·7天畅读卡 | 大师课·入门串讲

扫码
免费领取

体验资格每人限申领一次



限免



写评论

请发表您的评论



表情



图片

发布评论

