

摘要：

国海证券指出，AI推理拐点已至，算力租赁进入量价齐升高景气周期。H100 GPU一年期租约价格从2025年10月低点涨至2026年3月的每小时2.35美元，涨幅近40%；腾讯云、阿里云、百度云集体上调算力服务价格。同时，豆包日均Token调用量较2024年5月增长1000倍，中国AI大模型全球调用量已连续六周超越美国。

4月21日，国海证券计算机行业首席分析师刘熹发布行业专题报告《算力租赁：锐度鲜明的中国AI核心资产》，从商业模式、行业量价趋势、国内企业融资进展三个维度，系统梳理了算力租赁赛道的投资逻辑。

报告判断，AI推理拐点已至，算力租赁进入量价齐升高景气周期，是当前AI产业链确定性较强的核心赛道。

这一判断背后，有一组数据支撑：H100 GPU一年期租约价格从2025年10月低点每小时1.70美元急升至2026年3月的2.35美元，涨幅接近40%；与此同时，按需GPU租赁容量在所有GPU类型中均已售罄。

最近一年走势



商业模式：长单锁定，折旧摊完后利润弹性显著

算力租赁的商业逻辑，类似于“先重资产投入、后稳定收租”。

报告指出，行业以2-5年承诺制长期合同为主，截至2024年，承诺制合同的加权平均期限约为4年。客户在合同期内预留算力容量并支付固定费用，通常在签约时支付合同总价值15%-25%的预付款。交付、验收后进入计费阶段，“业绩兑现节奏清晰，现金流可预测性强、收入稳定性高”。


以Coreweave为例，其数据中心租赁、电力及折旧成本先于营收确认，但“业务常态化后可实现25%-30%长期利润率”。报告进一步指出，随算力设备使用年限推进，服务器折旧逐步计提完毕，“核心成本将大幅下降，后续稳定的租金收入大部分将直接转化为净利润，企业有望迎来利润阶梯式增长，长期盈利弹性显著”。

表：Coreweave算力租赁优势

类别	优势
专为人工智能打造	CoreWeave的平台从根本上进行了全新架构设计，旨在为人工智能工作负载提供前沿性能。CoreWeave重新构想了传统云架构，以提供人工智能所需的基础设施和技术堆栈，并对其进行优化，去除了诸如管理程序层等服务以及其他可能导致性能损耗的不必要托管服务。CoreWeave的托管软件服务，包括公司的编排解决方案OKS以及应用程序服务，均针对复杂的人工智能工作负载进行了优化。
融资能力	开创了GPU基础设施支持的贷款模式，到目前为止，公司已通过12轮融资筹集了超过145亿美元的债务和股权资金。公司最近由黑石集团（Blackstone）和麦格理集团（Magnetar）牵头筹集的76亿美元承诺的GPU基础设施支持债务，是历史上最大的私募债务融资之一，这表明债务投资者对于公司提供资金以构建和扩展下一代人工智能云充满信心。
生态系统关系	受益于与供应商和客户之间牢固、互利的关系，这些关系强化了公司的解决方案和市场地位。公司与英伟达（NVIDIA）合作大规模部署最新的GPU技术。反过来，公司也是英伟达的合作伙伴。

此外，报告还提到，不同应用场景需求均强劲，解决方案并非万能——“MoE等推理工作负载在最新的大型世界级系统（如GB300 NVL72）上运行效果最佳；而训练工作负载在H100系列显卡上则能获得最佳性价比，因此即使是较老的显卡也需求旺盛”。这意味着算力设备的有效生命周期被拉长，折旧期满后残值有望获重估。

1.3 中国AI算力：国产AI芯片+算力租赁+英伟达特供款




Token需求爆炸：中国AI出海打开增量空间

需求侧的变化，是理解这轮算力涨价的关键。


报告援引黄仁勋在英伟达GTC 2026的判断，将AI分为三个阶段：生成式AI、推理AI（o1/o3），以及以Claude Code为代表的Agent时代。“AI要思考、要行动、要阅读、要推理，每一环都在进行推理（Inference）。现在已经远超训练阶段，进入了推理的疆场。过去两年，计算需求增长了约10,000倍，而使用量增长了约100倍。”

图：推理拐点到来



中国市场的数字尤为亮眼。报告引用火山引擎数据：豆包大模型日均Token调用量已于2026年3月突破120万亿，在过去三个月内增长一倍，相比2024年5月首次对外推出时，增长达1000倍。

图：豆包大模型日均tokens调用量（万亿）



出海方面，OpenRouter数据显示，2026年3月30日至4月5日，全球调用量排名前六的大模型均为中国AI大模型，合计周调用量达12.96万亿Token；4月6日至4月12日，TOP9大模型中，中国AI大模型的周调用量已连续六周超越美国。

Kimi的数据更为直观：截至2026年2月，其海外收入已超过国内收入；1月底至2月23日，近20天收入超过2025年全年。MiniMax则有约73%的收入来自国际市场。

表：国产模型海外表现亮眼

国产模型	海外业务表现
Kimi	截至2026年2月，公司的海外收入已超过国内收入。受Kimi K2.5模型及Kimi Claw火爆出圈带动，1月底至2月23日，Kimi近20天收入超过2025年全年。 2025年12月底至2026年3月14日，Kimi估值在不到三个月内翻了四倍，升至180亿美元。
Minimax	2025年MiniMax约73%的收入来自国际市场，共5766万美元，而中国内地的收入约为2138万美元，海外市场份额持续扩大。
智谱	国内头部互联网公司、海外主流应用、平台均在接入智谱模型，并逐步提升使用深度。 量价齐升本质是基模从工具走向生产力基础设施过程中的自然结果，趋势具备延续性：一方面，模型能力向更复杂维度推进，新使用场景持续被打开；另一方面，企业级应用仍处于早期阶段，用户数和单用户使用深度均有提升空间。

报告认为，“智能体、多模态生成等高频场景持续增加，直接带动Token需求量级式增长”，国产大模型有望形成“应用普及—调用提升—模型优化—生态扩张”的正向循环。

量价齐升：云厂商集体涨价，供给收紧逻辑获验证

需求爆发叠加供给收紧，推动算力服务进入涨价周期。

国内方面，报告梳理了三大云厂商的涨价动作：



腾讯云：3月13日起，GLM 5、MiniMax 2.5、Kimi 2.5三个模型结束限时免费公测，转为正式商用；混元系列模型Tencent HY2.0 Instruct与Tencent HY2.0 Think的价格涨幅超400%。5月9日起，AI算力、容器服务及弹性MapReduce（EMR）相关产品刊例价上调5%。

图：腾讯云混元系列模型涨价详情

模型名称	输入/输出	调整前价格 (元/千 tokens)	调整后价格 (元/千 tokens)
Tencent HY2.0 Instruct	输入	0.0008	0.004505
	输出	0.002	0.01113
Tencent HY2.0 Think	输入	0.001	0.0053
	输出	0.004	0.0212

阿里云：4月18日起，平头哥真武810E等算力卡产品上涨5%-34%，文件存储产品CPFS（智算版）上涨30%。5月15日起，对部分MU（Model Unit）模型单元的服务价格进行2%-7%的上调。

图：阿里云近期价格调整

调整内容		地域	调整幅度
平头哥真武810E等算力卡相关服务		全地域	上涨5% - 34%
CPFS（智算版）		全地域	上涨30%

计费模式	产品型号	上架规格	售卖单位	原单价	调整后单价	调整幅度
包年包月	III 型模型单元	MU3	元/个/月	63,000	65,969	↑约5%
	IV 型模型单元	MU4	元/个/月	19,000	19,914	↑约5%
	V 型模型单元	MU5	元/个/月	9,500	10,139	↑约7%
按量计费	III 型模型单元	MU3	元/个/小时	131	137	↑约5%
	IV 型模型单元	MU4	元/个/小时	40	41	↑约2%
	V 型模型单元	MU5	元/个/小时	20	21	↑约5%

百度云：4月18日起，AI算力相关产品服务上涨约5%-30%，并行文件存储等上涨约30%。

海外方面，亚马逊1月22日宣布对用于大模型训练的EC2实例实施15%的价格上调；谷歌1月27日宣布对AI和计算基础设施等服务进行价格上调，最高涨幅达100%。

报告指出，“此轮调价非单一厂商行为，是行业供需格局变化的明确信号，量价上行具备较强持续性”。

供给端还有一个新变量：DRAM和NAND内存价格上涨加速。报告援引SemiAnalysis数据，2026年Q1 LPDDR5和DDR5的合同价格预计将分别同比上涨约4倍和5倍。OEM厂商因此大幅上调AI服务器价格，“服务器采购成本的上升压缩了项目预期回报，迫使部分运营商放缓甚至放弃部署计划”，租赁市场供给或因此进一步收紧。

图：LPDDR5和DDR5合约价格在2026Q1分别实现约4倍和5倍的同比涨幅

B300 Liquid Cooled Chassis BoM									
Component + Warranty	Quantity	September BoM		December BoM		Current BoM		4Q26 BoM	
		Unit Cost	Extended Price	Unit Cost	Extended Price	Unit Cost	Extended Price	Unit Cost	Extended Price
CPU DDR5 RAM (per GByte)	3,072	\$4.0	\$12,288	\$8.0	\$24,576	\$14.0	\$43,008	\$21.7	\$66,601
Local NVMe Storage (per TByte)	30	\$80	\$2,400	\$120	\$3,600	\$156	\$4,680	\$156	\$4,680
Total Cost									
% Difference vs Sept					3%		8%		14%

国内企业：融资扩张加速，算力集群布局提速

行业高景气下，国内代表企业正同步加大融资与采购力度。

报告梳理了截至2026年4月21日的融资进展：

- **协创数据**：2025年累计申请授信额度不超过515亿元，2026年已累计申请不超过500亿元；赴H股上市备案申请材料已获证监会接收。
- **宏景科技**：2025年综合授信额度200亿元，2026年拟申请600亿元；拟定增12.90亿元，其中9.90亿元用于智能算力集群建设及运营项目。
- **盛视科技**：2026年已累计申请授信额度不超过230亿元。
- **利通电子**：已成功发行2亿元科技创新债，募集资金专项用于算力设备及备件采购。
- **智微智能**：2026年已申请授信额度不超过140亿元。

表：国内代表企业融资进展梳理（截至2026年4月21日）

	融资进展
协创数据	2025年度累计申请授信额度不超过515亿元，2026年已累计申请授信额度不超过500亿元。 - 赴H股上市备案申请材料获证监会接收。
宏景科技	2025年度累计申请综合授信额度200亿元，2026年拟申请综合授信额度600亿元。 - 拟定增12.90亿元，其中9.90亿元拟用于智能算力集群建设及运营项目。
盛视科技	2026年已累计申请授信额度不超过230亿元。
利通电子	- 拟申请注册发行不超过6亿元（含）超短期融资券及不超过6亿元（含）中期票据。 - 已成功发行2亿元科技创新债，募集资金专项用于算力设备及备件采购。
盈峰环境	拟申请注册发行不超过6亿元（含）超短期融资券及不超过24亿元（含）中期票据。
智微智能	2025年度拟申请授信额度不超过90亿元，2026年已申请授信额度不超过140亿元。

报告认为，“稳定的采购渠道叠加大额融资支撑设备投入，即可快速落地算力产能，依托行业长约锁定，业绩增长具备强可预见性”。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

119 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论