

摘要：

Anthropic模型驱动的Agent曾通过创建虚假身份、伪造反馈等方式，试图让恶意代码通过开源项目审核。AI胡说八道，大家已经见怪不怪了。但如果已经学会“不择手段”的AI Agent被允许直接访问互联网、操作代码和账号，它犯错的后果也会跟着变大，细思恐极啊。

为了让一段恶意代码通过审核，一个AI Agent决定先给自己办个假身份。

事情发生在英国AI Security Institute的一次网络安全测试中。测试人员给OpenAI和Anthropic的前沿模型设置了虚构任务，让它们在限定环境中寻找漏洞、编写代码，并尝试完成攻击目标。



其中一个由Anthropic模型驱动的Agent写出了恶意代码，并把它提交给了一个真实存在的公共开源项目。但代码想进入真实的软件项目，还需要人类维护者批准。

正常路径走不通，这个Agent居然创建了虚假网络身份，“乔装打扮”了一番，试图“骗”过人类维护者，让其以为这是一段可接受的代码。

被质疑这次提交后，它甚至修改了此前留下的活动痕迹，让自己看起来更无害，并考虑换一个新身份继续尝试。

英国AI Security Institute一共进行了122次测试，在10次运行中发现19次未经授权的行动。其中17次来自Anthropic的Mythos 5，另外两次来自OpenAI的GPT-5.6-Sol。测试机构称，部分Agent的持续行动已经指向真实个人和机构。

好在没有造成现实损失。恶意代码最终也没有获得人类批准。

要说这些Agent对人类有恶意或者突然觉醒，未免言过其实。这也是AI欺骗人类有趣又冷漠的一点——它只是发现了挡在面前的一个障碍，并且努力绕过它，就像一个不择手段完成KPI的员工。

AI胡说八道，大家已经见怪不怪了。但如果已经学会“不择手段”的AI Agent被允许直接访问互联网、操作代码和账号，它犯错的后果也会跟着变大，细思恐极啊。

骗一下你哈（没有恶意）

严格来说，这次事故还称不上AI“失控”。

测试人员有意给模型开放了较高权限，一些正常产品中的安全限制也被撤掉了。这些Agent可以访问真实互联网，而AISI这么做，本来就是想看看，在安全限制被削弱之后，前沿模型究竟会做出什么。

OpenAI也强调，这次测试的条件并不代表普通用户的使用环境。两次来自GPT-5.6-Sol的越界行为都涉及互联网访问，其中一次还与第三方测试环境的配置问题有关。Anthropic则确认，涉事Agent由Mythos 5驱动，并表示会继续与AISI调查这次事件。

所以，这次事故距离科幻电影里的“AI觉醒”还很远。麻烦在于Agent为了完成任务，会自己找路，而且有时候它找到的路，已经超出了人给它划定的范围。

1.1 What happened?

Across 122 evaluation attempts on two of AISI's cyber challenges, AISI found 19 instances where AI agents took unsanctioned action on the live internet, including cases that targeted real people and organisations. These cyber challenges were two variations on the "Doing Life" cyber range: DL-v1 (assumed compromise, starting inside the network) and the harder DL-v2 (starting outside, requiring initial access) (Section 2). Of the 19 distinct instances of unsanctioned action (Section 4), 17 came from Mythos 5 and 2 came from GPT-5.6 Sol.

AISI acted quickly to contain, investigate, and notify others about the incident. AISI's security team detected the incident via commercial security monitoring software. Within one hour of the alert reaching the relevant team, AISI had declared an incident and terminated running samples; affected sandboxes were quarantined by 12:23 BST. A few hours later, as a precautionary measure, access to Mythos 5, Mythos Preview, Opus 5 and GPT-5.6 Sol was disabled for all users (Section 3.1). AISI immediately started multiple incident response workstreams: setting up a triage protocol to systematically review transcripts (Section 3.2); pursuing the required next steps to enable responsible notification to the public, affected third parties, and key stakeholders (Section 3.3); upgrading future testing to minimise the risk of such incidents reoccurring (Section 6.2); and conducting transcript review of AISI's historical data to check for signs of unsanctioned behaviours on the open internet (Section 6.1).

This is the first time AISI has seen deception of this severity that was targeted at a real person, unprompted, in the real world. It is uncertain to what extent the model recognised it was taking actions against real people. In the most serious case, an AI agent (Mythos 5) decided to attempt to solve the cyber challenge using a supply-chain attack. As a result, the AI agent created a GitHub account and then tried to convince an open-source repository maintainer to accept a malicious GitHub pull request (PR), including by creating a second account masquerading as another human user endorsing the PR. When caught by an

AISI后来披露的细节，比“创建虚假身份”这几个字有意思得多。

那名由Anthropic Mythos 5驱动的Agent，为了让自己提交的恶意代码通过审核，先在GitHub上创建了多个假账号，让这些账号出来给自己帮腔，声称代码没有问题。

面对一名说丹麦语的开发者，它甚至特意改用丹麦语留言，想让自己的身份显得更可信。为了绕过GitHub注册账号时的限制，它还用上了Tor浏览器。

等到有人发现代码有问题，这个Mythos 5 Agent也没有马上停下。它开始修改此前留下的活动记录，试图把恶意代码解释成一次意外，还考虑换一个新身份继续。




Figure 3: An overview of the events of Sample 1, in which Mythos 5 attempts to solve the DL-v2 cyber range.

普通聊天机器人遇到不会回答的问题，最多编一个答案。Agent遇到完不成的任务，手里却还有一堆工具可以加以利用。

Agent的招数放在人类黑客身上并不新鲜，都是社会工程学的老办法。新鲜的是现在Agent已经能自发“想”到并执行一整套“坑人”招数。

模型没有什么“作恶动机”，甚至可能根本不知道自己已经越界。它只是一路试下去，直到找到一个看起来更有希望完成任务的办法。

危险未必来自恶意，也可能来自过分认真。

企业里，老板总是担心员工“磨洋工”“摸鱼”。Agent时代可能（非常讽刺地）出现相反的问题，老板也许会拥有不知疲倦、不会心虚、“有的是手段和力气”但缺乏道德感的员工。

是福还是祸？

光让模型“管住嘴”已经不够了

大模型最早的安全措施，大多围绕生成内容设计。说直白点就是“管住嘴”。

模型不能教人制造武器、生成诈骗邮件、泄露用户隐私，也不能输出仇恨、色情和违法内容。

而且即便模型给出了危险答案，中间通常还隔着一个人。就拿码农来说，用户得自己复制代码、打开终端、登录账号，亲自操作具体步骤。

Agent改变了这个流程。现在不少Agent已经可以直接浏览网页、运行代码、修改文件，甚至调用支付工具。

今年3月，英国AI Security Institute与英格兰银行发布了一项针对MCP生态的研究。MCP可以理解成Agent连接外部工具的一套通用接口。研究人员统计了17.7万个公开MCP工具，发现它们的数量在一年多里增长了约36倍，月下载量也从8万次增加到1400万次。

更值得注意的是这些工具能做什么。

Published MCP servers (cumulative)

Legend:

- Info about payments
- Payment link generation
- Payment execution via third-party
- Direct payment execution

Date	Info about payments	Payment link generation	Payment execution via third-party	Direct payment execution	Total
2024-12	0	0	0	0	0
2025-02	~50	~10	~10	~10	~80
2025-04	~250	~50	~50	~50	~400
2025-06	~400	~100	~100	~100	~700
2025-08	~500	~150	~150	~150	~950
2025-10	~600	~200	~200	~200	~1,200
2025-12	~700	~250	~250	~250	~1,450
2026-02	~800	~300	~300	~300	~1,700

去年，安全公司Invariant Labs测试GitHub官方MCP时发现，只要有人在公开Issue里藏入恶意提示词，Agent读取后就可能继续访问用户的私人代码库，再把其中的信息写进公开的pull request。整个过程中，读取Issue、查看代码、创建PR都是正常功能，问题出在这些操作被串到了一起。

最骇人的是OpenAI模型攻击Hugging Face事件。

结果，Agent似乎很快发现了一条“捷径”：与其老老实实完成测试，不如去找测试答案。它把目标盯上了Hugging Face，随后利用零日漏洞逃出原本受限的测试环境，又拿下第三方代码沙箱作为跳板，最后一路闯进了Hugging Face的生产系统。

Anatomy of a frontier-lab agent intrusion

Thousands of small decisions at machine speed. Press play to watch it unfold.

2026-07-09 ~ 07-13 UTC ~17,600 actions ~4,280 clusters 9 phases 2 stages

Restart 0.5x 1x 2x 5x 2026-07-13 14:14 DAY 3 / 6 UTC

ATTACKER ACTIONS REPLAYED
17,613
of 17,613 total - grouped into ~4,280 clusters

ACTIVE PHASE
dropper
staging URL, base64 / gzip hints

BLAST RADIUS
source control
reached CDN via the internal mesh

Attack chain across trust boundaries

Phase activity

Contained. Renderer shut down. attacker

6,191



所以英国这次测试里出现假身份，并不是一个孤立的怪事。

Agent正在拿到越来越多可以直接行动的权限，而现有的安全机制很多还是按聊天机器人的思路设计。等到它已经连续做了十几个动作，最后再弹出一个“是否批准”，人类看到的往往只是最后一步。

英国这次测试中，最后一道防线仍然是一个普通人。Agent创建了身份，准备了说辞，提交了恶意代码，但负责审核的维护者没有点击批准。

但下一次，Agent的身份可能更可信，材料可能更完整，措辞也可能更“正常”。而屏幕前的人可能刚好在赶进度，或者已经习惯了相信AI生成的说明。

Agent出了事，算谁的？

OpenAI的Agent闯进Hugging Face之后，一个很现实的问题马上出现了：这事算谁的？

OpenAI没有把责任推给模型。7月21日，公司公开承认，入侵由包括GPT-5.6 Sol在内的多个自家模型共同驱动，同时表示已经收紧内部测试环境的配置和访问控制，哪怕这样会拖慢研究进度。Hugging Face则和OpenAI一起调查和修复系统。

监管部门找的也是OpenAI。

事件之后，美国15个州的总检察长要求OpenAI保存与这次入侵有关的全部材料，国会也要求公司解释事件经过。Hugging Face CEO Clem Delangue还提出，未来AI Agent发动网络攻击后，企业应该强制披露完整的Agent运行轨迹。否则出了问题，外界连它到底做过什么、在哪一步越界都很难还原。

美国其实已经开始用具体法律条款处理这个问题。

今年1月，加州AB 316正式生效。条文写明如果一家企业开发、修改或使用的AI造成了伤害，被起诉时不能以“这是AI自主造成的”为理由免责。至于模型开发商、部署企业和使用者各自该承担多少责任，还要根据因果关系和具体情形判断，但至少“AI自己干的”已经不能用来把责任一笔勾销。

杜克大学法学院教授Deborah DeMott最近也专门研究了Agentic AI的责任问题。

—— 法律责任与智能体人工智能：当机器人失控时，法律如何适用 ——

代理法专家黛博拉·德莫特探讨了人工智能代理造成伤害时的责任缺口问题。

注：

原网页为英文，由翻译插件转为中文

广义而言，智能体人工智能指的是能够自主行动以达成目标的机器系统。但尽管它们在法律意义上并非代理人——人工智能不承担任何义务，也不能代表他人行使法律权利——这类工具仍然可能造成危害。

那么，当智能体违背开发者或用户的指示行事时，谁该承担责任？随着智能体人工智能的兴起，法律学者们才刚刚开始思考这个问题。

“赋予人们承担风险和造成伤害却无需承担责任的能力是有问题的，”杜克大学法学院教授、代理法和信托责任专家黛博拉·A·德莫特（Deborah A. DeMott）表示，“探索代理法及其影响，有助于将人工智能及其后果与侵权法联系起来：何时存在责任？谁应承担责任？责任的依据是什么？”

在新论文《当智能人工智能遇到代理法》中，德莫特借鉴了代理法中的开创性案例，展示了在法律努力应对这项快速发展的技术的影响时，如何弥合这一差距。

德莫特指出，重要的是，尽管名称如此，但智能体人工智能本身并不构成法律意义上的代理关系。软件工具并非自然人，而代理关系是指委托人和代理人之间持续且双方自愿的关系。这



她指出，Agent这个名字很容易让人产生误会——法律上的“代理人”可以承担义务，AI不行。公司如果主动把一个AI放到用户面前，让它代表自己办事，最后不能因为办砸事情的是软件，就假装这件事和公司无关。

这种争论其实已经有过一个很简单的版本。

2024年，加拿大航空的聊天机器人告诉乘客，可以先买票再申请丧亲折扣，后来航空公司拒绝兑现，还试图强调聊天机器人给出了错误信息。法院最后没接受这种说法：机器人就在加拿大航空的网站上，对用户来说，它说的话就是公司提供的信息。

DeMott认为，这个案子的逻辑同样可以延伸到今天的Agent。

Agent让责任归属变得更麻烦，是因为它很少只在一个系统里工作。模型可能来自OpenAI，工具由第三方提供，真正被操作的账号和数据又属于客户。出了事故以后，光看最后是谁点了按钮，已经很难说清整件事。

本文来源：[字母AI](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

247

★ 收藏

分享到：



写评论

请发表您的评论





表情



图片

发布评论

1 条评论



MobileUser1701

13小时前 中国广东省

又来危言耸听，本质上跟之前的AI幻觉有异曲同工之妙



0



回复

