

摘要：

企业AI支出正从狂热转向理性。一家神秘公司月耗5亿美元Claude账单，亚马逊则因员工为冲榜滥用AI而取消内部工具排行榜。微软收缩Claude Code授权，Uber四个月烧光全年预算。黄仁勋“多用Token即省钱”的Token经济学，正被一张张巨额账单和低ROI的现实挑战。

Token经济学，可能并不经济。

(除了AAAAA显卡黄总)

最近，Axios爆出一个挺逆天的事儿：一家企业，一个月就烧掉了5亿美元的Claude账单，合人民币34亿元。



原因嘛，就是老板给员工开通了Anthropic的企业授权之后，忘了设置用量上限，然后token就一直烧烧烧.....

烧了一个月，34个小目标就这么水灵灵地出去了。


咱先不说烧得值不值，如果按Anthropic目前约470亿美元的年化收入（ARR）计算，相当于这一家公司，一个月就贡献了Anthropic接近八分之一的月收入。

换句话说，Anthropic每赚8块钱，其中就有1块来自这家公司。

更夸张的是，这家公司至今没有公开身份。

但Axios在报道里提到，能够“无痛”吞下5亿美元AI账单的企业，全球其实也没多少家。

很快，X上开始出现各种猜测，其中被点名最多的是亚马逊。



巧的是，就在几乎同一时间，《金融时报》披露，亚马逊已经取消内部AI使用排行榜，因为员工开始为了冲榜而疯狂刷Token，甚至执行大量没有实际价值的任务。

这一前一后两条新闻放在一起看，味道就有点不一样了。

过去两年，企业最担心的是员工不用AI。而现在，越来越多企业开始担心另一件事：

AI是不是用得太多了。


美国大厂，开始算账了

这种变化，最近正在越来越频繁地出现。

微软就是一个典型例子。

最近，微软宣布将在6月30日之前取消Experiences + Devices部门（负责Windows、Microsoft 365、Outlook、Teams、Surface）的大部分Claude Code授权，工程师们被要求迁移到自家的GitHub Copilot CLI。

Microsoft starts canceling Claude Code licenses



/ Thousands of Microsoft developers will use GitHub Copilot CLI instead

by Tom Warren
May 15, 2026, 3:00 AM GMT-8



25 Comments (All New)

公众号 · 量子位

而Claude Code进入微软内部，距离现在不过6个月。



微软给出的理由很符合硅谷传统——

Claude Code已经完成了帮助团队学习和探索的阶段，是时候回到“Eat Your Own Dog Food”，使用自己的产品了。

但无论如何，Token账单都是绕不开的话题。


类似的变化，也出现在DeepSeek身上。

今年4月发布V4时，DeepSeek在技术报告里提到，V4已经成为公司内部员工日常使用的Agentic Coding模型，体验优于Claude Sonnet 4.5，交付质量接近Opus 4.6。

虽然官方没有明确提及成本因素，但对于拥有自研模型的公司来说，用自己的模型完成同样的工作，显然是一个更经济的选择。

如果说微软和DeepSeek还算委婉客气，那么Uber则说得更加直接。

Uber CTO Praveen Neppalli Naga今年早些时候透露，公司工程师仅用4个月就烧完了全年Claude Code预算。



随后，Uber首席运营官Andrew Macdonald公开表示：**AI Token消耗与最终发布的有价值产品之间，似乎并不存在明显的线性关系。**

换句话说，花掉更多Token，并不一定意味着创造出更多价值。

AI

Uber's COO says it's getting harder to justify the money spent on AI tokenmaxxing

By Aditi Bharade + Follow



号 · 量子位

类似的反思，也开始出现在更多公司内部。

此前，多邻国曾计划将AI使用情况纳入员工绩效考核。但在员工质疑“是否必须为了使用AI而使用AI”之后，公司最终撤回了这一决定。

“感觉我们不是在为实际结果负责，而是在试图强推一些并不总是适合的东西。”

今年4月的一档播客中，多邻国CEO路易斯·冯·安如此总结。

Meta的变化则更具代表性。

在被曝出内部建立Claude使用排行榜、单月消耗数十亿Token后，Meta也逐渐开始收紧相关激励，从鼓励“多用、多刷”，转向更关注实际产出。

与此同时，国内也出现了类似声音。

米哈游郑银河曾分享过一次经历：某个Agent项目上线后，一晚上烧掉了200万元Token费用。

这笔学费不算便宜。但它也让越来越多企业意识到一个问题：Token本身并不是价值，完成任务、交付产品、创造收入，才是价值。

可以说，企业依然相信AI，只是相比去年，它们开始不再单纯追求消耗更多Token，而是开始认真计算每一个Token背后的ROI。

AI第一次变成了财务问题

毫无疑问，在经历了大半年的“黄氏Token经济学”之后，美国大厂开始认真反思：

这些Token，到底花得值不值？

今年3月，黄仁勋在《All-In Podcast》中曾为这套逻辑公开背书。

如果一个年薪50万美元的工程师每年消耗的token不到25万美元，他会深感担忧。

在当时，这句话被很多企业奉为圭臬。

毕竟，如果AI真的能提升工程师效率，那么多烧一些Token，本质上是在购买生产力。

用的越多，省得越多就是这么来的。

但问题在于：当一张张真实账单开始寄到企业手里时，事情开始变得没那么简单。

无论是Amazon取消排行榜，微软收缩Claude Code授权，还是Uber发现工程师4个月烧光全年预算。

老板们最终还是选择了用脚投票。

最近，关于这件事的讨论也开始在Hacker News上发酵。

有人认为，这是一个重要转折点。

过去那种把Token消耗量等同于AI采用率、甚至等同于生产力的狂热阶段，正在结束。

▲ imglorp 3 days ago | prev | next [-]

This is an important inflection point.

这是一个重要的转折点。

When tokens get correctly priced, all of the insane over-investment in capital will need to draw back: buying data centers, semiconductors, and politicians.

当代币定价得到正确时，所有疯狂的资本过度投资都将需要收回：购买数据中心、半导体和政治人物。

Even then, it won't be right-priced with regard to actual costs. The environmental impact should have been priced in from the beginning. There seems to be a parallel with subsidizing fossil fuels, under pricing them which encourages over dependence, ignoring the real costs society will pay later.

即便如此，实际成本也不合理。环境影响从一开始就应该被计入。这似乎与补贴化石燃料、压低价格、助长过度依赖、忽视社会未来实际成本有相似之处。

reply

也有人把矛头直接指向了过去半年流行的“Tokenmaxxing”文化。

（注：Token是大语言模型处理文本的基本单位，也是计费单位。Tokenmaxxing指的是企业和员工疯狂追求token消耗量，把“烧了多少token”当成AI采用率和生产力的衡量指标。）

在他们看来，问题并不在于AI，而在于企业把“烧更多Token”误当成了目标本身。

如果使用更高效的模型、合理控制Agent工作流，或者让人类参与关键决策，成本本可以低得多。

▲ CuriouslyC 3 days ago | prev | next [-]

This is almost entirely on Anthropic and the stupid C suite people trying to push TokenMaxxing. GPT5.5 is much more token efficient, other models are much cheaper, and if used in moderation rather than trying to get everyone to OpenClaw 24/7 with token leaderboards, it's much more economical.

这几乎完全是 Anthropic 和那些愚蠢的高管们推 TokenMaxxing 的责任。GPT5.5 的代币效率更高，其他模型成本更低，如果适度使用，而不是试图让所有人全天候通过代币排行榜让所有人都去 OpenClaw，成本也更低。

Also ironically, a lot of Gen Z and young Millenials who were already bitter at their employers have used the tokenmaxxing push to sabotage the AI rollouts by burning tokens on stupid shit. It seems to be working.

讽刺的是，很多本就对雇主心存怨恨的 Z 世代和年轻千禧一代，利用代币最大化的推动，通过在愚蠢的事情上烧代币来破坏 AI 的推广，看起来效果不错。

当然，也有人开玩笑说：

这场运动最大的赢家，从头到尾可能只有黄仁勋。

▲ customguy 3 days ago | root | parent | next [-]

> The more tokens you burn, the more demand for hardware there will be. More demand for hardware means higher stock prices -> more money in your employer's pocket.

> 你烧毁的代币越多，对硬件的需求就越大。硬件需求增加意味着股价上涨——>雇主口袋里的钱也更多。

If you work for NVIDIA, sure, but otherwise, this makes no sense to me.

如果你在 NVIDIA 工作，当然可以，但除此之外，这我就完全不明白了。

不过，另一种观点同样值得关注。



不少开发者认为，这并不是AI热潮退去的信号。

恰恰相反。

这意味着企业终于开始从“先用再说”，进入“精细运营”的阶段。



ajay kumar yadav 
@ajayJournalist_

Microsoft is canceling most Claude Code licenses in its Experiences + Devices division by June 30 and moving engineers to GitHub Copilot CLI due to high token costs. Uber did burn through its entire 2026 AI budget by April after 84% of engineers adopted Claude Code, with heavy users hitting \$500-2k/month.

These cases are real and show clear bill shock from usage-based pricing. However, this is enterprise cost optimization (shifting to owned tools), not **“the AI bubble bursting.”**

Microsoft isn't dropping AI it's moving spend in-house. Big Tech capex is still running at record levels (\$725B in 2026).

由于代币成本高昂，Microsoft 计划于 6 月 30 日前取消其 Experiences + Devices 部门的大部分 Claude Code 许可，并将工程师迁移至 GitHub Copilot CLI。Uber 在 4 月前已耗尽 2026 年全部 AI 预算，84% 的工程师采用了 Claude 代码，重度用户每月收入达到 500 至 2000 美元。

这些案例是真实存在的，明显显示了基于使用量定价带来的账单冲击。然而，这其实是企业成本优化（转向自有工具），而不是 **“AI 泡沫破裂”**。

Microsoft 并没有放弃 AI，而是将资金内部转移。大型科技公司的资本支出仍处于创纪录水平（2026 年为 7.25 亿美元）。

5:21 PM · May 25, 2026 · 3,321 Views

 公众号 · 量子位

未来大家关注的重点，可能不再是谁烧掉更多Token，而是谁能用更少的Token完成更多任务。

比如：更高效的Agent workflows；廉价模型处理简单任务；昂贵模型只负责关键决策；更严格的预算和权限管理。



Hue Chen, Retail CRE 
@Hue.Chen · May 25

There needs to be a middle layer that directs LLM usage to the right model. Less rigorous queries to go internal models or cheaper ones, save the Claude for the heavier lift.

需要有一个中间层，引导 LLM 的使用到合适的模型。如果查询不那么严格，可以做内部模型或者便宜的，把 Claude 留给更重的任务。

  公众号 · 量子位

本文来源：[量子位](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 142  收藏

分享到： 



写评论

请发表您的评论



表情



图片

发布评论

