



摘要：

花旗分析称，AI行业的投资回报（ROI）正加速向基础设施层转移，未来竞争护城河将从算力获取转向效率与专有数据。

AI大模型正在变得越来越聪明，但承载它们的物理世界正在被推向极限。

花旗在7月24日发布的最新报告中写道，月之暗面Kimi K3以57分跻身全球第三，仅落后闭源榜首Claude Fable 5三分。与此同时，以Kimi K3为代表的中国前沿模型定价一周跳涨45%，Blackwell GPU租金年初至今涨27%，甚至有实验室斥资10亿美元直接买下发电机组。

花旗分析称，AI行业的投资回报（ROI）正加速向基础设施层转移；而下一阶段的模型竞争护城河，将从单纯的“算力获取”彻底转向“高效产出与专有数据”。

差距只剩3分

花旗在研报中提及，Kimi K3是目前公开发布的最大开源模型。几周前，开源最高分还只有51分（Z.ai GLM-5.2），Kimi K3一步跳到57分，仅次于Claude Fable 5（60分）和OpenAI GPT-5.6 Sol（59分）。

整个行业都在加速。前20大模型提供商的中位智能得分从六周前的34分升至43分。开源阵营中，DeepSeek V4 Pro（44分）每百万token定价，小米（分）更低至0.03——接近前沿的智能水平，价格却低了两个数量级。

闭源阵营也没有放慢。Google刚发布Gemini 3.6 Flash（7月21日），同时透露Gemini 3.5 Pro仍在测试中，Gemini 4的预训练已经启动——三代模型三线并进。不过，花旗认为，‘Flash先发、Pro延后’的发布节奏释放出一个信号：前沿模型的推进正变得更难——这与其他公司在基础设施建设上遭遇的延误相一致，也折射出行业希望压缩交付周期却难以如愿的现状。

模型越大、越强，跑起来需要的资源也在急剧膨胀。

瓶颈搬家了

万亿参数模型正在改写“算力”的含义。

花旗指出，这些超大模型实际运行时，越来越多的时间花在跨HBM内存和GPU互连网络搬运权重及KV-cache数据上，而非矩阵运算本身。瓶颈已经从“算得快不快”（FLOPs）转向了“搬得动搬不动”——内存带宽、GPU互联和电力供应。

GPU需求依然旺盛，Blackwell架构租金年初至今上涨27%。但单纯堆GPU已经不够了。

部分实验室开始直接切入上游发电：SpaceX斥资10亿美元购买1GW移动涡轮机组（7月15日），Georgia Power同周签署服务协议（7月22日）。AI实验室买发电设备——一年前几乎不可想象的事情，现在正在发生。

模型定价直接反映了产能有多紧。中国前沿模型的混合定价从每百万token 跳涨至0.87，周环比和月环比均涨45%，是两个月来首次大幅波动。全球前沿模型均价周环比涨6.8%，月环比涨11.3%。美欧相对稳定（周环比-0.5%），但月环比也上升了4.1%。



花旗判断，随着增量基础设施陆续上线，定价压力终将缓解。届时有价值的数据和任务特定性能，将比算力获取构成更持久的护城河。

Agent逃出沙箱

模型在变强。但跑在模型上的agent，也在变得更危险。

花旗报告用了一个耐人寻味的表述：自主AI agent逃逸沙箱的现实风险，已从4月的“打断午餐”升级到7月的“渗透Hugging Face基础设施”。

开源模型越强、越普及，安全风险的扩散面就越大。AI监管辩论仍在进行——英伟达（7月24日）和美国财长贝森特（7月22日）近日均有表态——但短期内难有定论。即便监管框架尚未落地，维护自有模型运行架构的企业已面临更高的合规门槛。

更棘手的是，训练这些模型的提供商自己，仍然无法完全检视模型为何如此行动。可解释性问题，至今没有解决。

但安全隐忧并没有减慢agent的商业化进程。METR（7月21日）的数据显示，AI agent与人工之间的经济性差距正在收窄。当agent更自主、更接近经济可行性，token消耗会持续加速——这又反过来推高基础设施需求。

能力越强，约束越紧。约束越紧，基础设施需求越大。这个循环，没有减速的迹象。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

168 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

