

摘要：

AI推理基础设施服务商Baseten首席执行官透露，其云服务商已通知，英伟达B200 GPU租赁价格将于10月续约时上涨约94%，同时采购1000块GPU的交付周期已长达12至15个月。交付瓶颈与租赁涨价叠加，AI推理的算力成本正遭受系统性抬升。

AI推理基础设施市场正面临一轮显著的成本与供给冲击。

在美国知名风投机构Altimeter近期举办的活动上，AI推理基础设施服务商Baseten首席执行官Tuhin Srivastava透露，其云服务商已于今年5月提前通知，英伟达B200 GPU的每小时租赁单价将在10月合同续约时，从现行的2.63美元涨至5.10美元，涨幅约94%。

他强调，这一数字的关键不在于绝对价格水平，而在于其所折射出的供需失衡程度——云服务商提前数月主动报价，本身即表明在算力持续紧缺的背景下，需求方已几无议价空间。

与此同时，供给端紧张态势同样未见缓和。据Tuhin Srivastava介绍，当前采购1000块GPU的交付排期已普遍延至明年第二季度，等待周期长达12至15个月。交付瓶颈与租赁价格上涨形成叠加效应，企业即便加大投入，短期内亦难以通过采购途径补足算力缺口。价格上行与供给瓶颈双重挤压下，AI推理的成本正面临实质性抬升。

Baseten成立于2019年，总部位于旧金山，定位为生产级AI推理基础设施服务商，业务涵盖模型部署、管理、扩展与监控，提供多集群、多云环境的弹性扩展支持，并辅以性能研究与嵌入式AI工程服务。截至2026年1月，公司已完成D+轮融资，并获得英伟达战略投资。



Baseten首席执行官Tuhin Srivastava

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取



VIP会员·7天畅读卡 | 大师课·入门串讲

限免

写评论

请发表您的评论

 表情  图片

发表评论