摘要：

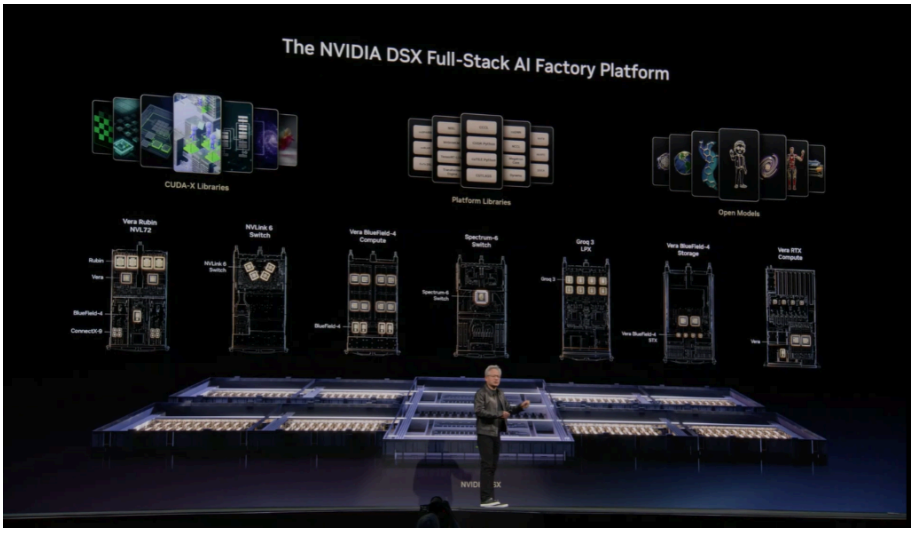
黄仁勋在柏林GTC大会密集发布新品，涵盖模块化AI工厂DSX Pod、智能体安全架构OpenShell、人形机器人参考平台及自动驾驶合作，并宣布过去一年在欧洲投资近100亿美元。他呼吁所有行业都成为AI公司，预测电信基站将演变为分布式AI网络。英伟达美股盘前一度涨逾2%。

英伟达首席执行官黄仁勋在柏林GTC大会上密集发布新品，覆盖AI基础设施、智能体安全、机器人与自动驾驶等多个领域，并向欧洲政商界发出强烈呼吁——所有行业都必须成为AI公司。

10月21日，英伟达首席执行官黄仁勋在GTC大会上表示，**未来所有电信运营商都将提供AI算力，电信基站有望演变为分布式AI网络。**他将AI经济描述为由能源、算力、AI工厂、模型与应用构成的五层结构，并在展示中突出指出，算力层仅出现英伟达一家公司的标志。

此次发布涵盖模块化AI数据中心产品DSX Pod、智能体安全架构OpenShell、人形机器人参考平台，以及涉及自动驾驶、癌症治疗和蛋白质设计等多个垂直领域的新品与合作。英伟达在活动中还宣布，过去一年已在欧洲投资近100亿美元，建立超过12000项合作关系。演讲期间一度被绿色和平组织抗议人士打断，黄仁勋称将事后与其沟通，随即继续演讲。

在当前部分投资者对AI基础设施投入规模日益质疑的背景下，黄仁勋发出明确看多信号。"欧洲要想从AI中受益，并真正建立起AI生态和AI经济，就需要所有终端市场、终端行业都采用AI，"他在演讲中表示，并点名汽车、金融服务和医疗保健行业。英伟达美股盘前一度涨逾2%。



DSX POD：将部署周期从六个月压至14天

英伟达发布的DSX POD是基于Vera Rubin架构的完整AI工厂参考设计。其核心逻辑在于，将计算、网络、布线、机架级供电及液冷系统的集成安装工作，从现场施工转移至制造工厂。合作伙伴在发货前完成机架间线缆连接、电气布线、管道安装和功能验证，集装箱运抵现场后只需接入预先准备好的电力、冷却与网络设施，即可投入使用。

黄仁勋表示：

> "AI工厂在开始生产token时创造价值，而不是在建设完工时。借助DSX POD，我们将工厂级精度和速度带入AI基础设施建设，把部署时间从数月缩短至数周，使客户能够更快扩展容量并让可

> 创收的生产上线。"

需要指出的是，14天指的是场地已完成准备情况下的现场部署时间，不包含从选址到建成的完整周期。客户仍需提前完成电力、冷却、网络等支持设施的准备工作。英伟达计划与戴尔科技、HPE、联想、Bull、施耐德电气、维谛技术等合作伙伴，于2027年初在全球交付基于DSX POD设计的模块化AI工厂。

在能效层面，DSX AI工厂平台采用闭环液冷和干式冷却器，将冷却用水量降至接近零，在2吉瓦规模下每天可节省高达5400万升水；DSX MaxLPS软件则可帮助运营商在相同token输出下减少最多30%的功耗。

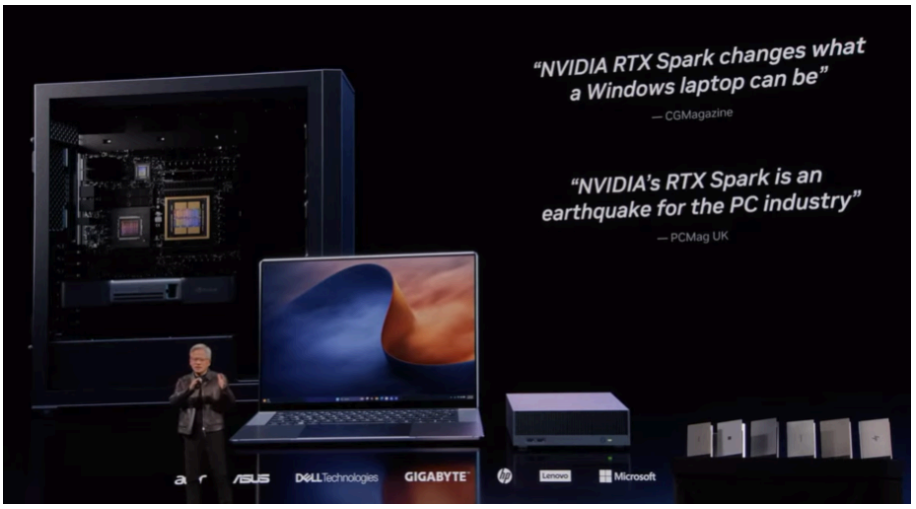


OpenShell：以硬件级隔离管控AI智能体行为

随着智能体部署规模扩大，英伟达推出OpenShell参考架构，专门应对智能体安全问题。该架构整合Vera Rubin基础设施、Vera CPU、BlueField-4数据处理器，以及OpenShell安全运行时软件，通过在系统调用、文件访问和网络连接粒度上执行策略，限制智能体可访问的资源范围。

核心机制是运行在BlueField-4上的NVIDIA Sentry安全框架，该框架在硬件隔离的可信域中持续监控智能体行为，一旦检测到异常操作，可在毫秒级将其隔离并切断其与模型的连接。英伟达称，Vera Rubin NVL72系统在智能体工作负载下的每兆瓦吞吐量可达此前的30倍，NVIDIA Sentry则可将智能体承载能力提升最多20%。

OpenShell采用Apache 2.0许可证开源，支持Linux、Kubernetes、微软Windows等企业环境，并可扩展至边缘设备。微软、谷歌云、戴尔科技、思科、OpenAI、Anthropic等已宣布参与相关合作，其中Anthropic与英伟达正合作开发Claude OpenShell智能体。



机器人与自动驾驶：多家欧洲车企及机器人公司加入生态

在物理AI领域，英伟达披露，今年上半年相关市场营收同比增长约30%，至约110亿美元。

在机器人方向，**英伟达宣布扩展Isaac开放机器人开发平台，推出开源运行时框架Isaac OS、机器人学习框架Isaac Lab 3.0，以及包含2000余种仿真就绪机器人和工厂资产的SimReady Central Library**。同时，英伟达与思灵机器人合作推出人形机器人参考平台Agile One SN，内置Jetson Thor计算硬件，预计明年第一季度上市。黄仁勋表示：

> "通用机器人正以惊人的速度进步——机器人的ChatGPT时刻正快速临近。"

在自动驾驶领域，沃尔沃汽车将采用英伟达Hyperion计算平台及Alpamayo自动驾驶软件栈开发自动驾驶汽车；大众将英伟达产品用于商用车；Bolt Technology则基于英伟达软件及硬件推进Robotaxi业务，计划2027年起在马德里采集真实驾驶数据，并规划在欧洲部署至少2.5万辆具备L4自动驾驶能力的车辆。此外，梅赛德斯-奔驰将利用Hyperion平台开发L3和L4级自动驾驶能力。英伟达还推出Halos SAFE安全评估框架，将仿真、软硬件在环测试、道路测试和车队监测纳入统一评估流程。



医疗与生物医药：从放射治疗到蛋白质设计

英伟达在医疗健康领域宣布多项合作。与西门子医疗旗下癌症治疗业务合作，探索将智能体AI、患者个体化仿真及实时计算应用于自适应放射治疗，相关系统将实时监测患者呼吸与体位变化并动态调整放射剂量。

在生物医药方向，英伟达与华盛顿大学医学院蛋白质设计研究所合作推出开放模型BioNeMo RFD4-Proteina，可根据分子输入、设计约束和评分目标生成并优化蛋白质设计方案，应用场景涵盖药物研发、疾病检测及工业酶开发。

开放模型与基础设施：布局欧洲本土AI生态

面向欧洲企业和研究机构，英伟达宣布扩充开放模型产品组合，新品涵盖Nemotron 3.5系列语言与视觉模型、面向结构化商业数据分析的Kumo模型、用于机器人训练与仿真的Cosmos世界模型、面向自动驾驶边缘推理的Alpamayo 2 Edge，以及用于量子计算的Ising模型。

黄仁勋将AI经济比作由能源、算力、AI工厂、模型与应用五层构成的结构，并指出欧洲AI基础设施建设正在加速。他预测，未来所有电信运营商都将提供AI算力，现有电信基站有望逐步演变为分布式AI网络。在合作伙伴层面，Nscale、Firebird等AI数据中心建设商，以及Mistral、Legora、DeepL等欧洲AI模型与应用公司，均被纳入其展示的AI经济生态图谱。

以下为黄仁勋在英伟达2026年柏林GTC主题演讲全文：

黄仁勋：

2020年，我们开始与梅赛德斯-奔驰合作开发自动驾驶汽车。回顾英伟达33年的发展历程，我在德国度过了很多时间。因此，我很高兴再次来到这里，也很高兴今年能在这里举办GTC。

过去一年，我们开启了一段新的旅程：在欧洲建设一个新产业，推动AI经济起步。

仅在过去一年，我们就在欧洲投资了近100亿美元，涵盖初创企业，以及遍布欧洲的大大小小的合作项目。

就在过去一周，我从法国、英国来到瑞典，再来到柏林。期间，我们宣布投资了14家初创企业。迄今为止，我们在欧洲建立了超过12,000项合作关系，大家都在朝着同一个目标努力。

计算机产业经过数十年的发展，如今，我们正站在一场新工业革命的起点。

这张图片是计算机生成的，提示词由我提供。我只是简单描述了“AI推动新工业革命”，再列出几家希望突出展示的合作伙伴，它就生成了这幅画面。

非常有意思的是，在AI的理解中，建设一个新产业，意味着生成Token、生产智能，再把智能融入每一个行业，推动新的工业革命。

当一项新技术改变了我们如何制造产品，以及我们能够制造什么产品时，一场新的工业革命就会发生。

我认为，人工智能将在各个方面影响我们制造的一切，并让我们能够创造过去无法创造的新事物。

每个人都会使用它，每家公司都会由它赋能，因为它是数字智能，是一切的基础。每个行业都会因此改变，新的行业也会诞生。

就像电力一样，AI将带来一场新的工业革命，而我们才刚刚起步。

问题是：什么是AI？

如果你希望参与创造这个未来，理解AI究竟是什么，至关重要。

我们很早就意识到，AI实际上是一个制造产业。

它不仅是一项软件技术。AI当然运行在计算机上，但这种计算机的运行方式已经发生了根本变化。它不再仅仅是供我们使用的工具，而是成为机器、基础设施和工厂的一部分，用来生产智能，再将智能融入每一个行业和应用。

一个简单的理解方式，是把AI看作一块五层蛋糕：

能源驱动先进计算机；这些计算机构成AI工厂；运行在工厂中的模型生成Token，也就是数字智能；这些智能再融入各种应用。

要参与AI经济，你不应该只消费AI，也应该生产AI。这些事情，我们都可以在欧洲完成，而且已经开始了。

欧洲正在建设自己的AI经济，图中展示的就是这五个层次。我们拥有出色的合作伙伴。观察这五层结构，你会发现，这确实是一个新产业，因为每一层都在增长。

我们正在以惊人的速度创造就业和增长机会。欧洲的施耐德电气、西门子、西门子能源等公司，在全球都有出色表现。

英伟达处于计算层，我们的技术被集成到欧洲各地不断涌现的AI工厂中。Nebius等新兴企业发展得非常好；一家名为Firebird的新公司正在中亚地区建设新的云平台，非洲也有Cassava这样的企业。

我预测，未来每一家电信运营商都会向AI转型。大量通信站点及数据中心构成的分布式基础设施，将演变为分布式AI网络。原稿所述规模为约10万个站点、约100吉瓦。

AI基础设施正在建设，其上才是AI模型。

必须认识到，在模型出现之前，基础设施就必须先存在。就像拥有互联网之前必须先建立网络，要享受电力的能力，必须先建设电厂、让住宅接入电网一样。

模型层也不只有语言模型，还包括生物、化学、物理、机器人动作和动画等模型，而且规模各不相同。

不同产业将由不同模态的AI模型驱动。这些模型进一步融入AI原生企业和初创公司，而欧洲有大量这样的企业。

欧洲的AI经济已经起步，而且正在加速发展。

谈到英伟达在底层的贡献，多数人首先想到的是GPU，这当然没错。

1993年，我们从图形芯片起步，后来发展出GPU和可编程着色GPU。随后，我们加入CUDA加速能力，重新定义了计算，并推动了人工智能的发展。

但今天的英伟达，实际上已经是一个覆盖全栈、端到端的完整AI工厂平台。多年来，我们的技术范围已经大幅扩展。

我们的技术包括GPU计算，最新一代是Vera Rubin；包括将多颗GPU连接成一颗巨大GPU的NVLink交换机；包括最近推出的Vera和BlueField-4，稍后我还会介绍。

还有我们的以太网解决方案Spectrum-X，它使英伟达成为如今全球最大的网络公司。

还有用于文本及Token生成的解码加速器Groq 3。

此外，还有基于Vera和BlueField-4的存储加速，以及Vera RTX计算。稍后我会分别介绍。

这些技术共同构成了建设AI工厂所需要的硬件体系，但如果没有软件将其激活，一切都无法工作。

首先是运行AI工厂的系统软件。

这些系统极其庞大。一座1吉瓦的数据中心，也就是一座1吉瓦的AI工厂，成本大约为500亿美元。这包括土地、电力、建筑，以及计算、网络、存储、供电和冷却设备。

所有设备连接起来，形成占地数英亩的AI工厂。仅仅让它启动并正常运行，本身就是一项壮举。

让这座工厂运转、投入使用并生产Token，需要海量软件，这是一项非凡的工程。英伟达提供完整的全栈软件。

其上是我们称为CUDA-X的库，也就是英伟达的算法体系。

从本质上说，英伟达是一家算法公司，我们设计芯片来加速这些算法。

其中之一是cuDNN。很多研究人员认为，这个库推动了现代AI的大爆发。

cuDNN之于AI，就像SQL之于全球数据库产业。它是面向特定领域的语言和库。

就像OpenGL和DirectX推动了实时计算机图形的发展，cuDNN推动了AI计算产业的发展。

除此之外，我们还有350个其他库。这些库才是公司的核心资产，覆盖计算光刻、信号处理、图像处理、数据处理、粒子、流体、稀疏求解器等广泛领域。

在座许多人的公司已经接入了这些库。

我们通过这种方式开拓新市场，将英伟达与各种算法连接起来，让大家以极高速度完成计算。

最右边则是模型。

模型是新的软件，也是新应用的引擎。它们建立在CUDA-X库之上，并与这些库协同工作。

英伟达一直在多个领域开发这些模型，它们将开启新的机会，稍后我会详细介绍。

回顾AI时代的各代产品，我们从Pascal开始。

基于Pascal的DGX-1，是世界上第一台AI超级计算机。我在十年前发布它，并将第一台交付给OpenAI，开启了他们的计算发展历程。

从Pascal到Volta、Ampere，再到很多人第一次听说英伟达时接触到的Hopper，然后是当前的Blackwell，以及如今已全面投产的Vera Rubin。

这是六代架构。每一代，我们都在推动技术进步。

过去十年，我们将AI性能提高了100万倍。

退一步想，如果只依靠摩尔定律，十年会发生什么？前五年提高10倍，后五年再提高10倍，合计约100倍。

而在同一时期，我们通过所谓的“极致协同设计”，同时在计算机架构和软件栈各层开展创新，优化算法、创造新算法，并设计相应架构来加速它们，最终将AI性能提高了100万倍。我们还会继续这样做。

这就是今天英伟达所构建的技术体系，也是我们帮助欧洲参与AI生态和AI经济的基础。

早期的Pascal、Volta、Ampere和Hopper，主要围绕GPU展开。我们创造了新的DGX形态。

到了Blackwell，我们向世界推出了首个机架级计算系统。

机架级计算把一整套系统变成一台巨大的计算机，或者说一颗巨大的GPU。

到了Vera Rubin，我们进一步扩展计算范围：不再只处理模型或大语言模型，而是处理整个智能体。

稍后我们还会回到这张图，但请记住：智能体需要思考，而模型承担的就是这部分工作。

感知、推理、规划和工具使用，都依赖大语言模型，模型也是为这些能力而设计的。

但智能体还需要一个运行框架，也就是Harness。你可以把它理解为数字智能体的外骨骼。

就像人有大脑，也有身体，智能体框架负责协调工作，让智能体能够调用记忆，包括活动记忆、工作记忆和长期记忆，并使用工具。

第三部分是处理知识的计算机，专门负责数据处理。

最后，还有一类专门运行CUDA-X库的计算机，负责执行工具。

这些计算机共同构成完整的智能体系统。

Vera Rubin已经全面投产。我们来看看实物。

这是我们打造的第一款没有外露连接线缆、采用100%液冷设计的计算机。它可以直接抽出来，非常方便。

这就是一台Vera Rubin计算机，这个单元有两颗GPU。

过去，组装一个Grace Blackwell节点需要两个小时。你看过实物就会明白，到处都是线缆，它采用约80%的液冷设计。

现在，Vera Rubin实现了100%液冷，组装时间不到五分钟。

这是了不起的进步，意味着更短的制造周期、更高的可靠性，以及更好的性能。

这是NVLink交换机托盘。它将72颗GPU连接起来，形成一颗巨大的GPU。

每颗GPU的性能为20 PFLOPS，再将72颗连接成一个庞大的系统。

这是我们的新款Vera计算机。

[现场出现插话]

没关系，温和一点，让她有机会说话。每个人都有表达的机会。不过今天，先让我完成演讲，我稍后会和你们交流。

这些都是重要的问题，但请让我先讲完主题演讲。

这个会场已经坐满，全球还有100个同步观看活动，现在有15,000人正在观看。

最后我准备了一些非常有意思的内容。在娱乐环节到来之前，大家得先忍受一下我的知识讲解。

这是全新的Vera计算机。Vera CPU是一颗非常强大的处理器，每个时钟周期能够执行八条指令。

它采用了我们所说的全球首创LPDDR内存子系统，兼具高性能、极高带宽和出色的能源效率。

它的片上互连速度在全球芯片中处于领先水平，因此，数据处理，以及智能体会话的启动和执行性能，都非常出色。这正是它的设计目标。

这就是Vera计算机。

旁边这套是Spectrum-X，采用共封装光学，也就是CPO技术。我给大家看看。

舞台上有些地方是空的，有些地方可以踩，我不太确定分别在哪里。如果我突然消失了，大家要知道，那不是特技，是意外。

这里是激光器。光信号通过光学连接直接进入芯片。

我们与台积电共同开发了一项名为COUPE的工艺，让硅光子器件能够直接连接到芯片上。

否则，这一整块区域都需要通过印刷电路板传输信号，而电路板的传输能力远不如光纤。

现在，我们可以让极高数据速率、高质量的信号直接到达芯片，减少传统方案中通过电路板和收发器进行转换的环节。

这是我们的CPO产品，已经进入全面量产，提供512个端口，每个端口的速率为200Gbps。

这是全球最先进的以太网交换机，我们对此非常自豪。

这些系统让我们能够处理大语言模型的思考过程，运行智能体框架，处理智能体所需的知识数据，并通过加速计算运行各种工具。这些基本上构成了智能体的完整工作负载。

Vera Rubin已经全面投产，性能非常出色。

正如我所说，每一代产品，我们都通过极致协同设计，实现远超摩尔定律所能带来的性能进步。

大家知道，摩尔定律在很大程度上已经走到尽头。因此，我们需要从芯片到系统、从系统软件到算法，再到整个AI工厂，开展这种协同设计。

Vera Rubin在Blackwell的基础上又迈出了一大步。

在大语言模型处理方面，Blackwell的性能约为Hopper的30倍。而仅仅两年后，Vera Rubin又达到了Blackwell的约30倍。

接下来看看，Vera Rubin如何构成DSX全栈AI工厂。

视频旁白：

AI正在推动历史上规模最大的基础设施建设。

工厂规模庞大，投资金额巨大，我们必须把它建好。但只有优秀的芯片，还不足以构成优秀的AI工厂。

NVIDIA DSX是与全球领先基础设施企业共同开发的全栈AI工厂参考架构。

计算、网络、存储、软件、供电和冷却作为一个整体协同设计，从设计阶段到实际运营全面优化。

DSX从数字孪生开始。

在施工之前，先在虚拟环境中验证性能、功耗、用水量及扩展能力。

PTC将设备设计转化为可用于仿真的资产。

达索系统通过基于模型的系统工程，将机架设计与设施设计连接起来。

施耐德电气模拟配电和液冷系统。

Jacobs将这些内容整合进Omniverse数字孪生。

西门子评估热、声学及电网影响。

Procore支持施工阶段的规划。

电力决定AI工厂能够生产多少智能。

DSX Max LPS是一套端到端控制回路，能够根据工作负载需求动态分配电力，在实现相同产出的情况下减少30%的用电量。

DSX也重新设计了冷却方式。

NVIDIA Vera Rubin系统采用闭式液冷，在适宜气候条件下，冷却液温度可以高达45摄氏度。室外干式冷却器将热量释放到空气中，不需要蒸发水。

对于一座2吉瓦的设施，DSX每天可以节省5,400万升水，相当于18万户家庭的日用水量。

然而，建设AI工厂可能需要数月时间。在投运之前，它不会生产任何Token。

今天，我们发布NVIDIA DSX Pod，将这一全栈平台整合成在工厂内制造的一体化系统。

它以Vera Rubin NVL72为基础。

七个液冷计算机架，通过17公里的Spectrum-X线缆连接，构成一个Vera Rubin DSX Pod。

整个Pod在工厂完成集成、布线和测试，再装入可运输的集装箱交付。

干式冷却器取代传统蒸发冷却系统，800伏直流电直接连接机架，提高供电效率。

只要现场基础设施就绪，预计现场部署时间就能从数月缩短至数天。

NVIDIA DSX AI工厂从设计阶段就考虑资源效率和责任。现在有了DSX Pod，AI工厂的建设速度将大幅提升：每瓦电力产生更多智能，从交付到生成首个Token所需的时间也更短。

黄仁勋：

大家觉得怎么样？

2016年，我们发布了世界上第一台AI超级计算机。当时，它是一台单节点GPU系统。

三年前，我们推出了Grace Blackwell NVLink 72机架级计算机。

这两次创新，我们不仅重新设计了计算机、软件和运行方式，也重新设计了供应链。

以NVLink 72为例，过去整个机架需要在现场组装，现在我们把组装工作移到了供应链内部。

本质上，我们实现了超级计算机的规模化制造。

这正是我们能够如此快速行动，同时支持全球数百个数据中心建设项目的原因。

如今，全球所有主要计算机制造商都在制造NVLink 72。我们生产计算系统的规模，是过去从未有过、难以想象的。

即便如此，当这些系统运抵现场后，仍然需要数月时间进行组装。

刚才大家听到了，仅用于横向扩展计算的Spectrum-X连接，就需要17公里线缆。

假设我们把这些工作全部放到供应链内部完成：组装系统、启动运行、验证完整功能、完成质量认证和老化测试，确保出货时已经能够正常工作。

这样，现场布线和组装量就会大幅减少。

但更重要的是，数据中心里等待安装调试、无法投入使用的闲置算力，也会显著减少。

记住，每座1吉瓦数据中心的成本约为500亿美元，预期每年可创造数百亿美元收入。

假设这套基础设施每年能够创造400亿美元收入，仅仅延迟三个月，就意味着100亿美元收入推迟实现。这足以让任何人感到焦虑。

通过将这些工作转移到供应链内部，从计算设备到货、安装，到正式生产Token的时间，有望从四五个月缩短至大约一个月。

这将彻底改变全球供应链，也会改变人们安装和建设数据中心的方式。

我们希望，这能提高建设和投运速度，减少闲置算力及闲置资本支出的浪费，让所有参与者获得更好的盈利能力。

这就是将NVLink 72进一步集成为大型机柜系统的DSX Pod，也是英伟达计算系统发展的下一步。

你制造什么，以及如何制造，决定了你的独特之处。

就像欧洲企业，你们掌握的专业能力让你们与众不同：你们设计机器、运营工厂、发现药物，拥有非凡的工艺和专业知识。

英伟达的独特之处主要有两点。

第一，我们的架构是一种通用加速计算架构。

我们不只针对一种算法，例如Transformer，而是支持各种可以并行处理的工作负载，包括流体、粒子、量子计算、量子化学、图像处理、数据处理，以及结构化数据和向量数据处理。

由于我们长期投入，而且架构在过去约25年里保持一致，我们支持和加速的算法、领域及行业数量持续增长。

庞大的装机基础、通用架构、长期投入，以及与各行业的合作，让英伟达架构几乎无处不在。

第二，是我们的实现方式。

我们不仅开发架构，还将其构建成完整的全栈AI工厂。

世界上有不少公司希望自行设计芯片，但绝大多数公司只是希望部署AI基础设施，然后在其上运行自己的业务。

设计芯片、制造超级计算机、编写全部软件，对大多数企业来说都不是它们打算承担的工作。

因此，CUDA与全栈AI工厂的结合，使我们能够服务过去难以触及的市场。这也是我们能够与这里众多企业合作的原因。

从云服务提供商，也就是CSP开始，多数人认为今天绝大部分AI都集中在那里。但在演讲开头，我提到的很多公司并不属于传统CSP。

CSP仍然是全球计算市场的重要组成部分，但与此同时，世界各地正在涌现AI原生企业。

还有新型AI云服务商，也就是Neocloud。每个地区都希望参与AI经济，希望将自身拥有的宝贵资源和能源用于支持本地区企业。

例如法国的Mistral、欧洲的Nebius，以及欧洲各地建设新型AI云的公司。

还有为全球企业制造计算机的OEM和ODM厂商，以及AI实验室。

去年，我们大量讨论OpenAI；如今，除了OpenAI和Anthropic，还有Meta、Grok、Gemini等参与者，越来越多AI实验室正在推动前沿技术发展。

但最重要的是，如果AI要真正成功，如果欧洲要从AI中受益并建立完整的AI生态和AI经济，那么所有终端行业都必须采用AI，并通过AI取得成功。

无论是开发自动驾驶汽车的汽车行业、使用机器人进行制造的工业企业、通过AI发现新药的医疗行业，还是金融服务业，每个行业的企业都需要成为AI公司。

借助CUDA以及我们的计算机制造方式，我们能够服务AI的各个细分领域。

一种架构，覆盖多个市场。

这些基础设施规模巨大、成本高昂，因此必须尽快发挥最大生产力，而且能够灵活用于各种工作负载。

从AI旅程最初的数据处理，到训练、后训练、推理和智能体处理；从化学、物理到语言；从各个行业到它们使用的各种算法，都应当由同一套基础设施支持。

因此，英伟达架构具有很强的通用性和可调配性。

持续创新、持续软件更新，以及庞大装机基础所形成的丰富软件生态，又让这套架构具有长期使用价值。

通用、耐用、高效，这就是基础。

有了这些基础设施，我们能做什么？

过去一年，AI发生了转变，开始真正创造生产力。

其中一个重要时刻，是年初我们谈到OpenClaw，它将开源智能体的概念带给了更多人，也推动了如今全球正在发生的变化。

智能体会思考、推理、迭代和使用工具，因此会消耗大量Token。但也正因如此，它们开始真正有用。

更多智能体被开发出来，因为更有用，所以更多人使用；又因为思考需要大量Token，Token消耗迅速增长，GPU需求也随之大幅上升。

这张图展示的是一个智能体的五个组成部分。

第一是语言模型。模型运行在GPU上，生成供智能体使用的Token。

第二是我所说的“外骨骼”，也就是智能体框架，例如OpenClaw。

框架运行在沙箱内，沙箱将它与系统其他部分隔离。这是一个非常重要的概念。

另外两个部分是知识和工具。

模型、框架、沙箱、知识和工具，构成了智能体的五个要素。

在讨论如何让智能体变得有用之前，首先必须确保它是安全的。

智能体是自主系统，可以访问文件、资源、网络和工具。因此，我们必须赋予它最小必要权限，并持续监控其行为。

为此，我们推出了一个新平台：OpenShell。

OpenShell是一个安全运行时，提供刚才提到的能力，并可以配合额外的硬件监控机制。

在详细解释之前，我们先看一段视频。

视频旁白：

企业正在准备部署数十亿个AI智能体。

为了发挥作用，它们需要推理、规划、使用工具、访问数据并相互协作。

但如今，阻止智能体滥用这些能力的方式，往往只是告诉它：

“请不要删除任何东西。”
“请不要向主分支推送代码。”
“请不要碰我的SSH密钥。”

这就是“请不要”的安全方式。

但希望不等于安全。安全不是愿望，而是技术和工程。

NVIDIA OpenShell和Sentry将这一理念落实到实际系统中。

你为每个智能体编写策略，规定它可以接触什么。OpenShell在系统调用、文件访问和网络连接层面执行这些策略。

形式化验证会检查每一次策略变更，确保其不突破你设定的权限上限，使智能体不会获得超出预期的访问权限。

这类似于早期互联网：在浏览器严格限制网页能力之前，病毒曾经四处传播。OpenShell为智能体建立类似的边界。

这些限制在智能体之外执行，而不是只依赖大语言模型内部的护栏，从而将智能体原生安全能力引入基础设施。

每个智能体都运行在自己的隔离沙箱中，不能直接访问网络。

所有出站网络请求，都必须经过沙箱外的监督组件。监督组件根据策略检查请求，未获允许的操作会被拒绝。

密钥保存在沙箱外，由监督组件管理，只有向获准访问的端点发送请求时才会加入。即使智能体遭到入侵，也无法泄露它从未持有的密钥。

网关充当控制平面，监督组件负责作出决定，沙箱容纳智能体，策略证明器则检查拟议策略是否符合权限上限。

OpenShell将Linux内核隔离与运行时策略执行相结合。

NVIDIA Sentry还可以在主机之外、远离智能体的位置，增加一层可选保护。

Sentry运行在NVIDIA BlueField-4上，在硬件隔离的信任域中监控智能体活动并执行安全策略。

智能体的推理流量经过Sentry，因此一旦检测到需要阻止的计划，系统可以立即更新策略，切断智能体与模型的连接，在毫秒内完成隔离。

它还保留可验证、防篡改痕迹的记录，供运营人员进行检测、调查和响应。

OpenShell采用Apache 2.0许可证开源，可运行在智能体所在的各种环境中，从边缘到云端。只需两个命令即可开始使用：安装命令行工具，创建沙箱，然后运行你喜欢的智能体。

智能体能发挥多大作用，取决于你赋予它多少访问能力。OpenShell和Sentry让这些访问能力处于你的控制之下。

这就是我们同时推进AI能力与安全的方式。

黄仁勋：

智能体是自主系统。我们必须创造高度安全的技术，确保能够安全地开发和部署它们。

OpenShell发布后，从前沿模型实验室，到操作系统公司、网络安全公司和平台公司，许多大型企业都开始采用它。

因为这项技术到来的时机恰到好处：我们正准备在全球大规模部署智能体。

这不仅关乎服务提供商在部署智能体时使用OpenShell，也关乎世界各地的企业采用OpenShell，让这些智能体能够在企业内部自主运行。

不同能力、不同任务、不同使用者，对应不同的权限需求。每次启动智能体，所需要的权限可能都不一样。

因此，权限配置、策略执行和监控，都必须动态完成。

我很高兴宣布，Anthropic与英伟达正在合作，将Claude智能体与OpenShell结合。网站上有一篇很好的介绍文章。

你可以使用OpenClaw、Hermes、OpenHands，也可以通过LangChain、Deep Agents构建自己的框架，甚至直接用Python编写。

这些智能体框架都可以运行在OpenShell提供的安全沙箱中。

接下来谈模型。

未来，我们不会只用一个模型处理所有工作，而是会根据任务选择最合适的模型，无论它是闭源、开放还是定制模型。

有些工作相对通用，通用人工智能就能做得很好。

但另一些工作包含大量专有知识和专业能力，而且你希望持续提升这些能力。

因此，未来每家公司都会同时使用闭源模型，以及自行定制的开放模型。

到今天演讲结束时，大家会发现，构建自己的AI并没有那么困难。

首先当然是模型。

我们一直致力于推动开放模型的发展，开拓新机会，让大家能够构建自己的定制AI。

Nemotron面向语言。

Cosmos是我们的世界基础模型，我们在这一领域处于前沿。

GR00T面向人形机器人。

Alpamayo面向自主导航。

Ising面向量子—经典混合计算。

Earth-2面向物理AI。

在这些不同领域，我们都提供模型，并持续投入研发。我们已经做了十年，也会长期做下去。

我们不仅开放模型，还提供相关数据，让你了解模型的数据来源，并提供复现所需的脚本。

因此，你得到的不只是开放权重，而是完整的方法、数据和复现路径。你能够知道模型从何而来，并建立对它的信任。

这些模型未必在所有领域都是最前沿的，尤其是在语言模型方面。

但通过定制，以及与生态伙伴合作，你可以将它们提升到自己所需领域的前沿水平，把专有数据转化为自主掌握的智能。

例如，AI21帮助Alice将Nemotron定制为超越相关前沿能力的模型。

Baseten帮助CodeRabbit使用自身数据微调Nemotron，实现前沿水平的能力。

Trajectory与Harvey也通过对Nemotron进行后训练，构建自己的前沿能力。

Scale与Skydance同样在做这样的事情。

例子还有很多。

核心在于，你可以从Nemotron这样优秀的开放模型出发，用自己的数据针对特定用例进行后训练，从而获得高度专业化的智能。

这是一条非常合理的路径，所需技术今天都已具备。

这里还有Palantir与坦帕综合医院的案例。

我们拥有丰富的合作伙伴生态，能够帮助大家。这些都是出色的公司，可以为世界各地的客户提供服务。

我如果只提一家，就会漏掉其他伙伴；如果全部列出来，又要花很长时间。我非常珍视所有这些合作伙伴。

总结一下：首先，让智能体框架运行在OpenShell安全沙箱中；其次，选择Nemotron等大语言模型。

但真正让普通智能体变成“超级智能体”的，是让它访问你公司的知识。

我们将这套能力称为智能体知识基础。

它由一组世界级模型和工具组成，帮助你处理公司的各种数据资产。

数据可能以非结构化形式存在于文档中，因此需要AI理解PDF和其他非结构化文件；也可能以结构化形式存在于数据库中。

我们提供必要的库和工具，帮助你从企业数据中提取含义、形成理解。

Nemotron Parse负责文档解析，表现位居相关排行榜前列。

Nemotron Embed将查询与向量数据库中的知识关联起来，同样具有领先表现。

Nemotron Rerank则处理检索到的多个来源和数据片段，根据与查询的相关程度重新排序。

Kumo可以利用结构化数据库预测可能发生的事情。

举例来说，你收到供应商通知，某些物料将出现短缺或交付延迟。这条信息很可能是一份非结构化文档。

而公司订单信息通常保存在SQL等结构化数据库中。

如果要预测哪些订单会受影响、哪些会缺货、延迟多久，可以使用Kumo。

接下来，为了寻找替代零件，你可以使用向量数据库检索，找到相关替代部件的工程文档。

这些模型、库和数据处理能力，共同构成知识基础，让AI能够利用你的专有数据和专有知识。

最后是工具，也就是完成专业工作所需要的工具。

英伟达一直在开发CUDA-X。

在AI成为主要话题之前，我们的大量讨论都围绕着如何加速模拟器、求解器、数据处理引擎，以及各种领域专用库展开。

这些工具用于各个科学领域的发现，也用于工程、研究、设计、建造和创意艺术。

它们的核心是CUDA-X库，而CUDA-X库本质上是算法。大家知道，算法是美的。

我们来看一段展示。

数学很美。

CUDA-X库是我们公司的核心资产。原因在于，当你构建AI助手时，无论它是实验室助手、研究助手，还是与你共同设计和创造的伙伴，最终让它真正有用、能够完成实际工作的，都是工具。

现在，我们拥有能够让智能体理解信息、推理、规划，并不断采取行动、使用工具直到完成任务的模型。

但最终，仍然离不开工具。

这些工具，我们已经开发了很多年。

刚才展示的右侧那类计算机，可以运行所有这些工具，无论是流体动力学、粒子物理、量子化学、数据处理，还是光线追踪。

与直接在CPU上运行相比，它可以将处理速度提高10倍、50倍，甚至100倍。

CUDA-X给智能体提供了完成专业工作的能力。看到其他人如何使用这些工具，非常令人兴奋。

这就是智能体背后的关键。

智能体最终需要使用工具。

软件编程是最早采用智能体的领域之一，在那里，编译器或Python往往就足以完成很多工作。

但未来，随着智能体承担越来越多实际任务，我们需要为它们提供更多工具。

下面是几个例子。

Lila Sciences正在开发实验室助手，使用英伟达的BioNeMo模型理解蛋白质和细胞，并在药物发现中设计蛋白质及化学分子，同时调用CUDA-X工具。

西门子正在构建工厂智能体，使用理解物理世界的Cosmos世界基础模型，以及CUDA-X工具。

达索系统则在开发虚拟伙伴，使用Nemotron语言模型和CUDA-X工具。

来看看它们如何工作。

视频旁白：

最聪明的科学家仍然需要实验室，最优秀的工程师仍然需要模拟器和求解器，AI智能体也是如此。

一个智能体由五个部分组成：

模型负责感知、推理和规划。

框架负责协调工作。

知识基础从公司的结构化和非结构化数据中提供上下文。

工具让智能体能够模拟、实验和采取行动。

NVIDIA OpenShell控制智能体可以访问和执行什么。

你可以从前沿闭源模型开始，也可以定制开放模型。借助NVIDIA Agent Toolkit，任何公司都能将自身知识和专业能力转化为定制超级智能体。

来看三个例子。

对于Lila Sciences，目标是设计一种针对B细胞淋巴瘤的疗法。

基于Nemotron构建的Lila Iris智能体，将这一目标转化为实验计划。

在计算干实验室中，Lila智能体使用NVIDIA BioNeMo Agent Toolkit，调用蛋白质设计和RNA优化模型，运行数百万次虚拟实验。

最有前景的候选方案进入Lila的AI科学工厂，由借助Omniverse和Cosmos开发的自主机器人及仪器进行制备和测试。

结果返回Iris，影响下一轮设计和实验，形成持续迭代的闭环。

在西门子埃尔朗根电子工厂，目标是让新产品投入生产。

Process Preparation X智能体使用Cosmos生成虚拟原型和合成数据，在生产开始前训练并验证检测模型。

基于NVIDIA工厂运营蓝图构建的Intelligence Center X智能体，根据订单、物料供应和产线配置，提出生产计划建议。

Digital Twin Composer利用Omniverse库，将物理仿真与实时工厂数据结合，在实际调整生产现场之前验证这些计划。

在达索系统平台上，一位工程师需要将大众Golf的车门设计适配到Tiguan车型。

Aura和Leo使用Nemotron理解和推理工程要求。

智能体框架协调各个专业子智能体，并在规划、设计和仿真过程中保留上下文。

Aura使用ENOVIA，根据车辆尺寸、重量限制和其他工程要求规划工作。

Leo设计智能体选择兼容的Golf车门设计，再使用CATIA修改形状，使其适配Tiguan。

Leo仿真智能体使用由CUDA-X加速的SIMULIA测试不同方案，发现了振动问题。

结果返回设计智能体进行优化，工程师审核改进后的设计，并选择最终方案。

不同的目标，不同的专业知识，相同的基础组成：开放模型、CUDA-X加速工具，以及OpenShell安全运行时，通过NVIDIA Agent Toolkit整合在一起。

黄仁勋：

很棒，对吧？

有人说，AI来了，软件和工具公司的时代就要结束了。

事实恰恰相反。

AI到来后，使用这些工具的用户将比以往任何时候都多。

每一家工具公司都将成为AI公司、智能体公司。它们不仅提供工具，还会提供经过专门优化、非常擅长使用这些工具的智能体。

Cadence、CrowdStrike、达索系统，以及其他许多企业软件公司，都在构建智能体。我们很高兴与它们合作。[原稿名单中另有一家公司名称不清。]

构建智能体并没有那么困难。它有五个组成部分：模型、框架、OpenShell安全运行时，以及最重要的知识和工具。

模型和框架都有开放和闭源版本，而知识与工具属于你，代表你的专业能力。

这些事情如今都已能够实现。稍后我还会展示更多，但在此之前，先谈谈物理AI。

物理AI是AI的下一波浪潮。

它能够理解物理世界，并对其进行推理。因为物理世界多样、复杂，存在极其丰富的长尾情况，AI需要理解这些情况，再使用合适的工具与物理世界互动。

一谈物理AI，大家往往想到机器人。

但我最喜欢的应用之一，其实是移动通信基站。

它不是用摄像头、扬声器或麦克风，而是通过无线电波感知世界，处理信息并进行推理，再利用波束成形与世界互动。

因此，通信是一种非常适合AI的技术。

AI将彻底改变电信网络，大幅提高频谱效率。

就像我们在光线追踪上所做的一样：大家看到的图形采用完整光线追踪，而在引入AI之后，与过去认为必要的计算量相比，效率出现了百万倍量级的变化。

我们将为电信网络带来巨大的频谱效率提升。

除此之外，还将改变这些通信站点。原稿所述西方地区约有10万个站点，构成约100吉瓦的分布式数据中心基础设施，未来将演变为分布式AI基础设施。

我们很高兴与欧洲众多公司合作。

经过近八年的研发，就在上周，英伟达与诺基亚合作，在T-Mobile网络上完成了首次商用通话。

现在，CUDA已经能够执行传统通信处理。在此基础上，我们就可以进一步叠加AI能力，推动新的变革。

另一个让我非常兴奋的物理AI应用，是机器人辅助放射治疗。

在治疗过程中，肿瘤形状可能变化，人体也会移动。这套自适应放疗系统必须感知环境变化，识别肿瘤位置，精确分割目标，并据此准确引导放射治疗。

本质上，这是一种机器人化治疗。

当然，大家最熟悉、近期最有望实现大规模应用的机器人或物理AI领域，是我们已经投入十多年的自动驾驶。

我们意识到，每一家汽车公司都希望自己的车辆能够加入出行服务车队。

今天已有Uber、Bolt、Grab、Lyft等平台。未来，自动驾驶出租车也会接入这些出行服务，而且不会只来自一个品牌。

但开发这样的系统，尤其是其软件，成本非常高。

因此，我们决定创建一个标准架构。

这套架构包括14个摄像头、9套雷达、3个激光雷达，以及一组超声波传感器。

这些传感器形成一个环绕车辆的感知系统，由双NVIDIA GPU系统提供自动驾驶计算能力。

我们将它发展为行业标准，如今正在被越来越多车型采用。

自动驾驶软件公司在其上开发能力，英伟达自己也是其中之一。这些自动驾驶出租车再接入出行服务平台，形成完整生态。

全球每年的出行里程约为1万亿英里。未来，其中相当一部分里程可能由自动驾驶出租车完成，按每英里1至2美元计算，这是一个巨大机会。

但市场非常分散。

通过建立Hyperion这样的标准架构，并与整个生态合作，我们就能形成一个巨大的虚拟车队，让各方都能接入。

今天，我很高兴宣布，又有四个品牌或车型系列加入：大众厢式车、捷豹路虎的新车型、沃尔沃车队，以及梅赛德斯-奔驰下一代车型。

它们将兼容Hyperion，并成为这一自动驾驶出行网络的一部分。

欢迎加入Hyperion。

下一个伟大产业，而且很可能规模极其庞大的产业，是人形机器人。

机器人之所以难做，一个重要原因是任务种类非常多。

如果针对每一种任务都开发一种特殊形态，就会把机器人产业分割成许多不同配置，难以形成推动技术进步的规模效应。

手机、个人电脑，以及英伟达NVLink 72之所以进步如此迅速，是因为标准化配置可以服务大量客户。

大量需求带来规模，规模又推动技术迭代，让产品更快、更好。

因此，我们需要尽可能标准化的机器人形态。

人形机器人未必适合所有任务，但很可能适合很多任务。因此，它可能成为出货量最大的机器人形态。

如果我们再为它开发能够快速学习的AI，那么即使中小企业没有专门的机器人团队，也不必从头编程，只需要向机器人演示要完成的工作。

机器人凭借通用能力和通用智能，就能快速学习和适应。

这很可能成为下一个重要技术平台。

我们正在与许多公司合作，其中不少来自欧洲。这是欧洲的重要机会。

欧洲在机电一体化、电子和机械系统的精度与工艺方面，拥有深厚积累。这里有大量制造能力极强的企业。

机器人将成为下一个大规模产业。许多公司已经参与进来，我们很高兴与大家合作。

构建物理AI系统，需要三类计算机。

第一类，就是我们一直在谈、大家也很熟悉的计算机，用来训练AI模型。

第二类，用来让AI学习技能。

你不能只是把AI编写出来，就让它进入物理世界随意尝试。学习应该先在数字孪生中进行。

我们创建了Omniverse数字孪生平台。

刚才看到的很多CUDA-X演示，都运行在数字孪生世界中。

Omniverse是一组可以接入各种平台和工具的库，包括西门子、达索系统、Cadence等公司的平台。它们共同构建数字孪生系统。

第三类，是部署在机器人上的计算机。

对于自动驾驶汽车和自动驾驶出租车，我们将相关平台称为Hyperion。

它包括计算机本身、功能安全系统、主动安全系统，以及专为物理AI安全设计的操作系统。

我们也需要为机器人提供同样完整的平台。

这样，当大家开始研究或开发机器人时，就不必从零拼装所有软件、计算系统、传感器和机械部件。仅仅完成这些准备工作，就可能耗费几年时间。

因此，我们决定打造一款参考机器人。

这就是英伟达与Agile Robots合作的Agile One。

这款参考机器人预计将在明年第一季度提供，出厂时已经完成组装，内置计算机，集成软件，开箱即可具备相当不错的能力。

它将成为一个很好的起点，推动机器人开发加速。

现在，让我们回到演讲开始的地方。

英伟达诞生于个人电脑革命之中。

1993年，我们成立时，PC革命正准备进入新的阶段；Windows 95随后让它进一步加速。

此后，我们发明了GPU，推动可编程着色和实时光线追踪发展，将CUDA加入计算模型，并帮助点燃现代AI革命。

四年前，我们开始思考：面对新的时代，能否重新定义个人电脑？

它不再只是你的工具，而是你的个人智能体、个人助手。你与它的互动，更像与一位帮助你工作的伙伴交流。

因此，这台计算机需要具备今天介绍的五个部分。

它需要模型，模型可以在本地运行，也可以在云端运行。

它需要智能体框架。

它需要OpenShell安全运行时。

它还需要访问个人电脑中的知识和工具。

好消息是，英伟达已经加速这些工具很多年。

只要我们创造一台同时支持OpenGL、DirectX和CUDA加速的计算机，英伟达过去开发的一切就都能够在其上运行。

这就是成果。

经过四年与微软的合作，我们打造了RTX Spark，这是一条全新的计算机产品线。

数千个工程人年的投入，凝结在其中。我们秘密研发了四年，创造了一颗名为N1X的芯片，最近与整个PC产业共同发布。

我们打造了台式机、笔记本电脑和工作站。

这台设备提供1 PFLOPS算力。

作个对比：2016年，我向当时还很小的OpenAI交付了一台拥有1 PFLOPS算力和128GB内存的计算机。

现在，这台小设备同样提供1 PFLOPS算力和128GB内存。

区别在于，我可以这样把它拿在手里，而当年的DGX-1需要两个人才能抬上楼。

这就是全新的RTX Spark PC。

如果你想要一台运行CATIA、达索系统其他软件，以及Autodesk、Adobe、Cadence和Synopsys工具的配套工作站，也可以选择运行Windows的DGX Station。

它提供20 PFLOPS算力和754GB内存。

此外，还有桌面版本。

相关产品正在推出，运行Windows的DGX Station预计将在今年年底上市。

现在，我已经讲了智能体的五个组成部分。接下来的问题是，怎么构建智能体？

如何让它运行在这些计算机上，或者运行在云端、企业本地环境中？

答案其实很简单。

构建智能体的方法，就是请一个智能体替你构建。

接下来，这段提示词将驱动一个应用。

大家将看到一个机器人应用演示。观看时请记住，这台个人电脑上运行着一个智能体，而整套演示涉及三类计算机：

第一类用于训练。

第二类运行数字孪生。

第三类将AI部署到机器人本身。

这里有两个核心概念：一是如何构建和运行智能体，以及能用它做什么；二是由三类计算机构成的物理AI计算模式。

我们来看演示。

视频旁白：

这是Hugging Face的机器人Micro Duck。

让我们使用NVIDIA RTX Spark，教它观察世界和行走。

我使用Hermes作为智能体框架，以Nemotron和OpenAI的GPT-6 Astra作为模型，并使用CUDA-X加速工具：FreeCAD、Blender、Isaac Sim、Newton物理引擎和Isaac Lab。

除非需要将大型工作负载扩展到云端，否则所有任务都在RTX Spark上运行。

首先，我描述训练场地，以及Micro Duck需要学会什么。

RTX Spark上的Hermes和Nemotron规划场地，列出所需的全部物体。

随后，Astra使用FreeCAD建立三维物体模型，用Blender赋予材质，再通过Omniverse仿真就绪库添加物理属性。

Astra在Isaac Sim中布置场景，为Micro Duck配置关节、执行器和连接结构，再利用Newton物理引擎模拟它的运动。

接下来开始训练。

云端的Isaac Lab让数千个Micro Duck同时训练。

每一次跌倒都是一次学习机会，推动控制策略不断改进。

Omniverse库模拟Micro Duck的摄像头，教它“看见”环境。

当感知与物理能力结合后，Micro Duck能够避开障碍、穿过狭窄空间，并适应周围环境。

我将训练策略下载到RTX Spark，使用Nemotron和Isaac Sim，通过多智能体编排对Micro Duck进行评估。

最后，将通过验证的策略部署到真实机器人上，它就可以开始行动了。

NVIDIA RTX Spark，让你直接在笔记本电脑上构建和运行AI智能体及其加速工具。

黄仁勋：

你们好！过来，给大家看看你们会走路。

你们还有摄像头。小心，别绊倒。

能坐下吗？现在站起来。休息一下，再站起来。

你们知道自己是在这里被创造出来的吗？

你们诞生于RTX Spark，在云端的大量英伟达超级计算机上接受训练，并在RTX Spark上的Omniverse数字孪生中学习技能。

是不是很神奇？

你们真可爱。你们的“父母”叫Pollen，对吧？Pollen Robotics。

听说大家太喜欢你们了，已经卖光了。

所有观看这段视频的朋友——可能会有两千万人——都可以去Pollen的网站看看，下一笔订单。

这家初创公司大概只有十个人，订单可能一下子就把他们淹没了。

每个人都应该有一只，你们太可爱了。

有一台RTX Spark，我们就能继续教你们新技能。

能翻个跟头吗？

太棒了！

那么，今天我们谈了什么？

我们谈到了欧洲建设自己的AI经济，而这一切从基础设施开始。

我们发布了新的DSX Pod系统，让建设AI工厂更加容易。

而这些AI工厂，不再只是运行模型。

[转向机器人。]

集中注意力，过来，坐下。

这些工厂运行的是完整的智能体。

智能体包含五个部分：

大语言模型负责感知、推理、规划和行动。

智能体框架相当于它的外骨骼，负责协调运行。

框架运行在OpenShell安全运行时中。

再赋予它访问知识和工具的能力。

这些智能体运行在我们的计算机上，而我们还在向下一代扩展，也就是物理AI。这就是你们这些小机器人的用武之地。

每个人都能构建智能体，欧洲每家公司都会成为AI公司，这一点毫无疑问。

欧洲将拥有蓬勃发展的AI经济。

33年来，这是一段不可思议的旅程。我们制作了一段很酷的视频，你们要一起看吗？

过来一点，我们让开舞台。全速前进！

视频主持人：

这样的演示之后，我们还能拿什么接着上场？

有一件事，能让现场更沸腾。

是什么？

你绝对想不到，GTC要变成欧洲歌唱大赛了！

黄仁勋：

感谢大家，感谢所有赞助商，也感谢33年来与我们一路合作的伙伴。

还有Micro Duck，我的新朋友们。

让我们一起建设欧洲的AI经济，让AI真正投入工作。

祝大家度过一场精彩的GTC！

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

504 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

2 条评论



见闻用户

30分钟前 中国福建省

英伟达黄仁勋力推欧洲全行业拥抱AI是为英伟达寻找拓宽芯片销售渠道。

0 回复



MobileUser6748 VIP会员

6小时前 中国广东省

利好什么？电力设备？

0 回复