


摘要：

GTC大会内容对产业链公司的影响更多，但英伟达自身的增量信息并不多，比如市场关心的资本开支持续性，英伟达的市场份额。此外，大会指引平淡，黄仁勋预测“至2027年数据中心累计收入达到1万亿美元以上”，这个数字可能不及市场预期。


2026年3月16日，英伟达创始人兼CEO黄仁勋在GTC 2026大会上发表主题演讲，核心议题涵盖CUDA平台20周年、推理拐点与算力需求爆发、Vera Rubin系统架构、Groq集成、OpenClaw代理革命及物理AI与机器人。

一、GTC2026核心要点

1) **数据中心营收展望**：2025-2027年数据中心累计收入达到1万亿美元（去年GTC大会给的是2025-2026年累计收入5000亿美元），符合预期。市场主流预期本身已经提升至1万亿美元以上，更期待的是公司能给出明确订单等方面的信息。




2) **性能和成本**：在tokens/watt（吞吐量）和token速度（智能度）两个维度上，英伟达均为全球最高性能；英伟达的token成本全球最低。



3) **数据中心成为"token工厂"**：每个工厂受限于功率（如1GW），需要管理token生产的吞吐量和速度。

token将像大宗商品一样细分层级：免费层（高吞吐、低速度）->\$3/百万token层->\$6/百万token层->\$45/百万token层->\$150/百万token层（顶级低延迟、高带宽算力）。

以1GW数据中心为例，每25%功率分配一个层级：Grace Blackwell可比Hopper生成5倍收入，Vera Rubin可再提升5倍。



4) Vera Rubin：在此前6类芯片基础上，新增了Groq 3 LPU。

①Vera Rubin：100%液冷（45℃热水冷却），所有线缆取消，安装时间从两天缩短至两小时；

②CPO（共封装光学）Spectrum-X交换机：已全面量产，与TSMC共同研发；

③CPU：世界上唯一使用LPDDR5的数据中心CPU，独立售卖，将成为数十亿美元级业务；


Vera CPU Tray用于Agentic workload, 单个Vera Compute Tray集成了8颗Vera处理器, 每个处理器88核, 同时支持8通道的LPDDR5x内存, 单个socket支持1.2TB/s的内存带宽。CPU Tray上集成了2块BF4-DPU。

④Vera Rubin：已在Microsoft Azure上线运行（第一个rack）。英伟达供应链已可每周生产数千套系统，每月数GW级AI工厂产能；

⑤Rubin Ultra：Rubin是横向滑入机柜，Rubin Ultra要垂直放入新机架Kyber，其中144 GPU在一个NVLink域内，中板后方用NVLink交换机替代铜缆。

	H200	B200	B300	Rubin	CPX	Rubin Ultra
Launch	2Q24	4Q24	3Q25	2H26	2H26	2H27
Node	N4P	N4P	N4P	N3P	N3P	N3P
Back-end	CoWoS-S	CoWoS-L	CoWoS-L	CoWoS-L	FC-BGA/CoWoS-S	CoWoS-L
Interconnect	NVLink 900GB/S	NVLink 1800GB/S	NVLink 1800GB/S	NVLink 3600GB/S	PCIe Gen6	NVLink 3600GB/S
HBM (GB)	141GB HBM3e	192GB HBM3e	288GB HBM3e	288GB HBM4	128GB GDDR7	1024GB HBM4e
Memory Bandwidth	4.8TB/S	8TB/S	8TB/S	20.5TB/S	2TB/S	53TB/S
TDP	700W	1000W	1000W	2300W	800W	3600W
Networking	400GB CX7	400GB CX7	800GB CX8	Dual-800GB CX9		1600GB CX10

Source: Company data,Dolphin Research



5) Groq 3 LPU（新增芯片）：Groq和HBM并用，符合预期

技术来自于收购的Groq团队，Groq LP30由三星制造，预计三季度发货。

单颗Groq芯片500MB SRAM vs 单颗Rubin芯片288GB，Groq单独无法承载主流大模型的参数和KV Cache。


解决方案：推出了一个Dynamo软件，把推理步骤分解出来：

1. 预填充阶段：也称Prefill，也是模型批量处理用户输入的Prompt的阶段，主要是以计算为主，因此在Vera Rubin上完成；
2. 解码的注意力环节：主要是计算当前产生的token与历史tokens（KV Cache，对话存储的记忆）的关系，是计算和存储并重的工作性质，也是在Vera Rubin上完成，频繁读取Rubin上的HBM内存单元。
3. 解码的前馈网络（FNN）：在Attention环节确定上下文关系后，前馈网络负责基于前Token来输出下一个Token的概率分布，并选出下一Token，即“吐字”。

这个环节的每一层都要读取模型的权重参数，读一次只能处理一个Token，原本参数放在HBM中，计算单元一直在等着数据从HBM搬运过来，这也是“内存墙”的真正堵点。

把解码分成用软件拆出两个阶段后，等于把模型在工作的“上下文记忆”仍然保留在HBM上，但把大部分模型参数转移到了Groq的SRAM上，芯片上内嵌的存储层SRAM能够以极低的延迟读取这些权重参数，从而解决推理吐字慢的问题。


Rubin和Groq之间用以太网紧密耦合，RDMA特殊连接模式可以让两芯片之间的交互延迟降低约一半。



6) **Feynman**: 全新GPU + LP40 (LPU) + Rosa CPU (以Rosalind命名) + BlueField-5 + CX10。

Kyber铜缆scale-up + Kyber CPO scale-up (首次同时支持铜缆和CPO scale-up)。这意味即使在Feynman阶段，也将同时支持铜和CPO的混合方式。

虽然英伟达长期看好CPO方案，但客户方面倾向于将铜缆方案用到极致后再切换CPO (部署/维护更简单)。



7) 其他信息:

①太空数据中心: 针对能源不足问题,英伟达宣布Vera Rubin Space-1, 计划将数据中心部署到太空 (需解决辐射散热问题, 太空中无传导和对流, 仅有辐射);

②OpenClaw: 每家SaaS公司将变成GaaS公司 (Agent-as-a-Service)。

代理系统在企业网络中可以访问敏感信息、执行代码、对外通信——这需要企业级安全。英伟达与OpenClaw创始人Peter Steinberger合作推出NemoClaw (OpenClaw的企业安全参考设计), 集成OpenShell技术, 包含网络护栏 (network guardrail) 和隐私路由器 (privacy router), 可连接各SaaS公司的策略引擎;

③物理AI与机器人: 自动驾驶方面, 比亚迪/吉利/现代/日产等厂家加入Robtaxi, 并与Uber合作。然后机器人方面KUKA/ABB等厂商, 还有很多机器人/无人机平台等。

总体来说，这次发布会，除了澄清了铜缆和CPO会并用，主要就是新加入了一个服务器中新加入了Groq的LPU选项。这个在Groq被买后，市场已有充分预期；甚至指引的三年一万亿美金收入，市场实际其实也已经超过这个数字了。

整体上从英伟达的产品迭代可以看到：最近几年的迭代重心不再芯片微架构的创新，从Hopper到Blackwell解决主要是组合和连接的问题，英伟达主要是完成了卖芯片到卖系统和服务的切换。

而从Blackwell到Rubin，无论是新加入的DPU（NAND芯片），还是这次新买来后紧急放进来的LPU（SRAM），主要完成的是AI进入推理和Agent时代，内存墙的问题。

二、英伟达的近况：大会指引平淡，需要“成长性新故事”


英伟达的股价表现，在近半年的时间内基本上一直都在170-200美元的区间内震荡。即便下游大厂增加资本开支、公司业绩持续超预期，公司股价也没能实现向上突破，主要是市场有以下几方面担心：

a) 大厂资本开支持续性：Meta、谷歌等厂商都明确增加了2026年的资本开支，四大核心云厂商在2026年的资本开支有望达到6600亿美元以上，同比增长60%。但值得注意的是，大厂资本开支在收入中的占比处于达到了相对较高的位置。

以Meta为例，公司预期2026年资本开支将达到1150-1350亿美元，资本开支/年度收入将达到50%以上，进一步提升的空间相对有限。即使各家大厂增加了2026年的投入展望，但依然难以打消市场对后续资本开支增长持续性的担心。

b) AI芯片市场份额：当前英伟达在AI芯片市场的份额维持在75%以上，较高的价格和“近乎垄断”的市场结构，促使下游云厂商寻求“替代方案”。

在谷歌之外，博通AVGO已经明确收获了Anthropic、Open AI等的大额订单，多个客户也都开启了自研方案。即便英伟达后续还有Rubin新品，但市场普遍预期公司在AI芯片市场的份额将逐步下滑。



3) 产品竞争力：当前谷歌TPUv7在FP8等领域的表现大致已经接近于英伟达的B200（2024年四季度量产），谷歌TPU大致落后于英伟达一年左右。

英伟达在Blackwell系列中引入了NVFP4 格式，能使推理性能在FP8的基础上再翻一倍。但其实FP8满足了当前市场大部分的需求，TPUv7已经是一个“替代选项”。

为了对抗行业竞争，英伟达正在通过战略投资和算力扩容，来锁死供应链上下游，比如说，以芯片部署为前提的战略投资Open AI（300亿美元）和Anthropic（100亿美元）、为Meta旗下全新 AI 实验室MSL提供数百万块GPU的算力支持，其中部分协议有一定的降价锁定客户需求的意味。

	TPU v5p (Viperfish)	TPU v6 (Trillium)	TPU v7 (Ironwood)	H200	B200	B300
Time	1Q24	4Q24	4Q25	2Q24	4Q24	3Q25
Node	N5	N5P	N3E	N4	N4P	N4P
HBM(GB)	95GB HBM2E	32GB HBM3	192GB HBM3E	141GB HBM3E	192GB HBM3E	288GB HBM3E
HBM Bandwidth(GB/s)	2765	1640	7380	4800	8000	8000
FP4 TFLOPS					9000	14000
FP8 TFLOPS	459	918	4614	1466	4500	4500
INT8 TFLOPS	918	1836	4614	1466	4500	4500
BF16 TFLOPS	359	918	2307	733	2250	2250
TDP(W)	550	390	980	700	1000	1100

Source:Media reports,Dolphin Research

结合上述的市场担心，公司估值也处于相对较低的位置。海豚君按照截止25-27自然年数据中心收入1.15万亿（高于公司目前指引的1万亿），英伟达当前市值（4.4万亿美元），对应2028财年（接近2027自然年）净利润约为13倍PE左右（假定营收两年复合增速64%，毛利率72%，税率18%）。

英伟达上季度交出了超预期的财报，但公司股价并未迎来上涨。这主要是因为2027年收入预期已经全部打进去后，市场担心下游云厂商在资本开支强度拉到50%以上的之后，进一步拉高资本开支的空间非常有限。

理论上，处于云厂商二级导上的英伟达，即使客户资本开支高位维持，英伟达来自云客户的收入会变成零增长，市场不敢给2027年之后的英伟达高估值，导致英伟达当前只有27年利润13X的PE，建筹的兴趣也不高。

结合本次GTC大会的内容来看，老黄给出的“至2027年数据中心累计收入达到1万亿美元以上”，其实市场预期早已拉到比这个数还更高一些。

会议中更多的时间，给到了英伟达的产品推销和路线规划，对产业链公司的影响更多（CPO和铜仍将混合使用、LPU与HBM分担不同的工作），对公司自身的增量信息并不多。

未来英伟达公司的PE再次提升，海豚君认为除了AI应用上能够更大规模、更快速度落地之后，还需要新的“成长曲线”来拉动，比如“Physic AI”、“太空算力”等。

本文来源：[海豚研究](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时0元领

*同一用户免费领取一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

327

收藏

分享到:

写评论

请发表您的评论

