

摘要：

英伟达斥数十亿美元训练万亿参数开放大模型Nemotron 4，表面“不务正业”，实则暗藏商业逻辑：模型免费，算力收费。通过免费模型吸引企业、政府和开发者部署AI，推动GPU、网络、软件全栈消费。此举还有助于分散客户集中风险，对抗大客户自研芯片威胁。同时，亲自训练前沿模型可提前发现硬件瓶颈，反哺下一代芯片设计。

英伟达正悄然完成一次战略身份转变，从开源AI生态的“支持者”升级为亲身下场的“构建者”。

[华尔街见闻提及](#)，8月11日，据The Information报道，英伟达希望下一代Nemotron 4跻身全球最强开放模型之列。

参与项目的员工预计，最大版本至少拥有1万亿个总参数，约为6月发布的Nemotron 3 Ultra的两倍。

模型的预训练数据和架构已有初步决定，但最终规格、发布时间尚未确定，最关键的一轮训练也还没有开始。所谓“万亿参数Nemotron 4”，目前仍是一项研发计划，不能当作已经发布的产品。

这场投入很容易被理解成英伟达也想成为OpenAI或者Anthropic，但实际上英伟达无须靠Nemotron的API收费收回成本。

只要免费模型让更多企业、政府和创业公司开始训练、微调 and 部署AI，英伟达便能在GPU、NVLink网络、整机系统、CUDA以及企业软件上逐层收费。

Nemotron 4更像一台算力需求发生器：模型免费，使用模型所需的计算并不免费。

英伟达需要把买家从少数巨头扩散到整个市场

眼下的GPU繁荣异常集中。

英伟达截至4月26日的10-Q显示，三个直接客户分别贡献当季收入的21%、17%和16%，合计54%；公司还披露，一家AI研究与部署企业通过云服务间接贡献了“有意义的收入”。

这类直接客户可能是整机商、分销商或云厂，不能简单等同于三家最终用户，但客户集中风险已经写在账面上。

更麻烦的是，大客户同时在造英伟达的替代品：

- 亚马逊AWS用Trainium承接Anthropic的训练和推理，官方称已有接近100万颗Trainium 2服务Claude；
- 谷歌的Ironwood TPU面向大规模训练和推理；
- AMD也用MI350和ROCm争夺开放模型负载。

闭源模型把需求集中在几家实验室和云平台，它们规模巨大、议价能力强，还有动力把成熟而稳定的工作负载迁往自研芯片。

对英伟达而言，最安全的市场形态并非某一家模型公司统治AI，而是成千上万个互不相同的模型和应用同时生长。需求越分散，客户越难用一款定制ASIC覆盖所有架构；工作负载变化越快，通用GPU和CUDA成熟的软件生态越占便宜。

这也解释了英伟达为什么不能只在口头上支持开放生态。一个远落后于闭源模型的开放模型，只能吸引研究试验，很难让银行、制造商、政府部门为生产集群开预算。

模型必须足够强，强到企业愿意用自己的数据继续训练，强到客户愿意把高频工作流交给它，开放模型才会从开发者下载量变成机房里的GPU利用率。

万亿参数的作用在这里。它不是一枚证明智能水平的奖章，而是英伟达争取跨过企业可用门槛的一种手段。

现有Nemotron 3 Ultra拥有5500亿个总参数、每个token激活550亿参数，支持最长100万token上下文。

英伟达公布的测试显示，它在部分任务上接近其他头部开放模型，推理吞吐量则明显更高。但The Information援引第三方榜单称，它仍落后于最强的中国开放模型，在全球综合模型中也远非第一梯队。

所以，参数规模只能说明野心，不能代替成绩。

稀疏MoE架构中，总参数与每次推理实际调用的参数相差很大，数据质量、训练token、后训练、工具调用能力和推理系统共同决定最终效果。

Nemotron 4若只有“1万亿”这个好看的数字，却没有进入真实任务的第一梯队，它很难改变任何采购决定。

一款免费模型，可以卖出一整座AI工厂

英伟达已经把转化路径铺好：

- 开放的Nemotron提供模型权重、数据和训练配方；
- 企业用NeMo做继续预训练、微调、强化学习和评测；
- 部署时再接入NIM推理微服务、TensorRT-LLM和CUDA；
- 规模扩大后，算力落到DGX Cloud、公有云GPU或者企业自建的HGX/DGX集群。
- GPU之外，NVLink、InfiniBand或Spectrum-X网络、CPU、DPU和NVIDIA AI Enterprise订阅也进入账单。

这条路径已经出现早期样板。Palantir把Nemotron带入美国政府的隔离网络，客户可以在本地基础设施上训练、保留模型权重并持续迭代，生产部署由NVIDIA AI Enterprise支持。

日本市场则更接近“主权AI”模板：研究机构和企业用Nemotron数据及NeMo训练日语模型，HGX B300承担私有基础设施，Jetson负责边缘部署。

闭源API进不了隔离网络，也很难满足数据驻留、模型所有权和本地审计要求。开放模型把这些原本不会发生在公共云API上的负载带进政府机房、企业数据中心、区域AI云和边缘设备。

对模型公司来说，这是一个较分散、较难收费的市场；对出售基础设施的英伟达来说，每多一个部署地点，就多了一处硬件和软件收入入口。

模型路由让这盘生意更大。The Information报道英伟达在推出Nemotron 3.5 Lightning的同时，发布了免费的模型路由软件。路由器会把简单任务交给便宜的小模型，把少数困难任务交给大模型。

表面看，它在帮助客户少用昂贵算力；实际的赌注是，当单次任务成本降下来，企业会启动更多常驻智能体，让一次问答变成包含规划、搜索、工具调用、验证和返工的连续流程。

Gartner预计，到2030年，万亿参数模型的推理成本会比2025年下降90%以上，但智能体每项任务消耗的token可能是普通聊天机器人的5至30倍；如果token用量增长快于单价下降，推理总支出仍会上升。

英伟达押注的并非“大模型越昂贵，GPU卖得越多”，而是“智能越便宜，使用量扩张得越快”。Nemotron同时覆盖轻量模型、旗舰模型和路由工具，正是在主动制造这种价格下降后的需求弹性。

做模型也是为了把下一代芯片提前做对

Nemotron还有一层不直接体现在模型收入里的价值：它是英伟达自己的全栈压力测试。

芯片公司若只等客户模型定型，再去适配新的注意力机制、MoE路由、长上下文和低精度格式，硬件迭代会永远慢半拍。

亲自训练前沿模型，工程团队能更早看到算力、显存、互联、数据吞吐和推理调度的瓶颈，再把这些发现写进下一代GPU、NVLink和软件库。

Nemotron 3 Ultra已经带有很强的“硬件共设计”痕迹：模型使用混合Mamba-Attention与MoE架构，预训练采用为Blackwell设计的NVFP4格式，并通过多token预测提升生成速度。

英伟达称，量化后的版本可以在4张B200上部署。这样的模型既是产品，也是Blackwell低精度能力、显存体系和推理软件的演示负载。

开放之后，外部开发者又会替英伟达继续优化这套负载。

新的模型架构先在CUDA、PyTorch、vLLM、SGLang和TensorRT-LLM上跑通，优化回流到英伟达平台，后来者面对的就不再是一颗GPU的性能差距，而是一套已经被数千个项目打磨过的生产环境。

英伟达今年展示的案例中，Blackwell运行DeepSeek V4的每token成本在一个月内最多下降到原来的五分之一；多项软件优化叠加，吞吐量最高可提升20倍。

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

32 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论