

摘要：

英伟达公布Q2财报，单季营收达960亿美元实现翻倍，并罕见给出2028财年营收增长约70%的超预期指引。CEO黄仁勋强调，70%的增长仅是“受限于产能”的结果，在Agentic AI普及的推动下，真实市场需求增速远超100%。同时，黄仁勋力挺对前沿AI实验室的500亿美元投资，直言“唯一的遗憾是没能更早投资”。

面对极度受限的供应链与爆棚的“代理AI（Agentic AI）”需求，英伟达在交出Q2创纪录的960亿美元营收后，抛出了下财年增长70%的强劲指引，并直言该数据仍未能完全反映市场的真实渴求。

当地时间2026年8月26日，英伟达召开了2027财年第二季度财报电话会议。在这场万众瞩目的业绩会上，英伟达首席执行官黄仁勋与首席财务官科莱特·克雷斯（Colette Kress）向市场交出了一份惊艳的答卷：

- Q2总营收达到创纪录的960亿美元，同比翻倍；
- 其中数据中心营收环比增长18%至890亿美元；
- 公司预计Q3总营收将达到1080亿美元（上下浮动2%）。

令市场意外的是，在以往通常只给出下季度指引的惯例下，首席财务官Colette Kress罕见地给出了长期预期，预计2028财年（对应自然年2027年），公司营收将实现约70%的同比增长。

首席执行官黄仁勋在财报电话会议上将此轮AI计算投资浪潮定性为“一代人一次”的平台级转型。黄仁勋强调，70%的增长仅是“受限于产能”的结果，在Agentic AI普及的推动下，真实市场需求增速远超100%。

英伟达预计第三季度毛利率约为74%，此后将在第四季度触底至71%至72%，理由是内存价格涨幅“远超此前预期”且仍在持续攀升。公司预计价格调整措施将于2028财年第一季度生效，届时毛利率回稳至72%至73%。

此外，管理层预计英伟达的CPU收入将在2028财年实现翻倍以上增长。

需求远超产能：“如果不受限制，我们的增长会高得多”

市场最为关注的焦点之一是英伟达未来业绩的可持续性。

对此，英伟达首次给出了长达一年的前瞻指引。预计2028财年营收将同比增长约70%。但管理层反复强调，这是一个“打折”后的数字。

黄仁勋在回答分析师提问时直言：

尽管我们的需求远远大于70%，但我们的供应使我们有信心实现70%的增长。如果不受限制，这个数字会高得多。我们今年的同比增长达到了100%，目前的非受限需求非常巨大，因此我们只能拼命工作去获取更多产能。

对于当前供应链的紧张程度，黄仁勋用一种接地气的方式描述道：

现在整个供应链都面临挑战，每个人都在满负荷运转……我需要整个供应链来帮我的忙。

克雷斯也补充指出，非超大规模企业（即ACI&E部门，包括主权AI、区域云、企业等）的增长势头极其迅猛。该部门Q2营收达到400亿美元，环比增长25%，同比激增138%。黄仁勋对此表示：

这部分世界的计算量随着时间的推移，可能会比我们目前在云端看到的还要大。

算力经济学跃升：每吉瓦（GW）产值翻倍至400亿美元

英伟达之所以能让云厂商和主权资本心甘情愿地掏出巨资，核心在于其不断跃升的“算力经济学”。

会议上，黄仁勋揭示了一组让投资者振奋的单位经济模型数据：

在Hopper时代，我们每吉瓦（GW）数据中心的营收机会大约是180亿美元；到了Grace Blackwell，大概是250亿美元；而对于Vera Rubin，这个数字大约是400亿美元。

这意味着，随着整机柜系统（如NVLink 72）的演进，同样规模的电力和土地带来的产值正在呈指数级上升。黄仁勋强调：

最理想的答案实际上是每吉瓦能产生无限的计算量。如果能在1吉瓦的电力和土地上放入1万亿美元的计算量，那将是一个美妙的结果。只要生产力、耐用性和通用性持续增长，人们就会乐于投资那些能产生收入、创造利润并以难以置信的速度收回成本的资产。

押注前沿AI实验室：“我唯一的遗憾是没能更早、更多地投资”

针对市场对于英伟达投资前沿AI实验室（如OpenAI、Anthropic）并引发“循环融资”的担忧，英伟达管理层给予了正面且强硬的回应。

英伟达已在前沿AI实验室投资了近500亿美元，并联手黑石、贝莱德等资本巨头成立了融资平台，计划筹集超5000亿美元的第三方资本。克雷斯表示：

我们知道有些人会称之为循环融资，但我们不这么看。这是一次重大的计算平台转移，这些公司是百年一遇的。我们预计它们将成为历史上最大的科技公司。

黄仁勋更是对这些投资毫不掩饰地表达了看好：

投资这些公司是一个千载难逢的机会。我唯一的遗憾就是没能更早、更多地投资。

他进一步强调：



我百分之百确信我们的技术将继续为他们提供非凡的价值，他们将在很长一段时间内成为我们的客户和合作伙伴。

高管预警毛利率Q4触底，直面HBM存储成本狂飙

在极其乐观的增长预期中，管理层极为罕见地主动释放了关于毛利率下行的预警，这成为了本次电话会上最值得投资者警惕的变量。

克雷斯给出了一条清晰的毛利率路径指引：Q3毛利率预计为74%，并在Q4触底至71%~72%区间，随后2028财年全年随着Q1涨价，生效回升至72%~73%。

导致毛利率承压的核心痛点在于高带宽内存（HBM）价格的超预期飙升。Kress表示：

正如你们所知，我们正经历存储市场的极端定价。价格上涨的幅度超出了我们之前的预期，并且进入明年还会继续走高。因此，我们今天要设定下预期。

克雷斯解释：

我们希望能直言不讳地说明这一点，而不是让它作为一个悬而未决的问题拖延下去。

她同时补充道，存储供应紧张本身就是驱动英伟达自身增长的同一需求激增的症状。

Agentic AI引爆新战局，纯CPU机架成下一增长极

在终端应用层面，本次电话会最大的增量信息在于确认了Agentic AI（智能体人工智能）已经跨越了临界点，并正在引爆纯数据中心CPU市场的狂欢。

黄仁勋表示：

今天绝大多数的AI是由人类提示（prompted）的。但我相信，就在上个月，情况已经发生了变化。现在大多数AI已经是智能体化（agentic）的了。

他详细解释了背后的算力消耗逻辑：

相比于人类使用，一个智能体进行推理、计划和多次工具调用所需的算力，可能是15到100倍。

这种工作负载的剧变直接拉动了Vera CPU的需求。作为独立于Rubin GPU的单独产品，Vera不仅在SPEC基准测试中比竞品快1.8倍，其每瓦带宽更是达到其他数据中心CPU的5倍。

管理层预计，在约200亿美元的总体服务器CPU市场中，英伟达的CPU收入将在2028财年实现翻倍以上增长，确立其作为全球领先服务器CPU供应商的地位。

英伟达 2027财年第二季度财报电话会全文（AI辅助翻译）：



主持人：

下午好。我是Tiffany，今天将担任本次会议的主持人。欢迎各位参加英伟达第二季度财报电话会议。为避免背景噪音干扰，所有线路已静音。演讲结束后将进行问答环节。谢谢。现在有请Toshiya Hari开始发言。

Toshiya Hari（英伟达投资者关系部门）：

谢谢。下午好，欢迎参加英伟达2027财年第二季度财报电话会议。今天与我一同出席的有英伟达总裁兼首席执行官黄仁勋，以及执行副总裁兼首席财务官Colette Kress。本次电话会议正在英伟达投资者关系网站上进行网络直播。

直播将提供回放，直至下一次讨论2027财年第三季度财务业绩的财报电话会议。今日电话会议内容为英伟达财产，未经我方书面许可，不得复制或转录。本次电话会议中，我们可能会就当前预期作出前瞻性陈述。

这些陈述涉及若干重大风险和不确定性，实际结果可能与预期存在重大差异。如需了解可能影响公司未来财务业绩和经营的相关因素，请参阅今日财报发布的披露内容、我们最近提交的10-K和10-Q表格，以及向美国证券交易委员会提交的8-K表格报告。本次所有声明均基于我们截至2026年8月26日当前可获取的信息，除法律要求外，我们不承担更新上述声明的义务。

本次电话会议将讨论非GAAP财务指标。您可以在我们网站发布的首席财务官评论中找到非GAAP财务指标与GAAP财务指标的对照表。下面，请Colette发言。

Colette Kress（执行副总裁兼首席财务官）：

谢谢，Toshiya。

我们再度交出了一份亮眼的季度成绩单，营收、营业利润和每股收益均创历史新高。总营收达960亿美元，同比增长逾一倍，增速连续第四个季度加快。人工智能需求的强劲增长正在推动全球基础设施建设，增长机会覆盖超大规模云服务商、人工智能实验室、AI原生企业、传统企业以及主权客户等多元群体。我们预计2028财年营收将增长约70%，这一展望受供应端制约。

数据中心业务

第二季度数据中心营收环比增长18%，达890亿美元，超大规模（Hyperscale）和ACI&E两大细分板块均贡献突出，其中ACI&E涵盖我们的新云（Neocloud）、工业及企业客户。超大规模营收达490亿美元，环比增长13%，持续受益于Blackwell的强劲表现。更多算力上线印证了“算力越多、营收越高”的逻辑——我们的超大规模客户本季度财务表现亮眼，营收增速加快，利润率持续扩张。随着云行业积压订单突破2万亿美元，前五大超大规模云服务商的资本支出预计2026年将接近8000亿美元，2027年将达1.3万亿美元。

与AWS的合作扩展

今天，我们很高兴宣布与AWS深化合作。在现有庞大英伟达算力装机基础上，AWS将从本季度至2029财年第二季度额外部署200万颗GPU，同时配套Vera CPU，部分与Rubin集成，部分独立部署。AWS将在Amazon Bedrock和SageMaker上托管英伟达Nemotron系列开源模型。此外，亚马逊还将全面采用我们的物理AI全栈——Omniverse、Cosmos、Isaac和Jetson——为其仓储机器人舰队提供动力。

ACI&E板块



ACI&E营收达400亿美元，环比增长25%，同比增长138%，增长动力来自企业、AI初创公司和主权客户需求上升带动的产能扩张，以及超大规模客户为补充自建而采购的外部容量。借助英伟达DSX参考设计，我们的新云合作伙伴得以更快上线、以更低的token成本运营，预计年底总装机容量将达8吉瓦，较2025年底的约3吉瓦大幅提升。

令人振奋的是，即便规模如此庞大，我们仍在观察到需求加速的态势。客户预测显示明年需求将翻倍，然而正如前述，受供应制约，我们预计增速约为70%。英伟达算力在我们服务的每一朵云中均已满负荷运转，为超大规模客户、新云和AI实验室合作伙伴创造的经济价值持续攀升。

驱动增长的三大核心能力

除打造最优秀的AI计算技术和最强大的供应链外，英伟达还具备三项独特能力，构成我们增长的核心引擎。

第一，英伟达架构兼容所有模型，并随着开源和闭源模型的普及持续扩大份额。闭源模型和开源模型的采用量均在急速攀升。英伟达承载着领先的闭源模型——OpenAI、Anthropic、Grok、Meta、Gemini，以及领先的开源模型——TML、Mistral、Qwen、Kimi、GLM、DeepSeek、Minimax和Nemotron。无论小模型还是大模型、语言还是视频、自回归还是扩散模型、云端还是边缘，英伟达均可高效运行。英伟达在训练、推理和智能体（Agentic）工作负载上均表现卓越。一个平台，可灵活适配所有模型和工作负载，并贯穿AI全生命周期，这种性能、灵活性与耐久性的组合，使英伟达成为最具生产力和融资价值的算力基础设施。

第二，我们的全栈AI工厂平台正在扩大我们在数据中心潜在市场（TAM）中的份额。自Hopper以来，我们的每吉瓦营收机会已从约180亿美元增长至Blackwell时代的250亿美元，再到Vera Rubin的400亿美元。Vera Rubin现已涵盖Vera CPU、Rubin GPU、NVLink、InfiniBand或以太网，以及本周早些时候发布的Groq LPU。我们跨GPU、CPU、NVLink纵向扩展网络、横向扩展网络、系统、算法和软件的极致协同设计能力，使我们每代产品均能实现突破性的性能提升。

Vera Rubin充分体现了这一点，相比Grace Blackwell Ultra，其每兆瓦吞吐量提升30倍，token成本降低35倍。我们已于本月初启动Vera Rubin量产出货。目前已收到所有主要超大规模云服务商、AI云及系统OEM的采购订单，预计Vera Rubin将成为英伟达历史上出货爬坡最快的产品。我们的网络业务再创季度新高，营收环比增长18%。Spectrum-X以太网同比增长2.6倍，助力我们迈向全球最大、增速最快的网络公司之列。

随着智能体AI的普及，数据中心CPU需求正在加速增长。我们于2021年推出的Grace CPU取得了显著成功，过去12个月的滚动营收超过50亿美元。当前，我们的下一代Vera CPU已全面量产。作为独立产品，Vera进一步扩大了我们的潜在市场空间。Vera在SPEC基准测试中完成智能体任务的速度比其他数据中心CPU快1.8倍，每瓦带宽提升5倍。我们预计Vera将被所有主要超大规模云服务商、新云、AI实验室和系统OEM部署，出货已向牵引伙伴展开，包括OCI、SpaceX AI，以及本季度开始的AWS。

我们仍看到约200亿美元的服务器CPU总需求空间。基于客户需求及改善中的供应前景，我们初步预计2028财年CPU营收将翻倍以上，有望跻身全球领先服务器CPU供应商行列。

自去年宣布与Grok的合作以来，我们一直致力于融合英伟达的高吞吐与Grok的高交互架构。本周在Hot Chips大会上，我们宣布Grok 3 LPX——我们首款机架级LPU系统——已全面量产，并已创造记录：在人工智能分析基准测试中，每秒token数达到次优方案的近4倍。我们预计本季度晚些时候至下季度初将向早期用户批量出货，Nebius将成为首家。

如今，我们售卖的不仅是最优秀的芯片，更是一套完整的全栈AI工厂平台，为客户提供卓越的经济性，同时拓展我们在数据中心潜在市场中的份额。



第三，我们的全栈AI工厂与丰富的CUDA生态系统相结合，使我们能够将AI延伸至单一芯片无法触达的市场。超大规模客户之外，是一片渴望拥抱AI的广阔市场。对于无意自研定制芯片的客户，英伟达经过充分验证的全栈平台，独特地助力主权客户、新云和企业构建AI基础设施、实现全面运营、通过CUDA软件持续优化，并与我们庞大开发者生态系统的需求相对接。

超大规模客户仍将是主要增长引擎，但非超大规模业务——即涵盖主权、区域新云、企业、边缘和隔离数据中心的ACI&E板块——将占数据中心业务的约半壁江山。我们的AI原生初创生态系统主要在英伟达算力平台上开发和运行，规模正在快速扩张。2026年上半年，全球风险投资对AI的投入超过4000亿美元（其中约70%用于算力），已超过2025年全年2650亿美元的融资规模。

近20家公司，包括SpaceX旗下的Cursor、Figma和Together AI，年化营收现已超过10亿美元，较去年第四季度的13家有所增加，其中垂直企业软件增速最快。在企业业务方面，过去12个月滚动数据显示，汽车垂直领域本地部署（On-Prem）营收达80亿美元，金融服务、制造和医疗健康合计贡献70亿美元。Hudson River Trading和Jane Street正借助英伟达AI工厂加速量化交易；三星电子利用英伟达cuLitho将计算光刻性能提升最高20倍；百时美施贵宝（Bristol Myers Squibb）正投资Vera Rubin AI工厂——紧随罗氏（Roche）和礼来（Lilly）的布局之后——以应对药物研发周期从数年压缩至数月的需求。

主权AI与新云

主权AI业务方面，我们主要通过区域新云开展，第二季度环比增长35%，同比增长逾三倍。一个国家或地区可以将土地和电力直接分配给区域云合作伙伴，而这是其绝不会对外国超大规模云服务商开放的。我们自身不运营云业务，是所有主权客户和新云的中立合作伙伴。由于英伟达算力高效、灵活、可租用且经久耐用，区域云的兴趣正在全球各地持续升温。

我们帮助CoreWeave、Nebius和Nscale建立了完整的基础设施业务，新云也正在各地涌现：亚美尼亚的Firebird、覆盖非洲的Kosovo Technologies、中国台湾的GMI Cloud、印度的Yoda和NASA、澳大利亚的Hermes、马来西亚的YTLA Cloud——它们以低功耗和运营专长与我们的平台强强联合。

上个月，我们宣布与日本国家AI公司Noetra建立合作，共建英伟达DSX AI工厂，打造开源模型，为AI智能体、数字孪生、机器人和物理AI应用提供动力。韩国LG和现代汽车集团正与英伟达携手构建和扩展AI能力。在欧洲，创纪录的35台全新英伟达驱动AI超级计算机相继亮相，推动产业和科学领域的突破性进展。

新云融资模式

新云正在看到来自多元客户群体的强劲需求管道。有别于传统模式——将全部容量分配给单一长期包销保证（而这通常是贷款方独立为数据中心项目融资所要求的），我们引入了一种收入分成结构：英伟达对设施部分容量提供“要么使用、要么付款”的承诺，即最低收入保证，帮助贷款方建立承销信心；作为交换，我们分享新云超出该底线所获收入的一部分。独立资本仍对每个项目进行独立的基本面审核——我们不发放贷款。

在这一模式下，我们实现双重收益：一次来自硬件销售，另一次来自租金收入分成，后者是叠加在一次性设备销售之上的高度重复性收入流。长期来看，该模式可扩大我们的可寻址市场，在核心平台收入之外创造与使用挂钩的经常性收入流，中长期有望带来数十亿美元的营收。

前沿AI实验室战略

综上，英伟达的三大核心能力——运行所有模型的平台、抢占更多数据中心潜在市场的全栈AI工厂平台，以及将AI延伸至单一芯片无法触达市场的CUDA生态系统——相互强化，共同构成我们增长的引擎。



下面，让我汇报我们与前沿AI实验室合作的进展。前沿AI实验室对训练和推理算力的需求极为旺盛，但其增长速度已超出自身资产负债表和信用状况所能支撑的范围。它们面对快速增长的客户需求，却尚不具备数十年基础设施合同和投资级融资能力来独立保障AI工厂基础设施的建设。换言之，制约其增长的不是技术，也不是客户需求，而是算力。对这些企业来说，更多算力意味着更多智能、更多用户和更多营收。英伟达需要助力这一飞轮持续转动。

首先，我们已向前沿AI实验室投资近500亿美元。这是一笔有分量的承诺，但仅占我们同期预期自由现金流的一小部分。其次，为支持前沿实验室的基础设施建设，我们近期宣布与全球六家领先基础设施资本提供方——Apollo、贝莱德（BlackRock）、黑石（Blackstone）、布鲁克菲尔德（Brookfield）、高盛（Goldman Sachs）和KKR——建立融资平台合作，将募集逾5000亿美元第三方资本。借助这些合作，AI实验室将能够依托我们独特、灵活且经久耐用的算力平台，以相对具有吸引力的利率，通过长期机构资本融资，构建和使用AI基础设施。

上周，我们宣布通过与软银能源（SoftBank Energy）的合作，以独家托管方式，在其PORTS-Pike园区取得土地电力和机房容量。初期部署预计可支持4.25吉瓦AI工厂容量，将由OpenAI使用。PORTS-Pike部署的每代英伟达AI工厂系统预计涵盖约150万颗英伟达GPU，未来20年内该基地可支持多轮升级迭代。这里有一个核心经济逻辑：长期采购（LPS）承诺锁定了一个长期运营的AI工厂站点，而数据中心内的英伟达算力则可以反复升级。

这一项目深化了我们与OpenAI的长期合作关系。OpenAI承诺到2030年大规模部署英伟达AI基础设施，其现有及规划承诺对应约12吉瓦的英伟达算力。此外，对另一家前沿AI实验室，我们将为近2吉瓦算力提供选择性信用增信，这与其不借助英伟达信用支持独立保障的大量英伟达算力容量互为补充。

我们清楚这一支持规模不小，也预料会有人将其定性为“循环融资”。但我们持有不同看法。我们正在经历一次重大算力平台转型，这是人类历史上最重要的技术之一的诞生过程，而这些都是百年一遇的企业。其技术领先地位已获验证，客户牵引力和使用量正在急速攀升。我们预计它们将成为史上最大的科技公司。我们相信，衡量这些投资时，无论是需求的强度、它们为我们创造的业务、在英伟达平台上构建的生态系统，还是我们投入资本的股权回报，都将是优异的。且我们的风险有限——英伟达算力平台灵活可调配，可重新部署以服务其他客户。

为提供背景参考，我们预计明年来自AI实验室（即我们预计将运用资产负债表支持的对象）的需求，将贡献我们约四分之一的业务。我们出货的算力将由投资级客户或其支持方消化。

损益表其余项目

GAAP和非GAAP毛利率均为75%，与上季度基本持平，主要因产品组合相近。GAAP和非GAAP运营费用分别环比增长10%和11%，主要由算力基础设施成本上升以及薪酬和福利支出增加所驱动。非GAAP实际税率为16%，较去年同期上升，主要由营收增长所致。

在资产负债表方面，为备战Vera Rubin发布，存货增至320亿美元。应收账款天数升至60天，反映部分投资级客户就跨多季度出货的大额采购获得了延长付款期限的安排。

股东回报

第二季度，我们向股东回报创纪录的260亿美元，其中股票回购200亿美元，按每股0.25美元的季度股息派发60亿美元。相对于回报50%或以上自由现金流的计划，我们年初至今已回报60%。展望未来，我们拟在战略用途净额之外，进一步提高并回报超额自由现金流。

第三季度展望

总营收预计为1080亿美元，误差幅度±2%。预计环比增长主要由数据中心内的AI原生客户驱动；超大规模业务的增长则预计在第四季度及2028财年随Vera Rubin供应增加而重新加速。预



计第三季度Vera Rubin将占数据中心营收的约20%。

展望未来，我们初步预计2028财年营收同比增长约70%。尽管我们将努力弥合供需缺口，但预计至少在2028财年结束前，供应仍将是制约因素。

毛利率预期

我们知道许多投资者对毛利率深感关切，因为零部件成本已大幅上涨。大家已经了解，我们正面临内存价格的极端涨价情况，涨幅超出我们此前预期，且明年还将持续走高。对此，我们今天明确设定预期。第三季度，GAAP和非GAAP毛利率预计均为74%，误差幅度±50个基点。预计毛利率将于第四季度触底，区间为71%至72%，随后随着第一季度执行价格上调，在2028财年回升至72%至73%区间。我们希望直接说明这一情况，而不是让其悬而未决。

当前内存紧缺在很大程度上正是由AI基础设施建设本身所驱动，与那些单纯推高我们成本、却无任何对冲收益的零部件不同，内存供应趋紧恰恰是推动我们自身增长的同一需求浪潮的表征。我们与三大内存供应商均保持长期深厚的合作关系，正与其密切协作，进一步扩大我们路线图所需的产能。

GAAP和非GAAP运营费用预计分别约为92亿美元和90亿美元。全年来看，我们现预计运营费用增速约为50%出头，增长动力来自产品组合的持续拓展以及AI工具使用的进一步加深——后者已经并将持续提升工程效率。

2027财年全年，我们继续预计GAAP和非GAAP税率区间为16%至18%，不含特殊项目及税务环境的重大变化。

以上是我的陈述。下面进入问答环节。主持人，请开始提问。

问答部分

主持人： 第一个问题来自摩根士丹利的Joseph Moore。

Joseph Moore（摩根士丹利）：

谢谢。想请教一下70%增速目标的依据——你们此前从未给出全年指引，这次为何有足够信心这样做？另外，需求增速达100%，你们实际能实现70%，这30个百分点的差距究竟来自哪些关键制约？未来能否逐步弥合这一差距？

黄仁勋（创始人、总裁兼首席执行官）：

谢谢，Joe。

人工智能已经真正进入实用阶段。随处可见的AI智能体需要消耗海量算力——大型语言模型因日益强大而规模越来越大，这些智能体要进行推理和规划、多轮工具调用。完成一项任务，智能体所需的算力相当于人类使用量的15到100倍，视问题类型而定。因此，算力需求之巨是有目共睹的。

但还有一部分增长驱动力不那么为人所知。我们的业务在某种程度上几乎是独一无二的——因为我们是全球唯一一家设计、构建并提供完整AI工厂平台、全栈系统的公司。客户当然可以自由组合，但大多数公司既没有能力也没有意愿自行集成。因此，市场中有相当一部分客户群体给我们带来了增长，这包括：主权AI、区域AI、新云、AI初创公司、企业客户，共同构成我们业务的约一半，且这部分每年增速达100%。

从长远看，这部分市场很可能比当前云计算领域的规模还要大。我们所看到的需求，正是由上述所有因素共同驱动的。



还有另一个不可忽视的现实：如今你无法简单地采购技术就能搭建起这套基础设施，必须提前数年保障土地、电力和机房资源。整个供应链的统筹协调——建设、供电、制冷以及所需的大量劳动力——都需要精心规划。AI基础设施正在全美乃至全球创造大量就业机会，但这需要更长远的谋划。因此，我们现在就在深入推进上游基础设施的保障工作。就如同很久以前，人们曾质疑我们身为芯片公司为何要与内存供应商深度合作——如今回过头来看，那正是我们早早布局上游供应链的先见之明。如今，我们与发电商合作，与全球各地的土地、电力及机房合作伙伴合作，这一切都在为最终服务我们生态系统和客户的算力建设做好铺垫。

因此，我们在上下游都拥有了更高的能见度。我们从未以全年为单位进行前瞻指引，但尽管实际需求远超70%，我们对供应端有足够信心保障70%的增长，并将持续与供应链协作，力争突破这一上限。

我们想做的，是让客户、股东和供应链合作伙伴看到完全一致的视角。这一点至关重要，因为各方都在投入大量资源，让所有人对同一套信息高度对齐非常必要。明年将是极为重要的一年，前景令人振奋。

主持人： 下一个问题来自Cantor Fitzgerald的CJ Muse。

CJ Muse（Cantor Fitzgerald）：

好的，下午好，感谢提问机会。投资者目前非常关注您在推理市场的份额。能否谈谈您所观察到的智能体AI工作负载的演变趋势，以及随着全栈平台代际更迭、ACI&E板块增长加速，以及Grok 3 LPX的加入，您预计自身份额将如何演变？

黄仁勋：

谢谢CJ。

AI的全生命周期正变得远比以往复杂，而这愈发契合英伟达的架构优势。可以将其划分为四个阶段：第一阶段，准备所需数据，涵盖合成数据、真实数据，以及人工标注和生成的数据；第二阶段，预训练模型；第三阶段，后训练；第四阶段，智能体推理。每个阶段都相当复杂，而智能体推理尤为如此。

英伟达架构的卓越之处，正体现于NVLink 72机架级架构的创新。当我们首次推出世界上第一个机架级架构时，这震惊了整个行业——打造第一代产品绝非易事，极具挑战性。如今，我们已进入NVLink 72机架级系统的第三代。为此，我们重塑了整个供应链，重新设计了系统，重新发明了技术，重构并重写了软件——每一个环节都历经艰辛。但它使我们得以打造出一套统一的、可灵活调度的系统，能够在数据创建、数据准备、预训练、后训练到智能体推理之间无缝切换，为客户带来难以估量的价值。

而这一点之所以意义重大，在于每吉瓦的英伟达技术所对应的营收贡献正在持续攀升。在Hopper时代，配合InfiniBand，每吉瓦约对应180亿美元；到了Vera Rubin时代，加上CPU、三种不同类型的网络（因为需要多种网络类型才能覆盖全球数据中心的完整需求，更不用说园区内安全网络和跨园区网络），以及Groq，每吉瓦营收机会已上升至400亿美元。一个数据中心每吉瓦对应的投资，已从大约五年前的约300亿美元增至今天的约600亿美元。

当然，生产效率是相当惊人的，性能提升也是有目共睹的。但面对600亿美元的投入，如果能够跨越AI生命周期的多个阶段充分利用，运行各种类型的模型——无论是扩散模型、自回归模型、状态空间模型还是各类混合架构，无论注意力机制如何变化，大模型还是小模型——那么这笔投资将能更长时间地保持其价值和生产力。因此，我认为我们在这个新时代的竞争优势是相当显著的，这也解释了为何我们的增长非但没有放缓，反而还在加速。



谈到Grok，我对Grok 3感到无比兴奋。我们实现了创纪录的token交互速率，延迟极低，团队表现非常出色。过去几个月，我们一直在将NVLink架构深度融合进来——这将成为核心引擎，承担绝大多数工作负载。而对于需要极高交互性和极速token生成的服务，虽然吞吐量会低一些，每token成本也更高，但可以将其与高客单价服务相匹配。对于这类公司，可以在系统上附加一个Groq加速器。我对此非常期待。当然，全球数据中心的绝大多数工作负载，将依托Vera Rubin NVLink 72来完成。

主持人： 下一个问题来自Bernstein Research的Stacy Rasgon。

Stacy Rasgon (Bernstein Research)：

大家好，谢谢提问机会。2028财年70%的增速——对应的是大约2027日历年，如果我往回推算，这意味着与此前展望相比大约增加了2000亿美元，此前的三年展望约为1万亿美元。能否帮我们拆解一下这一提升的构成，包括Vera、CPU、Grok等各产品线的贡献？另外，您提到第一季度的价格上涨将生效，我猜其中也有一部分是定价因素。还有，我知道我可能问题太多了，但请问如果没有供应制约，实际数字会是多少？

黄仁勋：

无供应制约的情况下，数字会高出很多。我们今年已实现同比增长100%，而无约束需求更为可观，我们必须更加努力地扩大产能。我们拥有庞大的供应链，合作伙伴非常出色，已锁定大量供应，但仍需要更多。

要理解这个问题，首先要认识到，大多数人只看到超大规模云，而那只是一半的图景。另一半是我们所说的ACI&E板块，涵盖所有企业、新云、主权AI——这部分对大多数人来说几乎是不可见的，原因在于他们不购买定制芯片，也不是逐颗购买芯片，他们真正需要的是一套专为其构建的工厂平台，而这恰恰是我们能够带来极大价值的领域。

超大规模云当然也在飞速增长。大家都知道，他们如今积压订单超过2万亿美元；都知道英伟达算力一旦上线，他们的营收就随之上涨，利润贡献就随之扩大。算力如今已经高度盈利，并直接转化为营收增长。因此，各方都在争相引入更多英伟达算力——既包括超大规模云，也包括超大规模云之外那些真实存在却难以被外部观察到的机会。

另外，我们为大家梳理了每吉瓦营收的演变：Hopper时代约180亿美元，Grace Blackwell约250亿美元，Vera Rubin约400亿美元，且每代产品的生产力都在大幅提升。因此，客户希望尽快迁移到下一代。与此同时，由于英伟达算力极富生产力，客户出售的token、出租的GPU时长都获利丰厚，利润率相当可观。这一切都在同步发生。

从宏观视角来看，我们正在经历一场影响深远的平台转型。全球每个行业都在使用计算机，因此每个行业都受到影响，每家企业都受到波及。这种全新的计算方式具有智能化特征——不再是基于文件检索，而是生成式的，能够产出智能，而这需要算力，但所能带来的成果是非凡的，从根本上改变了游戏规则。全球所有人都想参与AI革命，所有人都必须参与这场算力变革，所有人都必须构建基础设施。

主持人： 下一个问题来自美银证券的Vivek Arya。

Vivek Arya (美国银行证券)：

感谢提问机会，也感谢你们提供了这么多透明度、多年承诺和保障。我将CFO评论中的所有数字加总，得出一个约5000亿美元的数字，显然是横跨未来数年。我有几个问题：第一，这个理解是否正确？所有生态系统投资加总在这个量级，还是说未来仍有其他股权或投资待公布？第二，2028财年有多少具体的现金支出需要考量？第三，Jensen，您提到的很多投资是为了支持前沿AI实验室，尤其是OpenAI和Anthropic。但两家都在自研芯片，事实上OpenAI近几天还发

布了"Jalapeno", 声称优于Blackwell。请问您如何看待这一动态——一方面大力投资生态系统, 另一方面生态系统内的成员又在研发竞争性解决方案?

黄仁勋:

我们构建的是截然不同的东西。这些XPU大多是面向单一云或单一服务的推理专用芯片, 而英伟达是一个覆盖AI全生命周期的完整AI工厂平台——可在任何云上运行, 已进驻每一朵云, 可在任何地方部署, 我们会协助在任何地方完成搭建。

所有AI服务在某一时刻都会走向全球, 而在那些海外数据中心里, 基础设施不一定由这些公司自建。我完全预期他们的服务将在全世界的英伟达平台上运行。我对我们的技术有百分之百的信心, 相信其在数据处理、训练、后训练到智能体推理的完整链条上, 经济价值将持续出众。他们会使用, 会长期使用。因此, 我非常有信心, 他们将长期是我们的客户和合作伙伴。

退一步讲, 投资这些公司——不止两家, 我们投资了多家AI实验室——是千载难逢的机会。我唯一的遗憾是没有投得更多、更早。其中两家即将上市, 其他也将陆续跟进, 它们将成为历史上最具影响力的科技公司之一。我很高兴能成为他们的朋友, 很高兴与他们合作, 很高兴他们在英伟达架构上构建生态系统, 也很高兴他们依赖我们持续扩大规模。我有百分之百的信心, 在相当长的时间里, 他们的大量算力需求都将由英伟达来承载。对此, 我感到非常欣慰。

Colette Kress:

Vivek, 我来补充一些关于承诺的说明, 尤其是其中的供应承诺部分。供应承诺对于当前Vera Rubin的爬坡以及明年的持续建设至关重要。可以看到, 这些承诺中最大的部分集中在前三年, 我们将以此为基础生产所需产品。这也正是我们对增长和营收信心充足的根本原因——我们已经在供应和产能两个维度完成了大量前置性对齐。

主持人: 下一个问题来自瑞银集团的Timothy Arcuri。

Timothy Arcuri (瑞银集团):

谢谢。Jensen, 我想请教关于开源模型的问题。有很多讨论认为, 开源模型可能会在美国市场抢占工作负载份额。英伟达在Nemotron上显然布局良好, 但另一方面, 大量终端需求正是由大型前沿模型公司所驱动的。许多投资者认为开源模型的崛起会对那些公司的增长构成负面影响。请问您如何看待这个问题? 开源模型的兴起, 对英伟达而言是利好还是利空?

黄仁勋:

这个世界既需要闭源模型, 也需要开源模型, 两者的使用量都在飞速攀升。绝大多数开源模型运行在英伟达平台上, 原因在于英伟达在全球的覆盖足迹最广, 架构兼容性最强, 无处不在——从DGX Spark等PC和边缘设备 (表现非常出色), 到机器人、工作站, 再到本地部署的数据中心, 全部覆盖。

开源模型发展势头极好, 闭源模型同样如此。前沿实验室的销售额正在飙升, 利润率相当可观, 产出的token都是盈利的, 唯一的制约就是算力。开源模型也面临同样的局面。我们在开源模型领域的地位很强, 因为CUDA生态系统无处不在。开源模型对几乎所有AI初创公司和企业而言都是根基所在, 原因很简单: 只要有机会, 就应该尽可能使用能够购买到的强大智能, 这也是我鼓励员工尽量使用云端服务的原因。但每家大型企业、每个国家、每家初创公司都需要构建自己的领域特定、专有AI和专有优势。开源模型达到前沿水平, 正是使这一切成为可能的关键。

开源前沿模型至关重要的一个领域是网络安全。大量网络安全公司正是依托前沿模型, 才得以打造分布式、大规模、持续运行的自主网络安全防御系统, 这些令人惊叹的公司正在快速涌现。没有开源模型, 这一切根本无从实现。因此, 开源模型不仅取得了巨大成功, 不仅终于达到了前沿

水平，更是美国经济、世界经济和各企业构建自有专属AI的关键支柱——两者缺一不可，都将极为成功，而且两者正在同步驱动我们的销售增长。

最后，在我们覆盖的所有AI模型份额中，我们是——我认为也几乎肯定是——唯一运行所有前沿模型的平台，无论闭源还是开源，大多数都构建于英伟达之上，因此都能在英伟达上出色运行。只要模型蓬勃发展，我就感到高兴，而闭源和开源模型都将蓬勃发展。

主持人： 下一个问题来自Melius Research的Ben Reitzes。

Ben Reitzes（Melius Research）：

嗨，谢谢。Jensen，我想换一个角度问关于需求的问题。您提到明年需求可能增长100%，我想知道驱动这一增长的几个背景因素，以及更长远的前景。有两个概念很值得关注：一是递归自我改进（RSI），据报道Anthropic和OpenAI在这方面进展顺利；二是OpenAI表示今年年底可能实现AGI。请问RSI和AGI的发展，将如何影响行业需求？是否会带来进一步的拐点，对英伟达意味着什么？

黄仁勋：

谢谢你的提问。

需求将进一步提速。今天，绝大多数AI是由人主动触发的。我相信上个月已经出现了转折点——大多数AI现在已经是智能体驱动的。而在不远的未来，每家公司都将拥有大量的智能体。英伟达目前大约有4万名员工，未来我们将拥有40万个、乃至400万个智能体，这些智能体全天候持续运行，在后台不断工作。任何有机会接触边缘个人AI智能体的人都知道，在DGX Spark或DGX工作站上运行AI智能体，意味着它会全年无休地处理各种任务。当世界真正进入全面智能体系统的阶段，智能体将持续运行，相互协作，在后台默默改进公司运营，改善人们的生活。

在很多方面，我们现在已经处于某种形式的递归改进之中——虽然是粗粒度的，但每次智能体运行后，它都会反思如何做得更好，并更新技能文档（Markdown格式的技能档案）。下次运行时，它的表现就会更好——这是一种松散的粗粒度自我改进，已经随处可见。

因此，在某种意义上，对于许多任务而言，我们可以说已经实现了AGI。我认为这些里程碑现在意义已经不大。对行业而言，真正重要的是：第一，AI正在做有价值、有意义的工作；第二，AI正在产出盈利的token；第三，如果我们拥有更多算力，就能产出更多盈利的token，从而为所有服务带来更多利润。这正是我们当下所处的阶段，也是所有人全力押注的根本原因。

主持人： 下一个问题来自高盛的Jim Schneider。

Jim Schneider（高盛）：

下午好，感谢提问机会。您提到无约束需求可能增长100%，而实际供应端可实现的增速约为70%。能否帮助我们了解或排序当前最关键的瓶颈？包括数据中心电力及机房供应、DRAM、晶圆代工产能等，哪些是其中最为紧迫的制约因素？谢谢。

黄仁勋：

我本来可以说句俏皮话，但还是算了。

过去一年最有趣的事之一，就是看看我去哪里吃晚饭，和谁共餐——第二天对方的股价就翻倍了。认真回答的话：我们整个供应链都面临挑战，每一个环节都在全力冲刺。更多产能正在陆续上线，这也是今年有利的地方——产能不会在某一个时间节点集中释放，而是每天都在增加。良率在持续提升，我们也在积极推进良率改善，与每一家供应商密切协作。



现在还没有到明年，我们有大量的时间可以持续努力。此时此刻，我们拥有的供应对应70%增速，实际上略多于70%，但需求远高于此，我们必须加倍努力，否则就会让客户失望——而我們不希望让客户失望，我们愿意为他们努力付出。因此，我需要整个供应链的共同支持，而他们都清楚这一点。我现在向你们传达的明年需求信息，与我告诉供应链伙伴的信息完全一致——大家看到的是同一张乐谱。我努力保持尽可能高的透明度，因为我们谈论的是巨大的数字，所有参与方都需要拥有同等的信息。

主持人： 最后一个问题来自富国银行的Aaron Rakers。

Aaron Rakers（富国银行）：

谢谢提问机会。我想回到每吉瓦营收这个话题，从250亿提升至400亿美元。Jensen，您在最近一些会议上提到，这一数字还会进一步提升。在我们展望Vera Rubin Ultra及其后续产品时，是否可以理解为从400亿将走向600亿、800亿？另外，如何看待2027财年——抱歉，是2028财年——产能部署规模的扩展路径，这是一个线性过程，还是说存在某种供应释放的转折点？

黄仁勋：

好问题。

答案其实很简单：我们的目标是在单位土地上、单位吉瓦内塞入尽可能多的算力，方向是无限，当然我们力争越来越接近理想极限。在通用计算和摩尔定律时代，每吉瓦算力对应的市场规模大约是30亿到50亿美元；到了Hopper时代是180亿，Grace Blackwell是250亿，Vera Rubin是400亿，而之后还会继续提升——这是必然方向。

这对整个行业是极大的利好，对客户而言同样如此。只要生产力持续提升，灵活性和耐久性持续增强，客户就会乐于持续投资这些能产出营收、产出利润、帮助他们快速实现投资回报的资产。我最近听说，如今投资回报周期已缩短至不到一年——而我们谈论的是500亿美元规模的数据中心。这充分说明英伟达技术的生产力以及其可租用性的价值。

感谢各位今天的参与，问答环节到此结束。有请Toshiya Hari。

Toshiya Hari：

谢谢。在结束之前，请注意Jensen将于9月10日在旧金山高盛Communacopia科技大会上参加主题炉边对话，并将于10月21日在柏林GTC大会上发表主题演讲。关于2027财年第三季度业绩的财报电话会议定于11月17日召开。感谢各位今天的参与。主持人，请结束会议。

主持人： 今天的电话会议到此结束，您可以断开连接了。活动已结束。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免



写评论

请发表您的评论



表情



图片

发布评论

6 条评论



见闻用户

5小时前 中国上海

一个左手倒右手的公司，没有需求自己创造需求，所有一切都是自己编织起来的一个根本没有这么多需求的骗局，大而不能倒绑上了401k，绑上美国国运，简直是疯狂至极

👍 0 ↩ 回复



1560000585076

11小时前 中国广西

即使没有国内市场，也是牛逼！不得不服

👍 1 ↩ 回复



赚钱买金毛

13小时前 中国山东省

黄仁勋疯狂借钱给买家买自家芯片，把所有公司捆绑在一起，把所有船链接在一起，非常危险，功利心急不可耐。为了一己私利，把所有关联企业绑上自家战车黄仁勋疯狂借钱给买家买自家芯片，把所有公司捆绑在一起，把所有船链接在一起，非常危险，功利心急不可耐。为了一己私利，把所有关联企业绑上自家战车

👍 1 ↩ 回复



FisH·Man 11小时前 中国浙江省

回复 赚钱买金毛：

你以为就那么简单？幼稚

👍 0 ↩ 回复



MobileUser9059 VIP会员

13小时前 中国

利好茅台，每8块 gpu消耗一瓶茅台

👍 2 ↩ 回复



浙海石 VIP会员 11小时前 中国浙江省

回复 MobileUser9059：

哈哈哈哈哈

👍 0 ↩ 回复

