

摘要：

英伟达管理层在电话会上表示，当前需求正在加速，并将2030年末年度AI行业整体开支规模预测，上调至3万亿至4万亿美元。“智能体AI”驱动下一波算力基础设施建设狂潮，并首次将CPU业务作为未来核心增长引擎推向台前。预计今年CPU收入有望达到200亿美元。



受益于“智能体AI”时代的爆发，英伟达不仅交出了单季营收820亿美元的历史新高答卷，更通过超预期的股东回报计划和瞄准2000亿美元全新市场的CPU战略，试图向华尔街证明其高增长的持续性与广阔的想象空间。

5月20日，[华尔街见闻提及](#)，英伟达公布强劲财季业绩，第一季度总营收达到820亿美元，同比增长85%，环比增长20%。这已经是英伟达连续第三个季度实现同比加速增长，以及连续第14个季度环比增长。

公司管理层在电话会上表示，“智能体AI”驱动下一波算力基础设施建设狂潮，并首次将CPU业务作为未来核心增长引擎推向台前。

英伟达预计今年CPU收入有望达到200亿美元，并表示相信公司能够获得足够供应以支撑持续增长。

公司CFO Colette Kress表示，公司当前需求正在加速，并将2030年末年度AI行业整体开支规模预测，上调至3万亿至4万亿美元。

英伟达CEO黄仁勋则预计Vera Rubin在整个生命周期内都将面临供应受限局面。

在利润极其充沛的背景下，英伟达宣布新增高达800亿美元的股票回购授权。同时，季度股息从每股0.01美元大幅上调至0.25美元。公司计划在今年将50%的自由现金流返还给股东。

“需求呈抛物线增长”，智能体AI成新引擎

在财报电话会上，英伟达CEO黄仁勋直言：

需求呈抛物线增长。原因很简单，智能体AI已经到来。

黄仁勋指出，自ChatGPT问世以来，主流AI已经从一次性推理过渡到逻辑推理，现在又进入了“智能体”阶段。AI不再是可有可无，而是必需品。他表示：

词元（Tokens）现在是有利可图的。在AI时代，计算能力就是收入和利润。

为了应对这种转变，AI基础设施的建设正在加速。

管理层引用分析师预测称，2027年超大规模数据中心（Hyperscale）的资本支出将超过1万亿美元，而到2030年末，AI基础设施的年度支出有望达到3万亿至4万亿美元。

推理份额激增，Rubin架构下半年接棒

在订单履约和未来业绩指引方面，CFO Colette Kress表示，GB300和VL72的需求尤为强劲，标志着公司历史上最快的产品爬坡。

针对市场对其在推理市场份额可能被定制芯片（ASIC/LPX等）蚕食的担忧，黄仁勋强硬回应：

我们在推理领域的份额正在非常、非常快地增长。

他指出，随着Anthropic等前沿模型公司加入英伟达生态，公司在推理端的算力部署正急剧扩大。

对于基于SRAM的定制芯片（如LPX），黄仁勋认为其吞吐量和上下文处理能力较低，他认为：

在未来一段时间内，它仍将是一个小众产品（Niche product）。

在下一代产品节点上，黄仁勋宣布：

我们将于今年下半年，从Q3开始启动Vera Rubin的量产出货。Vera Rubin在这一点上将比Grace Blackwell更加成功。我能想到的每一家前沿模型公司，从一开始就会全面转向Vera Rubin。

通过集成七个专用芯片，Vera Rubin的推理吞吐量最高可达Blackwell的35倍。对于未来，黄仁勋总结道：

世界正在为智能体AI和机器人物理AI重建计算体系。我们在这一刻到来之前就建立好了架构，所以当智能体AI到来时，英伟达已经准备好了。它现在真的来了。

全新王牌Vera CPU，打开2000亿美元市场

本次电话会最大的增量信息和想象空间，来自于英伟达对CPU业务的重磅加码。

面对“智能体AI”需要大量调用工具、浏览器和进行编排调度的特性，单纯的GPU已经不够，市场需要全新的CPU架构。黄仁勋宣布：



Vera CPU为英伟达打开了一个全新的2000亿美元的市场，这是我们以前从未涉足过的市场。

Vera不仅将作为Rubin GPU的配套设备销售，还将作为独立CPU、存储节点和安全节点出售。

黄仁勋透露，今年已有望看到近200亿美元的独立CPU总收入，这标志着英伟达正准备成为全球领先的CPU供应商。

Vera Rubin系统将于今年下半年（Q3开始）量产出货，其推理吞吐量比Blackwell高出35倍。

更改业务指引框架，数据中心走向多元化

为了让投资者更好地理解业务结构的健康度，英伟达在本次财报中更改了报告框架，将业务划分为“数据中心”和“边缘计算”两大平台。

数据中心业务（Q1营收750亿美元）进一步细分为“超大规模云厂商（Hyperscale）”和“ACIE（AI云、工业和企业）”：

- **Hyperscale（380亿美元）**： 占据数据中心约50%的份额，环比增长12%。
- **ACIE（370亿美元）**： 环比增长高达31%，其中AI云收入同比激增两倍以上，主权AI收入同比增长超80%。

值得注意的是，英伟达未将任何中国数据中心计算收入计入预期。分析认为，该数据回应了市场此前关于英伟达“过度依赖少数几家硅谷云巨头”的担忧。

黄仁勋指出，第二类市场（ACIE）极其分散且庞大，代表了未来数百万家企业的需求，而英伟达提供的是最容易租赁、TCO（总体拥有成本）最优的完整AI工厂解决方案。

英伟达2027财年第一财季电话会议实录，全文翻译如下（AI工具辅助）：

主持人致辞

下午好，我是今天的会议接线员Sarah。欢迎参加英伟达第一季度业绩电话会议。为防止背景噪音干扰，所有线路已静音。发言人讲话结束后，将进行问答环节。谢谢。现在请Toshiya Hari开始发言。

Toshiya Hari（投资者关系与战略财务副总裁）

谢谢，大家下午好。欢迎参加英伟达2027财年业绩电话会议。今天与我一同出席的有英伟达总裁兼首席执行官黄仁勋，以及执行副总裁兼首席财务官Colette Kress。本次电话会议在英伟达投资者关系网站上进行网络直播，并将提供回放，直至我们召开2027财年第二季度业绩电话会议。

本次电话会议的内容为英伟达的财产，未经我们事先书面同意，不得复制或转录。本次电话会议中，我们可能会基于当前预期作出前瞻性陈述，这些陈述面临多项重大风险和不确定因素，实际结果可能与陈述存在重大差异。如需了解可能影响我们未来财务业绩和业务的相关因素，请参阅今日业绩发布文件、我们最近提交的10-K和10-Q表格，以及向美国证券交易委员会提交的8-K报告。

本次电话会议中所有声明均以2026年5月20日为基准，基于我们目前可获取的信息。除法律要求外，我们不承担更新上述声明的义务。本次电话会议中，我们将讨论非GAAP财务指标，相关GAAP与非GAAP财务指标的调节表已发布于我们的网站CFO评论栏目中。下面我将把发言权交给Colette。

Colette Kress（执行副总裁兼首席财务官）

谢谢Toshiya。

本季度我们取得了出色业绩，营收、营业利润和自由现金流均创历史新高。总营收为820亿美元，同比增长85%，环比增长20%。这是我们连续第三个季度实现同比加速增长，也是连续第14个季度实现环比增长——考虑到我们制造运营的规模和复杂程度，这一成绩尤为难得。

本季度135亿美元的环比营收增量同样创下历史纪录。我们抓住推理需求的拐点机遇，向多元化终端客户群加速铺开Blackwell系统，覆盖超大规模云厂商、模型开发商、AI云服务提供商及主权客户。与此同时，本季度我们在研发、生态系统投资和股票回购方面高效配置资本，向股东返还了创纪录的200亿美元，并在上游供应链和下游市场生态两端同步推进战略投资。这对市场的长期发展和我们的长期市场地位至关重要。

数据中心营收为750亿美元，同比增长92%，环比增长21%，主要受Blackwell架构持续强劲需求驱动。GB300和VL72在前沿模型构建者和超大规模云厂商中需求尤为强劲，各方累计部署的Blackwell GPU均已达到数十万枚，创下我们公司历史上最快的产品爬坡速度。Grace Blackwell是目前最快的训练系统，同时也是推理环节单位token生成成本最低的平台。

我们专为AI打造的端到端以太网平台Spectrum X，规模已超过所有以太网同类竞争对手的总和。InfiniBand本季度同样表现强劲，在下一代XDR技术部署的带动下，同比增长超过4倍。针对前沿模型，数据中心算力营收为600亿美元，同比增长77%；数据中心网络营收为150亿美元，同比接近翻三倍。

在深入介绍数据中心业务之前，我们希望先向大家介绍我们向新汇报框架的转变，新框架能更好地反映我们当前和未来的增长驱动因素。

我们设有两个市场平台：数据中心和边缘计算。数据中心下设两个子市场：超大规模（Hyperscale）和ACIE（涵盖AI云、工业及企业）。超大规模包含来自公有云和全球最大消费互联网公司的营收；ACIE则面向各行业和各国家中多元化的AI专用数据中心及AI工厂的增长机遇。边缘计算涵盖面向智能体AI和物理AI的终端设备，包括PC、游戏主机、工作站、AI-RAN基站、机器人及汽车。我们已在官网发布基于新平台口径的过去九个季度营收明细，供大家参考。

回到数据中心业务，超大规模营收为380亿美元，约占数据中心营收的50%，环比增长12%。ACIE营收为370亿美元，环比增长31%，其中AI云营收同比增长超过两倍。客户方面，AI算力容量的快速建设能力显著增强——规模超过10兆瓦的合作伙伴数据中心在短短一年内数量几近翻倍，目前已超过80个站点。主权营收同比增长超过80%，英伟达AI基础设施目前已部署于近40个国家，覆盖GDP总量约50万亿美元。

正如本季度业绩所呈现的，我们的客户基础多元且持续壮大，背后依托的是我们庞大的生态系统和已有的装机规模、CUDA加速应用的广度，以及作为最低token成本提供商的竞争优势。我们有充分的条件抓住这一远超任何其他AI计算平台的市场机遇。

AI基础设施需求正在以前所未有的速度持续扩张，AI工厂建设步伐不断加快，英伟达AI基础设施的价值也在持续提升。H100的租用价格年初至今上涨了20%，A100的云端定价涨幅接近15%。得益于我们平台的多功能性以及软件栈带来的持续性能提升，客户在其GPU折旧期满后仍能持续产生盈利性收入。英伟达计算平台庞大且值得信赖的市场，是支撑整个生态系统数千亿美元AI基础设施投资的关键基础。



AI基础设施建设加速背后有两大主要驱动力：

第一，从搜索和广告到推荐系统，再到内容理解，超大规模厂商的大型工作负载正在持续从CPU向GPU加速计算迁移。第二，AI原生产品和服务的采用正在迎来拐点。自ChatGPT问世以来，主流AI已经历了从单次推理到推理增强、再到如今智能化体的演进。AI已不再是锦上添花，而是在所有行业和岗位提升生产力的必要工具。这正在推动AI全栈各层——包括能源、芯片、基础设施、模型和应用——的营收加速增长。

模型层的增长尤为亮眼，Anthropic和OpenAI势头强劲、持续提速，其中自GPT-5.5发布以来，OpenAI Codex的爆发式增长尤为突出。分析师目前预测超大规模厂商2027年资本支出将超过1万亿美元，随着智能体AI开始向各行业全面渗透，AI基础设施支出有望在本十年末达到每年3至4万亿美元。

我们的Blackwell架构已无处不在，被每一家主要超大规模云厂商、每一家云服务提供商和每一家主要模型开发商采用并投入部署。上个月，我们庆祝了OpenAI发布GPT-5.5——该模型针对Blackwell进行协同设计、在Blackwell上完成训练并由Blackwell提供服务，目前位居Artificial Analysis排行榜首位。微软全球最强大的AI数据中心Fairwater已提前上线，由数十万枚Blackwell GPU提供算力支持。从今年起，AWS将新增超过100万枚Blackwell和Rubin GPU，并在Spectrum网络方面展开合作。在谷歌方面，Blackwell将向云端客户开放，包括支持机密计算能力，为安全、高性能AI提供全新基础。

我们在前沿AI算力领域的市场份额正在不断提升。我们深化了与Anthropic的合作，很高兴成为其战略合作伙伴，共同扩大算力规模，并将通过AWS、Azure、CoreWeave、SpaceX xAI等多个渠道支持Anthropic的增长。此外，目前已在英伟达平台上构建的重要前沿实验室还包括：OpenAI、Gemini、SpaceX xAI、Meta、MSL、Microsoft AI、TML、Reflection、Perplexity、Cursor等。随着Anthropic的加入，我们在前沿AI模型领域的市场份额将大幅提升。

当今的数据中心是受功耗和资本约束的创收型AI工厂，AI工厂运营商必须选择正确的架构。凭借我们极致的协同设计理念，我们能够提供业界最低的token成本、最高的token吞吐量和最高的投资回报率。最新的MLPerf推理测评结果出炉，Blackwell Ultra再次横扫全部基准测试，在广泛的模型类型和部署场景中实现了最高吞吐量。全栈创新推动GB300相较六个月前吞吐量提升2.7倍，每token成本降低60%。

英伟达算力不仅是性能最高的AI基础设施，更是最具经济性、最易融资的选择。客户购买的不是GPU，而是在构建AI工厂，正确的经济衡量指标不是GPU的购置价格，而是AI工厂生产智能的全生命周期成本——每瓦token数、每美元token数、运行时间、利用率、投入生产的时间、软件持久性，以及资产寿命。英伟达在所有这些维度上均表现卓越。

智能体AI和强化学习为CPU带来了全新的增长机遇。在Grace CPU成功的基础上，Vera CPU的到来恰逢其时，有望把握这一拐点。Vera基于定制Arm核心构建，与Rubin GPU和NVLink进行端到端协同设计，相比x86架构方案，可实现最高1.5倍的单核性能提升、2倍的每瓦性能提升，以及4倍的机架密度提升。

Vera CPU为英伟达开辟了一个全新的2000亿美元市场，是我们此前从未涉足的领域，且每家主要的超大规模厂商和系统厂商都在与我们合作推进部署。我们预计今年CPU营收将接近200亿美元，这将助力我们成为全球领先的CPU供应商。

我们每年保持无与伦比的产品迭代节奏，这仍然是支撑我们市场地位的核心支柱。Vera Rubin的量产出货预计将于今年下半年启动，从第三季度开始。通过将七颗专用芯片集成于五个加速机架之中，Vera Rubin相比Blackwell将实现最高35倍的推理吞吐量提升，以及最高10倍的AI工厂营收提升。



作为早期采用者，谷歌的A5X裸金属实例最多可支持跨多个站点部署96万枚Rubin GPU，使客户能够在英伟达优化基础设施上运行其最大规模的AI工作负载。

关于中国市场，虽然美国政府已批准向中国客户出口H200的许可证，但我们尚未产生任何相关营收，且对于货物是否被允许进口至中国仍存在不确定性。因此，与上一季度保持一致，我们在业绩展望中未纳入任何中国数据中心算力营收。

边缘计算业务方面，我们的边缘计算市场平台营收为64亿美元，环比增长10%，同比增长29%。Blackwell工作站的强劲需求是本季度增长的重要贡献因素，而消费端需求则因内存和整机价格上涨而略有下滑。物理AI继续保持强劲增长势头，过去12个月营收超过90亿美元。我们与Uber的合作将于2028年前为近30个城市、四大洲的Robotaxi车队提供技术支持。在机器人领域，工业、手术和人形机器人等各类应用的领先企业正基于英伟达技术进行大规模开发和部署。

我们持续积极推进供应保障工作，以支持客户增长。第一季度，我们将涵盖库存、采购承诺和预付款在内的总供应量增至1450亿美元。尽管我们无法完全规避供应挑战，但我们对支撑未来增长机遇的能力保持充分信心，我们在专注度、规模以及与关键供应商的长期合作关系方面的优势将持续发挥作用。

利润表方面，GAAP毛利率为74.9%，非GAAP毛利率为75%，环比基本持平，Blackwell系统在出货中持续占据主导地位。GAAP和非GAAP运营费用环比均增长12%，主要由薪酬提升和计算及基础设施成本增加所驱动。非GAAP有效税率为16%，略低于此前预期，原因是地域结构改善。资产负债表方面，应收账款周转天数为45天，主要受回款时间节点有利影响，预计第二季度将恢复至55天左右。本季度实现创纪录的自由现金流490亿美元，高于第四季度的350亿美元。

资本配置方面，我们的首要原则是优先保障研发和战略投资，这将使我们能够培育生态系统、推动市场增长并巩固市场地位。作为AI的核心使能平台，我们将持续进行必要的投资，以实现业界最低的每token成本和最高的token吞吐量，从而帮助客户和合作伙伴持续扩大AI边界。

股东回报计划是我们资本配置策略的另一核心组成部分。鉴于我们对长期自由现金流前景的信心，以及与股东共享成长成果的承诺，我们将季度股息从每股0.01美元提升至每股0.25美元，并将随着业务规模的持续扩大定期审查股息政策。我们还宣布新增800亿美元的股票回购授权，叠加现有计划中剩余的390亿美元。正如我们在GTC上所宣布的，我们计划今年将50%的自由现金流回报给股东。

第二季度业绩展望：总营收预计为910亿美元，上下浮动2%，环比增长主要由数据中心驱动。我们正在持续大力推进供应链生态系统建设，以应对我们所预见的巨大需求，这给予我们充分信心——我们预计2025年至2027年期间，Blackwell和Rubin平台的累计营收将达到1万亿美元。GAAP和非GAAP毛利率预计分别为74.9%和75%，上下浮动50个基点，全年仍预计维持在70%中段水平。GAAP和非GAAP运营费用预计分别约为85亿美元和83亿美元，全年运营费用增速预计在40%高段，主要由研发投入增加以及AI工具使用加速所驱动。

2027财年全年，我们预计GAAP和非GAAP税率在16%至18%之间（不含重大税务环境变化相关的离散项目），低于此前17%至19%的预期，原因是地域结构改善。

以上是我准备好的内容，接下来将进入问答环节，交回给Toshiya主持。

Toshiya Hari（投资者关系与战略财务副总裁）

感谢Colette。我们现在进入问答环节，请接线员开始提问。

二、问答环节

第一问：细分市场划分逻辑（摩根士丹利 Joseph Moore）



Joseph Moore（摩根士丹利）： 感谢提问机会。我想请教，本次细分市场调整的背后逻辑是什么？两个细分市场在竞争格局上有何差异？另外，您提到的那个令人意外的CPU数据，如何在两个细分市场中理解？谢谢。

Toshiya Hari： 感谢Joseph。首先需要更正一点，Colette刚才说的季度股息应是从每股0.01美元提升至每股0.25美元，请大股东们留意这多出来的0.05美元。

关于细分市场的调整，我们希望帮助大家更好地理解我们的业务。AI是多元的，计算本身也是多元的，体现在多个维度：

第一，AI本身是多元的。 根据行业不同，AI的形态各异——制造和工业机器人领域是三维图形，生命科学领域是蛋白质结构，生命科学或材料科学领域是小分子化学，物理科学（无论是能源领域还是高校科研实验室）则是物理仿真，不一而足。

第二，应用场景是多元的。 应用场景涵盖企业、能源、制造等各行各业。

第三，运行环境是多元的。 可以在超大规模云上运行，可以在AI原生云上运行——而这类AI原生云正在全球各地不断涌现；可以在企业本地部署，可以在工厂、车间等工业场景中运行，也可以在超算中心和边缘端运行。边缘端涵盖大家熟知的自动驾驶汽车和机器人，但同样还包括芯片厂、封装厂、各类制造工厂内部不断扩大的计算网络。未来，每一个基站、每一个无线网络都将成为AI驱动的无线网络。

第四，治理方式是多元的。 部分工作负载可以运行于公有云，但也有一些因工业法规合规要求、机密计算需求或国家安全原因而无法上云，需要专门构建独立的数据中心。

英伟达独特之处在于，我们是唯一一家构建全部技术组件的公司，以极致协同设计的方式、完整端到端、全栈的方式进行研发，同时保持平台开放性，使其能够集成进各类不同环境。而某些环境，例如企业客户，需要所有技术组件协同工作，不用自己动手构建，能够直接购买并运营完整解决方案。

因此，我们将业务拆分为三大板块：

- 超大规模云：这是第一大板块。在这个板块中，我们帮助超大规模云厂商加速其数据处理和机器学习工作负载，支持其内部AI处理，同时将大量英伟达生态系统业务引入其公有云平台。
- AI原生云、企业本地部署、工业本地部署及主权AI：这是第二大板块，增速极快，因为每个行业、每个国家、每家企业都需要AI，且都希望以不同的方式构建。我们提供完整解决方案，使这一切成为可能，也大大降低了实施难度。
- 机器人边缘计算：这是第三大板块。过去的计算以个人计算为核心，未来将以个人AI为核心。个人AI的一个典型例子就是自动驾驶汽车——本质上是一个作为个人AI存在的机器人系统。未来还会出现各种形态的机器人系统，包括基站无线网络，它本质上也将成为一种机器人系统。

这三大板块各自拥有不同的软件栈、不同的操作系统和运营方式，我们的市场进入策略在每个板块中也大相径庭。超大规模云的市场进入最为简单，因为全球只有五六家超大规模厂商。其余的板块涉及全球约25万家企业，市场进入极为复杂，需要对AI有高度多元化的深刻理解。英伟达拥有全球规模最大的加速库套件，从计算光刻到流体力学、粒子物理、分子动力学，涵盖范围极广，这些库对于我们深入服务第二和第三类垂直行业至关重要。

总而言之，这次调整是因为我们的业务已演进和壮大到如此规模，进行合理细分有助于大家更清晰地了解我们的业务运作逻辑。



第二问：增长哲学与超大规模资本支出展望（Melius Research Ben Reitzes）

Ben Reitzes（Melius Research）： 非常感谢。黄仁勋，我想请教您关于增长哲学的问题。本季度数据中心业务（不含中国）增长约120%，你们的指引约为100%。许多分析师（包括我）预测今年超大规模厂商资本支出将增长90%至100%。您也提到数据中心市场到本十年末有望达到3至4万亿美元的规模。请问，您认为公司增速能否持续超过超大规模厂商资本支出增速？而超大规模厂商资本支出是否会在今年之后继续保持高速增长？

黄仁勋： 感谢Ben。首先，我们理应增长得比超大规模资本支出更快，原因正是我刚才介绍分类逻辑时所阐述的。

我们的数据中心业务由两大部分构成（实际更为复杂，但我简化为两大部分以便于理解）：

第一部分是超大规模业务。这正是你们所关注的超大规模资本支出。今年超大规模资本支出约为1万亿美元，我有充分理由相信这一数字将持续增长。这就是未来计算的运作方式，没有算力就没有营收。这一逻辑非常清晰——算力就是营收，算力就是利润。SaaS模式此前的算力消耗有限，但AI需要海量算力，同时也能创造难以想象的价值。这也正是为什么我们看到Anthropic和OpenAI这样的AI前沿公司以惊人的速度增长——它们在一个月内实现的增长，有些SaaS公司可能需要十年。第一大类的超大规模资本支出目前约1万亿美元，并正在向3至4万亿美元迈进。

第二部分是AI原生云及其他。 包括各类区域性AI原生云，遍布全球各地；有初创公司在为这些平台提供支持；还有约25万家企业——其中许多将自建或希望自建AI工厂；以及大量工业企业——对它们而言，别无选择，必须将计算部署在情境所在地、行动所在地，根本无法依赖云端。想象一下，一家芯片制造厂连接到云服务提供商，这根本行不通。此外还有主权AI云。这第二类数据中心，半定制化芯片根本无法胜任，因为这类数据中心希望购买和运营完整系统，不想自行设计和构建。这第二类不是五六七家公司，而是数百、数千家公司，未来将扩展到数十万家企业，每家规模相对较小。

这第二类将以惊人的速度持续增长。当我谈到物理AI，谈到在过去30年中基本未受IT冲击的近百万亿美元的实体经济产业，它们即将迎来AI的深刻影响，这正是第二类所代表的市场。在这一类别中，我们的市场份额极高，我们几乎是唯一能够服务这一市场的公司。我们的平台构建方式如同垂直整合，一切协同运作，但同时又能拆解开来，供客户按需组合、以自己偏好的方式集成。这第二类的情况远未被充分理解，因为其中涵盖的公司数量庞大，而每一处安装规模相比单个超大规模厂商又相对较小。

因此，综合来看，我们在超大规模厂商中的份额正在增长——Anthropic作为我们的新合作伙伴，未来几年我们将大力帮助其扩大算力。而第二类中，很少有公司能够真正服务这一市场，我们的平台解决方案是关键所在。

第三问：Vera Rubin与推理市场份额（Cantor Fitzgerald CJ Muse）

CJ Muse（Cantor Fitzgerald）： 下午好，感谢提问机会。Vera Rubin即将到来，你们对前沿模型的迭代趋势和多元化AI工作负载的优化方向有着清晰的洞察。投资者对你们在推理市场的份额高度关注，请问Vera Rubin和极致协同工程将如何影响你们在进入26年底和27年时的推理市场份额？

黄仁勋： 我们在推理市场的份额正在快速增长，原因在于今年前沿模型公司的数量大幅增加，涌现出Cursor、Perplexity等新兴公司，以及TML、Reflection等新模型企业。我们今年还将Anthropic纳入合作伙伴体系，他们的扩张速度极快——我们已与其合作，在Azure、AWS、CoreWeave等平台上为其锁定算力，此外还有其他正在推进中的合作伙伴正在陆续上线。今年和明年我们为Anthropic带来的算力规模将相当可观。在此之前，我们对Anthropic的算力覆盖几乎为零，因此我们在推理市场的份额提升速度极快。

Vera Rubin甚至会比Grace Blackwell更为成功。现在我几乎想不到有哪家前沿模型公司不会从一开始就迁移到Vera Rubin——这一点在Blackwell推出时并非如此。Vera Rubin的起点极为强



劲，必将超越Grace Blackwell的成就。

回到Ben之前的问题，以上关于推理份额增长的讨论，实际上聚焦的是超大规模云这第一类。而在第二类AI数据中心中，我们几乎是独家供应商，其中推理业务几乎100%由英伟达承接。当然，物理AI领域目前也基本上只有英伟达一家在服务，我们深耕物理AI已久。因此，综合来看，我们在推理市场的份额正在快速增长。

第四问：LPX与平台战略（UBS Timothy Arcuri）

Timothy Arcuri（UBS）： 非常感谢。黄仁勋，我想请教一下LPX的市场进展。您此前提到Groq在某些市场约占20%份额，我想了解LPX的牵引力情况，以及它如何融入您更广泛的平台战略？

黄仁勋： LPX专为低延迟、高token速率场景设计，但其吞吐量相对较低，支持的模型规模有限，处理长上下文的能力也较弱——例如软件编程、智能体工作负载等需要大量上下文的场景，LPX的能力有所受限。

正如我此前所解释的，LPX的适用场景并不广泛，它的定位是：面向拥有多元化token服务组合的提供商，其中某些服务属于高溢价服务、客户数量有限但单用户token速率极高的应用。这一判断与我之前的分析完全一致。

因此，我预期LPX以及其他基于SRAM、专注于解码、高token速率生成的加速器，在相当长的时间内仍将是一类细分市场产品。相比之下，Grace Blackwell和Vera Rubin支持AI的全生命周期——从数据处理、预训练准备、预训练，到强化学习后训练，再到推理，Grace Blackwell是完成所有这些任务的最好平台。而对于已经拥有高token速率服务的提供商，在特定场景下可以搭配LPX，进一步提升该服务的交付质量。

至于LPX占多少市场份额——20%也好，10%也好，取决于AI的发展阶段。我认为目前远低于20%，未来随着高溢价token服务的发展，这一比例或许有机会达到20%。我们也期待与服务提供商合作，共同推进这一能力。

第五问：CPU与GPU的关系及Vera CPU规模（美国银行 Vivek Arya）

Vivek Arya（美国银行）： 感谢提问机会。黄仁勋，近期关于智能体应用中CPU的讨论热度很高，甚至有说法认为CPU的数量将超过GPU的数量。我想请你从两个角度分析：第一，这是增量性的新工作负载，还是对GPU原有工作负载的替代？第二，您提到的200亿美元规模，是仅针对独立Vera CPU，还是已包含在Vera Rubin整机中的CPU部分？请帮助我们理解CPU与GPU的关系——是竞争还是互补，以及这200亿美元应如何理解？

黄仁勋： 这200亿美元指的是独立Vera CPU。我来介绍一下Vera的四种使用方式：

第一种：Vera Rubin整机。我们将售出数百万套Rubin，每两套Rubin搭配一颗Vera，有相应的价格体系。

第二种：Vera独立CPU。

第三种：Vera搭配CX9网卡及相应软件栈，用于存储场景。

第四种：Vera搭配CX9，配合安全与计算隔离、机密计算软件栈。

以上四种场景都基于Vera构建。我预计在Vera Rubin的整个生命周期内，供给将始终处于供不应求的状态。

关于CPU在智能体AI中的角色——智能体本质上是一个“执行框架”（harness）。这个框架可以是OpenClaw，可以是Hermes；Anthropic的Claude Code本质上是Claude Opus模型外的一层框



架，OpenAI的Codex本质上是GPT-5.5模型外的一层框架。框架负责处理I/O、编排、内存管理，以及工具调用——例如连接浏览器、C编译器、Python编译器等。框架在CPU上运行，工具调用也在CPU上运行。例如，AI执行搜索或使用浏览器时，这些都在CPU上完成。

人类世界有10亿用户，未来世界将会有数十亿个AI智能体，虽然不是今天，但我们会逐步走到那里。每个智能体都会使用工具，这些工具类似于我们今天使用的PC。未来，智能体将拥有自己的"AI PC"。假设现在全球有几十万个智能体，未来有几十亿个，每个智能体都有自己的"PC"来使用。

每个智能体还会衍生出子智能体，每次衍生就需要调用推理——而所有的"思考"都发生在GPU上，所有的编排则在CPU上进行。子智能体在"思考"时使用GPU，在调用模拟器时则可能使用CPU或GPU。这也是为什么我们与Cadence、Synopsys、Siemens、Adobe等公司深度合作——我们正在加速全球所有的设计工具和数据处理、数据库引擎，让它们运行在CUDA上。原因很简单，智能体比人类的容忍度更低，需要更快的响应速度，而工具加速到GPU上能显著提升效率。

Vera正是为智能体时代而设计的CPU。过去的CPU设计逻辑是多核心、便于按核心出租；人们按核心付费，这是传统云计算的经济学。未来AI时代的经济学是每美元token数或每token成本，核心目标是尽可能快地生成和处理token——这正是Vera的强项所在。

我们正在构建的是完整的AI基础设施：出色的存储（这是我们构建STX的原因）、出色的网络（这是我们打造Spectrum X的原因）、出色的GPU与推理能力（NVLink 72）、出色的安全与机密计算（Vera Rubin是全球首个支持端到端机密计算的平台）、出色的CPU。我们一应俱全。

第六问：1万亿美元展望之上的增长空间（高盛 Jim Schneider）

Jim Schneider（高盛）： 下午好，感谢提问。在GTC上，您提到了Blackwell和Rubin平台1万亿美元的可见营收，但我相信这一数字不包括LPX、Rubin CPX和Vera CPU机架。请问Vera CPU是否将成为1万亿美元之上最大的超预期来源？还是说您在考虑其他产品组合，包括CPU，以进一步提升在总市场中的份额？

黄仁勋： 关于1万亿美元之上的增量空间，我认为主要有三个来源：

第一，前沿AI模型市场份额的持续提升。我预期份额将进一步增长，这是最大的增量来源之一。

第二，独立Vera CPU——这未包含在此前的1万亿美元预测中。智能体系统的总市场规模相当可观，我们的客户对Vera的热情非常高，我们将售出大量Vera CPU，这是第二大增量来源。

第三，LPX——如前所述，由于其SRAM架构带来的低延迟、高交互性优势，以及相对有限的吞吐量和上下文处理能力，LPX将服务于一部分细分市场。通过Vera、Vera Rubin和LPX的组合，我们将能够覆盖AI从预训练、后训练到推理、智能体系统的全生命周期和完整需求谱系。

第七问：Vera Rubin爬坡斜率（TD Cowen Joshua Buchalter）

Joshua Buchalter（TD Cowen）： 非常感谢，也恭喜业绩出色。Colette，您在准备好的发言中提到GB300是公司历史上爬坡速度最快的产品。应如何对比看待Vera Rubin的爬坡速度？Vera Rubin虽然在芯片层面是全新架构，但机架形态相似——是否意味着爬坡斜率与GB300相当，还是因为新硅片的缘故会更为平缓？

Colette Kress： 我们此前已说明将在下半年推出Vera Rubin，第三季度将是初始出货阶段，进入第四季度后爬坡将持续加速，明年第一季度预计也将是强劲的一季。目前难以判断哪个产品的爬坡会更快，但需求已经明确，我们已有采购订单，几乎所有主要客户都已就绪。这些系统极为复杂，需要时间完成整机组装并推向市场。总体而言，制约因素主要是所有系统配件的量产进度，而非需求本身。



结束语

Toshiya Hari： 感谢各位参与问答。以下是几项会议安排提示：黄仁勋将于6月1日在中国台北 Computex发表主题演讲；我们还将参加5月28日的TD Cowen TMT会议，以及6月4日的美国银行全球科技会议。2027财年第二季度业绩电话会议定于8月26日举行。下面请黄仁勋做本次电话会议的总结发言。

黄仁勋总结发言

这是一个非凡的季度，需求已呈抛物线式增长。原因很简单：智能体AI已经到来。AI现在能够完成真正有价值的生产性工作，token已经实现盈利，模型开发商正在竞相扩大产量。在AI时代，算力容量就是营收和利润，英伟达正是这个时代的核心平台。

在全球所有平台中，英伟达算力所支撑的需求多样性是最丰富的。让我重点讲五件事：

第一，英伟达是唯一能够运行所有前沿AI模型的平台。随着Anthropic加入我们现有的合作伙伴——包括OpenAI、xAI、Meta-MSL、Gemini等——我们在前沿AI模型市场的份额正在增长。

第二，我们覆盖每一家超大规模云厂商，支持其核心数据处理和机器学习工作负载、内部AI服务，以及其公有云中面向英伟达用户的需求。

第三，我们的全栈完整AI工厂解决方案和庞大的全球生态系统，使我们能够独特地服务新兴AI数据中心细分市场——包括新型AI原生云、主权AI云，以及企业和工业本地部署基础设施，这正是我之前所讲的第二类市场。

第四，NVIDIA CUDA的触达延伸至边缘端：机器人、自动驾驶汽车、嵌入式医疗仪器、AI-RAN电信基站。下一波浪潮是物理AI——数十亿个自主机器人系统将在物理世界中运行，这正是我之前所讲的第三类市场。

第五，我们迎来了一个重大的全新增长引擎——Vera：全球首款专为智能体AI设计的CPU。Vera为英伟达开辟了全新的2000亿美元市场，是我们此前从未涉足的领域，每家主要的超大规模厂商和系统厂商都在与我们合作部署。

世界正在重建计算基础设施，以支撑智能体AI和物理AI机器人的发展，英伟达处于这些转变的核心。我们用了三十年构建英伟达计算平台——统一架构、庞大生态系统、跨芯片、系统、网络和软件的极致协同设计。我们提前为这一时刻做好了准备，当智能体AI到来之时，英伟达已经准备就绪。而这一时刻，已经到来。

主持人： 今天的电话会议到此结束，感谢参与，再见。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 770

 收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

