

摘要：

英伟达联合LangChain发布NeMoClaw Deep Agents蓝图，定位为企业级Agent参考架构，重点解决治理、审计与持续迭代等部署难题。该方案单任务推理成本仅4.48美元，而竞品成本高达43.48美元。此举补齐NeMo生态短板，推动英伟达从算力供应商向企业级Agent开发标准与全栈AI生态平台延伸。

在AI算力基础设施建立领先优势后，英伟达正将竞争重心进一步推向软件生态。

7月8日，英伟达与AI开发框架LangChain联合发布NVIDIA NeMoClaw Deep Agents蓝图。该蓝图为企业提供一套开放、可定制、且具备治理能力的AI智能体参考架构，旨在破解企业在智能体部署中面临的可控性、治理与持续演进等核心难题。

相比单纯提升模型能力，这一蓝图更强调企业级Agent的软件工程能力。官方数据显示，该方案不仅在多项基准测试中取得领先表现，还可将Agent推理成本降低超过10倍，与Blackwell推理平台形成软硬件协同，进一步压缩AI应用部署成本。

对于市场而言，这意味着英伟达正进一步补齐NeMo软件生态最后一块拼图，从AI算力供应商向定义企业级Agent开发标准的生态平台延伸，为软件业务打开新的增长空间。



从Agent"执行"走向Agent"治理"

随着生成式AI从内容生成迈向自主执行任务，Agent正成为企业AI应用的核心形态，但企业部署过程中始终面临安全、可控和与业务流程融合困难等挑战。此次推出的蓝图，核心并非再打造一个Agent框架，而是提供一套完整的企业级参考架构。

基于与LangChain的合作，该蓝图采用开放架构设计，企业可以完全掌控底层系统，自定义Agent能力，并随着业务发展持续迭代，而不是依赖封闭平台。

相比强调Agent"能完成什么任务"，该方案更关注Agent如何被治理、监控、审计和持续优化。这种能力对于金融、医疗、政府等强监管行业尤为关键，也降低了企业大规模部署Agent的门槛。

软件优化叠加Blackwell，推理成本再降一个数量级

Agent商业化的加速落地，关键瓶颈在于推理成本。

英伟达最新发布的NeMo Claw Deep Agents蓝图，在保持领先性能的同时，**可将Agent推理成本降低超过10倍**。这一降本能力与Blackwell平台形成明显的软硬协同效应。

据LangChain公布的评测结果，搭载LangChain Deep Agents后的Nemotron 3 Ultra综合得分达0.86，**推理成本仅为每任务4.48美元**；而性能最接近的竞品模型成本高达**43.48美元**，降幅约**90%**。官方指出，这一优势不仅来自模型本身，更得益于对工具调用、上下文管理和中间推理流程的联合优化。

在硬件层面，基于Blackwell的新一代推理系统已通过架构升级显著压低单Token推理成本，**部分场景成本降至上一代平台的约1/35**，推理吞吐效率大幅提升。

此次蓝图则进一步从软件层面对Agent执行流程进行系统优化，覆盖任务规划、工具调用、上下文管理及推理路径精简等关键环节，使同样算力能承载更多Agent任务，充分释放底层GPU的潜在价值。



补齐NeMo软件生态，争夺AI应用入口

从产品布局看，NeMoClaw Deep Agents蓝图补齐了**NeMo体系在Agent开发层的短板**，使**英伟达软件生态更趋完整**。近年来，英伟达围绕CUDA、TensorRT、NIM、NeMo持续构建AI软件栈，目标不仅是销售GPU，更希望成为模型训练、推理部署和企业应用开发的全链路平台。

随着Agent成为AI应用的重要载体，开发框架正成为新的生态入口。与LangChain的合作，**表明英伟达正借助主流框架将自身能力嵌入企业AI流程**，在基础设施之外**争夺Agent时代的话语权**。

对资本市场而言，这同样具有战略意义。AI基础设施竞争日趋成熟，单靠GPU销售难以持续支撑估值扩张，而软件和平台服务毛利率更高、黏性更强。

通过完善NeMo生态并向Agent标准延伸，**英伟达正从基础设施提供商向全栈AI生态平台演进**，为在AI应用爆发周期中获取更多软件收入和生态溢价奠定基础。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

43 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论