



摘要：

英伟达联手全球最大数据中心托管商Equinix及AI推理平台Together AI，三方分工合作——Equinix提供托管、Together AI提供推理平台、英伟达提供GPU及软件栈，共同为企业客户提供开放模型推理服务。此举标志着英伟达将算力生态从训练侧延伸至推理侧，补全完整闭环。

英伟达正把AI基础设施的版图从训练侧延伸到推理侧。

周三，英伟达与全球最大数据中心托管商Equinix及AI推理平台公司Together AI达成合作，联合为企业客户提供开放模型推理服务，补上从模型训练到推理部署的最后一环。

按照三方分工，Equinix提供数据中心托管，Together AI提供推理平台，英伟达提供GPU及软件栈。三方把硬件、软件与托管能力打包，直接切入企业级AI应用的推理环节。

这一合作是英伟达在推理侧生态的关键补位。公司此前在训练侧已建立起领先地位，如今借开放模型推理向企业客户延伸，进一步拓宽其算力生态的覆盖面。

对Equinix而言，此次合作同样意味着它在万亿美元级的AI数据中心建设热潮中，找到了企业级开放模型推理这一差异化切入点。

三方分工：托管、平台与算力的组合

在此次合作中，Equinix负责数据中心托管，Together AI提供推理平台，英伟达提供GPU及软件栈。

在万亿美元级的AI数据中心建设热潮中，Equinix作为全球最大数据中心托管商，通过与英伟达和Together AI的绑定，将自身定位聚焦于企业级开放模型推理这一细分领域，成为这轮合作中同样受关注的受益方。

三方合作的核心目标，是帮助企业客户运行开放模型的推理工作负载，而非将算力局限于少数头部模型厂商。

英伟达押注开放模型的逻辑清晰。首席执行官黄仁勋近期发表公开文章阐述开源AI的重要性，获得几乎所有主要AI公司联署。在其看来，AI模型和应用是英伟达GPU的互补品，开源模型的繁荣意味着更准确、更广泛的算力需求。

推理收入已超训练，英伟达补上闭环

据英伟达投资者会议透露，约18个月前，英伟达的训练与推理收入大致各占一半；如今推理收入已超过训练，且这一差距预计将继续扩大。

与此同时，新兴云服务商贡献的AI计算基础设施收入已超过50%，增长动力正从传统超大规模云厂商向更广泛的AI算力生态扩散。

在训练与架构侧，英伟达此前已密集落子。



通过技术许可协议引进Groq核心团队及其 LPU 技术，并计划在下一代**Vera Rubin 架构（Groq 3 LPX）** 中深度融合 LPU；拟以129亿美元收购开源AI平台Hugging Face。

此次联手Equinix与Together AI，则是英伟达把布局延伸至推理侧的关键一步，使其算力生态覆盖从模型训练到推理部署的完整链条。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 ➤
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

👍 40 ★ 收藏

分享到:

写评论

请发表您的评论

😊 表情 🖼️ 图片

发表评论