摘要：

为缓解供应链压力，英伟达悄然下调HBM4带宽指标，并将12层堆叠降级至8层混配。此番“降维”操作意在大幅压降成本，同时变相放宽供应商门槛，HBM产能瓶颈有望借此破局。

英伟达正对其下一代AI加速器平台的内存架构进行重大调整，涉及堆叠规格降级与带宽指标下修两条并行主线，折射出高带宽内存供应链的深层压力与成本优化逻辑。

据ZDNet报道，**三星和SK海力士正准备于2027年第二季度向英伟达Rubin Ultra供应8层HBM4，此举意味着原定采用12层HBM4E的方案或将生变。**与此同时，据Wccftech报道，英伟达早在去年9月便已悄然下调Vera Rubin平台的HBM4带宽规格——每颗Rubin GPU的带宽削减约13%，HGX Rubin NVL8系统层面降幅则高达26%。

上述调整对HBM供应商及GPU产业链均具直接影响。带宽门槛下调意味着更多HBM4产品有望通过英伟达资质认证，潜在供货来源扩大；而8层配置的引入则将降低每组HBM堆栈的成本与物料清单负担，在HBM供应持续偏紧的背景下，有望缓解产能瓶颈。

Rubin Ultra舍弃12层方案，转向8层HBM4混配

据ZDNet报道，8层HBM4原本并不在英伟达的规划之列，但随着公司重新审视Rubin Ultra的内存配置，相关讨论在2026年第三季度逐渐升温。报道指出，Rubin Ultra原计划依赖12层HBM4E，但最终产品可能转而采用8层HBM4与HBM4E的混合方案，以缓解12层堆叠因热管理挑战和良率偏低所带来的供应制约。

ZDNet援引知情人士消息称，英伟达预计将视机架配置不同，在基于Rubin Ultra的NVL机架级系统中同时部署8层HBM4和8层HBM4E。值得注意的是，尽管三星和SK海力士均已完成英伟达对12层HBM4的资质认证，其8层产品仍需单独通过认证流程。

TrendForce分析指出，与12层HBM模组相比，8层配置所使用的DRAM芯片数量更少，可同时降低每组堆叠成本及GPU整体物料清单成本，并能以相同的HBM位输出支撑更多GPU。鉴于HBM供应持续偏紧，8层方案预计将成为2027年众多GPU及ASIC厂商的优先评估选项。

ZDNet报道还显示，12层HBM4虽仍是2026年的主流配置，但8层HBM4的采用率预计将从2027年中期起大幅攀升。此趋势或不止于英伟达——Economy Tribune援引大信证券分析称，Anthropic自研AI芯片亦可能采用8层HBM4，三星或将同时承接该项目的晶圆代工与内存供货。

带宽指标静默下修，合格供应商范围有望扩大

在带宽规格调整方面，据Wccftech报道，英伟达官方规格页面存档于9月1日的版本显示，Vera Rubin NVL72系统配备20.7 TB HBM4容量及1580 TB/s带宽，Vera Rubin超级芯片单芯容量为576 GB、带宽44 TB/s，每颗Rubin GPU对应288 GB及22 TB/s。

此后英伟达悄然下调规格：每颗GPU的HBM4带宽从22 TB/s降至19.2 TB/s，NVLink 6吞吐量则从3.6 TB/s降至3 TB/s，**降幅分别约为13%和17%。**据IT Home报道，Vera CPU的内存规格亦从固定的每芯片1.5 TB LPDDR5X调整为"最高1.5 TB"。

Economy Tribune指出，目前三大内存厂商均已披露HBM4性能数据：三星和SK海力士的HBM4数据传输速率为每引脚11.7 Gbps（三星最高可达13 Gbps），美光则超过11 Gbps，对应每组

HBM4堆叠带宽分别约为3.0 TB/s（三星、SK海力士）和逾2.8 TB/s（美光）。

以每颗Rubin GPU集成8组36 GB HBM4堆叠计算，达到原定22 TB/s带宽需每引脚约10.7 Gbps，而修订后19.2 TB/s目标对应的引脚速率约为9.4 Gbps。Economy Tribune分析称，**从理论上看，各内存厂商已披露的性能数据足以满足英伟达原始目标；IT Home则进一步指出，降低带宽要求后，更多HBM4产品有望获得Rubin GPU资质认证，整体产出有望随之提升。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

15 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论