

摘要：


英伟达首次公布Vera Rubin NVL72片上实测数据，搭配DeepSeek-V4-Pro跑Agent编码任务，较GB300每兆瓦吞吐量最高飙升30倍，Token成本暴降35倍。同日，专为Agent设计的Vera CPU已被SpaceX AI规模化部署，并计划2028年送上太空。Groq加速器全面量产。

太炸裂了。

就在刚刚，英伟达史上首次公布了下一代旗舰级机柜 Vera Rubin NVL72 的首次片上实测数据。

而且，这次实测直接拉来了DeepSeek-V4-Pro，跑最真实的「智能体编码」任务！

结果令人吃惊：对比当前的主力机皇GB300 NVL72，Vera Rubin的每兆瓦吞吐量最高飙升了30倍、Token成本最高暴降了35倍！



有人惊呼：「我连骗投资人的 PPT 都不敢这么写！」

还有网友神评：「以前嫌 H200 三万美元一张贵，现在回头一看，H200 居然连丐版都算不上了。」

以前嫌 H200 三万美元一张贵，现在回头一看，卧槽，H200 居然是丐版。

老黄这个摩尔定律已经有点不对劲了。

H200 → GB300:

用梁子的 DeepSeek V4 Pro 跑真实 Agent 工作负载，每兆瓦吞吐最高30倍。

成本口径：大概 2×。

GB300 → Vera Rubin:

今天第一次上硅实测，还是 DeepSeek V4 Pro，又最高 30×。

整机架价格：又大概 2×。

🔥 按老黄 PPT 的算法硬往下乘：

性能：30 × 30 = 900×

价格：2 × 2 = 4×

😂 合着这两年 NVIDIA 最大的技术突破不是 GPU。
是让贵了 4 倍，获得 900 倍的速度。

我他妈 ppt 都不敢这么写 🤡


公众号 · 新智元

让我们来仔细盘一盘。

从H200到GB300，真实Agent工作负载的吞吐量提升了最高30倍，成本大致翻倍。

从GB300到Vera Rubin，吞吐量再次飙升最高30倍，整机架价格大致再翻倍。


按照老黄的摩尔定律，合着这两年英伟达最大的技术突破不是GPU本身，而是让价格贵了4倍，却换来了整整900倍的速度飞跃！



这次，英伟达向所有人宣布了一个反常识的真相：LLM时代结束，Agent时代降临，以前的AI跑分基准，全部作废！

The Era of Agentic Scaling Demands More

Multi-Agent Applications Require Low-Latency & High-Throughput



与此同时，专为智能体打造的Vera CPU，已被马斯克的SpaceXAI连夜装机，甚至准备直接打上太空。

同在今天，英伟达Groq 3 LPX也全面量产。

Gemma 4 31B在上面跑，速度简直绝了，直接干到每秒3400个Token。万亿参数模型吞吐，狂飙35倍。

Ben Pouladian @benitoz · 4h
HotChips 预热：NVIDIA 刚刚发布了幻灯片。

Groq 3 LPX。每秒 3,431 个 token。是下一个公开端点的 4 倍。Gemma 4 31B，支持 100,000 token 上下文。已全面投产。

比 Cerebras 更快 🤯🔥

\$NVDA

THE FOURTH PIECE SHIPS

Groq 3 LPX printed 3,431 tok/s on Gemma 4 31B at 100K context.

nvidia Hot Chips 2026 In production. Nebius first.

GROQ 3 LPX NEXT PUBLIC

TOKENS PER SECOND - GEMMA 4 31B - 100K CONTEXT - ARTIFICIAL ANALYSIS

System	Tokens per Second
Groq 3 LPX	3,431
Next public	870

4x

✓ The fourth piece is in production. Slide is 3,431 and 4x, not the 2,900 from the room.


BEP Research

Source: NVIDIA Hot Chips 2026 press deck. © Groq 3 LPX PR, 24 Aug 2026
Groq 3 LPX is a 50-request median on a private endpoint. Public benchmarks are a 14-day PRG, 21 Aug 2026.

公众号 新智元

Unlocking a New Category of AI Experiences

Vera Rubin NVL72 with Groq 3 LPX
enables high throughput and low latency.




这些新纪录，直接让Agent生态的商业格局，从今夜开始重写！

为什么英伟达必须推出Vera Rubin？

OpenRouter的最新数据给出了答案：在真实世界里，一个Agent AI任务消耗的Token数量，是普通聊天对话的15倍！


比如，如果让一个Agent为投资决策去研究一家公司，在这个过程中，智能体和子智能体会不断推理，累积的Token成为下一步的输入，长上下文处理，就成为限制智能体AI的最关键要素。



智能体交互次数越多，吞吐量越大——智能体数量多了10倍，工具调用多了2倍，算力和算法的矛盾催生了新的需求。

What An Extreme Codesigned Platform Delivers For Agentic

More Agents and More Tool calls




别拿聊天当智能体，旧基准全废了！

这时候，传统的AI基准测试（如固定长度的8K/1K序列测试）就彻底无效了。

英伟达官方挑明：性能测量必须进化！不能再测单一的推理请求，必须捕捉完整的Agent workflow。

为此，他们使用了SemiAnalysis 旗下的 AgentX 基准测试。

这个测试不再是死板的问答，而是回放真实的、具有上下文增长、工具调用和子智能体生成的「代码编写会话」。




这就是为什么H200在新的Agent战场上显得力不从心，Vera Rubin注定要称王。

Vera Rubin NVL72 × DeepSeek-V4-Pro：算力怪物来了

为了证明Vera Rubin NVL72的实力，英伟达直接使用开源王者——DeepSeek-V4-Pro (1.6T) 进行片上实测。

数据一出，结果惊人——

在AgentX工作负载下，Vera Rubin NVL72的每兆瓦吞吐量，比GB300 NVL72最高提升了整整30倍！



请注意，这里对比的不是老旧的H200，而是炙手可热的主力GB300。

GB300在同样的DeepSeek-V4-Pro测试中，每兆瓦吞吐量已经比H200提升了15倍。

然而Vera Rubin却在GB300的肩膀上，又拔高了30倍，在整个帕累托曲线上又提高了！


这意味着什么？

对于受制于电力供应的「AI工厂」来说，这直接拓展了物理法则边界。

在同样的电力预算下，Vera Rubin能干30倍的智能体活儿。

对于兆瓦级甚至吉瓦级的数据中心来说，这相当于凭空变出了30倍的算力资产。

而且，NVIDIA DSX MaxLPS 技术可以在 GPU、机架和工作负载层面进行电源管理，能在相同的兆瓦预算内多配置高达 40% 的 GPU，让AI工厂进一步提升了每兆瓦吞吐量！




Token成本暴降35倍！Agent行业的「账本」彻底重写

每兆瓦吞吐量，直接影响的就是每个生成 token 的成本。性能的飙升，带来的最直接后果就是商业模式的核爆。




英伟达宣布，Vera Rubin NVL72 生产每百万Token的成本，比 GB300 NVL72 最高降低了 35 倍！



当推理成本呈断崖式下跌35倍时，24小时无休的数字员工将成为现实，ToC端超级应用将迎来大爆发。

老黄这一刀，直接切开了Agent应用的时代大门。




极致协同设计：老黄是怎么做到的？

你可能会问：凭什么能提速30倍？靠的是单颗芯片的工艺吗？

显然不是。

Vera Rubin NVL72惊人的性能提升，靠的是「极致协同设计」。




比如分离式服务，分布式KV缓存，KV感知路由，MegaMoE等等。

- disaggregated serving 将上下文处理（prefill）与响应生成（decode）分离，使两者可以独立扩展。
- Rate matching 同步 prefill GPU 与 decode GPU 生成 token 的速度，以最大化效率。
- 大规模专家并行将混合专家模型中的专家子网络分布到 scale-up GPU 域上。
- 分布式 KV 缓存将内存扩展到整个 scale-up GPU 域，而 KV 缓存卸载则将不太活跃的上下文分层存储到主机和存储设备中，使先前处理过的上下文保持可访问，无需重新计算。
- KV 感知路由将传入请求引导至已保存相关缓存上下文的 GPU，从而减少长会话中的冗余计算。
- MegaMoE 等融合 CUDA 内核将大量计算与 GPU 间通信操作合并为单次执行流程，使 GPU 保持活跃而非等待数据。

另外，NVFP4 量化直接将模型权重压缩到 4 位精度，在不牺牲输出质量的情况下，大幅缩减内存占用，让吞吐量原地起飞。


而第六代 NVLink 与大模型MoE，提供了比现成以太网快10倍、延迟低3倍的互连网络，让像 DeepSeek这种基于MoE架构的大模型，可以在72个GPU之间行云流水地调用不同的「专家」子网络。

这早已不是在卖显卡，老黄卖的是一套「AI发电厂」。



英伟达Groq 3 LPX 全面量产：3400 Token/秒，代码Agent变天！


这次Hot Chips 2026 大会上，英伟达还抛出一个震撼消息：Groq 3 LPX 开始全面量产！



Groq 3 LPX，是Vera Rubin NVL72 数据中心平台的专属扩展。

它是专为这个系统「量身定制」，主打就是一个低延迟推理加速。


这项黑科技，是去年12月英伟达豪掷200亿美元从初创公司 Groq 手中买来的。



AI智能体会遇到解码延迟的问题，为了终结这一痛点，Groq 3 LPX 巧妙地将庞大的上下文处理与 Token 生成彻底分离。

英伟达的解法是，让Rubin GPU处理大规模上下文，把极速生成Token的任务交给Groq 3 LPX。


一个管「读」，一个管「写」，各干各最擅长的。



在一个完整的机架级部署中，多达 256 个 LP30 加速器可以通过超高带宽互连与 GPU 协同作战，构造出企业级规模的推理引擎。

NVIDIA Dynamo Orchestrates Heterogeneous Compute

KV-aware routing for prefill and disaggregated decode (ATTN ↔ FFN)



由此，Groq 3 LPX直接达到了破纪录的输出速度。

在 Artificial Analysis 的基准测试中，Groq 3 LPX 在 10 万 Token 超长上下文窗口下运行 Gemma 4 31B，输出速度达到惊人的3,400 Token/秒！


这使得它在延迟极度敏感的工作负载中，响应速度比竞品快了4倍。

Output Speed: Gemma 4 31B (Reasoning)


Output speed: o200k_base tokens per second - 100k input tokens

100K Token Context

Artificial Analysis




过去几个小时才能完成的多步智能体任务，现在几分钟内就能完成！




Groq 3 LPX在生成5000 Token，所用时间从50秒降至1.5秒，34倍差距。


Time to Generate 5,000 Tokens



而且在编码任务中，Groq 3 LPX最大输出速度6981 token/s。



黄仁勋直言，通过 LPX 推进超高速 Token 生成，在 AI 吞吐量和响应能力上实现了「又一次巨大飞跃」。



Nebius已经在Nebius Token Factory 中部署该芯片，让智能体循环的每一步都能获得即时响应的极致体验。



紧随其后的，还有Groq自己。



首款Agent专属CPU发布，马斯克连夜「打上太空」！

这次官宣中，最具野心的一步棋，就是 Vera CPU了。


为了Agent，英伟达专门造了一颗CPU。

Vera这颗CPU，就是专门喂饱智能体的，

它配备了88个自研的Olympus核心，高带宽的LPDDR5X内存，带宽直接干到1.2TB/s。

Scalable Coherency Eliminates Data Ingestion Bottleneck

Vera designed to support core collaboration



为什么大模型时代需要全新的CPU？

Hot Chips现场，英伟达Vera CPU高管直言，「Agentic AI是史上最复杂的计算任务」。



一次任务，Agent背后要跑上百步：调用工具、执行Python代码、翻上下文、处理海量数据....

这些跑腿调度的活儿，全都压在CPU身上硬扛。因此，英伟达必须给Agent单独造颗CPU。

正是看中了这一点，马斯克的 SpaceXAI 连夜宣布，正式规模化部署英伟达 Vera CPU！


早在今年5月，英伟达就把第一批Vera样片，悄悄送到了A社、OpenAI、SpaceXAI先「试水」。

仅仅3个月后，SpaceXAI 就迫不及待地将其转入全面部署。


更疯狂的是，SpaceXAI 正在基于Vera Rubin 平台建设吉瓦级算力工厂，用来驱动Grok。

不仅如此，这套算力，还要被直接送上太空。

马斯克表示，「两家强强联手，设计了一款优化版的Vera Rubin NVL72，将在2028年大规模部署」。




SpaceXAI的第一代「Starlink」AI卫星，就计划采用Vera Rubin NVL72 机架级系统。



从一块GPU，到整座Agent工厂

同一天，两大芯片Vera CPU和Groq 3 LPX，全面量产。

这对英伟达来说，意义重大。



大模型时代，英伟达靠GPU拿下训练和推理。

Agent时代，它的版图已经延伸到CPU、推理加速器、NVLink等等。

老黄卖的，早已不只是一块GPU。

他要卖的，是一座可以不断生产Token的AI工厂。

老黄这一次，是要给整个「Agent时代」重新铺一遍地基。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 410  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

6 条评论



MobileUser1859 VIP会员
56分钟前 中国江苏省

硬件更新迭代太快了

 0  回复



Redcoat
1小时前 中国四川省

也就是说，实际上是换了一套标准然后测出来暴涨30倍

 0  回复



无锋重剑
1小时前 中国陕西省

用 号称完全适配国产芯片的 deepseek 测试 有意思

 0  回复



MobileUser3058
2小时前 中国

吹英伟达，已经不是一年两年了

 0  回复



TONY焦
2小时前 中国广东省

 0  回复