

摘要：

苹果正与初创公司PrismML展开早期洽谈，后者周二发布压缩模型，将54GB大模型压缩至不足4GB，令270亿参数大模型可以直接跑在iPhone 15或更新机型上。本地处理意味着更低延迟、更强隐私保护，以及潜在的更低授权和云计算成本。

苹果正与硅谷初创公司PrismML展开早期洽谈，后者声称可将大型AI模型压缩至能在iPhone上本地运行。若技术验证通过，此举将强化苹果的隐私主张，并为其迟滞已久的Siri升级提供关键支撑。

PrismML CEO表示，苹果已开始评估其技术。洽谈目前处于非常早期阶段，走向尚不明朗，但"进展顺利"。

此次消息发布恰在苹果推出iOS 27公测版的次日——这是苹果对Siri进行大幅改版后向公众开放的首次广泛测试，旨在与OpenAI和Anthropic的AI助手展开竞争。

对于苹果而言，将更多AI运算留在设备本地，意味着更低的响应延迟、更少的云计算成本，以及无需联网即可使用部分功能的能力——这些与其核心隐私定位高度契合。

PrismML的公开发布，为普通用户和投资者提供了在实验室之外检验其技术声明的机会。Counterpoint的Pathak总结道：

"云端与设备端AI的组合，能够提供更完整、更高效、更注重隐私的AI体验——复杂任务交由云端处理，敏感、时延敏感及隐私相关的任务则在设备端执行。"

压缩技术突破：54GB模型缩至4GB以内

PrismML由加州理工学院研究团队孵化而来，背后有Khosla Ventures支持。该公司周二公开发布了阿里巴巴开源模型Qwen的压缩版本，将约54GB的原始模型压缩至不足4GB，使全部270亿参数能够在iPhone 15或更新机型上直接运行。

PrismML CEO Babak Hassibi向CNBC表示，公司通过大幅简化模型内部信息的存储方式实现压缩——将每个数值从16位降至仅1至3个可能值，从而显著削减存储和运行模型所需的内存。

据该公司称，压缩后的模型内存占用减少10至15倍，响应速度提升6至8倍，能耗降低3至6倍。Hassibi坦承存在一定取舍：模型整体性能通常下降个百分点，事实性记忆的衰减早于推理、数学和编程等能力。

目前，PrismML免费发布了两个压缩版本，适配iPhone、MacBook及搭载英伟达芯片的PC。公司表示，谷歌的开源模型Gemma是下一个压缩目标，此后还将处理需要数据中心硬件才能运行的更大规模前沿模型。

今年3月，该公司完成由Khosla Ventures领投的1625万美元种子轮融资，加州理工学院拥有底层专利并向其独家授权。

苹果本地AI布局：隐私与效率的双重驱动

苹果目前已在设备端本地运行部分AI功能，包括翻译、部分摘要生成及与个人信息密切相关的特性，较复杂的请求则路由至其私有云基础设施或外部模型。

Asymco创始人Horace Dediu表示，**苹果的目标很可能是将绝大多数日常Siri交互保留在设备端，仅将最高需求的任务交付云端处理**。本地处理意味着更低延迟、更强隐私保护，以及潜在的更低授权和云计算成本。

Creative Strategies总裁兼首席分析师Carolina Milanesi指出，更小的模型可让苹果将更多高需求功能移至iPhone本地，包括计算摄影、视频生成，以及依赖健康、药物等敏感数据的健康与健身工具。“设备端能做的越多越好，”她说。

苹果在推进本地AI方面具备潜在优势——其芯片与软件协同设计，对AI在设备上的运行拥有更精密的控制权。

分析师警示：规模化验证是关键门槛

尽管技术指标亮眼，分析师普遍提示，PrismML的声明尚需在受控演示之外得到验证。

Counterpoint Research研究总监Tarun Pathak表示，模型在长提示下的表现、多任务处理时的电池消耗，以及跨数百万次请求和数千种设备组合的可靠性，将是关键考量。他说：

“最终考验将是数百万次查询、数千种设备组合以及大规模稳健测试。”

IDC客户端处理器研究负责人Phil Solis则指出，功耗可能是最大的未知变量。一个足够强大、被频繁使用甚至在后台持续运行以执行智能体任务的模型，即便内存占用较低，**也可能对手机电量造成显著消耗**。

对芯片需求的影响：需求转移而非消失

PrismML的发布也触及了市场对AI效率提升能否最终压缩芯片需求这一持续争论。

摩根士丹利估计，苹果在2027财年的每比特动态随机存取内存平均成本可能同比上涨约190%，NAND存储成本上涨约180%。该机构预计苹果将把iPhone 18同等起售机型的价格提高约200美元以保护利润率。

PrismML表示，其压缩方案可使原本需要8块GPU运行的云端模型缩减至仅需1块，并让原本依赖服务器的模型迁移至手机和笔记本电脑。**这可能降低单一AI任务所需的内存或算力，但并不必然导致整体芯片需求下滑**。

D.A. Davidson分析师Gil Luria表示，模型瘦身并不会消除对处理器或内存的需求，**只是将更多芯片从数据中心转移至手机等终端设备**。“你仍然需要GPU，仍然需要内存，”他说。

他还补充，在单一设备上运行AI实际上可能比共享数据中心基础设施效率更低，因为手机芯片大多数时候处于闲置状态。此外，**效率突破往往催生更多使用需求，而非带来支出下降**。

市场对“AI所需内存少于预期”的信号向来反应灵敏。今年3月，谷歌发布TurboQuant论文——涉及在不损害模型性能的前提下削减内存使用——美光科技股价随即大幅下跌，尽管此后有所回升。

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

111 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论