

摘要：

计算机安全领域全球最高被引学者宋晓冬宣布加入Meta超级智能实验室，担任AI研究副总裁。作为麦克阿瑟天才奖得主及安全与AI安全领域的开拓者，她将携其创立的Virtue AI团队一并加入，旨在强化Meta在智能体安全方面的能力，以应对模型抵御恶意滥用的严峻挑战。

本周四，UC Berkeley 计算机教授 Dawn Song（宋晓冬）宣布加入 Meta 超级智能实验室 Superintelligence Labs，担任 AI 研究副总裁。



Dawn Song

@dawnsongtweets

翻译自 英语 显示原文

我很兴奋地分享，我将加入 Meta Superintelligence Labs (MSL)，担任 AI 研究副总裁，与 Virtue AI 团队的许多成员一起。我将帮助塑造 Meta 的 AI 安全和 AI 安全工作，推动前沿 AI 模型和代理 AI 系统的安全与保障，这些系统将服务于全球数十亿人和组织。

在我的职业生涯中，我一直被一个简单的信念所驱动：为了让 AI 发挥其全部潜力，它必须是安全的、可信的且有益的。这一信念指导了我的研究多年，并最终引领我们在 2024 年共同创立 Virtue AI。我们的目标是将可信赖 AI 研究的进步转化为实际解决方案，并为 AI 系统和代理构建信任层，使组织能够自信地部署 AI。

我为 Virtue AI 团队所取得的成就感到无比自豪。我们共同构建了 AI 安全和代理安全技术，与领先的企业和前沿 AI 实验室合作，并贡献了研究、基准测试和开放平台，这些工作帮助推动了可信赖 AI 的科学与实践。最重要的是，我们组建了一支由共同使命团结起来的卓越团队：让 AI 变得更安全、更可信赖且更有益。

我深深感激我们的团队、客户、合作者、顾问和投资者在这一旅程中给予的信任与支持。特别要感谢 Lightspeed Venture Partners、Walden Catalyst Ventures、Prosperity7 Ventures、Factory、Osage University Partners、Lip-Bu Tan，以及所有帮助我们将雄心勃勃的愿景变为现实的支持者。你们的信任、指导和伙伴关系在塑造 Virtue AI 的历程中发挥了关键作用。

随着 AI 系统变得越来越强大和自主，确保其安全、可信赖性和一致性将成为我们时代最具决定性的挑战之一。我被 Alex、Nat、Prashant 和更广泛的 MSL 团队的愿景所激励，他们致力于构建惠及数十亿人的 AI 和 AI 代理，我期待通过 AI 安全与保障的进步，帮助将这一愿景变为现实。

AI 的未来不仅仅由我们的系统变得多么智能来定义，而是由我们如何让它们变得安全、可信赖且有益来定义。我相信我们拥有一个非凡的机会和责任，来共同塑造这一未来，并将 AI 的益处带给全球数十亿人。

我们才刚刚开始。如果你对推进前沿 AI 充满热情，同时致力于构建 AI 安全、安全性和信任的基础，我很乐意听到你的声音。加入我们，一起踏上这场非凡的旅程，帮助塑造 AI 的未来。

评价此翻译：

上午1:03 · 2026年6月26日 · 8.4万 查看




宋晓冬将直接向 MSL 主管 Nat Friedman 汇报工作。

宋晓冬在学术界和工业界都享有很高声誉，她是全球计算机安全与 AI 安全领域最具影响力的学者之一，目前任加州大学伯克利分校（UC Berkeley）电气工程与计算机科学系（EECS）教授。



宋晓冬本科毕业于清华大学物理系，1999 年在美国卡内基梅隆大学计算机系获硕士学位，2002 年于加州大学伯克利分校获得博士学位。伯克利任教期间，她同时任去中心化智能中心（Berkeley RDI）联合主任。她是麦克阿瑟天才奖（MacArthur Fellowship）得主，同时也是 ACM Fellow、IEEE Fellow 以及美国艺术与科学院（AAAS）院士，包揽了计算机与科学界的多项最高荣誉。

她在 2005 年所提出的「污点分析法」（Dynamic Taint Analysis）论文，是计算机安全领域的经典论文。



宋晓冬的研究不仅覆盖传统的软件和网络安全，更是对抗性机器学习和智能体安全领域的开拓者，她深度参与了生成式 AI 时代安全基准测试的制定。

在 AMiner 评选的榜单中，她是计算机安全领域全球最高被引学者。她在伯克利的实验室被誉为计算机安全领域的黄埔军校。

两星期前，我们报道过其团队开发的 ALE（Agents' Last Exam，智能体的最后考试），用来衡量 AI 智能体是否真的能够在广泛的真实世界领域中完成具有经济价值的工作。



在 ALE 中，伯克利团队评测了 Fable 5、GPT-5.5、Composer 2.5 以及其他前沿智能体系统，其结果令人印象深刻。

宋晓冬也是 Oasis Labs 和 Virtue AI 的创始人。Virtue AI 专注于企业级 AI 安全基础设施，特别是针对 AI 智能体的自动化红蓝对抗（Red-teaming）和运行时护栏（Runtime guardrails）。

据外媒报道，本次包括宋晓冬，Virtue AI 的另两位创始人 Bo Li 与 Sanmi Koyejo，以及更多团队成员也一同加入了 Meta。自从 Anthropic 的新一代安全大模型 mythos 发布和被禁用后，AI 的安全问题已经引起了科技界的广泛关注，Meta 正在寻求加强其在智能体方面的安全措施。

随着前沿模型面临的安全问题，全球顶尖 AI 实验室目前正在面临空前的压力。Meta 的目标是将 AI 部署到几十亿人的社交产品矩阵中，同时继续推进开源战略。要做到这一点，它必须向监管机构和公众证明其模型具备抵御恶意滥用的硬核能力。Virtue AI 团队的加入有望提供巨大帮助。

与此同时，Gemini Reasoning Team 创始人 Denny Zhou 据传已于数月前离开 Google，加入 MetaTBDLab (领英上已有更新入职 Meta 好几个月了，且职级为 Level 10。



Yuchen Jin ✓
@Yuchenj_UW



I didn't realize Denny Zhou, who led the Gemini Reasoning Team, left Google 4 months ago for Meta's TBD Lab.

A lot of people left Google recently. I'm still waiting for Gemini to catch up in coding. Time for Sergey to pull a Code Red.

我之前并不知道领导 Gemini 推理团队的 Denny Zhou 已经于 4 个月前离开 Google，加入了 Meta 的 TBD 实验室。

最近很多人都离开了谷歌。我还在等 Gemini 的编程水平赶上来。是时候让 Sergey 来个“红色警报”了。

Experience



Research Scientist (Level 10), Meta Superintelligence

Meta

Mar 2026 - Present · 4 mos

TBD Lab, solve superintelligence



Research Scientist (Level 8), Google DeepMind

Google DeepMind · Full-time

Sep 2017 - Mar 2026 · 8 yrs 7 mos

- Founded and led the Reasoning Team in Google Brain/DeepMind (since 2021)

- Formed the foundation for modern reasoning / LLM reasoning... more

Denny Zhou 是 AI 推理领域绝对的顶级大牛之一，被誉为「教 LLM 学会推理」的关键人物。



过去几年，Denny Zhou 参与推动了 Chain-of-Thought、Self-Consistency、Least-to-Most Prompting 等一系列关键方法，把大模型推理从「提示词技巧」推进为一套可研究、可扩展、可工程化的技术路线。某种意义上，今天 Gemini 在复杂数学、代码和长程推理任务上的持续加码，离不开这条由 Reasoning Team 早期奠定的研究脉络。



Denny Zhou

LLM Reasoning, Superintelligence

美国 · [联系方式](#)

9,819 位关注者 · 500+ 好友

+ 关注

发消息

更多

工作经历

**Research Scientist (Level 10), Meta Superintelligence**

Meta

2026年3月 – 现在 · 4 个月

TBD Lab, solve superintelligence

**Research Scientist (Level 8), Google DeepMind**

Google DeepMind · 全职

2017年9月 – 2026年3月 · 8 年 7 个月

- Founded and led the Reasoning Team in Google Brain/DeepMind (since 2021)
- Formed the foundation for modern reasoning / LLM reasoning
- Developed algorithms central for Gemini Thinking
- Co-founded COLM in 2024, General Chair for COLM 2024

Research work summary (publish till 2024, lecture at Stanford): <https://dennyzhou.github.io/LLM-Reasoning-Stanford-CS-25.pdf>: chain of thought (CoT), self consistency, task decomposition, self correction, CoT scaling and RL

本文来源：[机器之心](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员 · 7天畅读卡 | 大师课 · 入门串讲



限免

 18  收藏

分享到:  

写评论

请发表您的评论



