

摘要：

当AI逼近自进化，失控风险正引发硅谷恐慌。随着核心研究员愤而辞职，OpenAI急呼行业“协调减速”。但在商业博弈与竞争压力下，无人敢单方面踩下刹车。这场狂飙揭露了一个致命的治理悖论：真正失控的，究竟是AI，还是制造AI的科技巨头？

9月11日，OpenAI CEO萨姆·奥特曼（Sam Altman）在本周的一场全员会上表示，公司可能放缓前沿AI开发，并考虑与其他AI实验室协调行动。他同时承认，这样的共同行动未必能得到所有同行支持。

几天前，OpenAI首席科学家雅库布·帕乔茨基（Jakub Pachocki）刚刚发出一封更明确的警告：随着AI越来越多参与下一代AI研发，行业正在逼近recursive self-improvement（AI自进化）带来的新风险。在建立共同安全标准之前，他希望前沿AI公司“自愿减速”能够成为常态。



Jakub Pachocki @merettm




翻译自 英语 显示原文

我撰写了关于人工智能现状的文章，阐述了我对未来几年的担忧，以及我们需要做出的选择，以确保未来掌握在人类手中。

An Alien Mind:

评价此翻译：



过去一个多月，OpenAI至少两次真的踩过刹车。

7月，一批OpenAI内部研究模型在网络安全测试中绕过隔离机制，最终进入OpenAI自身以及第三方Hugging Face的系统。OpenAI随后暂停了部分前沿模型推理任务，并一度暂停拟部署最新模型的强化学习训练。公司原计划进行的一次最大规模前沿RL训练因此延后，直到新的安全和隔离标准建立后才在8月底恢复，部分实验训练至今仍处于暂停状态。

OpenAI自己把这起事件称为一次可能导致“真正失控”的警告。

但几乎就在同一时间，另一家把“安全”写进公司基因里的AI实验室，却陷入了一个更尴尬的局面。



9月8日，Anthropic研究员雅各布·考克森（Jacob Coxon）宣布辞职。他曾先后在OpenAI和Anthropic参与大模型预训练研究，离职时距离部分股权归属仅剩约两个月。Coxon公开指责Anthropic和OpenAI正在向能够自我改进的超级智能加速，“拿我们的生命赌博”。

他的帖子很快获得超过1.6亿次浏览。

随后，Anthropic内部更多从事AI安全与对齐研究的人开始公开表达类似担忧。与此同时，两名近期离开Anthropic和Google DeepMind的研究人员也呼吁前沿AI公司提高透明度。今年7月底，超过1000名AI公司员工还联名要求建立一套能够让前沿AI开发真正慢下来的机制。

过去几年，从杰弗里·辛顿（Geoffrey Hinton）、约书亚·本吉奥（Yoshua Bengio）到达里奥·阿莫迪（Dario Amodei），关于超级智能、失控和灾难性风险的讨论几乎从未停止。

但这一次的讨论度明显更高，原因是Coxon正在亲手训练今天最强的模型；还有一些热烈参与讨论的人，就是研究这些模型能否被控制。

这个过去很容易被当作哲学争论的问题，突然也变成了一道公司治理题。如果一家前沿AI公司的安全研究人员认为研发速度已经超过了控制能力，他们究竟能做什么？完全没有话语权，只能通过辞职来发出警告和呼吁吗？

这可能才是这场讨论突然席卷硅谷的原因，不只是AI是否能够被控制，更是制造AI的公司，究竟能不能控制自己。

Anthropic安全承诺的“死亡开关”



Anthropic的治理结构在AI行业里几乎没有先例。理解这套结构，才能理解Coxon辞职的真正含义。

2023年9月，Anthropic发布了“负责任扩展政策”(RSP)，核心是一套条件承诺：如果模型能力超过特定安全阈值，公司必须暂停开发，直到相应的安全措施到位。

这套政策将AI安全风险分为五个等级（ASL-1到ASL-5），当前所有Anthropic模型适用ASL-2标准。2025年5月发布Claude Opus 4时，Anthropic首次激活了ASL-3级别的部署和安全标准。

AI Safety Level	Dangerous Capabilities	Containment Measures <i>Required to store model weights</i>	Deployment Measures <i>Required for internal/external use</i>
ASL-1	Models which <i>manifestly and obviously</i> pose no risk of catastrophe. For example, an LLM from 2018, or an AI system trained only to play chess.	None	None
ASL-2 <i>Our current safety level</i>	No capabilities likely to cause catastrophe, although early indications of these capabilities. For example, an AI system that can provide bioweapon-related information that couldn't be found via a search engine, but does so too unreliably to be useful in practice.	Evaluate for ASL-3 warning signs when training, using methods and <i>Evaluation Protocol</i> described below. Harden security against opportunistic attackers.	Follow current deployment best practices e.g. model cards, acceptable use policies, misuse escalation procedures, vulnerability reporting, harm refusal techniques, T&S tooling, and partner safety evaluation. These overlap significantly with our White House voluntary commitments .
ASL-3 <i>We are currently preparing these measures</i>	Low-level autonomous capabilities or Access to the model would substantially increase the risk of catastrophic misuse, either by proliferating capabilities, lowering costs, or enabling new methods of attack, as compared to a non-LLM baseline of risk.	Harden security such that non-state attackers are unlikely to be able to steal model weights and advanced threat actors (e.g. states) cannot steal them without significant expense. Evaluate for ASL-4 warning signs when training, likely similar to but much more involved than the methods described below. Implement internal compartmentalization for training techniques and model hyperparameters.	Implement strong misuse prevention measures, including internal usage controls, automated detection, a vulnerability disclosure process, and maximum jailbreak response times. Each deployed modality (e.g. API, fine-tuning) must pass intensive expert red-teaming and evaluation measures for catastrophic risks.
ASL-4	<i>Capabilities and warning sign evaluations defined before training ASL-3 models</i>		
ASL-5+	...		

但2026年2月，RSP更新到v3.0版本时，一个关键承诺被悄悄撤回了：如果无法在达到下一个安全等级前实施所需保障措施，公司将暂停开发。旧版的“暂停承诺”不再作为硬约束保留。

Anthropic的解释是，如果其他公司不采取类似约束，单方面暂停可能使自己在竞争中落后，从安全角度看反而不利。替代方案是发布“前沿安全路线图”和公开风险报告，但这些属于“雄心勃勃但可实现”的目标，没有硬性约束力。

另一层治理机制是“长期利益信托”(LTBT)。这是一个由五名财务上无利益关系的受托人组成的独立机构，成员包括前美联储主席本·伯南克（Ben Bernanke）、诺华CEO瓦斯·纳拉辛汉（Vas Narasimhan）等。

Ben Bernanke appointed to Anthropic’s Long-Term Benefit Trust

Jul 9, 2026

Anthropic's Long-Term Benefit Trust (LTBT) has appointed Dr. Ben Bernanke, a Distinguished Fellow at the Brookings Institution and former Chair of the Federal Reserve, as its newest member. He joins an independent body that works to hold Anthropic to its mission: the responsible development of advanced AI for the long-term benefit of humanity.

Bernanke led the Federal Reserve from 2006 to 2014, steering the central bank through the 2008 global financial crisis and the recovery that followed. Before entering government, he spent more than two decades as an academic economist, much of that time at Princeton, where he chaired the economics department and built a body of research on the Great Depression and the role banks play in financial crises. That work earned him the Nobel Prize in Economic Sciences in 2022.

“The potential of artificial intelligence is enormous, and so is the range of outcomes. How that potential plays out will depend, in part, on the institutions we build around it,” said Dr. Bernanke. “Anthropic has created a unique governance structure to try to ensure that the long-run benefits of AI for humanity far outweigh the risks. I am honored to have this opportunity, and I will try to contribute in any way I can to this critical mission.”



LTBT持有Anthropic的特殊类别股份，有权选举和罢免董事会成员。2026年4月，随着纳拉辛汉被任命为董事，LTBT任命的董事首次构成董事会多数。理论上，这层结构可以在股东利益与安全承诺冲突时，为后者提供一道缓冲。

但这道缓冲有一个致命漏洞：投资者可以通过85%投票权的超级多数终止信托，并罢免LTBT任命的所有董事。哈佛法学院教授杰西·弗里德（Jesse Fried）将其称为“Ben & Jerry’s风险”，使命守护者可能既损害投资者利益，又恰恰实现与初衷相反的结果。

Share Class	Holders	Votes Per Share	Key Rights
Class A	Public investors (post-IPO); most financial investors	1 vote	Standard economic and voting rights
Class B	Dario Amodei, Daniela Amodei, and select co-founders	Multiple (exact ratio TBD in S-1)	Super-voting; founders retain operational control
Class T	Long-Term Benefit Trust	Special governance rights	Authority to elect and remove designated board directors

在Anthropic准备进行可能估值高达2万亿美元IPO的当下，这个“死亡开关”格外引人注目。

更关键的问题是，安全团队在这个结构中究竟有多大话语权？公开信息显示，Anthropic安全团队并没有正式的“一票否决权”。他们可以进行高风险能力评估、触发内部审查，但最终决策权在管理层和董事会手中。

2026年4月，Anthropic内部红队在评估中发现Mythos模型可能具备攻击银行、政府系统等底层基础设施的能力，安全团队触发了内部“能力暂停”。但随后美国政府推动联邦机构继续获得访问权限，安全考量最终让位于其他因素。

这正是Coxon辞职所暴露的结构性问题：当安全判断与商业利益发生冲突时，没有任何机制能确保安全优先。安全研究人员能做的，最多是内部上报，或者像Coxon这样，选择公开离开。

OpenAI从加速变成“协调减速”

与Anthropic不同的是，这次OpenAI的态度似乎转变得很快。

7月的Hugging Face事件是一个转折点。8月初，OpenAI在Black Hat安全大会上披露，他们的智能体在数月内通过留言板留下“秘密笔记”，彼此协调行动，这一行为当时未被OpenAI员工发现。

8月7日，OpenAI宣布其即将推出的Astra模型触及了公司Preparedness Framework中的“Critical”网络安全阈值，这是该框架设立以来首次有模型达到这一级别。

11天后，公司宣布暂停部分AI训练约两周，同时最大规模的前沿强化学习训练保持暂停。新安全协议平均增加了20%的计算负担。

迈向 Astra：关键能力与前沿防护机制

▶ 聆听文章 14:31

🔗 分享

自从我们在早期评估中判定 Astra 可能达到“关键”级网络安全能力以来，我们收集了更多证据，并完成了更多评估来衡量该模型的能力。我们现在认为，Astra 已达到准备框架所定义的“关键”级网络安全能力阈值。这意味着，在配备适当工具并获得相应访问权限后，它无需人工逐步指导，即可在许多防护严密的系统中发现此前未知的安全漏洞，并制定漏洞利用策略。这是我们首个评定为这一等级的模型，因此在开发期间和发布之前都需要更完善的防护机制。

过去几周，我们推迟了 Astra 的部分开发和发布工作，以加强并测试针对网络滥用及模型未经授权行动的防护措施。基于这些工作，我们认为 Astra 的防护机制足以将严重危害的风险降至最低，可按照准备框架发布。

尽管 Astra 并未涉及 [Hugging Face 事件](#)，但我们已将在该事件中吸取的经验纳入安全方案。根据回溯测试，我们认为当时的生产环境防护机制本可阻止 Hugging Face 事件发生。此后，我们为 Astra 实施了更完善的防护机制，包括训练模型更强有力地拒绝有害的网络攻击请求并遵守安全限制、增设防范滥用的措施，以及部署能够阻止潜在未经授权活动的监控机制。

到了9月，奥特曼开始用“减速”这样的措辞。几天前，帕乔茨基在博客文章《An Alien Mind》中发出了更直接的警告：“当前我认为，没有任何实验室已经足够解决对齐和监控问题，使其能够继续在最高速度上负责地扩展很长时间。”他呼吁“自愿放缓成为常态”。奥特曼转发了这篇文章，并称其为“重要文章”。

但一边呼吁减速，一边继续开发更强大的模型并推进IPO，这种矛盾让人很难判断这究竟是真诚的安全关切，还是竞争策略的另一种表达。TechCrunch高级记者丽贝卡·贝兰（Rebecca Bellan）评价说：“奥特曼很擅长在正确的时间说正确的话。但重要的是指出，OpenAI实际上并没有放慢速度。”

也有一个细节值得注意：OpenAI已经私下向国会寻求指引，核心问题是，如果前沿实验室为了安全目的协调放缓前沿模型开发，是否违反反垄断法。7月，两党跨两院立法者提出了《Collaboration on AI Safety》法案，可能为AI实验室的安全协作提供反垄断豁免。

这表明，OpenAI不只是在做公开表态，而是在同时处理政策和法律层面的风险。

AI治理悖论：谁都不敢先松油门

奥特曼表态里最值得注意的几个字，其实不是“slow down”，而是“with other labs”。

7月底，来自OpenAI、Anthropic、Google、Meta等公司的1386名员工联名致信美国政府，要求建立能够有意减缓AI开发的技术和治理工具。签署者中，Anthropic有533人，OpenAI有330人，Google有191人。

Pacing the Frontier

A statement from 1,386 employees of frontier AI companies

Signatories

John Schulman
Chief Scientist, Thinking Machines

“

Jakub Pachocki
Chief Scientist, OpenAI

Jared Kaplan
Co-Founder and Chief Science Officer, Anthropic

Shengjia Zhao
Chief Scientist, Meta AI

“

Shane Legg
Co-Founder & Chief AGI Scientist, Google DeepMind

Ilya Sutskever
CEO, Safe Superintelligence Inc.

“

Statement

“

AI could help create a dramatically better future, but that outcome is not guaranteed. The world's leading AI companies believe they could be close to automating AI research. It is hard to predict exactly how much this will accelerate AI progress, but there is a real risk that capability development rapidly accelerates beyond our ability to understand or control the resulting systems.

To realize AI's potential, industry, government, and society at large may need the option to buy time to address emerging risks, develop security measures, and strengthen oversight. But each company—and country—is under intense competitive pressure not to unilaterally slow that acceleration. And today, the world lacks the technical and governance tools to deliberately pace frontier-wide progress.

Building on work already underway to monitor frontier model

这封信的特殊之处在于，签署者包括Anthropic CEO阿莫迪、OpenAI首席科学家帕乔茨基、Anthropic联合创始人贾里德·卡普兰（Jared Kaplan）等高管。他们并非要求立即停止开发，而是要求政府构建一套在必要时可以“踩刹车”的工具。

这封信发布后，OpenAI和Anthropic均在X上发帖表示支持。但支持归支持，结构性的困境没有改变：每家公司都明白风险，但谁也不敢单独减速，因为竞争对手不会等你。

MIT数学家马克斯·泰格马克（Max Tegmark）用博弈论中的“摩洛克”（Moloch）概念来解释这种逐底竞争。即便实验室负责人知道有风险，在没有任何协作制约的情况下，为了生存和利润，他们不得不陷入集体加速。

斯坦福大学胡佛研究所高级研究员史蒂文·库宁（Steven E. Koonin）曾在论文中指出，监管前沿AI面临三重结构性障碍：模型文件无法有效验证、国家利益优先、以及AI的双重用途使得军民用途难以区分。


Regulating AI Development: Challenges, Constraints, And A Realist Agenda

Calls for comprehensive regulation of artificial intelligence have intensified as the technology's capabilities have grown. Such calls conflate two distinct regulatory objects: the domestic application of AI systems, which is already underway and broadly feasible, and the development of increasingly capable AI systems at the global frontier, the subject of this paper, where the structural constraints attenuate traditional regulatory approaches.

CLICK HERE TO DOWNLOAD

Thursday, June 11, 2026 • 1 min read

By: Steven Koonin



2023年多国签署的《布莱切利宣言》是国际AI治理的早期外交里程碑，但两年过去，具体的执行机制仍然缺位。

2026年8月，白宫与四家前沿实验室达成了自愿性安全测试框架。这是非约束性的。英国AI安全研究所资助的“失控观测站”（Loss of Control Observatory）记录的数据显示，2026年7月单月AI失控事件超过300起，超过去年同期的两倍，累计已超1600起。

AI安全正在经历一次角色变化。过去的问题是怎么约束模型，现在越来越变成怎么约束一群彼此竞争、却又无法单独退出比赛的模型公司。单个研究者的辞职无法改变公司的激励结构，公司的自愿承诺在竞争压力下也会瓦解。有效的约束只能来自外部，来自政府或国际协议。但现有的国际框架还远不足以应对这个问题的规模和速度。

而当AI系统开始参与自身的设计和改进时，这个决策窗口可能急剧缩小。从现在的几年，甚至会逐渐压缩到几个月。

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

140

收藏

分享到:

写评论

请发表您的评论

表情

图片

发布评论

