

摘要：

智谱神秘模型Ox Alpha正式揭面，以国产芯片全量承载50万亿token推理流量震动AI硬件圈，使用量已超DeepSeek两倍。模型性能比肩Claude Opus 4.8，定价却仅为其1/40，精准狙击竞争对手涨价后的市场缺口，带动股价盘中上涨超9%。

智谱旗下神秘模型Ox Alpha正式现身，带动公司股价大幅走高，并以国产芯片全量承载海量推理流量的披露，在AI硬件领域引发广泛关注。

周四，智谱股价盘中上涨超9%，报1124港元。消息面上，智谱8月26日正式确认，此前在开发者社区引发热议的匿名模型Ox Alpha——中文社区称“牛来”，即为其最新发布的GLM-5.3-Flash（320B-A18B）。该模型在Artificial Analysis Intelligence综合智能指数中取得57分，与Anthropic的Claude Opus 4.8持平，高于DeepSeek旗舰模型V4 Pro正式版的53分。

HK 02513 智谱

1124.000 港元 +94.000 +9.13%

交易中 08-27 11:43:00 北京时间

今开	1115.000	最高	1138.000	成交量	413.61万股
昨收	1030.000	最低	1071.000	成交额	45.57亿
换手率	1.72%	市盈(TTM)	亏损	总市值	5234亿

分时

五日

日K


周K

月K

季K

年K

更多



在正式发布前，GLM-5.3-Flash以匿名形式在OpenRouter和OpenCode两个平台免费开放测试，5天内累计流量超过50万亿token，刷新两平台流量增长纪录，当前使用量已超过DeepSeek的两倍以上。智谱同时披露，上述全部流量均由国产芯片承载，调用超过10万张国产芯片集群用于推理服务，并称“硬件效率及单token成本已经达到了与主流英伟达GPU相当的水平”。

国产芯片全量承载，硬件叙事引发市场关注

智谱此次披露中，国产芯片的表现是市场关注的焦点之一。据智谱官方技术文档，公司调用超过10万张国产芯片组成集群，为GLM-5.3-Flash提供推理算力支持，并表示硬件效率与单token成本已可与英伟达GPU相媲美。

半导体研究机构SemiAnalysis随即在X平台发文评论称：“所有流量均由国产芯片承载，硬件效率和单token成本已可与英伟达GPU相媲美。继Jalapeño（OpenAI自研推理芯片）昨日宣布之后，CUDA护城河再度受到考验。”该机构还特别指出，此前业界普遍认为只有顶级前沿实验室

才具备每日100万亿token的算力规模，"而这里每日100万亿token的免费流量，全部跑在国产芯片上。"

据《晚点LatePost》了解，这批芯片的供应商或来自华为、摩尔线程与海光。智谱官方对此未予置评，技术文档中亦未明确具体芯片型号。

为应对单张芯片内存容量与带宽的瓶颈，智谱在SGLang基础上构建了专用推理引擎，采用W8A8量化、INT8/FP8/BF16混合缓存量化及节点内张量并行等技术，并引入生产级Encode–Prefill–Decode（EPD）分离式架构。智谱称，与同一硬件上的初始基线相比，端到端服务性能提升了3倍。

架构重构：激活参数与层数近乎减半

GLM-5.3-Flash在架构层面与前代产品存在显著差异，这也是其能够以更低成本实现更高性能的核心原因。

与GLM-4.5相比，GLM-5.3-Flash总参数量相近（355B对比320B），但激活参数量从32B降至18B，层数从92层减至45层，几乎减半。参数量约为上一代旗舰GLM-5.3的40%，与DeepSeek V4 Flash几乎持平。

智谱称，GLM-5.3-Flash是首个采用稀疏注意力与线性注意力混合架构的开源前沿模型，相较于GLM-5.3，其注意力计算量与KV缓存大小分别降低了3.01倍和4.44倍。此外，该模型也是GLM-5系列首个原生多模态模型，支持图像和视频输入，同时是智谱战略聚焦coding以来首次推出具备多模态能力的新模型。

定价策略：瞄准涨价潮后的需求缺口

GLM-5.3-Flash的发布，恰逢中国AI模型市场一轮集体涨价之后。Kimi K3输出价格高达每百万token 100元，超过前代K2.6三倍以上；DeepSeek V4 Pro从6元涨至13.5元，高峰时段达27元；DeepSeek V4 Flash输出价格从2元涨至4.5元，高峰时段9元。

据《晚点LatePost》，DeepSeek V4 Flash提价后，在OpenCode平台上的调用量下滑了一半，这部分外溢需求成为国产模型厂商新的增长空间。

GLM-5.3-Flash的定价策略正是瞄准这一缺口。该模型每百万token输入0.8元，输出2.8元，缓存命中价格0.23元，为GLM-5.3的十分之一，上线前两周实行半价。智谱表示，限时折扣期内定价为GLM-5.3的1/20，为Claude Opus 4.8的1/40。与调价后的DeepSeek V4 Flash相比，GLM-5.3-Flash在绝大多数常规调用场景下更为便宜。

智谱计划于下周一发布首份详细财报，覆盖今年1月上市以来的前六个月业绩。此次GLM-5.3-Flash的发布及其市场表现，将为投资者提供评估公司商业化进展的重要参照。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

71 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论