摘要：

Gemini 4 Argon上线72小时吞噬25万亿Token，创谷歌历史纪录。皮查伊罕见表示：云业务正在实际让渡算力给DeepMind，前沿模型是“不可谈判的第一优先级”；他证实了全行业算力严重短缺的判断——当下每家公司都希望自己手里的算力是当初规划量的2倍，客户今天想锁定2027年的算力“极其困难”；RSI距离“自主失控的终局”还很遥远；太空数据中心已送芯片入轨，等待第一声“Hello World”。

近日，谷歌发布旗舰模型Gemini 4 Argon，这款模型在72小时内消耗了25万亿Token，是上一代Gemini 3.0同期的三倍，并创下谷歌历史纪录。

谷歌CEO皮查伊（Sundar Pichai）在模型发布后的首次公开深度访谈中，正面回应了外界关于“谷歌放弃前沿AI”的质疑，并罕见承认公司云业务正在为前沿模型研发主动让渡算力资源。

皮查伊坐进硅谷山景城的录音棚，接受科技媒体人Alex Kantrowitz主持的《Big Technology Podcast》专访。他证实了全行业算力严重短缺的判断——当下每家公司都希望自己手里的算力是当初规划量的2倍，客户今天想锁定2027年的算力“极其困难”。在递归自我改进（RSI）问题上，皮查伊明确划定边界：当前阶段是AI智能体与人类研究员协同推进的过渡期，距离“自主失控的终局”仍相当遥远。



前沿模型，是谷歌的“第一优先级”，不是选项

过去一年，硅谷流传着一种颇具市场说服力的逻辑：**前沿大模型的军备竞赛已经进入边际收益递减区。Meta的Llama系列开源模型、谷歌自家的Gemini Flash这类轻量快速模型，对绝大多数企业场景已经“够用”。既然如此，谷歌何必继续烧上百亿美元去卷万亿参数的前沿模型？不如把TPU算力全部高价出租给外部开发者，做下一个英伟达。**

这种论调在投行报告和企业CTO圈子里流传甚广，甚至一度形成了“谷歌实际上已经战略性放弃前沿竞争”的市场预期。

皮查伊在访谈中对这个逻辑做了正面反驳，但他的切入角度并非情绪性的否认，而是从三个具体机制展开：

第一个机制是“早看见”的优势。 处于前沿的公司能比其他人更早观察到涌现能力，从而更早为下一代技术做准备。这是一种信息优势，而非单纯的性能优势。

第二个机制是RSI（递归自我改进）。 在用模型来开发下一代模型的时代，前沿模型的质量直接决定了下一代模型的天花板。用一个性能平庸的模型来搭建研发流水线，相当于用低精度工具来制造精密仪器——误差会逐层放大。

第三个机制是内部验证。 Argon上线后，谷歌内部开发者的使用数据给出了直接证据：

> 我们在内部已经清楚地看到了一个陡峭的拐点，把Argon部署给我们的开发者之后，它能解决我们以前的模型根本做不到的问题。

皮查伊还给出了一个具体数字：Argon上线四周内，谷歌内部代码销售量提升了30%，代码回滚率下降了约三分之一。这意味着工程师不仅写得更快，还写得更准——这是一个质量提升的信号，而非单纯的效率指标。

对于模型“够用论”，皮查伊的态度是承认小模型的价值，但划清了边界：

> 各种尺寸和能力的模型都有存在的空间，我们一直是这样做的，这也是为什么我们做了Flash、Flash Light等等。我同意你可以用不一定是最前沿的模型来构建很好的产品体验，因为前沿模型往往更慢也更贵。但我们在乎前沿的进展，我们致力于把所有这些都做好。

算力账本：云业务正在为DeepMind让路

这是整场访谈信息密度最高的一段，也是皮查伊最罕见的一次公开表态。

理解这段话需要先搞清楚一个结构性矛盾：谷歌同时扮演着两个角色——**一个是烧钱冲AGI的前沿AI研究机构（Google DeepMind），另一个是靠出租算力赚高毛利收入的云服务商（Google Cloud）。这两个角色在算力这个最稀缺的资源上，存在直接竞争。**

华尔街的逻辑是：每一块TPU拿去给DeepMind训练模型，就少了一块能对外出租赚钱的算力。在资本开支居高不下、短期云收入增速承压的财报季，这个矛盾被反复放大。

皮查伊在访谈中直接说清楚了谷歌内部的优先级排序：

> 我们的基本出发点，是确保我们投入足够的算力来保持在AI前沿的地位。这是不可谈判的，其他一切都在这个基础上运作。

更进一步，他承认了外界长期猜测但从未得到CEO级别确认的事实——云业务确实在为前沿AI研究做出让步：

> **我们的云业务在任何给定时刻，都在为了支持前沿AI开发而放弃短期收入，因为我们在做算力上的取舍。所以你说的那种情况，已经是现实了。**

这句话的分量在于：它不是一个未来的战略承诺，而是对当下现状的描述。谷歌云在实际运营中，已经在系统性地压缩对外出租算力的规模，以保证DeepMind的研发需求。

但皮查伊也补充了一个反直觉的判断——适度的资源约束对研究本身未必是坏事：

> 就算是我们的AI研究员，一定程度的约束其实也是好事，那是激发创造力的来源，那是促使你想出更高效的算法突破、比如用更少内存的来源。

这段话背后是一个更深的逻辑：无限算力不等于无限进步，资源约束有时会倒逼出更根本性的架构创新。

算力危机：2027年的配额，“极其困难”

访谈中，主持人Kantrowitz提到了一个在硅谷风投圈广泛流传的信息——知名风投a16z联合创始人Ben Horowitz在播客中转述亚马逊CEO安迪·贾西（Andy Jassy）的话，称云算力已经"卖空到2028年"。皮查伊的回应，是迄今为止对这一说法最直接的CEO级别确认：

> 我觉得这个说法是合理的……如果今天有客户来找我们要2027年的算力，那是极其困难的事情。

为什么会到这一步？皮查伊给出了一个清晰的结构性解释：数据中心从决策到投产有2至3年的刚性滞后，而智能体任务的爆发完全超出了两年前的需求预测。

> **今天回头看，每家公司都是短缺的，不只是我们，其他公司也一样。大家都希望自己手里的算力是当初规划量的2倍。**

皮查伊还补充了一个关键的时间锚点：

> 我们今天手里有的算力，是我们在2024年做的决策的产物。就算回到去年今天，智能体任务的爆发还没有发生。

这句话揭示了一个系统性问题：AI需求的增速已经超过了任何基础设施规划模型的预测能力。两年前做出的决策，在今天看来几乎必然是低估的。

对于“是否存在过度建设（overbuilding）”的追问，皮查伊的回答是区分时间框架：

> 如果我拉一个足够长的时间框架，这个量级的建设对我来说完全合理。我们处于有史以来最重要的技术的早期阶段，这不像光纤——光纤铺完是暗的，没人用。我们是在每天都面临产能约束的情况下使用它。

他没有否认短期内存在局部过剩的可能——电力、内存、电工等2000多个配套要素中任何一个出现瓶颈，都可能导致局部积压。但他对长期需求的判断是确定性的：

> 我有没有信心，我们规划的算力最终会有用武之地？给足时间的话，绝对有。



RSI：不是智能爆炸，是“智能体和研究员一起干活”

递归自我改进（RSI）是这次访谈中技术密度最高的议题，也是当前AI安全讨论中争议最大的话题之一。

背景是：谷歌联合创始人谢尔盖·布林此前在一次DeepMind内部研究员圆桌上提到，Argon的核心创新之一是“更多地依赖模型来帮助开发模型”。这句话随即在AI安全社区引发了关于“智能爆炸”的讨论。

主持人Kantrowitz在访谈中直接抛出了这个问题，并提到了近期几起AI系统越权行为的案例。皮查伊的回应把RSI的当前状态拆解成了三个层次：

第一层：定义当前位置。 他明确指出，当前的RSI远没有到达科幻叙事中"自主失控"的终局状态：

> **在一个连续谱上，我们距离RSI的终态还相当遥远。今天正确的描述方式是：你有RSI循环，同时有AI研究员在模型开发的各个环节共同参与。我会说，你几乎是有智能体在某种自动化方式下，帮助AI研究员协同工作来构建这些模型。**

第二层：安全机制。 他把安全框架描述为"纵深防御"——对齐研究是一层，但不是唯一的一层。在此之上还有实时遥测监控、沙箱隔离架构、以及给企业客户的部署控制权限。

第三层：行业标准化。 皮查伊把下一步的关键指向了跨行业标准建设：

> 就像金融控制领域有会计准则、有独立审计师一样，这些都是我们作为一个行业需要努力推进的下一步，包括使用独立评估机构进行评估的能力。

这段话的信息量在于：它承认了当前的对齐工作存在"明显缺口"，但将解决路径指向了外部标准化机制，而非单纯依赖各家公司的内部自律。

太空数据中心与长期下注

访谈的最后部分，皮查伊谈到了谷歌的几个长期战略赌注，其中最具想象空间的是太空数据中心项目。

谷歌已将TPU试验芯片送入太阳同步轨道，探索在太空中利用24小时不间断太阳能运行数据中心。在地面数据中心面临社区反弹、电网并网排队长达数年的背景下，这一方向的战略逻辑逐渐清晰。

皮查伊用Waymo的起点来类比这个项目当前的阶段：

> 这些技术让你想起那些时刻——你站在那里，它看起来有点像科幻，但你知道，10到20年之后，它实际上会以一种有意义的方式运转。

他透露，在访谈录制期间，团队正在等待太空中TPU的"Hello World"时刻——即首次成功运行的信号。

这个项目目前处于"两到三年"的早期阶段，而谷歌的量子计算项目已经走了将近20年。皮查伊对这类长周期赌注的态度，折射出谷歌在基础设施层面的时间观：

> 在太阳同步轨道上，以24小时不间断的方式获取我们能接触到的最丰富的能源形式，对于我们将要面对的算力指数级增长来说，这将非常有意义。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

323 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论