



摘要：

谷歌正与Marvell洽谈联合开发两款AI推理定制芯片，既有配合TPU运行的内存处理单元，也有专攻推理场景的新型TPU，计划产量近200万个。此举是谷歌系统性“去博通化”的最新动作，英伟达3月发布LPU直接加速了谷歌的布局节奏。随着AI智能体时代推理算力需求爆发，这场芯片卡位战已悄然提速。

谷歌正寻求与芯片设计商Marvell Technology合作，开发两款专为AI推理工作负载定制的新芯片，此举是谷歌系统性削减对长期合作伙伴博通依赖的最新举措，也折射出AI行业对推理芯片需求的急剧升温。

据The Information 19日报道，知情人士透露，谷歌与Marvell的谈判涉及两款芯片：一款是配合谷歌张量处理器（TPU）运行的内存处理单元（MPU），另一款是专为运行AI模型而设计的新型TPU。与谷歌此前向Marvell采购现货芯片不同，此次合作旨在为谷歌量身定制专属半导体产品。

此次谈判对芯片市场格局具有直接影响。博通股价面临潜在压力——尽管博通本月刚与谷歌签署了延续至2031年的新协议，但谷歌多元化供应商的战略意图已愈发清晰。与此同时，Marvell有望进一步扩大其定制芯片业务版图，该业务目前已是其增速最快的板块。

两款新芯片：分工明确，直指推理效率

据两位知情人士透露，谷歌与Marvell合作开发的内存处理单元将与现有TPU协同工作，根据计算需求与内存需求的差异，在两类芯片之间动态分配AI工作负载。这一设计思路源于推理任务的内在异质性——生成响应的某些步骤对算力要求极高，另一些步骤则受制于芯片读写内存的速度，单一处理器难以兼顾两者。

谷歌计划生产近200万个内存处理单元，但知情人士指出，由于谈判仍处于早期阶段，该数字存在变动可能。作为参照，摩根士丹利估计谷歌2027年的TPU产量约为600万个。双方目标是最快于明年完成内存处理单元的设计定稿，随后移交试产。

第二款芯片——专为推理场景打造的新型TPU——的设计完成时间及计划产量目前尚不明确。谷歌目前在台积电生产芯片，新芯片是否仍由台积电代工同样有待确认。

推理芯片军备竞赛提速，英伟达发布LPU成催化剂

谷歌加速推进这一合作，部分原因在于英伟达的竞争压力。

据一名谷歌员工透露，谷歌此前已有开发推理芯片的计划，英伟达在今年3月GTC大会上发布语言处理单元（LPU）后，谷歌随即加快了相关工作。英伟达的LPU基于其以200亿美元从初创公司Groq授权的技术构建，而Marvell正是Groq第一代LPU的芯片设计合作伙伴——这意味着Marvell已具备设计推理芯片的实战经验。

推理芯片需求的爆发，根本上源于AI产品形态的演进。随着自主智能体等更复杂的AI应用落地，其所需算力远超传统聊天机器人。OpenAI近期与Cerebras签署了逾200亿美元的推理芯片采购协议，同时也在与博通联合开发自有推理芯片，行业整体正加速布局这一赛道。

去博通化：战略意图明确，但进程仍受制约



谷歌寻求与Marvell合作，是其自2023年以来持续推进供应商多元化战略的组成部分。**博通长期作为谷歌TPU的唯一设计合作伙伴，并按每颗TPU产量收取授权费——随着TPU需求激增，谷歌支付给博通的费用水涨船高，这是谷歌寻求替代方案的核心动因。**

谷歌已于去年引入联发科参与TPU芯片的设计与生产。此次与Marvell的谈判，则进一步拓宽了谷歌的合作伙伴矩阵。谷歌此前已向Marvell采购过CXL控制器芯片，用于管理数据中心内服务器间的内存共享，这段合作经历为双方建立了互信基础。

然而，博通的核心地位短期内难以撼动。博通本月刚与谷歌签署新协议，将为谷歌下一代AI数据中心机架提供定制TPU及网络组件，合作期限延伸至2031年。这表明，谷歌的多元化战略更多是在现有格局上叠加新选项，而非彻底切换。

对Marvell而言，与谷歌的深度合作意味着其定制芯片业务有望再获重量级客户背书。Marvell的主营业务涵盖数据中心标准网络、存储及光互联芯片，但近年来协助客户设计专属芯片的定制业务已成为其增速最快的板块。

谷歌TPU的商业化进程也为此次合作提供了更广阔的市场想象空间。谷歌去年开始向非谷歌数据中心的客户租赁TPU，直接挑战英伟达在AI芯片市场的主导地位，Anthropic、Meta和苹果均已成为TPU客户。若新型推理芯片研发顺利，其潜在市场将不局限于谷歌内部需求。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 117

 收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论