

摘要：

Gemini 3.6 Flash提升代码、知识工作和多模态能力，减少输出Token消耗的同时，输出价较前代低近17%；Gemini 3.5 Flash-Lite主打3.5系列中最低价和最快速；Gemini 3.5 Flash Cyber通过CodeMender代码安全智能体，试图以更低成本切入网络安全AI市场。谷歌透露，Gemini 4已启动“迄今最雄心勃勃的预训练工作”。

谷歌又一次把“AI军备竞赛”的焦点，从单纯追求更大、更强的旗舰模型，转向了更便宜、更快、更适合大规模部署的AI智能体。

美东时间21日周二，谷歌一口气推出Gemini 3.6 Flash、Gemini 3.5 Flash-Lite以及面向网络安全的Gemini 3.5 Flash Cyber三款新模型。

其中，Gemini 3.6 Flash重点提升代码、知识工作和多模态能力，并通过减少Token消耗降低实际运行成本；Gemini 3.5 Flash-Lite主打Gemini 3.5系列中最低的定价和最快的速度；Flash Cyber则瞄准软件漏洞发现与自动修复，直接切入Anthropic旗下Mythos等网络安全模型的优势赛道。

相比前代3.5 Flash，Gemini 3.6 Flash的输出价格下调约17%，但并非所有新模型都名义上价格下降。Gemini 3.5 Flash-Lite的重点在于通过更快的响应速度和更高的任务效率，降低高吞吐场景下的整体使用成本。与上一代Gemini 3.1 Flash-Lite相比，其名义Token价格并未下降，输出价格反而更高。

因此，谷歌此次AI产品策略的核心，与其说是全面“价格战”，不如说是通过模型分层，试图在模型能力、Token消耗、响应速度和实际任务成本之间寻找新的平衡。

同时，此次发布暴露出谷歌当前AI战略的一个尴尬：市场最期待的旗舰模型Gemini 3.5 Pro仍然没有正式发布。路透社报道称，该模型原定于6月推出，目前仍在与合作伙伴测试，谷歌只表示将在“准备好后”尽快扩大开放。与此同时，谷歌已经启动了迄今最雄心勃勃的Gemini 4预训练工作。

在OpenAI和Anthropic持续推出更强大模型、AI企业客户开始越来越关注推理成本和Token效率的背景下，谷歌此次发布的三款模型，实际上更像是一次围绕“AI智能体商业化”的全面补位。

Gemini 3.6 Flash：更少Token，更低价格，代码和智能体能力同步提升

谷歌此次更新的核心模型是Gemini 3.6 Flash。

按照谷歌的说法，3.6 Flash是在此前Gemini 3.5 Flash基础上，根据开发者和企业客户反馈进行优化的“工作马”模型，重点提升代码编程、知识工作和多模态能力。

更值得关注的是效率。


谷歌援引Artificial Analysis Index称，Gemini 3.6 Flash相比3.5 Flash的输出Token消耗减少17%，同时完成多步骤工作流所需的推理步骤和工具调用次数也有所减少。对于需要长时间运行、反复调用工具的AI智能体而言，这意味着成本并不只是简单地按Token价格下降，而是整个任务的计算量都有望减少。

价格方面，Gemini 3.6 Flash的输入价格为1.5美元/百万Token，输出价格为7.5美元/百万Token，较前代3.5 Flash9美元/百万Token的输出价低将近17%。

从谷歌公布的测试数据来看，Gemini 3.6 Flash在多个关键指标上较3.5 Flash有所提升：

- DeepSWE：49%，高于37%；
- MLE Bench：63.9%，高于49.7%；
- OSWorld-Verified：83%，高于78.4%；
- GDPval-AA v2：1421分，高于1349分。

其中，OSWorld-Verified主要测试模型使用计算机完成实际任务的能力，GDPval-AA则更偏向现实世界的知识工作任务。



谷歌强调，3.6 Flash能够减少不必要的代码修改和执行循环，从而生成更高质量、更接近生产环境要求的代码。

这正是AI模型竞争正在发生变化的一个缩影。

在早期的大模型竞争中，市场更关注模型能否在数学、知识问答和综合基准测试中取得更高分数。但随着企业开始真正部署AI智能体，模型每多调用一次工具、每多生成一段无效Token，都可能转化为实际成本。

因此，“单位智能的成本”正在成为AI模型竞争的新战场。

Flash-Lite：每秒350个Token，瞄准高频、低成本AI应用

如果说3.6 Flash针对的是复杂任务，那么Gemini 3.5 Flash-Lite的目标更加明确：规模化。

谷歌将其定位为Gemini 3.5系列中速度最快、成本效率最高的模型，适用于智能搜索、文档处理以及其他高吞吐、低延迟任务。


根据Artificial Analysis的数据，Flash-Lite的输出速度达到每秒350个Token。

价格则进一步下探至：输入定价0.30美元/百万Token，输出2.50美元/百万Token。



这意味着，在大量文档总结、分类、信息抽取以及AI搜索等高频任务中，开发者可以使用更加便宜的模型处理海量请求，而不必让更昂贵的旗舰模型承担所有工作。

谷歌公布的测试数据显示，Flash-Lite相比此前的3.1 Flash-Lite，在Terminal-Bench 2.1上的成绩从31%提高至54%，GDM-MRCR v2从60.1%提高至72.2%，GDPval-AA v2则从642分提高至1140分。



更值得注意的是，谷歌称，3.5 Flash-Lite在部分测试中甚至超过了更高级别的Gemini 3 Flash，包括SWE-Bench Pro和OSWorld-Verified。

这背后反映的是谷歌对未来AI应用架构的一个判断：


未来的AI智能体可能不会由一个超级模型独立完成所有工作，而是由多个不同成本、不同能力的模型协同完成。

一个较强的“主智能体”负责规划和决策，多个便宜、快速的“子智能体”负责搜索、整理、调用工具和执行重复性任务。

在这种架构下，模型的速度和成本效率，可能比单纯的最高基准分数更加重要。

谷歌推出网络安全专用模型，正面迎战Anthropic的高端模型

此次发布中最具战略意味的产品，可能是Gemini 3.5 Flash Cyber。



谷歌表示，该模型专门用于发现、验证和修复代码安全漏洞，并与其CodeMender代码安全智能体结合使用。

在CodeMender体系中，多个Gemini 3.5 Flash Cyber智能体可以协同工作，最终形成综合安全报告。

谷歌称，Flash Cyber的设计目标是在低于大型模型的每Token成本下，实现具有竞争力的网络安全能力。

这显然是在对准一个正在快速升温的AI应用市场。

随着AI模型越来越擅长生成代码，企业面临的一个新问题是：AI生成代码的速度可能已经超过人类安全团队审查和修复漏洞的速度。

因此，能够自动扫描代码、发现漏洞、验证漏洞并生成修复方案的AI安全智能体，正在成为企业AI应用的重要方向。

谷歌此次将Flash Cyber与CodeMender结合，实际上试图打造一个“低成本、可规模化”的自动化安全防御系统。

谷歌对该模型的部署也相当谨慎。由于网络安全AI具有明显的双重用途属性，Flash Cyber初期将仅通过有限访问试点向政府和受信任合作伙伴提供，而不是直接全面开放。

路透社指出，谷歌当前正面临Anthropic和OpenAI的竞争压力。Anthropic近期推出了更强大的Mythos 5和Fable 5模型，OpenAI也推出了GPT-5.6。

其中，Anthropic最新模型的网络安全能力尤其受到市场关注。

因此，谷歌推出Flash Cyber的意义，不仅在于发布一个垂直领域模型，也是在试图证明：**在AI安全领域，企业不一定需要使用最昂贵、最大的模型。**

如果一个更小、更快、更便宜的模型能够完成大部分漏洞检测和修复任务，那么企业部署AI安全工具的成本就可能显著下降。

■ 旗舰Gemini 3.5 Pro仍然延期，谷歌已经开始训练Gemini 4

不过，谷歌此次密集推出Flash系列，并没有完全消除市场对旗舰模型的疑问。

Gemini 3.5 Pro原计划于今年6月发布，但目前仍然处于与合作伙伴测试阶段。

路透社援引知情人士称，Gemini 3.5 Pro延期的一个重要原因，是其在内部测试中尤其是在代码任务上的表现没有达到预期。

而代码能力恰恰是目前企业AI市场增长最快、商业价值最高的应用场景之一。

这也解释了为什么谷歌在Gemini 3.5 Pro仍未发布的情况下，选择继续加码Flash系列。

一方面，Flash模型能够迅速覆盖开发者和企业客户；另一方面，谷歌也可以通过更低的价格，扩大Gemini模型的实际调用规模。



Alphabet CEO皮查伊此前曾强调，企业如果将大部分AI工作负载转移至Gemini模型，每年可能节省超过10亿美元。路透社称，谷歌近期也在持续强调Gemini模型的成本优势。

但从竞争格局看，谷歌面临的压力依然不小。

去年Gemini 3系列发布时，谷歌一度重新回到AI竞争的第一梯队，并迫使OpenAI内部发出“红色警报”。然而，此后Anthropic和OpenAI继续推出更强大的模型，谷歌的旗舰产品却出现延期。

如今，谷歌的战略开始出现明显分层：

Gemini 3.6 Flash负责效率，Flash-Lite负责规模，Flash Cyber负责垂直场景，而Gemini 3.5 Pro则承担重新证明谷歌顶级模型能力的任务。

更大的悬念在于Gemini 4。

谷歌此次透露，Gemini 4已经启动了“迄今最雄心勃勃的预训练工作”。

这意味着，谷歌正在一边修补Gemini 3.5 Pro的延期问题，一边加速下一代旗舰模型的研发。

对于Alphabet而言，真正的考验已经不只是“能否发布一个更强的模型”，而是能否同时解决三个问题：

模型能力能否追上OpenAI和Anthropic；模型成本能否足够低；以及AI模型能否真正转化为搜索、云计算和企业软件业务的收入增长。

从此次三款新模型的发布来看，谷歌正在把“更强模型”的竞争，进一步转向“更高性价比的AI基础设施”竞争。

但在Gemini 3.5 Pro正式亮相之前，市场恐怕仍会继续追问：谷歌能否再次拿出一个足以改变AI竞争格局的旗舰模型。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

245 收藏

分享到:

写评论

请发表您的评论



