

摘要：

谷歌在Cloud Next 2026大会上发布了第八代TPU的两款独立芯片——TPU 8t（训练）与TPU 8i（推理），这是谷歌历史上首次将训练与推理任务拆分至独立芯片，标志着AI基础设施从“通用加速器时代”正式进入“分工时代”。

谷歌在Cloud Next 2026大会上发布了第八代TPU的两款独立芯片——TPU 8t（训练）与TPU 8i（推理），这是谷歌历史上首次将训练与推理任务拆分至独立芯片，标志着AI基础设施从“通用加速器时代”正式进入“分工时代”。

这一战略转向的本质是对AI计算特性分化的深刻洞察：训练任务追求极致吞吐量与规模扩展，推理任务则对延迟和并发更为敏感，单一芯片无法同时满足两种需求的成本最优解。谷歌同时展示了软硬件一体的完整AI基础设施体系：通过Axion CPU消除主机瓶颈，通过Virgo网络（带宽提升4倍）和Boardfly拓扑（跳数减少56%）重构互联架构，通过JAX和Pathways将分布式训练扩展至单一集群超过100万颗TPU芯片。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

VIP会员

加入见闻VIP会员

立即解锁全文

73 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论