

摘要：

豆包推出收费版并非流量焦虑或变现困境，而是AI推理成本高昂的必然选择。与OpenAI、Anthropic等一线大厂策略同构，通过付费分层筛选高质量用户反馈，优先保障专业用户的算力与体验，同时缓解免费用户排队压力。此举标志着AI从流量平台回归工具属性，是通向AGI的可持续商业闭环。

看了几天，市场上关于豆包收费版这件事，大多解读不幸都是错的。

总结下来，市场上对于豆包保留免费版本、同时对高级功能开启收费版本的叙事，基本可以分为两类：

第一类是互联网时代的“免费战胜收费”叙事：

在这个叙事中，豆包现在月活全球第二、中国区第一，一旦推出收费版，活跃用户就会迁移到免费模型，DAU下降，会影响豆包的估值。

第二类是SaaS时代投资人的“收费困难症”痛苦记忆重现：

在这个叙事中，中国市场软件付费习惯有限，开启收费模式产生的收入体量非常可疑，杯水车薪，于事无补。

这两个解读在我看来，毫无意外均属对AI发展的误判，也是今天互联网舆论圈对于AI发展前沿的判断力，尚未跟上中国AI技术能力进化的一种体现。

在我们看来，以豆包为样本，**保留免费基础功能、通过订阅模式走向商业化，是AI作为一种提供价值的工具属性的必然回归，更为重要的是，这个过程中无论免费用户还是付费用户，产品最终体验都将获得提升。**

而当下舆论囿于古典互联网时代的流量叙事，或受限于收入体量逻辑的SaaS叙事，已经与当下AI时代的发展逻辑产生了相当的脱节。

模型推理有真实成本：一线AI大厂的同构妙手

与互联网和SaaS“边际成本为零”的逻辑不同，AI无论是训练还是推理，每天都在产生巨大的真实成本。

关于字节算力成本的信息有限，我们不妨用有限公开信息做一个粗略年化估算：

根据媒体和火山引擎官方披露，截至2026年3月，豆包日均Token消耗已达**120万亿**，较2024年5月上线时增长1000倍（当时仅0.12万亿/天）。这个增速意味着用户对豆包的消耗，远超早期聊天机器人时代，是Agent、多模态、长链路任务爆发后的结果。

字节跳动对算力成本的控制已经非常优秀：

例如在之前的Pro版中，字节公布了低至**0.0008元/千Token**的定价，不难推算字节自建算力的真实成本应该比这个数字更低。但即使以这种显著低的成本来评价，豆包的算力消耗依然惊人：



以Pro版定价估算，豆包每日算力消耗上限在**1亿人民币上下**；即使我们假设算力成本仅为定价的30%，豆包每日算力消耗最低也应在**几千万人民币量级**。这意味着豆包年化推理硬成本轻松过百亿。

要知道，这还没有算新模型训练、上游资本开支、算力迭代采购等巨额投入，也没有考虑豆包用户数继续增加、长任务增长后的额外消耗——每一项都直指每年千亿级消耗。

豆包这样每年百亿人民币起步、且仍在指数级增长的使用成本，与古典互联网时代的“边际成本为零”逻辑天差地别。

每年动辄百亿直指千亿的长任务算力消耗，意味着任何一家互联网巨头用自己的广告业务对AI进行现金流补贴，都几乎不可持续，很快就会碰到现金耗竭的墙而不得不有所取舍：

要么大幅涨价/限额，要么挖掘专业付费用户生产力服务潜力。

豆包收费的行动逻辑与OpenAI等一线大厂如出一辙

我们不妨看一下全球其他AI大厂是怎么做的：

2025年底至2026年初，OpenAI大幅强化Codex能力（代码生成 + Agentic Coding能力），但同时主动限制免费用户的使用，并放缓整体用户增长速度。

具体做法是：OpenAI把最强的推理模型（o1、o1-pro、Codex增强版）深度绑定到ChatGPT Plus / Pro / Team付费计划。免费用户虽然还能用基础GPT-4o，但**复杂长任务（多文件重构、长时间Agent调试、百万行代码库理解）被大幅限制或排队**。

这直接导致2025年下半年到2026年初，OpenAI的周活跃用户增长明显放缓——之前每月新增几千万用户，如今增长已逐渐趋稳。但这正是OpenAI有意为之的一步棋：优先服务愿意付费的专业开发者和企业，API与企业订阅收入占比快速上升，财年收入增长主要来自API和企业订阅，而非消费者免费用户。

2026年初，OpenAI正式将Codex代理功能开放给ChatGPT Pro、Team和Enterprise用户，并明确表示初期“慷慨访问权限”，随后将实施使用频率限制，免费用户需额外购买积分。

这正是“强化高消耗能力 + 付费优先 + 免费限流”的典型操作，与豆包当前策略高度同构。

随着付费增强的ChatGPT能力提升，免费用户也会因此受益——这才是正确的商业飞轮。

我们不难看出，在这个问题上，字节和OpenAI面临的情况是同构的。豆包在中国市场的地位与ChatGPT等量齐观，用户继续高速增长已不是首要目标，基于定价区分的用户体验优化来的更为重要。

事实上，AI组织设定的北极星指标越是靠近“领红包、做月活、强运营”，整个公司的模型能力就距离AGI这个圣杯越发遥远，模型会陷入浅层使用和流量优化等非核心指标里无法自拔，始终在与生产力提升无关的问题上反复打转，消耗已经十分昂贵的算力资源和组织耐心。

AI是工具，付费用户的体验才是有效反馈源

今天很多的AI舆论所走入的误区是：AI订阅的本质不是卖功能，而是卖**不同强度、不同成本曲线下的Token使用权**。



生产力工具必然伴随成本，它本质上是通过付费机制筛选出高质量反馈源，从而推动模型向更实用、更可靠的方向进化。

首先，工具类产品的迭代需要明确的参照系。免费模式虽然能快速积累用户规模，但往往带来大量低质量反馈。这些免费用户多为浅层尝试者，使用场景有限，反馈内容常停留在表面情绪或随机测试层面，容易形成噪声，掩盖真实的核心需求。

相比之下，付费用户是愿意为性能、响应速度、稳定性、上下文长度等关键指标直接付费的群体。他们的付费行为本身就是一种强信号，表明他们对模型有实际依赖和深度使用意愿。这种反馈更具商业真实性和改进价值，能帮助团队优化方向。

这一机制在传统软件和SaaS领域早已被验证有效。

比如，Figma在推出Professional和Organization付费计划后，付费设计团队（尤其是大型企业用户）的高频复杂协作场景反馈，直接推动了多版本历史、AI辅助设计（生成变体、自动布局优化）等核心功能的快速迭代。这些功能远超免费用户浅层使用的贡献，最终让Figma在设计工具领域形成难以撼动的护城河。

豆包也是同样的道理：通过设置付费门槛，锁定的是有真实业务场景的企业用户、专业工作者和深度应用者。通过收费，这些生产力场景的用户可以免去算力稀缺产生的排队时长消耗。

这意味着在资源分配上，系统会优先保障付费用户的请求：响应速度更快、无需排队、复杂任务处理更稳定。付费版往往能调用更高性能或满血版模型，减少幻觉、提升上下文保持能力，同时在多轮对话或重度生产力任务（如PPT生成、长文档分析、高清生图）中保持流畅。

免费版高消耗功能（如高级生成）有每日额度限制，用完即受限或降速；付费版不仅额度大幅提升，还叠加优先权，确保重度用户在需要时“说用就用”。

更重要的是，在算力稀缺的大背景下，当前全球大模型普遍面临算力卡短缺的现实困境，OpenAI、Anthropic、Google等一线厂商无一例外都在通过付费分层来缓解这一矛盾：豆包这一设计符合工具类产品的资源分配逻辑。

对普通用户而言，日常轻度使用免费版完全够用，不会受到明显影响；对职场人士、创作者、学生等有频次需求的用户来说，68元/月换来“不卡顿、不等待”的效率提升，往往是值得的——它直接转化为时间节省和产出提高。

通过付费分流高消耗用户后，整体算力资源得到更合理的分配，免费用户的排队等待时间也将明显缓解，形成“付费用户体验升级 + 免费用户体验改善”的双赢局面。这正是工具类产品在资源稀缺环境下的最优资源配置逻辑。

简单说，**工具必然有成本，工具迭代必须有明确参照系**。只有付费用户愿意为性能、速度、稳定性买单，他们的意见才具备商业真实性与改进价值。免费用户的大量噪声往往掩盖真正需求，付费行为本身就是最精准的信号筛选机制。

AI的终点是AGI，而不是下一个流量平台或SaaS

无论我们有多乐观，但不能否认的是，今天的AI仍然处于物种繁荣的早期。穿越通向AGI这一最终圣杯的漫漫长路，需要依靠付费用户的深度反馈，真正推动模型向实用工具、向AGI进化。



在这条路上，企业和个人付费的营收以及倍数并非关键。用古典的SaaS估值倍数衡量，往往会产生极大的偏差。真正有价值的，是模型在逻辑推理、知识应用、任务执行等方面的进步。而付费用户的真实场景反馈，正是推动这一进步的最可靠输入。

他们在工作、创作、决策等实际应用中，会充分暴露模型的幻觉问题、上下文保持能力不足、领域知识短板等缺陷。这些反馈能直接转化为迭代优先级，帮助模型从通用聊天工具逐步向可信赖的生产力助手转型。

收入增长在这一过程中，也成为衡量生产力水平的重要标准。付费用户规模扩大，意味着模型为用户创造的边际价值被市场认可，中国AI公司因此获得可持续的现金流，用于进一步加大研发投入、算力采购和数据优化，形成正向循环。

反之，如果完全依赖免费模式，虽然短期流量可观，但容易导致资源分散和反馈失真，拖累长期技术进步。

今天炙手可热，估值接近一万亿美金的Anthropic在付费分层问题上走的更早，走得更远：

在2026年初，Anthropic将高消耗的Claude Code功能逐步从基础Pro计划移除或限额，推动重度用户升级至更高档位或转向API付费。

这直接帮助Anthropic推理毛利率从38%提升至70%以上：Claude Code周活用户两个月内翻倍，ARR（年化收入）快速攀升至数百亿美元级别。

付费用户的高强度反馈，正是推动其Agentic Coding能力持续领先的核心动力。

豆包的收费策略，正是对长期主义的一种体现：不被流量焦虑主导，而是通过价值交换来积累高质量信号，推动AGI相关能力的稳步提升。

事实上，更多的中国大模型公司，都应该积极推动用户基于模型能力付费，来用更优秀的商业模式，对模型优化产生正反馈。

诛心而论，没有信心收费，反而才可能是组织内核不稳的显性表现。

结语

在我看来，豆包此次收费不是太早，甚至可以说姗姗来迟。

它体现了豆包作为中国大模型先发者应有的觉悟：不沉迷免费流量和用户数量的一时一地的领先，而是主动建立可循环、健康的商业闭环。

这一步不仅是为自身造血，更是为行业树立正确标杆——**AI的未来，属于那些敢于向价值付费者负责的模型，这是通向AGI的必经之路。**

本文来源：[锦缎](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

139 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



见闻用户
10小时前 中国福建省

收费必然的，拼服务就不能再自我审查了。

0 回复