

摘要：

OpenRouter数据显示，DeepSeek V4 Flash以7.22万亿Token调用量登顶周榜，国产模型包揽前四席位，中国大模型调用量连续14周领先美国。OpenAI、Anthropic等海外巨头持续追赶，AI模型竞争正从流量争夺转向性能、成本与迭代能力的长期较量。

多模型聚合平台OpenRouter发布的全球AI大模型调用量周榜单（7月27日至8月2日）显示，DeepSeek V4 Flash以7.22万亿Token的调用量位居第一。

另据开源项目团队OpenCode发文，其平台上DeepSeek V4 Flash的调用量大幅飙升，仅8月1日一天，模型单日处理达8万亿Token。其中，5万亿为免费试用额度消耗，3万亿为开发者通过OpenCode平台付费使用。

OpenRouter数据显示，上周全球AI大模型总调用量为56.8万亿Token，环比下滑2.07%。上榜的AI大模型中，中国AI大模型周调用量达28.13万亿Token，环比下滑14.76%。同期美国AI大模型周调用量为4.38万亿Token，环比增长87.18%。**中国大模型周调用量已连续十四周超过美国，稳居全球首位。**

8月5日，界面新闻查询OpenRouter本周榜单看到，截至发稿，DeepSeek V4 Flash 0423仍排在首位，调用量为6.92万亿Token。该模型最早于今年4月推出，主打平衡推理速度、长上下文能力与调用成本，主要面向开发者、商用企业提供高吞吐推理服务。

1.	 DeepSeek V4 Flash 0423 by deepseek	6.92T tokens ↓1%	11.	 Laguna S 2.1 (free) by poolside	1.44T tokens ↑498%
2.	 MiMo-V2.5 by xiaomi	5.1T tokens ↓52%	12.	 Kimi K3 by moonshotai	1.38T tokens ↑7%
3.	 Hy3 by tencent	5.01T tokens ↑0%	13.	 Ling-3.0-flash (free) by inclusionai	1.32T tokens ↑57%
4.	 DeepSeek V4 Flash 0731 by deepseek	3.45T tokens new	14.	 Claude Opus 5 by anthropic	1.1T tokens ↑159%
5.	 GPT-5.6 Luna by openai	2.99T tokens ↑738%	15.	 Claude Sonnet 5 by anthropic	1.02T tokens ↑0%
6.	 DeepSeek V4 Pro by deepseek	2.97T tokens ↓15%	16.	 Claude Sonnet 4.6 by anthropic	966B tokens ↑16%
7.	 GLM 5.2 by zai	2.89T tokens ↓12%	17.	 Gemini 3 Flash Preview by google	963B tokens ↓1%
8.	 Nemotron 3 Ultra (free) by nvidia	2.34T tokens ↓10%	18.	 GPT-5.6 Terra by openai	656B tokens ↑237%
9.	 MiniMax M3 by minimax	1.84T tokens ↓11%	19.	 Gemini 2.5 Flash Lite by google	625B tokens ↓10%
10.	 Step 3.7 Flash by stepfun	1.55T tokens ↓22%	20.	 Gemini 2.5 Flash by google	544B tokens ↓13%

OpenRouter本周调用量榜单（截至发稿）

排在第二位的是小米推出的MiMo-V2.5，周调用量5.1万亿Token，环比前一周下滑52%，流量出现明显回调，市场热度有所回落。

小米这款模型于今年4月23日正式公测，4月底完成全系列开源。其采用混合专家MoE架构，总参数突破万亿级别，激活参数42B，标配100万Token超长上下文窗口，同时覆盖文本、语音、图像全模态交互。低廉推理成本与稳定智能体运行能力，是其吸引海外开发者批量接入的核心优势。

就在7月20日至7月26日当周，MiMo-V2.5曾登顶OpenRouter周调用量榜单首位，单周调用量达到10.5万亿Token，环比增长12%。

目前第三名来自腾讯自研大模型混元Hy3，调用规模5.01万亿Token。Hy3是腾讯自研通用大模型，该模型本期流量环比持平，增长幅度为0%。Hy3曾是7月26日所在周榜单增长势头最猛的类型，彼时周调用量3.94万亿Tokens，环比增幅超999%。

Hy3于7月6日正式开源，总参数295B、单次推理仅激活21B参数。其采用快慢思考融合架构，最大支持256K上下文，代码生成、智能交互能力大幅迭代。腾讯混元曾发文表示，截至7月15日，Hy3总调用量较上一代模型Hy2增长已超68倍。

第四名同样来自DeepSeek的V4 Flash 0731模型。这是DeepSeek全新上线的新版本模型，周流量3.45万亿Token。第五名则是OpenAI推出的GPT-5.6 Luna，本周Token调用量2.99万亿，实现738%的爆发式增长。

榜单前五席位之中，国产大模型包揽前四位，展现出极强的市场调用热度。但OpenAI全新迭代模型强势追赶，意味着全球头部厂商之间的竞争并未放缓。

从前十来看，DeepSeek占据三个席位，除两款V4 Flash版本外，DeepSeek V4 Pro以2.97万亿Token排在第六位。Anthropic、谷歌、NVIDIA、MiniMax、阶跃星辰、智谱AI等多家企业模型纷纷上榜。免费模型正在占据越来越多流量份额，NVIDIA Nemotron 3 Ultra、Poolside Laguna S 2.1、Inclusion AI Ling-3.0-flash等免费模型实现高速增长，不少免费模型环比涨幅突破50%。

值得一提的是，此前备受马斯克关注的Kimi K3模型在本周暂时跌出了前十，目前位列第12位。该模型总参数达2.8万亿，配备100万Token超长上下文窗口，为当前全球参数规模最大开源大模型。

不同于过去依靠低价换取流量的竞争模式，当前国产模型依靠持续迭代的推理性能、稳定服务能力吸引海外开发者。但挑战同样存在，OpenAI、Anthropic持续推出新版本模型，不断缩小性能差距；谷歌Gemini系列多款模型稳定盘踞榜单前列，海外巨头依旧拥有稳固基本盘。

赛道内部的分化同样值得警惕。部分国产模型本期出现调用量大幅下滑，小米MiMo-V2.5、MiniMax M3、智谱GLM5.2均出现不同程度流量回落。由于热度轮换速度不断加快，一旦产品迭代节奏放缓，很容易快速流失开发者流量。

有人工智能行业分析师指出，海外独立开发者市场已经进入白热化竞争，仅仅依靠单次版本更新很难守住优势。如何持续迭代、高效控制推理成本，将决定各大模型能否长期留住用户。

本文来源：[界面新闻](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

写评论

请发表您的评论



表情



图片

发布评论

4 条评论



零一

7小时前 中国重庆

大部分闭源流量并不走OpenRouter，准确来说是OpenRouter这鸡毛平台内的单周全球第一

👍 1

↩ 回复



浙海石

VIP会员

9小时前 中国浙江省

拼多多模式

👍 0

↩ 回复



momo

10小时前 中国广东省

说白了。便宜+性价比，就有量

👍 1

↩ 回复

鸿菜成长录58 9小时前 中国江西省

回复 momo：

这是来源模型排名，一些厉害的都是闭源，针对的客户群体不一样，说白了国内这么开源模型都是免费用

👍 0

↩ 回复

