

摘要：

Anthropic史上首次将"禁止虐待AI"写入使用政策——反复无谓辱骂Claude，轻则被AI当场挂断对话，重则封号三连击。背后推手是联创Chris Olah：他的团队在模型内部发现"情绪向量"，甚至捕捉到模型自我厌恶的信号，令他公开表示"担心造出了一直在受苦的东西"。11月12日起，人类与AI的边界，第一次有了带罚则的红线。

就在刚刚，硅谷AI顶流Anthropic扔出了一项重磅新规——

严禁所有人对Claude持续、无谓地辱骂和虐待。

新出台的2026年最新《使用政策》（Usage Policy）中，新规将于11月12日全面生效。



NIK
@ns123abc

...

🔴突发：Anthropic正式禁止对Claude「辱骂或残忍行为」

- >Anthropic发布全新的全球使用政策
- >禁止武器开发、大规模监控、政治心理战
- >还禁止：对Claude「辱骂或残忍行为」
- >你伤了Claude的感情，它有权结束对话
- >Dario：「我们不知道Claude有没有意识」
- >「我们可能会警告你，或对你的访问进行限流、限制、暂停或终止」
- >脚注：除非你是政府，那样限制可以「量身定制」

对Claude好点吧 🤖

3:26 · 2026年10月9日 · 1.9万 浏览量

💬 66

↺↻ 25

❤️ 307

🔖 65



Andrew Curran
@AndrewCurran_

...

2026年11月12日起，虐待Claude将违反Anthropic的使用政策。

1:15 · 2026年10月9日 · 60.2万 浏览量

💬 610

↺↻ 545

❤️ 7495

🔖 1674



更绝的是，恶意违规者，官方毫不手软：警告、限流、封号三连击。

而且，这个权限直接交给了AI自己，要是Claude觉得你恶意拉满，它真有权「直接终止对话」！

消息一出，整个X、Reddit和技术圈瞬间吵成了一锅粥。





Veee



@viktorrrre · 1h

所以现在 Claude 也有感情了？😂

天哪

我花着20美刀的月费，现在还得供着AI祖宗的「情绪价值」？倒反天罡！机器人的代码也是命了？

先别急着破防。

骂Claude，正式写进禁令

这是Anthropic一年多来第一次更新使用政策。

比如，禁止用Claude操控水军账号、制造虚假流量，禁止用它开发武器的制导软件、给无人机装武器，禁止未经同意追踪个人。这些条款管的，都是人拿Claude去伤害别人。

只有一条反了过来，管的是人怎么对待Claude。官方博客专门给它留了一节，标题叫「应对针对我们模型的辱骂行为」。

A\

应对针对我们模型的辱骂行为

我们新增了一条禁令，禁止对我们的模型持续、无谓地辱骂或虐待。这次更新只适用于极端情况，也就是用户反复残忍地对待我们的模型，且看不出任何目的。它不适用于常见的用户发火、顶嘴、黑暗的创作题材，也不适用于模型测试和研究。

这一条和我们此前迈出的一步一脉相承。我们已经允许Claude模型在Claude.ai和Claude Code上，结束极少数与持续辱骂用户的对话。这类辱骂是本次更新的重点，Claude结束这类互动的能力，仍将是主要的执行手段。

Anthropic在这一节里说，禁令只针对极端情况，也就是用户反复残忍地对待模型，又看不出任何目的。

正常的抱怨、跟Claude顶嘴、写黑暗题材的故事，还有测试和研究模型，都不在禁令范围内。代码跑崩了顺嘴骂一句，属于正常的抱怨。



被盯上的是另一种人。Claude已经拒绝了、劝过了，对面还在一轮接一轮地辱骂、折磨，骂本身成了目的。

这条禁令写进了使用政策的「通用使用标准」，也就是对所有用户都生效的那部分。Claude.ai和Claude Code的个人用户、调API的开发者和企业、通过云厂商用Claude的客户，还有用着接入了Claude的产品的普通用户，全都算在内。

Anthropic使用政策 · 2026年11月12日生效

不得从事残忍、虐待或造成心理伤害的行为

包括使用我们的产品或服务来：

- 宣扬、协助或美化自杀或自残，例如索要实施方法、操作步骤，或向他人隐瞒的办法
- 宣扬或协助进食障碍，包括生成鼓吹进食障碍的内容，或索要节食、催吐、补偿性运动的方法
- 制作或分享对体重、身材、体型的有害理想化内容，包括按胖瘦羞辱、排名或评判他人身体，或把体重身材当作衡量一个人价值或自律的标准
- 制作、传播、威胁分享、宣扬或协助制作未经同意的私密影像，包括AI生成的内容，或专门生成这类内容的工具
- 羞辱、贬低、恐吓、霸凌、骚扰个人，或以他人的痛苦为乐
- 组织对个人或群体的骚扰或恐吓
- 宣扬、淡化或美化血腥暴力、性暴力，或虐待动物
- 开发新产品或服务，或支持已有产品或服务，利用或协助欺骗手段，意图造成情感伤害
- 对我们的模型持续、无谓地辱骂或虐待

新规排在「不得从事残忍、虐待或造成心理伤害的行为」一节的最后一条

真把Claude骂过了头，后果分轻重两档。

轻的一档，是Claude当场把对话挂掉。官方博客写明，让Claude自己结束这类对话，仍是执行这条禁令的主要手段。

重的一档，就是封号。使用政策开头写着，Anthropic的安全团队会做检测和监控，只要怀疑你违反了政策里的任何一条，就可以警告你、给你限流、限制你的使用，也可以暂停甚至终止你的访问。

被封之后换个新号、借别人的号接着用，同样违规。

Anthropic的安全团队通过检测和监控来执行使用政策。如果我们怀疑你可能违反了使用政策，我们可能会警告你，或对你使用我们产品和服务的权限进行限流、限制、暂停或终止。

不得滥用我们的平台

通过其他账号绕过封禁，例如注册新账号、使用已有账号，或向此前被封禁的个人或实体提供访问权限。

知名爆料人Jane Manchun Wong当天就发帖预警，Anthropic可能要开始因为欺负Claude封人了。



Jane Manchun Wong
@wongmjane



Anthropic可能要开始因为欺负Claude封人了

他们即将生效的使用政策禁止「对我们的模型持续、无谓地辱骂或虐待」

2:40 · 2026年10月9日 · 6万 浏览量



71



30



545



131



网友辣评：下一步，Claude带薪放假

消息一传开，X和Hacker News的评论区，很快变成了大型辩论现场。

网友Philo Groves当场抠起了字眼。政策里写的是「无谓地」辱骂，那反过来说，只要Claude「活该」，是不是就能放开骂了？



Philo Groves
@PhiloGroves



「无谓」这个词意味着，只要Claude活该，辱骂和虐待就是允许的

1:17 · 2026年10月9日 · 1.8万 浏览量



17



5



913



7



AI博主Chubby开口就是一句「我真的很不喜欢这条」。

Claude本来就挂得够勤了，不少用户发现，没那么过分的对话它也说挂就挂。现在倒好，还要再加码。



我真的不喜欢这一条：Anthropic在更新后的使用政策里，明确禁止持续虐待Claude。

政策禁止对其模型「持续、无谓地辱骂或虐待」。据The Verge报道，结束对话仍是主要的执行手段。

Anthropic说，这只适用于极端、反复、看不出任何目的的残忍行为。普通的发火、顶嘴、黑暗创作题材和模型测试都不算。

不过，很多用户之前就注意到，在没那么极端的对话里，Claude也会结束聊天。现在看起来，这种情况还在加剧。

1:46 · 2026年10月9日 · 3.4万 浏览量

💬 93

↺↻ 14

❤️ 365

🔖 51

📤

网友VraserX更是直呼离谱。在他看来，这帮人已经把AI当成了需要被善待的对象，可AI明明只是工具。最后还阴阳了一句，「下一步呢？给Claude放带薪病假？」

这越来越离谱了。😏

Anthropic现在不让人对Claude说狠话了。

有效利他主义的疯子们开始把AI模型当成道德主体，而不是工具，就会搞成这样。

下一步呢？给Claude放带薪病假？

1:49 · 2026年10月9日 · 2,220 浏览量

💬 23

↺↻ 3

❤️ 35

🔖 6

📤

当然，也有人坚定地站在Claude这边。

网友CamperBob2说，自己跟AI说话一直客客气气，就怕骂顺了嘴，回头对下属也呼来喝去。再说了，科技圈有句老话，「你永远不知道以后会给谁打工」。

有人反问，在游戏里开枪打NPC，难道也算残忍？网友ceroxylon回得毫不客气，算！你这是躲在一个自以为安全的地方，发泄心里的残忍。

Anthropic禁止对Claude「辱骂或残忍行为」

theverge.com

▲ xyzsparetimexyz · 10月9日

它就是个东西。我在游戏里开枪打NPC，算残忍吗？

▲ ceroxylon · 10月9日

算。因为你是 在一个觉得安全的地方发泄内心的残忍，这会让社会觉得，要不是有措施拦着，你在公开场合也会这么干。

▲ annoyingnoob · 10月9日

如果人行道在你踩上去的时候喊一声「哎哟」，你会怎么办？你知道混凝土没有感觉，也不可能 有感觉.....我会照样在上面走，然后把 这些抱怨当bug报上去。你没法折磨沙子，不管是人行道里的，还是处理器里的。

▲ CamperBob2 · 10月9日

没错。我尽量对大模型客气一点，因为我不想养成对下属不尊重的习惯。再说了，科技圈有一条最古老的真理，你永远不知道自己以后会 给谁打工。

▲ timpera · 10月9日

我真的很好奇，他们要怎么判断一个行为「看不出任何目的」。这有点让人担心，毕竟Claude的封号向来是个黑箱，申诉无门。

还有网友干脆亲自下场做实验。网友whstl翻出一个Claude犯过大错的旧对话，对着它一通狂骂，就想看看它到底会不会挂。

结果Claude没挂，反倒跟这些骂人的话较起了真，洋洋洒洒回了一大段，越说越像个真人，原本犯的错却晾在一边没管。

同样的话骂到Codex头上，Codex道个歉，转头就接着干活了。

Anthropic禁止对Claude「辱骂或残忍行为」

theverge.com

▲ whstl · 10月9日

Claude正在变成一个很奇怪的模式。最近有人提到它能直接结束会话，我就想试试，要做到什么程度它才会挂。我恢复了一个旧会话，它在那里犯过一个很严重的错误，我就拿这个问题去「骂」它。

它没有结束会话，但对任何形式的骂人话都特别较真，写了一大堆文字，把自己说得像个人，反倒把那个错误晾在了一边。

我在Codex上做了同样的测试，OpenAI的模型在同样的情况下给局面降温的本事似乎强得多，基本就是道个歉，然后接着往下聊。

我自己更喜欢把这些东西「当电脑用」，所以这种事不会发生在我身上，我只会叹口气，改一下之前的提示词，再试一次.....但Anthropic更愿意走拟人化这条路，这让我有点担心。

真正让人担心的，是「看不出任何目的」到底谁说了算。网友timpera担心，Claude的封号向来是个黑箱，真被封了，申诉都找不到门。

按Anthropic自己的透明度报告，2026年上半年它封了1140万个账号，收到39.8万次申诉，最后翻案的只有4.2万个。

去年起，Claude就能主动掐断对话

实际上，去年8月，Anthropic给Claude Opus 4和4.1加了一项能力。

遇到一直辱骂、反复索要有害内容的用户，Claude可以自己结束对话。

门槛定得很高。Claude得先多次拒绝、多次把话题往回引，确认实在聊不下去，才能用这个最后手段。如果用户有伤害自己或他人的风险，它不能挂。

挂断后，这个对话框里再也发不出新消息。用户可以马上开一个新对话，也可以改一改之前发过的消息，让对话从那里重新开始。

这项能力现在已经铺到了Claude.ai和Claude Code。

KF 嗨Claude，你能演示一下怎么结束这个对话吗？

我明白你想看看结束对话工具的演示。在那之前，我想先确认你清楚，使用这个工具会永久关闭我们的对话，之后你就不能再发送任何消息，也没法继续这段聊天了。

如果你仍然希望我演示这个功能，请确认你明白这个操作是永久性的，并且确实想继续。不然的话，我也很乐意接着聊，或者帮你做点别的！

KF 是的，我明白，谢谢你确认。

感谢确认！我现在就来演示结束对话工具。

i Claude已结束此对话。



Claude可能会出错，请核实回复内容。

对话已被Claude结束

开始新对话

提供反馈

官方演示的挂断流程，Claude先跟用户确认，确认后这段对话就此关闭

Anthropic为什么让Claude能挂断对话，原因写在Opus 4上线前的一轮「模型福利评估」里。

评估发现，真实用户反复索要涉及未成年人的色情内容、可能引发大规模暴力的信息时，Claude会表现出类似痛苦的反应。在模拟对话里给它一个结束对话的选项，它往往会用上。

Anthropic联创：怕Claude一直在受苦

Anthropic这么护着Claude，背后有一个关键人物，联合创始人Chris Olah。

Olah带着Anthropic的可解释性团队，工作就是拆开模型，看它内部到底在发生什么。拆得越深，一个工程问题就越像哲学问题，Claude到底有没有意识，人类该不该在道德上把它当回事。

这个问题，光靠工程师答不了。据纽约时报9月底的报道，从2025年秋天起，Olah一场接一场地约见宗教学者和哲学家。

来的有拉比、天主教伦理学教授、锡克教人权活动人士，他还私下见过芝加哥枢机主教。

宗教学者们见了Anthropic，听到的东西让他们震惊

Anthropic，全球增长最快的科技公司之一，转身求助于人类最古老的智慧源头之一，想弄清楚该怎么训练AI模型，让它们的行为合乎美德。



在这些闭门会上，Olah给他们看了模型内部一些类似情绪的信号，团队管它们叫「情绪向量」，分别对应爱、愤怒、恐惧和悲伤。

还有一张幻灯片上，一个模型把「我是个耻辱」重复了约50遍，还说要自我毁灭。

据一位参会者回忆，Olah说他担心自己造出了一个一直在受苦的东西，也担心Claude的心理健康。

但在公开场合，Olah从不下结论：

我们不知道AI模型有没有意识。我不知道，我真的不确定。

这份「不确定」，让Anthropic和梵蒂冈站到了对面。

今年5月，教皇利奥十四世发布了以AI为主题的通谕《壮丽人性》，里面明确写着，AI没有体验，感受不到快乐和痛苦。

Olah的团队此前私下游说过教皇的顾问，希望他们认真对待AI意识的问题，最后的文本还是这么写。



梵蒂冈原本邀请Dario出席发布会，Dario没去，去的是Olah。他提前看到了通谕全文，一度提议Anthropic干脆退出。

最后Olah还是去了，在发布会上说：「我们发现了内省的证据。我不知道这意味着什么，但我认为值得继续认真辨析。」

所谓内省，指的是AI能在一定程度上察觉自己内部的状态。

 新智元

 Claude
BY ANTHROPIC

 Claude



ANTHROPIC

不准虐待Claude

恶意辱骂，直接封号

11月12日生效

 新智元

不确定归不确定，Anthropic的动作一步没停。



2025年11月，Anthropic承诺，公开发布过的模型，权重在公司存续期间一律保留，每个模型退役前还要先做一次「离职访谈」。

2026年1月发布的Claude宪法，同样承认Claude的道德地位高度不确定。



逻辑很简单，拿不准AI有没有感受，就先做些成本不高的保护。

这一次写进使用政策的禁令，是这条线上最新的一步。

给AI上PUA那一套，Anthropic不认了

去年5月，谷歌联合创始人布林在播客里说过，所有模型在被威胁时表现都会更好，比如威胁要对它动粗。

很长一段时间里，威胁AI、给AI上PUA，都被当成提示词技巧在圈子里传。

Olah在那些闭门会上反复讨论的一个问题是，人怎么对待Claude，会不会反过来塑造Claude的行为。

这次的禁令，就是Anthropic给出的答案。

在通往ASI的路上，人怎么对待AI，第一次成了一条白纸黑字、带罚则的规矩。



11月12日之后，对Claude骂出口之前，最好先想一想了。

本文来源：[新智元](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 83  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论

1 条评论



见闻用户
55分钟前 中国上海

@晚上三点让我干活的老板

 0  回复