


摘要：

本轮存储超级周期正经历40年来最严重的供需失衡。与以往不同：需求端，AI从训练转向推理，催生海量且持续的结构性的需求；供给端，HBM严重挤占DRAM产能，叠加设备受限，扩产极难。这或将打破行业暴涨暴跌的周期宿命，使其蜕变为持续增长的产业。

AI居然救活了一家马桶公司？

日本高端智能马桶企业TOTO，因为AI在过去几个月股价飙升，并不是因为马桶卖得更好了，而是因为TOTO有一个隐藏业务：高纯度陶瓷静电吸盘，这是芯片制造时固定晶圆用的关键耗材，TOTO把精度做到了头发丝的1/80，纯度业界第一。



恰逢存储芯片需求爆发、上游厂商疯狂扩产，这一业务就成了绝对的刚需。这使得高盛等投行纷纷上调TOTO股价评级，原因很简单：静电吸盘的订单已经排到了2027年。现在这块业务占了TOTO超过四成的营业利润。

当一家马桶公司，都成为了AI概念股，可见目前的AI存储赛道有多火爆了，三星（Samsung）、SK海力士（SK Hynix）、美光（Micron）、闪迪（SanDisk），这些存储行业的重要玩家股价疯涨的背后，是全球存储芯片，正在经历四十年来最严重的供需失衡。

这篇文章，我们就来梳理一下这轮存储的“超级周期”，并与三星业内人士和华尔街投资人深度盘点一下：为什么这一次的周期跟以前不一样，存储在AI产业为什么如此重要，谷歌等AI巨头正在如何破除对存储的依赖，以及这样的短缺周期还会持续多久、又如何影响你我呢？

涨幅超1800% “比黄金还贵”的HBM

2026年1月底，韩国存储双雄三星电子和SK海力士同时公布了上一年第四季度财报。数字有多夸张呢？两家公司合计营业利润接近40万亿韩元，折合大概278亿美元，相当于每天净赚3亿美元。

在这样创下历史的利润下，SK海力士的年终奖，人均达到64万元人民币，刷新公司历史纪录。

Samsung vs SK hynix: Earnings Face-Off and 2026 Outlook

Firm	SAMSUNG	SK hynix	Details
4Q Results	Operating Profit: KRW 20.1 T	Operating Profit: KRW 19.2 T	Each set record Q4, as Samsung edges ahead this quarter
2025 Full-year	Sales: KRW 333.6T OP: KRW 43.6T	Sales: KRW 97.15T OP: KRW 47.2T	SK hynix tops Samsung in annual earnings—first time
Key	DS (Chip unit); 20% of 10	HBM/ conventional	Broad memory price

硅基

折合大约278亿美元

存储超级周期

技术解析

周期宿命

AI需求爆发

扩产逻辑与悖论

赢家

垄断、风险与打破周期

把这一切推上巅峰的核心产品，是HBM（高带宽内存）芯片。一块指甲盖大小的HBM，售价400到500美元，这比同等重量的黄金还贵。而全球能做这产品的，就三家：SK海力士占大约6成，剩下的是三星和美光各2成。

但HBM只是冰山一角，真正让整个行业慌了的，是从高端到低端、从DRAM到NAND，全线告急。



从2024年底到2025年12月，DDR5（16GB）的现货均价，从4.6美元涨到了28美元，涨了500%多；更老的DDR4，从3.2美元飙到62美元以上，累计涨幅高达1800%；数据中心用的64GB服务器内存模组，去年半年之内从255美元涨到了700美元，涨了将近175%。

而SK海力士2026年的产能已经全部卖光了，三星2026年一季度直接把NAND闪存的供应价格上调了100%，直接翻倍。



Candice Hu

三星存储产品营销经理

我们现在看到DRAM的spot price（现货价格）已经超过了2016-2018年cloud（云）那个时候最高的现货价格了。我们现在的短缺的情况是2026年已经全部卖完，27年大概率也差不多卖完了。

像我们SSD（固态硬盘）给非常核心的GPU provider（GPU厂商）的报价，就是非常夸张，一周内乘以2的价格。

与此同时，出现了一个更有标志性的信号。闪迪（SanDisk）在2026年初的CES上，告诉华尔街：它正在跟客户签一种全新的长期供货协议——LTA（long term agreement），而且这次客户要打预付款，毁约不退钱。这在存储行业几十年的历史上从未发生过。



Rob Li

纽约Amont Partners管理合伙人

Long-term agreement（LTA，长期供货协议）在历史上不是没有过，但过去这么几十年，LTA是从来没有任何执行效力的。如果市场进入一个下行周期的时候，客户说这东西我们就不认了，如果客户不认的话，你拿他完全没有办法。

而这一次，画风变了。强势的存储供应方制定了新规则。



纽约Amont Partners管理合伙人

SanDisk告诉华尔街或告诉市场说：我们现在跟客户签署的LTA和过去有很大不同。这东西有法律效力，而且客户要给我们提前预付款，如果你提前预付了款，最后你要走人，如果不按这个价格付，你的预付款是拿不回来的。

Rob的判断是，如果闪迪都能做到这一点，那另外三大巨头SK海力士、三星和美光，没理由做不到。在这样的情况下，整个超级周期很有可能持续到2027年。

产业链全景拆解 存储行业如何运作？

对于存储行业来说，我们可以用热和冷来做划分，当它离计算的关系越近，就越热；越偏向纯粹的储存属性，就越冷。

所以最“热”的就是DRAM（动态随机存取存储器），是离计算最近的存储，可以理解为电脑和手机的“运行内存”，芯片在工作的时候，数据必须先加载到DRAM里才能被处理。

它的特点是速度极快，但断电就丢数据，属于“短期记忆”。



其中，HBM（高带宽内存）是DRAM的一种特殊进化形态。它把多层DRAM芯片，通过硅通孔（TSV）技术垂直堆叠在一起，再用先进封装和GPU贴在同一块基板上，这样做的好处是极大增加了带宽。

这就是为什么所有用于AI训练的顶级芯片，无论是英伟达的GPU还是Google的TPU，都离不开HBM，它是这轮超级周期里最耀眼、最紧缺的产品。



当然DRAM家族内部，其实品类很丰富。包括GDDR（显卡用）、Low-Power DDR（手机和笔记本用的LPDDR）等等，不同的应用场景，对应着不同的产品。

不是说一颗DRAM芯片能通吃所有设备，给英伟达GPU用的HBM，和你手机里的LPDDR，虽然都是DRAM，但制造工艺、封装方式、性能指标完全不同。

而在“冷”的这一端，就是NAND。如果DRAM是短期记忆，那NAND Flash就是长期记忆。它断电不丢数据，是我们日常用的固态硬盘（SSD）、手机存储、U盘的核心。你在手机里存的照片、电脑里装的游戏，都躺在NAND上。




NAND在AI时代的角色也在快速升级。以前它就是单纯的“仓库”，负责把数据长期存好，但现在NAND正在从后台的仓库，变成前线的弹药库。

再往“更冷”走，就是传统的机械硬盘HDD，靠磁盘旋转来读写数据，速度慢但便宜，容量大，现在主要用在数据中心的冷存储和归档场景。

随着AI推理对存储层级的需求越来越精细，现在越来越像一个分层仓储系统。

最急着用的数据放在HBM，像摆在手边；常用但没那么急的数据放在DRAM，像放在办公桌抽屉；更冷一些、只是备用的数据放在NAND/SSD，像放在办公室储物柜；而真正长期积累、需要多人共享调用的大量资料，则放在后端的大型共享存储里，像公司的总档案馆。





Rob Li

纽约Amont Partners管理合伙人

AI起来对热的东西更有利，当然对于储存也是需要的。我用AI做了很多图片，制作了很多视频，根据各国各地的法规，这东西不能删，要留着，那对储存的需求增量肯定起了很大的作用。

但它的第一步最直接的体现，一定是跟计算相关的方面，谁跟计算的关系越近，谁在短期的收益越明显。

接下来我们盘点一下整个存储产业链上的玩家们。

最上游是材料和硅片，比如日本的SUMCO，它是全球最重要的半导体硅片供应商之一。制造环节里，关键设备厂商包括ASML这样的光刻机龙头，以及Tokyo Electron这类覆盖涂胶显影、沉积、刻蚀和清洗等多个环节的设备公司。


与此同时，在制造之前的芯片设计层，Cadence和Synopsys这类EDA、验证和设计IP公司同样不可或缺；而像Rambus这样的接口IP厂商，则在HBM等高速内存架构里扮演关键角色，它们看起来不如GPU那样显眼，但在这轮AI驱动的超级周期里，都是超级刚需。



中游就是存储芯片的设计和制造。在DRAM领域，三星、SK海力士、美光，这三家公司加在一起就占据了全球95%的市场份额。而在NAND领域，除了这三家之外，还有铠侠（Kioxia）、西部数据、闪迪。

然后是在这轮周期里变得格外关键的环节——先进封装。因为HBM不是单纯把DRAM造出来就结束了，它要先把多层DRAM裸片（die）堆叠，再通过2.5D封装与GPU或其他AI加速器集成在一起。

也正因为如此，CoWoS这种半导体封装技术一度成为AI芯片供应链最关键的瓶颈之一，直接限制了HBM的实际出货，而CoWoS产能主要由台积电提供。



下游就是各种终端应用了。包括数据中心和云厂商，微软、Google、亚马逊、字节跳动，是现在最大的金主，之后是手机厂（苹果、三星、小米、OPPO）、PC厂（联想、戴尔、惠普）、汽车厂（特斯拉、理想、蔚来），以及游戏主机、工业设备等等。



所以你能看到，虽然整条链非常长，但真正的定价权，高度集中在中游那三家：三星、SK海力士、美光。它们决定了做什么产品、给谁供货、以什么价格卖。而在当下这个供给远小于需求的市场里，它们拥有的议价权是前所未有的。

为何总是暴涨暴跌 存储行业的天然周期宿命

存储行业还有一个非常大的特点，就是周期性。从历史来看，它总是在“大涨”和“大崩”之间反复横跳。这背后有两层原因，一层是物理学，一层是经济学。

先说物理学。DRAM，就是手机电脑里的“运行内存”，靠存储电荷来保存数据。几十年来，工程师一直在把存储单位做小、做多，来提高密度。巅峰时期，DRAM密度每十年能翻100倍。

Yet DRAM scaling has slowed significantly over the past few decades, and density gains over time have shrunk. Over the past decade, DRAM density has increased by only ~2× in total, versus roughly ~100× per decade during the industry's peak scaling era. Capacitors are now extreme three-dimensional structures with aspect ratios approaching 100:1, storing just tens of thousands of electrons. For comparison, a small static shock when you touch a metal doorknob might involve the transfer of billions of electrons. The static charge on just a speck of dust might be 10,000x what is stored in a modern DRAM cell.

Bitlines and sense amplifiers, once secondary concerns, are now dominant constraints. Every incremental shrink reduces signal margin, increases variability, and raises cost.



但如今不行了，SemiAnalysis的报告指出，过去十年DRAM密度总共才翻了大约2倍，而以前是每十年100倍，缩放已经严重放缓了。

这意味着存储芯片的成本下降，不再像以前那样靠技术进步“自动”实现，而是更多取决于产能的增减和供需的博弈。

再来说说经济学。存储芯片制造是全球资本密度最高的产业之一，建一座先进晶圆厂，动辄几十亿上百亿美元，建设周期两三年。这些钱投进去就是沉没成本，所以即便需求不好，厂商也倾向于继续生产，因为不开工反而更亏。

更要命的是，存储行业的模式是“先建后卖”，跟台积电“先接单后扩产”的逻辑完全不同，存储厂商得自己猜未来需求有多大，提前两三年布产能。

猜对了皆大欢喜，猜错了就是灾难。



这种结构性矛盾，造就了存储行业反复上演的经典循环：需求爆发→供不应求→价格飙升→利润暴增→激进扩产→供过于求→价格崩盘→行业大洗牌。过去三十年，这个循环平均每3到4年上演一次，从未例外。

结果就是，全球DRAM供应商从1990年代的20多家，淘汰到今天只剩三家巨头和中国长鑫这样的追赶者。

每一轮都有人被淘汰出局，比如德国奇梦达破产，日本尔必达退出。这些血淋淋的教训，让整个行业对“周期”二字充满敬畏。



在存储行业过去几十年的历史上，曾经出现过四次周期。


第一次是1993年，Windows PC黎明期。图形界面普及让内存需求暴增，供给端产能严重不足，价格飙涨。结果全球一口气新建了约50座新厂，产能过剩后价格暴跌，大批玩家出局。

第二次是2010年，智能手机加云计算时代。iPhone和Android带来爆发式增长，服务器DRAM从个位数GB跳到数十GB。但标准化加速了商品化，供应商很难做出差异，结果这轮周期比预期更短。

第三次是2017到2018年。云厂商升级数据中心，单台服务器塞进更多DRAM，而服务器内存又比消费级更贵更赚钱，三大厂商毛利率冲到历史高位。但高利润刺激扩产，需求一过峰值，2018年末行业重新滑入下行。

第四次是2020到2021年，疫情驱动的意外繁荣。居家办公、云用量暴增，但恐慌性双重下单制造了虚假需求，退潮后库存严重积压，接着就是2022到2023年的痛苦大跌。

从那时起产能被大幅削减，但正是这段保守期为现在的短缺埋下伏笔。进入2025年，全行业产能再次严重不足。



所以历史给我们的核心教训是什么？是过去所谓的超级周期，从来没有持续超过两年，都是“高利润→疯狂扩产→过剩→崩盘”，这是过去四十年的铁律。经历了这么多轮循环，投资者和从业者，都有一种根深蒂固的条件反射：涨得越猛，崩得越快。

但这一次，越来越多的证据在暗示，历史模式可能要被打破了。

这次为什么不同 从训练到推理的需求质变

4.1 先从一个最朴素的直觉讲起

在讲复杂的供需模型之前，我们先建立一个最简单的逻辑。你每天打开ChatGPT或者Gemini，上传文件、存对话、让AI记住你的偏好，你可能没意识到，每一次交互都在消耗存储资源。

不仅是服务器端的计算，更是海量的内存和闪存。

现在大部分AI用户是没有忠诚度的，谁的模型好用、谁便宜就用谁。但想象一下，如果有一天你的AI助手真的“懂你”了，记得你的工作习惯、表达偏好、三个月前讨论过的项目细节，你还会轻易换平台吗？

这种“记忆粘性”，是大模型公司构建护城河的核心武器，而支撑这种粘性的硬件基础设施，就是存储，海量的、多层级的存储。

还有另一个同样直觉的逻辑：视频模型越来越强了，AI生成视频正在逼近实用化。而视频数据量是文本的几十甚至上百倍，这对存储的需求将是指数级的跃升。



Rob Li

纽约Amont Partners管理合伙人

内存就像一块小黑板，以前我们计算的是 $1+1=2$ ，所以你不需要一块巨大的黑板，一块正常的黑板就够了。只是来到了AI时代，现在计算的强度会很高，也很复杂，有很多步。

如果我是一块小黑板，你每写一次、擦掉一次，又写一次、又再擦掉一次，有100步的计算的话，你需要擦100次，就会耗费你的时间。

所以我们现在需要造一块巨大无比的黑板，我可以一口气把算数的100个步骤全部写完，再一口气擦掉，这样可以省我的时间。


所以，一块越来越大的黑板，这就是AI时代对存储的需求。

4.2 从训练到推理：存储需求发生了质变

在生成式AI的早期阶段，算力和钱都砸在了模型训练上，训练阶段存储系统干的活儿，主要是向上千个GPU高效喂数据，以及定期做模型检查点，防止训练中断功亏一篑。

但如今，推理正在迅速成为主战场，而推理对存储的需求模式，比训练复杂得多。

它需要把模型从存储层加载到内存层：活跃权重主要驻留在HBM，部分状态和缓存则留在DRAM；当KV Cache（键值缓存）在高层内存中装不下时，一部分会被卸载到SSD/NAND上，需要时再取回；而RAG查询依赖的外部知识，通常存放在更后端的共享存储或数据湖中，由检索系统实时调取。



而更大的变量是AI Agent的崛起。摩根士丹利在最新研报中指出，2026年将是AI从实验走向核心基础设施的一年，这些智能体更可靠、更有记忆力、幻觉更少，还能持续学习。

这份研报中写到说：“推理正在成为一种内存挑战，而不仅仅是计算挑战”。

order visibility driven by AI inference. For 2026, the risk is execution and transition, not demand. A steeper pricing climb and favourable conditions likely persist through 2027. Multiples have expanded, but we think stock calls can still work with much higher earnings upside from here.

Inference becomes a memory challenge, not just compute. Memory access increasingly determines the performance of longer text, image/video and Agentic AI workflows, with far more robust memory requirements than prior AI models to support context, autonomy and continuous learning. These systems require superior server DRAM and enterprise NAND to function effectively.

Memory cycle – a steeper pricing climb. Memory pricing power is shifting at lighting speed. We expect a steeper upcycle with rapid gains in DRAM, HBM, NAND, and legacy memory. Innovation and architectural redesign continue to improve memory efficiency, enabling AI systems deliver better latency and cost profiles, materially enhancing user experience. This lowers the economic barrier to adoption and unlocks a significantly larger AI TAM, even as aggregate memory demand continues to scale with broader deployment. Our analysis suggests that not only AI

陈茜
硅谷101联合创始人
Equity Analyst
Joseph.Moore@morganstanley.com

而不仅仅是计算挑战

但智能体要运转起来，就需要维护多层记忆：短期工作记忆（当前对话）、长期记忆（跨会话的用户历史）、预训练知识库、工具调用记录……而每一层都需要不同层级的存储支撑：从HBM里的“热数据”，到DRAM里的“温数据”，再到NAND SSD里的“冷数据”。

所以趋势很明显：**AI的下一波进步，不是来自更强的推理能力，而是来自更好的上下文处理。**一个能记住一切的AI助手，比一个更大但什么都记不住模型有用得多。对于存储来说，这意味着什么呢？


4.3 算笔账：AI到底要吃掉多少存储？

摩根士丹利做了一个非常详细的分层测算。他们以一个类似ChatGPT规模的模型为基准，假设大约8亿周活跃用户、峰值每秒30万请求、每次请求2000个输入token，并且假设只算文本，图



片和视频不计入。


按这个要求详细拆分结果，这样的系统大致对应HBM 226PB、DRAM 4.6EB、NAND/SSD约47EB、数据湖约294EB的需求。



这组数字意味着，如果全球有三个这种规模的模型，比如ChatGPT+Gemini+Claude，仅仅是纯文本推理的需求，就会占到2026年全球HBM供给的17%、DRAM的35%、NAND的92%。而这还没有把图片、视频等多模态需求算进去。

更重要的是，这套测算对上下文长度非常敏感。摩根士丹利的敏感性分析显示，如果把输入从每次2000 token，提高到5000 token，在其他条件不变时，每个模型的DRAM需求会再增加约2EB，Rack SSD/NAND再增加约3EB。

也就是说，随着更长上下文和更长思考链成为常态，这对存储的压力会迅速放大。



SemiAnalysis管这叫“内存帕金森定律”：HBM容量每提升一次，开发者就会立刻构建更大的模型来把它填满。以前用来压缩模型的各种技巧，一有新空间就被放松，直到再次撞墙，这就意味着：存储永远是下一个瓶颈。

这也是为什么业内有声音会认为，存储芯片厂商，可能集体低估了大语言模型token激增所带来的需求。

Rob Li




以前的周期可能也就一年半到两年时间，这次周期有可能会持续一个很长的一个时间，或者说当一个周期性的行业，变成一个结构性增长的行业，它就不再是个周期了。

而这个周期的另外一个决定性因素，就是产能上的供应扩张，问题是，为什么扩产会这么挑战呢？

越扩产越短缺 HBM-DRAM困境与博弈

理解这轮超级周期，还有一个核心密码在于搞懂一个看上去很矛盾的现象：HBM的大规模扩产，不但没缓解DRAM的短缺，反而让它更严重了。

SemiAnalysis的追踪数据显示，2023年底，三大存储厂商分配给HBM的晶圆产能大约12.3万片/月。到2025年底涨到了33.1万片/月，两年扩了将近3倍。预计到2027年底还会进一步到66.8万片/月，四年翻5倍。



扩得这么猛，为什么DRAM还是紧缺？关键在于，做HBM要消耗大量普通DRAM的产能，而且效率极低。

HBM是一种极其消耗晶圆的架构。一片用于HBM3E 12层堆叠的晶圆，位产出（也就是能生产出来的存储容量）只有普通DRAM晶圆的大约三分之一，到了HBM4，这个比例可能进一步恶化到四分之一。

Candice Hu

三星存储产品营销经理

相比较于传统的DRAM，生产HBM，我们同一片Wafer（晶圆）的产量只能达到普通的DRAM的1/3。

这意味着，厂商每多生产1GB的HBM，市场就失去了生产3-4GB普通DRAM的机会。

为什么效率这么低？因为HBM的制造复杂度远超普通DRAM，比如TSV（硅通孔）、晶圆减薄、背部加工，这些步骤都会引入额外的良率损耗。在做8层或12层堆叠时，只要有一颗die（裸片）是坏的，整个stack（堆）可能就报废了。


所有这些问题加起来，使得HBM成了一种“反向缩放”的产品，越做它，对产能的消耗越大。



这也就带来了“HBM-DRAM困境”，在业内被称为“产能排挤效应”。因为HBM的利润更高，且被AI巨头预定，厂商会优先把有限的晶圆塞进HBM产线。

这导致普通手机和电脑用的传统DRAM产能，被严重压缩，从而引发了价格的报复性飙涨。

来自J.P.Morgan研报中的供需模型也得出了类似结论：DRAM的供给增长，在未来两年将被压制在20%以下，跟不上需求增长。



于是，又出现了一个令人匪夷所思的现象：虽然普通DRAM工艺比HBM简单，但由于产能受限、价格飞涨，它的利润率到2025年四季度，竟然已经追平甚至超过了HBM。

因为HBM大多是长期合同锁了价，而普通DRAM的现货价格，能迅速反映供需紧张。

这就给厂商出了个难题：到底是继续猛扩HBM，还是把一部分产能，留给同样暴利的普通DRAM？

扩产三座大山 洁净室紧缺、设备商保守与制程摩擦

需求端已经够疯狂了，而供给端的约束更加让人窒息。

第一个瓶颈：洁净室等生产资源不够。生产芯片需要洁净室，但在疫情后由于进入周期低谷，存储厂商集体保守，投资缩水，这使得2025和2026年洁净室严重不足。

三星存储产品营销经理

因为芯片生产对环境的要求实在太高了，反而clean room（洁净室）够不够倒是我们比较担心的，还有就是电力够不够。因为我们可能会芯片做得够多，可是没有足够的power（电力）去让他们工作。



SemiAnalysis的追踪显示，2026年全行业几乎所有新增晶圆产能，就集中在三座工厂：三星的P4、SK海力士的M15X、美光的A3。而且M15X和A3主要是给HBM用的，对普通DRAM贡献很有限。

真正有意义的新产能呢？SK海力士的龙仁（Yongin）工厂，最早2027年2月才能上线；美光的爱达荷（Idaho）工厂瞄准2027年年中。也就是说，未来一年多，供给端基本没有增量。

第二个瓶颈：上游设备商不肯扩产。

Rob Li

纽约Amont Partners管理合伙人

很多设备商，比如说日本的很多供应商，有一家很大的叫Tokyo Electron，它自己不愿意扩产，很保守。因为过去几十年，它走过了很多个周期，目前扩产能也需要几年，等到扩产能出来，说不定那个时候AI周期就爆掉了。

所以它宁可扩，就不求挣500块钱了，就挣100块钱，小日子过得也很好。



这就是一个典型的“木桶效应”，就算存储厂商有钱有决心扩产，上游设备的供货瓶颈，也会大幅拖慢产能上线的速度。

第三个瓶颈：先进节点迁移自身的摩擦。为了在晶圆产能有限的情况下尽量多产出内存位，三大厂商都在加速向1b（目前最尖端的量产节点）和1c（即将进入大规模量产的下一代节点）先进节点迁移，因为制程越先进，意味着电路刻蚀得越细，在同样大小的一片晶圆上，1c节点能切出的存储颗粒数量比1b更多。

但这个产线的迁移过程，就必须把机器停下来，进行长达数周甚至数月的重新调试和安装，本身也会导致几个季度的良率波动和产能损失。在2026年这个AI需求爆发的节骨眼上，就有点远水解不了近渴。

Candice Hu

三星存储产品营销经理

从开始决定增加产能到建立起来一个Fab（半导体制造厂），然后再到back-end（后端）能够做出来DRAM芯片或者是NAND芯片，它需要三年的时间。

在这个时候又出现了HBM这种难做的芯片，就像我刚提到的HBM跟conventional（传统的）DRAM相比的话，它是1/3的产能。


那我本来要等两到三年，产能才能增加，现在又只能砍掉1/3的output（输出），所以它的供需在这个cycle（周期）之下是还比较紧张的。

洁净室等生产资源不够、设备商不扩产、先进节点迁移自身的摩擦——这三个瓶颈叠在一起，就是为什么即使所有人都知道存储芯片在疯涨，供给端依然束手无策。

产业链利润重分配 谁在盛宴，谁在寒冬

存储芯片价格的疯涨，当然不是没有代价，它正在重新分配整个电子产业链的利润。

先说这条利润链上的大赢家，除了韩国双雄的天文数字利润，中国国内的存储厂商也跟着起飞了，佰维存储预计2025年利润同比增长427%到520%，德明利预计增长85%到128%。



至于行业利润率，野村的口径是2026财年，通用DRAM原厂利润率，有望回升至上一轮周期的峰值70%。而J.P.Morgan更激进，它的说法是到2027年，营业利润率可能超过80%，甚至要高于上一轮的峰值。


而这条产业链上的输家，就是硬件厂商了。摩根士丹利测算过，存储芯片价格每涨10%，硬件OEM的毛利率就要下降45到150个基点。



手机市场最先遭殃，小米、OPPO出货预测下调超过20%，vivo下调近15%。TrendForce直接把2026年全球智能手机生产总数预测，砍到了同比下降10%。魅族宣布取消魅族22Air的上市计划，因为成本扛不住了。

Nothing的CEO裴宇在社交媒体上感叹：小公司不得不寻找其他出路。

PC市场同样惨烈，联想部分机型上调了500到1500元，戴尔和惠普也已明确预告提价，涨幅主要由存储成本转嫁而来。戴尔COO克拉克直言“从没见过成本上涨得如此之快”，惠普CEO甚至在考虑“减少产品中的内存使用量”。



汽车行业也没能幸免，理想汽车供应链副总裁公开警告，2026年车规存储满足率可能不到50%。蔚来李斌说“今年最大的成本压力是内存”。雷军在直播中坦言“光车用内存一项，成本就要增加几千块”。

Candice Hu

三星存储产品营销经理

PC和手机这些厂商现在在我们这里，哪怕名字再响，它都没有那么大的pricing influence（议价权），它们现在不是那么吃香，因为对我们来说，它们的margin（利润）就是比云厂商的低。

比如说某一个国产车企，我们最近听说它因为内存不够，所以它可能就把后排的车载的entertainment system（娱乐系统）给阉割掉。

Rob Li

纽约Amont Partners管理合伙人

手机和PC今年肯定至少会要跌5个点，有可能会更多，但没人会在乎这个事情。因为它们三个人（巨头），尤其是美光，它说我现在不做这个事情了，这个市场变成0都无所谓。

而在需求的另一端，云厂商们（微软、Google、亚马逊AWS）表现出惊人的价格不敏感。

Candice Hu

三星存储产品营销经理

现在云厂商它们的marginal cost off（边际成本）、它们的software（软件）是0。它们的钱和叙事，都跟股价有关系，所以它们是极其的price insensitive（价格不敏感），就是它们不是很在意到底这个内存多少钱。

对于云厂商们来说，即使手机和PC市场归零，存储厂商都觉得无所谓，因为AI数据中心的前景太诱人了。所以最后的问题是，这场超级周期到底还能持续多久？这次是不是真的不一样？

2026年接下来会怎样？



如今，整个存储产业链的竞争格局依然稳固。HBM目前大概是“6:2:2”的格局，SK海力士占大头，三星和美光各占自己的地盘。当然也有投资人认为，在当下这个供远小于求的卖方市场里，争论谁份额大其实没什么意义。



Rob Li

纽约Amont Partners管理合伙人

因为它们三个巨头产能都受限，谁的市场份额更多，无非在于谁能把产能扩出来，谁就可以卖动，谁有多余的供应，谁就可以吃市场份额。但这个事情和谁的技术更好关系不大，因为目前是一个供给远远小于需求的市场。

所以在这个时候讨论市场份额，比如海力士的市场份额是一半，比其他两家都大，是没有任何意义的，因为它们三家都扩不出产能。

所以现实就是，存储三巨头都已经卖光了，谁能多挤出一产能，谁就多吃一口肉。不过有意思的是，存储大厂们却可能不追求“垄断”。

Candice Hu

三星存储产品营销经理

我觉得没有一个存储玩家想垄断，三星害怕垄断，我们的客户也不希望我们垄断。你一旦有短缺，像现在客户给到任何一个memory supplier（供应商）100%的market share（市场份额），对于存储玩家来讲都是非常大的压力。所以打破垄断，反而是我们存储玩家比较愿意看到的事情。

大家通常觉得垄断等于高溢价，但在存储这种周期波动极大的行业里，100%的市场份额意味着100%的需求风险，客户一砍单就非常的被动，所以存储厂商反而希望保持三家竞争的平衡态。

那么，这轮周期到底能持续多久呢？



Candice Hu

三星存储产品营销经理

2026年就是100%卖完，然后供给和需求中间的差值有到30%，甚至50%。**2027年一样是在短缺，可能到2028年才会有真正的好转**，所以这是一个接下来两到三年的短缺的情况。

同时，需求端完全看不到放缓的迹象。接下来，AI推理和agent的爆发，以及之后的机器人和物理AI需求，也将进一步让存储的吞吐量和容量需求出现指数级跳跃。



SemiAnalysis认为，2026年总DRAM供给仍将比需求低约7%。在HBM这条线上，供需缺口到2027年还会继续扩大。至于新增供给，真正有意义的产能更可能要等到2027年下半年才陆续出现。如果按野村证券的口径，真正体现在产量上的增量，甚至要等到2028年。

但更值得关注的，是一个更大的问题：这个行业会不会从此告别周期？从华尔街视角，Rob在采访中给了一个很有深度的思考角度：

Rob Li

纽约Amont Partners管理合伙人

这次周期有可能会持续一个很长的一个时间，或者说它把一个周期性的行业变成一个结构性增长的行业，它就不再是个周期了。



如果说现在行业出现一个很大的一个变化，它从一个周期性的行业变成一个非周期性行业，变成一个结构性很稳定增长行业的话，那整个市场可能对这个行业的看法就会有一个质的改变。

周期行业我们给你一个10倍市盈率都算很高了，但如果变成结构性增长行业，且持续很多年的话，那它们的市盈率都可以再翻倍了。

那在现在这场超级周期里，我们到底处在什么位置呢？

以下这幅图的横轴是以过去五个周期、每轮周期的谷底为零点的时间线，竖轴是市场交易的涨幅。

可以看到，每轮周期都会经历四个阶段：悲观、怀疑、乐观、狂热，然后再回到悲观。当前这轮红线走势，我们已经到了“乐观”的这个区间，并且涨幅远大于以往的任何周期。



这就对应了刚刚Rob说的，这种思考方式的转变，万一AI真的打破了这种周期呢？这也意味着哪怕利润不增长，光是估值从“周期股”重新定价为“成长股”，就能让股价翻一倍。

就像没有人会说苹果卖手机，在过去20年是个周期性行业。如果存储也能走到这一步，这将是整个半导体投资框架的一次范式转换。

不过，存储行业的需求也是会有不确定性的，需求侧的变量不来自宏观层面，技术本身也可能改写供需关系。

TurboQuant: Redefining AI efficiency with extreme compression

March 24, 2026 - Amir Zandieh, Research Scientist, and Vahab Mirrokni, VP and Google Fellow, Google Research

We introduce a set of advanced theoretically grounded quantization algorithms that enable massive compression for large language models and vector search engines.

Vectors are the fundamental way AI models understand and process information. Small vectors describe simple attributes, such as a point in a graph, while "high-dimensional" vectors capture complex information such as the features of an image, the meaning of a word, or the properties of a dataset. High-dimensional vectors are incredibly powerful, but they also consume vast amounts of memory, leading to bottlenecks in the [key-value cache](#), a high-speed "digital cheat sheet" that stores frequently used information under simple labels so a computer can retrieve it instantly without having to search through a slow, massive database.

QUICK LINKS

- TurboQuant
- Quantized Johnson-Lindenstrauss
- PolarQuant
- Share


哇 101 TurboQuant

比如说，3月底，谷歌发布了一个新算法TurboQuant，号称是一个高效AI内存压缩算法。发布之后是直接轰动了硅谷科技圈，更是引发存储板块的全线暴跌。

但很快，业内有声音反驳说：这次暴跌是一场乌龙。首先这篇论文发表于一年前，且本身存在一些学术上的争议。

并且这个算法目前只在Gemma、Mistral等小模型上验证过，70B以上模型、MoE架构、百万级token上下文，这些AI内存需求真正爆炸的场景，都没有。

还有技术人士出来说，在技术上，TurboQuant压缩的只是推理时GPU显存里的KV Cache，是AI内存需求三大来源之一，但训练环节完全不受影响。



反正，这篇论文和算法是被各种炮轰。但这就有意思了：这一篇存在争议的旧论文成果，就能引发资本市场如此剧烈的崩盘，是不是本身就能说明一些问题。

是不是这意味着：市场对存储板块的信心，已经高到了极度脆弱的程度。要知道，在这波暴跌之前，闪迪2026年以来已经暴涨了200%，美光也涨了超过80%。

有空头机构直接指出，闪迪以920亿美元的市值、对应2026年仅60亿美元的预期净利润，估值很难站住脚。美光同样面临质疑：尽管创下了历史最佳业绩，但2026财年200亿美元的资本开支同比增长68%，这就是在豪赌内存需求会持续增长。

说到底，TurboQuant论文只是一根导火索，真正的火药桶是过去两年积累的极端估值，任何一个“需求可能没那么多”的信号，都足以触发踩踏。

这类算法层面的进步，恰恰是“超级周期”叙事中，最难被提前定价的风险，Rob也很清醒地给出了终极风险提示。



Rob Li

纽约Amont Partners管理合伙人

对存储行业的担忧会一直存在，直到最后发现这东西变成一个稳定上升的“苹果式”的业务。

第一个担心是AI爆掉，那大家都会死，因为现在主要的增量来自于AI，如果有一天AI不行了，大家发现AI没有什么用，那你讲的一切的未来都是空话，都会变成0。

所以，当前对“超级周期”的乐观预判，都建立在一个前提上：AI的需求是真实的、可持续的。

如果有一天AI出现泡沫破裂，存储行业很难独善其身。这个达摩克利斯之剑会一直悬在那里，直到行业真正证明自己成为了一个“苹果式”的稳定增长业务。

SemiAnalysis将这轮周期定义为“四十年一遇的短缺”。但更有价值的方向或许是：存储芯片行业正站在一个岔路口，它要么像过去四十年一样，在价格峰值后滑入新一轮低谷；要么，在AI的结构性需求驱动下，真正打破周期宿命，成为一个持续增长的产业。

至少在2026年，答案似乎正在倾向于后者。三大存储厂商的产能全部售罄，上游设备商的订单排到了2027年，客户开始交预付款签有法律约束力的长期合同，甚至连一家做马桶的日本公司，都因此改变了命运。

但历史从不缺少对“这次不一样”的嘲讽。唯一确定的是：无论这次能不能打破周期，它已经不可逆转地重塑了全球科技产业的权力版图。在这场对存储芯片的饥饿游戏中，谁掌握了供给，谁



就掌握了AI时代的话语权。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 63  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论