

摘要：

OpenAI称其自研AI芯片Jalapeno在功耗效率和响应延迟上超越英伟达GB300，专攻推理场景，由Broadcom协助开发。该芯片700瓦低功耗实现高性能，旨在降低算力成本。

OpenAI称其同时具备高吞吐量与低延迟，尤其适合大模型。但OpenAI无意完全替代英伟达，仍将维持多供应商合作。

OpenAI正加速推进AI芯片自研，旗下Jalapeno在关键基准测试中跑赢英伟达GB300，最快将于今年晚些时候投入实际使用。

8月25日，据彭博，OpenAI表示，**Jalapeno在单位功耗可处理的AI工作量和响应速度两项指标上均领先英伟达GB300**。该芯片由OpenAI与Broadcom合作开发，主要用于支撑AI模型推理，有望帮助OpenAI降低对外部芯片供应商的依赖。

与传统芯片往往需要在吞吐量和延迟之间取舍不同，Jalapeno同时具备高吞吐量和低延迟性能。**OpenAI芯片负责人Richard Ho表示，该芯片在700瓦低功耗下即可实现强劲性能，有助于降低数据中心的电力成本。**

不过，OpenAI并未将Jalapeno定位为英伟达芯片的全面替代品。Richard Ho表示，OpenAI对算力的需求极为庞大，未来一段时间仍将与多家供应商合作，英伟达也仍是重要合作伙伴。

与此同时，第二代Jalapeno已进入较成熟阶段，第三代芯片也已启动概念设计，OpenAI正试图通过自研芯片进一步压低AI基础设施成本。

测试表现：两项指标超越英伟达GB300

根据OpenAI使用公开基准测试系统进行的评测，**Jalapeno在功耗效率和响应延迟两个维度均优于英伟达GB300，后者是该测试系统中排名最高的产品。**

Richard Ho在采访中表示，Jalapeno在高吞吐量领域表现突出，意味着能够以更低成本服务更多用户；同时，其低延迟表现同样出色，对于注重响应速度的客户而言，可以显著缩短响应时间。

OpenAI使用旗下一款小型开源模型，以及来自DeepSeek和月之暗面的第三方模型对芯片进行了公开测试。其中，Jalapeno在月之暗面旗下Kimi模型上的优势最为明显，该模型也是测试中规模最大的模型。**内部测试显示，该芯片在运行OpenAI尚未发布的多款大型高阶模型时同样表现良好。**

OpenAI在博客中指出，这表明该芯片的设计“随着工作负载增大和复杂度提升而愈发体现其价值”。值得注意的是，此次测试并未纳入英伟达最新一代芯片Vera Rubin，该产品目前刚刚开始出货。

定位推理阶段，不取代现有供应商

Jalapeno专为AI推理阶段设计，即模型完成训练后响应用户指令、执行任务的阶段，并非用于AI模型训练，而训练领域正是英伟达技术的核心优势所在。

在推理领域，Jalapeno的速度优势使OpenAI得以实现此前只能依赖特殊内存架构才能达到的性能。OpenAI目前部分模型使用Cerebras Systems的技术，但这类芯片更适合规模较小的模型。

Richard Ho表示，Jalapeno能够处理更大规模的模型，从而形成差异化优势。

尽管如此，Richard Ho明确表示，OpenAI短期内不会放弃现有供应商。他表示，公司对算力的需求极为庞大，这也是签约众多不同供应商的原因，这种局面还将持续一段时间。

他同时强调，英伟达仍是重要合作伙伴：“英伟达是非常好的合作伙伴，我们持续需要大量英伟达产品。”

研发提速，第二代已在路上

OpenAI表示，公司借助自身AI模型进一步加速了Jalapeno的研发进程。Jalapeno与Broadcom的合作于去年宣布，两家公司曾在今年6月强调该芯片创纪录的开发速度。

目前，第二代芯片已经推进至较为成熟的阶段。**Richard Ho表示，预计将在“未来几个月”完成流片。与此同时，第三代芯片的概念设计工作也已经启动，目标是进一步压低OpenAI在全球范围内大规模铺设AI基础设施的成本。**

Richard Ho表示，公司已经达到一个能够切实降低基础设施成本的功耗和成本水平，“这只是第一步”。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

303 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

2 条评论



路人
13小时前 中国江苏省

但是人下一代都出来了

0 回复





见闻用户

13小时前 中国辽宁省

这标题写的OPENAI全大写，感觉看着好难受

👍 0 ↩ 回复

