

摘要：

知名分析师郭明錤调查显示，英伟达重启AI推理预填充芯片“Rubin CPX”，预计2027年初量产。新版采用168GB HBM4显存，功耗2300瓦，算力接近标准Rubin GPU。该芯片采用独立模块化机架与分层互联设计，与Rubin GPU按1:1协同部署，专攻预填充与KV Cache生成，以降低长上下文推理成本。

英伟达悄然重启一项一度被市场认为已经放弃的芯片项目，目标直指AI推理成本较高的预填充（Prefill）环节。

知名分析师郭明錤最新产业调查显示，**英伟达已重新启动AI推理预填充加速GPU项目“Rubin CPX”，并对产品设计进行大幅调整。按照目前规划，新版Rubin CPX预计于2027年第一季度开始生产。**

此次项目重启释放出一个明确信号：**英伟达正在加码解决AI推理阶段的预填充性能与成本瓶颈**。随着大模型上下文长度持续增加，预填充阶段需要处理大量输入信息并生成KV Cache，其效率直接影响AI推理的整体成本和部署经济性。

郭明錤称，目前超过50%的AI推理工作负载来自输入上下文处理及KV Cache构建。

芯片规格大幅调整，算力接近标准Rubin

新版Rubin CPX的核心规格较此前方案出现明显变化。

在算力和功耗方面，新版CPX的性能已接近标准Rubin GPU，单卡最高功耗同样达到2300瓦。内存方面，新版CPX改用168GB HBM4显存，较此前方案的128GB GDDR7明显升级，但仍低于标准Rubin GPU的288GB HBM4。

按照郭明錤的说法，8卡CPX计算托盘的HBM4容量合计约1.34TB，能够覆盖大多数长上下文预填充工作负载及对应的KV Cache需求。**这意味着，Rubin CPX并非单纯追求更高的通用算力，而是针对长上下文场景对显存容量和预填充效率进行了重新设计。**

从共享机架转向独立部署，配置更加灵活

机架架构也是此次调整的重点。

此前方案中，CPX计划与Rubin GPU共享机架；**新版则改为采用独立的MGX ETL机架，从而允许客户根据实际需求单独扩展CPX算力。**

具体来看，客户可以选择64、128、192或256张CPX GPU的部署规模。每64张CPX GPU构成一个机架模块，包括8个计算托盘，每个托盘搭载8张CPX GPU，同时配备一个交换机托盘。

模块化设计意味着，客户无需按照固定的大规模Rubin机架进行采购，可以根据预填充负载的实际需求灵活增加CPX算力。

分层互联设计，降低预填充部署成本

在互联架构上，Rubin CPX采用分层设计，在性能与成本之间进行取舍。

在单个计算托盘内部，8张CPX GPU通过NVLink进行Scale-up扩展。每张CPX GPU的NVLink带宽为1至1.5TB/s，低于标准Rubin GPU的3.6TB/s。

在托盘之间以及机架模块内部的Scale-out层面，CPX采用Spectrum-6以太网全铜L1链路；跨机架模块连接时，则通过各模块的Spectrum-6交换机，经OSFP光纤链路完成互联。

相比完全依赖高带宽GPU互联的方案，这种分层架构更强调针对预填充场景进行成本优化。

与Rubin GPU协同，瞄准长上下文推理

Rubin CPX并不是独立运行的通用GPU，而是作为预填充加速器与Vera Rubin NVL72配套使用。

按照郭明錤的说法，英伟达推荐CPX与Rubin GPU按照1:1的比例部署：CPX负责预填充阶段的计算并生成KV Cache，随后通过以太网RDMA将KV Cache传输至Rubin GPU，由后者完成后续解码。

从产品定位来看，Rubin CPX的核心并不是取代标准Rubin GPU，而是将AI推理流程进一步拆分，让不同GPU分别承担预填充和解码任务。

郭明錤将其定位为“长上下文预填充的最佳性价比方案”。随着AI模型上下文窗口不断扩大，预填充阶段的计算量和KV Cache规模持续增长，英伟达此次重启CPX项目，或正是试图通过专用硬件和异构部署方式，进一步降低长上下文推理的成本。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

34 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

