

摘要：

英伟达GTC大会上，黄仁勋将Groq 3 LPU正式纳入Rubin平台，郭明錤随即发布调查报告：2026至2027年LPU出货量预计达400至500万台，较历史年产量暴增10倍。机架密度从64跃至256单元，背后的PCB供应链同步迎来新周期——WUS印制电路或成最大赢家。

英伟达将Groq LPU技术纳入Rubin平台，正在引发一场供应链层面的深刻变革。

在英伟达GTC大会上，CEO黄仁勋宣布推出Nvidia Groq 3 LPU芯片，将其正式纳入Vera Rubin平台体系，作为下一代AI数据中心的核​​心推理加速组件。

知名苹果供应链分析师郭明錤随即发布供应链调查报告，指出在英伟达入股Groq之后，LPU出货量预测已大幅上调，2026至2027年合计出货量预计达400至500万台，较历史年产量实现约10倍以上的数量级增长。

郭明錤认为，这一爆发式增长背后有两大核心驱动力：一是LPU与英伟达CUDA生态的深度整合大幅降低了开发门槛，二是AI代理、实时消费端及物理AI等超低延迟推理场景需求的快速扩张。他同时指出，LPU/LPX机架的规模化量产将对PCB供应链产生重大影响，WUS印制电路（WUS Printed Circuit）有望成为关键受益标的。



郭明錤 (Ming-Chi Kuo) @mingchikuo



Nvidia LPU/LPX racks set for order-of-magnitude growth: application trends, ecosystem integration, and a new PCB cycle

1. My latest supply-chain checks suggest that following Nvidia's investment in Groq, LPU shipment forecasts have moved significantly higher. Total shipments in 2026–2027 are estimated at 4–5 million units (with 30–40% in 2026 and 60–70% in 2027). Relative to historical annual volumes, this implies order-of-magnitude growth, roughly 10x+.

2. Fast-growing LPU demand reflects two key factors:
(1) Deep integration with Nvidia's ecosystem (e.g., CUDA), significantly lowering barriers to application development and deployment.
(2) Rapid expansion of ultra-low-latency inference workloads, including AI agents (such as coding agents) as well as emerging real-time, consumer-facing, and physical-AI applications.

3. Nvidia is expected to increase LPU density per rack from 64 to 256 units. This helps preserve ultra-low latency during the decode stage of inference while accommodating expanding KV-cache requirements driven by long-context inference. The new rack architecture is expected to enter mass production in 4Q26–1Q27, with rack shipments projected at 300–500 units in 2026 and 15,000–20,000 units in 2027.

黄仁勋GTC发布：LPU正式成为Rubin平台第七块基石

在本届GTC主题演讲中，黄仁勋披露了英伟达如何将去年收购Groq所获得的IP技术融入Rubin平台。Nvidia Groq 3 LPU作为一款推理加速芯片，成为Rubin平台继Rubin GPU、Vera CPU、



NVLink 6扩展交换机、ConnectX 9智能网卡、Bluefield 4数据处理单元以及Spectrum-X扩展交换机之后的第七个核心构建模块。

从技术架构看，Groq 3 LPU与主流AI加速器的差异化路线鲜明。大多数AI加速器依赖HBM作为工作内存，而每颗Groq 3 LPU内置500MB SRAM——与CPU和GPU超高速缓存所用内存类型相同。尽管这一容量远低于Rubin GPU所配备的288GB HBM4，但其带宽高达150TB/s，远超后者22TB/s的HBM带宽。

对于对带宽高度敏感的AI解码操作而言，Groq 3的超高带宽在推理应用场景中具有显著优势，尤其适用于需要大批量、低延迟、高交互性输出的前沿AI模型部署。

供应链调查：2026至2027年出货量预计达400至500万台

据郭明錤最新供应链调查，英伟达入股Groq后，LPU出货量预测已出现实质性上调。**他预计2026至2027年LPU总出货量为400至500万台，其中2026年占30%至40%，2027年占60%至70%。与历史年产量相比，这一规模意味着约10倍以上的数量级跃升。**

在机架层面，英伟达计划将每机架LPU密度从64个单元提升至256个单元，以在推理解码阶段维持超低延迟，同时应对长上下文推理所带来的KV缓存需求扩张。

郭明錤预计，新机架架构将于2026年第四季度至2027年第一季度进入大规模量产，机架出货量预计从2026年的300至500台跃升至2027年的15,000至20,000台。

生态整合是关键：三大技术节点决定落地速度

郭明錤指出，LPU需求的快速增长，根本上源于其与英伟达生态系统的深度绑定。与英伟达CUDA的整合显著降低了应用开发与部署门槛，使开发者无需重构现有工作流即可调用LPU算力。与此同时，AI代理（如编程代理）、实时消费端应用及物理AI等超低延迟推理场景的快速扩张，进一步拉动了LPU的需求曲线。

他同时列出三个需要重点跟踪的技术整合节点：其一，网络架构层面，机架级互连能否通过NVLink Fusion和RealScale实现顺畅对接；其二，开发者接口层面，Nvidia NIM是否能让开发者在无需区分GPU与LPU的情况下直接部署工作负载；其三，编译器层面，TensorRT-LLM能否支持LPU的“先编译”架构。郭明錤认为，上述三项整合的推进节奏，将直接决定LPU规模化落地的速度与深度。

PCB供应链迎来新周期：WUS印制电路或成核心受益方

郭明錤特别强调，LPU/LPX机架的规模化量产对PCB供应链具有重大意义。他指出，LPU/LPX机架代表了M9级CCL（覆铜板）材料的首次大规模商业部署，而WUS印制电路在这一供应链中扮演关键角色。

M9级CCL材料对制造工艺要求极高，涉及石英玻璃织物处理高层数板的技术突破。郭明錤认为，若LPU/LPX机架顺利放量，不仅将对WUS 2027年业绩产生实质性贡献，更将验证该公司在上述高端制造领域的技术能力，进而可能催化整个PCB行业开启新一轮增长周期。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时0元领

* 同一用户免费领取一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

125 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论