

摘要：

AI算力竞赛的焦点正悄然转移：随着智能体AI爆发，CPU从数据中心配角升级为关键瓶颈。CPU与GPU配比预计从1:8骤收至1:1，算力需求四倍激增。Intel、AMD提价应对短缺，英伟达、Arm同月宣布强势入局，竞争格局加速重写。

AI算力竞赛的焦点，正在悄然从GPU转向一个长期被忽视的角色——CPU。

随着AI智能体和强化学习（RL）工作负载的爆发式增长，CPU在数据中心的战略地位正经历结构性重估。[知名半导体分析机构SemiAnalysis首席分析师Dylan Patel在4月8日的一次深度访谈中直言](#)，AI工作负载的范式正从简单的文本生成向复杂的智能体和强化学习演进，CPU正面临“极其严重的产能短缺”。

市场研究机构TrendForce的最新报告印证了这一判断：当前AI数据中心的CPU与GPU配比约为1:4至1:8，而在智能体AI时代，这一比例预计将演变至1:1至1:2。

CPU vs. GPU Key Comparison

	CPU	GPU
Computing Principle	Complex logic and sequential processing	Simple parallel computing
Core Count	Low (tens to hundreds)	High (thousands to tens of thousands)
Memory Type	DRAM	HBM
AI Application	Data preprocessing, task scheduling	AI model computation
Vendors	Intel, AMD, Ampere (SoftBank)	Nvidia, AMD, Intel

Source: TrendForce, April 2026



这一结构性转变已在供需两端引发连锁反应。Intel和AMD已于2026年第一季度末对部分CPU产品线提价。与此同时，英伟达和Arm双双于2026年3月宣布进军服务器CPU市场——一家GPU巨头与一家IP授权商在同一个月做出相同选择，绝非巧合，而是市场信号的集中释放。

智能体崛起，CPU从配角变瓶颈


在AI发展的早期阶段，CPU的角色相当边缘。Dylan Patel将其描述为：“负载很轻。你发一个字符串，它回一个字符串，简单的推理，对CPU需求不大。”彼时，GPU凭借其大规模并行矩阵运算能力主导了AI算力需求，CPU仅承担向GPU压缩和路由内存数据的辅助职能。

然而，以OpenAI o1为代表的新一代推理模型，以及随之兴起的AI智能体架构，从根本上改变了这一格局。与静态大语言模型不同，智能体AI需要动态与环境交互——规划任务、调用工具、在子智能体之间传递数据、评估任务是否完成。这一“编排层”（Orchestration）的全部协调工作，恰恰落在CPU肩上，使其成为典型的CPU密集型负载。

2025年11月发布的学术论文《A CPU-Centric Perspective on Agentic AI》进一步量化了这一压力：在智能体AI场景中，CPU工具处理（包括Python解释、网页爬取、词法摘要、数据库检索等）产生的延迟，可占总延迟的高达90.6%；在大批量处理场景下，CPU动态能耗可达系统总动态能耗的44%。

Arm的测算则从容量角度揭示了需求缺口的量级：传统AI数据中心每吉瓦（GW）约需3000万颗CPU核心，而在智能体AI时代，这一需求将激增至1.2亿颗——增幅达四倍。

CPU:GPU Ratio Shift in Agentic AI Applications



Source: TrendForce, April 2026



Intel承压，AMD乘势扩张

CPU需求的结构性上升，首先在传统x86市场引发了格局重塑。

Intel的Xeon处理器曾长期占据数据中心CPU市场逾95%的份额。这一统治地位自2021年起开始松动——Intel 7制程的良率问题导致Xeon Sapphire Rapids发布延迟近两年，为AMD的EPYC Milan打开了市场缺口。

2026年，Intel计划推出两款旗舰产品：采用Darkmont架构的Xeon 6+（Clearwater Forest），拥有288核/288线程，TDP约450W；以及采用Panther Cove-X架构的Xeon 7（Diamond Rapids），最高256核/256线程，TDP高达650W。两款产品均基于Intel最先进的18A制程，并首次引入Foveros Direct混合键合技术。然而，TrendForce指出，受18A制程良率问题持续困扰，两款产品的量产时间均可能推迟至2027年。

相比之下，AMD的节奏更为稳健。其2026年旗舰产品EPYC Venice将采用台积电N2制程、Zen 6架构，并搭载CoWoS-L与SoIC先进封装，通过同步多线程（SMT）技术实现256核/512线程——线程数为当前市场最高。**TrendForce预计，AMD将在2026年持续从Intel手中蚕食市场份额。**


英伟达、Arm强势入局，竞争格局重写

传统x86双雄之外，一批非传统玩家正以前所未有的速度涌入服务器CPU赛道，从根本上改写竞争格局。

2026年3月，英伟达宣布将Vera CPU作为独立产品对外销售，以满足客户对更灵活CPU:GPU配置的需求。Vera采用英伟达自研Olympus架构，基于台积电N3制程与CoWoS-R封装，提供88核/176线程，并配备1.8 TB/s的NVLink-C2C互联，可与英伟达GPU实现内存共享。首批合作伙伴涵盖Alibaba、ByteDance、Cloudflare、CoreWeave、Oracle等。英伟达还推出了Vera CPU机架，单机架集成256颗CPU，合计22,528核/45,056线程，总内存达400 TB。



NVIDIA Vera CPU



来源：英伟达

同月，Arm宣布推出首款自研CPU产品Arm AGI CPU，终结了其35年纯授权商的历史定位。该产品基于台积电N3制程与Neoverse V3架构，提供136核/136线程，TDP为300W，支持DDR5-8800内存与PCIe Gen6。首批合作伙伴包括Meta、OpenAI、Cerebras、Cloudflare、SK Telecom等。Arm同步推出两款机架配置：风冷版集成60颗AGI CPU（8,160核，约180 TB内存），液冷版则支持336颗CPU（45,696核，1 PB内存）。

主要云服务商（CSP）同样加速布局自研CPU。AWS于2025年12月发布基于台积电N3制程的Graviton5（192核/192线程），并与自研Trainium 3 AI ASIC协同部署以降低AI计算成本；微软于2025年11月推出Cobalt 200（N3制程，132核/132线程）；谷歌则计划于2026年推出Axion C4A.metal裸金属版本及下一代Axion N4A，主打最高性价比。

IC后端设计服务商迎来增量机遇

非传统玩家的大规模入场，正在为IC后端设计服务商创造可观的增量业务。

TrendForce指出，AWS目前仍坚持自主完成CPU后端设计，而谷歌和微软均已将CPU后端设计服务外包给创意电子（Global Unichip Corp.，GUC）。随着更多CSP和新兴CPU厂商加入市场，这一外包需求有望持续扩大。

TrendForce预计，2026年至2028年间，Broadcom、Marvell、GUC、Alchip、联发科等ASIC设计服务商将陆续承接来自上述客户的新增项目。对于寻找AI基础设施投资新切口的市场参与者而言，这一环节或许正是GPU热潮之外，尚未被充分定价的结构性机遇。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

412 收藏

分享到:  

写评论

请发表您的评论

1 条评论



lijingjing

1小时前 中国江苏省

AI 服务器 CPU/GPU 配比从 1:8 转向 1:1，CPU 从边缘调度变核心算力，互联成 IA 新瓶颈。

这一结构性变化，最直接、最刚性受益的就是澜起科技：

CPU 数量翻倍 → DDR5 内存接口芯片用量暴增，澜起全球垄断；

CPU-GPU 对等协同 → PCIe 5.0/6.0 Retimer量价齐升；

内存池化刚露 → CXL 互联芯片从 0 到 1，打开新增长曲线。

展开全部

 0  回复