

摘要：

黄仁勋在GTC26抛出震撼弹：英伟达订单可见性已突破1万亿美元，增长仍在加速。他断言AI已进入第三拐点——智能体时代，“每个工程师将管理100个智能体”；Token将成新型工资，不消耗Token的工程师形同荒废生产力。50万亿美元物理AI蓝海，正等待引爆。

在刚结束的 GTC26 期间，英伟达（NVIDIA）CEO 黄仁勋通过一场深度访谈与财务问答，向外界展示了这家市值巅峰企业的宏大蓝图。从“1万亿美元订单可见性”到“智能体（Agent）就是未来的个人电脑”，老黄不仅在卖芯片，更在重塑全球IT产业的分配逻辑。

华尔街见闻整理金句如下：

关于 Token 与价值：如果你的一名年薪50万美元的工程师，一年只花5000美元买Token，我会发疯的。如果那名50万美元的工程师没有消耗至少价值25万美元的 Token，我会深感不安。即使芯片是免费的，如果它不能跟上技术状态和我们运行的速度，它也依然不够便宜。

关于智能体与未来：每个工程师都将拥有100个智能体。在过去我们编写代码，在未来我们将编写想法、架构和规范。智能体系统是完成工作的系统，它们正在帮助我们的软件工程师完成工作。

关于Token经济学：计算机过去只是工具，未来的计算机是制造设备。人们购买这些计算机是为了生产Token，生产这些Token的有效性至关重要。你同时购买了最昂贵的计算机，并生产了成本最低的 Token。

关于市场需求与增长：我们对Blackwell加Reuben的需求、**订单和需求有超过1万亿美元的强劲可见性**。我们的增长率实际上正在加速。每一个软件公司、每一个公司都需要有一个OpenClaw策略。

关于竞争与架构：任何说‘我的芯片便宜 30%’的人，只是证明了他们不懂 AI。你只要呼吸空气，直到呼吸完为止。在那之后，我们将呼吸压缩液态空气，但在此之前，空气怎么样？它是免费的，我们已经用了很久了。”（注：此处指代对铜缆/电缆技术的使用极限）

财务核弹：1万亿美元的订单墙

黄仁勋在分析师会议上抛出了一个震撼数字：**英伟达对 Blackwell 和 Reuben 架构的订单需求可见性已超过 1 万亿美元。**

- 。 **增长背后的逻辑：** 这一数字并非虚标，而是基于确定的采购订单和工厂建设流水线。老黄强调，英伟达的优势在于其交付周期远快于自研 ASIC 芯片的公司，甚至能实现“同季度下单、同季度出货”。
- 。 **毛利护城河：** 面对“价值被英伟达抽走”的质疑，老黄直言：“TSMC 的晶圆全球最贵，但价值最高，所以我乐意付钱。”他认为，客户买的不是昂贵的电脑，而是**全球成本最低的 Token 生产力**。

第三次拐点：从大模型到“智能体”

黄仁勋认为，AI 已经历了生成式、推理两个阶段，现在正处于第三个拐点——**智能体系统（Agentic Systems）**。

- **Token 成为新工资：** 未来企业雇佣工程师，发的不只是笔记本电脑，还有 **Token 预算**。如果一个年薪 30 万美元的工程师不消耗 Token，那他就是在荒废生产力。
- **个人 AI 电脑的诞生：** 以开源项目 OpenClaw 为代表的系统，被老黄定义为“人类历史上第一台个人人工智能计算机”。它拥有内存、调度、技能和 API，是未来 IT 产业的操作系统。

硬件新版图：Vera Rubin 与 Groq 的“联姻”

英伟达不再只是一家 GPU 公司，而是一家“AI 工厂”公司。

- **解耦推理（Disaggregated Inference）：** 这是 Dynamo 操作系统的核心。通过将推理任务拆解，不同性能的芯片各司其职。
- **Groq 的角色：** 英伟达收购并整合 Groq（LPX 系列）并非为了取代 GPU，而是利用其极低延迟的 SRAM 架构处理自回归推理的“最后一步”。
- **三位一体架构：** 英伟达是全球唯一能同时优化 **HBM（高带宽显存）、LPDDR5 和 SRAM** 的公司，这种“液冷机架化”的整机交付，让竞争对手的单点芯片显得像个“缝合怪”。

物理 AI：50 万亿美元的蓝海

老黄特别看好**物理 AI（Physical AI）**，认为其最终规模将超过数字 AI。

- **重塑传统工业：** 这是一个产值 50 万亿美元、过去 20 年几乎是科技荒漠的领域。从机器人手术、自动驾驶到智能基站，物理 AI 需要在边缘侧遵守物理定律。
- **3-5 年内的机器人爆发：** 黄仁勋预言，未来 3 到 5 年机器人将随处可见。虽然中国在电机、稀土等硬件供应链上极具优势，但英伟达将提供大脑（训练、仿真、车载三台计算机）。

行业共生：英伟达是云服务商的“最佳销售”

针对云巨头自研芯片的威胁，老黄表现得极其自信：

- **流量带货：** “AWS、谷歌、微软在 GTC 展位最大，是因为他们要向我的 CUDA 开发者推销服务。”英伟达通过 CUDA 生态将开发者引向云端，本质上是云服务商的获客引擎。
- **不可替代性：** 40% 的业务来自于非云巨头领域（区域云、企业私有云），这些客户买的是“全栈平台”而非“芯片”。如果没有英伟达的整机方案，这些市场根本无法触达。

以下为两场访谈的全文，由AI辅助翻译：



《All-In Podcast》访谈

主持人 (Jason Calacanis):

本周是特别节目，我们破例推迟了常规节目。通常我们只为三个人破例：特朗普总统、耶稣和黄仁勋。你可以自己排个序。Jensen，你这一年的表现太惊人了，这次活动也非常棒，每个行业、每家科技公司、每家 AI 公司都在这里。

主持人 (Chamath Palihapitiya):

去年最重大的宣布之一就是英伟达收购了 Groq。当你决定买下 Groq 时，你有没有意识到 Chamath 会变得多么难以忍受？

黄仁勋 (Jensen Huang):

我有这种预感（笑）。我们是他的朋友，每周都要应付他，我知道在结案的那六周里你得怎么对付他。

黄仁勋 (Jensen Huang):

实际上，我们的许多战略早在 GTC（英伟达 GPU 技术大会）上就已经公开展示了。两年半前，我介绍了 AI 工厂的操作系统，叫做 **Dynamo**。正如你们所知，Dynamo 是西门子发明的，目的是把水能转化为电能，它驱动了上一次工业革命。我觉得这是下一次工业革命“工厂操作系统”的完美名字。

在 Dynamo 内部，核心技术是 **解耦推理（Disaggregated Inference）**。Jason，我知道你技术很强，我让你来向观众解释一下。

主持人 (Jason Calacanis):

谢谢你没直接抢过话头。解耦推理意味着推理的处理流水线极其复杂，它是当今最复杂的计算问题。规模庞大，涉及各种形状和大小的数学运算。我们的想法是把处理过程拆解开，让一部分在某些 GPU 上运行，其余部分在不同的 GPU 上运行。这让我们意识到，甚至解耦计算也是有意义的。

这种思路引导我们收购了 Mellanox。如今，英伟达的计算分布在 GPU、CPU、交换机和网络处理器中。现在我们加入了 Groq，我们将把合适的工作负载放在合适的芯片上。我们已经从一家 GPU 公司演变成了一家 AI 工厂公司。

主持人 (Chamath Palihapitiya):

你在台上提到，高价值推理用户应该关注这一点。你说数据中心 25% 的空间应该分配给这种 Groq LPU 和 GPU 的组合。你能告诉我们，行业如何看待这种“预填充-解码解耦”的新型计算形式吗？

黄仁勋 (Jensen Huang):

退一步看，当我们加入这项技术时，我们正从“大语言模型处理”转向 **“智能体处理（Agentic Processing）”**。当你运行一个智能体时，你会访问工作内存、长期内存、使用工具，并对存储产生巨大的压力。智能体之间还会相互协作。

因此，数据中心内存在各种类型的模型。我们创建了 Vera Rubin 架构来处理这些极其多样化的负载。英伟达的潜在市场规模（TAM）因此增加了 33% 到 50%。其中很大一部分将是存储处理



器（BlueField）、Groq 处理器、CPU 和网络处理器。这些共同构成了 AI 革命的电脑，也就是“智能体”。

主持人 (David Friedberg):

那嵌入式应用呢？比如我女儿在家里的泰迪熊想要和她聊天。里面装的是定制芯片，还是会有一套更广泛的、针对边缘侧开发的工具？

黄仁勋 (Jensen Huang):

在大规模层面上，我们认为这个问题涉及三台计算机：

- 第一台用于 **训练 AI 模型**。
- 第二台用于 **评估**。比如机器人和自动驾驶汽车，必须在符合物理定律的虚拟实验室（Omniverse）中进行评估。
- 第三台是 **边缘侧的机器人计算机**。它可能是一辆车、一个机器人，或者是一只小泰迪熊。我们还在做一件非常重要的事：将电信基站转化为 AI 基础设施的一部分。这是一个 2 万亿美元产业，未来无线电基站、工厂、仓库都将成为 AI 的延伸。

主持人 (Brad Gerstner):

Jensen，去年你领先全球预言“推理不会只增长 1000 倍”。现在它是要增长 100 万倍还是 10 亿倍？当时人们觉得你太夸张了，因为大家都在关注训练。但现在推理需求爆炸了。

有人说你的推理工厂成本高达 400-500 亿美元，而定制芯片（ASIC）方案只要 250-300 亿，你会因此失去市场份额。你对此怎么看？为什么大家要付双倍的溢价？

黄仁勋 (Jensen Huang):

核心逻辑是：你不应该把“工厂的价格”等同于“Token 的成本”。我可以证明，一座 500 亿美元的工厂能为你产生 **成本最低的 Token**。

因为我们的效率高出 10 倍。在 500 亿的预算中，有 200 亿是土地、电力和厂房，无论用什么芯片这些钱都要花。剩下的差额在整体成本中占比并不大。但如果我的数据中心吞吐量是别人的 10 倍，那么即便别人的芯片是免费的，他们也拼不过我们。

主持人 (Chamath Palihapitiya):

你管理着全球市值最高的公司，明年营收可能超过 3500 亿美元。你是如何决定“该做什么”的？你如何获得直觉，知道在哪里加倍下注，在哪里撤退？

黄仁勋 (Jensen Huang):

这就是 CEO 的工作：定义愿景和战略。我会被公司里优秀的科学家和技术专家启发，但我必须塑造未来。

我的标准是：这件事是不是 **难到令人发指**？如果很容易，我们就应该退缩，因为容易的事竞争对手会很多。我寻找的是那些从未被实现过、极其困难、且能发挥英伟达“超能力”的事。我们知道这会带来痛苦和磨难，但如果没有痛苦，也就没有伟大的发明。

主持人 (Brad Gerstner):



你能谈谈几个长线业务吗？比如空间数据中心、自动驾驶或是数字生物学？

黄仁勋 (Jensen Huang):

物理 AI 是一个巨大的类别。这是一个产值 50 万亿美元的产业，直到现在几乎还是科技的荒漠。我们 10 年前就开始布局，现在它正处于爆发点，每年为我们带来近 100 亿美元的收入。

数字生物学 正在迎来它的“ChatGPT 时刻”。我们正开始理解如何表示基因、蛋白质和细胞。在未来 5 年内，医疗行业将发生巨变。农业也是如此。

主持人 (Jason Calacanis):

英伟达最初是靠游戏玩家和发烧友起家的。你提到了“智能体”的革命，特别是开源智能体在桌面端的应用。这对于你来说意味着什么？

黄仁勋 (Jensen Huang):

过去两年有三个转折点：

- **生成式 AI**：ChatGPT 让所有人意识到了 AI 的存在。
- **推理 (Reasoning)**：像 O1 这样的模型让 AI 不仅能回答问题，还能进行推理。
- **智能体 (Agents)**：最初是像 Claude Code 这样的企业工具，而 **OpenClaw** 将 AI 智能体带入了大众视野。

OpenClaw 之所以重要，是因为它重新定义了计算模型。它有内存、文件系统、技能 (Skills)、资源调度和 API。这本质上就是人类历史上第一台 **个人人工智能计算机**。它是开源的，可以在任何地方运行。

主持人 (Brad Gerstner):

这种范式转移是否让现在的 AI 监管立法变得毫无意义？政治家们该如何应对这种快速变化？

黄仁勋 (Jensen Huang):

我们需要站在决策者面前，告知他们技术的真相：它不是生物，不是外星人，没有意识，它只是计算机软件。

我们不能让“末日论”影响政策。作为国家，最大的安全风险不是 AI 本身，而是当我们因为恐惧而停滞不前时，其他国家却在采用这项技术。我担心的是 AI 在美国的普及速度。

主持人 (Brad Gerstner):

关于 Anthropic 之前与国防部的风波，如果你是董事会成员，你会给他们什么建议来改变公众的恐惧感？

黄仁勋 (Jensen Huang):

Anthropic 的技术非常出色，我们也是他们的大客户。警示技术的潜力是好事，但“警示”不等于“恐吓”。

我们作为技术领袖，说话必须更加谨慎和谦虚。在没有任何证据的情况下散布“毁灭性”的言论，其伤害比人们想象的要大。现在技术对社会结构和国家安全如此重要，我们的言辞至关重要。



主持人 (Brad Gerstner):

美国公众对 AI 的支持率只有 17%。我们曾因为恐惧毁掉了核能产业，现在中国在建 100 座核反应堆，我们是零。

回到智能体，英伟达内部的生产力提升如何？大家都在讨论投资回报率（ROI）。你认为我们会看到营收像智能一样呈指数级增长吗？

黄仁勋 (Jensen Huang):

看这个会场的观众就知道了，99% 的东西都是 AI。从生成式到推理，计算量增加了 100 倍；从推理到智能体，计算量又增加了 100 倍。两年内计算量翻了 1 万倍。

人们会为“信息”付费，但更愿意为“工作”付费。聊天机器人很好，但能帮我完成工作的智能体才真正值钱。智能体正在帮我们的工程师完成工作。我们现在还没到真正的大规模阶段，未来的增长将是百万倍级的。

主持人 (Jason Calacanis):

英伟达有 4.3 万名员工，其中 3.8 万是工程师。如果你的一名年薪 50 万美元的工程师，一年只花 5000 美元买 Token，你会怎么想？

黄仁勋 (Jensen Huang):

我会发疯的！如果一个 50 万美元年薪的工程师一年不消耗至少 25 万美元的 Token，我会非常担心。

这就像一个芯片设计师说他只要纸和笔，不需要 CAD 工具一样。这是一种范式转移，就像勒布朗·詹姆斯每年花 100 万美元保养身体一样。我们要给知识工作者“超能力”。

主持人 (Jason Calacanis):

未来两三年，这种“全明星”员工的工作效率会变成什么样？

黄仁勋 (Jensen Huang):

那些“这太难了”、“这需要太长时间”的想法将不复存在。就像工业革命后，没人会说“那个建筑太重了”一样。重力和规模不再是问题，剩下的只有 **创造力**。

过去我们编写代码，未来我们编写“想法”、架构和规范。每个工程师未来都将管理 100 个智能体。

主持人 (David Friedberg):

我上周日晚上花了 90 分钟用智能体替换了一整套软件架构，原本这需要很多人手。这种加速感是前所未有的。

黄仁勋 (Jensen Huang):

这就是为什么 OpenClaw 如此不可思议。一些人认为企业软件行业会被摧毁，但我的观点相反：这个行业过去受限于“办公位上的员工人数”。未来将有 100 倍数量的智能体去敲击 SQL 数据库、Photoshop 和 Blender。这些工具是人类控制结果的最后途径。



主持人 (Chamath Palihapitiya):

关于开源，中国的一些开源模型非常强大。你认为 AI 的终局是去中心化的吗？

黄仁勋 (Jensen Huang):

我们需要“模型即产品（私有）”和“模型即开源”并存。对于大多数消费者，我不想自己微调模型，我会用 ChatGPT 或 Claude。但对于垂直行业，他们需要控制自己的领域知识，这必须依靠开源模型。英伟达也在大力支持开源生态，因为这能让初创公司在第一天就拥有世界级的垂直能力。

主持人 (Brad Gerstner):

特朗普总统希望美国工业领先，希望美国 AI 走向世界。目前英伟达在某些市场（如中国）的市场份额从 95% 跌到了 0%。现在情况如何？

黄仁勋 (Jensen Huang):

特朗普总统希望我们重返战场。我们已经为许多请求采购的中国公司申请了许可证，并得到了批准。我们正在重启供应链进行发货。

如果美国不能主导 AI 技术的堆栈（从芯片到系统），那是国家安全的重大损失。我希望美国的计算堆栈占据全球 90% 的份额。

主持人 (Jason Calacanis):

全球冲突、台湾局势、甚至中东的氦气供应，这些供应链风险让你担心吗？

黄仁勋 (Jensen Huang):

在中东，我们有 6000 个家庭在那里，我们 100% 支持他们，100% 留在以色列。关于台湾，我们要做的有三点：

- 尽可能快地实现美国本土工业化（如亚利桑那州的工厂）。
- 实现供应链多元化（韩国、日本、欧洲）。
- 保持耐心和克制。

主持人 (Jason Calacanis):

自动驾驶方面，你的策略是像 Android 那样的开源平台，而特斯拉更像 iOS。你如何看待这个棋局？

黄仁勋 (Jensen Huang):

我们的目标是让世界上每一家汽车公司都能制造自动驾驶汽车。我们提供三台计算机（训练、仿真、车载），并开发了最安全的操作系统。即便像马斯克和特斯拉这样拥有强大自研能力的客户，也会买我们的训练计算机。我们乐于提供任何层面的解决方案，我们不是来取代谁，而是来解决问题的。

主持人 (Brad Gerstner):



但像谷歌、亚马逊这些大客户也在自研芯片（TPU、Trainium）。他们既是客户也是竞争对手，你如何应对？

黄仁勋 (Jensen Huang):

我们是世界上唯一一家与每一家 AI 公司都合作的 AI 公司。我不看他们研发什么，但我向他们展示我研发的一切。

信心来自于两点：

- 购买英伟达的产品仍然是目前最经济的选择。
- 我们是唯一的跨平台架构（云端、本地、车载、甚至空间）。很多人没意识到，英伟达 40% 的业务来自于构建完整的 AI 基础设施，而不只是卖芯片。事实上，英伟达的市场份额正在增加，因为 Anthropic、Meta 都在用英伟达，开源模型的爆发也在英伟达之上。

主持人 (Brad Gerstner):

分析师们似乎不相信你的增长潜力。他们预测你明年增长 30%，后年 20%，2029 年只有 7%。他们觉得“大数法则”会限制你。

黄仁勋 (Jensen Huang):

他们只是不理解 AI 的规模和广度。过去数据中心的 CPU 市场一年只有 250 亿美元，而我们现在的体量已经完全不同了。英伟达做的不是芯片，而是 AI 基础设施，这个市场比人们想象的要大得多。

主持人 (Chamath Palihapitiya):

谈谈空间数据中心？

黄仁勋 (Jensen Huang):

我们已经在太空中了。挑战在于散热（只能靠辐射），但这并非不可解决。目前我们的芯片已经安装在卫星上处理影像。与其把数据传回地球，不如直接在太空处理。

主持人 (Jason Calacanis):

在医疗领域，AI 将如何产生真正的影响？

黄仁勋 (Jensen Huang):

三个方向：

- **AI 生物学**：预测生物行为，助力药物研发。
- **AI 智能体**：辅助医生诊断。
- **物理 AI/机器人手术**：未来的超声、CT 仪器都会内置智能体。

主持人 (Jason Calacanis):



机器人技术经历了“失去的二十年”，现在马斯克的 Optimus 还有中国的机器人发展很快。我们离“机器人厨师”或“机器人管家”还有多远？

黄仁勋 (Jensen Huang):

大约 3 到 5 年。中国在电机、稀土、磁铁等硬件生态上非常强大，全球机器人产业都将依赖那个供应链。最终，机器人将成为人类繁荣的最大推动力。它不仅能解决劳动力短缺，还能让每个人通过机器人开启自己的事业。甚至我们可以通过虚拟现实“附身”在机器狗身上，在出差时陪孩子聊天或遛狗。

主持人 (Brad Gerstner):

Anthropic 的 CEO 预测 2030 年 AI 模型和智能体将产生 1 万亿美元的收入。你觉得呢？

黄仁勋 (Jensen Huang):

我觉得他太保守了。Anthropic 的表现会远超这个数字。因为每一家企业软件公司未来都会成为这些 AI 模型的“增值经销商”。

主持人 (Brad Gerstner):

那这些公司的“护城河”是什么？

黄仁勋 (Jensen Huang):

深度专业化。不要只做一个通用的横向平台，而要深耕某个垂直领域，把你的专业知识注入智能体。谁先连接客户，谁就能获得数据飞轮。

主持人 (Jason Calacanis):

你三年前说过：“你不会被 AI 取代，但会被使用 AI 的人取代。”现在你对就业的看法有变化吗？

黄仁勋 (Jensen Huang):

我不是末日论者。虽然司机会减少，但“移动助手”会增加。就像飞机的自动驾驶增加了飞行员的数量一样。我对年轻人的建议是：**成为使用 AI 的专家。**这需要艺术性，需要知道如何引导 AI 而不完全限制它。

主持人 (Brad Gerstner):

你曾在斯坦福建议年轻人要经历“痛苦和磨难”。现在你建议他们学什么？英语专业会比计算机专业更有前途吗？

黄仁勋 (Jensen Huang):

深厚的科学、数学和语言能力仍然关键。因为语言就是 AI 的编程语言。

看看放射科的例子：10 年前有人预言 AI 会让放射科医生消失。结果呢？放射科医生的需求量激增。因为 AI 让扫描变快了，医院能处理更多病人，收益更高。

一个增长更快的国家需要更多的老师、更多的专家，只是他们每个人都将拥有 AI 赋予的“超能力”。



主持人 (Jason Calacanis):

Jensen，祝贺你取得的成就。这是一场非常积极且令人振奋的对话。

黄仁勋 (Jensen Huang):

谢谢。我们不需要陷入恐慌，我们有自主权去选择如何创造未来。

英伟达 GTC26 财务分析师问答会

主持人:

大家早上好。希望你们喜欢昨天的演示。虽然时间长了一点，但我认为这是一个非常完美的总结。现在我们将时间留给你们，重点关注你们的需求和问题。我先把时间交给 Jensen（黄仁勋）。

黄仁勋 (Jensen Huang):

正如我昨天提到的，AI 近期经历了三个拐点：第一个是生成式 AI，第二个是推理（Reasoning），而我们现在正处于第三个拐点——**智能体系统（Agentic Systems）**。

这些系统具备“自主行动能力”，所以被称为智能体。你可以给它们设定目标，它们不再只是回答问题，而是执行任务。最流行的应用之一就是编写软件。在你们公司，以及我的公司，工程师们整天都在使用智能体系统。

过去工程师入职发一台笔记本电脑，现在是发笔记本电脑和 **Token（代币/令牌）**。Token 预算现在成了实实在在的东西。如果你雇了一个年薪 30 万美元的工程师，但他在工作中不消耗任何 Token，你得问问他整天在干什么。

未来的计算机不再仅仅是工具，而是**生产设备**。就像 ASML 的光刻机一样，它们生产的是可以出售的产品。这和很久以前生产电力的发电机（Dynamo）没什么区别。能源效率和生产效率决定了你的收入。

每一个软件公司、每一个企业现在都需要一个“OpenClaw 策略”，就像我们当年必须有 Linux 策略、互联网策略和移动云策略一样。

黄仁勋 (Jensen Huang):

我想更新一下关于订单可见性的情况。一年前我说过，到 2026 年，我们的 Blackwell 和 Reuben 出货量有 5000 亿美元的强劲可见性。

现在是 2026 年 3 月，我们对 **Blackwell 加 Reuben 架构拥有超过 1 万亿美元（1 Trillion Plus）的强劲需求可见性**。这包括了确定的需求预测和采购订单。

请注意，这 1 万亿美元仅指 Blackwell 和 Reuben。我不包含 Groq、独立 CPU 或其他新产品，因为我要和去年的数据做对比。

而且，这个数字到 2027 年底还会继续增长。我们拥有库存和供应流水线，甚至可以在同一个季度内完成接单并出货。这是那些做 ASIC（定制芯片）的公司做不到的，因为它们的交付周期太长。

黄仁勋 (Jensen Huang):



去年（2025 年）是“推理之年”。我们让大家明白：计算机的价格和 Token 的成本之间只有微小的联系。人们买电脑是为了生产 Token。你买了一台昂贵的电脑，但它生产 Token 的速度极快，结果你反而拥有了成本最低的 Token。

这也是我们能保持毛利率的原因。我们每一代产品都提供更高的价值——即“每秒、每瓦特产生的 Token 数”。客户宁愿以更高的价格购买下一代产品，也不愿以低价买旧产品。安装 Vera Rubin 比继续买 Grace Blackwell 更聪明，因为价值更高。

黄仁勋 (Jensen Huang)：

2025 年我们还扩大了平台支持。Anthropic 和 Meta SL 都成为了我们的新合作伙伴。目前 API 推理服务提供商的数据显示，**开源模型（Open Models）已成为全球第二大流行的 AI 模型类别**，仅次于 OpenAI。而英伟达是开源模型在全球最好的运行平台。

我们还与云服务商（CSP）紧密合作。我们在他们的云端拥有 CUDA，这吸引了所有开发者。我们是云服务商最好的销售力量，所以你会看到 AWS、谷歌、微软、甲骨文在我们的展厅里拥有最大的展位，因为他们想向我们的开发者推销服务。

此外，我们 40% 的业务来自于非 CSP 领域，如区域云、工业企业等。如果没有英伟达的全栈平台，你根本无法触达这 40% 的市场，因为他们买的是“平台”，而不只是“芯片”。

问答环节 (Q&A)

提问者 (Amelius Research, Ben Wright)：

Jensen，大家最担心的推力是：这笔投资值吗？云服务商的收入增长能覆盖这些巨额开支吗？我们什么时候能看到他们的收入上修？

黄仁勋 (Jensen Huang)：

我真希望那些 AI 公司已经上市了，这样你就能看到我所看到的。**历史上从未有初创公司能像他们现在这样，每周增加 10 亿或 20 亿美元的收入。**

2 万亿美元的 IT 软件行业正在整合 OpenAI、Anthropic 和开源模型。未来的 IT 行业将变成这些模型的“经销商”。我估计 IT 行业将从目前的 2 万亿增长到 8 万亿。

所有 IT 公司未来都会租赁或生产 Token。他们的商业模式将从软件授权转变为 Token 租赁。虽然这会引入销售成本（COGS），但提供的价值要高得多。OpenAI 和 Anthropic 的收入增长速度是在“一个月内长出一个完整的 IT 公司”。

提问者 (Caner Fitzgerald, CJ Muse)：

物理 AI（Physical AI）会对你的业务构成什么样的变化？

黄仁勋 (Jensen Huang)：

目前数字 AI 和物理 AI 的增长率差不多。但几年后物理 AI 迎来拐点，它必须在本地、在工厂边缘运行。由于全球 70 万亿美元的产业涉及物理原子（而非数字比特），物理 AI 最终会占据我们业务的 70%。

未来计算机将 24/7 全天候运行。我希望年薪 2000 美元一天的工程师每天能花 1000 美元的 Token 预算。我要让他管理一整支智能体舰队来替他工作。



提问者 (Bernstein, Stacy Rasgon):

Reuben 会和 Groq 一起发布吗？推理负载的演变如何？

柯莱特·克雷丝 (Colette Kress):

LPX（Groq 相关）预计在今年下半年。

黄仁勋 (Jensen Huang):

Vera Rubin 会比 Groq 更早出货。关于计算架构，有低延迟（CPU）和高吞吐量（GPU）之分。Groq 是极端的低延迟架构，几乎整块芯片都是 SRAM。它不灵活，但非常快。

我们将 Groq 与 Vera Rubin 融合，用 Groq 处理语言模型自回归推理的最后阶段。对于免费或普通层级的推理，Vera Rubin 是无敌的。但对于极高端、极其聪明的模型，加入 Groq 后吞吐量会大幅提升。

这就像 iPhone 或汽车行业，市场扩大后就会出现分层：从免费层到极客层（每百万 Token 50 美元的高端层）。

提问者 (Bank of America, Vivek Arya):

1 万亿美元的市场里，CPU、存储等产品占比多少？Groq 会蚕食 HBM（高带宽显存）的需求吗？

黄仁勋 (Jensen Huang):

我们是唯一能跨 HBM、LPDDR5 和 SRAM 三种内存进行优化的公司。如果 1 万亿的订单全部加上 Groq，规模会变成 1.25 万亿。存储是第二大支出，CPU 约占 5%。Vera Rubin 解决了“智能体”的计算需求——它不仅需要推理，还要查内存、用工具、跑浏览器。

我们把这些功能全部和谐地整合进了一个液冷机架架构中，不再是“缝合怪”。

提问者 (Goldman Sachs, Jim Schneider):

Token 成本一直在下降，这会趋于平缓吗？

黄仁勋 (Jensen Huang):

Token 成本会持续下降。但与此同时，每个 Token 的“聪明程度”会持续上升。评价 AI 工厂必须看“每瓦特产生的 Token 数”。任何不除以功耗的对比都是在误导。我们会不断推高帕累托前沿（Pareto Frontier）——即让工厂在同等成本下产出更多、更聪明的 Token。这是计算机科学中最难的问题。

提问者 (Evercore ISI, Mark Leatis):

SSM（状态空间模型）和 Neimotron 3 的混合架构对你们意味着什么？

黄仁勋 (Jensen Huang):

英伟达的架构美妙之处在于它支持一切：Transformer、扩散模型、SSM 等。Groq 跑不了扩散模型，但我们能跑。Neimotron 3 旨在处理超长上下文。我们希望推进 AI 技术，而不是单纯竞



争。

提问者 (UBS, Tim Aruri):

有人担心英伟达拿走了生态系统太多的价值，毛利率无法持续。你怎么看？

黄仁勋 (Jensen Huang):

如果你继续提供数倍的生产力提升，客户会很高兴与你合作。这就像 TSMC（台积电）的晶圆是全球最贵的，但价值也是最高的，所以我乐意付钱。ASML 也是如此。那些说“我的芯片便宜 30%”的人根本不懂 AI。他们不懂 AI 工厂的整体经济学。

提问者 (Redburn, Tim Schultzander):

你们的员工人数增长很慢，但任务量增长极快，如何平衡？

黄仁勋 (Jensen Huang):

我有 60 个直接下属。我们的公司架构反映了我们的产品架构。为了每年更新一代产品，你必须完全拥有整个软件栈、存储和网络。你不能靠拼凑别人的技术来实现一年一更。我们拥有从芯片到操作系统（Dynamo）的一切，这让我们在第一天就能让旧软件在全新系统上完美运行。

提问者 (最后一位提问者):

训练的需求会如何演变？

黄仁勋 (Jensen Huang):

训练经历了预训练（幼儿园）到后训练（学技能）。后训练需要强化学习、工具使用等，其计算强度可能是预训练的百万倍。未来的预训练将主要使用“合成数据”。我希望未来 99% 的算力都用于推理，因为推理是将 Token 转化为经济效益的过程。

这就是为什么英伟达去年全方位押注推理。推理就是“思考”和“工作”，怎么可能容易呢？推理只会变得越来越难。

黄仁勋 (Jensen Huang):

谢谢大家来到 GTC。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 同一用户免费领取一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



写评论

请发表您的评论



表情



图片

发布评论

2 条评论



Aaron 制鞋匠

13小时前 中国福建省

多少个token能产出一桶石油啊？ 什么还要消耗天然气



0



回复



MobileUser7888

16小时前 中国陕西省

50万亿?好家伙



0



回复

