

摘要：

企业AI落地，稀缺的能力是判断哪些事不该做

今年1月2日，阿里云智能集团副总裁霍嘉跑了一个半程马拉松。当天他发了一条朋友圈：「今年是奥运第一个周期的决赛年，练了四年终于比赛了。」

这比的正是AI应用落地。

9月23日，云栖大会期间的一场媒体群访上，霍嘉又讲了一遍这个判断。大模型真正落地的第四年，今年才是AI应用落地的元年。

Token消耗在爆发，价格在上涨，这是比赛开始的信号。企业侧的情况要复杂得多。

霍嘉的团队一年来接触了大量企业项目。他看到的失败，很少死在模型不够聪明上。死因是找错了场景，高估了自己的数据，用做信息化项目的办法做AI。

他给出的办法有两个，一是对客户说No，二是把工程师推到客户现场。

01 四类客户：前两类靠需求，后两类看价值

霍嘉对今年AI价格上涨的解释是三个因素叠加：需求爆发，模型能力提高，企业实际感受到了生产力提升。

海外头部模型产品出现之后，AI从聊天和娱乐工具，走到了生产力工具的早期，Token背后的算力不足随即暴露出来。

把时间窗口往回拉两年，那时候模型老在打折，Token量却没起来。霍嘉表示，想清楚当时为什么没起来，就能理解今天为什么起来了。

霍嘉把市场分成四类客户。第一类是AI原生客户，包括围绕新模型公司的创业团队，甚至短剧公司。第二类是高科技客户，互联网、汽车、手机，自身技术能力强。第三类是企业级客户。第四类是政府。

从规模化使用和Token调用量看，越靠前的占比越高。

「第一、第二类是需求驱动，第三、第四类是价值驱动。」

前两类客户知道自己要什么，买了Token就能用。后两类要先被证明值得用。

四类客户，两种驱动。

越靠前，规模化使用和Token调用量的占比越高。



Token调用量占比 高 ————— 低

资料来源：霍嘉9月23日云栖大会媒体群访

1 / 3

企业级客户用不起来，霍嘉归结为三个原因。

第一，AI人才极度匮乏。

第二，可借鉴的实践太少。互联网和移动互联网时代，开发者能看到大量落地经验。这轮大家四年前同时起跑，到今年才开始有东西可以分享。

第三，传统IT项目的工作方式跟不上技术。模型基本一个月发布一次，模型之上的工程方法，今年从Harness工程到loop engineering换了好几轮。「规划、执行、再规划、再执行」的节奏走完一圈，技术已经变了。

02 企业AI项目死在哪里

企业AI项目失败，有多少是因为模型不够聪明，这是群访上被直接抛出来的问题。

霍嘉没有给比例。他先说了个事实，去年8月底接手这个团队以来，没有出现过一次客户投诉，没有一次需要他出面道歉。原因是项目选得非常严，有钱有项目不一定接。

然后他讲了见过的三类失败。

第一类，硬训垂类模型。

这是算法团队过去最喜欢接的活。数据没准备好，集群精度不适合训练，客户还要保证效果，最后训不下去。

一位手握大笔预算的领导曾想请阿里云训一个模型。霍嘉见面问的第一个问题是：你跟不跟我们的模型发布？当时千问一个季度发一次，他手下没人跟他讲过这件事。对方很快决定不跟。

今天模型已经一个月一发。霍嘉的团队说服过很多客户放弃训垂类模型，「你跑不过前沿实验室的」。准确率要保证，办法在工程层面找，评测集怎么建，RAG不行换什么方法，都得跟客户的实际工作绑在一起才定得下来。

第二类，企业以为自己有数据。

去年夏天霍嘉反复讲「IT Data不等于AI Data」，当时指的是训练。今年他改成了「**IT Data不等于Agentic Data**」，指的是应用。企业系统里躺着的数据，大量没法在Agent环境里直接用，客户又一定要效果。

第三类，做给几个人用的Agent。

几个人提了需求，IT部门觉得终于有人关注，一起搭了个智能体，上线后一天只有几个人点一点。

霍嘉讲了一个真实案例。一家大企业有个B2B电商平台，主管领导找到阿里云，说你们做电商、做B2B起家，又在做AI，请你们帮我们设计B2B电商的AI化方案。团队很兴奋，预算很大。

霍嘉只问了一个问题：每天多少笔交易？

一百多笔。

「那要AI干什么？」人工处理只要几分钟到几个小时。

● 失败样本

项目很少死在模型不够聪明上。

霍嘉团队见过的三类企业AI失败。

01

硬训垂类模型
数据没准备好，集群精度不适合训练，客户还要保证效果，最后训不下去。

霍嘉原话
你跑不过前沿实验室的。

02

以为自己有数据
系统里躺着的数据，大量无法在Agent环境直接使用，客户又一定要效果。

霍嘉原话
IT Data不等于Agentic Data。

03

几个人用的Agent
B2B电商平台每天100多笔交易，人工几分钟到几小时就能处理完。

霍嘉原话
那要AI干什么？

资料来源：霍嘉9月23日云栖大会媒体群访

2 / 3

这类事情今天还在发生。

霍嘉的做法是告诉客户不该这么做，说服不了就再等等。

早在「十四五」数字化转型项目里，他就对客户说过很多No。「跟客户Say No是非常难的一件事情，但因为Say了No，后面反而大家合作起来没有那么多乱七八糟的事情。」

接下来的项目，他还有两个条件。

一是周期要短。一家央企项目，团队第一次汇报说首次上线要在3个月后。**霍嘉的回复是那就不**

要做了，大概率会失败。他去见了客户高层，把节奏改成每月发布一次，后来到每周一次。

过去卖人天，项目周期越长越好。现在技术每个月都在变，只有压短周期，才能在一个确定的技术时间点交付大家都认可的东西。



二是One Team。还在用甲乙双方方式合作的项目，他判断大概率失败，「不如给他标准品用好了」。

03 FDE火了，他却不提这个词

FDE的说法来自Palantir。Forward Deployed Engineer，前置部署工程师，直接进驻客户现场写代码、改流程。Palantir把这支队伍分成Echo和Delta两类，前者贴着客户业务找问题，后者负责工程落地。

大模型让这个岗位重新变热。

MIT NANDA项目在2025年8月发布的研究显示，95%的企业生成式AI试点对损益几乎没有可衡量的影响。a16z合伙人Joe Schmidt在2025年6月撰文主张，AI创业公司应该用毛利换护城河，走服务驱动的增长。2025年1月到9月，FDE相关招聘岗位增长超过800%。

OpenAI在2024年组建FDE团队。今年5月11日，OpenAI成立Deployment Company，首期投入超过40亿美元，TPG牵头，贝恩资本、Advent、Brookfield联合领投，麦肯锡、贝恩、凯捷作为咨询和集成伙伴加入，同时通过收购Tomoro获得约150名资深FDE。Anthropic也在扩张Applied AI团队。

国内从7月开始，FDE的视频和文章多到霍嘉自己都刷到不少。到了9月，一批公司跑出来宣布自己在做FDE。

阿里云走上这条路，比这轮热度早。

去年云栖大会，一家能源企业想做「人工智能+」，列了一批核心生产流程的场景。霍嘉觉得很难做，让解决方案团队先去调研。跑了很多现场之后，团队发现一开始设想的场景很多落不了地；客户如果不能很快看到效果，很难坚持下去；过程中要引入大量新技术，前线出报告、后方开发、再版本迭代的老办法走不通。

去年11月底复盘这个项目时，服务人员已经根据售前的内容在现场推进。霍嘉的判断是，这好像是FDE的工作方法。团队在现场验证场景，最终把它做成生产级系统上线。12月的内部战略会上，这个模式被确定可以试。

有同样痛点的客户很多。找不准场景，不会验证技术可行性和ROI，不会做生产级上线，三件事都不会。

跟传统交付相比，区别有两个。

第一，人往前推了一步。

传统交付先谈清楚项目范围（Scope），签下工作说明书（SOW）再干活。FDE在售前阶段就进场，边做边谈。阿里云没有照搬Palantir的Echo和Delta，SA承担Echo的角色，FDE负责落地。

霍嘉组队之初最看重大模型技术能力，后来发现懂技术不够，关键是能不能听懂客户、把话说清楚。「最基本的你应该告诉客户这件事情的Yes和No，以及他的代价。」很多事情技术上可行，代价却不值得。报一个100人天的工作量，最后交一个东西，客户已经不要了，过去两年这样的Demo太多了。

第二，前线和产品的距离缩短了。



霍嘉的说法是，所有产品的先进性来自两方面，一是对技术的前瞻预判，二是市场的真实反馈。过去大部分厂商并不清楚客户到底怎么用模型，是拿着锤子找钉子。

千问办公是最直接的例子。它有公共云版本，国央企需要私有化版本，私有化部署之外还有大量合规要求。FDE团队直接进入千问办公的研发周期，在客户现场做POC，需求实时带回，和千问的工程师坐在一起开发。「这个在过去是无法想象的。」

客户用的东西也在变。从只用模型、云的基础产品和百炼，开始用上千问办公、Qoder这类AI原生产品。

- 工作方式

把工程师往前推一步。

传统交付与FDE工作方式的五处差别。

	传统交付	FDE
进场时点	先谈Scope，签SOW再干活	售前阶段进场，边做边谈
上线节奏	三个月、半年甚至一年上线	每月发布一次，再到每周一次
对人要求	技术出身，习惯不跟客户说话	讲清楚Yes、No，以及代价
产品关系	需求按内部流程逐层传递	现场POC，和千问办公研发共同开发
收费逻辑	按人天，周期越长越好	考核带动产品，重点客户签长约

资料来源：霍嘉9月23日云栖大会媒体群访

3 / 3

海外和国内的FDE差在哪里，霍嘉的看法是工作模式和价值定位没有本质区别，差的是商业环境。海外模型公司也没打算靠FDE赚钱，目的是把AI用起来。产品和使用的飞轮转起来，底层数据和模型的飞轮才有回报。

「国内想依靠这个东西去赚大钱，可能不太现实，大家不要有这种期待。」

阿里云自己也不靠它赚钱。团队考核的核心指标是能否带动产品。阿里不是一家Service Company，服务长约只和重点战略客户签。**FDE如果不能成为产品能力的黏合剂和加速器，就很难持续存在。**

至于FDE是不是换了名字的驻场工程师，霍嘉已经跟团队说不太想再谈这个词。在中国，这个词容易变味，有人说新瓶装旧酒，有人说挂羊头卖狗肉。FDE最后会不会固化成一种模式，今天还是问号。

04 商业模式只有两种

FDE怎么收费，背后是一个更大的问题：AI时代的企业软件和服务，靠什么赚钱。

霍嘉的判断从中国软件业的旧账开始。软件和服务业的商业回报率一直一般，按功能付费讲不清客户为什么要出这笔钱，同质化严重，陷入价格战，最后恶性循环。他用了一个词，「死掉的SaaS」。

他押注结果付费，Result as a Service。真能交付结果，才有谈溢价的空间。



这个认知他是今年5月以后才想明白的。在那之前，他并不相信这个模式。上一轮做结果付费的公司过得很惨，阿里云自己也做过很多痛苦的项目。变化来自模型能力，大家对capability的信心上来了。

对传统软件公司，他的话更直接。核心产品的竞争力和利润率上不去，就只能按人天收费。「你的护城河到底是什么？」

另一个检验标准是客户愿不愿意跟你签长期服务合同。

中国公司和几家大咨询公司最大的区别，是太喜欢签Project Contract，不喜欢签Service Contract。签服务合同的公司比不上产品厂商，但比做项目的活得好，而且有毛利。霍嘉认识几支这样的小团队，一群90后硕士、博士，在模型能力还不强的时候就用这种方式工作，已经三年，赚到了利润，最大的一支长到了小一百人。

「商业模式就两种，一种是Service长约，一种是产品的商业模式。」先选定一种，再决定团队怎么定位。

企业客户的心智也在变。几个月前还有客户说，报预算要先锁定模型。霍嘉反问，那个模型到时候下架了怎么办？越来越多客户发现，很多任务放在MaaS上，效率和成本对自己最优。Token仍然很贵，他打了个比方，3G时代的流量，你敢天天刷刷吗？

中国的头部客户不在乎厂商投入了多少人，只在乎事情能不能做成。霍嘉说他能跟很多领导讲清楚，这个问题今天做不到，以及为什么做不到。

Token的价格曲线和企业的落地曲线，今天还没有重合。前者由AI原生和高科技客户拉动，后者要一个场景一个场景地验证。

一年前云栖大会发布的模型和当时的应用，没有人想到今年会长成这样。FDE、结果付费、服务长约，哪一种会成为常态，今天同样说不准。

霍嘉的提醒是，「不要因为不知道而丧失了想象力」。

练了四年，比赛才刚开枪。

本文来自微信公众号「[AI原生Lab](#)」，持续拆解真实AI落地案例，分享企业AI实践与方法论。

AI原生Lab

研究 AI 原生实践，重构组织与工作

拆解 AI 实践， 重构企业能力。

真实案例 | 方法提炼 | 落地复用



关注 AI 原生Lab
获取更多 AI 原生实践

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

87 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论