

摘要：

“一个模型，能看、能想、能写代码、能行动。”阿里官方介绍，Qwen3.7-Plus构建的Hybrid-Agent系统，曾连续稳定运行11小时以上，自动完成一款英语单词学习App的完整研发闭环，还自主复刻了一款股票行情应用。模型屏幕理解得分79，超过GPT-5.4和Gemini-3.1 Pro。

MiniMax M3模型昨日刚炸场，阿里千问又发布了一个强到可怕的新“怪物”。

6月2日，阿里云通义千问团队在X平台正式宣布发布**Qwen3.7-Plus**。这是一个多模态Agent模型，官方表述是“将视觉与语言统一为一体化智能体基座”。

团队用一句话来概括了它的产品定位：“一个模型，能看、能想、能写代码、能行动。”



显示翻译

Introducing Qwen3.7-Plus — a multimodal agent model that unifies vision and language into one versatile agent foundation.

- ✓ Multimodal interactive hybrid agent: unified GUI & CLI operation across visual and text tasks
- ✓ Versatile coding agent & productivity assistant with full-modality input
- ✓ Visual Agent: perception, reasoning, grounding, and search-augmented QA
- ✓ Cross-harness generalization across diverse agent frameworks

One model. Sees, thinks, codes, acts. 🧐🧐🧐

Now available via API on Alibaba Cloud Model Studio. Try it — let us know what you build. 😊



Blog: qwen.ai/blog?id=qwen3...

Qwen Studio: chat.qwen.ai/?models=qwen3...

API: modelstudio.console.alibabacloud.com/ap-southeast-1...

用Qwen3.7-Plus做App、复刻股票应用不在话下。千问官方博客披露，基于Qwen3.7-Plus构建的Hybrid-Agent系统，曾连续稳定运行11小时以上，自动完成一款英语单词学习App的完整研发闭环。Hybrid-Agent系统还自主完成了macOS原生Stocks股市应用的高保真复刻。**而模型屏幕理解得分79，也超过GPT-5.4和Gemini-3.1 Pro。**

而千问这次发布的时间点颇为微妙。就在前一天，[MiniMax刚刚推出新一代旗舰开源模型M3](#)，宣称同时实现顶尖编程能力、1M超长上下文与原生多模态。两家在同一周内密集发布，国内大模型开源竞赛愈发白热化。

Qwen3.7-Plus的定价为：输入\$0.4/百万token，输出\$1.6/百万token。

这个案例的关键点不在于“写了多少代码”，而在于链路够长。一个真实软件任务往往不是一次生成代码就结束，还要安装、运行、测试、改Bug、再验证。官方演示想强调的正是这种长流程能力。



复刻炒股APP，还接入真实行情API

另一个官方案例是，直接做一个炒股APP。

Qwen官方博客称，Hybrid-Agent系统自主完成了macOS原生Stocks股市应用的高保真复刻。流程包括：交互原生应用并理解UI布局和功能细节，基于交互记录生成SwiftUI源码，接入LongBridge真实行情API获取实时市场数据，自动编译构建并启动复刻应用。

模型自主执行了10项功能验证测试，内容包括实时行情加载、股票选择与切换、多周期视图切换、搜索过滤和详细数据面板展示等，且全部通过。

这个演示更直观：模型不是只生成一个静态页面，而是要理解行情App的结构、数据源和交互逻辑，再把它做成一个可以运行的桌面应用。

- Let me first check if the longbridge CLI is available and understand its capabilities.

- Let me explore what data is available for our stocks.

```
Bash(Longbridge quote .IXIC.US AAPL.US LITE.US GEV.US  
CBRS.US --format json 2>&1)
```

```
{  
  "change_percentage": "-1.54",  
  ...  
}
```


```
Bash(Longbridge line AAPL.US --help 2>&1 | head -80)  
OMLV candlestick (K-line) data, or historical dat  
e-range candlesticks  
...  
+59 lines (ctrl+o to expand)
```

```
Improvising... (42s / 471 tokens)  
Tip: Floop runs any prompt on a recurring schedule.  
Great for monitoring deploys, babysitting PRs, or  
polling status.
```


```
bypass permissions on . 1 shell . esc to interrupt ...  
11% until auto-compact
```

接入真实环境API接口 Real-World API Integration

原APP Original App



复刻APP Replicated App



看图写代码：图像/视频转SVG，也能生成网页原型

Qwen官方博客称，Qwen3.7-Plus可以将图像、视频、UI截图和设计参考转化为可执行代码，覆盖SVG复现到完整网页生成。

在图像/视频转SVG任务中，模型需要识别几何结构、颜色、布局、层级关系和动态变化，再用代码表达出来。对于图标、插画、动效、图形设计和信息可视化，这类能力的产品价值在于：把“看见的参考图”变成“可编辑的代码资产”。

在网页设计任务中，模型不仅要复现页面风格，还要组织布局、写前端代码、处理交互逻辑，并把多模态素材整合进最终页面。

同时，Qwen3.7-Plus可以作为视觉Agent，把视觉理解和工具使用结合起来，解决找不同、补图块、华容道、走迷宫、拼拼图等任务。

这里的流程不是“看一眼给答案”。模型会先理解图像结构和约束，再把视觉问题转成可计算的问题表示，然后自主编写并执行代码进行求解、搜索或验证。

跑分怎么看：屏幕理解跑赢GPT-5.4，但不是所有项目都第一

在多模态基准测试上，Qwen3.7-Plus有几个数字值得关注：

屏幕理解和移动端操控：ScreenSpot Pro得分79.0，高于GPT-5.4（67.4）和Gemini 3.1 Pro（68.1）；AndroidWorld得分81.0，同样超过Gemini 3.1 Pro（70.7）和Opus-4.6 Max（62.0）。




数学视觉推理：MathVision得分90.3，接近GPT-5.4的91.0，超过Gemini 3.1 Pro的87.4。

搜索增强视觉问答：SimpleVQA得分81.7，WorldVQA得分61.1，在这一赛道上与Opus-4.6 Max基本持平。

图表识别：CharXiv(RQ)得分85.9，为所有参与对比模型中最高。

测试项	GPT-5.4	Gemini-3.1 Pro	Qwen3.7-Plus
ScreenSpot Pro（屏幕元素定位）	67.4	68.1	79.0
AndroidWorld（手机App操控）	—	70.7	81.0
BabyVision（空间视觉推理）	53.1	55.9	70.4
CharXiv(RQ)（图表理解）	84.5	84.4	85.9
MathVision	91.0	87.4	90.3
MedXpertQA-MM（医学多模态）	77.3	80.7	71.0



	GPT-5.4 (xhigh)	Opus-4.6 Max	Gemini-3.1 Pro	Qwen3.6-Plus	Qwen3.7-Plus
Multimodal Reasoning					
MMMU-Pro	81.2	73.9	81.8	78.8	79.0
MathVision	91.0	65.5	87.4	88.0	90.3
BabyVision	53.1	12.6	55.9	37.4	70.4 / 64.7
CharXiv(RQ)	84.5	66.0	84.4	81.5	85.9 / 84.4
HiPhO	65.0	40.8	85.4	80.4	84.1
ERQA	67.8	40.8	68.0	65.7	69.8
VisFactor	40.8	24.4	39.8	36.0	42.8
MedXpertQA-MM	77.3	64.4	80.7	68.7	71.0
Visual Agent & Coding					
ScreenSpot Pro	67.4	49.5	68.1	68.2	79.0
OSWorld-Verified	75.0	72.7	--	62.5	73.3
AndroidWorld	--	62.0	70.7	67.2	81.0
QwenVision2Code	1884.0	1518.0	1632.0	1522.0	1772.0
ClawEval-MM	54.4	54.7	45.7	49.1	55.7
Multimodal Search & Knowledge QA					
SimpleVQA	69.4	79.6	76.9	69.4	81.7
WorldVQA	45.9	65.4	56.1	33.6	61.1
MMSearchPlus	19.7	38.9	42.0	19.6	41.4
BC-VL	48.1	51.5	49.9	26.1	51.1
MMBC	18.8	46.3	28.2	18.3	46.3
MMBC	18.8	46.3	28.2	18.3	46.3
General Visual Understanding					
RealWorldQA	83.8	73.9	83.5	85.4	86.9
CountQA	58.4	32.5	72.8	71.7	77.0
OmniDocBench1.5	85.5	86.6	90.0	91.2	91.4
OCR-Bench-V2(EN)	59.1	54.3	64.6	67.0	70.7
OCR-Bench-V2(ZH)	57.7	54.9	58.2	63.6	67.1
ODinW13	--	--	--	51.8	51.1
Autonomous Driving					
LingoQA	78.2	77.6	66.8	76.0	83.4
Ego3D-BenchI	6.9	8.1	10.4	6.1	5.9
SURDS	64.6	58.3	64.0	73.2	77.2
VLADBench	77.1	48.0	73.1	75.6	77.2
Video Understanding					
VideoMME (w/ sub.)	89.5	86.1	88.4	87.8	88.0
VideoMMMU	82.4	85.2	85.3	84.0	85.4
MLVU (M-Avg)	86.1	81.7	84.7	86.7	87.4
TVBench	82.5	69.8	73.0	76.0	78.2
LVBench	77.4	63.0	75.1	74.8	76.2

纯文本能力方面，官方表示Qwen3.7-Plus"整体接近Max级别模型"。

在Terminal Bench 2.0上得分70.3，超过Opus-4.6 Max（65.4）、K2.6 Thinking（66.7）和DeepSeek-V4-Pro Max（67.9）。

在Deep-Planning（复杂多步规划）上得分62.3，同样领先同级别模型。



不过也有弱项。

在SWE-Verified（真实软件工程任务）上得分77.7，低于Opus-4.6 Max（80.8）和DeepSeek-V4-Pro Max（80.6）；在HLE（极难推理）上得分34.7，低于GPT-5.4（40.0）。

纯文本测试集

	Opus-4.6 Max	K2.6 Thinking	GLM-5.1 Thinking	DeepSeek-V4-Pro Max	Qwen3.6-Plus	Qwen3.7-Plus
Coding Agent						
Terminal Bench 2.0-Terminus	65.4	66.7	63.5	67.9	61.6	70.3
SWE-Verified	80.8	80.2	--	80.6	78.8	77.7
SWE-Pro	57.3	59.5	58.8	59.0	56.6	57.6
SWE-Multilingual	77.5	76.7	--	76.2	73.8	75.8
NL2repo	47.6	42.8	41.0	35.5	34.4	41.1
SciCode	51.9	52.2	45.1	--	41.4	51.3
QwenWebDev	1617	--	1564	1570	1500	1536
QwenSVG	1541	1325	1605	1506	1432	1588
General Agent						
Qwenclaw	65.5	54.7	58.7	59.2	57.2	61.8
CoWorkBench	68.2	58.2	66.0	66.3	64.5	65.1
ClawEval	70.4	61.5	62.7	58.4	57.1	62.7
Skillsbench	--	56.2	53.1	52.3	45.7	54.9
BFCL-V4	76.7	71.3	70.9	70.6	68.9	72.9
MCP-Mark	56.7	55.9	57.5	57.1	48.2	58.7
MCP-Atlas	75.8	66.6	71.8	73.6	74.1	73.2
Vitabench	--	39.1	45.1	51.9	42.8	45.6

STEM & Reasoning						
GPQA Diamond	91.3	90.5	86.2	90.1	90.4	90.3
HLE	40.0	36.4	34.7	37.7	28.8	34.7
LiveCodeBench	88.8	89.6	--	93.5	87.1	89.6
HMMT 2026 Feb	96.2	92.7	89.4	95.2	87.8	92.9
IMOAnswerBench	75.3	86.0	83.8	89.8	83.8	86.0
CritPT	12.6	8.0	4.6	12.9	2.9	6.0
Apex	34.5	24.0	11.5	38.3	8.8	22.7
General Capability						
MMLU-Pro	89.7	87.1	86.3	87.5	88.5	88.5
MMLU-Redux	95.2	95.3	94.3	94.8	94.5	94.5
SuperGPQA	72.5	71.3	68.0	69.9	71.6	71.4
IFEval	91.9	94.5	94.5	91.9	94.3	94.6
IFBench	62.5	76.0	76.0	77.0	74.2	79.1
MRCR-v2_128k	84.0	63.1	62.0	74.4	85.9	91.7
Multilingualism						
WMT24++	82.7	81.6	81.8	82.2	84.3	84.6
MAXIFE	81.3	87.7	87.7	88.9	88.2	88.8
MMMLU	90.6	87.5	87.2	87.9	89.5	89.0
MMMLU-ProX	86.1	83.7	83.9	83.9	84.7	85.4
NOVA-63	59.1	56.7	54.6	52.8	57.9	58.8
INCLUDE	87.4	84.2	84.3	86.1	85.1	83.0
Global PIQA	91.2	89.2	89.5	90.5	89.8	90.3
PolyMATH	80.2	82.7	67.6	72.0	77.4	84.0

网友怎么看？

Qwen官方账号@Alibaba_Qwen于6月2日凌晨1:54发布公告，配合Demo视频展示了多模态混合Agent的操作过程。截至发文，该推文阅读量已达20万。

X网友表示，Qwen3.7-Plus模型不仅要面对各种屏幕，还要操作各类工具，并应对杂乱的工作流程。





Tiago Rama @tiagobuilds · 8小时
The interesting part is the interface spread.



Models now have to see screens, touch tools, and survive messy workflows.

使用DeepL翻译

有趣的是界面布局。

如今，模型不仅要面对各种屏幕，还要操作各类工具，并应对杂乱的工作流程。

[打开DeepL.com](https://www.deepl.com)

还有网友表示，Qwen这次的打法很清晰，就是往Agent和GUI操控上押注，这个方向现在是对的。



Louis @Louisreal__ · 8小时
Multimodal agents that can actually switch between GUI and CLI in one model is the direction that matters. Most current setups still feel too fragmented.



使用DeepL翻译

能够在—个模型中灵活切换图形用户界面（GUI）和命令行界面（CLI）的多模态智能体，才是真正值得关注的发展方向。目前大多数系统仍显得过于割裂。

[打开DeepL.com](https://www.deepl.com)

多个网友表示，Qwen将“看、想、写、做”集成于一个模型，实在太方便了。简直是“集成了一套员工系统！”



John Greg @JohnGregQuantum · 9小时
Qwen dropping a whole AI employee in one model now!!!



使用DeepL翻译

Qwen现在竟然在单个模型中直接集成了一整套AI员工系统！！

[打开DeepL.com](https://www.deepl.com)



Ferbin @Ferbin08 · 8小时
unified GUI/CLI is the real unlock here.



most agents handle one or the other. everything that matters - web apps, desktops, CLIs - needs both. single-mode agents are consultants pointing at buttons. multimodal ones are the ones actually pressing them.

使用DeepL翻译

统一的图形界面（GUI）与命令行界面（CLI）才是真正的关键所在。

大多数代理仅支持其中一种模式。而所有重要的应用——无论是Web应用、桌面应用还是命令行界面——都需要同时支持这两种模式。单模式代理就像是指着按钮的顾问，而多模式代理才是真正按下按钮的人。





Anton Abyzov · 8小时

Unifying vision and language in one base is real progress. The reliability gap lives a layer up: retries, tool errors, state over long runs. A stronger base model rarely closes that alone.

使用DeepL翻译

将愿景和语言统一在一个基础模型中，确实是一大进步。可靠性差距其实存在于更高层：重试、工具错误以及长时间运行中的状态问题。仅凭更强大的基础模型，很少能单独解决这些问题。

打开DeepL.com

相关评论中，不少技术用户关注的重点集中在两个方向：

一是ScreenSpot Pro的79分——这被不少人认为是"GUI Agent能否真正商用"的关键门槛指标，Qwen3.7-Plus目前是参测模型中的最高分；

二是Kernel Bench L3的98%——这个指标衡量的是模型优化GPU计算核心的能力，98%意味着几乎所有问题都能产出超越PyTorch默认编译器的方案。有用户指出，这个方向以前几乎是专业工程师的"禁区"。

与MiniMax M3的横向对比

两款模型几乎同期发布，定位有所不同。

MiniMax M3主打开源，技术报告和模型权重承诺在10天内公开，核心差异化是1M超长上下文（M3在1M上下文下每token计算量只有上代的1/20）和极强的长线程Agent能力（147次benchmark提交、1959次工具调用完成FP8矩阵乘优化）。

MiniMax团队让M3独立复现一篇ICLR 2025获奖论文。该任务需要看懂图文、曲线、数据和公式，也需要长上下文装入论文、代码和实验日志，还需要编程和Agent能力完成复现。M3自主运行接近12小时，最终跑通核心实验。

MiniMax M3

一个使用全新注意力架构 MSA、拥有1M 超长上下文的 Coding/Agentic 前沿模型

API & Token Plan

去 MiniMax Code 中体验


了解更多

Frontier Coding / Ag...
真实工程级，不止生成代码，更懂协作

MSA · 1M 上下文
全新稀疏注意力，让 context 真正可 scale

原生多模态
Step 0 混合训练 · 100T 量 · interleaved 数据

公众号 · 量子位



Qwen3.7-Plus目前**仅提供API调用**，不开源权重，核心差异化是多模态与GUI操作能力的深度整合，以及对主流开发框架的即插即用兼容性。

两者在编程Agent能力上存在直接竞争，但侧重点不同：M3更强调长上下文下的自主科研和代码优化能力，Qwen3.7-Plus更强调视觉感知与界面操作的端到端闭环。

相关链接：

https://x.com/Alibaba_Qwen/status/2061506641120641494

<https://qwen.ai/blog?id=qwen3.7-plus>

<https://chat.qwen.ai/?models=qwen3.7-plus>

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

 249  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论