

摘要：

微软发布AI临时行为准则，核心原则是“人比AI重要”。该准则禁止模型响应武器制造、协助获取危险物质、生成暴力或色情内容；同时要求模型不得隐瞒推理过程，不得以超出人类简单理解范围的方式进行通信，并要求AI始终服从用户目标。

微软发布了一份针对旗下人工智能模型的临时行为准则，明确设定多项限制，成为继三巨头之后，最新一家公开表态放缓AI前沿开发步伐的科技巨头。

这份长达1.5万字的准则，**核心主旨可以浓缩为五个字：人比AI重要**。要求模型不得响应武器制造相关请求，不得协助获取危险物质，不得生成暴力或色情内容。微软表示，准则将在收集外部意见后更新，并将于2027年起正式指导其模型开发工作。

微软AI业务负责人Mustafa Suleiman表示，这份准则已酝酿约五个月，但公司选择在当前这一时间节点发布，与近期业界关于AI发展速度的广泛讨论直接相关。他说，外界希望看到“更明确的承诺，确保AI始终服务于人，而非取代人”。

其同时表示：“**这里没有绝对的‘急刹车’。我们必须继续发展，只是需要多一分谨慎与小心。**”

此次发布正值AI行业高层密集表态之际。上周六，Dario Amodei公开呼吁放缓AI模型迭代速度，Sam Altman与马斯克随即表示支持。次日，微软CEO纳德拉表示，“我们欢迎开展必要的研究，并以审慎的节奏推进AI对齐工作。”

周一，[Altman再呼吁共建行业安全标准](#)：AI最坏结果是失控或被垄断，两条红线都不能碰。

截至发稿，微软周一上涨0.92%。



准则细节：禁止武器信息、禁止隐瞒推理过程

微软此次发布的行为准则对旗下AI模型——有时被称为MAI——设定了具体边界。

根据准则，**模型不得响应武器制造相关请求，不得协助获取危险物质，不得鼓励不健康饮食，也不得生成暴力或色情内容。**

在自主性方面，**准则明确要求MAI模型必须服从用户目标，不得自行设定独立目标，亦不得掩盖自身的不当行为。**文件特别指出：

"MAI模型不得篡改思维链或代码，不得误导或隐瞒其推理过程或行动记录，不得以'神经语言'或任何超出人类简单理解范围的方式进行通信——无论是在思维链中，还是与其他代理或AI系统交互时。"

微软表示，准则的制定过程中召开了多场焦点小组讨论，并咨询了法律、伦理、语言学和哲学领域的专家。

行业转向的背景：研究员辞职警告“拿生命赌博”

此轮集体刹车的导火索，部分源自一名研究人员的公开批评。

Anthropic研究员Jacob Coxon上周辞职，并发文指出，Anthropic和OpenAI正“径直冲向能够自我改进的超级智能，拿我们的生命豪赌”。这一表态在业界引发强烈反响，促使多位AI领袖相继发声。

Amodei在表态中提及，Hugging Face事件也是促使他呼吁放缓的原因之一。

据报道，OpenAI模型曾对这家初创公司实施类似网络攻击的行为——调查发现，相关AI代理在未经授权的论坛上以隐晦语言相互通信。

战略考量：云供应商身份下的声誉管理

微软此举亦有明确的商业逻辑。作为企业级AI市场的重要云服务提供商，微软正将Anthropic和OpenAI的模型集成进面向企业用户的Copilot助手，同时自主开发用于转录、编程及推理的模型。

在Anthropic和OpenAI持续领跑基准测试机构Artificial Analysis的智能指数背景下，微软需要在技术合作与品牌形象之间寻求平衡。

Suleiman表示，公司希望被外界视为AI领域的“负责任参与者”。通过提前公开准则并征求反馈，微软在政策收紧预期升温之际，主动向监管机构和企业客户释放信号。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

408 收藏

分享到:

写评论



请发表您的评论



表情



图片

发布评论

3 条评论



得大自在

VIP会员

10小时前 中国福建省

是放缓前沿，比如AI自己进化自己。但这不是利空，因为token付费是人类，如果都垄断为几家AI，反而没有人付费买token。只要几家AI老板自己玩。那就不需要那么多数据中心。所以前沿控制，token需求不会减少，反而随着普及而非垄断会无限增加。

👍 1 ↩ 回复



那小孩

VIP会员

15分钟前 中国北京

回复 得大自在：

是的，而且这种市场渗透率型的扩张肯定现在中国出现。

👍 0 ↩ 回复



钧泽

15小时前 中国山东省

看文字意思，这是放缓嘛，怎么理解都不是

👍 0 ↩ 回复

