

摘要：

瑞银预测，随着AI从对话生成进化为自主执行任务的Agent，算力瓶颈正从GPU转向CPU——每个GPU所需CPU核心数将增至传统场景的5-10倍。这场算力重估中，ARM凭借低延迟和能效优势成为最大赢家；AMD凭借多线程优势统治独立机架市场；而这一趋势也将催化PC换机潮，为英特尔带来关键利好。

AI时代，被GPU抢尽风头的CPU，或许正在悄悄迎来一场属于自己的爆发。

据追风交易台，5月5日，瑞银全球研究团队发布了一份针对美国半导体行业的深度研报。面对投资者关于“代理式AI将如何影响服务器CPU市场”的密集提问，分析师Timothy Arcuri等人通过一系列行业专家访谈并结合自下而上和自上而下两套模型，得出了一个明确的结论：

**市场严重低估了AI时代CPU的价值。服务器CPU的潜在市场规模（TAM），将从2025年的约300亿美元，增长至2030年的约1700亿美元，五年涨幅接近5倍。**

在过去两年的AI狂热中，GPU抢走了所有的聚光灯。但随着AI从“单纯的对话生成”进化为“自主执行任务的代理（Agent）”，算力的瓶颈正在悄然转移。

## 代理式AI重塑算力格局：从“GPU主导”到“CPU回归”

要理解CPU市场的爆发，首先要理解代理式AI与传统AI的工作负载差异。

在传统的AI训练和基础推理阶段，GPU是绝对的主力。如果把AI算力比作一个工厂，GPU就是流水线上不知疲倦的工人，而CPU则是负责分配任务的经理。在传统模式下，一个经理（CPU）可以轻松管理多个工人（GPU）。

但代理式AI改变了游戏规则。代理式AI不仅需要生成文本，还需要进行任务编排、工具调用（例如在沙盒虚拟机中执行代码）、文件检索等。这意味着“经理”的工作量呈指数级上升。

分析师在专家访谈中获取了极具冲击力的数据：

- **工作量重心的转移：** 专家指出，“在传统的AI工作负载中，70-80%的算力消耗在推理本身（GPU）上；但在代理式推理中，这个比例反转了，70-80%的工作量转移到了CPU上。”
- **核心配比的暴增：** 传统的AI训练中，每个GPU通常只需配备8-12个CPU核心；在基础推理中，需要16-24个核心；而在代理式AI中，每个GPU需要配备80-120个CPU核心。这相当于，同样一颗GPU，在智能体场景下需要的CPU核心数是传统训练场景的5-10倍。
- **并发任务的压力：** “一个代理（及其衍生出的每一个子代理）可能需要1-4个CPU核心，而一个复杂的任务可能需要生成10-100个子代理。”

这种底层逻辑的转变，直接打破了过去“重GPU、轻CPU”的算力架构，为CPU市场打开了巨大的增量空间。

Figure 1: Our TAM Estimates Suggest a \$170B TAM by C2030

| Estimate                             | 2025    | 2027    | 2030    | Comment                                               |
|--------------------------------------|---------|---------|---------|-------------------------------------------------------|
| <b>Traditional CPU Market</b>        |         |         |         |                                                       |
| Traditional CPU Market, MM           | 20      | 26      | 30      | Grows from 2025 at 8% CAGR like C2005-2020            |
| Traditional CPU ASP, K               | \$1,200 | \$1,348 | \$1,606 | Grows from 2025 at 1.5x 4% CAGR like C2005-2020       |
| Traditional Market, \$B              | 24      | 35      | 48      | Implied by units and ASPs                             |
| <b>AI CPU (Bottom-Up)</b>            |         |         |         |                                                       |
| AI Accelerator units (Bottom-up), MM | 9       | 23      | 40      | Largest programs (NVDA, AMD, TPU, Trn), ex-China      |
| AI CPU Market (Bottom-up Ests), MM   | 3       | 12      | 33      |                                                       |
| Head Node                            | 3       | 10      | ~20     | UBSe based announced systems                          |
| Standalone                           | 0       | 2       | 13      | Additional CPU units outside of rack                  |
| AI CPU ASP, K                        | \$2,420 | \$3,175 | \$3,769 | Higher core count and clock speed increasing ASPs     |
| AI CPU Market (Bottom-up Ests), \$B  | 7       | 39      | 125     |                                                       |
| <b>AI CPU (Top-Down)</b>             |         |         |         |                                                       |
| AI CPU Market (Top-Down Ests), MM    |         |         | 40      | TAM based on 3-4T AI Spend, and 1-to-1 CPU/GPU attach |
| AI CPU ASP, K                        |         |         | \$3,000 | UBS ASP ests                                          |
| AI CPU Market, \$B                   |         |         | 120     | Implied by units and ASPs                             |
| <b>Total Market</b>                  |         |         |         |                                                       |
| Bottom-up units, MM                  | 23      | 36      | 63      | Traditional + Bottom-up Ests                          |
| Bottom-up TAM, \$B                   | 31      | 74      | 173     |                                                       |
| Top-Down CPU Market, MM              |         |         | 70      | Traditional demand + Top-Down Est                     |
| Top-Down CPU Market, \$B             |         |         | 168     |                                                       |

Source: UBS estimates

## 1700亿美元的海量市场

基于上述逻辑，该行分析师对服务器CPU的总潜在市场（TAM）进行了重新测算。结果显示，到2030年，该市场规模将达到约1700亿美元。

这个庞大的数字是如何得出的？分析师采用了“自下而上”和“自上而下”两种方法进行交叉验证：


**1. 自下而上（Bottom-up）测算：** 分析师基于美国超大云服务商（Hyperscalers）的加速器模型预测，到2027年，市场将出货约2300万个加速器（XPU）和约1000万个头节点CPU。随着代理式AI的发展，到2030年，加速器出货量将达到约4000万个。更重要的是，CPU与GPU的配比率将从目前的1:4，逐渐向1:2甚至1:1靠拢。此外，由于AI应用需要更高核心数和更高频率的芯片，AI CPU的平均售价（ASP）将显著提升。例如，英伟达的144核Grace CPU定价可能在3000至4000美元之间。量价齐升之下，仅AI CPU市场的规模就将达到1250亿美元。

**2. 自上而下（Top-down）测算：** 分析师参考了英伟达对2030年AI总潜在市场（3万亿至4万亿美元）的预测。推算出2030年将有约4000万个XPU出货。假设每个XPU的平均ASP提升至3000美元，结合1:1或2:1的CPU配比率，同样推导出AI CPU市场规模在1200亿至2000亿美元之间。

分析师将未来的CPU市场划分为三个核心板块：

- **传统服务器市场：** 保持稳定增长，预计到2030年出货量约为4400万台。
- **AI头节点（Head Nodes）：** 与GPU机架捆绑，主要负责任务编排和优化GPU利用率。
- **AI独立机架（Standalone）：** 纯CPU服务器，专门用于处理代理式AI的工具调用和子代理并发任务。

Figure 2: CPU Market To Reach ~\$170B By C2030E



Source: UBS Research, Mercury Research

市场的饼做大了，关键是怎么分。

分析师明确给出排名：**ARM是服务器CPU侧最大受益者，其次是AMD，再次是英特尔——但三者均将受益。**

### ARM：份额从15%冲向40-45%

2025年，ARM架构在服务器CPU市场的单位份额约为15%。报告预计，到2030年，这一数字将升至**40-45%**；若以收入口径计算，由于AI CPU的平均售价（ASP）更高，ARM的收入份额将进一步达到**50-55%**。

ARM的优势在哪里？


该行援引专家观点：ARM架构**功耗效率高出约30%，内存效率高出约20-30%**，且凭借更小的核心设计，在延迟和成本上具备明显优势。更关键的是，英伟达Grace、AWS Graviton 5（192核）、谷歌等头部超大规模云厂商的自研CPU，几乎清一色采用ARM架构。

该行预计，到2030年，**ARM将占据头节点CPU市场75%以上的份额。**

但ARM也有短板。报告指出，ARM传统上是单线程架构，同步多线程（SMT）能力是近年才逐步开发的功能；在高核心数场景下，核心间干扰和软件兼容性问题依然是挑战；此外，生态系统成熟度仍有待提升，部分软件栈的完善可能要到2028年前后。


基于上述判断，分析师将ARM的12个月目标价从175美元上调至**245美元**。截至报告发布前一日（5月4日），ARM股价报203.26美元，维持“买入”评级。

Figure 14: We Arrive at ~40-45% Unit Share of ARM of Total CPU Market by C2030E



Source: UBS Research, share estimate based on units

Figure 15: But ARM's Share is Higher on Revenues basis at ~50-55% by C2030E



Source: UBS Research, share estimate based on revenues

## AMD：高核心数+多线程，AI最佳拍档

AMD的优势在于高核心数和多线程能力，这与智能体AI对CPU“又要快、又要多”的需求高度契合。

报告援引AMD在2025年11月分析师日的表态：AMD预计服务器CPU市场将从2025年的260亿美元增长至2030年的约600亿美元，其中AI驱动的CPU将占2030年市场的约50%；AMD预计自身在总市场的份额将超过50%。

分析师目前对AMD 2030年的EPS预测为25.27美元，若市场按预期演进，修正后的2030年EPS可达28.14美元，上行空间约+11%。

Figure 23: AMD C2030E EPS Power

|                          | 2030E          | Pro Forma 2030 |
|--------------------------|----------------|----------------|
| <b>Revenues</b>          |                |                |
| Server CPU Revenues      | 26,821         | 41,300         |
| Other Revenues           | 101,012        | 101,012        |
| <b>Total Revenues</b>    | <b>127,833</b> | <b>142,312</b> |
| Gross Margin             | 59.2%          | 59.2%          |
| Operating Margin         | 41.7%          | 41.7%          |
| Other Income & Expenses  | -68            | -68            |
| Tax Rate                 | 13.0%          | 13.0%          |
| Taxes                    | -6,923         | -7,708         |
| <b>EPS</b>               | <b>\$25.27</b> | <b>\$28.14</b> |
| Pro Forma EPS Upside (%) |                | 11%            |

Source: UBS Research

## 英特尔：基础盘稳固，但追赶压力大

英特尔的处境相对复杂。

在传统服务器市场，x86架构仍将保持约85%的份额，英特尔在工具调用、存储优化等特定工作负载上仍具优势。但在AI头节点市场，英特尔的存在感正在被ARM快速压缩。

瑞银指出，英特尔正寄望于"Coral Rapids"产品线来缩小与AMD和ARM的差距，但目前来看，AMD和ARM在AI CPU市场的定位更为有利。

不过，英特尔也有一张独特的牌：**PC端的溢出效应**。随着智能体AI将更多任务推向本地设备执行（Anthropic的Claude Code已在采用这一策略），PC升级周期有望被催化，英特尔将从中受益。

该行对英特尔2030年EPS的修正上行空间约为+7%，是三家中最底的。

Figure 4: Pro-Forma C2030E EPS Power

| Company | UBSe 2030 | Pro Forma 2030 | Pro Forma EPS<br>Upside (%) |
|---------|-----------|----------------|-----------------------------|
| INTC    | \$4.35    | \$4.67         | +7%                         |
| AMD     | \$25.27   | \$28.14        | +11%                        |
| ARM     | \$9.31    | \$11.56        | +24%                        |

Source: UBS Research, \*ARM using UBS estimates prior to the update in this note

并非所有CPU都一样：延迟vs吞吐量的取舍

报告还深入拆解了一个容易被忽视的细节：智能体AI对CPU的需求，并不是简单地“核越多越好”。

超大规模云厂商在硬件选择上面临一个根本性的取舍：

- 。高核心数CPU：总吞吐量高，能效比好，但时钟频率低，延迟表现较差，且软件扩展能力有限（大多数软件无法高效利用数百个核心）
- 。低核心数、高频率CPU：延迟低、响应快，适合“头节点”角色（负责编排调度、优化GPU利用率）

实际部署中，超大规模云厂商倾向于采用“头节点+大规模计算节点”的分层架构：前者负责低延迟的编排控制，后者负责高吞吐量的并行执行。

这意味着，能提供宽泛SKU组合（覆盖不同核心数、频率和功耗档位）的厂商，比只押注单一“最强”配置的厂商更有竞争力。

瑞银还指出，超大规模云厂商的采购决策核心指标不是峰值性能，而是每瓦特可处理的事务数（transactions per watt），内存配置是首要设计变量。

Figure 8: Based on Announced Roadmaps and UBSe Accelerator unit Ests, ~20-25MM accelerators shipping in C2027E and ~10MM Head Node CPUs

|                           | 2024         | 2025         | 2026          | 2027          |
|---------------------------|--------------|--------------|---------------|---------------|
| <b>Accelerators</b>       |              |              |               |               |
| NVDA                      | 4,846        | 5,736        | 8,755         | 9,522         |
| AMD                       | 384          | 406          | 573           | 1,052         |
| TPU                       | 1,280        | 1,710        | 5,030         | 10,430        |
| Trainium                  | 744          | 756          | 1,711         | 2,300         |
| <b>Total Accelerators</b> | <b>7,254</b> | <b>8,607</b> | <b>16,069</b> | <b>23,304</b> |
| <b>Head Node CPUs</b>     |              |              |               |               |
| NVDA                      | 116          | 1,492        | 3,663         | 5,133         |
| Non-NVDA Head nodes       | 1,154        | 688          | 763           | 803           |
| AMD                       | 96           | 101          | 143           | 263           |
| GCP                       | 160          | 373          | 1,305         | 3,148         |
| AWS                       | 93           | 94           | 285           | 748           |
| <b>Total CPUs</b>         | <b>1,618</b> | <b>2,748</b> | <b>6,159</b>  | <b>10,095</b> |
| Head Node CPU Ratio       | 22%          | 32%          | 38%           | 43%           |

Source: UBS Research

云端还是边缘？一个悬而未决的变量

分析师另外提出了一个值得关注的不确定因素：云端与边缘的计算分工。

早期智能体部署几乎完全依赖云端，但越来越多的系统设计开始将计算推向本地设备——5到10个并行任务可以直接在本地文件和数据上运行，既减少了延迟，又节省了云端算力成本。

瑞银援引专家估算：本地执行的扩展，可能将云端智能体工作负载所需的CPU容量减少约25%。

这意味着，智能体AI对数据中心CPU的拉动倍数，最终可能从5-8倍压缩至约4倍。但与此同时，PC端的CPU需求将被同步拉升，AMD和英特尔均将受益。

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线



公众号 · 追风交易台

#### 风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免



278



收藏

分享到:



#### 写评论

请发表您的评论



表情



图片

发表评论

#### 2 条评论



见闻用户

1小时前 中国广东省

应该服务器CPU中，ARM架构是赢家，而不是ARM公司吧

0

回复



华尔街09099009 1小时前 中国上海

回复 见闻用户:

他意思就是ARM公司，后面两个也是公司啊

0

回复

