


摘要：

基础文本模型领域，智谱、DeepSeek被视为长期最具竞争力，多模态领域，字节跳动领跑。高盛认为，中国AI大模型已从“低成本”迈向“高智能”，以智谱GLM、DeepSeek为代表的开源模型性能逼近全球顶尖闭源模型，并凭借成本优势、开源生态和海外扩张，有望推动中国AI市场高速增长。

中国AI大模型正站在一个历史性拐点上。高盛认为，中国开源/开放权重模型的智能性能已逼近全球顶尖专有模型，国内企业及全球中小企业的采用规模正在快速扩张，由此形成的数据飞轮效应将进一步推动模型迭代升级。

据追风交易台，高盛最新报告指出，这一演进轨迹可概括为“从DeepSeek去年的成本效率时刻，到智谱GLM今年的模型智能时刻”。高盛分析师Ronald Keung领衔的团队在这份50页的报告中，围绕中国AI模型如何以低成本实现高性能、为何选择开源路线及如何变现、核心可寻址市场在哪里，以及谁将成为长期赢家等四大核心问题展开系统评估。

在竞争格局判断上，高盛推出了一套基于定价能力、成本优势与财务实力的“竞争定位框架”，并据此认定，在基础文本模型领域，智谱（首次覆盖）与DeepSeek（未上市）定位最为强势；在多模态领域，字节跳动（未上市）领跑。高盛同时维持对MiniMax和快手的买入评级。



以小博大，效率制胜

中国大模型能够以远低于美国同类产品的成本实现接近的性能，核心在于架构创新与参数效率的双重突破。

高盛报告指出，中国开源模型的参数规模普遍在2000亿至1.6万亿之间，仅为全球顶尖模型的2%至10%，这主要源于高端算力获取受限。与此同时，混合专家架构（MoE）、稀疏注意力机制等创新使得实际激活参数占总参数的比例仅为3%至5%，大幅压低了训练与推理成本。

在具体模型层面，DeepSeek V4 Pro参数量为1.6万亿，智谱GLM5.2为0.7万亿，MiniMax M3为0.4万亿。

高盛将中国模型在编程能力上的近期跃升归因于数据筛选、强化学习后训练等因素的协同作用。6月27日，DeepSeek推出推测解码框架DSpark，已在V4-Flash和V4 Pro的在线服务中部署，在不改变模型权重或输出质量的前提下，将每用户生成速度提升60%至85%（V4-Flash）和57%至78%（V4 Pro）。

美团于6月30日发布的LongCat 2.0被高盛视为中国AI基础设施自主化的重要里程碑——这是中国首个完全基于5万张国产算力卡训练和部署的1.6万亿参数开源MoE模型。高盛认为，这证明了在计算密集型预训练阶段，本土化硬件栈的可行性，对中国AI模型摆脱对外国高端芯片的依赖具有深远意义。

市场两极分化，强者愈强

高盛将中国AI模型市场描述为正在形成的“双层结构”，并识别出两个ARR最大化象限。

在高端市场，以智谱GLM5.2和阿里巴巴Qwen3.7 Max为代表的顶尖模型定价约为每百万token 1美元，是低端模型的5倍，推理毛利率约为10%至20%（高盛估算）。相比之下，美国顶尖模型定价为每百万token 4至8美元，中国高端模型仅为其10%至25%，但凭借更低的参数激活比，仍能维持正毛利。

在低端市场，面向智能体任务的模型定价低至每百万token 0.06至0.2美元，正在开拓对价格敏感的全球中小企业和个人用户市场。MiniMax有60%至70%的收入来自海外。值得关注的是，DeepSeek已宣布自7月中旬起对V4系列引入峰谷定价机制，峰时费率为非峰时的2倍，混合定价约为每百万token 0.35美元（V4 Pro）和0.12美元（V4 Flash）。

高盛预测，中国AI模型的API及订阅收入将从2026年估算的350亿元人民币增长至2030年的8790亿元人民币，对应每日token消耗量从350万亿增至4600万亿，增幅约25倍。

开源策略：广泛渗透，变现路径待升级

高盛报告详细梳理了中国AI模型普遍采用开源/开放权重路线的战略逻辑及其变现局限。

开源策略的核心优势在于部署灵活性与社区生态。阿里巴巴Qwen系列、DeepSeek、智谱GLM及MiniMax M3均采用开源或开放权重方式，字节跳动的Seed模型是主要例外，采用完全闭源的专有路线。开源模式允许模型在中国大陆内外灵活部署，并通过社区反馈加速迭代。

然而，高盛指出，开源模型公司披露的ARR数字很可能严重低估了实际部署规模和收入潜力。以智谱为例，其2026年底ARR目标为10亿美元，但GLM5.2在全球的实际部署量将远高于智谱自有API渠道的token量和收入——阿里云百炼MaaS平台可直接托管GLM5.2开源模型，无需向智谱支付任何费用。

高盛预计，行业将逐步从纯开源（MIT许可证，完全免费）向“开放权重+社区许可证”模式迁移——即商业使用须与模型公司签订收入分成协议。MiniMax M系列已率先采用这一模式。高盛认为，这一转变将显著改善AI模型公司的单位经济效益，因为模型公司可通过与AWS Bedrock、阿里云百炼等平台的收入分成协议获益，而无需自行承担推理算力成本。

从“token最大化”到ROI优先

高盛将国际市场扩张定性为中国AI模型最重要的上行空间，尤其是在非美国市场。

高盛美国研究团队估算，到2030年，智能体AI将推动全球token消耗量增长24倍，达到每月120千万亿token，其中企业智能体贡献55倍增长，消费者智能体贡献12倍增长。在全球（中国以

外) 市场, 中国AI模型已凭借性能提升和价格优势实现显著的token份额增长。

高盛报告指出, 全球企业的AI使用范式正在经历从"token最大化"向"ROI优先"的根本性转变。前者盛行于2025年底至2026年初, 企业将高token消耗等同于组织生产力; 后者则更关注清晰的任务边界、每日活跃智能体数量、后端流程自动化及实际产出。一项Jellyfish AI工程趋势研究的数据显示, 企业中的重度AI用户消耗了10倍的token, 但产出仅提升了2倍。

在渠道层面, Alphabet旗下Gemini Enterprise Agent Platform和亚马逊AWS Bedrock均已提供DeepSeek、MiniMax、Moonshot、GLM和Qwen等中国AI模型的托管服务。据华尔街日报报道, 微软CEO近期表示, 微软正在考虑将DeepSeek的版本托管于Copilot, 作为可选的低成本模型, 并强调若托管DeepSeek, 该模型将在微软云生态系统内运行, 确保客户数据留存于Azure之内。

谁是长期赢家?

高盛构建了一套三维竞争定位框架, 以定量指标评估各玩家的长期胜出概率, 核心公式为:
ARR规模×毛利率优势+财务实力。

定价能力维度考察上市速度 (与前代及同级别模型的对比)、LMArena竞技场评分 (基于大规模盲测用户评价) 以及每百万token的混合定价水平。

成本优势维度考察吞吐量 (每秒token数)、缓存命中率、参数激活比以及推理毛利率。**财务实力**维度考察手头现金、净现金占总资产比例以及估值倍数。

在**基础文本模型**领域, 高盛认定智谱 (首次覆盖, 中性评级, 目标估值1100亿美元) 和DeepSeek (未上市) 定位最强, 两者在定价能力和成本优势上均表现突出。独立AI模型公司整体隐含估值合计超过2000亿美元。

在**多模态/视频生成**领域, 字节跳动凭借Seedance领跑, 据LatePost和36Kr报道, Seedance毛利率高达70%, ARR运行率已超过20亿美元。快手可灵和MiniMax Hailuo/即将推出的H3模型亦被高盛看好, 预计2026年下半年将受益于视频生成与LLM融合的功能突破及供给紧张带来的健康定价。

高盛对MiniMax维持买入评级, 目标价860港元, 理由是其M3模型处于高token量与有吸引力定价的ARR最大化象限, 且当前估值仅为2026年底ARR的13倍, 相较中国及全球同类公司的估值倍数存在明显折价, 风险收益比偏向上行。

风险提示及免责条款

市场有风险, 投资需谨慎。本文不构成个人投资建议, 也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资, 责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码
免费领取



限免

320 收藏

分享到:



写评论

请发表您的评论



表情



图片

发布评论

2 条评论



金之锋狂

9小时前 中国香港

直接越过小米mimo啊



0



回复



见闻用户

9小时前 中国江苏省

Qwen3.8什么时候出来啊，等好多天了



0



回复

