

摘要：

高盛最新深度报告系统拆解中国AI投资五大核心辩题：中国模型性能加速追赶美国SOTA、Token需求较2024年初暴增千倍、国产芯片替代提速、豆包DAU破1.5亿强势切入电商——云与数据中心已成中国互联网首选赛道，阿里云评级“买入”，MiniMax获上调。

中国AI大模型发布节奏显著加快，但围绕其叙事的投资辩题愈发深化且充满争议。高盛发布最新深度报告，系统梳理五大核心投资辩题，覆盖中美模型表现、国内竞争格局、token增长动力、国产芯片转型以及消费级AI Agent走势。

高盛表示，中国AI大模型的年化经常性收入（ARR）今年以来持续超预期，Token需求爆发式增长推动云基础设施进入高景气周期，而美国云巨头的一季度业绩（谷歌云同比增长63%、Azure增长40%、AWS增长29%）已为行业景气度提供了有力佐证。

分析师将MiniMax评级从“中性”上调至“买入”，维持阿里巴巴“买入”评级。分析师预计阿里云三月季度收入增速将达40%，高于上季度的36%。与此同时，中国大型云服务商的资本开支尚有扩张空间，这为云与数据中心板块提供了多年期的景气支撑，云与数据中心成为中国互联网首选子行业。

辩题一：中美模型表现到底如何？

高盛认为，从多项基准测试来看，中国模型在定价竞争力、推理速度及智能体任务完成率上表现突出，与美国领先模型（GPT/Opus/Gemini系列）之间在部分维度有所收窄。

分析师表示，中国基础模型表现收窄已带动定价能力与ARR改善，复杂编程与多模态将是下一阶段关键竞争维度。

超紧的算力约束正推动中国AI企业走上一条独特发展路径——专注训练与推理效率、数据质量及训练后优化，以更少芯片和内存构建高效架构。

随着美国SOTA模型对中国用户的访问限制趋于收紧，中国AI模型在高价值场景的使用率有望提升，形成正向数据飞轮，编程领域尤为如此。多模态方向上，字节跳动Seedance 2.0与阿里巴巴Happy Horse已具备业界前沿水平，MiniMax即将推出的Hailuo 3被视为下一个重要催化剂。

辩题二：竞争格局碎片化，差异化是关键

DeepSeek V4于4月23日发布，支持100万token上下文窗口，所需KV Cache内存仅为上一版本V3.2的7%-10%，并向开发者提供价格折扣，再度引发外界对中国AI模型竞争格局的讨论。

高盛认为，MiniMax及智谱股价自3月高点以来的回调，主要源于DeepSeek V4、腾讯Hy3.0、小米MiMo V2.5、阿里Qwen3.6等竞品模型的集中发布。

投资者对竞争格局的核心疑虑集中于三点：

一是入场门槛下降与市场碎片化——小米入局、腾讯Hy3训练周期不足三个月，均表明中等规模厂商的模型开发成本正快速下降；

二是200亿至3,000亿参数规模模型的竞争日趋白热化，该区间是智能体应用主战场，MiniMax M2.7虽已建立知名度并获多个平台认可，但DeepSeek V4 Flash、Hy3.0及MiMo V2.5均构成竞争压力；

三是定价战风险——Hy3预览免费版一度登顶OpenRouter用量排行，但高盛指出免费期通常较为短暂，全球算力供需偏紧格局将持续支撑中国AI模型定价能力的改善。

在格局判断上，高盛认为独立AI模型公司的核心优势在于高效的组织架构与快速决策能力；互联网大厂则凭借核心业务强劲的经营现金流，更具条件把握AI基础设施与云计算机遇，但需为AI芯片及模型团队设立独立激励机制，以应对来自独立AI原生公司的人才竞争。编程能力、多模态及任务完成率将是未来定价权的核心驱动，未来或将从按token收费演进至按任务成功付费的模式。

辩题三：Token增长可持续，云厂商定价存上行潜力

token消耗量持续高速扩张，是支撑AI云服务增长的核心变量。

据国家数据局，中国3月日均token使用量已超过140万亿，较2024年初的1,000亿增长逾千倍，环比2025年底亦增长约40%。企业端，字节跳动豆包模型日均token使用量突破120万亿，三个月内翻倍；火山引擎日均token使用量超过1万亿的企业客户数量，从2025年底的100家增至140家。

在第三方API聚合平台OpenRouter，中国AI模型在过去两个月持续从美国AI模型手中获取市场份额，主要受益于新发布中国模型在性能、长上下文、Agent能力及定价方面的综合优势。

高盛指出，OpenRouter日均token消耗的峰值出现在3月最后一周，此后数周均值约为峰值的79%，但随着AI Agent承担更多全天候任务，以及企业端对AI工具使用的激励仍在延续，高盛预期token需求将继续序列增长。

在资本支出层面，高盛估计美国超大规模云厂商2026年资本支出合计逾7,000亿美元，中国逾700亿美元（均为高盛预测）。

中国云厂商资本支出占经营现金流的比例约为60%，显著低于美国的约90%，为2026年下半年至2028年的进一步扩张提供财务空间。

高盛预期token定价具有上行潜力，部分由模型性能改善驱动，部分由供应紧张及成本推升带来的云服务提价传导。据Gartner，阿里云2025年亚太IaaS市场份额升至22.5%（2024年为20.8%），全球IaaS市场份额升至7.7%（2024年为7.2%）。

辩题四：加速转向国产芯片

多方因素催化下，正推动中国AI产业加速转向国产芯片。

主要方向包括华为昇腾910C及950系列（预计2026年下半年起扩大量产），以及互联网大厂自研芯片（如阿里巴巴平头哥系列）。

高盛认为，向国产芯片的迁移将在2026至2028年间加速推进，但近期供应瓶颈仍然存在。中国AI模型训练将越来越多地依赖高度优化的计算效率架构。此外，内存成本上涨将推动中国超大规模云厂商近期资本支出上行，与美国云厂商在相关评论中的反映相互印证。

辩题五：OS级Agent或成范式转变，超级应用护城河面临考验

消费端AI助手领域，豆包持续领跑。

据QuestMobile，豆包3月DAU约达1.5亿，占中国AIGC to-C应用整体时长份额约63%，3月环比用量增长78%。阿里Qwen凭借交易功能推动用户增长位居其次。

4月24日，豆包在应用导航栏嵌入"豆包帮你选"功能，正式切入电商赛道。高盛认为，任务执行能力、无缝交易功能及社交推送机制，将是用户留存与规模扩张的关键。

当前市场的核心辩题是：以**豆包手机助手**为代表的操作系统级Agent，与以即将上线的**微信AI Agent**为代表的**应用内Agent**，谁将主导下一阶段消费端AI入口格局。

OS级Agent的潜在扩张引发更深层的结构性讨论：以**微信**为代表、以**封闭生态运营的中国"超级应用"**，究竟会受到OS级Agent的流量蚕食，还是以**数据隐私与安全**为由实施屏蔽，进而催生即时通讯赛道的新竞争格局。

高盛将OS级Agentic AI定性为深刻的范式转变，认为其可能在中期通过占据主要流量入口，将**独立应用降格为后端工具提供商**，削弱其**用户参与度与数据积累优势**。

高盛预期各方将围绕互操作性、数据权限及生态控制权展开激烈博弈。深度整合支付、物流与社交关系链的互联网大厂（如腾讯、阿里巴巴）可能通过深化自身应用内Agent商业化能力来捍卫护城河，而硬件制造商及独立AI玩家则将积极推动更广

~~~~~

以上精彩内容来自[追风交易台](#)。

更详细的解读，包括实时解读、一线研究等内容，请加入 [【追风交易台·年度会员】](#)

# 追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

## 什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

## 在这里，你将看到

### 最专业的解读

来自全球顶尖投行、研究机构、  
一线从业者的最新解读



### 最独到的视角

以全球市场第一线的视角  
感知市场动向



### 最适时的时机

快速、完整、准确  
最终汇集成适时



## 如果你

关心全球宏观经济和资本市场

## 如果你

苦恼于没有合适的信息和研究



关注“追风交易台”  
成为“追风会员”

你将身处全球市场第一线

公众号 · 追风交易台

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

\* 体验资格每人限申领一次

扫码  
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

327 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



见闻用户  
7小时前 中国上海

彻底错误。技术差距和成本才是关键，永远是赢家通吃，

0 回复