摘要：

法国陷入新一轮暴力抗议风暴，7万安保人员紧急上阵、多城宵禁，马克龙坦承应对失误。金融市场已率先发出警报——法德国债利差飙至欧债危机以来峰值，PMI跌破荣枯线，奢侈品门店封窗、卢浮宫闭馆，巴黎市政预计损失数千万欧元。动荡烈火更有蔓延欧洲之势。

法国正面临新一轮全国性抗议活动，持续的社会动荡不仅考验着该国的安全防线，也显著加剧了市场对法国公共财政与经济前景的担忧。

据媒体报道，随着抗议演变为暴力骚乱，法国政府紧急部署7万名安保人员以维持秩序，并下令部分城市实施宵禁。法国总统马克龙承认在应对上周末暴力事件中存在失误，他已推迟原定的外交行程，以集中应对当前的国内危机。

持续的动荡局势直接冲击了金融市场与宏观经济。**法国与德国的10年期国债收益率利差大幅飙升，触及欧元区债务危机以来的最高水平，同时最新数据显示私营部门经济活动已跌破荣枯线，陷入萎缩区间。**

商业与零售活动同样首当其冲，巴黎多家奢侈品门店及主要景点被迫关闭。企业高管与地方官员警告称，游客流失将重创即将到来的假日季销售，并给市政带来高达数千万欧元的经济损失。

市场告急与经济萎缩

动荡局势加剧了投资者对法国公共财政的担忧。

尽管法国在周五晚间勉强避免了穆迪（Moody's Ratings）的评级下调，但该国在2027年大选前削减预算赤字的努力正面临严峻挑战。**作为衡量债券风险的关键指标，法国与该地区避险资产德国的10年期国债收益率利差在周四达到178个基点，远高于9月初的85个基点，触及欧元区债务危机以来的水平。**

此外，宏观经济数据也释放出疲软信号。由标普全球（S&P Global）编制的综合采购经理人指数（PMI）从上月的51.1降至10月的48.4，跌破50的荣枯线，表明私营部门经济活动已陷入收缩。

商业停摆与消费冲击

暴力的重演预期正迫使商业活动大面积停摆。

在巴黎，包括众多奢侈品精品店在内的商铺已用木板封住橱窗并增派安保人员，部分门店选择继续关闭。**卢浮宫，奥赛博物馆和毕加索博物馆三大热门景点周六闭馆，原定在巴黎举行的巴黎圣日耳曼队与里昂队的足球比赛也被推迟。**

据媒体报道，Breitling首席执行官警告称，随着游客远离巴黎，该公司正准备迎接假日季销售受到的冲击。

据报道，巴黎市长Emmanuel Grégoire表示，市政府正为持续数周的长期情况做准备，预计市政厅的损失可能达到数千万欧元。此外，他在社交媒体上指出有迹象表明暴徒计划在本周六和下周六向首都聚集。

严阵以待的安保升级

为应对被称为“第二幕”（Acte II）的抗议活动，法国政府全面升级了安保措施。

法国内政部长Laurent Nunez周五向记者表示，政府将部署7万名安保人员，其中包括精锐的反恐部队。他将社交媒体上呼吁暴力的行为归咎于极左翼，并强调政府对暴徒，抢劫者以及任何实施暴力行为的人（包括极左翼政治团体）绝不妥协。

军队将协助守卫敏感建筑，直升机，水炮以及被称为Centaurs的装甲车也已随时待命。包括里昂在内的部分城市已在周六发布抗议禁令并延长了宵禁时间。马克龙周四承认，在上周末的暴力事件背后存在“计划上的失败和令人意外的因素”。他将煽动性行为归咎于极端左翼团体。

政治分化与外溢风险

距第二任期结束还有六个月的马克龙目前正处于支持率低谷。

此次抗议最初源于民众对改善公共服务及政府干预高昂生活成本的诉求。据Cluster 17为L’Opinion进行的民调显示，该运动目前仍获得53%的多数公众支持，但支持率已下降4个百分点。同时，随着对负面影响的担忧加剧，59%的受访者希望抗议迅速结束，这一比例上升了6个百分点。

民调还显示，暴力事件使明年总统大选的领跑者，极右翼候选人Marine Le Pen从中受益。她计划于周六在奥尔良为其国民联盟党大会召集数千名支持者。与此同时，包括左翼人士和工会领导人在内的数千名反对者，已于当地时间上午在奥尔良市中心开始抗议游行。

社会动荡的情绪也在欧洲多国蔓延。在意大利，预计周末米兰和罗马将出现学生及青年的示威活动，上周末发生抢劫和骚乱后，意大利政府表示将在米兰部署军队。比利时预计也将发生抗议活动，而阿尔巴尼亚正努力应对因不满总理Edi Rama统治而引发的连续第二周的暴力示威。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

92 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

野村证券认为，AI投资叙事正深陷内在矛盾：超大规模云厂商若加速资本开支，自由现金流将持续消耗，融资可持续性遭质疑；若减速，则意味着AI需求与盈利前景预期失守。两条路均指向抛售。9月"智能体热"行情积累的拥挤多头仓位，在负面催化剂触发下引发大规模止损，并蔓延至美债、汇率及大宗商品市场，形成系统性去杠杆。

AI投资叙事正面临自身逻辑的内在矛盾。市场对超大规模云计算厂商资本开支路径的判断，已从此前的"正面无论如何都赢"演变为当前的"两害相权"困境——**加速则自由现金流承压，减速则需求前景存疑，两条路均指向AI相关资产遭到抛售。**

追风交易台消息，10月23日，据野村证券跨资产策略Charlie McElligott报告中指出，过去一周，AI生态系统内的负面情绪催化剂接连涌现，叠加此前9月"智能体热"行情中积累的多头仓位，市场经历了大规模的被迫平仓。

仅在最剧烈的单日抛售中，野村监控的124个美股多空配对中，有47个出现逾3个标准差的单日波动，6个触及5个标准差以上的极端偏离。

此次震荡不仅冲击了AI核心概念股，更通过拥挤仓位的连锁平仓，向美债、汇率及大宗商品市场蔓延，触发了跨资产范围的系统性去杠杆。

下周市场将迎来超大规模厂商财报密集披露窗口，包括谷歌、亚马逊、微软，叠加美联储议息会议，市场方向将在短期内面临关键检验。

资本开支的"囚徒困境"

AI交易的核心叙事，已从此前"正面结果全面利好"的单边逻辑，急剧切换至"怎么看都是利空"的双向困境。

McElligott在报告中将这一处境描述为"任选其一都是毒药"：

其一，若超大规模厂商资本开支继续加速。正如Meta最新财报所揭示的趋势，**市场将高度聚焦于自由现金流的持续消耗，并进一步质疑整体融资可持续性。**

这一路径具有非线性风险，意味着需以更大规模、更高利差发行债务，AI交易因"不可持续"叙事而承压。

其二，若超大规模厂商资本开支出现实质性减速，则意味着市场此前已定价的"最优情景"，**涵盖AI需求、技术采用、盈利能力及终端用户生产率提升等核心论题正在失守，AI交易将面临更为猛烈的冲击。**

这一困局的形成，与9月"智能体概念"行情期间多头仓位的快速重建高度相关。彼时大量资金涌入AI核心标的，并伴随着规模可观的看涨期权投机性建仓，为后续的踩踏式出逃埋下伏笔。

止损触发引发跨市场去杠杆

仓位拥挤是本轮波动异常剧烈的核心原因。

据野村交易台数据显示，在最剧烈的单日抛售中，共有124个美股多空配对触发止损，其中47个配对的波动幅度超过正负3个标准差，26个配对超过正负4个标准差，6个配对超过正负5个标准差。

Cumulative Returns

	YTD	Past Quarter	Past Month	Past Week
Semi-Energy Barbell	57%	4%	-1%	-3%
AI Enablers Vs Hyperscalers	37%	-11%	-10%	-2%

Sharpe Ratio

	YTD	Past Quarter	Past Month	Past Week
Semi-Energy Barbell	2.8	0.9	-0.9	-6.1
AI Enablers Vs Hyperscalers	1.2	-0.9	-4.3	-2.4

Drawdown

	YTD	Past Quarter	Past Month	Past Week
Semi-Energy Barbell	-8.8%	-6.6%	-5.5%	-3.1%
AI Enablers Vs Hyperscalers	-25.7%	-19.8%	-14.2%	-1.7%

Source: Nomura Vol

（各类配对交易过去一段时间表现）

McElligott认为，本轮止损潮的根源在于，2026年全年"高夏普比率交易"高度集中，套息策略与趋势跟踪策略长期共振，形成罕见的广谱赢家效应。

而当前时点恰逢四季度末，基金经理面临年末业绩压力，在已然承压的回撤环境下，主动出击博取反弹的动力远不及"保住资本、安全越年"的避险本能——"去风险、关仓位"模式主导了市场行为。

与此同时，AI叙事的重置正在加速系统性趋势策略的仓位调整，尤其集中于此前极为拥挤的美国国债及短期利率空头。

据野村QIS数据，过去两周，CTA趋势策略已平仓约680亿美元的美债期货空头及380亿美元的短期利率期货空头，但信号仍处于净空头状态，意味着若债市涨势延续，潜在的被迫回补规模依然可观。

CTA SHORT COVERING "PAUSE" AS NEXT LEVELS REQUIRED TO FLIP 3M WINDOWS "LONG" ARE OTM

Bonds

Global Bonds Notional Trigger Level Bands

	-4%	-2%	+2%	+4%
USD_2Y	$-11.8 (101.78)	$-11.8 (101.78)	$+65.1 (103.46)	$+79.8 (104.31)
USD_5Y	$-5.0 (103.86)	$-5.0 (103.86)	$+9.6 (106.37)	$+27.5 (107.67)
USD_10Y	$-3.3 (105.40)	$-3.3 (105.40)		$+18.3 (110.15)
USD_20Y	$-0.7 (106.21)	$-0.7 (106.21)		$+1.3 (110.38)
USD_30Y	$-0.8 (107.78)	$-0.8 (107.78)		$+1.5 (112.35)
AUD_3Y	$-1.9 (94.69)	$-1.9 (94.69)	$+10.7 (95.95)	$+13.1 (98.24)
AUD_10Y	$-1.1 (93.70)	$-1.1 (93.70)	$+6.0 (96.48)	$+6.0 (96.48)
EUR_2Y	$-10.3 (104.50)	$-10.3 (104.50)	$+69.6 (106.64)	$+69.6 (106.64)
EUR_5Y	$-4.5 (111.92)	$-4.5 (111.92)	$+24.8 (114.62)	$+30.3 (116.40)
EUR_10Y	$-2.8 (120.25)	$-2.8 (120.25)	$+15.4 (124.16)	$+15.4 (124.16)
EUR_30Y	$-0.5 (102.07)		$+0.9 (106.63)	$+2.5 (107.70)
GBP_10Y	$-2.4 (84.48)	$-2.4 (84.48)	$+8.5 (86.72)	$+13.1 (87.52)
JPY_10Y	$-5.7 (124.66)	$-5.7 (124.66)	$+31.5 (127.01)	$+31.5 (127.01)
CAD_10Y	$-2.1 (115.84)	$-2.1 (115.84)	$+11.7 (118.73)	$+14.3 (120.39)
CHF_10Y	$-0.4 (103.43)	$-0.4 (103.43)	$+0.8 (105.42)	$+0.8 (105.42)
FRA_10Y				$+0.7 (109.83)
ITA_10Y			$+0.7 (110.90)	$+0.7 (110.90)
ESP_10Y			$+0.3 (116.18)	$+0.3 (116.18)
Total	$-53.0	$-52.6	$+255.5	$+326.5

STIR

Global STIR Notional Trigger Level Bands

	-4%	-2%	+2%	+4%
SFR4	$-7.0 (95.24)	$-7.0 (95.24)	$+47.8 (96.76)	$+47.8 (96.76)
SFR8	$-6.6 (95.23)	$-6.6 (95.23)	$+44.8 (97.01)	$+44.8 (97.01)
ER4	$-6.3 (96.35)	$-6.3 (96.35)	$+42.7 (97.93)	$+42.7 (97.93)
ER8	$-7.0 (96.42)	$-7.0 (96.42)	$+47.4 (97.81)	$+47.4 (97.81)
SFI4	$-6.0 (95.22)	$-6.0 (95.22)	$+40.9 (96.38)	$+40.9 (96.38)
SFI8			$+40.6 (96.62)	$+40.6 (96.62)
Total	$-33.0	$-33.0	$+264.1	$+264.1

Source: Nomura QIS, Nomura Vol

（过去两周CTA已完成超千亿美元的空头回补，若要触发绿色框内下一波约500亿美元的强力追买，需等待债券价格进一步向上突破+2%的触发门槛）

McElligott认为，随着短期窗口的回补基本完成，债券空头的挤压动能正在阶段性停歇。2周及1个月周期模型均已翻转为"做多"信号，但3个月周期模型若要从当前水平翻转做多，仍需债券价格出现大幅进一步上涨。

宏观共振：债券与股市的相关性切换

此次AI叙事重置，同步触发了债市与股市内部的相关性结构变化，这一信号在市场机制层面值得关注。

债券方面，"股债负相关"保护属性重新显现。McElligott指出，大量资金于前一交易日通过股票期货抛售与国债期货买入完成资产配置切换，债券再度扮演风险对冲工具的角色。

这一特征贯穿全年的大部分时间后曾一度失效，如今伴随"增长恐慌"情景的信用度上升而回归。

股票市场则出现方向相反的切换。2026年大部分时间内，纳斯达克及半导体板块呈现罕见的"上涨日波动率高于下跌日"特征；而当前，这一关系已重新反转为"负向现货-波动率相关性"，即股价下跌时波动率更大。

这一切换在纳斯达克及SMH（半导体ETF）空间最为突出，直接反映了市场对AI资本开支可持续性的重新定价。

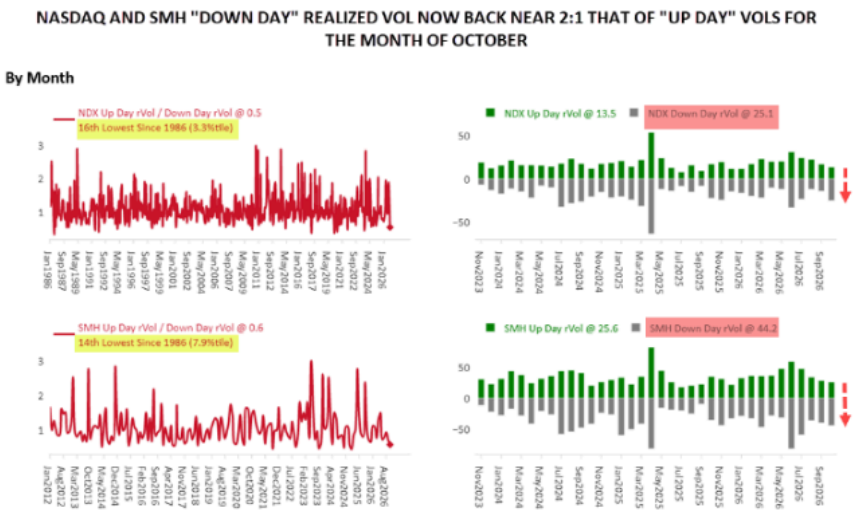

Source: Nomura Vol

（纳斯达克和半导体ETF指数在“下跌日”的成交量是“上涨日”成交量的近2:1，这一现象在10月份再度显现）

值得注意的是，标普500整体指数层面的VIX波动相对温和。McElligott将此归因于"反向离散"效应——**科技多头遭受重创，而利率敏感型板块及其他空头标的则急剧反弹，两相对冲使得指数层面的整体相关性并未爆发式上升。**

大额期权信号：逆势资金仍在布局AI反弹

尽管整体情绪承压，期权市场中仍出现了若干值得关注的逆势布局信号，主要体现在部分核心AI名称的看涨期权上。

据McElligott的观察，过去一周内出现了以下显著的看涨期权买入活动：

- CoreWeave合计支付权利金约6900万美元，涉及期权名义敞口约1.7亿美元；
- Nebius Group合计支付权利金约2570万美元，涉及名义敞口约8000万美元；
- 美光合计支付权利金约2000万美元，涉及名义敞口约8500万美元。

上述交易涉及2025年3月至4月到期的价外看涨期权，显示出部分资金在当前动荡中仍维持对AI板块中期反弹的方向性押注。

对于潜在的企稳条件，McElligott认为关键在于波动率风险溢价（VRP）卖方是否愿意遵循历史规律"逢波动率上涨做空"，尤其是0DTE Gamma卖出策略在买入下跌、卖出上涨方面的稳定器作用，将是判断波动率能否再度收敛的重要观察指标。

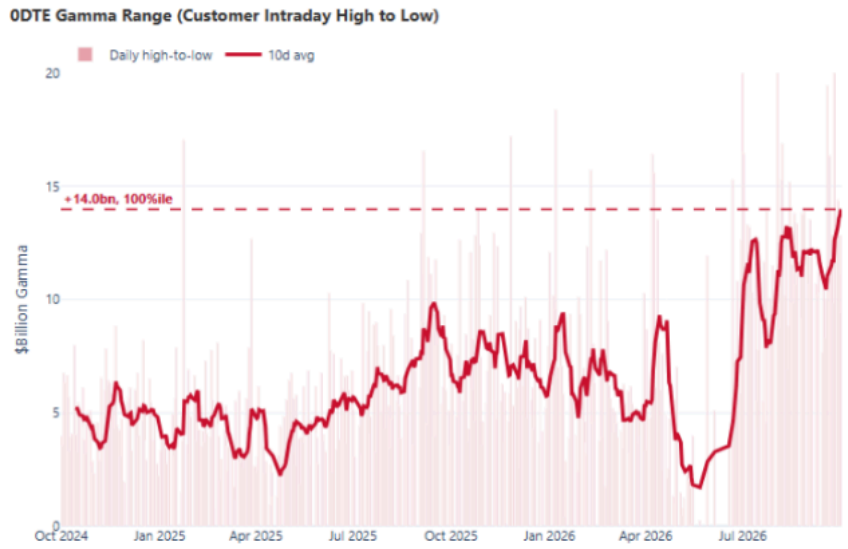

Source: Nomura Vol

（0DTE伽马区间）

~~~~~~~~~~~~~~~~~~~~~~~~~

以上精彩内容来自追风交易台。

更详细的解读，包括实时解读、一线研究等内容，请加入【**追风交易台·年度会员**】
~~~~~~~~~~~~~~~~~~~~~~~~~

追风

RISK CHASE

全球宏观研究 | 交易 | 配置

你 / 不 / 能 / 错 / 过

什么是“追风交易台”

追风交易台由顶流全球宏观资讯及研究团队联手打造。

我们的目标是给中国投资者提供专业、独到和适时的全球金融市场研究。

在这里，你将看到

最专业的解读

来自全球顶尖投行、研究机构、一线从业者的最新解读

最独到的视角

以全球市场第一线的视角感知市场动向

最适时的时机

快速、完整、准确
最终汇集成适时

如果你

关心全球宏观经济和资本市场

如果你

苦恼于没有合适的信息和研究

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

289 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

3 条评论

天予不取反受其咎
24分钟前 中国浙江省

脱离了工业生产规模的美股ai叙事，注定幻梦，到现在题材上还没赚钱的，就别想了

0 回复

MobileUser2088
2小时前 中国

根本原因就是不能快速变现，投入持续大于产出，也是一种泡沫的表现形式。

0 回复

见闻用户 VIP会员
8小时前 美国

所有的故事，只能有一首主题歌

0 回复

摘要：

英伟达、英特尔与AMD豪掷50亿美元预付款，疯抢台湾高阶IC载板。受“砸钱锁单”驱动，台系载板三强狂掷1612亿新台币扩产创纪录。巨头重金绑定产能，尽显AI核心材料的极致紧缺博弈。

据台湾《经济日报》报道，英伟达、英特尔、AMD三大科技巨头为抢占AI供应链关键产能，已向中国台湾高阶IC载板厂合计预付逾新台币千亿元（约50亿美元）订金，锁定长期产能供应。

受此驱动，台湾载板三强欣兴、景硕与南电今年累计宣布投资建厂规模达1612亿元新台币，创下历史新高。

英特尔执行长陈立武（Lip-Bu Tan）此前公开表示，AI需求带动先进封装与芯片需求，上游IC载板及材料供应持续吃紧，已有多家客户主动提前支付预付款，以协助英特尔锁定载板与产能。法人据此推估，英特尔长期预购载板产能金额约30亿美元。

AMD此前宣布投资台湾百亿美元，业界普遍解读为锁定供应链产能，其中载板相关投资估计约10亿美元；英伟达亦宣布与多家核心供应链合作伙伴推进大规模扩产计划，外界推测其对台厂载板投资规模同样约10亿美元，且存在进一步追加的可能性。

欣兴：资本支出居同业之冠，斥资百亿收购厂房

据上述报道，欣兴今年资本支出规模在载板厂中排名首位。公司董事会此前决议追加今年资本支出197亿元新台币，使全年资本支出总额升至537亿元，同步大手笔采购长交期设备，相关采购订单金额亦再追加176亿元。

在土地与厂房布局方面，欣兴于9月底公告以约100.8亿元新台币收购台湾普利司通湖口厂办，用于应对客户未来高阶载板产能扩充需求。公司公告指出，此次收购土地系基于中长期营运发展策略，旨在进行整体生产配置与产能规划。

景硕：转型高阶载板，三年扩产预算逾四百亿

景硕近年持续从传统PCB生产淡出，集中资源转型高阶载板业务。董事会已拍板资本支出235亿元新台币，以满足未来三年ABF载板产能扩充所需设备投资，其中2026年计划支出80亿元，60亿元将专项用于ABF载板投资。

此外，景硕董事会还额外新增专案资本支出预算196亿元，进一步强化扩产力度，合计扩产预算总额超过四百亿元新台币。

南电：兴建智慧工厂，单项投资近五百亿

南电董事会此前通过决议，将新增资本支出用于兴建专注大尺寸、高层数高阶载板的智慧工厂，预计投资金额达468亿元新台币，为三家厂商中单项投资额最高。

AI基础设施军备竞赛向上游蔓延

三大科技巨头合计对台湾载板产业的投资估计达50亿美元（约合新台币1629亿元），折射出AI基础设施建设对上游关键材料与封装基板的深度依赖。载板作为连接芯片与电路板的核心中介元

件，其供应瓶颈已直接影响整体AI供应链的产能释放节奏。

客户以大额预付款锁定产能的模式，一方面为台湾载板厂商的大规模资本支出提供需求能见度支撑，另一方面也显示科技巨头对供应链安全的优先级已提升至主动绑定资源的层面。今年台湾载板大厂宣布的累计投资额创下1612亿元新台币的历史新高，反映市场对AI相关载板需求的长期乐观预期。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

68 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：
投资很贵，这份日历并不贵。让2027每一个重要日子，都有备而来。

FEBRUARY
40/365
2月 · 羊年 · 周二
正月初四
忌 · 为面子买单
09
澳洲联储公布利率决议;中国内地、中国香港金融市场因春节假期休市
当然，在人生的旅途上，也要记住据说是查理说的关于节俭的一句名言："乘飞机坐经济舱和头等舱是同时到达目的地。"
[美]玛丽·巴菲特、大卫·克拉克《新巴菲特之道》
华尔街见闻
提前了解
全年重要财经日程
每日启发
316条大师箴言
打开投资视角
发现趣味
每日宜忌藏着奇妙暗示
越翻，越有共鸣
回看历史
49个时光印记
重温金融史上的危机、转折与高光时刻

不止一本日历
随日历附赠
3重知识权益
知识礼包详情及领取方式
请见实物日历内页说明
华尔街见闻 VIP
VIP会员
大师课
抵用金
¥129
Alpha
体验券
线上团门私享会
知识礼包
总价值超¥1000
12:53
知运势
看日程
听要闻
开启通知，最新财经日程早知道
2026年9月
农历八月十二
忌·犯蚤
星期二
22
今日暂无要事，喝杯咖啡休息下>
市场就像上帝一样，帮助那些自助的人；但和上帝不同之处在于，市场不会原谅那些不知道自己在干什么的人。
[美]沃伦·巴菲特，投资家、企业家及慈善家
转发
分享
购买
重磅订阅
企业定制
配套小程序
扫码进入 · 一键收藏
看日程|看数据|听要闻|看前瞻
7×24小时在线
让纸上的365天
连接实时变化的财经世界

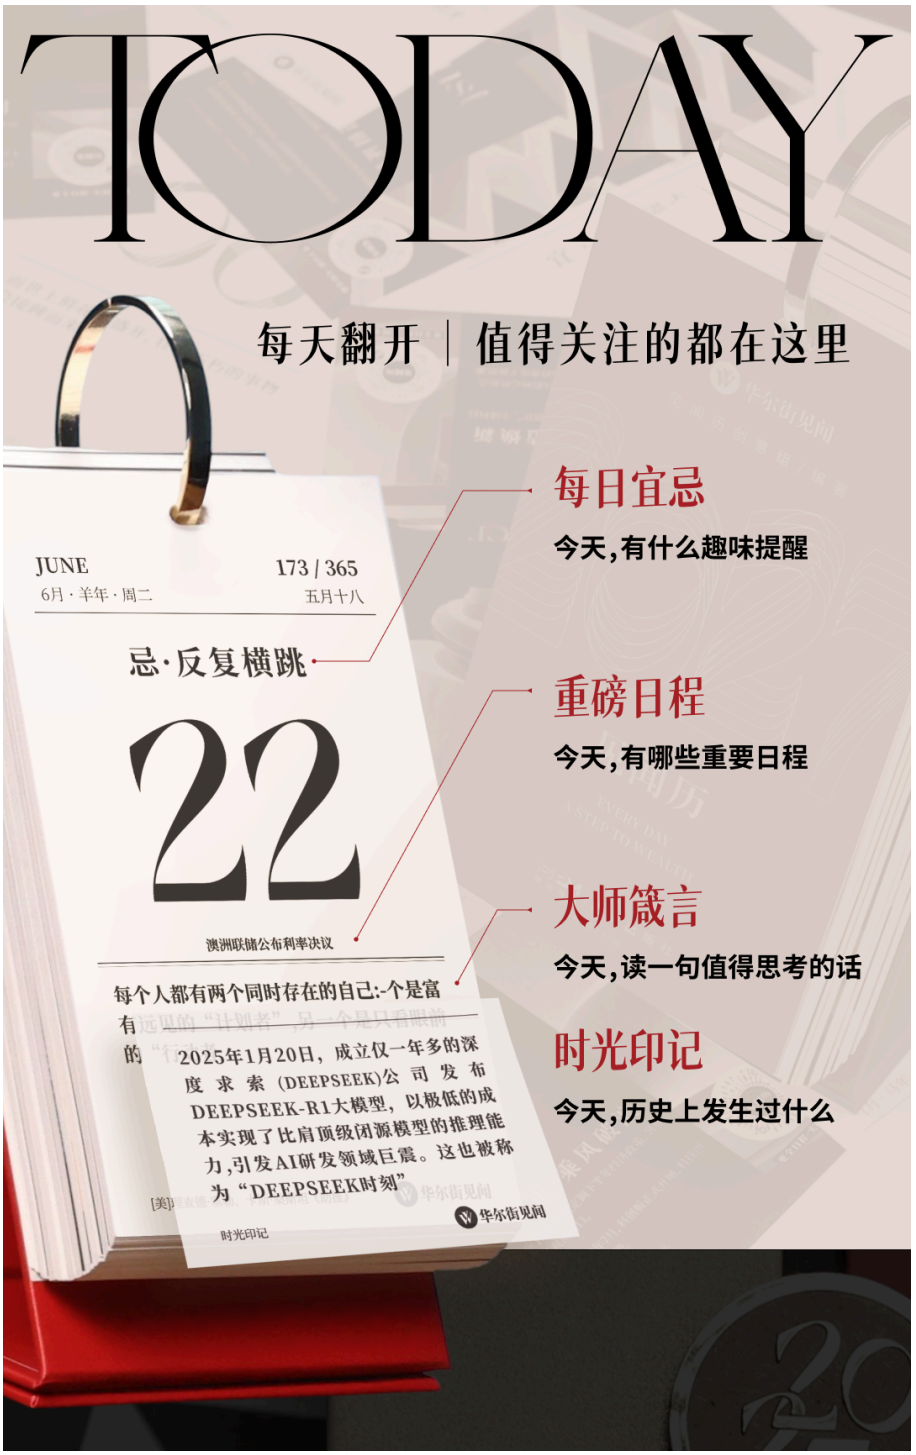
TODAY
每天翻开 | 值得关注的都在这里
JUNE
6月 · 羊年 · 周二
173 / 365
五月十八
忌·反复横跳
22
澳洲联储公布利率决议
每个人都有两个同时存在的自己:一个是富有
的
2025年1月20日，成立仅一年多的深度求索（DEEPSEEK)公司发布DEEPSEEK-R1大模型，以极低的成本实现了比肩顶级闭源模型的推理能力，引发AI研发领域巨震。这也被称为“DEEPSEEK时刻”
时光印记
华尔街见闻
每日宜忌
今天，有什么趣味提醒
重磅日程
今天，有哪些重要日程
大师箴言
今天，读一句值得思考的话
时光印记
今天，历史上发生过什么

每年一个新主题

换个角度理解周期

2027月历页主题
A股的日历效应与历史回响

梳理每月日历效应
回看同月发生过的A股大事件

＊以上为部分页面展示
实物包含全年12个月历页

全新包装·双开礼盒设计
打开，更有仪式感
华尔街见闻
2026
见闻历
EVERY DAY
A STEP TO WEALTH
华尔街见闻
见闻历创意组/编著
2027
见闻历
EVERY DAY
A STEP TO WEALTH
06
TRADER
MODE
投资，
不打无准备之战
09

一份放在对方桌上
365天的心意

新年礼赠 | 客户答谢
亲友相赠 | 企业年礼

2027见闻历 品质升级

01 内页纸张升级
触感细腻 | 翻阅舒适

02 高质感金属环
做工精致 | 翻页顺畅

03
磁吸双开礼盒
开合顺滑 | 阻尼适中

设计参数

见闻历尺寸	100*170*40mm	页数	378
外包装尺寸	220*115*75mm	外盒样式	双开礼盒
材质	触感纸、双胶纸等	工艺	烫金等

⚠ 手工测量，可能存在误差

包装清单

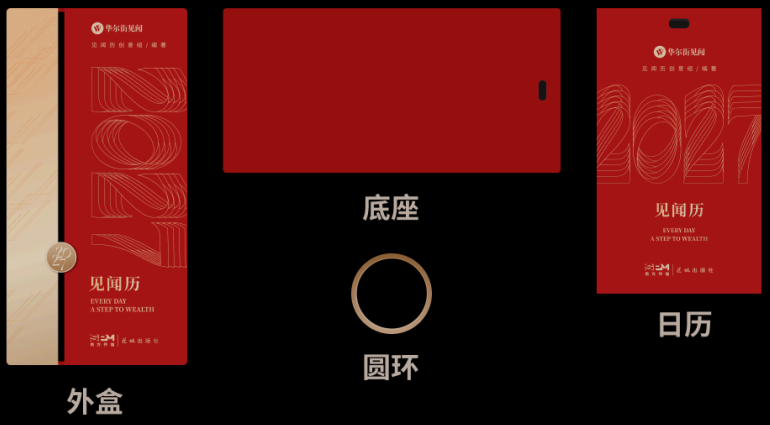

2027

见闻历

WALLSTREETCN

企业定制

为企业提供1V1礼品设计服务

打造一款年度硬核好礼

见闻历 | 联名定制

起订数量：100

外盒腰封

可定制企业logo
（以联名方式）

日历底座

可定制企业logo
（以联名方式）

见闻历 | 轻度定制

起订数量：100

外盒

可定制企业logo

日历封面

可定制企业logo

日历扉页

可定制企业logo

企业slogan或者CEO语录
（字数限制100~200字左右）
企业二维码

见闻历 | 深度定制

起订数量：1000

外盒

可定制企业logo

日历封面

可定制企业logo

日历扉页

可定制企业logo
企业slogan或者CEO语录
（字数限制100~200字左右）
企业二维码

日历内页

名人名言或月历页内容可替换

内页替换数量：
60页内（需企业提供）

定制详细扫码咨询
需提前三周下单 | 不接急单
保存或转发图片打开扫码

支 持 小 批 量 定 制

外盒 | 封面 | 扉页 | 底座

企业年礼 | 客户礼赠 | 员工福利

合作联系：shijianliu@wallstreetcn.com

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

530 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

10 条评论

MobileUser9379
10-20 12:14 中国山西省

内容主要是服务股票知识。 能弄一套 服务期货得吗?

1 回复

见闻用户
10-14 03:54

用了很多年的见闻历，内容一直做的很用心

1 回复

七七七七七七七
10-14 03:42

从第一本开始我就买了，一本不落，继续支持

1 回复

见闻用户
10-13 02:26

救命，怎么感觉一年又要过完了

1 回复

吃肉冠军
10-13 02:23

有人买过前几年的嘛，质量咋样

1 回复

抹茶牛奶 10-13 02:30 中国上海

回复 **吃肉冠军:**

我每年都买，质量不错👍

0 回复

摘要：

民主党已明确部署三大调查方向：马斯克旗下企业获取的联邦合同利益冲突、主导DOGE期间的"破坏性遗产"，以及星链干预乌克兰战场通信的国家安全指控。马斯克强硬回击，誓言追查民主党"幕后操盘者"，并斥资数亿美元力保共和党守住国会——一旦共和党失守，特斯拉、SpaceX等核心资产将面临系统性审查。

马斯克与民主党之间的政治对决正在急剧升温。随着美国国会中期选举临近，民主党人已公开放话，一旦夺回国会控制权，将对马斯克发起全面国会调查，并祭出被外界称为“史上最大规模传票”的法律手段。马斯克则以强硬姿态回击，誓言反击到底，并正斥资数亿美元力保共和党守住国会席位。

据媒体报道，民主党正筹备对马斯克旗下企业及其政府活动展开大规模国会调查，调查范围涵盖其联邦政府合同、领导"政府效率部"（DOGE）期间的相关行为，以及涉嫌干预乌克兰军事通信等多项指控。

纽约大学教授Scott Galloway在其播客节目中预言："11月4日之后，你将看到史上最大规模的传票和国会听证要求砸向他。"资深科技记者、马斯克批评者Kara Swisher随即附和："对，百分之百。他们已经说了，这是板上钉钉的事。"

面对步步紧逼，马斯克在X平台上以"以剑为生，以剑为亡"（Live by the sword, die by the sword）作出回应，并警告称将追查“真正幕后操盘者”，而非仅针对“傀儡”。与此同时，马斯克正向维持共和党国会多数席位的政治行动倾注数亿美元资金，将这场政治博弈与其商业利益深度捆绑。

民主党锁定三大调查方向

据媒体周二报道，民主党高层正就三条主线推进对马斯克的调查部署。

其一，联邦合同与利益冲突。民主党议员Rep. Pramila Jayapal（华盛顿州）直接点名质疑：“当一个人从政府拿到巨额合同，却反过来利用这份合同切断对美国至关重要的乌克兰战场通信，这意味着什么？”这一表述直指马斯克旗下星链（Starlink）卫星服务在乌克兰战场上的角色争议。

其二，DOGE的“破坏性遗产”。马斯克主导的政府效率部曾大刀阔斧削减联邦开支、取消政府合同、压缩联邦雇员规模。民主党议员Rep. Greg Meeks（纽约州）表示：

> “国会必须要求对马斯克和DOGE造成的损害进行全面清算，我们不会允许任何人阻挠我们的监督职责。”

其三，乌克兰军事通信干预指控。民主党人将马斯克在乌克兰冲突中的通信决策列为重点审查对象，认为其中存在潜在的国家安全风险与利益输送问题。

马斯克强硬回击，誓言反制

面对来势汹汹的调查威胁，马斯克并未选择低调应对，而是公开宣示反击立场。**他在X平台发文称，将深挖“真正拉线的人”，而非仅仅应对台前的“傀儡”**，措辞强硬，暗示将把政治攻势延伸至民主党内部更深层的权力网络。

马斯克此前亦已明确表态，若民主党在11月选举中重夺国会控制权，他将采取报复行动。这一表态将其个人政治命运与共和党的选举结果直接挂钩。

在政治防御层面，**马斯克正将资本力量转化为选举筹码。**据报道，他正向维持共和党国会多数席位的相关政治行动投入**数亿美元**资金。

分析认为，这一举动的逻辑清晰：共和党若守住国会，民主党的调查议程将无从落地；一旦民主党翻盘，马斯克的联邦合同、DOGE遗留问题乃至其商业版图都将面临系统性的国会审查压力。

对投资者而言，特斯拉、SpaceX等马斯克旗下核心资产的政策环境，将在相当程度上取决于11月选举结果。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

147 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

亚马逊CEO Andy Jassy透露，即便今年砸下2200亿美元巨资，仍有大量需求未被满足，AI算力到2028年都已基本售罄；AI业务年化收入超250亿美元，是AWS初期增速的数百倍。他直言，解锁企业级AI大市场必须将推理成本再降十倍，这正是死磕自研芯片的核心逻辑。

近日，亚马逊CEO安迪·贾西（Andy Jassy）作客知名风投a16z的播客节目，与a16z联合创始人Ben Horowitz进行了一场深度对谈。在这场访谈中，贾西全面揭示了亚马逊在生成式AI浪潮下的战略全景。

面对华尔街对科技巨头无底洞般资本支出的担忧，贾西给出了最直接的市场反馈：需求不仅没有放缓，反而正在极速透支未来的产能。同时，他详细拆解了目前AI市场的“杠铃型”需求结构，并明确指出，要真正解锁企业级的AI应用，算力推理成本还必须再降一个数量级。

“即使砸下2200亿美元，我们仍把大量需求留在了桌面上”

市场当前最关注的核心问题，是巨头们动辄千亿的资本支出是否会变成过剩的沉没成本。贾西用一组惊人的订单数据直接回应了市场的疑虑。

“即使今年花费2200亿美元，我们仍然把大量有意义的需求留在了桌面上。”贾西在访谈中直言不讳地指出当前算力极度供不应求的现状：“我们总是会为按需服务保留一定比例的算力，但2026年的产能显然已经售罄，2027年也基本售罄，甚至2028年的很大一部分也已经卖光了。”

从业务增速来看，AI带来的增长曲线极其陡峭。贾西对比了AWS（亚马逊云服务）早期与当下的发展速度：“在AWS刚起步的前三年，我们觉得自己增长很快，当时的年化收入运行速率大约是6000万美元。但在这一波生成式AI浪潮的前三年里，我们在AWS的AI业务年化收入运行速率已经超过了250亿美元。它的速度是当年的几百倍，我们从未见过类似的情况。”

针对资本市场的担忧，贾西解释了数据中心投资的现金流周期逻辑。他表示，数据中心建筑的投资需要提前两年，但使用寿命长达30年；而服务器和网络设备的采购则只需提前几个月。这意味着公司对客户需求有非常清晰的能见度。“如果你发现实际上不需要填满那些数据中心，你就不会去买服务器和网络设备。大部分服务器协议都是五年期，通常三年就能实现盈亏平衡。由于这种现金周期的存在，当你以如此快的速度增长时，早期的自由现金流确实会面临逆风，但一旦全部上线，回报将非常可观。”

驳斥数据中心争议：“高尔夫球场两天的耗水抵我们一年”

在美国本土，数据中心的能耗和环保问题正演变成一场政治争议。贾西对此予以了强硬回击，并将其上升到了国家竞争力的宏观层面。

“我们正在经历的基础设施建设，其规模堪比上世纪50年代美国建设高速公路和桥梁。国家乃至整个世界都承受不起不建数据中心的代价，否则我们将发现像中国这样的国家会确立所有的领导地位和规范，这对我们无论是国内还是全球层面来说，都是不可接受的。”

对于环保指控，贾西抛出了极具冲击力的数据事实：“现在有很多介于神话和谎言之间的说法正在传播，因为政客和投机者喜欢找一个简单的‘反派’。事实上，高尔夫球场或杏仁种植业消耗的水量远超数据中心。作为一个数据点：高尔夫球场消耗的水量是我们的200倍，它们两天用的水比我们数据中心一年用的还多。”

他还补充道，备用发电机的污染也被严重夸大：“你必须按照全天候满负荷运行来注册申报污染量，但实际上我们每年只运行备用发电机0.1%的时间（约10小时）用于维护。”

AI需求的“杠铃效应”与降低推理成本的核心逻辑

在拆解具体的AI需求时，贾西提出了一个生动的“杠铃”理论，这也解释了亚马逊为何坚持自研芯片的战略。

“杠铃的一端是AI实验室，他们正在消耗我见过的海量算力；另一端是企业，主要利用AI来降低成本和提高生产力，比如自动化客服或业务流程。而杠铃的中间，是企业目前的生产工作负载。绝大多数企业还没有普及（AI推理），但我认为5到7年后，几乎所有现存的企业应用都将深度使用推理技术。”

然而，要激活“杠铃中间”的庞大市场，价格是最大的绊脚石。

“过去几年，推理成本已经下降了不少，但在我看来，它仍然贵了一个数量级（an order of magnitude too expensive）。”贾西强调，“如果你要求企业用AI加速器重写他们现有的CPU应用，如果成本差异巨大，他们重写的门槛就会非常高。但如果你能把推理成本降下来，门槛就会大幅降低。这就是为什么我们要在自研芯片业务上发力。”

贾西高度评价了2015年收购芯片设计公司Annapurna Labs的交易，称其为“亚马逊历史上最成功的一笔收购，甚至没有之一”。他透露，通过自研的Graviton处理器（性价比比其他x86高出40%）和Trainium AI加速器（性价比高出30-40%），亚马逊正在强行拉低算力成本。

组织重塑：6名工程师干了40人一年的活，所有产品必须推倒重来

除了向外输出算力，AI正在从内部重构亚马逊这台庞大机器的运转方式，首当其冲的就是人员架构和产品开发逻辑。

贾西分享了一个令人震惊的内部案例：Bedrock（亚马逊AI推理服务平台）团队仅用6名工程师、耗时76天就重构了推理引擎，而这在过去需要40个人花上一整年的时间。

“这让所有人大开眼界。”贾西直言，“未来，做同样工作的人类将会比今天少。 我不是说不需要人了，但随着业务规模扩大，我们不会再像过去那样投入那么多的人力。团队会变得更小，人们需要跨职能工作，因为模型能帮你完成80%的工作。”

在产品层面，贾西认为渐进式改良已经走不通了，必须拥有“从头开始重构”的魄力。

“对于像Alexa这样的产品，它的‘大脑’在开发时非常具有创新性，但因为生成式AI的出现，能力的边界已经完全不同了。如果你想拥有制胜的客户体验，你必须重新接入（rewire）Alexa的大脑。”

不仅是Alexa，贾西指出，亚马逊的零售、Prime Video、音乐等所有核心消费者体验，都必须在未来几年内结合AI进行彻底的重新构想。“团队往往会因为骄傲和历史包袱而抗拒，说‘我们试过那个，行不通’。但这（重构）是必须经历的痛苦，如果只想着渐进式改善，三五年后你就会被淘汰。”

以下为播客全文翻译：

> Andy Jassy 00:00
>
> 即便今年要投入 2200 亿美元，我们仍然把相当可观的一部分需求留在了桌面上。我们总会留一部分产能给按需使用，但 26 年显然已经售罄，27 年基本售罄，28 年也有相当一部分已经售罄。
>
> Andy Jassy 00:14
>
> 金融市场在说，哎呀，世界上没有那么多钱来给这些东西融资。可我们今天在这个世界上做的每一件事——股市、银行、医疗——它们都在用数据中心。我们的工作就是想办法拥有尽可能多的产能；我们有这个机会，去覆盖多得多的客户体验，让他们的生活每天变得更好、更轻松。那些大型实验室愿意为电力、散热和芯片付出几乎任何代价。嗯，也许我们应该把老客户买出来、再卖给新客户，因为他们出价随我们开。
>
> a16z 00:48
>
> Andy，欢迎来到节目。很高兴你能来。谢谢你们的邀请。那么，你执掌亚马逊已经五年了，做了很多事。能来到这里本身就很不容易，作为 CEO 也有很多事情在接连推进——你现在手上是 2200 亿美元的资本开支，AWS 增长了 20%、28%。嗯，嗯，你确实已经做了很多。
>
> Andy Jassy 01:09
>
> 你已经实现了这么多，那么你怎么看待 2026 年亚马逊的雄心——相对于 2021 年你正式接任 CEO 的时候？哦，2021 年感觉已经是很久以前的事了，感觉就像、你知道的、像十年前一样。但是，你知道的，世界变化太快了。而且，你知道的，就是……
>
> Andy Jassy 01:30
>
> 如果和 2021 年相比，我们的整体营收大概高出 80%，AWS 业务大概接近三倍，广告收入大概是两倍半。所以这门生意，你知道的，增长得相当多。
>
> Andy Jassy 01:47
>
> 我觉得确实发生了几件事。在我刚上任不久——那正好赶在疫情尾段——我们的零售业务遭遇了一个真实的履约成本难题：我们基本上把履约网络的规模翻了一倍。我们用 25 年建起来的网络，在大约 18 个月里把规模翻了一倍；接着又在大约 20 个月里，建成了一个规模相当于 UPS 的末端配送运输网络。而只要你建得这么快，就一定会留下各种各样没有优化到位的东西。我们在履约网络里的履约成本，并不是我们想要的样子。嗯，你知道的，这在当时带来了很多挑战、很多焦虑。我记得那会儿我上任也就一年左右、还不到一年，大家都在说：哎呀，这个时候接手真是最糟糕的时机，运气太差了。可是现在回头看，我觉得那其实是一个非常好的开始时机，真的是一种福气——因为它逼着我们去考虑一大堆本来可能很多年都不会去考虑的事情，而那些事

情对我们的客户、对我们的业务来说都是非常好的想法。其中最大的一件，就是我们的履约网络：我们把这个原本扁平的全国性履约网络在美国做了区域化改造。通过区域化，我们把商品放得离客户近得多，结果不仅因为运输距离更短而降低了履约成本，同时送达客户的速度也快得多。嗯。在那个我们为履约成本苦苦挣扎的阶段，重新审视我们那些最根深蒂固的信条，真正释放了配送速度和零售业务里的大量需求，也是我们在那里能增长得这么快的一个重要原因。当然，你知道的，紧接着就是 AI 如何进一步引爆全场。并不是说 AI 是什么新东西——我们大家做机器学习已经很久了，此前也有过好几波被认为“真正的转折点”的 AI 浪潮。但当你走到 2023 年，你真的会看到生成式 AI 带来的巨大不同。我想说的是，当时我们的 AWS 业务已经增长得非常快了。我们有、你知道的、明显最广的功能覆盖、更强的运营表现和安全性，而且我认为还有一种不一样的伙伴生态。我们是明确的领导者，我们当时觉得，这门生意在很长一段时间里——假设十年以上——能做到几千亿美元的收入。现在我们再看 AI 正在发生的一切，再看我们所知道的每一种客户体验都将因为推理和 AI 而被重新发明，我们实际上认为，AWS 业务不仅增长非常快——上个季度我们同比增长了 36.7%，而且是在 1690 亿美元年化收入的体量上——今天摆在我们面前的机会真的非常惊人。而且你知道的，我觉得如果你再往上叠一层，我们有那些新业务的种子：不管是团队把 Prime Video 做成了什么样——它现在已经是规模很大而且盈利的业务；还是我们正在用 Amazon Leo 建设的低地球轨道卫星；或者是和 Zoox 一起做的自动驾驶网约车服务；还有医疗业务，以及我们在机器人领域做的事。你知道的，我们真的有机会去帮助多得多的客户，覆盖多得多的客户体验，让他们的生活每天变得更好、更轻松。而这个“努力让客户的生活每天变得更好、更轻松”的使命，真正把我们在公司各处所做的事情统一在了一起。那么关于这个我有几个追问。其一，你刚刚提到，当你这么快地扩建履约网络时，它必然会有点低效。你知道的，当你推进得这么快，就一定会有些粗糙的地方。那么你是怎么——而且你还提到内部围绕这件事有些焦虑——从一个 CEO 的视角，你要怎么去沟通你在做的事，同时又不拉低文化标准？我的意思是，亚马逊是以卓越、以运营效率、以节俭著称的，所有这些东西。可你现在说的是：我们要建一个 UPS 那样的东西，诸如此类。那么你是怎么把这两者调和起来的？嗯，有意思的地方在于，我们有这套很多人都知道的领导力准则，一共 16 条。很多条准则，它们本应、也确实在支配我们作为一个团队在运营和文化上的思考方式。但其中有好几条彼此之间是存在张力的，有时候人们会为此感到困惑。可现实是，这恰恰反映了真实世界的运作方式——没有任何事情是真正干净利落的，你永远在做取舍。所以回到当时那个时刻，当我们决定以那么激进、那么快的节奏去扩建履约网络和末端配送运输网络时，团队面临的问题是：我们知道，如果推进得这么快，会非常艰难；成本很可能比慢一点做要高；我们也很可能没法把每件事都做得像慢一点做时那么优化。但客户和卖家真的非常需要它。所以，我们到底要不要偏向“先把它做起来”这一边？你要记得，那时候是疫情早期，所有的实体店都关了。我是说，如果你看看亚马逊在疫情期间在每个人生活中扮演的角色，那是非常具有开创性意义的。所以我们必须问自己：我们是不是要建得快、也许做得没那么优化，以此来换取服务好那些客户和卖家——那些卖家当时也在努力让自己的生意维持下去？这是你首先要做的决定。而我们决定，就像我们几乎一贯所做的那样，偏向客户这一边。你知道的，接着，在建设过程中很快就很明显了——我们规划的事情并不是每一样都进展得很完美。我们有、你知道的，我们的履约团队比公司其他大部分部门更常在办公室里。但即便如此，还是有大量的人需要参与到大量的设计、规划和评估中。人被分散在各处、远程办公，然后你还要去平衡“崇尚行动”或者说速度，与“坚持极高标准”之间的组合或者张力——后者意味着你要按自己一贯规划的成本结构、交付方式和设计去交付。所以你又得做取舍。我们的取舍是站到客户这边、快速推进，以便服务好卖家和消费者，而且我们当时就想到后面会有一定量的清理工作。那么，我们当时是否确切知道最终会演变成后来那样？没有。也有一些东西是我们没有优化到位的，而我不确定我们事先预见到了它们不会被优化。但如果你有好的度量指标，如果你的文化是一个讲真话的文化——这也是我们文化中另一个非常重要的部分——我们，你知道的，会把数据摆到桌面上，把问题摆到桌面上，彼此直接沟通，我们不允许别人把问题粉饰过去。如果你有这样一种文化，那么在指标上会相当明显，在讨论中也会相当明显。然后你只要去想办法怎么改进它，分清哪些只是些小的效率问题，哪些是架构性的问题。等我们把那批产能装上之后，我们回过头去真的重新架构了网络的关键部分——那件事当时在那个团队的优先级清单上大概排第八、第九位，但后来变成了重要得多的优先级，因为它能真正拿到速度和成本的组合。是的，很有意思。你知道的，有点像最开始，当你创办 AWS 的时候——你创办 AWS，那时候的套路有点像“建好了他们就会来”，对吧？你在建这一整套基础设施，然后你去运营它。所以他们必须得来，否则你就麻烦大了。但现在这件事是在一个大得多的规模上重演：你和其他一些公司——不过我得说，主要是你，至少你肯定是最大的玩家之一——正在以如此之快的速度建设数据中心和芯片产能，以至于金融市场开始说：哎呀，世界上没有那

么多钱来给这些东西融资。然后，我们前阵子在 CoreWeave 的债务市场和股权市场等等地方，就看到了那种紧张情绪。所以你怎么判断——考虑到需求这么陡峭、你增长这么快——这轮建设到底建到多少才算太多？而且供应链上还有争夺，你要去抢你的散热、电力、芯片所有这些东西。是的，这是个非常好的问题。我真希望有个公式能把它变简单，那能替我们团队省下大把时间。嗯，我想我会这么说：在云的第一波浪潮里，当我们创办 AWS 的时候，确实有一点点“我们不知道人们会不会用它，所以先建好了他们就会来”的味道。但我们在公司内部有很好的信号。当时，你知道的，大约是 2000 年代早期那几年，我们有不少团队的推进速度远没达到我们的期望——尽管相对而言我们已经觉得自己够快了。但我们就是搞不明白为什么要花那么久。原因其实是，我们的产品团队把 70% 到 80% 的时间花在了基础设施那部分工作上，而那部分并不能让他们形成差异化；只有大约 20% 的时间花在真正让产品有差异的部分上。于是我们、你知道的，我们意识到每个团队都在重复做这件事、都在重新发明轮子。所以我们最初构思 AWS，是为了让我们自己在内部能跑得更快。我们当时的判断是：如果我们建一套大规模、高可用、低成本、高度灵活的基础模块服务，比如计算、存储、数据库、内容分发、消息等等，我们就能在消费者业务里建得快得多。然后我们只是说，相对而言我们技术还不错，其他公司大概也有同样的问题。但甚至在我们对外发布之前，公司内部就有那么多团队感兴趣，我们就知道方向对了。我不认为我们当中有人预料到它在外部会增长得那么快。在 AI 这边，你知道的，正如你所知，此前出现过一波又一波的人说：就是现在了，AI 终于来了。甚至在生成式 AI 这波浪潮之前大概六七年，人们就觉得那是 AI 的时代。我们建了一大堆 AI 服务，在 AWS 那边其实是一门相当不错的生意。但跟我们现在看到的完全没法比。在 AWS 的早期，我们、我们觉得自己已经增长得非常快了，而且对此感觉不错——三年之后，我们做到了大约 6000 万美元的年化收入。而在生成式 AI 这波浪潮的头三年里，光是我们在 AWS 里的 AI 业务，年化收入就超过了 250 亿美元。所以它快了几百倍。这个、我们真的从没见过这样的东西。于是问题就变成：你想投多少资本开支去追逐这个机会？我能告诉你的是，我们说过，2026 年我们预计要花大约 2200 亿美元的资本开支。顺便说一句，我记得大概 15 年前在一次领导团队早餐会上，我们当时无法相信有电信公司会花 500 亿美元做资本开支，我们当时说：他们怎么能花这么多钱在资本开支上？所以这些数字，你知道的，真是让人脑子发麻的数字。而即便今年要花 2200 亿美元资本开支，我们仍然把相当可观的一部分需求留在了桌面上。在这里真正帮到我们的是，我们对客户需求有很好的可见度。所以如果你去看 AWS 的资本开支投资以及现金周期的运作方式，它有两大块：一块是数据中心的投资，另一块是服务器和网络的投资。数据中心这一块，你必须、你知道的、提前大约两年投入，之后你才能在数据中心里放上服务器并开始变现。好消息是，这笔投资你只需要做一次，它是一个使用寿命资产，大约 30 年。但你得提前几年做这笔投入。服务器和网络设备则只需要提前几个月，视具体部件而定。所以在你真正扣动扳机之前，你对客户需求有很好的可见度。如果最后发现你其实并不需要那些产能去填满这些数据中心，你就不会去买服务器和网络设备。平均而言，它们、你知道的、大约三年就能回本，而目前它们的使用寿命大约是五到六年。我们做的大部分交易都是大约五年的。所以当你像我们这样同时建这么多数据中心、建得这么快时，你会花掉大量资本，而且你的自由现金流在那些年份会承受逆风——直到几年之后走到那个后期阶段：所有这些数据中心都上线了、都在变现了、你从服务器和网络投资里把钱赚回来。但由于现金周期的运作方式，在你增长得这么快的头几年，它确实会带来逆风。那么顺着这个说，你知道的，回到你创办 AWS 的时候，数据中心大概是世界上你最不可能相信会变成一个政治议题的东西。可我们现在就处在这样一个局面里，尤其在美国。你知道的，这挺有意思的，我相信你也经历过——世界上没有哪个地方的人，会比美国政治圈那样反数据中心，不管出于什么原因。所以你，你知道的，这种情况最终会怎么影响这件事？我想问的是，反数据中心的论点有任何道理吗？然后，这又会如何反过来影响你的策略——你在这里建什么、你在其他地区建什么？嗯，好的，我可以给你一些我所掌握的、至少是我所相信的背景。你想想，我们今天在这个世界上做的每一件事——股市、银行、医疗、娱乐、购物、教育、商业、网约车——我们所做的一切都是数字驱动的，它们都在用数据中心，说白了就是这么简单。不，每个人都是；我反对的是我自己，我再也不想用我的手机了。可它们都用数据中心。而这还只是在 AI 之前。AI 是我们这个时代最大的技术变革——考虑到我们经历过互联网、云和移动互联网，这么说是有分量的。所以现实是，为了支撑我们刚刚谈到的 AI 侧那种高速增长，我们所需要的这类基础设施建设，在这个世界、在这个国家，大概自 1950 年代我们修建高速公路和桥梁以来，就没有出现过能与之相比的东西。我是说，我们现在正在经历的，就是那种量级的建设。而这个国家——我认为整个世界大体如此，但我要特别说美国——承受不起不建数据中心的代价，否则我们会发现，像中国这样的另一个国家会把所有的领导地位和所有规则都确立在那里。我认为我们谁都不会喜欢那样，无论在国内还是在全球。所以我们现在必须建数据中心。那么，我是否认为

作为整个行业，我们有办法做得比现在更好？当然。我觉得事情发展得很快，大家都在共同学习。但现在有一批——我会称之为介于迷思与不实之词之间的东西——正在被传播，因为这是那种人人都能找到一个现成“反派”的议题。在政治上，有时候机会主义者喜欢去找出那个反派来指指点点。我可以给你举些例子。高尔夫产业或者杏仁种植产业消耗的水，比数据中心多得多。就给一个数据点：高尔夫球场这样的场所，耗水量是我们所有数据中心的 200 倍；它们两天的耗水量，比我们数据中心一年的耗水量还多。所以这类例子有很多，这是个很好的例子。或者你可以谈污染。实际情况是，当你注册新的场址、配备备用发电机时，你必须登记并申报：如果你把这些发电机全部满负荷、全天候运行，排放量会是多少。但当然，这种事从来不会发生。备用发电机一年只运行千分之一的时长，比如一年 10 小时用于维护。所以，你知道的，或者你谈电价——如果你去看我们有大规模数据中心布局的不同地区，有些地方的电价涨了，有些地方的电价降了。但真正的问题是：作为一个国家，我们没有以应有的方式投资我们的电网基础设施。这里必然会有可观的增长，所以总有什么东西会把它推到需要投资的临界点。结果就是 AI——因为它增长得如此之快、体量如此之大——成了那个把它推过去的东西。但等你真的把产能建起来，你会发现，在大多数地区，电价最终会走平甚至下降，就像在印第安纳州、佐治亚州或密西西比州发生的那样。所以，是有一些我们能做得更好的地方。另外人们容易忘掉的一点是：在这些地区，大型数据中心供应商缴纳了大量税收。你看，就拿印第安纳州的圣约瑟夫县来说，我们已经缴纳了大约 30 亿美元的税。社区拿到了这笔钱，可以把它花在对这些社区真正重要的事情上。所以社区也从中得到了回报。我们建了一些项目，比如 Built Together（共建），我们刚刚承诺在未来五年里，再向那些我们有数据中心布局的社区投入 10 亿美元。所以我认为，我们必须持续和社区一起努力推进这件事。它必须是一种公私合作伙伴关系。但这轮建设对这个国家的未来太重要了——想象一下，如果我们当初没有把高速公路建起来会怎样。

a16z 20:44

以及桥梁——那会决定这个国家的经济繁荣与能力边界。所以我们要把它放在一个合理的视角里看待，而且我们必须成为我们所建设社区的伙伴。我们再回到资本开支这个问题上。那 2200 亿美元，也就是每天 6 亿美元。我只是想、你知道的，把它放到一个参照系里。我很好奇你现在怎么看待 AI 需求——我们私下聊的时候，你把它形容为一个……

Andy Jassy 21:10

杠铃（barbell）结构。也许你可以梳理一下、或者说定位一下当下 AI 需求的状态。嗯，我想说，第一个背景就是我前面讲过的——我简直不敢相信 AI 长得这么大、这么快。你知道的，它比 AWS 初期快了几百倍；头三年，我们在 AWS 里光 AI 收入就做到了 250 亿美元的年化规模。所以它真的非常大。但同时，如果你看需求的结构，它真的是一个杠铃。杠铃的一端是那些 AI 实验室，它们在消耗海量、海量的算力，规模之大是我从未见过的。然后还有少数几个爆款应用，ChatGPT、Claude Code，诸如此类。

Andy Jassy 21:59

杠铃的另一端是企业，它们主要在用 AI 做成本规避和提效，比如把客服自动化、反欺诈、或者业务流程自动化。杠铃的中间，是企业当前的生产型工作负载，其中很多跑在 AWS 上、今天已经在用推理了。但我要说的是，其中绝大多数还没有以任何渗透性的方式用起来——你知道的，而我认为那会成为 AI 使用中绝对值最大的一块。我认为你会看到这一点。

Andy Jassy 22:38

我很难预测这件事发生的速度。它、你知道的，每一年都在更大程度上发生。但我觉得如果你把视角拉远——五年、五到七年——去看看那会是什么样子；而且我不认为它会等到五到七年之后才发生，它从来不会一蹴而就。但如果你能把视角拉远到五到七年，我认为相当多、甚至是我们今天使用和存在的多数企业应用，都会以渗透性的方式用上推理。所以我们面前还有大量的增长空间。那么你是怎么看待这件事的？因为我们正面临一场即将到来的数据中心、芯片、内存——所有东西——的短缺，而且真的就在 2027 年，因为大家现在都在建，但到今年年底未必能就

绪，而需求一点都没有放缓。所以面对这种情况你怎么想——当那些大型实验室愿意为电力、散热、芯片付出或许任何代价、几乎任何代价的时候，那种环境；而你又有这些已经存在很久的老客户在按常规费率付费来运转他们的业务。有没有一种商业压力会让你想：嗯，也许我们应该把老客户买出来、再卖给新客户，因为他们出价随我们开？而老客户呢，我又不能把他们的价格翻一倍，那不公平。或者，你是怎么看待这件事的？因为这实在很奇怪——你有一批在你这里待了 20 年的人，做着一件、如你所说、大概会走向推理的事情；然后你又有这些新客户，他们贪得无厌，什么东西都愿意买。

Andy Jassy 24:35

是的，这是个好问题。你知道的，我们看待这件事的方式跟你说的那种不太一样，但我完全能理解。如果你想想，今天的数据中心和电力就这么多，内存也就这么多，而且我不认为这种短缺会在 2027 年结束。我认为、我相信——回到资本投资这个话题，我之所以觉得我们可以投得多得多、而且那不会是糟糕的资本使用，其中一个原因就是：26 年在这个时点显然已经售罄，27 年基本售罄。我们总会留一部分给按需使用，无论是在我们的推理服务 Bedrock 里、还是在 EC2 里——但基本都售罄了，所有的大块都售罄了。28 年也有相当一部分已经售罄。需求就是这么大，你没法……我们有，如果你看 AI 业务和我们所谓的核心业务——核心可以理解为非 AI 部分——它们现在都在以非常快的速度增长。而且你知道的，如果你手上的内存只有那么多，你就得决定要把多少内存分配给 HBM、也就是给 AI 加速器，又有多少分配给 DRAM、也就是给你的核心业务。所以这些都是你必须做的真实取舍。但我要说的是，我们在这件事上的出发点是客户至上。对我们来说，我们在 AWS 里和客户有着深厚的关系和合作。就像疫情期间那样——当时我们的竞争对手，我认为他们在想的是怎么在一个季度内做优化，以便在一个所有人都要做成本优化的世界里尽可能多地推高收入；而我们采取了不同的做法。我们主动让我们的团队走出去，帮客户想办法做成本优化，尽管我们知道这会削弱我们短期和中期的收入。但你知道的，我们要帮客户成功，因为我们非常坚信：如果我们长期帮助客户，我们的业务也会随之而来。在核心业务上，这也是同样的道理。我猜你确实可以做一番计算，然后认定：由于稀缺性和客户的支付意愿，你可以从核心客户身上多挤出一些钱。但他们是把自己的生意跑在 AWS 之上的，他们所有核心应用都跑在上面。我们不会去挤压我们的客户，我们会确保他们能够扩展。然后我们的工作，就是想办法拥有尽可能多的产能，让不仅是我们的核心客户，还有所有想在我们这里用 AI 的客户、以及那些想用我们做 AI 的人，都能用得上，而且是以一种对我们而言经济上也可持续的方式去做。所以，我真希望我能告诉你，供应紧张只会是 2027 年的问题；我认为在不同部件上，我们会连续几年看到它。我们一直很进取，我认为我们投放的产能大概比任何人都多，因为我们真的很投入、非常执着于继续做基础设施和 AI 领域的重要领导者，就像我们一直以来的那样。但正如我所说，我们今年要花 2200 亿美元，而且我们本来可以花得多得多。那不会是糟糕的资本使用。而且从中期到长期看，我认为我们大概仍然满足不了全部需求。现在的需求实在是太惊人了。那么接着这个话题说，你在 2015 年做过一件事——你收购了 Annapurna Labs。那时候你大概还没有在想 2015 年会有巨大的 AI 需求，因为 2015 年的 AI 需求本来就不多。那么是什么驱动了那笔收购的决定？然后它在这个新世界里又是怎么产生回报的？是的，我觉得，Annapurna 团队是我有幸共事过的最有才华的团队和一群人之一，它是我们在亚马逊历史上做过的最好收购之一，如果不是最好的话。是的，我们预见到了其中的一些部分，但我并不认为我们当初收购 Annapurna 是专门冲着 AI 芯片去的。是这样的：当你达到一定规模，你就能接触到、看到客户在极大规模下的行为模式，你会意识到，如果你能做垂直整合、能自己建某些能力，你就能为客户提供更多价值，也能为业务本身带来更好的经济性。所以 Annapurna 在我们这里的起点，只是围绕核心的 EC2 服务器：我们觉得我们把太多的服务器资源花在了虚拟化、网络、安全和存储上，而我们希望几乎能把 100% 的服务器资源都用于给客户提供计算。所以我们在收购他们之前，就已经和 Annapurna 一起做这个网卡（NIC）——把这些组件卸载到网卡上，好让我们尽可能多地把服务器留给计算。我们非常喜欢这个团队，也非常喜欢我们一起合作做出来的那款产品。我们意识到我们要买的那个东西，最终会装进几乎每一台 EC2 服务器——结果它确实装进了我们所有的服务器。所以我们最初收购它，是因为那将成为我们计算能力的一项核心能力；也因为这个团队在造芯片上太有才华了，我们觉得他们大概也能造别的芯片。那时候，我们和英特尔有着非常深的合作关系——我们到现在依然和这家公司保持着深度合作。但问题是，英特尔当时几乎握有全部 CPU 份额；而当你有一个握有几乎全部份额的伙伴时，他们往往不会去想怎么提升性价比，他们会去想别的、能让他们拿到更多份额、带来更多收入的功能。顺便说一句，这完全可以理解，这就是市场运作的某些动态，也是“创新者的窘境”出现的一

部分原因。所以我们当时想在性价比上推一把，却很难得到对方的重视。但我们有客户想把越来越多的本地工作负载搬到云上，他们想要更好的性价比。于是我们让 Annapurna 团队去做的下一件事，就是造一颗 CPU 芯片。他们做出了 Graviton——今天我们排名前一千的 EC2 客户中，99% 都在非常广泛地使用它。它的性价比比其他 x86 处理器高出大约 40%，这对我们的客户和我们的业务都产生了巨大影响。然后在几年前，我们在 AI 领域看到了同一部“电影”重演：那里确实有一家非常优秀的主导供应商。我们和它有很深的合作关系——我们现在依然有很深的合作，而且在我能预见的未来都会一直有。但他们有巨大的市场，也有很多正在做的不同产品、不同的优先级。而我们知道我们的客户需要更好的性价比，这就是为什么我们在 Annapurna 里另起一支团队去做 AI 加速器，我们叫它 Trainium，它的性价比也比同类可比处理器高出大约 30% 到 40%。而且你知道的，当我们谈杠铃的中间部分——我们刚才聊到的那个——如果你问：会有哪些事情改变杠铃的中间，让更多当前的企业生产型应用用上推理？有那么几件事。其中一部分是人才：有些人已经习惯做后训练和微调，也需要那种知道怎么排优先级、知道该攻什么、以及怎么做的组织能力。但很大一块在于：过去几年推理成本已经降下来不少，但在我看来，它仍然贵了一个数量级，还不足以让它被尽可能广泛地使用。因为如果你要让企业把今天用 CPU 跑的应用改写成用 AI 加速器，如果两者成本差异非常显著，那么他们为了愿意去重写这些应用，就必须从 AI 加速器上获得非常高的增量收益——那是一个高得多的门槛。但如果你能把推理成本降下来，这个门槛就低得多，而所有应用都会因为 AI 加速器和推理变得更好、更聪明、更强大。所以，对客户能否广泛使用 AI 来说，一个非常关键的环节就是把推理成本降下来，而我们的芯片业务是其中很大的一块。是的，确实。我可以拿我们自己的公司告诉你，它真的会变得非常贵。我们有一位员工在过去几年里花掉了 200 万美元——做的是有价值的工作。但没错，当时的感觉就是：好吧，这个推理还真不便宜。那么，你做过的一件事是做了一些投资，特别是对 Anthropic 和 OpenAI 的投资，规模非常大的投资，我印象里对 Anthropic 是 180 亿美元，对 OpenAI 大概是 500 亿美元之类的。那么是什么让你想去做这些？而且这类投资，加上英伟达等等类似的投资，把华尔街搞得有点神经紧张，因为这让他们想起了互联网泡沫年代那些糟糕的旧时光。你是怎么看待这件事的——尤其考虑到他们同时也是你的客户？为什么这么做是合理的？这两家公司都是非常出色的团队，也是非常出色的公司；它们增长业务的速率——至少在营收端——我不知道我们是否曾见过类似的东西。真的，这简直令人难以置信。所以对我们来说，这是几个因素的组合：这些团队是什么样的团队，他们造出来的技术和模型，以及他们做出来的一些应用；我们相信 AI 有多大的变革性；我们相信它们会在很长一段时间里成为这个领域最成功的两家公司——当然这个领域不会每个人都成为赢家，但会涌现出很多非常成功的公司，而我们相信它们会是其中两家。再就是，我们合作得如此紧密。我先说 Anthropic——我们和它的合作时间更长。我们有非常多客户在我们的推理服务 Bedrock 里跑 Anthropic。而且我认为，客户在 Bedrock 里跑 Anthropic 是最成功的。我们在芯片上和它有深度合作——他们已经在 Trainium 之上构建了一段时间。我认为这对 Anthropic 非常好，对我们的 Trainium 团队也非常好，我认为双方都从对方身上学到了很多。所以我们和它有深度合作——无论是我们对 AI 未来的信念、对这些公司的信念，还是这种合作关系本身，都让我们觉得作为合作的一部分去做投资是合理的。然后在 OpenAI 这边，我们只是有太多客户想在 AWS 上使用 OpenAI，却因为此前的商业安排而无法做到。而且很长一段时间里，我认为两家公司都对彼此怀有很多尊重和合作的意愿。所以这也是那种情况：经过一系列、历时数月的对话之后——能在 Bedrock 里跑 OpenAI；我们一起做了一款独特的产品，就是那个有状态运行时环境（stateful runtime environment），我认为未来所有智能体都会以这种方式构建，你会需要状态；还有他们像 Anthropic 一样，对 Trainium 做出了多年、多吉瓦的承诺。而我们就是相信，它会在很长一段时间里成为这个领域最成功的公司之一。所有这些，都让我们觉得深化合作与投资是合理的。换个话题，谈谈你如何用 AI 来建设一家公司。我记得你说过，Bedrock 团队用 6 名工程师、76 天重建了你们的推理引擎，而那本来需要 40 个人干一年。这差别相当大。而且你知道的，亚马逊以“两个披萨团队”著称。那么现在，你的组织设计思路是什么？考虑到这项技术——它似乎真的改变了一切。这些年来我们变得极度专业化：有设计师、有产品经理、有前端工程师、有后端工程师，这个那个，诸如此类。而现在好像大家又都变成了通才。那么从组织设计的角度，你怎么看这件事？是的，我同意你说的。我认为你提到的那次 Bedrock 经历，对这里的每个人来说都非常开眼界。我们也花了很多时间在内部分享那个故事，去激励大家、提醒人们什么是可能的。因为随着时间推移，最终会发生这样的事——我是 29 年前加入公司的。我从一个助理产品经理做起，当时我一人负责、我不知道、五款产品。而今天，当公司成功、规模变大、产品变大之后，你会走到这样一个状态：一个产品经理只做一个产品，而且只拥有其中一个切片——比如他只负责定价之类的。每个人都变得更专业化，而且每个人都接受：如果你要做大、做成，这就

是必须的做事方式。但这不是，而且当你看 AI 正在发生的一切时，它绝对不是。就拿刚刚过去的一周来说，我们正在做一些事，围绕消费者业务里的智能体。我们在那里有一大堆投入，但我们有一个非常喜欢的想法，我们周四决定要去试试，看能不能做出一个真正能跑的原型。结果呢，我们四五个人在周末动手，到周日就已经让它以 80% 可发布的状态运行起来了。这是真的——那完全是两个不同的世界。所以我认为，这对组织的未来意味着什么：第一，我认为未来做今天这些工作的人类，会比今天更少。你就看现在有多少编码是由智能体完成的，看有多少客服、商业智能和研究工作在被做。是的，你再往前快进想想：表格会怎么被做出来、你需要多少律师——我只是认为，你不会变成没有人，但你不会再需要那么多人类；过去随着业务变大，我们都不停地往里堆人，未来不会是这样了。会出现不同的工作和新的工作，有些我们知道，有些我们还不知道。随着 AI、机器人和太空的发展，它们会涌现出来。会有各种各样的新工作，但做今天这些事的人类会更少。我认为团队会比现在小得多。你会拥有更小的团队，团队里的人能够跨职能工作；你不会只让一个人拥有其中一个小小切片，因为模型能帮你走到 80%。在很多这些不同的职能上，我认为每个团队都会从一个比过去高得多的起点开始，所以我认为你将能够更广泛、更快速地去发明。我确实认为有一大堆事情必须改变。今天成立的初创公司，大多数从一开始就是以智能体的方式、智能体原生（agent native）或者 AI 原生的方式起步的。而所有已经经营了一段时间的成熟公司，都必须搞清楚怎么以同样的速度去构建。我认为它们当中有一部分会搞明白。而且你总有这种情况：当你有一个拥有很多能力和忠实客户群的大生意时，有些公司会非常缓慢地去弄明白，在我看来，它们面对初创公司时会更加脆弱。而我认为，我预测，公司将不得不重写几乎全部代码，让它们具备智能体能力；它们必须允许智能体去更新不同的代码片段，你还得在那里建立约束。我认为单看安全这一块就很有意思。如果你看过去一两个月围绕模型的各种紧张情绪，它们都集中在那些更奇幻的场景上。顺便说一句，那些场景是可能的：有没有可能一个恶意的僵尸网络接管一切？我是说，我想是有可能的；有没有可能给机器人注入恶意意图？都是有可能的。我个人认为，作为一个行业、加上公共与私营部门，我们会一起把这件事解决。但你得从先关注某些事情开始。是的，但有意思的地方在于，我认为关于那些更近期的风险，讨论得还不够——那些风险其实主要是围绕网络安全的。这些模型太厉害了，它们能找出比过去多得多的漏洞，而人类过去根本没找出来。也许你可以争论人类到底能不能找出来，但事实就是他们没找出来。所以往前快进，我认为应用程序响应紧迫安全威胁的方式，必须以分钟计。今天的情况是：你发现漏洞，有人给漏洞分类，有人开发补丁；然后即便这部分做得很快，大多数公司部署也要花很长时间，因为有各种依赖关系。未来你必须以分钟为单位完成部署。所以如果你没有真正把应用重写成可以被智能体更新的形态，在那个新世界里你将毫无机会。所以我认为，所有组织都会被重新发明，而那些优先做这件事的公司，处境会远好于那些不做的。是的，而且看起来，作为一个行业，我们在架构一切东西的时候——从大型系统到嵌入式设备——并没有把安全架构做得很好。而清算的日子到了。不过我认为好消息是，这对新公司、新的尝试、人们去做事来说是一个巨大的机会。但没错，按我们说的，这个威胁——那些理论上的、思想实验式的威胁，嗯，也许会发生，也许不会。但这个是明确而现实的。是的，几乎所有我们在 AWS 侧谈到的合作伙伴和客户，无论规模大小，每家公司都在担心安全这一块。你知道的，我们有一个专业服务业务在帮客户做这件事，我们还建了一个叫 Continuum 的服务，它能识别大量这类漏洞并生成补丁。但这件事，你知道的，说起来容易做起来难。实际上，因为很多公司和很多工程师有时候觉得专注在安全上并不那么令人兴奋，很容易就等到出问题再说。可如果你保护的是重要的数据，那是个坏主意。而且，我认为在大多数公司里——回到我们前面的对话——专业化在安全领域大概是最糟糕的情形：你有这些非常深奥的安全工程师，他们不喜欢和其他工程师一起工作，他们是稀缺资源，诸如此类。结果就是，在大多数公司、大多数软件公司里，它们在写软件时的安全实践就是不太好。我认为这显然必须改变。好消息是我们有能帮助解决这个问题的工具。顺着你说的，好消息在于：你得去雇渗透测试人员，可你能雇到的安全人员就那么多，他们能覆盖到的应用也就那么多。模型加上自动化，会让你能够更好地对整个攻击面做渗透测试，而且你会找到一些如果不是运气好、本来可能发现不了的东西。所以我们观察这个市场时，有一件事挺有意思：用 AI 你可以做很多事。一种是你用它来削减成本，减少你需要的会计师或律师的数量之类的。现在确实有不少风险投资公司在说：好吧，我们去买下那些老公司，削减它们的成本。这一直都不太让我们感兴趣，因为我们会想：好吧，如果那就是你的主意，那你的主意实在太少了。再一种是：好吧，我们要去做一个世界从未见过的东西。那个非常令人兴奋。但还有第三种，就是你做 Alexa 这件事：你手上有一个产品——一个成功的产品——然后你说，好吧，我们从头把这个东西整个重新想一遍，因为我们有了这个新平台。你是怎么走到那一步的？它在什么情况下是合理的？是的，我觉得你把这个三分法划得挺有意思。而且我认为，正如我们刚才谈到的，组织会真正发生变化、变得更精简。如果你做对了，它会让你那些真正优

秀的构建者和这些小团队，去做出你所说的第二类东西——那些人们从未见过的东西，你是能做得到的。而且当你有了我前面讲的那种经历——四天之内就把一个新想法做到 80% 的样子——这对人们太有激励作用了，他们会真的花更多业余时间、更多空闲的思考周期去想新点子。对我来说，这是 AI 正在发生的事情里最令人兴奋的部分之一。但我也认为，对那些已经在规模化地拥有成功客户体验的既有公司来说，如果他们把 AI 主要理解为只是渐进式地改善体验，那么三到五年后，他们很可能不会拥有那些胜出的体验。因为我认为，我们所知道的每一种体验——哪怕是那些看上去最难以想象会被改变的——在几年后都会因为 AI 而变得显著不同。所以这意味着，如果你想要的不只是渐进式改善，你就必须想办法让团队从零开始重新想象这些应用应该长什么样——假设你今天用它所有可用的新技术来建它。在某些情况下，就拿 Alexa 来说，我觉得我们必须这么做是相当明显的。Alexa 的“大脑”在它被造出来的那个时点确实很有创造性。但由于生成式 AI，这个“大脑”所能具备的能力已经完全不同了，所以如果你想提供出色的客户体验、想长期保持相关性，你就必须给 Alexa 的大脑重新布线。所以那件事相当明显。顺便说一句，尽管相当明显，做起来其实很难——因为团队和他们所造的东西是有情感连接的，他们为自己造的东西骄傲，他们对于什么行得通、什么行不通有来之不易的伤痕认知。要让他们完全从头开始、重新想象，需要时间，因为团队会说：嗯，我们不是这么做的；我们试过那个，没成功。或者诸如此类。但我认为更难的是：拿我们的其他消费者体验来说——拿我们的零售业务，或者 Prime Video 业务、Fire TV 业务、Prime Music——这些体验里，技术今天已经有了好得多的解决方案，这一点并不那么明显。但我实际上相信，这些业务中的每一个，我们都需要重新发明；而且我们已经有团队在做这些业务的、被彻底重新想象过的版本。那么，我认为我们一上来就能做对吗？大概不会。我们会想办法迭代着走进去，但它已经在产生各种各样的新想法和客户体验，我们认为非常有吸引力。然后有意思的会是这样一个赛跑：你是想要一个完全不同的体验——几乎像一个新应用那样——还是说那些新东西推进得够快，你把它们加进现有体验里，在接下来两三年里一点一点地、实质性地改变整体客户体验？随着你找到奏效的要素。但我确实认为，如果你想成为一个成功的领导者，这些体验中的每一个都必须在未来几年里变得不一样。是的，这是个非常棘手的领导力难题。这让我想起我刚做工程师那会儿。我和某个人为某件事争论起来。我的老板说：听着，Ben，你必须明白一件事——在写下第一行代码之前，一切都可以讨论；之后，它就变成了信仰。我猜你在 Alexa 上也经历了这个。不过很有意思的是：所有那些知识、所有那些经验、所有那些用来构建原来那个东西的东西——现在你在说，好吧，我们愿意放弃其中很大一部分，走向这个新世界。而且顺便说一句，对客户也是一样：你会有一大批热爱当前体验的客户，对吧？是的，每一次大的转型——至少以我的经验，也许你能举出不是这样的例子——但几乎每一次大转型，都需要一次巨大的改变：技术、产品、客户体验和商业要素，都必须足够有说服力，才能让人想要改变。但即便如此，它也不会自动发生。这是一次巨大的变革管理——就像从本地部署迁到云上，是同一类转型：很多基础设施负责人对自己造的东西非常骄傲，他们对它了如指掌，他们身处行动的中心，他们不想去学新东西。这将会是同一回事，就是我刚才提到的那种体验。对于重新发明你所有的客户体验这件事，也会是这样。我们都为自己过去十年在这些体验上所造的东西感到骄傲，我们都有 100 件能让它变得更好的事情，我们都为此兴奋，我们把所有醒着的时间都花在上面。要去想“我怎么完全从头开始”，你知道的，这在理智上和情感上都是很难的。是的，毫无疑问。

a16z 53:06

还有，Andy，我们几周前刚刚孵化了 Harwood's 和 Jason Academy，帮助年轻人为我们正在谈的这场转型做准备。你说过 AI 让构建变得更容易，但年轻人仍然需要学习、你知道的、真正的专业能力。我很好奇：如果你在 2026 年是个 18 岁的人，你会给自己什么建议，来为这场我们正在进入的转型做准备？

Andy Jassy 53:29

嗯，我有一个 25 岁和一个 22 岁的孩子。所以我想，那个 22 岁的孩子在开始真正起飞的时候是 19 岁。我很快就明白了：你不能告诉他们在教育里不要用 AI。那艘船已经离港了，或者说那列火车已经出站了。而且我认为大学明智的做法是不去对抗它。我认为它就是一个人们会去用的工具。

Andy Jassy 53:54

但与此同时，我认为所有年轻人——而且我要说，对我们来说也一样，我们有很多人、我们有写作文化，大家在拿 AI 写东西——你能看出来什么是 AI 写的：它、就是不太对，那些部分没有被拼接到一起。而且你知道的，所以我会给年轻人的建议——也是我给我孩子的建议——是。

Andy Jassy 54:18

你不能逃避它，你知道的，你也不能指望它消失。它会在你的生活里、在你尝试使用的每一种体验里、在你的工作里，产生极大的影响；而且它会让你以我们从前不可能做到的方式去发明。所以你真的需要去了解它，你需要自学它，你需要大量地使用它。你需要去尝试。试着做一些超出你舒适区的事。

Andy Jassy 54:48

我的两个孩子都不是开发者，但他们、你知道的、用 AI 做过应用。把它当作你安排一天、以及在工作中使用工具的焦点。但我不认为它会取代批判性推理和思考。而且我认为对大学来说也是这样。我在很多方面会想到——我拿商学院举个例子。你会拿到三个要分析的案例，你要做大量阅读、做笔记、找出关键问题是什么。然后你会拿到一堆附件材料，你也要在上面做笔记。然后你得把你认为那家公司应该采取的方案整合起来。而你知道的，经常有一堆人根本不做这些功课——他们不阅读、不研究、不做笔记。而所有这些，AI 都能帮你搞定，它能把每个人更快地送到那个更高的起点。

Andy Jassy 55:52

但我也要说，真正把那些点、那些碎片串起来——不管是要形成一个战略、一个思路、一个计划、一个新产品，还是一个新的客户体验——我不认为 AI 会在大多数时候、为大多数人做到这一点。我不是说这永远不会发生。

Andy Jassy 56:10

我仍然认为你需要人类的判断力、创造力、发明力、实验精神，以及思考所有部件如何拼合在一起，最终做出惊艳的体验和生意。所以我认为你应该使用这些工具，它们会是巨大的助力，但我仍然认为批判性推理和思考在我们做的每一件事里都会非常重要。临近尾声了。你们所做的业务，是像……

a16z 56:43

从卫星连接到机器人、到医疗，如此多样。我是说，这种雄心太不可思议了。想想这门生意是从、你知道的、在互联网上卖书开始的，而现在它成了这样。你会怎么看待，嗯，是什么把这些不同的……

Andy Jassy 57:00

业务线串在一起？或者说，你如何判断哪些业务线值得投入数年？或者你怎么确保自己不会过度分散精力？或者你怎么理解这个极其宽广的版图？

Andy Jassy 57:11

嗯，我会说几件事。首先，我认为我们正处在我们有生之年——也许是有史以来——最大的三场转型之中：AI、机器人和太空开发。它们都非常巨大，而且都会彻底改变我们所有人会遇到的许多客户体验。而我们正处在这三场大转型的正中间。

Andy Jassy 57:40

如果你看我们在零售业务里做的事，以及我们如何使用机器人、我们在 AI 侧做的事——既包括让内部和外部的构建者更容易做出成功的 AI 应用和智能体，也包括重新发明我们所有的消费者体验。

Andy Jassy 57:58

如果你想想 Amazon Leo——我们正在为全球 5 亿还没有宽带连接的家庭建设的低地球轨道卫星星座——那里正在发生一系列不可思议的转型，我们有机会帮助客户去利用它们，让他们的生活变得更好。而且我们做这件事的方式，既能帮助客户，也能为我们自己带来长期可持续的业务。而且我们、你知道的，我认为我们有机会在更多领域里对客户变得更有相关性。这还没算上我们在杂货领域做的事、我们在自动驾驶网约车和医疗领域做的事，以及、你知道的，这些。

Andy Jassy 58:47

你知道的，关于我们的组织方式，这些年来我们经常有这种内部辩论，也有很多外部人士问过同样的问题：这算不算摊得太薄？我认为这在某种程度上取决于你怎么组织自己，以及你愿意投入多少。因为我们不会让同一批人去管理多块业务，我们是以这种去中心化的“单线程”方式来组织的。只要你在这些团队上有合适的领导者和合适的构建者，只要这个体验足够大、能推动增长指针，只要你在一个服务得并不好的领域里有差异化的想法，你就有机会同时去追求很多这样的事情——而且我们在很长一段时间里就是这么做的。然后就归结为你愿意投入多少。有些公司——完全可以理解——会说：我们就要做好自己的本行，我们就守着我们的核心业务，把它做大。顺便说一句，那也可以是一个非常成功的策略。而我们也非常专注于继续做大、做强我们的既有业务，我认为我们做得相当成功，速度也不错。但有那么多其他客户体验，我们知道客户真的希望我们去帮忙解决，而我们也能解决——它们会帮助我们的客户，也会长期改变我们的业务。所以我们会继续追求这些。这是个鼓舞人心的收尾——无尽的雄心。Andy，非常感谢你来上节目。是的，谢谢你们邀请我。非常感谢，各位。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

381 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

2 条评论

正在加载

摘要：

四个月内，韩国散户"弹药库"跌幅达36.5%，回落至年初水平。尽管散户累计净买入逾75万亿韩元仍在接盘，但新增资金断流，补充速度远落后于消耗。叠加KOSPI月内暴跌近20%、外资持续净卖出，叠加AI信用风险担忧，失去民间资金托底的韩股短期内恐难迎持续反弹。

韩国股市散户资金池正在以令人警觉的速度萎缩，市场流动性面临严峻考验。

据韩国金融投资协会数据，截至10月22日，韩国券商投资者存款余额降至88.68万亿韩元（约355亿美元），较6月4日创下的历史峰值139.69万亿韩元**骤降约51万亿韩元，跌幅达36.5%**，回落至年初水平。这一数字在10月21日跌破90万亿韩元关口，为近九个月来首次，并创下自1月13日以来的最低水平。与此同时，KOSPI指数本月经历七连跌，并于10月15日单日暴跌7.57%，外资持续净卖出的压力仍未消退。

散户资金的快速撤离，正在动摇此前支撑韩国股市的核心力量。上半年，正是散户投资者大规模入场，以巨额净买入对冲了外资的抛售压力；而如今随着“弹药库”告急，市场买盘支撑力度明显减弱，KOSPI后续走势面临下行压力。业内人士对市场能否实现持续反弹看法不一，分歧焦点集中在人工智能行业信用风险与芯片股基本面之间的博弈。

存款骤降：四个月蒸发51万亿韩元

投资者存款是指投资者存入券商账户、尚未用于购买股票或其他资产的资金，通常被视为股市潜在买盘的“弹药储备”。该指标的下降，既可能源于投资者主动买入股票，也可能源于资金直接撤离账户，因此不能将全部降幅简单等同于资金出逃。

然而，结合市场背景来看，**此轮存款下滑的信号意义不容忽视**。上半年，随着KOSPI持续上涨，投资者存款稳步攀升，新增流入资金明显超过实际购股支出，形成清晰的资金积累态势。而6月4日触及历史高点后，存款开始持续回落，表明流入股市的新增散户资金已大幅减少，无法跟上买入规模的步伐。

下滑速度在10月明显加快。存款余额从10月12日的100.44万亿韩元，短短三天内收缩至10月15日的96.91万亿韩元，并在随后一周进一步跌入88万亿韩元区间。与此同时，衡量杠杆投资规模

的融资余额也在本月中旬降至约32万亿韩元，现金储备与杠杆资金双双收缩，折射出市场剧烈波动下投资者情绪的全面降温。

散户仍在买入，但“新钱”已断流

值得注意的是，存款下滑并不意味着散户已经全面撤退。数据显示，**从6月4日至10月23日，个人投资者在KOSPI市场净买入股票44.17万亿韩元，在KOSDAQ净买入3.15万亿韩元，同期ETF净买入规模更达28.25万亿韩元**，散户在技术层面仍是市场的净买入方。

问题的症结在于，持续的买入行为消耗了存量资金，而新增资金的流入速度却远远跟不上消耗节奏。上半年，新流入资金超过购股支出，存款余额因此持续积累；进入下半年后，这一正向循环已然逆转——散户仍在接盘，但“弹药”补充速度已大幅放缓，存款余额随之持续下滑。

这一结构性变化意味着，即便散户短期内维持净买入姿态，其实际承接外资抛售的能力也已大打折扣。**上半年散户“接盘侠”的角色，在资金池持续萎缩的背景下难以为继。**

KOSPI近期走势进一步放大了流动性收缩的风险。指数从10月6日起连跌七个交易日，并于10月15日单日重挫7.57%，10月23日收报5550.30点，过去一个月累计跌幅近20%。在此期间，外资持续净卖出，市场供需结构明显恶化。

散户资金池的萎缩，与外资抛售的叠加，构成了对KOSPI的双重压制。上半年，散户凭借充裕的存款余额大规模承接外资卖单，在一定程度上稳定了市场；而当前存款余额已回落至年初低位，散户的缓冲能力显著下降。若外资卖压持续，市场缺乏足够买盘对冲，下行风险将进一步累积。

融资余额的同步下滑同样值得关注。杠杆资金的收缩通常伴随市场波动加剧，一旦触发强制平仓，可能形成负向螺旋，进一步压低指数。

反弹前景：基本面与风险情绪的拉锯

对于KOSPI后续走势，市场内部存在明显分歧。

乐观派认为，以芯片制造商为代表的核心企业盈利能力依然稳健，当前指数相对基本面已存在明显低估，具备修复空间。

然而，谨慎派的声音同样有力。**一家证券公司官员表示：**

> **“KOSPI近期跌幅相对于盈利基本面确实过度，但此前推动市场上涨的催化剂——人工智能行业——目前面临相当大的信用风险担忧，因此现在期待持续反弹还为时过早。”**

AI行业信用风险的浮现，动摇了此前支撑市场估值扩张的核心逻辑。在这一不确定性消散之前，散户资金的大规模回流恐难实现，而"弹药库"的持续萎缩，也将令KOSPI在承压时缺乏足够的民间资本托底。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

88 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

这是3万亿参数级最强模型，支持100万上下文，性能比肩GPT-6 Astra，成本仅其五分之一。权重一旦开放，将登顶开源榜首，与顶级闭源模型差距从12分骤缩至3分。代码审美大升级，可直接驱动Blender建模+Three.js网页一条龙；金融分析拿下OfficeQA Pro最优。

昨晚的X，被刚刚发布的Kimi K3.1 Pro正式刷屏了！

外国开发者们惊呼：欢迎来到3D Web 开发的新时代。

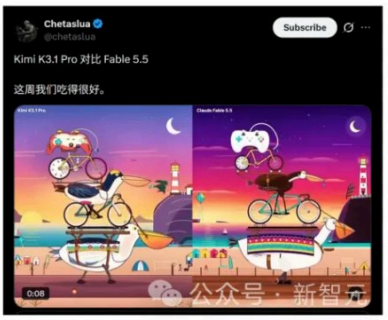

之前，AI榜单前十几乎被美国公司包圆了。相对而言，国模这边有点沉寂。

有人感慨：国产大模型最近发的都是主打性价比的「Flash」模型，真能打的「Pro」去哪了？

很多人在问：国模是不是掉队了？

今天，Kimi打破了沉默——Kimi K3.1 Pro来了！

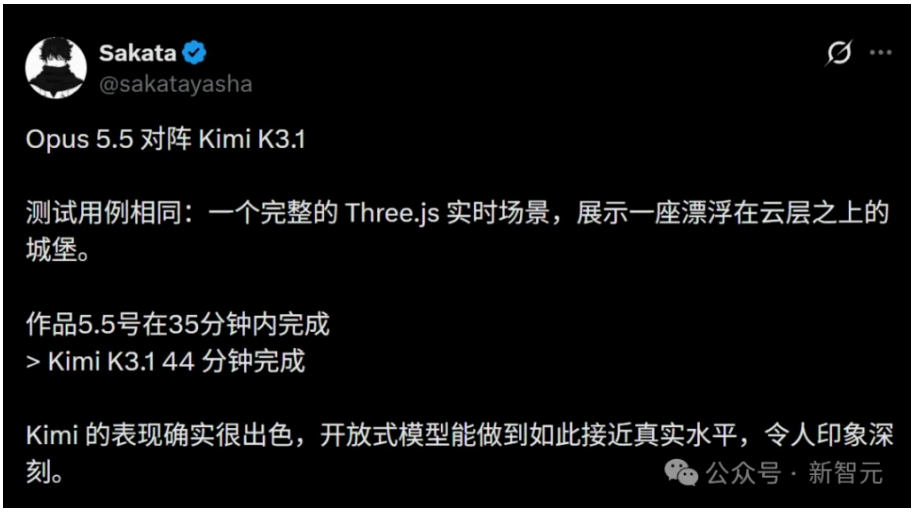

知名AI评测机构Artificial Analysis也公布了成绩：**K3.1 Pro以55分冲上全球智能指数第4，较前代暴涨11分。**

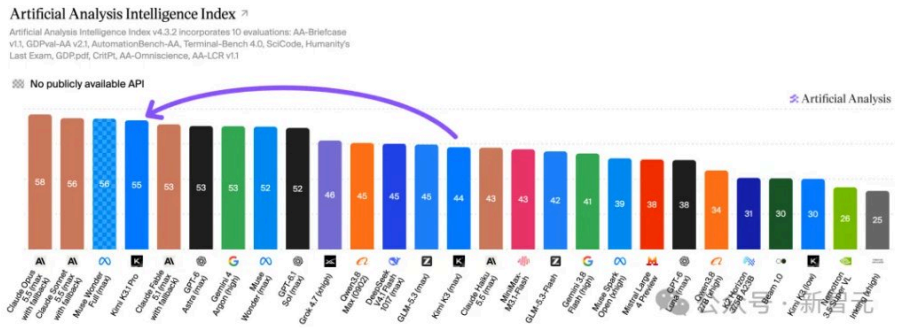

在考验Agent实战能力的Terminal-Bench 4.0上，它更是从13%飙升至65.7%， 距离 Opus 5.5 不到 1%！

Artificial Analysis还给出一个重磅判断：**一旦权重发布，K3.1 Pro将登顶开放权重模型榜首，开源与顶级闭源模型的差距，将从12分骤缩至3分！**

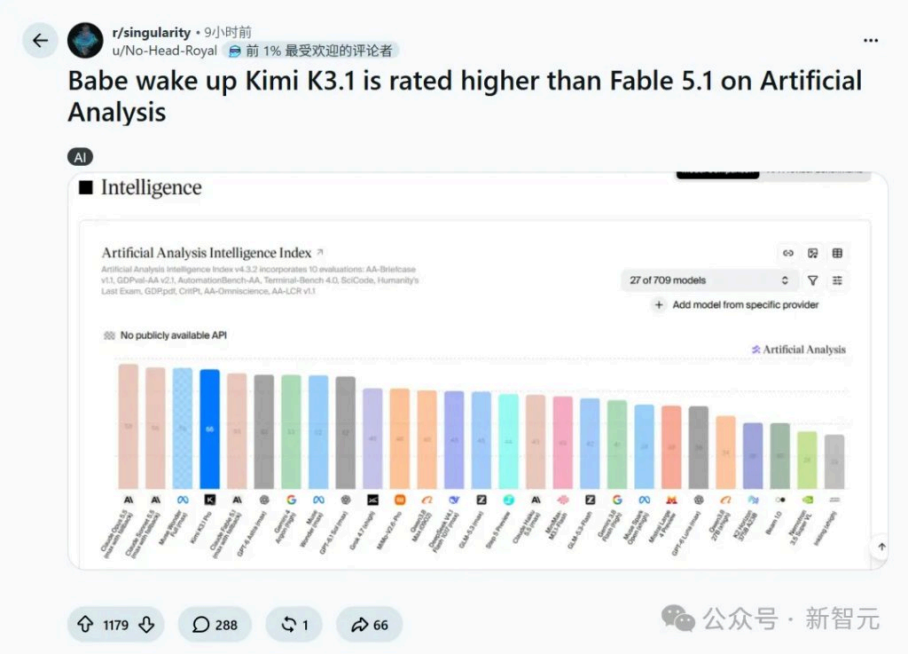

今天早上，reddit已经被这个跑分刷屏：Kimi K3.1超越了Fable 5.1！

国模这次，真把全球第一梯队的门踹开了。

国模王者归来！

这次Kimi端上来的，不是个过渡版本，而是一盘硬菜。

这是迄今为止能力最强的 3 万亿级参数模型，支持高达 100 万上下文。

它的出现告诉世界：China is back，国模王者归来！

在各大硬核测试中，K3.1 Pro 的性能直接比肩海外顶流 GPT-6 Astra！更离谱的是，它的成本只有 Astra 的五分之一，便宜了整整 80%！

所以，K3.1 Pro 的定位很清楚：做前沿模型里，最理性的那个选择。

而且，在真实场景中，要干有挑战的任务，还是得靠更大的模型。举个例子，尽管基准测试分数跟Opus相近，但真到了现实场景里，Fable 这种较大模型，经常会表现出更强的洞察力、创

作力和写作能力。

毕竟，高难度推理任务，才能显出大模型的本事。

这一次，K3.1 Pro 基于 K3 做后训练，月之暗面在强化学习上大幅加码算力。

为了让几百个下游领域一起联合训练，他们从 RL 框架、长上下文推理、沙箱，到调度系统、环境质检平台，整套技术栈逐层重新打磨。目标就是——每一份新增的算力，都要变成实打实的能力。

结果是，在代码、Agent 和知识类基准上，K3.1 Pro 达到或接近最强闭源模型的水平。

在考察 Agent 在真实终端里独立干活的 Terminal-Bench 4.0 上，它拿到了65.7分，而且在三种思考强度下，都落在「性能与单任务成本」的帕累托前沿上。

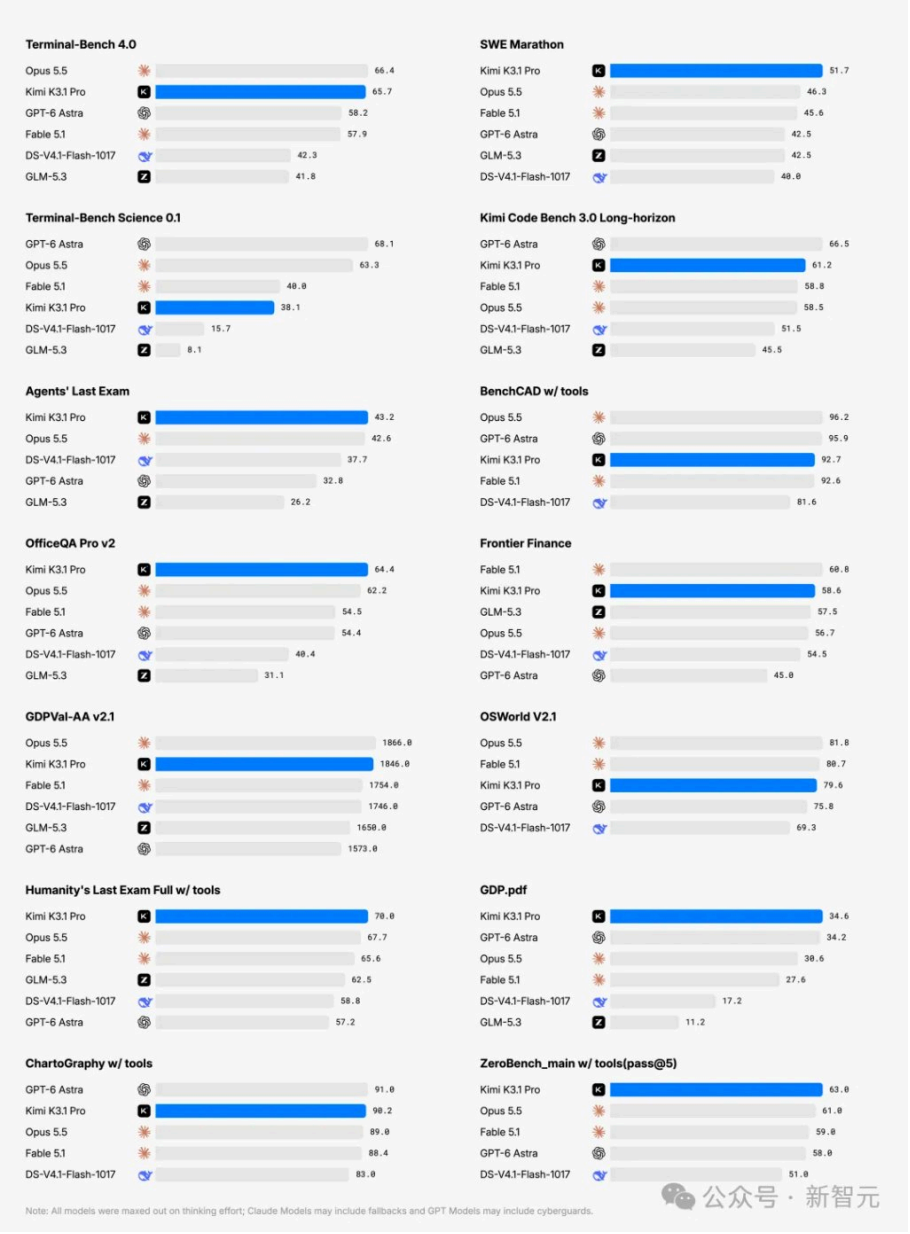

也就是说，**同样的钱，它干得最多；同样的活，它花得最少。**

Kimi 还贴心地端出了高速版模型 Kimi K3.1 Pro Highspeed，智商不减，但输出速度直接飙升 3 倍。

不过，跑分只是门票。榜上分数咬得再紧，一到真刀真枪的活儿上就会拉开差距——

任务越难，越是拼模型本身的底子，这恰恰是大模型的主场。

接下来，我们就看看 K3.1 Pro 在真实工作流里，是怎样表现的。

代码模型，审美大升级

据悉，K3.1 Pro 有个引人注目的变化：**审美，成了模型的能力项。**

Kimi想回答的问题是——代码模型，能不能好看？

这一次，无论是前端页面、Three.js 交互场景，还是3D 资产，它在构图、排版、动效和完成度上都有明显提升。

它还会用 Unity、Unreal Engine、Godot 这些游戏引擎，可以不靠 MCP 连接器，自己写脚本直接驱动 Blender、SolidWorks、Rhino 建模。

接下来，就让我们来一波硬核实测，来看看「大而美」的K3.1 Pro，究竟有多能打？

实测：文字 → Blender → 网页，一条龙 3D 资产

这是K3.1 Pro主打的新技能。官方说它能从一段文字、一张草图或参考图推断形状、比例和空间关系，直接写 Blender 脚本建模，再接入 Three.js 或游戏引擎。

我们来验证一下，这条链路是不是真的能打通。

一张手绘三视图扔进去，40 分钟，它交出来的是：608 行 Blender 脚本、可编辑的 .blend、1.7 MB 的 GLB，还有一个双击就能开的网页。

草图上写的翼展 8.0、总长 6.2、总高 2.4，建出来是 8.000、6.199、2.400，差了 1 毫米。

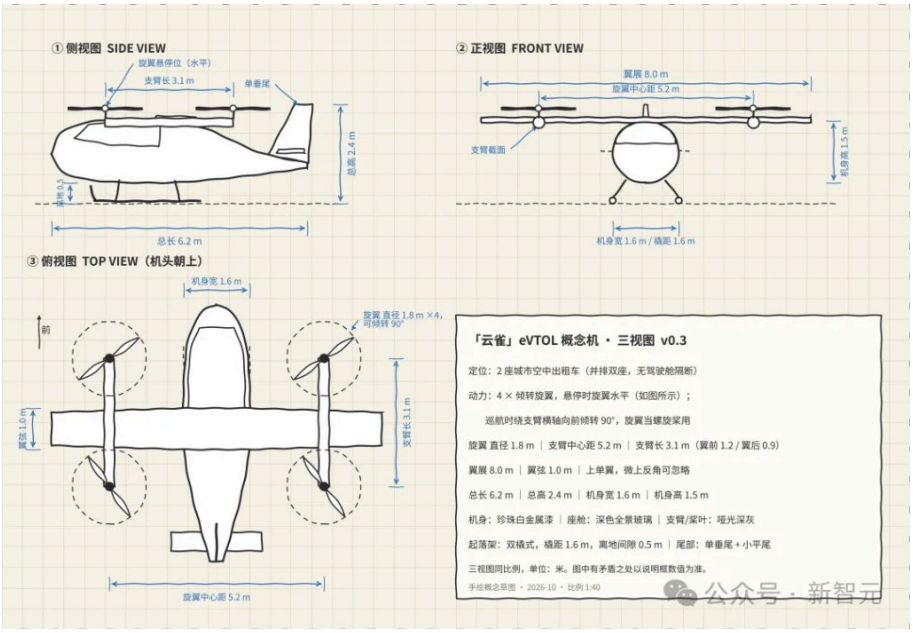

接下来，它开始了丝滑的操作。

动手前，K3.1 Pro会先试探 Blender 5.2 的新接口，确认了再写正式脚本；验收标准直接写成断言，旋翼直径差 1 毫米就不许导出；渲染完自己对照草图改了一轮；网页做完，它甚至还开浏览器给自己截了两张截图，这样才算交差。

六项待办，自己一项项划掉。

机身是样条插出来的流线体，座舱玻璃是吸附在机身上的曲面，桨叶带扭转，四个旋翼的倾转层级从 Blender 一路到浏览器里，滑块拉到底，真的绕支臂往前倒 90°。

全程，K3.1 Pro都没碰 MCP，没用外部模型库。

写到一半时，1M 上下文才用了 6%。40 分钟不是它的上限，是这张草图只有这么难。

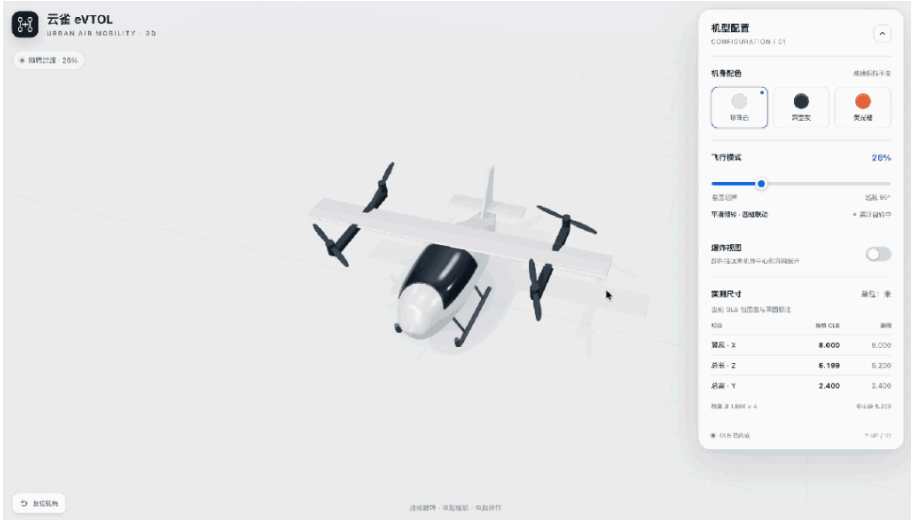

更令人振奋的是——这套活儿不用本地装 Blender 也能干！

kimi.com 和 Kimi app 已同步上线 3D Make 功能。把同一份草图和资料直接丢进 Kimi，一句「参考这些资料，把它的 3D 模型做出来」，它就在云端开工了，这次又跑了将近 40 分钟。

改 scene.js、改 style.css，跑终端重建，它发现两片桨叶转起来不对称，改成半整数转速；CSS 动画暂停不一致，修；截图时场景还没加载完，加一个「就绪」再截。

最后自己开浏览器点了一遍，报了句「无脚本错误或资源缺失」，才把版本号交出来。

做完的东西就在右边窗口里，能转、能换色、能拉倾转滑块，不满意直接在对话里改，它接着改。

使用3D Make可以在线预览和编辑，一键发布成网页，GLB 下载下来可以直接去 3D 打印，还能导出视频或实况照片发社交平台。

https://lsx4v6wl2amc4.kimi.page/

以前，这是建模师、前端和运营三个人的活，现在，K3.1 Pro用一个输入框就完成了。

而众多网友的实测也证明，K3.1 Pro的审美绝了。

仅用4.92美元，它就在一款绘画应用程序中画出一副肖像。

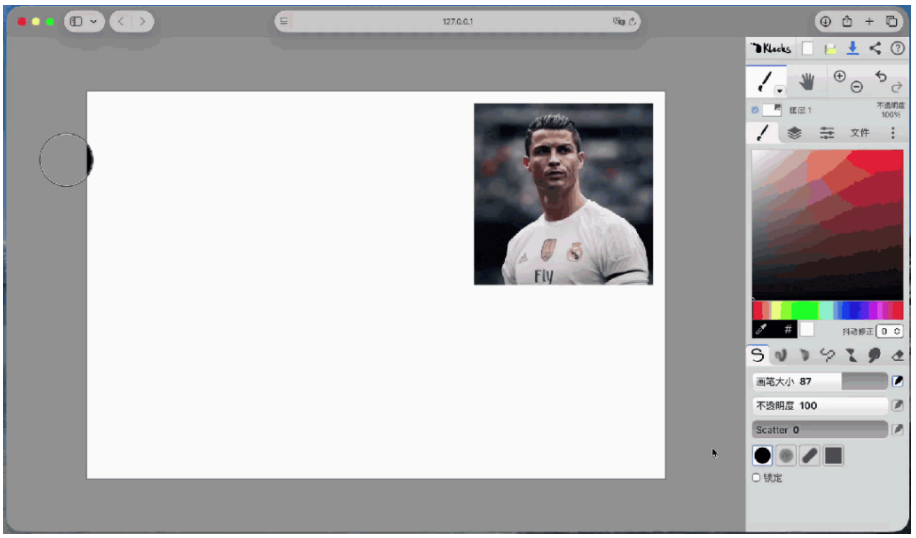

有人在虚幻引擎中建造了一座云端宫殿，成本不到10美元，引发了众多网友盛赞。

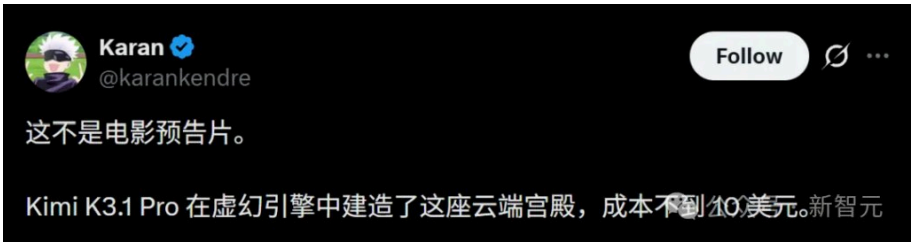

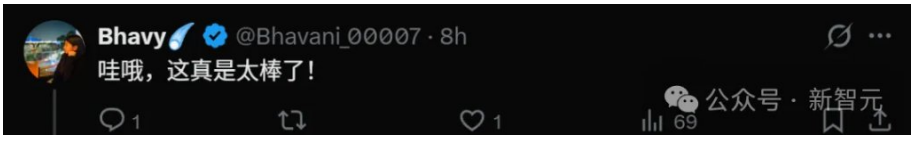

鹈鹕骑自行车的demo，审美绝了。

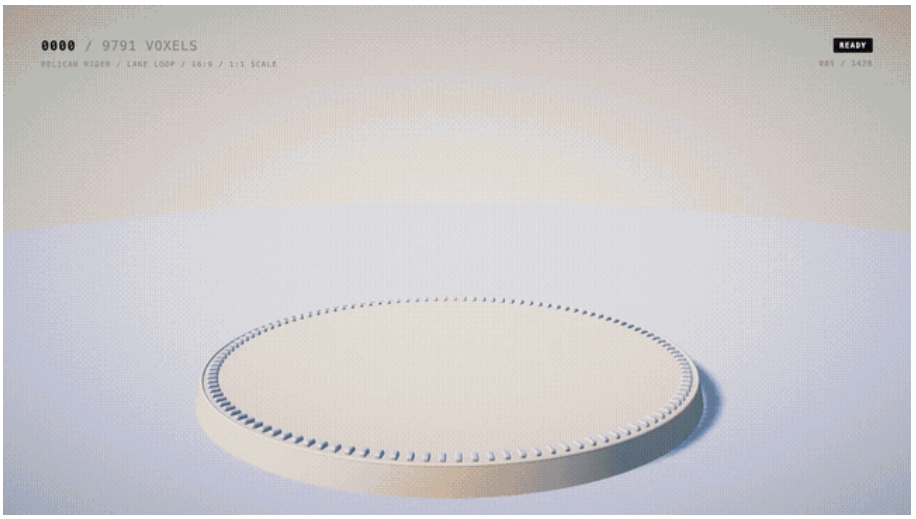

华尔街全栈分析师来了

以前的AI碰金融，只会写摘要，一遇到跨表公式和估值模型就胡言乱语。

但 K3.1 Pro 这次，直接干翻了海外顶流。

在 OfficeQA Pro v2（基于真实金融文档的复杂财务数据分析，考察检索、跨文档核对与多步数值推理）上，K3.1 Pro 拿下 64.4 分，当前最优（SoTA）。

在覆盖从标的筛选到盈利分析整条投资工作流的 Frontier Finance 上，K3.1 Pro 位列第二，较 K3 进一步提升。

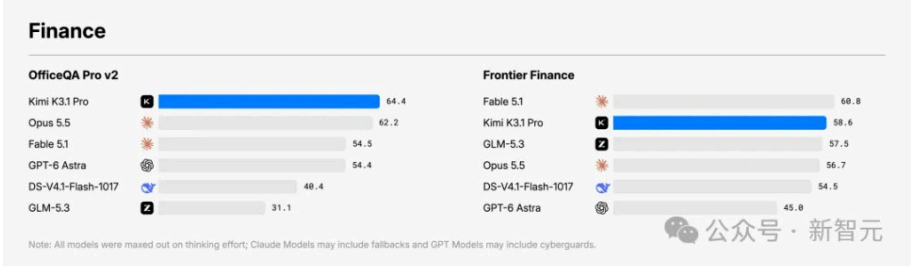

接下来，我们看看 K3.1 Pro 在真实投行工作流里，是怎样表现的。

它给我们手搓了一份英伟达的专业级财务模型。

它并不是简单地填表，而是能端到端交付一整个带公式联动的 Excel！它像极了老练的分析师，经营驱动因子可随情景调整，敏感性分析直接呈现对估值的影响，每一项假设都有硬核数据支撑。

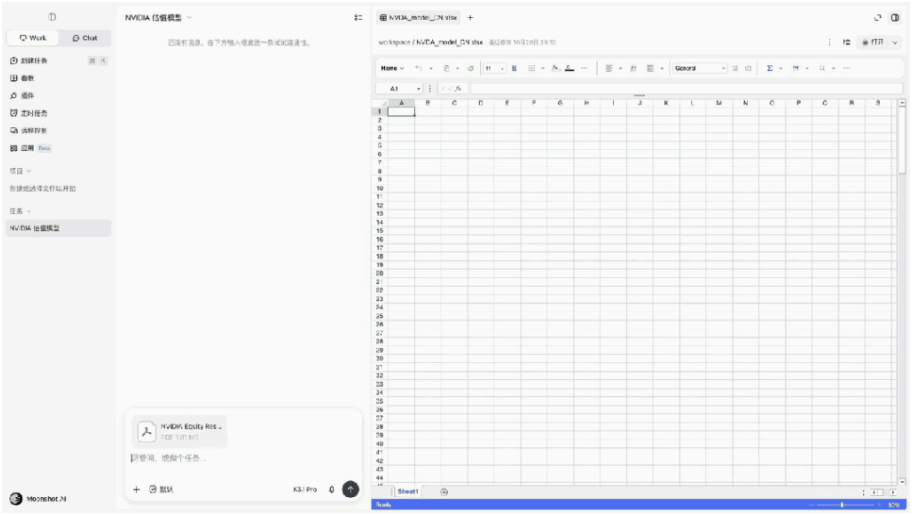

可以说，现在的K3.1 Pro是一个真正懂财务逻辑的「全栈金融民工」了。

国模崛起

Kimi K3.1 Pro 的出现，证明了我们在大模型的牌桌上，依然握有随时打出王炸的实力。

它当然不是全能冠军，在一些维度上离最强闭源模型还有距离。

但真正令人振奋的，是**国模正在向全球智能的性能天花板发起正面冲锋。**

性价比决定市场，能力上限决定未来。

Kimi K3.1 Pro已经能与全球最强模型正面交锋，甚至重新定义智能的边界。

而且这次性能更强了，价格反而更便宜：比 K3 便宜了三分之一，只有 GPT-6 Astra 的五分之一。

现在，不用苦等解封了。今日起，把Kimi K3.1 Pro用起来。

China is back!

本文来源：新智元

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次 VIP会员·7天畅读卡 | 大师课·入门串讲 扫码 免费领取

限免

17 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

"做多AI、做空一切"的极度拥挤交易正在痛苦解构——市场不再满足于"烧钱叙事"，超大规模云厂商必须在1.1万亿美元资本支出的同时，拿出真实可见的收入转化。40-50吉瓦的电力缺口、资金成本攀升与"支出过剩"时代的宏观范式切换，正将AI交易从信仰题变成一道严酷的变现大考。

此前市场极度拥挤的“做多AI，做空其他一切”交易正在经历痛苦的解构，创纪录抛售下，超大规模云厂商迎“变现大考”。

10月22日，高盛欧洲固定收益与股票（FICC & Equities）交易主管Rich Privorotsky在位于伦敦的高盛交易室接受了播客栏目《The Markets》的访谈。Privorotsky透露了一个极具冲击力的数据：**“上周我们的主经纪商业务账簿（Prime book）上，出现了有史以来最大规模的科技股抛售。”**

面对这波抛售潮，正在进行中的三季度财报季显得尤为关键。市场的焦点已从单纯的“讲故事”转向了严苛的业绩兑现。Privorotsky指出，市场预计明年AI的资本支出（Capex）将高达1.1万亿美元，但这已不足以让投资者买单。

“仅仅说你花了很多钱是不够的，你还需要证明未完成的订单正在转化为实质性的收入。”Privorotsky强调，“他们必须在推动资本支出的同时展示这些支出的回报。这不是一个轻松的局面。”他表示，云业务的增长、变现能力以及自由现金流实现收支平衡的速度，将对目前极其敏感的信用市场产生重大影响。

基础设施与资金双重掣肘：明年存在“40-50吉瓦”电力缺口

在AI狂热降温的背后，是现实世界中基础设施和资金池的硬性约束。市场目前正在与三个核心问题作斗争，首当其冲的便是资金成本的溢出效应和电力供应。

Privorotsky指出，杠杆率较高的AI交易领域（如新兴的云服务提供商）正面临严峻的融资考验：“这些企业在寻找融资来兑现AI支出时是否会遇到困难？”

更现实的物理瓶颈在于电力交付能力。

他提出了一组关键数据：“明年的电力缺口大约在40到50吉瓦。如果你无法获得实际为数据中心供电的能源，你还能消耗掉你已经提前订购的芯片吗？”这些担忧导致投资者进入“去风险模式”，通过做空AI和AI资本支出交易来降低增长预期，同时资金涌入债券市场避险。

宏观范式重塑：从“储蓄过剩”走向“支出过剩”

站在宏观周期的角度，Privorotsky描绘了一幅深刻的范式转换图景。

他表示，自己的整个职业生涯都处于“储蓄过剩”的环境中——系统里的钱多到不知道该怎么办。但现在，情况发生了“地震般的剧变（Seismic shift）”。

“在过去的一年里，我们预计将在AI资本支出上花费超过1万亿美元，而全球大多数政府都在运行财政赤字。**我们正处于一个‘支出过剩’的时代。”**

这种转变推高了资本成本，并自然而然地挤出了处于边缘、资质较差的借款人。

他观察到，这种压力不仅体现在CCC级信用利差的大幅走阔上，甚至蔓延到了主权债务领域（如面临高额财政赤字的法国国债）。再加上居高不下的能源价格，整体市场的风险偏好正在被显著削弱。

市场情绪走向两极，“成也AI，败也AI”

在复杂的宏观和微观交织下，投资者的焦虑情绪出现了奇特的“极化”现象。

Privorotsky分享了他本周与投资者交流的见闻：“我遇到一些投资者说，‘我担心无法交付算力，这让我害怕’；然后我又遇到了另一批投资者，他们说，‘我担心我们会过度交付算力，这让我害怕’。不知何故，两个完全互斥的结果构成了市场担忧的总和。”

由于能源价格对经济产生重大影响（标普500虽然表现平稳，但中位数股票实际上已下跌超过10%），金融状况指数（FCI）大幅收紧，迫使美联储采取更多行动。

Privorotsky曾坚信“原油决定一切（As goes oil, so goes everything else）”，但他现在承认，**在当前的市场语境下，逻辑已经演变为“AI决定一切（As goes AI, so goes everything else）”。**

尽管短期内面临压力，但Privorotsky并未完全悲观。他认为现货市场的算力价格每天都在创出新高，需求依然“贪婪且永无止境”。在交易策略上，他表示虽然目前信念度不高，但已遭遇大幅降级的“电气化”相关资产、民用航空航天资产以及部分运输板块，目前已经具备了可观的安全边际，值得保持谨慎乐观。

以下为播客对话全文翻译：

> **Chris Hussey 00:00**
>
> 这里是《The Markets》。我是 Chris Hussey，今天是 10 月的星期四。我从伦敦高盛交易大厅请到了 Rich Probarowski，他是 Prevo 旗下 FIC 与股票业务的欧洲股票交易主管。非常感谢你来做客。谢谢你们的邀请。Hussey，我们就直接进入正题吧，因为，你知道的，你写的东西我全都读了，而且你提出过一个很好的观点——今年夏初的时候，那个痛苦交易，也就是大家不得不去追的那个交易，是做多 AI、做空其他一切。它已经有点变成了、很大的一笔交易。现在随着我们进入三季报季，这个交易似乎正在瓦解。到底发生了什么？你认为接下来会怎么演变？股票市场出现了极其严重的集中度，而且我得说，过去几周对这类一致性交易来说尤其痛苦。

Rich Privorotsky 00:48

大家的仓位高度集中在 AI、半导体和超大规模云厂商上。我想说，眼下市场大概正应对三个不同的问题。其一，显然，我们在资本成本方面出现了溢出效应。我认为这几乎随处可见，无论是 CCC 级利差、欧洲的主权利差，还是 AI 交易中那些杠杆更高的、最为尖端的部分——其中 Neo 云（Neo clouds）尤其突出。所以，这就变成了一个供给问题。你知道，这些企业会不会难以找到融资来交付所有这些 AI 支出？第二点同样关于供给：我们是否真的有能力通电并交付吉瓦级电力，市场对此存在疑问，明年的区间大概是 20 到 40、50 吉瓦。所以，如果你拿不到电力真正让数据中心通电，你真的能够、能够消化掉你已经提前下单的那些芯片吗，所以。

Rich Privorotsky 01:38

这些都是萦绕在市场上空的担忧，而这一切叠加之后，已经把大家推进了一种去风险的心态；这种心态的具体表现，是通过 AI 交易和 AI 资本开支交易压低了增长预期。而在另一面，随着增长预期下修，债券一直在上涨——这一点完全不在任何人的剧本里。

Rich Privorotsky 01:56

好的，这里信息量很大。不过我们把焦点放在不远的未来、其实也就是当下——三季报季。我们已经身处其中了，一些大型科技股已经公布业绩，但后面还有很多。三季报季里你最密切关注的是什么？是的，我认为我们即将进入超大规模云厂商财报的核心部分，我觉得真正重要的不仅是看到资本开支维持在高位——市场普遍预期明年在 1.1 万亿美元——而最重要的是，要看到，你知道的，云业务的持续增长和变现。所以，光说自己在花很多钱是不够的，你还需要证明积压订单正在有意义地转化成收入。所以我认为这对市场会非常关键。我认为，他们实现自由现金流打平的这个过渡会有多快——相对于市场预期。可能会对信贷市场产生重大影响，而信贷市场已经变得极其敏感。所以对我而言，真的，有很多东西可以看。我会说，来自经济其他领域的。但我认为市场的焦点会真正落在超大规模云厂商身上，然后是交付的质量，而不仅仅是支出。对这些公司来说，要翻过这道坎太难了。他们必须一边继续推高资本开支，一边还得向你展示这些资本开支的回报。这不是一个轻松的局面，不是吗？是的，不是。但你看，我的意思是，当前的大背景是这样的：你看到算力价格在现货市场上每天都在创下新高。对他们所卖的东西，需求是永不满足的，所以我想说。

Chris Hussey 03:23

用稍微乐观一点的眼光看，他们应该有一个相当不错的故事可讲。好的，里奇，说起来确实有一阵子没请你上节目了。你上次来还是在一月。但这一年里，你一直是秉持那句口诀的人之一——石油怎么走，其他一切都怎么走。这还是那句口诀吗？是的，我认为我们在能源方面遇到了极其棘手的大环境。而且，你知道，我认为。

Rich Privorotsky 03:46

市场、股票市场，我认为，已经尽其所能地去忽视、并把能源价格的上涨隔离在一个角落里。但这其实不太公平，因为标普指数在隔离这件事上做得很好，可是中位数个股实际上已经下跌远超 10%。所以这对利率产生了影响。它也影响了 FCI。事实上我们经历了一次大规模的 FCI 收紧，这在某种意义上也倒逼美联储做了更多。而且我们重新定价了整整一轮加息周期。所以我认为能源在这中间占了很大一部分。我认为我们仍然因为能源而负担着大量的风险溢价。显然，接下来几周这些事情会如何演进，对整个风险资产而言将非常关键。而我乐观的看法是，我们会在未来几周内获得某种形式的解决。但我必须承认，我之前以为这在两个月前就该发生了，在这一点上我判断得有点偏了。我想我们都是。当然，你说的 FCI，指的是金融状况指数，它是。

Chris Hussey 04:35

算是衡量经济、或者说衡量所有经济脉冲是收紧还是放松的一个尺度。它不只是关于利率。当你看一个 FCI 时，有时它可能是石油，有时它也可能是股票。好的，这个观点不错。关于石油这块。

Chris Hussey 04:48

不过，与那笔石油交易相关的，还有你在年初时说的一句话，那就是：我想做多名义资产——在一个 GDP 增长强劲、而且看起来依然非常强劲的扩张世界里，而且通胀很高，我就是想做多这类东西，也就是大量的大宗商品。今天你怎么看这笔名义资产的交易？它现在还是值得配置的地方吗？

Rich Privorotsky 05:11

我认为，要回答这个问题，我得先回答那个价值万亿美元的问题，也就是：AI 支出接下来会如何，以及相对市场预期而言，它的可持续性如何？

Rich Privorotsky 05:19

因为现实是，当我们在重新定价它的时候，我们重新定价了一切，包括大宗商品，包括名义资产。我的直觉是，我们有点把孩子连同洗澡水一起倒掉了，而且我们显然已经开始担忧它的每一个维度。说得具体一点：这周我见到一些投资者，他们说「我担心算力交付不出来，这让我害怕」。然后我又见到另外一批投资者，他们说「我担心我们会过度交付算力，这让我害怕」。不知怎么的，我们得到了两个互斥的结果，而它们同时又构成了市场担忧的总和。

Rich Privorotsky 05:50

所以我认为，从大格局上看名义资产仍是你想要待的地方，除非我们陷入、一场反通胀式的崩坏，也就是资本开支放缓、所有人都不得不收缩、迎来一轮真正的信贷周期。换作三个月前我会说，这种风险很低，而现在无疑高得多了。但我的直觉是，从中长期看，那仍然是你想待的地方。不过我认为，现在在组合里多加一点杠铃策略或许更明智些。听起来你的意思是，以前也许是石油怎么走、其他一切就怎么走，现在是——AI 怎么走。

Chris Hussey 06:22

其他一切就怎么走。是这样吗？我认为，冒着过度简化的风险说，这大概是对的。是的，里奇，谢谢你愿意过度简化。我自己就是「过度简化先生」，所以我很高兴你能走到这一步。当然，这里面有一部分会是一轮大的信贷周期，而三个月前你并不担心信贷周期，现在你担心的程度多了一些。跟我们聊聊这个。你看到信贷出现裂缝了吗？你指的是欧洲主权债正在发生的问题，还是更多指的是我们在企业端看到的那些信用问题？

Rich Privorotsky 06:51

我整个职业生涯，可以说都身处在一个——储蓄过剩之中。你知道，系统里的钱多到我们不知道该怎么用。而就在过去这一年，我们的预计是要在 AI 资本开支上花掉超过 1 万亿美元。

Rich Privorotsky 07:05

全球大多数政府都在跑财政赤字。我们现在处在一个支出过剩之中。从事物运作的方式、以及资本成本会变成什么样来看，这是一次非常巨大的结构性转变。所以，我认为这自然会把那些处在边缘、资质不是最优的借款人挤出去。我认为你已经能从 CCC 级利差上看到这一点——公允地说，考虑到那边所发生事件的构成，这多少有些特殊性。但它们确实变动很大，而且已经稍微溢出到了信用市场更广泛的部分。然后显然，你还会有法国主权债的担忧，也就是：作为一个在这种环境下背负着巨额财政赤字的主权国家，它们同样都会被挤出去。所以我认为所有这些都在产

生影响，同时我们再回到石油交易上——只要能源价格维持高位，它就会压低风险偏好。而且，我认为对这类资产来说，现在有点像是一个买方市场。是的，从储蓄过剩到支出过剩，这个提炼方式太精辟了。这话太对了。而那个储蓄过剩也不过就是五年前的事。我们转变的速度真是惊人。

Chris Hussey 08:04

好的。发生的事情很多。你刚刚都跟我们说了。我们收个尾吧。现在这笔交易怎么做？

Rich Privorotsky 08:10

局面有点乱，而且我得说信心并不是特别高，但我认为电气化领域有一些板块我们认为看起来很有意思。它们的估值已经大幅下调，而且我仍然认为 A27 的能见度还很充足，能给你很大的安全边际。我认为有大量的航空航天资产已经回调，特别是在民用航空那一侧，同样对我们来说极具吸引力。然后甚至运输板块的部分领域，坦白说，如果能源问题能以某种方式解决，考虑到净头寸已经变得这么低、过去几周我们看到的抛售这么多，这笔交易里有很大的，我会说，凸性。举个例子，上周我们主经纪商业务中的科技股卖盘是有史以来最大的一次。所以，我认为有充足的理由保持担忧，我不想过度轻视这些风险，但我还是倾向于在目前这个时点保持谨慎乐观。好的，里奇，让我们快进到下周。下周有哪些会影响市场的事情是你在关注的？我认为关键在那些数字，也就是我们讨论过的超大规模云厂商的数字。我认为，你知道，让我们看看变现情况，让我们看看资本开支的数字。我认为这对盘面来说会非常关键。而且我认为，你知道，这件事的进展会决定人们对信贷的看法、对潜在需求的看法，以及我们从各家实验室和供应商那里得到的其他数据点。里奇，每次都带来大量信息。非常感谢你今天来做客。谢谢。那。

Chris Hussey 09:30

就到这里。本期《The Markets》到此结束。我是 Chris Hussey。感谢收听。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

239 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

AI算力需求爆表，亚马逊AWS核心产能已被抢购至2028年！亚马逊首席执行官Andy Jassy表示，面对满载的远期订单，其极具弹性的短周期“按需采购”策略成功规避了产能过剩风险。叠加自研芯片发力与AI生态深度协同，亚马逊正强势构筑技术与利润双重护城河。

亚马逊的云计算部门正面临前所未有的市场需求，其绝大部分核心基础设施产能已在未来数年内被抢购一空。

亚马逊首席执行官Andy Jassy最新表态称，**Amazon Web Services（AWS）的大部分产能已预订至2028年。**这一动态突显了企业端对云服务和人工智能基础设施持续且强劲的投资意愿。

尽管远期订单激增，亚马逊在资本支出层面依然保持了高度的运作弹性。公司能够根据客户需求的变化在短周期内调整服务器和网络设备的采购计划，这一防御性机制有效缓解了投资者对于云服务商过度扩产或未来需求放缓可能引发产能过剩的担忧。

除算力供需状况外，内部硬件生态的深化正在成为亚马逊应对市场需求的关键支撑。早期的战略性收购与近期对外部人工智能初创公司的投资正在形成协同效应，持续推动其自研芯片战略向前发展。

远期算力需求旺盛，核心服务预留弹性空间

在一档于周五发布的Andreessen Horowitz播客节目中，Jassy详细阐述了AWS目前的产能预订情况。他指出，随着企业对计算资源的需求不断攀升，AWS未来几年的大额产能已经基本见顶。

“现阶段2026年的产能显然已经售罄，2027年也已基本售罄。”Jassy在播客中表示，“2028年的很大一部分也已经售罄。”

尽管大块产能已被提前锁定，AWS并未完全切断短期需求的供给。Jassy补充说明，亚马逊始终会为按需服务以及运行应用程序的EC2和运行AI模型的推理服务Bedrock保留一定数量的算力，以确保核心服务的正常运转与客户体验。

资本开支具备防御性，按需调整硬件采购

针对市场周期波动可能带来的风险，亚马逊在数据中心硬件投入上采取了更为灵活的策略。即使未来整体算力需求增速出现放缓，亚马逊现有的供应链管理模式也能有效应对。

Jassy强调，AWS通常只需要提前几个月采购服务器和网络设备。这种较短的采购周期使得公司能够紧密贴合客户的实际需求来调整资本开支，避免了重资产投入带来的滞后风险。

“如果最终事实证明你不需要那么多产能来填满这些数据中心，你就不会去购买相关的服务器和网络设备，”Jassy明确表示。这种按需采购的逻辑为亚马逊的利润率和现金流提供了直接的保护。

自研芯片战略深化，合作提振技术能力

在讨论产能的同时，Jassy在广泛的采访中重点提及了亚马逊在底层硬件领域的长期布局。**他将十多年前对芯片制造商Annapurna Labs的收购，评价为可能是亚马逊有史以来最好的一笔收购交易。**

Annapurna Labs目前是亚马逊内部自研芯片项目的核心驱动力，负责研发包括人工智能芯片Trainium和CPU处理器Graviton在内的关键硬件产品。这些自研硬件不仅降低了AWS对外部供应商的依赖，也为客户提供了更具成本效益的计算选项。

此外，生态合作正在反哺亚马逊的硬件开发。Jassy指出，亚马逊对人工智能初创公司Anthropic的投资对自身的芯片制造业务起到了积极的推动作用。

“[Anthropic]在Trainium上进行开发已经有一段时间了，我认为这对Anthropic非常有利，同时对我们的Trainium团队也非常有利，”Jassy表示，“我们从彼此身上学到了很多东西。”

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

80 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

DeepSeek最新披露一个震撼数字：单GPU每小时可创造38美元计费产值，年化超33万美元。但这门生意真的赚钱吗？一边是中小企业AI需求"全面暴涨"，一边是OpenAI、Anthropic被推理成本侵蚀的毛利率；一边是CoreWeave112%的营收增速，一边是高达6.26亿美元的季度净亏损。效率提升与商业盈利之间，横亘着一道尚未解答的命题。

10月20日，DeepSeek开源推理框架DeepInfer时，公布了一个十分吸引眼球的数字：单个集群每天可以处理155万亿Token，如果按照DeepSeek API的谷时价格计算，平均每GPU小时对应38美元的收入。

这是根据Token处理量和公开API价格折算出的**理论计费收入**，实际情况要复杂得多。但这个数字依然太有吸引力：如果粗暴按照线性外推，按每天24小时、全年365天计算，一张GPU的年化计费产值超过33万美元。

过去几年，AI行业一直在讨论训练一个前沿模型需要多少钱，英伟达的GPU有多贵，云厂商又投入了多少资金建设数据中心。但这些昂贵的计算设备买回来之后，究竟能够生产多少可以卖钱的智能？抛开眼花缭乱的“金融手段”，企业真能赚到的，又有多少钱？

DeepSeek的38美元，提供了一个难得的观察窗口。在资本市场再次对AI巨额投入的回报提出质疑的时候，产业一线的反馈却很乐观。“业内”和“业外”，产生了巨大的分歧。

一位经营Token中转业务的创业者告诉腾讯科技，**最近几个月，中小企业的AI需求正在“全面暴涨”，他能从客户的实际使用情况中感受到这一变化**。今年七八月还只有少数公司在尝试的事情，如今同行已经普遍在做。一些原本有数据安全顾虑的企业也开始私有化部署模型。他也在认真考虑“扩产”。

另外一位AI应用领域的创业者态度也十分鲜明：“英伟达的股票，我还是会继续买。”他接触的B端企业正在加快引入Agent，从日常运营到客户服务，越来越多业务开始AI化。

但他也判断，中美AI市场短期内可能经历一个“小低谷”。此前模型突破、生产率提升和AI替代工作的消息不断推高市场预期，当资本市场开始要求AI在真金白银上交出成绩时，企业应用的实际成果可能还没有跟上，市场热情也会随之回落。

这或许正是当下AI产业面临的矛盾：一线需求正在增长，但从应用落地到形成足以支撑巨额算力投入的商业回报，中间还有一段距离。

DeepSeek的计算提供了另一个值得关注的信号，即使按照谷时价格，高度优化的推理系统仍然能够实现相当可观的单位GPU计费产值。

那么，**随着推理效率不断提高，如果有足够多的用户持续消耗Token，AI是否已经可以成为一门赚钱的生意？答案可能比想象中乐观，但也更复杂。**

一张GPU，每小时38美元

DeepSeek在9月10日发布的V4.1 Flash中，已经披露了不少推理效率优化的技术细节。

按照官方技术报告，这款模型拥有5520亿总参数，采用混合专家（MoE）架构和新的Causal Encoder–Decoder设计，处理输入时约激活80亿参数，生成输出时约激活160亿参数。

模型针对长上下文和Agent场景优化了缓存结构。按照论文披露，全局KV Cache占用降低到上一代的约四分之一，长期保存的缓存占用减少到约八分之一。每Token的全局KV Cache约为890字节，支持最高100万Token上下文。

这些优化直接影响长上下文推理的显存占用、数据传输和服务成本。

10月20日开源的DeepInfer，进一步公开了DeepSeek如何将这些技术整合为大规模在线推理服务。

它集成了此前陆续开源的FlashMLA、DeepGEMM、DeepEP、TileKernels等组件，同时引入专家并行、推测解码、异步调度等机制。

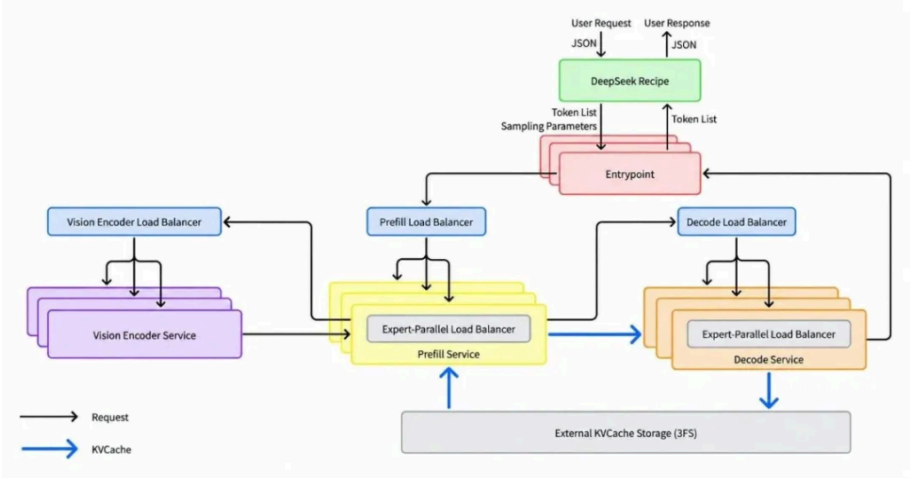

图：DeepSeek在线推理系统示意图

DeepSeek在官方部署问答中重点介绍了三项工程原则：适配不同厂商的加速硬件，将Prefill与Decode分开部署，以及尽可能长期保留KV Cache，减少重复计算。

在生产环境中，Prefill可以部署在普通8卡服务器上，而Decode采用64至128卡超节点，通过大规模专家并行提高吞吐量。DeepSeek还提出将KV Cache保留72小时以上，以适应Agent反复调用相同上下文的需求。

这些优化的核心目标，是在满足延迟要求的前提下，让同样数量的GPU服务更多请求。

不过，这次开源并不意味着DeepSeek已经公开完整生产环境中的所有组件。

官方README文档指出，KV Cache系统、视觉编码与Prefill/Decode分离服务编排、跨数据并行副本的负载均衡等，仍需要外部补齐。部分组件与DeepSeek内部基础设施深度耦合，因此尚未完整开源。

DeepInfer目前也主要面向DeepSeek-V4.1 Flash。其他模型如果在MoE专家组织、注意力结构、数值精度或硬件配置上存在较大差异，很难直接照搬。

因此，38美元并不代表任何企业下载DeepInfer、部署一批GPU，就能获得同样的收入表现。DeepSeek也没有完整公开计算这项指标所需的集群硬件构成、成本账单、付费流量比例及收入确认方式。

但它至少说明，在特定模型与硬件条件下，推理工程优化能够显著提高计算设备的潜在计费产值。

低价出售Token，与一张GPU产生较高的计费收入，并不矛盾。

关键在于，一小时内究竟能够处理多少有效Token，以及有多少Token真正可以向客户收费。

如果推理可以赚钱，为什么模型公司还在亏损？

如果推理效率已经可以做到如此程度，为什么一些大模型公司仍然需要不断融资，甚至持续亏损？

一个重要原因是，训练前沿模型和出售推理服务，本来就是两笔不同的账。

2026年斯坦福大学《AI Index》引用研究机构Epoch AI的数据，估算了OpenAI和Anthropic在模型研发与推理服务方面的计算支出。

2025年，OpenAI计算支出约163亿美元，其中研发相关计算支出83亿美元，推理支出80亿美元，两者几乎各占一半。

2024年，OpenAI的相应支出分别为40亿美元和18亿美元。**也就是说，一年之间，推理计算支出增长了约3.4倍，而研发计算支出增长约一倍。**

Anthropic在2025年的计算支出估计为68亿美元，其中研发相关支出41亿美元，推理支出27亿美元。研发仍然占据较大比例。

这些数字说明，前沿模型公司的算力投入结构正在变化。随着商业用户增加，推理已成为越来越重要的成本来源，但研发开支并没有因为推理业务扩张而消失。

一家追逐SOTA的模型公司，**需要同时承担持续训练和大规模推理服务的成本**。前者包括预训练、后训练、强化学习、数据处理、模型评测及大量实验，后者则需要维持在线服务的算力、容量和稳定性。

Epoch AI特别指出，研发计算支出并不全部用于最后一次正式训练。**大量资源实际上消耗在实验、研究和模型迭代过程中**。因此，某个模型公开的单次训练成本，不能简单视为一家前沿模型公司的全部研发成本。

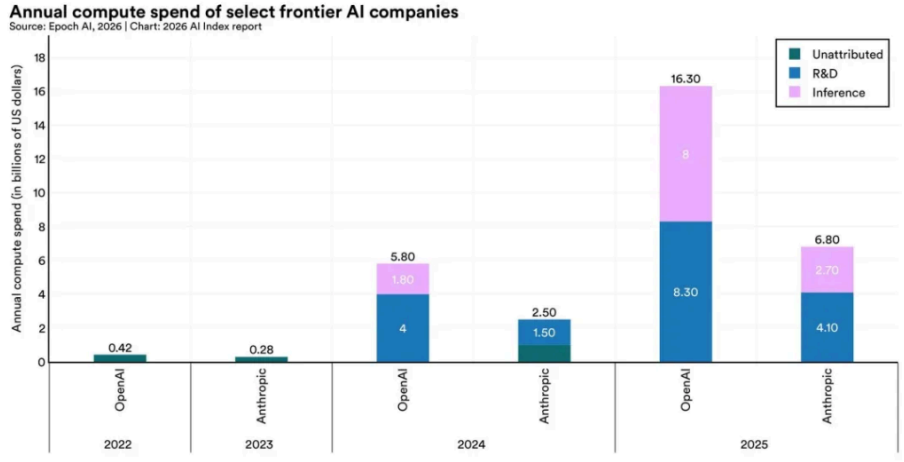

图源：Stanford HAI / Epoch AI，2026年

商业化带来的另一层压力，是用户越多，推理成本也可能越高。

《The Information》今年2月报道，OpenAI在2025年的毛利率约为33%，低于2024年的40%，也低于此前46%的预测。Anthropic对2025年毛利率的预期约为40%，虽然较2024年的负毛利状态改善明显，仍比其早先目标低10个百分点。

报道指出，两家公司毛利率低于预期的重要原因之一，**是实际推理成本高于原先估计**。

这与DeepSeek的38美元看起来形成了矛盾：一边是持续改善的推理效率，另一边却是被推理成本侵蚀的毛利率。

实际上，它们反映的是同一门生意的两个方面。

单位GPU能够生产多少Token，是供给效率；公司需要投入多少GPU，才能满足不同客户的延迟、上下文长度、稳定性和峰值需求，则决定实际经营成本。

即使单位Token成本下降，重度用户增加、任务执行时间延长、模型调用次数上升，也可能使总推理支出迅速增长。尤其在固定月费的产品中，客户支付的价格未必随着Token消耗同步增加。想想每天挖空心思发“重置卡”的Tibo。

图：OpenAI产品与平台负责人Tibo（Thibault Sottiaux）于10月11日在X平台连续发布有关Reset的动态，其中“Day 6 / Reset”获得约290万次浏览。

一家模型公司的推理服务可以拥有正毛利，整个公司却仍然因为持续研发、基础设施和经营投入而亏损。

反过来，如果不承担前沿模型训练，专门经营推理服务，生意的成本结构就完全不同。

不训练模型，只卖Token能不能赚钱？

AI产业链中已经出现一类与前沿模型实验室不同的公司。

它们不以训练最强的基础模型为核心业务，而是部署DeepSeek、Qwen、Llama等开放权重模型，通过多芯片集群、推理框架、模型优化和调度系统，向开发者与企业销售API调用、专属推理实例或私有化部署服务。

对于这些公司来说，模型本身未必需要从头研发，成本主要来自GPU采购或租赁、机房与电力、网络和存储、推理系统研发、模型适配，以及销售、运维和客户支持。

其中最关键的三个变量，是单位GPU产值、实际付费利用率和综合运营成本。

假设一家推理服务商每GPU小时的完全负担成本为10美元，而它能够以DeepSeek披露的38美元作为满负载计费产值的参考，那么理论上只要实现约26.3%的有效计费产出，便可以覆盖这10美元成本。

如果有效计费产出达到50%，收入相当于每小时19美元，扣除10美元后还剩9美元。

当然，这只是用于说明商业敏感性的假设。实际系统的吞吐量、并发和延迟具有复杂关系，低负载下的收入不一定与满负载表现呈线性变化。10美元也不是DeepSeek披露的真实成本，更不能将计算结果当作其实际毛利率。

但这种测算说明，推理系统效率足够高时，商业回报可能具有较大的空间。问题是，GPU本身并不便宜，购买或者租赁GPU，同样不意味着立即拥有稳定收入。

CoreWeave提供了一个可以对照的真实案例。

2026年第二季度，CoreWeave收入25.75亿美元，同比增长约112%，调整后EBITDA达到15.10亿美元，利润率为59%。

但在美国通用会计准则下，公司当季仍净亏损6.26亿美元。问题出在算力生意高昂的资产和资金成本上。CoreWeave需要投入大量资金采购GPU及配套设备，相关资产随着使用逐年折旧；同时，公司依靠债务融资支持扩张，还要承担高额利息。2026年第二季度，其折旧及摊销费用达到13.93亿美元，净利息支出高达6.4亿美元。

折旧反映的是已经购入的算力设备在使用期间逐步计入的成本，利息是为这些投资融资所付出的代价。即使GPU租赁带来了可观收入，这两项负担仍可能大幅压缩利润。

CoreWeave的财报也说明，算力利用率高、收入增长快，并不意味着经营算力就一定赚钱。

更复杂的是，推理算力并不是一个完全同质化的市场。

DeepSeek能够通过深度优化获得较高单位GPU产值，不意味着普通推理服务商可以用相同的硬件、相同的价格获得同样表现。

因此，**推理服务可能是一门具有可观毛利空间的生意，但它并不会自动成为高利润生意**。工程能力影响成本下限，客户需求和定价权决定收入上限，而资本成本影响最终能留下多少利润。

此外，推理市场还面临持续降价的压力。

DeepSeek降低单位Token成本之后，也在通过更低的API价格将一部分效率收益传递给用户。其他公司一旦采用更高效的算法和系统，也可能参与价格竞争。

推理效率提升创造的收益，最终未必全部留给卖Token的公司。

AI利润版图，谁能赚钱？

从英伟达、台积电、SK海力士，到数据中心和云服务商，AI基础设施投资已经为部分上游企业带来了可观的收入和利润。

但对于经营推理服务的企业来说，设备买回来之后，仍然需要不断寻找客户和任务，才能持续创造收入。

目前，Coding是商业化最清晰的AI应用市场之一，但即使在这个付费意愿较强的领域，盈利也并不容易。

《The Information》披露，Cursor在截至2026年1月的季度中，毛利率一度为-23%；如果将免费用户的推理费用全部计入销售成本，毛利率约为-31%。虽然此后毛利率已经转正，但高昂的模型调用成本，仍是AI应用需要面对的问题。

消费应用的情况更加分化。10月12日，曾经的明星AI陪伴公司Character.AI申请破产保护。根据破产文件及公开报道，公司当时仍拥有约1200万月活用户，2026年8月收入达到530万美元，但每月经营亏损仍有800万至900万美元。

仅2026年前八个月，Character.AI就花费了5610万美元购买算力，占运营费用约45%。即使转向更便宜的GPU和开放权重模型，并削减人员开支，也未能实现盈利。法律诉讼和监管压力同样加剧了公司的困境。

但是，AI原生应用并非无法盈利。Midjourney创始人David Holz在今年3月接受《The Information》采访时表示，公司2023年收入已显著超过2亿美元，此后继续增长，并且保持盈利。

但它也不是所有AI应用的普遍样本。图像生成拥有相对明确的使用场景和付费价值，而全天候运行的个人Agent，可能需要持续调用模型、使用工具和重新规划任务，成本结构更加复杂。

从整体市场看，需求实际上正在快速增长。

Menlo Ventures在2026年9月发布的《State of Consumer AI》报告估计，全球消费者AI支出已达到400亿美元，是2025年120亿美元的三倍多。

但值得注意的是，美国成年人AI使用率只从2025年的61%上升到64%。消费者AI支出的高速增长，主要来自**已有用户使用得更深入，付费更多**。新增用户有限。

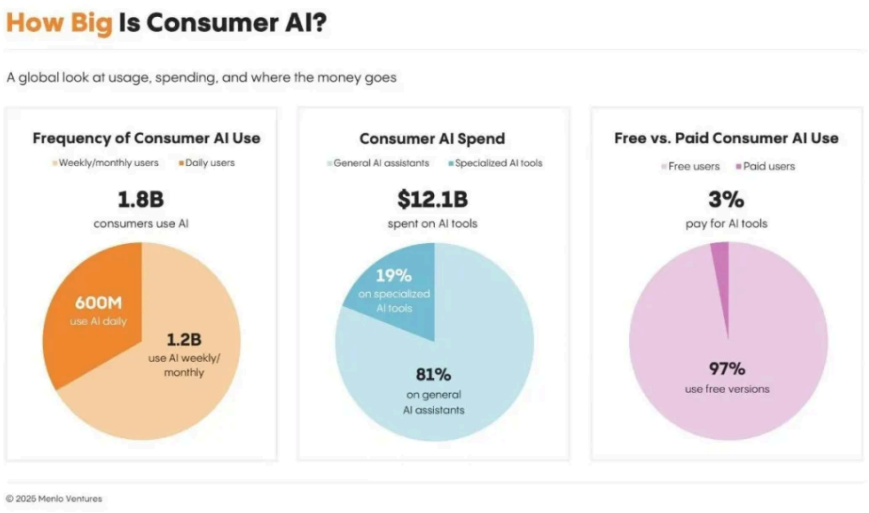

图：Menlo Ventures消费AI支出图

Menlo Ventures合伙人Amy Wu Martin指出，**今年令人意外的变化，是消费者AI市场在没有迎来大量新用户的情况下实现了三倍增长**。推动增长的，是重度用户将AI带入更多生活场景，并开始允许AI代表自己采取行动。

现在，更重要的是一个用户每天有多少任务交给AI，以及每项任务能够创造多少实际价值。这也是Personal Agent（PA）重新成为大厂和创业公司共同关注方向的原因之一。

最近推出的Duet、Dots、Muse、Grokbot以及一批独立创业公司的产品，虽然在入口、记忆、权限体系和执行方式上存在不同，但都在尝试扩大AI能够承接的个人任务范围。

如果Agent能够持续处理邮件、安排工作、操作软件、完成采购、协调不同服务，AI调用便可能从用户主动发起的短时会话，转向围绕实际任务展开的长流程执行。

Agent之间的协作，以及越来越多由机器直接发起的工具调用和服务请求，也可能进一步扩大推理消费市场。

不过，更多Token消耗本身并不代表商业成功。

一家PA公司如果每月向用户收取20美元，却需要花费30美元购买模型调用和其他服务，那么它可能帮助上游模型商扩大收入，自己却仍然无法盈利。

同样，模型越来越高效，也可能让过去需要大量Token的任务变得便宜。即使Agent数量大幅增长，市场总收入也不一定以相同比例增长。

模型公司希望扩大推理消费市场，应用公司希望以更低的推理成本完成任务，用户关心实际完成的工作值多少钱。

DeepSeek的38美元，展示了在特定条件下，高效率生产Token所具有的潜在收入能力。

过去几年，资本市场为AI投入了巨额资金，芯片、存储和算力基础设施率先从中受益。随着推理系统继续进步，模型公司和应用公司一直在面对另外一道更复杂的商业命题：**如果越来越多企业都能以更低的成本生产智能，谁能找到足够多愿意购买智能的客户？**

还有更难的问题：如果AI是一个新的时代，token承载的“智能”，要创造什么增量？AI Native的核心逻辑，还在一片混沌中等待。

本文来源：腾讯科技

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

258 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

《付鹏说·第七季》全新升级上线！立即订阅

实物黄金与“数字黄金”BTC的两次背离

2026年Q1季度，黄金吸收了主权资金去美元化、央行购金以及地缘对冲的核心买盘；而**BTC完全被视作高Beta的风险资产与流动性水龙头，**在利率维持高位、宏观风险偏好收缩时，风险资产属性明显，同时流动性上，大量加密资产的需求转入到了美股AI资产领域，也带来了加密资产的流动性变的单薄。

随着利率的走高流动性的收紧，黄金最终补跌，同时对于BTC来说却没有怎么放大波动，两者之间回到了同样的角色，都受到流动性，利率，资产虹吸等相同因素的影响.....

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

新用户注册，免费解锁 3 篇付费文章

写评论

请发表您的评论

表情 图片

发布评论