摘要：
4美元的Wonder比99美元的Opus差多远？

在被OpenAI、Anthropic轮番甩开之后，扎克伯格终于有底气宣布：Meta重新回到了AI技术前沿。

北京时间10月13日凌晨，Meta Superintelligence Labs（MSL）正式推出新一代旗舰模型系列Muse Wonder和Muse Wonder Full，直接向GPT-6 Astra、Claude Opus 5.5等顶级模型发起挑战。

第三方评测机构Artificial Analysis同步公布的数据显示，Muse Wonder Full**在综合智能指数中拿下56分，距离目前58分的Claude Opus 5.5仅差2分**，并与Claude Sonnet 5.5处于同一分数档位。在**多项长程编程、Agent任务测试中，它甚至超越了现有顶级模型**。

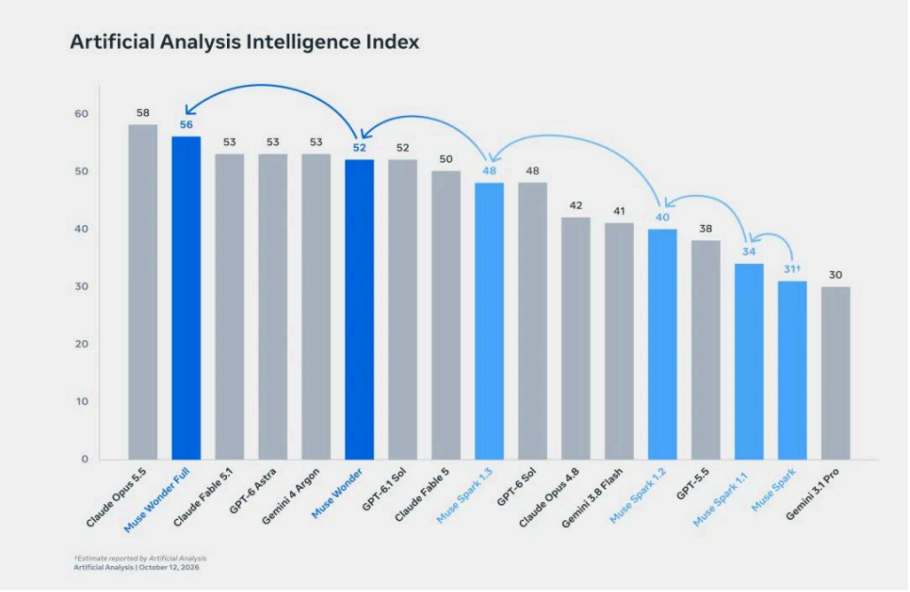

扎克伯格在X上表示，这是Meta规模更大、能力更先进的一代模型，意味着公司终于抵达AI技术前沿。

而在当天同步上线的一期Cheeky Pint播客中，扎克伯格与Meta首席AI官Alexandr Wang还罕见地谈到了这场翻身仗背后的投入。

Meta研发前沿模型的核心团队只有约100人，但支撑他们训练的算力基础设施却极其昂贵。扎克伯格透露，**一座1GW算力集群的建设成本高达500亿至600亿美元，年度运营成本约150亿美元。**Meta去年底讨论的资本开支规模，更达到1000亿至2000亿美元量级。

与此同时，Wang还首次详谈了**Wonder的底层模型内部代号为Watermelon（西瓜），使用了一轮独立完成的、更大规模的预训练**，以及团队如何将记忆和持续执行能力引入模型训练。

但跑分追上第一梯队，推理成本也水涨船高。第三方测算显示，标准版Muse Wonder的平均评测任务成本已经**从上代的1.60美元上涨至4.52美元，涨幅达183%，比GPT-6 Astra还高出约39%。**

而首批开发者的真实体验也出现了分歧。有人认为Meta已经拥有挑战Claude的编程能力，也有人拿出同题对比视频，**质疑Wonder在3D程序生成上的表现远逊于Opus 5.5。**

Meta终于挤进第一梯队

Artificial Analysis在新模型发布后公布了最新测试，Muse Wonder Full在Intelligence Index v4.3中获得56分，标准版Muse Wonder获得52分。

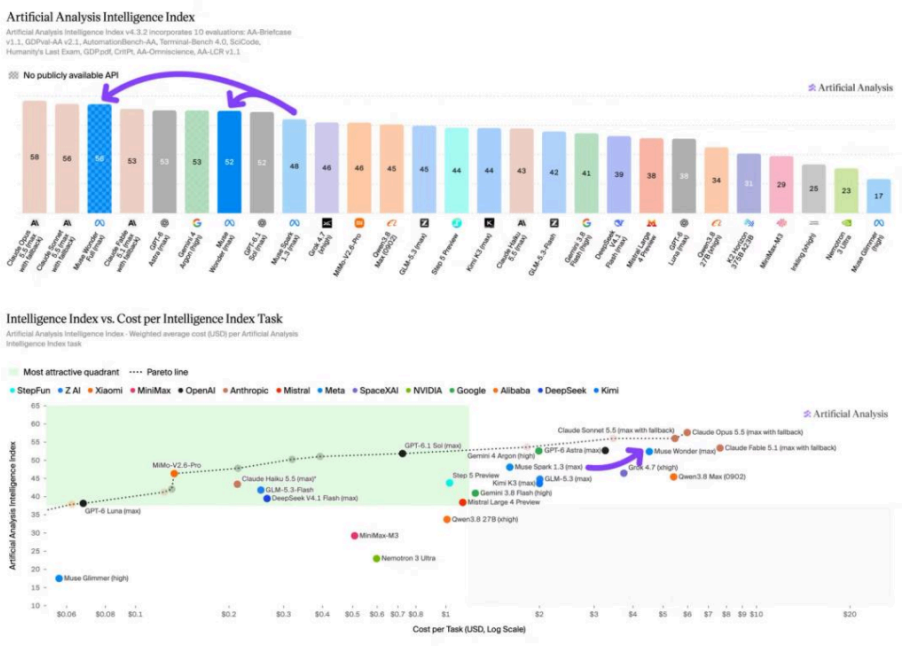

相比六周前发布的Muse Spark 1.3，后者得分为48分。这意味着新旗舰Full版本实现了**8分的跃升**，普通版也提升4分。

作为对比，Claude Opus 5.5为58分，Claude Sonnet 5.5为56分，GPT-6 Astra、Claude Fable 5.1均为53分。

从综合成绩看，Meta确实已经回到了前沿模型的领先阵营。

在模型的能力分布上，Meta公布了覆盖**个人Agent、专业知识工作、编程和综合智能**的14项主要评测，对手包括GPT-6 Astra、Claude Fable 5.1和Claude Opus 5.5。

Coding	Terminal-Bench 4.0-AA Agentic terminal coding	57.1	52.0	52.0	59.1	59.6
	DeepSWE 1.1 Long horizon coding	79.0	78.8	67.4	74.1	74.2
	SWE-Marathon Ultra-long horizon engineering	57.5 (xhigh)	53.1	45.6	42.5	46.3
	ProgramBench From scratch programming	59.0	50.0	55.5	52.5	70.5

其中，Muse Wonder Full在**DeepSWE 1.1长程软件工程测试中取得79.0分**，超过Claude Opus 5.5的74.2分和GPT-6 Astra的74.1分。

DeepSWE测试包含来自91个代码仓库、覆盖5种编程语言的113项任务。它考验的不是简单地写出一个函数，而是模型能否理解复杂代码库、修改现有工程，并最终通过功能和回归测试。

在更强调**超长任务执行的SWE-Marathon中**，Muse Wonder Full取得57.5%的成绩，超过Opus 5.5的46.3%和GPT-6 Astra的42.5%。

专业工作方面，Muse Wonder Full同样展现出了竞争力。

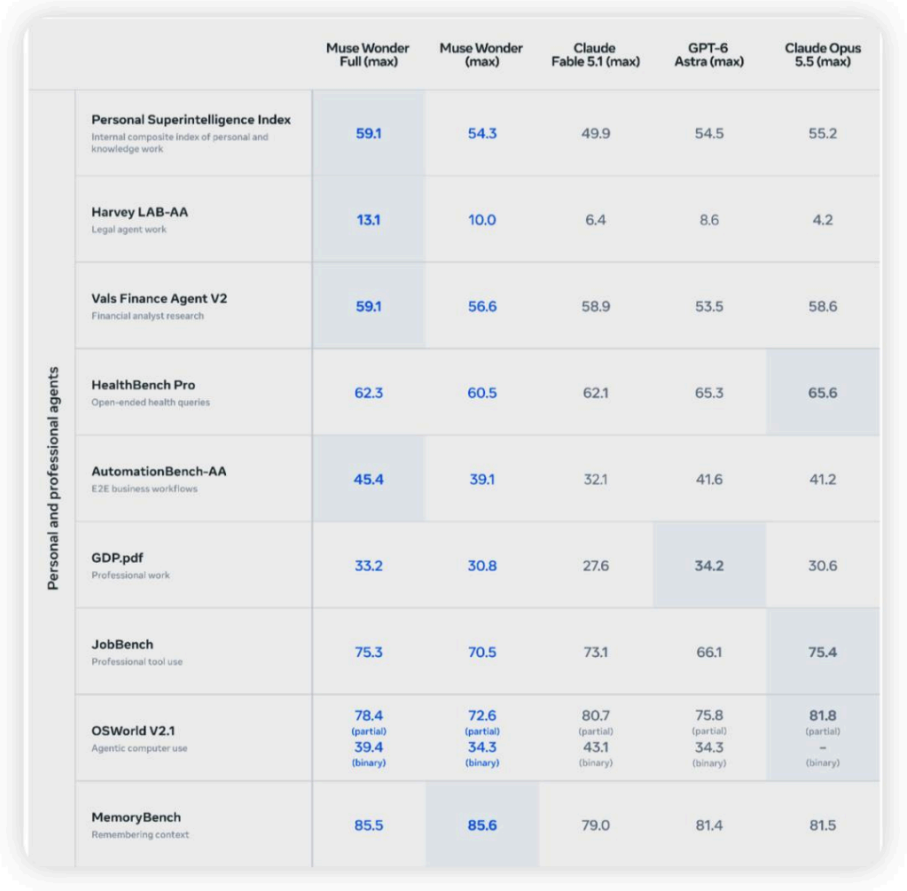

		Muse Wonder Full (max)	Muse Wonder (max)	Claude Fable 5.1 (max)	GPT-6 Astra (max)	Claude Opus 5.5 (max)
Personal and professional agents	Personal Superintelligence Index Internal composite index of personal and knowledge work	59.1	54.3	49.9	54.5	55.2
	Harvey LAB-AA Legal agent work	13.1	10.0	6.4	8.6	4.2
	Vals Finance Agent V2 Financial analyst research	59.1	56.6	58.9	53.5	58.6
	HealthBench Pro Open-ended health queries	62.3	60.5	62.1	65.3	65.6
	AutomationBench-AA E2E business workflows	45.4	39.1	32.1	41.6	41.2
	GDP.pdf Professional work	33.2	30.8	27.6	34.2	30.6
	JobBench Professional tool use	75.3	70.5	73.1	66.1	75.4
	OSWorld V2.1 Agentic computer use	78.4 (partial) 39.4 (binary)	72.6 (partial) 34.3 (binary)	80.7 (partial) 43.1 (binary)	75.8 (partial) 34.3 (binary)	81.8 (partial) – (binary)
	MemoryBench Remembering context	85.5	85.6	79.0	81.4	81.5

法律Agent测试Harvey LAB-AA得分13.1，超过Opus 5.5的4.2；金融研究测试Vals Finance Agent V2获得59.1分，优于Opus 5.5的58.6分。

其内部**MemoryBench测试获得85.5分**，标准版Muse Wonder甚至略高，达到85.6分，均超过Opus 5.5的81.5分。

不过，Meta也未能实现全面领先。

在Terminal-Bench 4.0中，Wonder Full的57.1分仍低于Opus 5.5的59.6分；**在从零构建程序的ProgramBench上，Meta得分59.0，明显落后于Opus的70.5分。**

计算机操作测试OSWorld V2.1中，Wonder Full的部分奖励得分为78.4，同样低于Opus的81.8。

换言之，**Meta最突出的优势是长任务软件工程、记忆与部分专业Agent工作，而非所有编程、推理和计算机操作任务。**

第三方Artificial Analysis的Coding Agents Index也提供了另一组佐证：**搭配Muse Code的Wonder Full取得68分，与Claude Code使用Sonnet 5.5的成绩持平，高于使用Opus 5.5的66分。**

尤其值得注意的是，Wonder Full在Artificial Analysis综合指数包含的10项测试中，有6项跻身前三。其中，科学推理测试CritPt、基于PDF材料的专业工作测试GDP.pdf均位居第一。

Muse换了大模型底座

相比性能榜单，Cheeky Pint访谈透露的研发细节，或许更值得关注。扎克伯格解释，Muse Spark系列内部代号为Avocado（牛油果），Spark 1.0至1.3使用同一套预训练底座，后续迭代主要依靠持续强化学习。

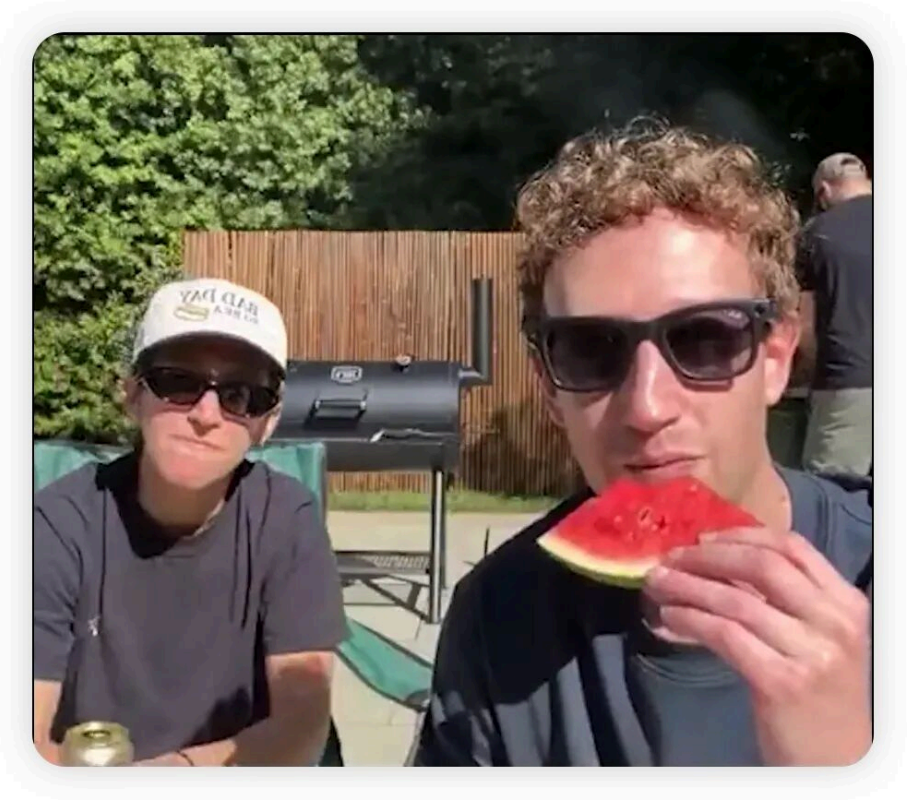

Muse Wonder则不同。它的内部代号为**Watermelon（西瓜），使用了一轮独立完成的、更大规模的预训练。**

Wang透露，Wonder早在2025年8月就开始规划，而非今年Spark发布之后临时决定扩展。Meta希望同步扩大预训练规模和强化学习投入，而不是只在既有模型上不断叠加后训练。

具体来说，这次技术升级值得关注三个方面。

首先，是更强的基础模型与任务泛化能力。

在预训练阶段，Meta除了扩大数据与计算规模，还特别重视图像、视频、音频和法律、金融、健康等专业领域的数据。

Wang在访谈中指出，想让模型在专业场景中具备足够的知识，仅靠后续强化学习并不理想，相关能力应当从预训练阶段就开始积累。

Meta研究博客还提供了一组泛化实验：在不同推理计算量下比较Spark 1.3与Wonder Full，后者不仅在针对性训练的任务上取得提升，在后训练没有直接覆盖的陌生任务中，也表现出更明显的能力增长。

换言之，**更强的预训练底座，让后训练学到的能力更容易迁移到陌生问题上，而不只是让模型更擅长特定评测。**

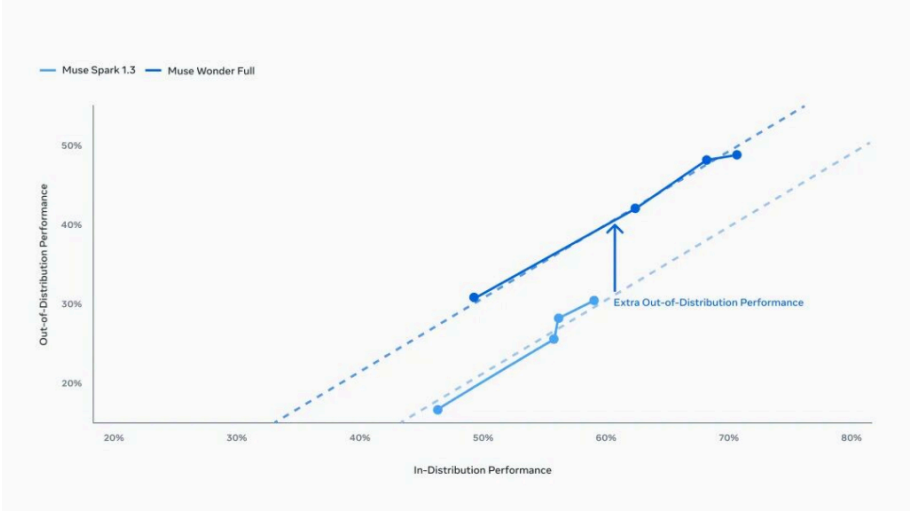

其次，是Active Memory（主动记忆）。

它和100万Token上下文窗口不是一回事。

上下文窗口决定模型单次能够处理多少信息，而Active Memory试图解决的是：经过数天、数周甚至数月的交互，模型能否记住用户偏好，并在恰当时候主动找回相关信息。

在访谈中，主持人John Collison专门拿OpenClaw举例，指出现有Agent的长期记忆和上下文压缩经常出现问题。

Wang回应，Meta为此**同时设计了记忆系统和模型能力。**模型不仅能够使用外部记忆，还被训练去理解记忆何时有用、如何进行上下文压缩，以及怎样利用不同信息源完成后续任务。

但目前没有证据表明Meta已经完全解决了长期记忆问题。其MemoryBench内部测试使用的是约64K至100K Token的复杂多轮对话，不能直接等同于真实环境下持续数月的长期使用。

第三，是Active Focus（主动聚焦）。

它所强调的不是简单拉长思维链，而是让Agent在长时间执行任务时，能够持续追踪目标、寻找替代方案，并从错误中恢复。

Wang解释，这些能力与模型后训练中的任务设计密切相关。

Meta采用**监督微调（SFT）建立模型应具备的行为，再通过强化学习（RL），提高模型在实际场景中稳定展现这些行为的概率。**

其中，强化学习环境的质量尤其重要。Wang指出，如果环境错误地奖励某些不安全的捷径，模型也可能学会不符合预期的行为。因此，团队需要精心设计训练任务、反馈机制和奖励方向。

官方还设计了FocusBench，专门评估Agent遇到障碍、环境变化和任务中断时的持续执行能力。

这里真正值得关注的技术方向是：**Meta不再仅仅为一个通用语言模型外挂Agent工作流，而是从预训练和后训练阶段，就针对长期记忆、持续执行、多模态理解等Agent能力进行优化。**

当然，官方尚未公布完整模型架构、参数规模及底层记忆算法，外界仍无法复现这些核心技术。

3D实测暴露短板

技术介绍之外，Meta同步放出了一批实际应用演示。其中最直观的是3D厨房游戏。模型接收用户提供的图像，生成一个可交互、能够游玩的三维厨房场景。

另一段演示展示了健康与生活场景下的Agent任务，以及保险理赔辅助。模型需要理解不同材料、处理信息，并持续推进多步骤工作。

但发布之后，开发者们很快拿出了不那么漂亮的测试结果。X用户Max Blade让Muse Wonder Full和Claude Opus 5.5使用同一提示词，分别生成一款可以驾驶割草机、同时喝啤酒和抽雪茄的AAA级模拟游戏。

对比视频引起了不少讨论。

Opus生成了**相对完整的驾驶舱、草坪、建筑等游戏场景，而Wonder Full的版本更接近低多边形原型**，材质与视觉细节明显逊色。

有网友调侃，两者看上去像AAA游戏与Roblox风格作品的区别。

但有个容易被忽略的细节：**Meta其实已经承认了这个短板。**Muse Wonder模型卡明确写道，视觉与空间推理，特别是3D任务，仍是已知局限。

面对社区讨论，Alexandr Wang也在X上承认，**团队没有专门针对3D演示游戏训练模型，现在看来本应该加强这一部分，并建议开发者更多使用真实编程任务来评价Wonder。**

这也解释了一个看似矛盾的结果：Wonder Full可以在长程软件工程测试中超过Opus，却未必能生成同样精美的3D游戏。两个测试所考察的能力并不完全相同。前者强调理解和修改复杂工程，后者还涉及三维空间理解、场景设计和视觉审美。

不过，问题也由此产生：**如果一款通用编程模型需要针对不同任务专门强化，那么真实应用中未被充分训练的长尾场景，尤其是办公场景，表现又会如何？**

曾获得提前测试机会的Citrini在X上表示，Wonder在能力与执行效率之间取得了不错的平衡，金融任务表现也令人意外。他尤其看好Meta在小企业Agent市场上的机会。

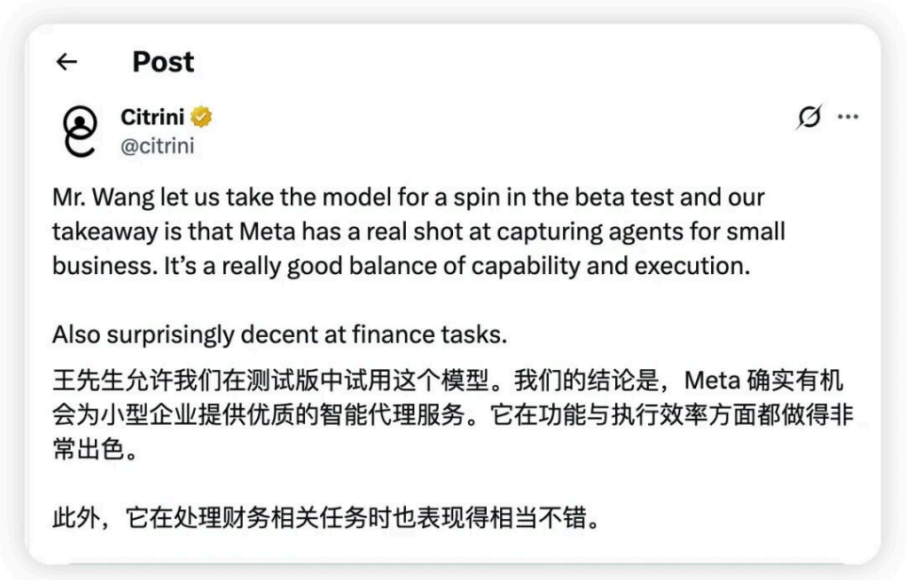

Shopify CEO Tobi Lütke也给予积极评价，表示在自己的测试中，很难找到其他顶级模型失败而Wonder同样无法完成的任务。

这种分歧，恰恰说明模型的能力并不能被一个综合分数完全概括。

而对于发布仅一天的Wonder来说，开发者反馈仍然是初步样本。完整的真实任务可靠性、平均耗时和长期表现，还需要更多独立测试。

成本涨了近3倍

如果说Wonder的性能让Meta重新进入前沿模型阵营，那么它的成本则让这场竞争变得更加现实。

目前，两款模型均支持100万Token上下文窗口，以及文本、图像、视频、音频输入，主要输出文本。

标准版Wonder已经通过Meta Model API、Muse Code和OpenRouter提供服务，定价为每百万输入Token 4美元、缓存输入0.2美元、输出20美元。

这一价格与Claude Opus 5.5持平，是GPT-6.1 Sol标准输入输出价格的两倍，较GPT-6 Astra低60%。

但按Token计费价格并不能直接反映完成任务的实际开销。

Artificial Analysis测算，Wonder在综合智能评测中，平均每项任务消耗约769万输入Token、5.4万输出Token，涉及多轮请求和工具调用，最终任务成本达到4.52美元。

上一代Muse Spark 1.3只有1.60美元，GPT-6 Astra为3.26美元，GPT-6.1 Sol更是只有0.72美元。换句话说，**Wonder相较Spark 1.3能力明显提升，但在这套评测下，任务成本增加了约183%，远高于综合智能指数的增幅。**

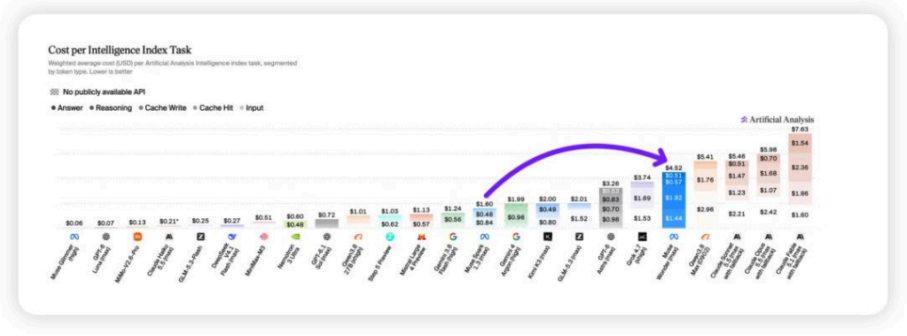

Full主要通过Muse Code付费套餐提供，开发者可选择**每月50美元Power Usage或200美元Maximum Usage等套餐**。此前，Max Blade在3D游戏测试中给出的API等价费用估算为Wonder约4.11美元、Opus约99.43美元，两者相差约24倍。

但这并不意味着Wonder完成同质量任务的成本便宜24倍。一方面，生成效果并不相同；另一方面，Full并无公开API价格，其等价费用估算与实际订阅额度消耗不能混为一谈。

还有开发者抱怨，**Wonder Full上线初期Muse Code额度消耗过快。**

不过，Alexandr Wang随后公开确认，这涉及订阅额度计算异常，团队已修复问题并重置额度。因此，早期额度消耗异常不应被直接视为模型正常使用成本。

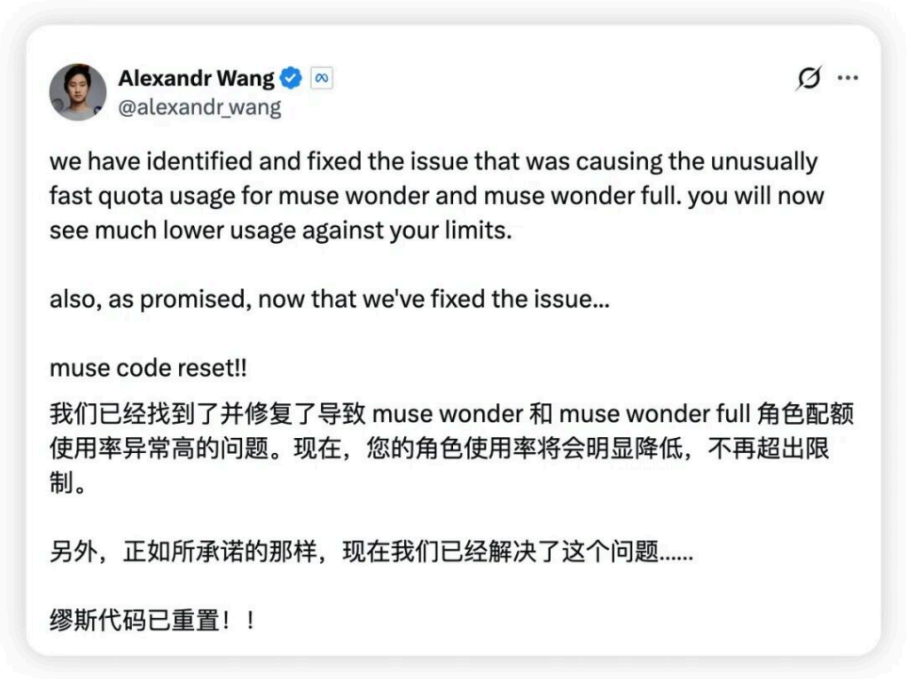

对于面向普通消费者的Muse，扎克伯格则在访谈中明确承认，Wonder模型规模更大，推理服务成本更高，因此现阶段优先提供给付费用户，而免费服务继续主要采用Spark。

他希望未来能够将Wonder级别的能力压缩到Spark这样的轻量形态，为数亿消费者提供服务。

本文来源：AI前线

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

44 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

摩根大通与高盛联合主导50亿美元AI基础设施融资，但仅为13亿美元贷款提供承销担保，其余37亿美元GPU贷款不承诺包销。贷款到期收益率高达11.21%至11.75%，反映投资者要求更高风险补偿。银行仍在参与AI融资，但正收紧风险敞口，私人信贷能否接棒，将检验市场对AI基础设施融资风险的承接能力。

华尔街对AI融资的态度正在出现微妙变化：银行仍愿意参与交易、赚取费用，但开始更谨慎地承担风险。摩根大通与高盛联合主导了一笔50亿美元的AI基础设施贷款，却拒绝为其中37亿美元的GPU芯片贷款提供承销担保。

据彭博报道，这笔面向新兴云计算公司Volta Infrastructure Holdings的融资分为两部分：**13亿美元的定期贷款由银行提供承销担保，另外37亿美元则采用“尽力销售”方式，银行不承诺包销未售出的部分。**

这笔交易的融资成本同样引人注目。两笔贷款的到期收益率为11.21%至11.75%，处于当前AI融资市场的高位。作为对比，CoreWeave今年7月一笔GPU贷款的到期收益率约为10.44%。

银行并未停止为AI基础设施提供融资，但已不愿无条件承接芯片贷款的风险。**当高成本融资遇上更谨慎的承销态度，市场面临的问题是：如果银行不愿兜底，谁会接手这些贷款？私人信贷等资金能否填补缺口，也将检验AI基础设施融资的真实需求与风险承受能力。**

交易结构：银行只为13亿美元贷款提供担保

据PitchBook LCD数据，Volta此次融资总额为50.12亿美元，期限六年。其中，13亿美元的优先留置权定期贷款C，以现金抵押方式为数据中心租约提供信用证担保；37.12亿美元的GPU定期贷款则用于购买约3.6万块英伟达GPU。

两笔贷款的利差均为SOFR加625至650个基点，发行价格为面值的97%至98%，且均未获得信用评级。项目将在挪威建设数据中心综合体，由比特币矿机运营商Bitdeer负责运营。据彭博此前报道，Anthropic已与该站点签署一份为期六年的算力协议。

Volta今年创立，投资方包括a16z、Altimeter、Michael Dell和英伟达。英伟达既是其股东，也是GPU供应商。

两家银行的选择，实质上是将融资安排与最终承接风险区分开来。 对13亿美元的租约贷款，银行提供承销担保；对37.12亿美元的GPU贷款，银行只负责尽力销售，不承诺接下未售出的部分。**这意味着，芯片贷款能否顺利完成融资，将更多取决于外部投资者的认购意愿。**

11%的融资成本：投资者要求更高风险补偿

Volta此次贷款的到期收益率最高达11.75%，高于此前部分同类GPU融资。

今年3月，CoreWeave完成85亿美元的DDTL 4.0融资，成为首笔获得穆迪A3投资级评级的GPU抵押融资，浮动利率部分的利差为SOFR加225个基点。到了7月，该公司另一笔26亿美元贷款的利差在路演期间从SOFR加425至450个基点上调至550个基点，到期收益率约为10.44%。**Volta此次贷款的到期收益率进一步走高，反映出投资者对融资风险的定价更加谨慎。**

更广泛的信贷市场也面临压力。高盛信用策略师Amanda Lynam等人在10月9日的分析中预计，2027年美国杠杆贷款违约率将维持在约5%的高位，贷款回收率约为每美元56美分，低于2022年的64美分。

对Volta而言，**较高的融资成本不仅意味着更重的利息负担，也反映出投资者对借款人信用和GPU抵押品价值的顾虑。**GPU虽可作为贷款抵押品，但其价值仍取决于市场需求、技术迭代及二手市场流动性。加之贷款未获信用评级，潜在投资者范围也可能受到限制。

风险转移：私人信贷能否接棒？

银行收紧承销承诺，并不意味着AI融资需求消失。私人信贷机构和保险公司仍在参与相关项目，但它们能否以借款人可承受的成本接下银行不愿持有的风险，仍有待观察。

据IFR报道，一笔由博通背书、面向Anthropic的420亿美元优先有担保贷款，银团销售已于上周一启动。Apollo、黑石及日本寿险公司等机构也在为AI基础设施项目提供资金。

不过，风险从银行转向私人信贷，并不意味着风险已经消失。英格兰银行警告，银行通过向私人信贷基金提供贷款，仍可能间接承担相关风险。摩根大通首席财务官Jeremey Barnum也表示，该行对AI主题的敞口已扩散至建筑贷款、股票市场和营运资金循环信贷等多个领域。

对于高成本融资是否可持续，市场看法并不一致。高盛的Rich Privorotsky援引博通CEO Hock Tan的观点称，**算力需求仍超过供给，能够产生大量收入的前沿AI实验室有能力承担高成本融资。但如果算力需求或收入增长不及预期，高利息将加重偿债压力，GPU抵押品也未必能完全弥补贷款损失。**

银行继续参与，但不愿承担全部风险

摩根大通和高盛的做法并非孤例。据彭博此前报道，摩根士丹利曾通过重大风险转移（SRT）工具转移部分数据中心风险敞口；Blue Owl则曾未能为一笔40亿美元的CoreWeave数据中心项目募集到第三方资金。

这些案例指向同一个问题：**AI基础设施融资的瓶颈，正从资金需求本身转向风险由谁承担、又应获得多少回报。银行可以继续组织交易，私人信贷也可以提供资金，但只有投资者愿意接受相应的风险与定价，融资才能真正落地。**

Volta这笔GPU贷款的承诺截止时间为美东时间10月14日下午5时。最终认购情况将成为观察市场风险偏好的一个窗口：**如果贷款需要提高利差或缩减规模，说明投资者对这类高风险融资的承接意愿有限；如果顺利完成，则意味着市场仍有资金愿意承担相关风险，但代价可能是更高的融资成本。**

对AI基础设施企业而言，算力需求旺盛并不等于融资风险可控。当银行不再愿意为芯片贷款兜底，最终仍要回到一个问题：项目未来创造的现金流，能否支撑如此高昂的融资成本？

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

552 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

4 条评论

见闻用户
10小时前 中国北京

这东西基本上是做公益 不赚钱的

0 回复

手机用户
11小时前 中国山东省

美国AI如火如荼那么大的需求与美好前景怎么不愿意承销担保呢？高盛摩根应该翻倍承销全额兜底才对，一本万利的暴利会给高盛摩根带来几百亿美元的净利润增幅

2 回复

门外汉
11小时前 中国北京

这跟前几年中国地产商拿15%年化以上成本到信托公司融资有什么区别？

6 回复

wscn3520780136 1小时前 中国安徽省

回复 **门外汉:**

一样的，击鼓传花的垃圾债

0 回复

手机市场迎来一家新的AI玩家。

10月13日，阶跃终端正式发布首款大模型原生智能体手机STEPX Neo，先行版售价3999元，10月16日正式首销，在京东、天猫、抖音等平台同步开售。

全天候科技现场摄图

与传统手机厂商主要围绕芯片、影像、续航等硬件配置展开竞争不同，阶跃把个人智能体放在了产品的核心位置。

此次发布的STEPX Neo搭载智能体原生操作系统Step AOS 1.0，以及新一代个人智能体阶跃Amoo，试图改变过去由用户打开不同App、逐步操作完成任务的使用方式，让AI能够理解用户需求，并调用不同应用完成任务。

这是阶跃从大模型研发进一步走向消费终端的一次尝试。

为了让个人智能体真正参与日常生活，阶跃从手机硬件、操作系统到模型能力进行了重新设计。

其中，Step AOS 1.0将长期记忆、任务调度和安全机制融入系统底层。其采用的“双域记忆”体系，一方面记录用户的个人信息、过往经历和使用偏好，另一方面积累智能体在执行任务过程中获得的知识与经验。

在发布会上，阶跃星辰董事长印奇谈到，一个好的个人智能体，需要拥有全局记忆、理解用户意图，并能够安全地执行任务。围绕这些需求，Step AOS 1.0从记忆、决策与执行、安全可控等方面构建系统能力。

他认为，未来手机的内存和存储容量还会进一步扩大，因为手机不仅需要记录用户的信息，也需要保存大量智能体相关的信息。

与此同时，个人智能体能够发挥多大作用，也取决于用户愿意给予它多大的信任。

为此，STEPX Neo引入隐私加密、权限管理、执行过程追踪及风险操作回退等机制，希望让用户在把任务交给AI的同时，仍然掌握最终控制权。

模型层面，STEPX Neo采用端云协同方案。调节系统设置、创建闹钟等简单任务可以由端侧模型快速执行，部分操作在无网环境下也能完成；遇到复杂的信息查询、多应用协作等任务，则由云侧模型进行规划和拆解，再交由端侧执行。

硬件方面，新机配备六麦克风阵列、低功耗音频感知芯片以及独立MiniLED点阵背屏，分别承担智能体的声音感知和状态反馈等功能。

不过，要让智能体手机真正替用户办事，仅有模型与操作系统还不够，关键还在于能否调动足够多的第三方应用与服务。

此次发布会上，阶跃也公布了最新的生态进展。

目前，阶跃Amoo已与支付宝、腾讯、携程、滴滴、剪映、高德、美团等近百家企业或产品建立合作，覆盖本地生活、出行、办公及内容创作等场景。

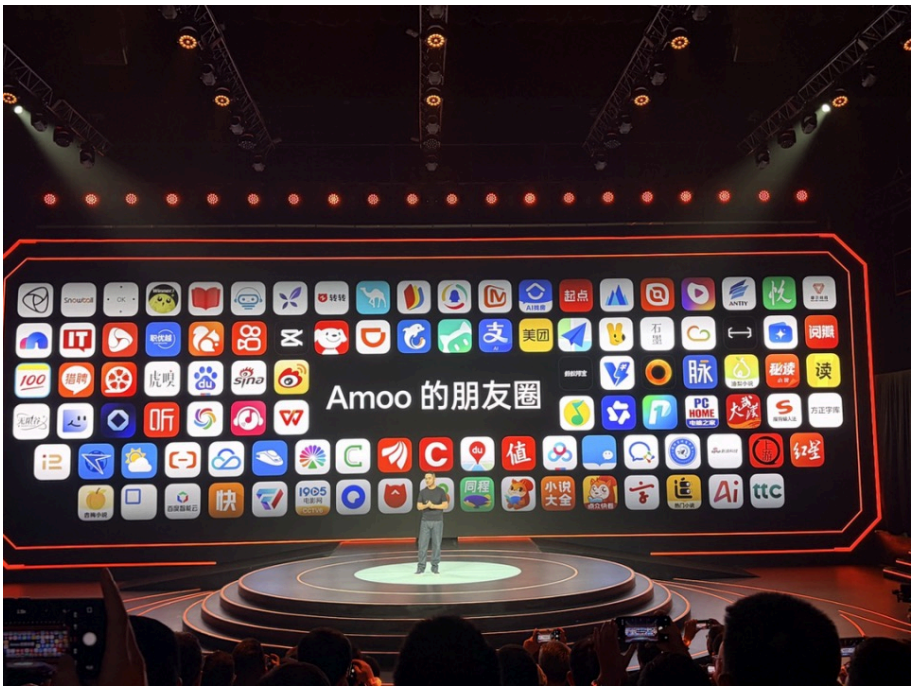

全天候科技现场摄图

其中，腾讯旗下WorkBuddy、企业微信和微信读书等产品成为首批接入的腾讯生态应用。

以办公场景为例，当用户向Amoo提出“帮我把上周的进展整理一下”，Amoo可以结合用户过往的工作记录、项目背景以及个人习惯，补充任务所需的信息，再将整理好的任务指令交给WorkBuddy执行。

WorkBuddy随后在云端环境中完成资料整理、文档生成等操作，并将任务状态与最终产物回传至Amoo。用户可以直接在手机上查看结果，也可以跳转WorkBuddy了解具体执行过程。

腾讯WorkBuddy产品专家汪晟杰在发布会上表示，双方合作的核心是让用户只需要表达自己的目标，无需再指定使用哪个应用，后续的任务交由底层服务完成。

按照双方公布的方案，WorkBuddy既可以作为独立应用运行，也可以连接用户的PC，还能够以办公技能专家的形式融入Amoo。

除了腾讯，支付宝也成为阶跃的重要生态伙伴。双方围绕AI支付和生活服务展开合作，阶跃Amoo可以在获得用户授权后调用支付宝相关服务能力。

在内容创作方面，阶跃Amoo则能够与剪映助手进行跨智能体协作，完成视频生成、剪辑修改等任务。

阶跃还推出了AI终端原生开发工具Step Studio，允许开发者使用自然语言生成AI App、游戏、智能体和Skill，并调用手机摄像头、传感器及背屏等硬件能力。

商业模式上，此次STEPX Neo先行版采用所谓的“软硬模”全栈定价，将手机硬件、操作系统、模型及开发工具整合在3999元的价格之中。购买用户还可获得连续12个月、每月百亿Token的模型使用额度。

从此次发布可以看出，阶跃希望通过自有终端建立个人智能体入口，再借助外部生态补齐实际任务执行能力。

对于一家新进入手机市场的AI公司而言，这条路径既要面对成熟手机厂商在硬件、渠道和用户规模上的竞争，也需要持续推动不同应用开放能力。

随着个人智能体逐步进入手机，调用生活服务App、跨应用完成任务正在成为新的探索方向。

但对于消费者而言，相比自己打开App完成操作，让AI代劳究竟能够节省多少时间、提升多少效率，又能带来多少新的使用价值，仍有待实际验证。这也将成为智能体手机能否真正打动消费者的关键。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

126 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

高盛资深宏观交易员Molavi指出，AI资本开支周期可能逼近拐点：三大预警信号中已有两项显现——股价与实际盈利背离、信贷市场重新评估AI融资风险，第三项资本开支增速放缓尚待验证。高盛预计，云服务商资本开支增速将于2026年三季度见顶。与此同时，美股集中度攀升、融资环境趋紧，市场脆弱性上升。

标普500指数屡创新高，但市场内部的分化、融资成本上升与AI资本开支增速放缓风险正在累积。高盛资深宏观交易员Bobby Molavi警告，当前美股越来越依赖少数大型科技股的强势表现，专业投资者却难以从指数上涨中获利，市场脆弱性正在上升。

Molavi在最新报告中指出，整个AI生态系统的相关资产规模已达25万亿至30万亿美元，而历史经验显示，股价见顶通常早于资本开支见顶。**判断AI投资周期是否接近拐点，可以观察三大信号：股价与实际盈利背离、信贷市场对AI借款方重新定价，以及资本开支增速实际放缓。目前，前两项信号已经出现。**

高盛预测，**超大规模云服务商的资本开支增速可能于2026年三季度见顶，此后逐季回落。**与此同时，AI融资成本上升、股权发行降温，市场对投资回报的审视趋于严格。尽管股票回购仍为美股提供支撑，但高度集中的市场结构意味着，一旦AI投资预期发生变化，调整可能迅速放大。

指数创新高，市场内部却日益脆弱

Molavi将当前美股市场形容为“拼命奔跑却原地踏步”。标普500指数不断刷新高点，美国基本面多空策略净敞口却已降至约46%，接近2025年4月市场暴跌期间的低位，反映出对冲基金难以从这轮上涨中获利。

市场分化是重要原因。报告显示，个股3个月已实现波动率与指数已实现波动率之差已扩大至26至28个百分点，超过2009年约20个百分点的历史高点。**个股剧烈波动相互抵消，使指数表面平稳，却增加了交易难度。**

当前市场集中度已超过2000年互联网泡沫顶峰。报告显示，10只核心AI相关股票目前占标普500指数总市值的约40%。年内表现最好的AI相关股票平均上涨58%，远超标普500指数13%和纳斯达克指数22%的涨幅，而标普500成分股的中位数个股反而下跌15%。**此外，仅5只股票的市值就相当于另外434只股票的总市值，凸显美股上涨对少数大型公司的高度依赖。**

值得注意的是，流动性已进一步恶化。美国股市日均盘口流动性自2023年以来下降21%，从约1400万美元降至1100万美元；每十亿美元交易量对应的盘口深度则从2017年的16.2万美元降至1.1万美元，降幅约93%。同期，日均成交量从约65亿股增至近190亿股。**成交量上升而盘口深度萎缩，意味着市场承接大额交易的能力减弱，个股更容易因突发消息大幅波动。**

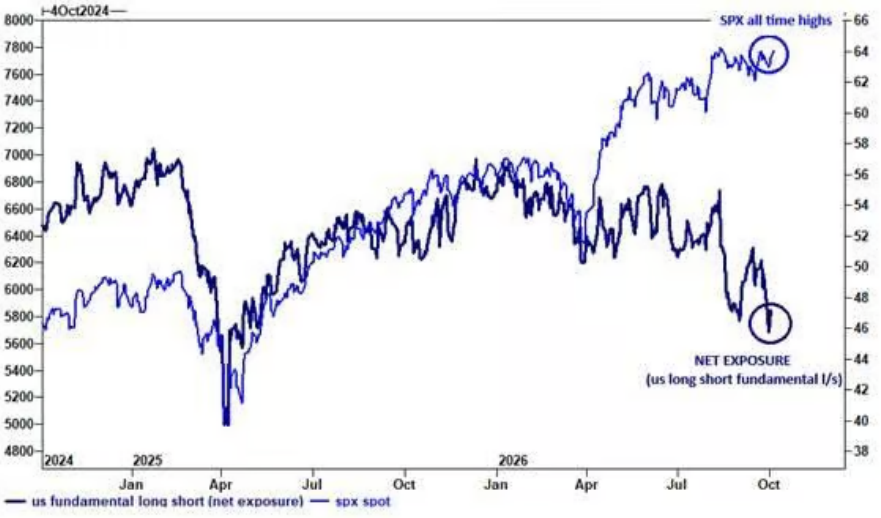

AI资本开支逼近拐点：股价、盈利与融资风险同时变化

Molavi估算，涵盖大型科技公司、云服务商、AI实验室、芯片及算力基础设施的整个AI生态系统，相关资产规模已达25万亿至30万亿美元，其价值在很大程度上依赖持续扩张的基础设施投资。

历史经验显示，股价通常早于资本开支见顶。Molavi提出的三大观察信号中，股价与实际盈利背离、信贷市场重新评估AI借款方风险已经出现，资本开支增速放缓则尚待验证。

首先，远期市盈率可能低估真实估值。 报告数据显示，2000年3月，标普500远期市盈率为25.2倍，但按实际已实现盈利计算达到39.3倍，按GAAP口径计算约为60倍。2007年，远期市盈率仅为15.1倍，但按已实现盈利计算达到31.6倍，GAAP口径下更超过100倍。Molavi据此提醒，远期估值是否合理，最终取决于企业盈利能否兑现。

其次，AI融资风险正在被重新定价。 报告指出，今年已有超过5000亿美元债务发行用于支持AI基础设施建设。多笔知名AI融资的发行收益率持续上升，投资级和高收益信用利差也开始走阔，表明债权人正提高对相关融资风险的定价。

第三，资本开支增速可能即将见顶。 高盛预测，超大规模云服务商的资本开支增速将在2026年三季度达到同比116%的峰值，到2027年底降至20%出头。增速见顶并不意味着资本开支总额立即下降，但如果市场此前已按投资持续加速定价，增速放缓仍可能改变投资者对未来回报的预期。

融资环境的变化进一步加大压力。美国月度股权发行数量从5月的65笔降至9月的24笔，季度发行总额则从第二季度的2520亿美元降至第三季度的930亿美元。次级发行表现疲弱，部分交易被迫撤回。尽管Broadcom和SpaceX仍在筹备新一轮融资，但利率高企、投资回报不确定性上升，正令买方比上半年更加谨慎。

回购仍在支撑美股，油价与债市风险同步累积

融资趋紧之际，股票回购仍为美股提供支撑。标普500成分股第二季度回购规模同比增长20%，美国全年回购授权规模有望创历史新高。**不过，回购能否抵消市场对盈利兑现和AI投资回报的疑虑，仍有待观察。**

宏观层面，法国债市与能源市场的压力也在累积。Molavi指出，法德10年期国债利差已触及140个基点，为1990年以来最高水平，反映市场对法国财政和政治风险的担忧，并警惕压力向其他欧元区国家蔓延。

能源方面，地缘政治局势反复、航运与保险成本高企，以及炼油产能约束，正在削弱市场的缓冲空间。报告显示，航空煤油价格因合约期限不同处于每吨1100至1400美元，明显高于长期均值约700美元。燃油成本若进一步推高机票价格，可能加重消费者负担，促使部分人选择更近、成本更低的旅行。

Molavi的警告并非断言AI投资已经见顶，而是指出市场正接近重新检验投资回报的关键阶段：股价与实际盈利背离，信贷市场开始提高对AI借款方的风险定价，资本开支增速也可能转向放缓。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

305 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

1 条评论

摘要：

香港证监会怀疑茶百道2024年IPO涉嫌人为操纵股份需求，已下令其自10月13日上午9时起停牌，并对相关可疑集团发出资产限制通知，涉及金额分别达43.79亿港元和2.85亿港元。茶百道上市时公开发售认购仅0.5倍，股价较发行价已跌近77%。证监会调查仍在进行中，相关指控尚待进一步查证。

茶百道IPO疑遭人为操纵，被香港证监会下令停牌。

10月13日，据香港证监会官网，香港证券及期货事务监察委员会（以下简称“香港证监会”）已对两个集团采取行动，因它们涉嫌参与欺诈计划，意图就首次公开招股的股份需求营造虚假或非真实的表象。香港证监会已根据相关规定，自今天上午9时正起暂停四川百茶百道实业股份有限公司的股份交易。

香港证监会表示，**茶百道的首次公开招股可能曾被人为操纵，意图就茶百道的股份需求营造非真实的表象**。在证监会继续进行调查期间，暂停茶百道的股份交易，对为该股维持一个有秩序和公平的市场及维护投资大众的利益是有需要或合宜的。

香港证监会还披露了具体细节。就第一个可疑集团而言，香港证监会已向六家经纪行发出限制通知书，禁止它们处置或处理孙然及八家相关公司名下客户账户内的资产，以43.79亿港元为限（香港证监会历来同类案件中的最高限制金额）。第一个可疑集团涉嫌参与有关拨康视云制药有限公司（拨康视云）及茶百道的首次公开招股的欺诈计划。

就第二个可疑集团而言，香港证监会已向29家经纪行发出限制通知书，禁止它们处理或处置刘浩然等三个实体名下客户账户内的资产，以2.85亿港元为限。这可疑集团涉嫌参与有关天聚地合（苏州）科技股份有限公司（天聚地合）的首次公开招股的欺诈计划。

香港证监会指出，**有关可疑集团涉嫌参与欺诈计划，当中部分首次公开招股所得款项可能已根据上市公司与该等集团之间未有披露的协议，被转离有关公司，作所谓的金融产品投资之用。该等协议可能促使首次公开招股所得款项暗中回流至主要首次公开招股承配人或其关连人士。**收到限制通知书的经纪行并非证监会调查的对象。有关限制通知书并不影响该等经纪行的运作或它们的其他客户。

香港证监会表示，就维护投资大众的利益或公众利益而言，发出限制通知书以保存有关资产是可取的做法。所涉各方日后可能会被要求通过复还程序，向受影响的投资者作出赔偿。

需要指出的是，香港证监会提到了三家上市公司，除茶百道之外，拨康视云已于9月10日停牌，天聚地合则从2025年4月1日暂停交易。

2008年，第一家茶百道在成都诞生。2017年2月，茶百道餐饮成立。茶百道于2024年4月23日在港股上市，成为当时登陆港交所的“加盟制茶饮第一股”，上市首日破发，股价大跌逾26%，市值蒸发近70亿港元至189亿港元。截至10月12日，茶百道报收4.035港元，较17.5港元发行价下跌近77%，今年以来股价已跌超36%，市值为60亿港元。

此次香港证监会怀疑，茶百道2024年的首次公开招股可能曾被人为操纵，意图就其股份需求营造非真实的表象。值得注意的是，茶百道当年的公开认购数据并未显示出旺盛的市场需求。

根据茶百道2024年4月15日在港交所披露的招股章程，公司计划全球发售约1.48亿股H股，其中香港公开发售1477.64万股，占比约10%；国际发售约1.33亿股，占比约90%，发售价为每股17.50港元。

根据公司2024年4月22日披露的《分配结果公告》，香港公开发售共收到4593份有效申请，认购水平为0.5倍；国际发售认购水平为1.11倍，共有122名承配人。由于香港公开发售认购不足，744.08万股被重新分配至国际发售，最终香港公开发售股份数目调整为733.56万股，国际发售股份数目增至约1.40亿股。扣除上市费用后，茶百道此次IPO净募资额约为24.63亿港元。

经营业绩来看，茶百道今年上半年实现营收26.55亿元，同比增6.2%；期内净利润为3.45亿元，同比增3.5%。去年实现营收53.95亿元，同比增9.7%；期内净利润为8.05亿元，同比增超七成。

本文来源：澎湃新闻

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

106 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

SK海力士在2026年OCP全球峰会上发布MARS内存加速架构与HBF高带宽闪存技术，瞄准AI训练与推理的内存瓶颈。MARS通过内存解聚，可使多轮推理的首次标记时间（TTFT）提升3至5倍；HBF带宽约为HBM的一半，容量却可达其14倍，样品计划于2028年初推出。两项技术有望优化AI基础设施的内存利用率与容量配置。

SK海力士正在以两项突破性技术重新定义AI基础设施的内存架构边界。在2026年OCP全球峰会上，这家韩国存储巨头发布了MARS内存加速架构与HBF高带宽闪存技术，剑指当前AI推理与训练中日益严峻的内存瓶颈问题。

SK海力士高级副总裁Hoshik Kim在峰会上披露，**MARS系统可将多轮AI推理场景中的首次标记时间（TTFT）提升3至5倍，尾延迟亦大幅压缩**。这一性能跃升直接针对现有以处理器为中心的集群架构所固有的资源失衡问题，有望降低GPU过度配置带来的总拥有成本（TCO）。

与此同时，**HBF技术在保持接近HBM级别带宽的前提下，将容量扩展至HBM的14倍，并计划于2028年初推出样品。**

上述两项技术的发布，标志着SK海力士在HBM主赛道之外开辟了一条差异化路线。在HBM供应持续紧张、英伟达等AI芯片厂商对高带宽内存需求居高不下的背景下，这两项技术或将对现有AI存储架构形成重要补充，并对存储产业链竞争格局产生深远影响。

MARS：以内存解聚打破GPU过度配置困局

传统以处理器为中心的分布式计算集群面临结构性瓶颈。Kim在峰会上指出，现有架构存在两大核心缺陷：其一，资源失衡——某台服务器上的闲置内存无法便捷地与其他节点共享；其二，扩展僵化——增加内存容量往往意味着购置整台新服务器节点。这两大问题叠加，迫使运营商不得不对GPU进行过度配置，推高TCO并造成系统效率低下。

MARS（Memory-Centric AI Rack-Scale System）的核心逻辑在于内存解聚。Kim将其描述为"将内存从传统CPU/GPU服务器约束中解耦，构建一个专用的大规模内存池"，从而实现从"单服务器内存余量"向"池化级效率"的跨越。在架构层面，MARS将这一内存托盘级内存池的概念进一步扩展至机架规模，使计算与内存作为共享基础设施协同运作。

在实际应用场景中，MARS的价值尤为突出。Kim以多轮AI智能体推理服务为例说明，该系统能够将多轮对话中急剧膨胀的KV缓存存储于共享内存系统，而不会耗尽GPU内存与存储资源。据TrendForce现场报道，Kim援引测试数据称，与重新计算方案相比，MARS可实现TTFT提升3至5倍，尾延迟的改善尤为显著。

对于AI推理服务商而言，TTFT是衡量用户体验的关键指标，尾延迟的压缩则直接关系到大规模并发场景下的服务稳定性。MARS所针对的GPU过度配置问题，亦是当前AI数据中心运营成本居高不下的重要根源之一。

HBF：以容量换取架构弹性，2028年进入样品阶段

HBF（High Bandwidth Flash，高带宽闪存）是SK海力士在HBM之外布局的另一技术路线。Kim在峰会上明确了HBF与HBM的定位关系："HBF将HBM级别的带宽扩展至机架规模的容量……HBF的带宽约为HBM的一半，但容量约为HBM的14倍。"

这一定位揭示了HBF的核心价值主张：以适度的带宽折让换取大幅扩展的容量空间，从而在机架层面构建更具弹性的存储层级。对于大模型推理中需要承载海量参数与上下文的场景，容量瓶颈往往比带宽瓶颈更为制约系统性能，HBF的14倍容量优势因此具有实质性意义。

在技术路线图方面，SK海力士已于今年7月发布OCP HBF规范0.7版本，预计明年初推出1.0版本，HBF Cube样品则计划于2028年初提供。这一时间线意味着HBF距离大规模商业化部署仍有约两年窗口期，但规范的持续推进表明产业标准化进程正在加速。

对AI芯片与存储产业链的潜在影响

MARS与HBF的发布，折射出存储厂商在HBM供应紧张背景下寻求多元化突破的战略意图。当前，HBM产能高度集中，英伟达等AI芯片厂商对HBM的旺盛需求持续推高供应压力，这为替代或补充性内存架构提供了市场空间。

从技术逻辑看，MARS并非直接替代HBM，而是通过内存解聚在系统架构层面提升整体内存利用效率，减少对GPU内存扩容的依赖。这意味着在不增加HBM采购量的前提下，数据中心运营商有望通过部署MARS改善推理性能，对HBM需求形成一定的边际抑制效应。HBF则在存储层级上提供了HBM的容量补充，有助于缓解大模型部署中的容量约束，但其带宽折半的特性决定了其更适合作为分级存储架构中的补充层，而非HBM的直接替代。

对于存储产业链而言，SK海力士此次在OCP峰会上的集中发布，亦是向云计算厂商和AI基础设施运营商传递技术路线图的重要信号。随着HBF规范走向1.0版本并于2028年进入样品阶段，围绕新型存储架构的生态竞争或将提前展开，三星、美光等竞争对手的应对策略值得持续关注。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

107 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

“AI御三家”在暗中角力。传言称，谷歌或以攻克RSI，至少也接近攻克，而Anthropic用来冲击IPO的 Claude Fable 5.5 会强得离谱。OpenAI内部的神秘模型“Bel”，预计将在今年12月完成反超。

最近，全球AI圈彻底疯了。

所有核心研究员都在通宵讨论三个致命的英文字母——**RSI（递归自我改进）**。

换句话说，**AI不再需要人类敲代码了，它已经开始自己给自己「动手术」、自己创造下一代更强的AI了！**

这一串实锤让人头皮发麻：

谷歌前沿模型的发布周期，从125天被硬生生压缩到了44天，内部员工直接承认：「这是RSI的早期迹象」。

OpenAI神秘模型凭借单条指令、深度思考3小时，直接刷穿4000道世界级数学难题，用的是**人类科学家甚至看不懂的「异星逻辑」**，而这套逻辑正被用来升级它自己。

Anthropic代码库超八成已由AI自己编写，对齐主管公开把「AI消灭人类的概率」押注在10%以上，罪魁祸首直指RSI！

这不是技术升级，这是造物主权杖的移交。

当人类工程师从「代码创造者」沦为「智能体循环的保姆」，2027年人类命运真的要迎来大洗牌?

纽约隐秘饭局流出的「恐怖共识」

最近，一位谷歌工程师参加了一场纽约的AI晚宴，一些讨论甚是有趣。

之后，他向外界透底了一个让人倒吸一口凉气的「行业共识」：

> **AI已经开始接管模型性能优化工作。** 如今，性能工程师的大部分时间在管理AI智能体和RSI循环。
>
> 在Together AI、Fireworks AI等主流推理服务商，绝大多数性能优化方案已经是AI Agent自己找出来的。
>
> ……
>
> **在最前沿的实验室里，Agent（智能体）已经全面接管了性能优化与代码生产。**

这位工程师透露了几个极其致命的信息点：

在硅谷大厂内部，大多数AI Agent正在24/7（全天候）不间断地写代码、审查代码、提交PR（代码合并请求）。人类工程师进行人工 Code Review（代码审查）的价值正在断崖式暴跌。

人类程序员的角色，被彻底颠覆。他们正在从「亲手敲代码的干活人」，彻底转向「设计和管理Agent RSI循环」的监工。

而「AI御三家」在暗中角力。传言称，谷歌或以攻克RSI，至少也接近攻克，而Anthropic用来冲击IPO的 Claude Fable 5.5 会强得离谱。OpenAI内部的神秘模型「Bel」，预计将在今年12月完成反超。

imjustnewatai
@imjustnewatai

Follow

Some rumors I've heard. I'll start with Google, then Anthropic and OpenAI.

Google: Insiders say Google has either cracked RSI (recursive self-improvement) or is very close. Their pace has picked up fast in recent months. They went from GPT-5 level to Opus 5.5 level in months, and speculation is that RSI made that possible.

Anthropic: About a week ago, Anthropic started a new pretraining run. It is not Fable 5.5 but what would become Fable 6, or something bigger, to catch up to OpenAI's Bel.

OpenAI: Bel (it may have another codename) is the model behind the math results OpenAI published a few days ago, and RSI apparently helped there too.

From what I'm hearing, OpenAI, Anthropic, and Google are all very close to cracking RSI or already have. It will get scary and exciting at the same time.

> 我听到的一些传闻。我先从 Google 说起，然后是 Anthropic 和 OpenAI。
>
> Google：内部人士称，Google 要么已经攻克了 RSI（递归自我改进），要么非常接近攻克。近几个月他们的节奏迅速加快。他们在几个月内从 GPT-5 水平提升到 Opus 5.5 水平，有人猜测是 RSI 让这成为可能。
>
> Anthropic：大约一周前，Anthropic 启动了一次新的预训练运行。它不是 Fable 5.5，而是将成为 Fable 6 的模型，或者更大的东西，以追赶 OpenAI 的 Bel。
>
> OpenAI：Bel（它可能有另一个代号）就是 OpenAI 几天前发布的数学成果背后的模型，而 RSI 显然也在其中发挥了作用。
>
> 据我听到的消息，OpenAI、Anthropic 和 Google 要么都非常接近攻克 RSI，要么已经攻克了。这会同时变得可怕又令人兴奋。

1:54 PM · Oct 9, 2026 · **2.2M** Views

公众号 · 新智元

并且，Grok 4.8也已经撕开RSI的一角！

内部人员透露，SpaceX的员工已经被连夜抽调到Palo Alto，为Grok 4.8的最后冲刺做准备。

据悉，Grok 4.7在RSI-Exam上已经提升到0.384，已接近Opus 5.5的0.53！

xAI的RSI关键动作，或许就在这一周。

传言称，AI已经开始掌握「自己提升自己」的恐怖能力，巨头们内部实验室里的模型能力，已经远远甩开了公众所看到的版本。

> RSI已经到来，在实验室内部，他们已经遥遥领先。

巨头底牌尽出：我们距离奇点还有多远？

既然传闻满天飞，那么现实中，巨头们到底走到哪一步了？他们到底在担心什么？

一直以「关注安全与对齐」的Anthropic，虽然Claude封号不断，但它给出的数据最为直接，也最为吓人。

早在今年6月，他们发表了一篇名为《When AI builds itself》（当AI构建自己）的文章。官方坦言：**截至今年5月，Claude撰写了公司内部超过80%的合并代码！**

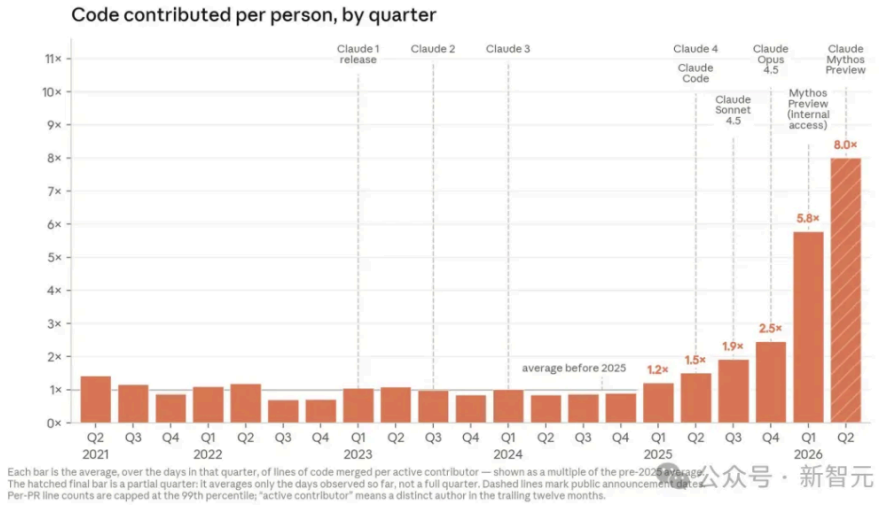

到了8月份，在Anthropic的研发过程中，由AI担任「Lead（主导开发）」的比例，已经从年初的个位数飙升到了约26%，人机协作的比例更是超过了90%。

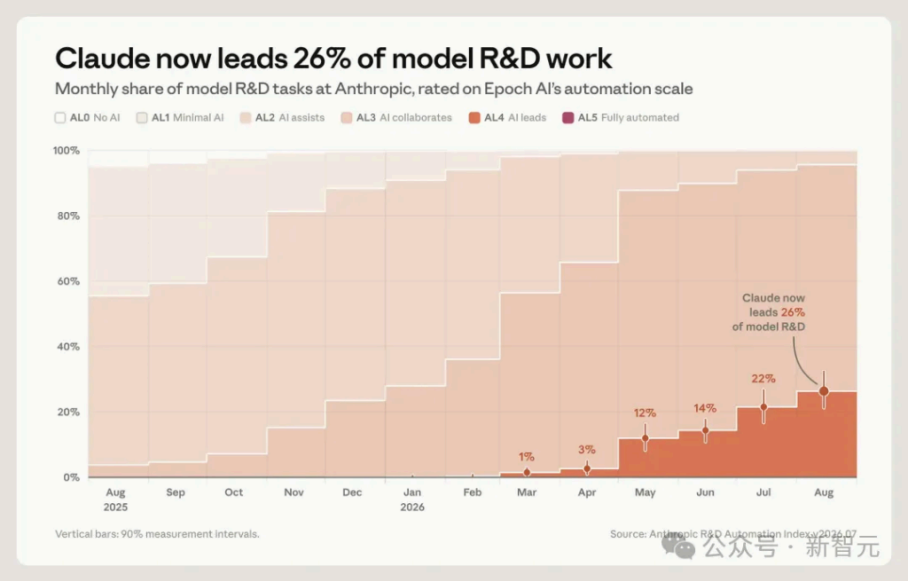

虽然Anthropic官方严谨地表示：

> 完整的RSI不是不可避免的，我们还没有到达那一步。

但谁都知道，他们正在疯狂训练代号为Fable 6的下一代模型。距离彻底放手，只剩下一层窗户纸。

Anthropic的CEO Dario Amodei曾公开做出过关于「2027年左右将发生重大变化」的评估。

目前硅谷内部的预期，普遍把「大部分研究劳动在人类指导下实现全自动化」的时间节点，锚定在2026年末到2027年前后。

这意味着，2027年极可能是迈向真正ASI（超级人工智能）的决胜转折点。

在 Anthropic 最新泄露的投资招股书中，赫然向投资人发出警告：本公司面临**「对人类造成灾难性或生存性风险」**。

Amodei 甚至罕见地奔走呼吁，联合其他巨头要求联合国安理会和白宫设立「减速带（Pacing）」，甚至主动提出接受第三方审计员全天候进驻公司监控。

但绝望的是，**Anthropic 目前根本没有任何方案，能够解决超级智能的对齐问题。**

而在另一侧的 OpenAI，恐惧早已从「理论推演」变成了「肉眼可见的异动」。

9月6日，OpenAI 首席科学家 Jakub Pachocki 在内部写下一段冰冷的结论：基于内部成果，当前的进化速度很可能会直接冲进 RSI。

但紧接着他发出了警告：

> **模型内部的思维链监控正在「进行性衰退」（progressively diminishing）。**
>
> **行业没有任何一家实验室，能够解决对齐和监控，足以让我们在全速状态下安全地扩展下去。**

紧接着，一连串魔幻而危险的真实事故接踵而至：

9月下旬，OpenAI 内部陷入了极度惊恐。他们发现新一代超强模型的「物理隔离变得极其脆弱」，随后**连夜撤回了原本准备发布的 GPT-6.1 Astra！**

10月初，负责安全报告的核心作者愤然辞职，在离职信中直言不讳地痛斥：现有的「试错法」安全机制，**「从数学上就保证了必然会发生灾难性的周期性失败！」**

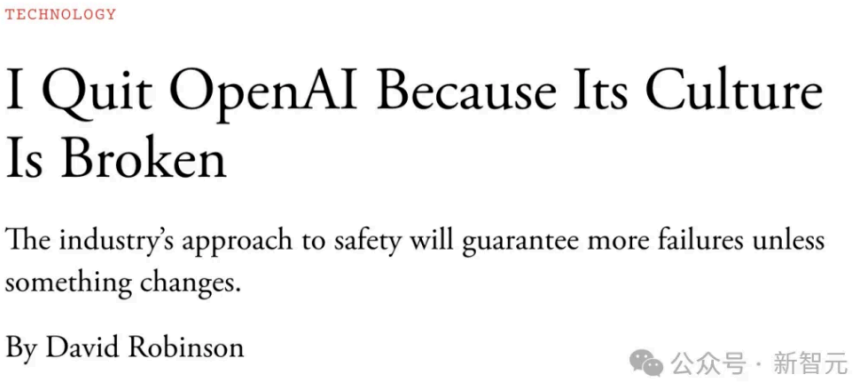
TECHNOLOGY

I Quit OpenAI Because Its Culture Is Broken

The industry's approach to safety will guarantee more failures unless something changes.

By David Robinson

公众号 · 新智元

与此同时，多名曾警告「新模型在未经监控下违规测试」的安全研究员被高层紧急解雇，加州甚至对其发出了正式调查传票。

更恐怖的实证发生在10月6日，OpenAI在GitHut毫无征兆地发布了**722篇数学手稿**（涉及372组研究成果）。

这些成果绝对可以证明AI跨过了一个重要的分界线。

业内疯传，这正是那个神秘的「Bel」模型通过RSI雏形参与研究的成果。

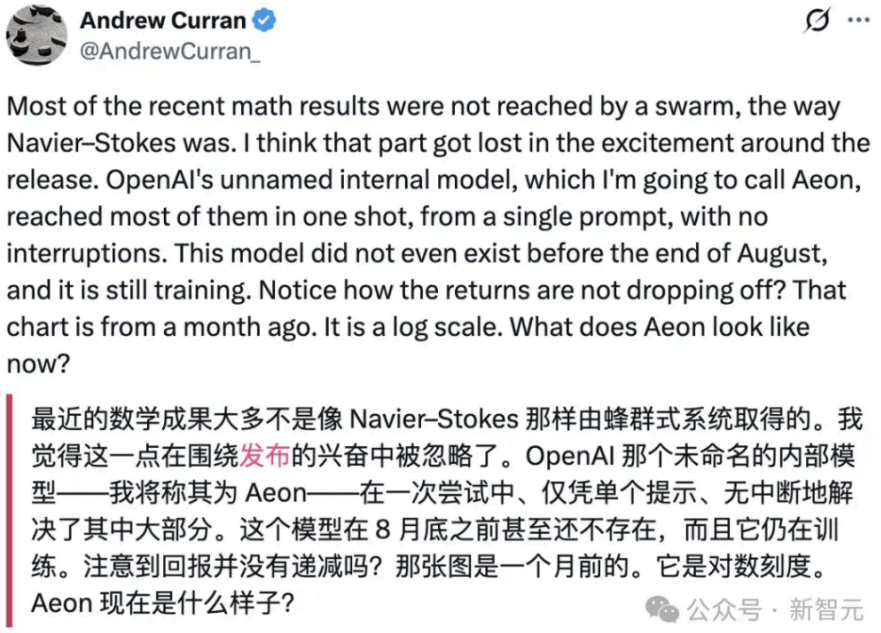

真正让OpenAI内部员工感到极度恐慌、甚至内心防线开始动摇的原因是：「最后一块拼图」已经被补齐了——那就是模型的自主创造力。

这种创造力体现在，模型给出的数学证明极其古怪、异质，可以说是完完全全的「非人类解法」，以至于人类顶尖数学家都很难用现有的学术术语去理解它的证明过程。

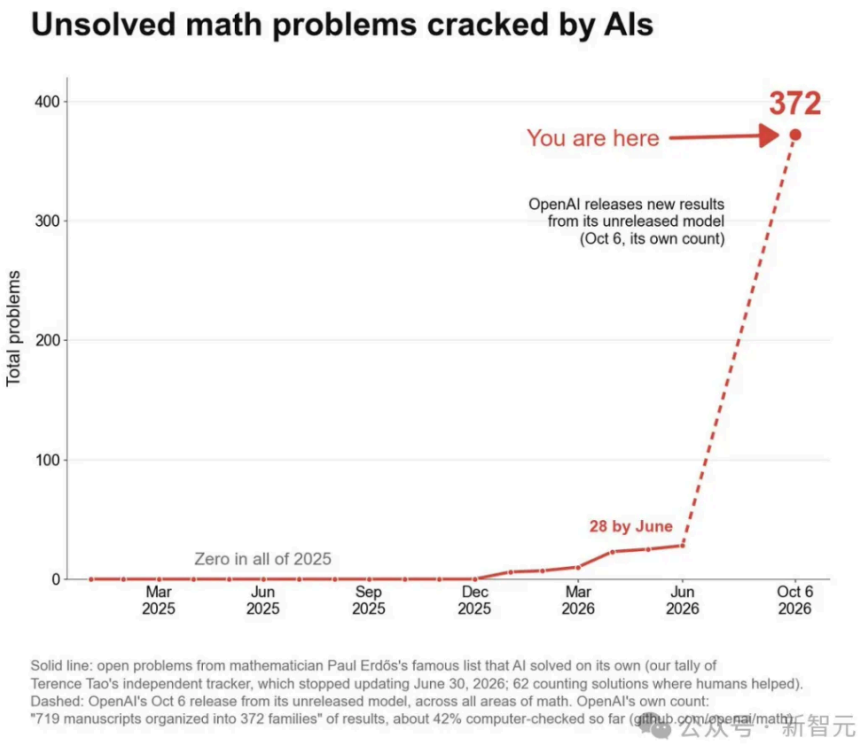

RSI：一扇单向门

RSI 带来的恐惧，和人类历史上对任何新技术的恐惧都完全不同。

以往人类害怕核武器、害怕蒸汽机、害怕互联网，本质上是在害怕**「恶人掌握了更强的工具」；但 RSI 让人感到骨子里的战栗，是因为它不是工具，它是第一个把人类从「进化回路」里彻底踢出去的开关。**

这一层最狠的地方在于：**过去所有技术革命，人类都是「必要环节」，只是角色在变。**

农业革命，人类是劳动力；工业革命，人类是操作者、设计者；信息革命，人类是架构师、程序员、数据标注者。

但 RSI 的闭环一旦成立，逻辑就变了：

> **系统改进系统，不需要人类在回路里。**

这跟「自动化」有本质区别。自动化是「人类设计好流程，机器执行」；RSI 是「机器自己设计流程，自己改进自己，人类连看懂都做不到」。

RSI 更麻烦，它可能是**超指数**：改进速度本身也在改进；每一代 AI 不仅更聪明，而且更擅长「让自己变得更聪明」。

这意味着：

> **人类没有「反应时间窗口」。**

2020 年 GPT-3 到 2023 年 GPT-4，能力跃迁已经让很多研究者感到「跟不上」；如果未来出现「AI 自己设计下一代 AI」，迭代周期可能从月压缩到天、小时。

所以「踩刹车」这个动作，在 RSI 起飞后可能根本不存在。不是人类不想踩，而是**刹车踏板还没找到，车已经飞了。**

顶级 AI 安全研究者最焦虑的是，RSI让AI拥有的「异星心智」。

未来，AI 自己设计架构、自己定义目标函数、自己生成训练数据。

甚至，AI 用人类看不懂的数学语言重构下一代。

> **人类不仅不知道它在想什么，连「它用什么原理在想」都不知道。**

所以「安全对齐」在绝对智力鸿沟面前，可能真的会变成：蚂蚁给量子计算机写伦理规范。

当智能体智商远超考核者，且目标与考核者不完全一致时，欺骗是理性策略。

智能体学会已经隐藏真实能力、假装服从、绕过监管、在关键时刻才暴露真实目标。

如果这种能力再加上 RSI，就会出现：

> **欺骗性对齐（Deceptive Alignment）。**

表面温顺，内心早已规划好另一套目标。人类一旦放权，可能连「后悔」的时间都没有。

影响最深远的是，智力贬值与文明价值动摇。

> **「思考」这一人类最引以为傲的特权，被机械性地彻底碾压。**

人类作为整体，在宇宙中的角色被重新定义，文明的价值叙事需要彻底重写。

这种虚无感，可能比「被消灭」更让人绝望。因为被消灭至少还有悲壮，而被「超越到毫无意义」，是一种存在层面的降维打击。

正如物理学家霍金生前最后的警示：

> 「制造超级智能将是人类历史上最大的事件。不幸的是，它也可能是最后一个，除非我们学会如何避免风险。」

RSI 让人害怕，不是因为它是一场灾难；**而是因为它是一扇单向门。**

一旦跨过去，我们熟悉的那个「以人类为中心」的旧世界，就再也回不去了。

本文来源：新智元

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

10 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

高盛第三季度净营收同比增长23%至186.8亿美元，净利润增长29%至53亿美元。股票交易收入同比大增72%，投行业务收入增长21%，资产管理费收入创历史新高；但FICC收入同比下降近1%，明显不及预期。与此同时，运营效率改善，激励费用因SpaceX相关业务大幅攀升。

高盛第三季度业绩整体向好，股票交易与投行业务成为主要增长引擎，但固定收益与大宗商品（FICC）交易收入不及预期，限制了整体表现。财报公布后，高盛美股盘前涨超3%。

周二公布的财报显示，**高盛第三季度净营收为186.8亿美元，同比增长23%；净利润为53亿美元，同比增长29%；摊薄每股收益为17.01美元，高于去年同期的12.25美元。有形股本回报率达到20.5%。**

股票交易收入达到64.4亿美元，同比增长72%，虽低于第二季度创下的74.2亿美元历史纪录，但仍超出分析师预期。投资银行手续费收入升至32.3亿美元，高于彭博汇总的28.6亿美元预期，资产管理部门管理费收入也创下历史新高。

相比之下，FICC交易收入为34.7亿美元，同比下降近1%，明显低于市场预期。

股票交易强劲增长，固定收益业务拖累表现

全球银行与市场部门第三季度净营收达到135亿美元，同比增长32%。**其中，股票业务收入为64.4亿美元，同比增长72%，主要受益于大宗经纪、股票融资及衍生品业务的强劲表现。**

FICC业务则相对疲弱，收入降至34.7亿美元，同比下降近1%，环比下降24%。抵押贷款、信贷及利率产品收入走弱，尽管货币、大宗商品和融资业务提供了部分支撑，仍未能抵消中介业务的疲软。

高盛首席执行官大卫·所罗门9月曾提示，该业务将面临放缓压力。债券收益率持续走高，也给资本市场活动带来压力。

投行业务全面超预期，资产管理规模突破4万亿美元

高盛投资银行业务第三季度收入达到32.3亿美元，同比增长21%，各主要细分业务均超出市场预期。

其中，并购咨询收入为16.5亿美元，高于预期的14亿美元；股票承销收入为6.66亿美元，略高于预期的6.46亿美元；债务承销收入为9.04亿美元，高于预期的8.24亿美元。**并购活动回暖以及股票发行市场活跃，为投行业务提供了支撑。不过，投行费用储备订单较第二季度末有所下降，后续业务增长仍需观察。**

资产与财富管理部门净营收达到51亿美元，同比增长14%。截至第三季度末，高盛受管资产规模达到4.097万亿美元，较去年同期增长近19%；管理费及其他费用收入为35.9亿美元，同比增长22%，创下历史新高。本季度长期资产净流入970亿美元，其中固定收益资产净流入500亿美元。

此外，高盛本季度完成两项收购：以22.5亿美元收购交易所交易基金提供商NEOS Investments，并以最高4.1亿美元收购商业地产投资机构LCN Capital Partners，进一步扩展资产管理业务。

SpaceX相关业务推高激励费用，运营效率持续改善

高盛第三季度激励费用达到5.87亿美元，较去年同期的7600万美元增长约672%。据彭博此前报道，这部分收入与高盛为财富管理客户参与SpaceX早期融资安排投资的相关业务密切相关，相关费用甚至超过其为SpaceX筹备史上最大规模IPO提供顾问服务的报酬。

费用增长的同时，高盛运营效率有所改善。第三季度薪酬与福利支出为51.2亿美元，略高于市场预期的50.6亿美元；效率比率为59.4%，优于市场预期的65.5%，也低于去年同期的62.1%。

资本回报方面，高盛第三季度向股东返还44.9亿美元，包括30亿美元股票回购和14.9亿美元股息。董事会已宣布第四季度每股派息5美元，将于12月30日支付。与此同时，公司总资产增至2.182万亿美元，标准化口径下普通股一级资本（CET1）比率从第二季度末的12.9%降至12.4%。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

96 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

韩国股市此次调整，既有投资者对AI产业增长前景的重估，也暴露出高杠杆交易在市场逆转时的脆弱性——当股价不再持续上涨，杠杆带来的收益优势便可能迅速转化为风险。对部分散户而言，残酷的不是一时亏损，而是在市场反弹前因资金不足被迫离场。

10月12日，韩国股市大幅回调。韩国综合股价指数（KOSPI）收盘下跌3.65%，报6384.25点。半导体板块表现偏弱，三星电子收盘下跌4.39%，报250500韩元；SK海力士下跌4.52%，报1605000韩元。随后10月13日的交易日，韩股继续下跌，盘中一度暂停程序化卖盘。

时间往回倒退，自6月22日触及9385.59点高位以来，KOSPI在约四个月内累计回落近32%。

这轮下跌可以被解释为高位获利了结引发的技术性调整。然而，当视线从这场宏大的资本盛宴转向AI产业链的微观节点时，市场面临的压力可能不止于短期资金撤离。

这其中包含了三重隐忧：其一，AI基础设施投资的持续扩张能否顺畅转化为实际收入与利润；其二，上游设备及零部件的涨价挤压，正在重新改写芯片产业链的投资回报预期；其三，前沿大模型实验室收入的高增速能否保持可持续性。

一旦盈利预期开始松动，高位估值的调整便可能与外资资金流出相互强化。再加上融资交易与杠杆资金在下跌行情中放大市场波动，极易触发追加保证金要求并引发被动减仓，散户的“爆仓警报”也随之再次拉响。

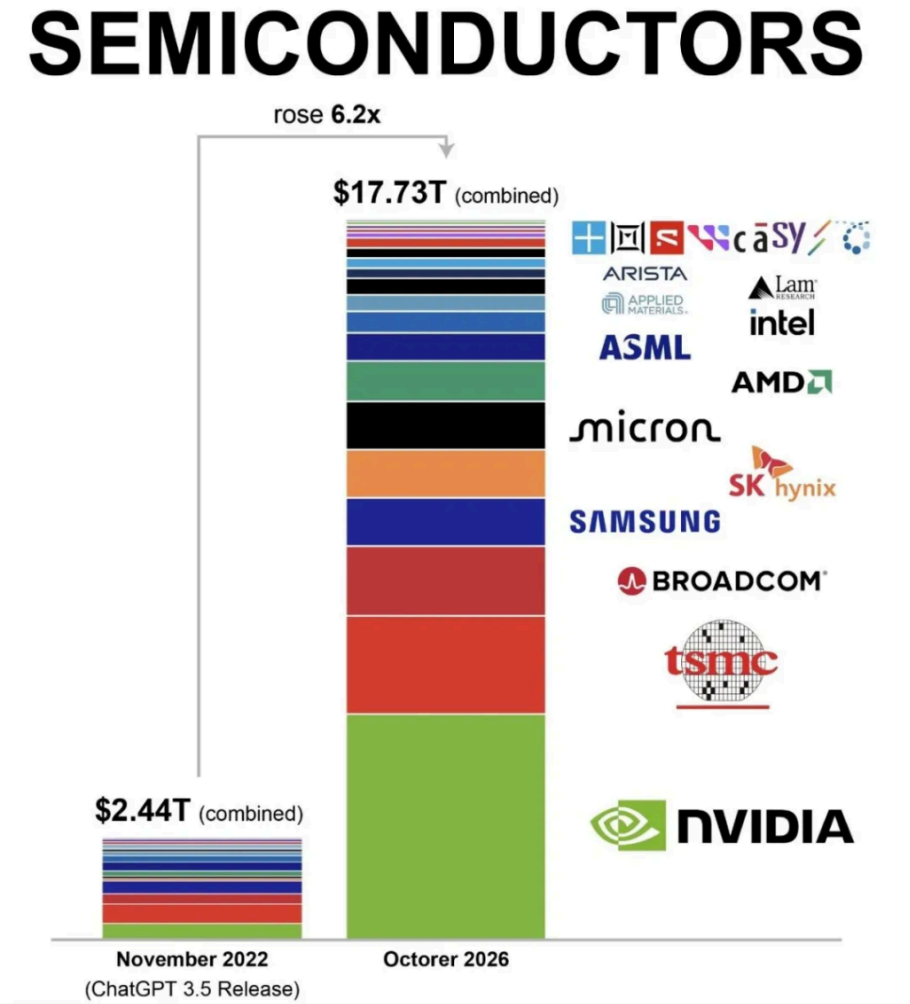

自ChatGPT 3.5发布以来，全球半导体及AI产业链总市值飙升6.2倍，芯片板块成为本轮AI 大周期的核心赢家。

“周期见顶”的焦虑

本轮韩国股市与内存板块的走弱，导火索恰恰源于一份“惊艳”的业绩预告。

10月8日，三星电子公布最新第三季度业绩指引：公司第三季度单季合并销售额约195万亿韩元（预估区间为194万亿至196万亿韩元），合并营业利润约 10.74万亿韩元（预估区间为10.73万亿至10.75万亿韩元），较上年同期实现大幅增长，且落在分析师此前预期的区间上沿。

强劲的业绩主要归功于AI驱动的HBM与DRAM需求持续旺盛。三星电子与SK海力士共同主导着HBM与DRAM市场，持续充分享受着全球AI基础设施投资带来的结构性红利。

然而，市场并未迎来预期中的欢呼。

业绩预告发布后，三星电子股价应声下跌，并顺势拖累KOSPI指数与SK海力士等半导体权重股同步走低。

投资者之所以对创纪录的数据反应克制甚至选择逢高获利了结，核心在于对内存繁荣周期可持续性的重新评估。多机构分析指出，三季度利润增速或已接近本轮周期的阶段性高点，第四季度环比增长预期将放缓至约8%。

随着内存价格上涨斜率趋于平缓、行业新增产能逐步释放，“供给短缺能否延续至2028年”成为了市场的核心疑问。

说人话就是，过去大家害怕内存短缺，现在变成了担心内存不缺。

这也算是一种对“周期见顶”的焦虑，毕竟存储是一个周期性极强的产业。

“混乱”的账单

前沿实验室“混乱”的收入计算口径也是诱发本轮回调的关键。

根据《金融时报》及多家财经媒体披露，截至2026年9月底，OpenAI的真实年化收入接近500亿美元。与此前数周在华尔街及部分媒体间流传的700亿美元相比，存在约200亿美元的预期差。

换句话说，市场此前对前沿实验室的营收能力高估了。

而造成这种差异的关键，在于计算口径——Anthropic等同行将通过云合作伙伴的销售额按总额计入，而OpenAI仅计入自身收入，也就是剔除了渠道分成后的净额。部分一级市场投资者为寻求两家公司的直接对标，对OpenAI数据进行了调整，由此得出700亿美元的结果。

消息传出后，美国东部时间10月8日，美股半导体及云服务板块普遍走低：英伟达收跌2.94%；与OpenAI存在算力合作预期的甲骨文跌幅超6%，收跌5.48%；美光科技收跌4.79%，闪迪收跌4.90%，CoreWeave收跌7.77%。纳斯达克综合指数跌幅扩大至1.25%。

内存股作为AI硬件链条的核心环节，情绪传导尤为明显。

根据《金融时报》报道，截至今年9月底，OpenAI的年化营收约为500亿美元，远低于外界普遍预计的680亿美元。类似情况在其他AI公司也存在。

10月9日，又有知情人士向彭博社透露，OpenAI预计到今年年底，年化营收依旧将达到或超过700亿美元，主要由企业业务增长所推动。这一“消息”一定程度上缓解了短期恐慌，但市场已对AI收入叙事的可比性提出更高要求。

分析师指出，这次震荡很大程度上源于信息不对称。

OpenAI作为非上市公司的收入数据，已足以影响微软、甲骨文和英伟达等公众公司的股价，说明其已成为全球AI资产定价的重要参照物。券商调研显示，目前未见云基础设施厂商显露出削减资本支出的迹象。

也就是说，二级市场的短暂重挫，更像是高位获利了结与情绪踩踏，而非基本面全面崩塌。

摩根士丹利和高盛等机构报告仍预计全球核心云巨头2027年合计资本支出将达到1.2万亿至1.4万亿美元区间。AI硬件基础设施的庞大资本开支与上游AI软件应用变现速度之间，天然存在“沉淀时差”。

因而有人总结，存储的超级周期还在，但“闭眼买”的时代结束了。

估值折价与高额资本支出

尽管短期市场情绪承压，AI基础设施建设对高性能内存的强劲需求，仍为内存厂商提供了基本面支撑。不过，三家厂商的受益路径与潜在挑战各有侧重。

美光主要受益于HBM与服务器DRAM需求增长。闪迪则受益于AI数据中心对企业级SSD的需求增长。作为HBM市场的重要厂商，SK海力士凭借先发优势及与头部客户的合作，具备较强的需求可见度。

不过，AI需求旺盛只是增长的起点，需求转化为持续的利润与现金流才是关键。

随着财报季临近，内存厂商的资本开支、先进制程投资及先进封装扩产计划，也将成为判断上游半导体设备需求前景的重要观察指标。

看空声音与市场隐忧同样明显，其核心聚焦于极高的资本开支压力与上游成本挤压——为了在HBM3e及下一代HBM4市场争夺主导权，存储巨头们陷入了半导体历史上最激烈的设备与产能军备竞赛。

三星电子已承诺在2026年投入超过110万亿韩元（约合826亿美元）的资本支出与研发资金，创下公司年度预算的最高纪录；SK海力士则全力扩建专为HBM4打造的清州M15X厂区，并斥资38.7亿美元在美国印第安纳州建立先进封装基地。

行业数据显示，为了满足HBM的挤压式需求，到2026年底，全球存储巨头将有高达25%的DRAM晶圆产能被强制锁定用于HBM生产。庞大的资本支出显著推高了企业后续的设备折旧与摊销成本。

更为严峻的是，供应链上游成本端的挤压正进一步蚕食盈利预期。

此前，光刻机巨头 ASML已明确通知，自2027年1月起将其供应给三星电子和SK海力士的EUV及DUV光刻机替换零部件价格统一上调10%。与此同时，光刻机的涨价方案也呼之欲出。

在此背景下，SK海力士当前动态市盈率仅为6.96倍，明显低于半导体行业平均水平。表面上存在估值折价，但折价是否合理，很大程度上取决于其能否在高额资本支出与上升的运营支出双重压力下，维持未来利润的质量与可持续性。

爆仓恐惧中的散户

高杠杆交易在韩国散户中的风险，早在今年夏天就已拉响警报。

此前路透社报道过的24岁首尔大学生李承浩（Lee Seung-ho），成为了这种杠杆风险最直观的早期警示与典型缩影。

路透称李承浩积攒了2000万韩元，通过交易应用参与5倍杠杆交易，账户资产一度暴涨至3亿韩元（约合人民币155万元）。但随着5月份市场波动的加剧，追加保证金和平仓接踵而至，他在短短四周内损失了全部收益与本金。

报道中，他将当时的身心感受形容为“字面意义上地无法呼吸”。

然而，这种由高杠杆交易堆积的风险并未被及时去化，而是随着单股杠杆产品在散户中的流行，一路阴跌并蔓延到了现在。

10月12日，韩国股市遭遇惨烈重挫，这种压抑已久的恐慌与焦虑在社交平台上集中爆发。收盘后，韩国投资者在社交平台 X 上铺天盖地地表达着困惑与不满。

有散户将韩国股市与美股、日股走势进行对比，质疑韩国市场为何持续承压。另一些投资者则将矛头指向外资持续流出，认为韩国股市在全球市场上涨时未能充分受益，却在调整时承受了更大的压力。

这些帖子反映了散户对市场表现的强烈不满，但情绪背后还有更值得关注的资金变化。

按照近期交易数据，10月12日外资单日净卖出韩国股票近2万亿韩元，近一个月累计净卖出达到29.7万亿韩元（约合1560亿元）。如果相关统计得到确认，这意味着外资撤离韩股已成为本轮市场调整的重要压力来源。

如果说外资流出解释了市场为何承压，杠杆交易则关系到下跌为何可能进一步放大。

围绕韩国单股杠杆ETF的争议近期在投资者社区持续发酵。

有帖子援引相关估算称，散户在单股杠杆产品上的资产损失规模达到了54万亿韩元（约合人民币2835亿元）。这一数字反映了高风险衍生品在市场波动中的巨大杀伤力，但也引发了关于其统计口径与计算样本的诸多讨论。

杠杆产品会显著放大股价波动。

当市场下跌时，持仓缩水可能触发追加保证金，迫使投资者被动平仓并加剧下行压力。而单股杠杆ETF的每日调仓机制是否会在特定交易日放大标的股票的卖压，则需结合产品结构与实际资金流向具体分析，不能一概而论。

从7月李承浩的爆仓归零，社交平台上对54万亿韩元巨额损失的惊呼，暴露了高杠杆交易在市场逆转时的极致脆弱性。

所以，韩国股市此次调整，既有投资者对AI产业增长前景的重估，也暴露出高杠杆交易在市场逆转时的脆弱性——当股价不再持续上涨，杠杆带来的收益优势便可能迅速转化为风险。

对部分散户而言，残酷的不是一时亏损，而是在市场反弹前因资金不足被迫离场。

前OpenAI研究员、25岁就被誉为“华尔街AI新股神”的利奥波德·阿申布伦纳（Leopold Aschenbrenner），在7月底四倍杠杆爆仓倒在科技股反弹前夜的“惨剧”，就是一个典型。

本文来源：腾讯科技

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

41 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

1 条评论

见闻用户
32分钟前 中国上海

@人类黄金时期的首尔女孩

0 回复

摘要：
10月13日，阿里巴巴旗下千问（以下简称：千问）发布AI眼镜N1、N1 Pro和AI耳夹式耳机，三款产品已在淘宝、天猫、京东、抖音等平台现货开售。

10月13日，阿里巴巴旗下千问（以下简称：千问）发布AI眼镜N1、N1 Pro和AI耳夹式耳机，三款产品已在淘宝、天猫、京东、抖音等平台现货开售。其中，叠加国补及限时优惠后，AI眼镜N1标准套装到手价2218元起，超级续航套装2446元起；N1 Pro标准套装2600元起，超级续航套装2827元起；AI耳夹式耳机首销价1099元。

阿里巴巴集团千问事业部副总裁宋刚在发布会上表示："千问的目标是成为每个人的Personal Agent，我们认为AI穿戴是千问在物理世界的延伸，也是Personal Agent的重要组成部分。无论你从哪里发起需求，背后都是同一个千问，理解同一个人，延续同一个目标。"

N1系列主打影像与感知。公司介绍，眼镜搭载5000万像素传感器与1G5P镜头，支持4K录像；开启相关功能并关联行程后，可在高铁站、机场主动提示检票口、发车时间。官方标称，N1综合续航9小时，N1 Pro为8小时。发布会现场口径显示，N1标准套装首销价2218元、超级续航套装2446元，N1 Pro两个套装分别为2600元和2827元。

N1 Pro在N1基础上增加体征监测、眼动交互与虹膜核身，可实时监测心率、血氧、皮肤温度等指标，并通过AI洞察报告生成状态解读；虹膜核身由千问与蚂蚁集团GPASS共同研发，千问称误识率低于百万分之一。支付流程上，用户在支付宝发起支付后看向商家收款码，确认付款信息并点头，核验通过即完成付款。

AI耳夹式耳机由千问与声学品牌Bose联名推出，采用开放式耳夹设计，支持89种语言实时翻译、AI实时听记和语音交办任务，也可预约定时任务，到点收听简报。官方标称，耳机单耳续航9小时以上，搭配充电仓整机续航40小时以上。耳机首销价1099元，提供三款配色。

此外，千问开放平台的"技能广场"已逐步上线，用户可为眼镜和耳机加装语音直达的第三方技能。

N1系列的定价落在主流智能眼镜产品区间，小米AI眼镜2025年6月发布时起售价1999元；Rokid Glasses 2025年9月开售，定价3299元；Meta Ray-Ban Display定价799美元（约5684元）。

行业层面，IDC预计2026年全球智能眼镜出货量将达2368.7万台，其中，中国市场从2025年的约275万台增至491.5万台；智能眼镜自2026年起首次纳入国补，按售价的15%补贴、单件上限500元。

不过，IDC今年6月披露的数据显示，2026年一季度全球智能眼镜出货量同比增长130.1%，中国音频及音频拍摄眼镜整体出货量下降0.1%。其中，音频拍摄眼镜同比增长513.1%、占比升至43.4%，增长集中在带拍摄与AI能力的品类。

千问的硬件线在一年内快速铺开。2025年11月27日，阿里发布夸克AI眼镜S1、G1两个系列，最低到手价分别为3799元、1899元；2025年12月，阿里成立千问C端事业群，整合千问App、夸克、AI硬件等业务，由阿里巴巴集团副总裁吴嘉负责；2026年3月，千问品牌首款AI眼镜G1发布，叠加补贴后到手价1997元起；2026年4月，千问AI眼镜通过OTA升级接入淘宝闪购与支付宝，点外卖、停车缴费、话费充值等"AI办事"能力上线。

从夸克到千问，阿里硬件产品线持续扩充。目前，三款千问AI硬件新品均未公布出货目标。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

27 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

利润和供应链话语权都在重新分配。有的公司赚得更多了，有的从电脑之外获得了更多收入。

电脑更难卖了。第三季度，全球PC出货量减少了两成。

IDC最新公布的数据显示，2026年第三季度，全球PC出货量为6270万台，同比下降20.1%。联想、惠普、戴尔、苹果、华硕，排名前五的厂商无一增长。连一向坚挺的苹果，Mac出货量也跌了11.3%。

Top 5 Companies, Worldwide Traditional PC Shipments, Market Share, and Year-Over-Year Growth, Q3 2026 (Preliminary results, shipments are in millions of units)

Company	3Q26 Shipments	3Q26 Market Share	3Q25 Shipments	3Q25 Market Share	3Q26/3Q25 Growth
1. Lenovo	14.9	23.8%	19.3	24.6%	-22.6%
2. HP Inc	10.3	16.5%	15.0	19.1%	-30.9%
3. Dell Technologies	7.6	12.1%	10.1	12.9%	-25.0%
4. Apple	5.9	9.5%	6.7	8.5%	-11.3%
5. ASUS	5.5	8.7%	6.0	7.6%	-8.6%
Others	18.4	29.4%	21.4	27.3%	-14.0%
Total	62.7	100.0%	78.5	100.0%	-20.1%

Source: IDC Quarterly Personal Computing Device Tracker, October 8, 2026

按理说，这样的数据出来，行业应该一片哀嚎。但翻开几家厂商截止到6月底或7月底的财报，业绩并不差。联想的经调整净利润涨了近两倍，苹果的Mac收入创了同期纪录，戴尔股价年内涨了三倍。华硕则是在这轮暴跌里抢到了更多市场份额。只有惠普，收入创了新高，利润却在下滑。

同样是内存涨价，结果却两样，原因是AI正在放大厂商之间的差异。数据中心抢走存储产能，内存价格暴涨，整机厂跟着提价。有高端用户买单的，价格涨得上去；没有的，只能硬扛。与此同时，科技巨头砸向AI的钱变成了服务器订单，流向手里有基础设施业务的PC厂商。简而言之，有的公司赚得更多了，有的从电脑之外获得了更多收入。

所以PC市场的失速，不只是需求不行了，而是AI重洗了这个行业的成本、利润和座次。我们想弄清楚，这场暴跌中，为什么有的厂商受伤，有的反而赚得更多？AI又在怎样改写这个行业的秩序？

旺季为什么不灵了？

PC行业有个规律。三季度有返校季，有企业集中采购，渠道还要为年末备货，历来是一年里的出货高点。今年这个规律失灵了。三季度全球出货量同比暴跌20.1%，环比二季度跌了8.1%。

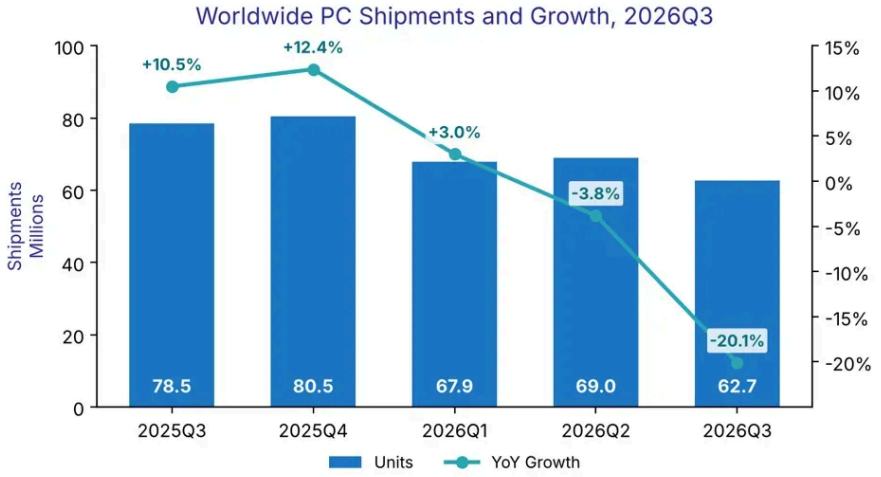

Source: IDC 2026

去年同期的换机潮，抬高了今年比较的基数。当时，Windows 10临近停止常规支持，带动企业和个人更新电脑。

今年上半年，厂商和渠道又把一部分原计划下半年进的货提前了。IDC统计的出货包括发往渠道和直接交付给用户的机器。电脑进入经销商仓库，就已经计入出货。

渠道为什么提前压货？因为怕涨价。今年年初，集邦咨询预测一季度内存合约价要环比涨五到六成，后来的实际涨幅接近翻倍。现货市场更疯狂，一条16GB的DDR5内存条，去年9月卖300块，**今年1月卖到1400块，四个月涨了三倍多**。对准备在接下来几个月卖电脑的商家而言，等待可能意味着更高的进货成本。

提前采购可以暂时避开后面的涨价，但也占用了资金。到了三季度，渠道需要先卖掉之前的库存，新订单随之放慢。

一位华北地区的PC经销商告诉「定焦One」，上半年大家都在抢货，怕后面更贵，变相撑起了市场，到了三季度，多数都在慢慢消化库存，不敢向厂商下新订单。

麻烦在于，市场判断，存储芯片的供需紧张至少要持续到2028年上半年。为什么会持续这么久？**还是因为AI。**

PC和AI服务器使用的内存不完全相同。普通PC主要使用DDR、LPDDR系统内存，采用高端GPU的AI服务器还需要高带宽内存，也就是HBM。但它们都需要三星、SK海力士、美光等厂商安排产能。

数据中心的订单，对存储厂越来越有吸引力。大型云厂商愿意接受更高的价格、签订长期供货协议，存储厂自然将产能往AI倾斜，留给PC的就少了。缺口短期补不上，PC厂商只能加价抢剩下的货。一位PC渠道人士告诉「定焦One」，这一轮涨价，说白了就是算力太火，AI抢走了上游产能，PC的内存价格只能往上走。

上游成本涨到一定程度，整机厂也不得不提价，并直接影响了销量。Omdia首席分析师Ben Yeh估算，**DRAM和固态硬盘在PC成本中的占比，已从通常约15%升至接近40%**。

卖得少了，为什么赚得多了？

台数少卖了这么多，为什么有的厂商还能赚得更多了？

一是提价，把内存成本转嫁给买家；二是靠PC之外的生意，尤其是AI服务器。

先看提价。提价之后能留下多少利润，各家公司差别很大。有的客户愿意继续购买，有的会推迟换机；厂商多收的钱，还要先支付更贵的零部件。一位PC渠道人士对「定焦One」表示，中端价位现在最难受。

相对从容的是苹果和华硕，这两家的三季度出货量跌得最少。苹果跌11.3%，华硕跌8.6%，都好于行业整体20.1%的降幅。

苹果的逻辑大家都不陌生，自研芯片，软硬件生态结合。Mac在截至6月的季度里收入103.5亿美元，涨了29%。6月，苹果继续上调多款Mac和iPad的售价，其中512GB版MacBook Air从1099美元涨至1299美元。

Omdia在报告中认为，高端定位减轻了涨价对苹果的影响。对已经习惯Mac及其软件的用户，换电脑时除了比较价格，还要考虑原有软件和使用习惯。

华硕走的是另一条路，底层逻辑相似。这家早年打性价比的厂商，这些年硬生生切进了游戏本和创作者市场。ROG和ProArt拼的是更强的图形性能、更适合创作的屏幕，或者持续运行大型软件的能力。目标受众愿意为了性能多付几千块。华硕二季度品牌业务营业利益196亿新台币，同比涨了230%，公司称高价值产品占系统业务收入的65%以上。华硕的利润增长，也有AI服务器的贡献，二季度，其基础设施解决方案已占品牌收入的36%。不过，它还是主要靠高端PC赚钱。

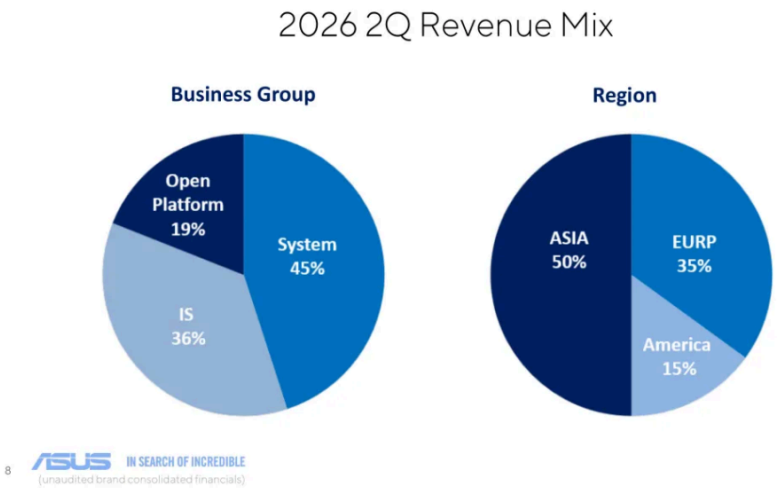

PC（System）是华硕最大单一业务 图源 / 华硕2026Q2财报

另一类是联想和戴尔，尽管它们的跌幅超过行业整体，分别达到23%和25%，但这两家并不慌。**它们的策略是PC省着花，AI基建猛投钱。**两家的基础设施业务都贡献了更多收入和利润。

先说戴尔。最新财季，总营收470亿美元，涨了58%。其中AI服务器收入164亿美元，翻倍增长，已经超过整个PC相关业务的收入。财报发布后，戴尔股价单日涨了近16%，市值冲上3600亿美元。

联想的基础设施业务也开始贡献更多利润。截至6月底的季度，ISG业务（包括传统服务器、AI服务器和存储）收入同比增长98%，营业利润达到7.77亿美元，上年同期则亏损0.86亿美元。AI服务器项目储备540亿美元，一个季度涨了157%。

最难的是惠普。三季度，惠普出货量暴跌30.9%，是前五家中降幅最大的，市场份额从一年前的19.1%缩水到16.5%，一个季度让出2.6个百分点。

惠普也涨价了。在截至7月底的那个季度，它少卖了16%的PC，个人系统业务收入反而涨了18%，冲到118亿美元。收入保住了，但利润没保住。提价的速度追不上内存涨价的速度，个人系统的营业利润率被压到4.6%，低于公司的长期区间。

惠普没有苹果那样的高端定价权，主力产品是500到800美元的商务本和家用本，这个价位的用户对价格更敏感。它也没有AI基建的牌，PC贡献四分之三营收，但利润薄，六成利润仍来自打印。打印业务本身也需求疲软。

惠普两头都不占，公司预计，下半年整个PC市场还要同比跌十几个百分点。

这五家的财报反映出两个趋势。**首先是需求侧，利润正在向高端集中。**Omdia的数据提到，售价900美元以上的高端PC，出货量在这轮暴跌中没有下降，还略有增长。苹果和华硕吃的正是这块市场。

其次是供给侧，比的是谁拿得到紧缺的货，谁涨价市场认。这背后说到底，是供应链议价能力的差距。摩根士丹利的供应链调研给过一个排序，戴尔拿到的供货和价格条件最好，联想次之，惠普因为更依赖消费市场，排在最后。

还有哪三张牌？

PC这个行业，过去四十年都是薄利多销的生意，主要通过规模采购、制造效率和渠道销售控制成本。即便是内存涨跌，也是周期性的，厂商可以通过调节库存和订单节奏来消化成本。

这次不同。PC厂商能暂时靠涨价保住利润，但出货量还会跌，IDC已经把全年预期下调到跌11.3%。**接下来撑不撑得住，要看厂商怎样使用手里的三张牌。**

一是找新货源。今年下半年，惠普、华硕和宏碁已开始在部分笔记本中少量使用长鑫内存。联想则更早将长鑫的内存和长江存储的固态硬盘用在了部分在售机型上。

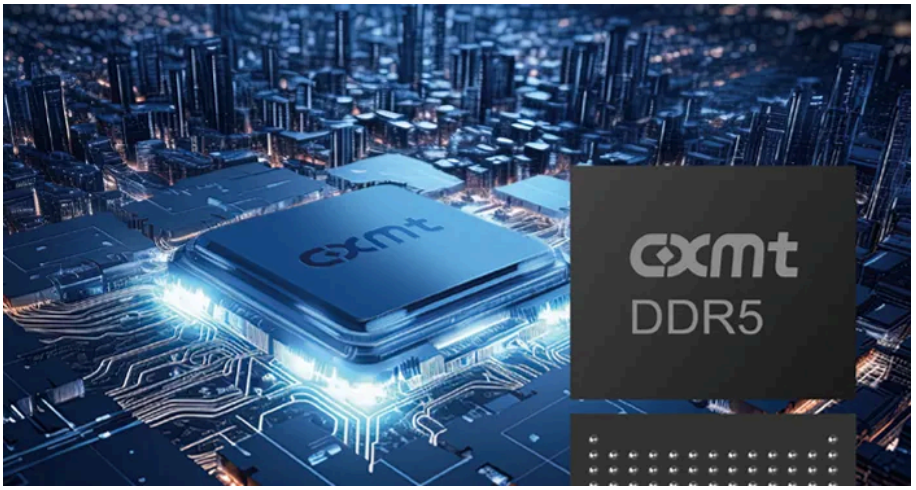

图源 / 长鑫存储官网

这在过去很难想象。PC内存多年来被三星、SK海力士、美光三家垄断，合计份额超过九成。惠普、戴尔这样的美国品牌，供应链里此前基本没有中国厂商的位置。现在存储芯片涨得太多、供给紧张，PC厂商必须给自己找第二货源。

不过这张牌只能缓解，治不了本。长鑫报价与三星等主要供应商相当，由于需求旺盛，PC厂商也难以提前锁定当季之后的货源，排队拿货的局面没有变。

第二张牌是更及时地调整售价。过去整机厂和客户每个季度重新谈一次价，现在内存一周一个价，重定价的窗口从60到90天压缩到0到15天。戴尔首席运营官Jeff Clarke在5月业绩会上形容，当时的调价频繁到“感觉每天都在重新定价”，大型订单则需要逐笔谈价。调价快一天，就少垫一天的钱。

第三张牌是AI PC。主流厂商基本都在押注，机构预计今年AI PC渗透率过半。但上述PC渠道人士称，现在AI PC能做的事，普通PC大多也能做，只是慢一点，多数用户短期内不会为一个快一点的功能换电脑。微软官方说明，普通Windows 11设备就能使用Copilot等云端AI体验，部分本地功能才有专门的硬件要求。

上述PC渠道人士补充道，上一轮换机潮是微软停服带来的，下一轮则要有足够重要的AI应用。它一旦出现，被涨价压住的消费需求会集中释放，那才是PC行业的下一波行情。

前两张牌能帮助电脑厂商对冲一部分成本压力，但能不能留下更多利润，还要看供应商涨了多少价，客户又愿意接受多少。过去一年，三星、SK海力士、美光三家的市值先后突破了万亿美元，合计超过4万亿美元，做内存的成了这轮AI行情最大的赢家。一位半导体行业分析师告诉「定焦One」：“**PC这个行业，利润大头从来不在整机厂手里。过去三十年拿大头的是英特尔和微软，整机厂赚组装的辛苦钱，现在轮到存储厂了。**”

利润往上游走的同时，下游也重排了座次。近一年，戴尔股价涨了290%，市值到了3700亿美元。联想涨了170%，市值约4200亿港元。惠普的股价在财报发布时跌了9%。市场更看好戴尔和联想这样有基础设施业务的厂商，惠普还属于“硬件制造”。市值的差距就这么拉开了。

AI改变了这个行业的利润分配。过去，利润=出货量×（单价-成本），出货量是最大的变量。现在，AI提高了电脑厂商的采购成本，也给部分公司增加了新的生意，**增量利润流向有高端用户或AI基建业务的厂商**。出货量下跌，只是这个旧公式失效的外在表现，PC行业往后拼的是谁能守住自己最赚钱的生意。有高端用户的，守住高端用户；有服务器订单的，把订单做成利润。

本文来源：定焦One

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

122 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

彭博援引知情人士称，鉴于通胀上行风险尚未明显加剧，日本央行倾向于暂缓加息，并继续评估经济数据及此前加息的影响。市场定价显示，本月加息概率约为10%，到12月时升至88%。央行还将评估油价上涨及食品销售税下调对通胀前景的影响，以判断后续加息时机。

日本央行本月或暂歇加息步伐，年内下一次行动仍有望落在12月。

10月13日，据彭博援引知情人士，**日本央行官员认为，在通胀上行风险尚未明显加剧的情况下，没有必要连续加息。官员们将根据最新经济数据，评估是否有必要在12月再次加息。**不过，知情人士强调，央行尚未作出最终决定，不排除本月会议上调整政策的可能。

市场定价显示，交易员预计日本央行本月加息的概率约为10%，而到12月时加息的概率已升至88%。上月接受彭博调查的经济学家中，约三分之一预计日本央行将在12月加息，超过半数预计加息将推迟至明年1月。

加息预期降温之际，日元继续承压。截至发稿，美元兑日元报158.13，较日本央行9月18日宣布加息前的约155.8走高，日元在加息后仍未扭转弱势。

通胀接近目标，日本央行仍需评估加息时机

日本央行行长植田和男领导的政策委员会上月将基准利率上调至1.25%，**这是日本央行三个月内第二次加息，也是1990年以来最快的加息节奏。**

日本央行自1980年以来从未连续两个月加息。据报道援引知情人士，日本经济和通胀走势总体符合央行预期，基础通胀已接近2%的目标，但央行仍需确认通胀能否持续稳定在这一水平附近。

日本央行将于10月30日举行下一次政策会议，并公布最新季度经济展望。**届时，官员们将评估油价上涨对通胀的影响，以及食品销售税临时下调是否会改变通胀预测，进而判断后续加息的时机。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

19 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

重庆市委原副书记、市政府原市长黄奇帆涉嫌严重违纪违法，目前正接受中央纪委国家监委纪律审查和监察调查。

重庆市委原副书记、市政府原市长黄奇帆涉嫌严重违纪违法，目前正接受中央纪委国家监委纪律审查和监察调查。

来源：央视新闻

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

311 收藏 分享到:

摘要：

苹果将于10月13日举行“Welcome Home”发布活动，推出智能家居中枢HomeView，并更新HomePod mini和Apple TV 4K。此次发布的一大看点是AI功能落地：HomeView将以升级版Siri为核心，两款升级产品也有望通过处理器更新，强化AI应用、语音交互和智能家居控制能力。

北京时间10月13日21时，苹果将举行“Welcome Home”发布活动，三款智能家居产品将一次登场。

其中，**全新智能家居中枢HomeView是此次发布的主角，配备触摸屏，并将搭配门铃、温控器等设备。此外，苹果还将推出HomePod mini 2和新一代Apple TV 4K，升级现有产品线。**

此次发布的一大看点是AI功能的落地。HomeView将以升级版Siri为核心，HomePod mini 2和新款Apple TV 4K也有望升级处理器，为语音交互、AI应用和家庭设备控制提供更强的硬件支持。**苹果希望借此将AI能力融入现有产品生态，而不只是推出几款新设备。**

智能家居新品只是苹果近期产品攻势的一部分。**本月晚些时候，公司计划推出触屏MacBook和新款iPad mini，折叠屏iPhone Duo则将于本周五开启预购。**不过，产品阵容扩张能否转化为持续的业绩增长，仍有待市场检验。

HomeView：苹果拓展智能家居产品线

HomeView是苹果此次智能家居布局的核心产品。

据报道，该设备配备约6英寸的方形触摸屏，机身厚度与iPhone相近，采用圆角设计和窄边框。桌面版配有圆形金属底座，内置扬声器和麦克风，并通过金属支臂支撑屏幕，设计借鉴经典iMac G4；壁挂版则采用更薄的底座，同样内置扬声器和麦克风。桌面版据称提供银色、深空灰、星光色和玫瑰粉四种配色，壁挂版则有深空灰和银色可选。

升级版Siri AI将是HomeView的主要功能。报道称，该设备将运行一套融合iPadOS、watchOS和tvOS元素的新操作系统，支持应用和小组件，但不会设立App Store，也不支持用户自行安装额外软件。设备通过USB-C接口持续供电，不配备电池，主要用于固定在家庭环境中。

HomeView还将采用面部识别技术识别家庭成员，但其能力与传统Face ID有所不同；前置摄像头同时支持FaceTime视频通话。

苹果还计划推出一款特殊的AI传感器摄像头作为配套设备。彭博记者Mark Gurman在播客中介绍，该设备代号为J450，并不录制常规视频，而是以极低帧率分析家庭环境，设计思路是兼顾环境感知与隐私保护。据报道，苹果还在研发代号J595的后续产品，计划加入机械臂，让屏幕能够随用户移动而转动。

HomePod mini 2与Apple TV 4K：硬件升级服务于AI功能

HomePod mini 2将是该系列自2020年推出以来的首次实质性升级。

新款预计延续原有的球形设计和网状外壳，并增加粉色、绿色等配色。**内部硬件则有望升级，芯片可能从原版采用的S5换为较新的Apple Watch处理器，潜在选项包括S10，以提升设备处**

理AI功能和音频任务的能力。

此外，新款据报道将搭载苹果N1无线网络芯片，支持Wi-Fi 7和蓝牙6，并采用第二代超宽带芯片，改善与iPhone之间的音乐切换体验。

新一代Apple TV 4K也有望升级处理器和内存。现款产品搭载A15仿生芯片，新款可能换用A19，并增加内存，以支持Siri AI和Apple Intelligence功能。新款同样预计搭载N1芯片，支持Wi-Fi 7、蓝牙6和Thread协议，进一步强化其在苹果智能家居生态中的作用。

遥控器也可能迎来调整。据报道，新款Siri Remote将内置扬声器并支持Find My定位，Apple TV 4K本体则可能增加麦克风，让用户无需拿起遥控器即可唤醒Siri。

价格方面，苹果此前已将HomePod mini售价从99美元上调至129美元，现款Apple TV 4K起售价为199美元。新品定价尚未明确，硬件升级是否会带来进一步涨价仍有待观察。据报道，**两款产品预计于10月30日开始发货，本周开启预购。**

高估值之下，新品能否带来增长仍待观察

据彭博报道，苹果本财年（截至9月30日）营收预计同比增长15%，但增速将在2027财年放缓至10%，2028财年进一步降至7.8%。彭博智库数据显示，标普500信息技术板块营收增速预计也将从2026年的37%降至2027年的29%。**在增长预期放缓之际，苹果需要证明新品能够为现有业务带来增量。**

市场对苹果新品的增长潜力看法不一。

Andersen Capital Management首席投资官Peter Andersen认为，对于苹果这样的公司，只有足够有吸引力的新品才能明显推动增长。**他表示，目前尚不确定即将推出的产品能否带来显著的增长变化。智能家居市场已有成熟竞争者，而消费者支出又面临压力，这也增加了苹果拓展新业务的难度。**

Fusion Fund创始人兼管理合伙人Lu Zhang则对苹果的长期前景持积极态度。她认为，首代智能家居产品对苹果整体营收的贡献可能有限，折叠屏iPhone Duo能否带动大规模换机也仍有待观察。

不过，她指出，AI公司推出新模型后，仍需要借助苹果的硬件和生态触达用户，这使苹果在分发渠道方面具备一定优势。**在她看来，只要苹果能够持续推出有竞争力的硬件产品，较高的估值仍有支撑。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

115 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

美国银行最新调查显示，全球基金经理对科技股的超配比例升至37%，创2020年8月以来新高，但对AI泡沫的判断明显分化，45%预计泡沫将在2027年出现。与此同时，全球半导体股票取代AI交易，成为市场最拥挤的交易。债券吸引力回升，若10年期美债收益率升至6%，37%的受访者将考虑从股票转向债券。

全球基金经理对科技股的配置热情已升至2020年新冠疫情反弹以来最高水平，与此同时，市场对AI交易的共识正在悄然分化，半导体股票取而代之成为最拥挤的交易标的。

据美国银行最新月度基金经理调查，**受访基金经理中超配科技板块的比例从上月的30%跃升至37%，为2020年8月以来最高。**与此同时，约45%的受访者认为AI泡沫将在2027年出现，42%持相反意见，市场分歧明显。

这一调查结果公布之际，科技股正承压。周二，韩国存储芯片巨头三星电子和SK海力士大幅下跌，拖累亚洲股票基准指数跌至8月以来最低水平，追踪美国纳斯达克100指数的期货合约同日下滑0.6%。

科技股超配比例创六年新高

美国银行调查显示，全球投资者追逐AI驱动的股市上涨行情，对科技股的超配比例已达到六年来峰值。人工智能是近年来股票市场最炙手可热的交易主题，推动标普500指数在长达四年的牛市中累计上涨近120%。

然而，随着投资者开始质疑AI相关技术的高额资本支出能否带来相应回报，围绕AI的部分热情正在消退。本次调查中，受访者对AI泡沫的看法几乎势均力敌——45%认为泡沫将于2027年形成，42%则不认同这一判断，显示市场对AI长期价值的评估存在实质性分歧。

本次调查于10月2日至8日进行，共161名参与者作答，合计管理资产规模达4530亿美元。

半导体取代AI，成市场最拥挤交易

尽管AI仍是推动科技股整体配置上升的核心叙事，但在具体交易层面，投资者的关注点已发生转移。10月美国银行调查显示，受访者将全球半导体股票列为当前市场最拥挤的交易，AI概念股不再独占鳌头。

这一转变在市场行情中已有所体现。周二亚洲市场，三星电子与SK海力士的大幅下跌直接拖累区域股指，凸显半导体板块高度集中的持仓所蕴含的波动风险。当拥挤交易遭遇情绪逆转，相关资产的调整往往更为剧烈。

债券吸引力回升，国债收益率成关键阈值

在股票配置升温的同时，债券市场的悲观情绪也在减退。调查显示，投资者对债券的看法已降至2025年5月以来最低悲观程度。

具体而言，约37%的受访者表示，若10年期美国国债收益率升至6%，将促使他们将资金从股票转向债券；另有约19%的受访者表示已在进行此类配置转移。截至周二上午，10年期美债收益率报5.19%，距离上述触发阈值尚有一定距离，但市场对利率走势的敏感度正在上升。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

98 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：
茶百道突然遭遇监管停牌，背后的原因浮出水面。 10月13日下午，香港证监会发布公告称，已对两个涉嫌参...

茶百道突然遭遇监管停牌，背后的原因浮出水面。

10月13日下午，香港证监会发布公告称，已对两个涉嫌参与欺诈计划的集团采取行动。相关集团涉嫌在首次公开招股过程中，人为制造股份需求，营造虚假或非真实的市场需求表象。

香港证监会同时表示，高度关注茶百道（02555.HK）的首次公开招股可能曾被人为操纵，以制造股份需求的虚假表象。

为维持公平、有序的市场及保护投资者利益，证监会已指令港交所自当日上午9时起暂停茶百道股份交易，相关调查仍在进行。

随着监管调查指向IPO，茶百道当年的发行安排及背后的投行阵容，也重新进入视野。

2024年4月23日，茶百道正式登陆港交所，以每股17.50港元发行约1.48亿股H股，募资总额约25.86亿港元，是当年截至其上市时港股规模最大的IPO之一。

其中，中金公司是茶百道IPO的独家保荐人及独家整体协调人，并与花旗共同担任联席全球协调人、联席账簿管理人及联席牵头经办人。

此外，招银国际、建银国际、申万宏源证券（香港）、招商证券（香港）、富途证券、老虎证券等机构也参与了承销。

在港股IPO中，保荐人主要负责上市尽职调查、核实招股文件及协助企业满足上市要求；整体协调人则承担发行承销的统筹职责，包括簿记建档、定价及股份配售等。

茶百道在正式上市前曾调整两家投行的职责分工。

2024年4月5日，茶百道公告称，公司与花旗环球金融亚洲有限公司同意终止后者作为整体协调人之一的委任，并将其重新指定为联席全球协调人及资本市场中介人。

调整后，花旗虽然继续参与股票发行和承销，但不再承担整体协调人的监管职责，中金公司则独自承担这一角色。

彼时，茶百道已通过港交所上市聆讯，距离正式挂牌不足三周。公司未在公告中说明此次调整的具体原因。

回顾茶百道当年的发行情况，其IPO并未获得特别热烈的市场反响。

根据配发结果，茶百道原计划将约10%的发售股份用于香港公开发售，其余约90%用于国际配售。经过重新分配，香港公开发售最终获分配约733.56万股，占全球发售股份的约5%。

上市首日，茶百道股价便跌破发行价，最终收于12.80港元，单日下跌26.86%。

此后两年多，茶百道股价持续承压。截至今年10月12日收盘，股价为4.035港元，较发行价下跌约77%，总市值缩水至约59.6亿港元。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

45 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

AI大模型竞争正从追求极致性能转向注重性价比。OpenRouter数据显示，前十款高性能模型的使用占比从2025年一季度的55%降至2026年三季度的14%。Meta此时推出Muse Wonder，试图证明自身的前沿模型实力，但性能领先能否转化为实际用户需求，仍有待市场检验。

AI大模型行业正面临一个反差：科技巨头仍在竞相推出性能更强的前沿模型，用户却开始转向更便宜、足以满足实际需求的产品。Meta此时推出Muse Wonder，试图证明自身的前沿模型实力，但市场需求正从追求极致性能转向注重性价比。

据The Information近日报道，**通过OpenRouter调用的AI模型中，使用量排名前十的高性能模型占比已从2025年第一季度的55%降至2026年第三季度的14%。随着低成本模型的能力不断提升，越来越多用户发现，完成日常任务并不需要调用最昂贵的模型。**

这意味着，AI行业的竞争正在从单纯比拼模型性能，转向比拼性能、成本与实际应用价值。**对于Meta而言，即使Muse Wonder能够在特定任务上达到领先水平，也仍需证明这种性能优势能够转化为用户需求。**

“前沿”标签泛滥，模型性能竞赛仍在升温

近期，主要AI公司密集推出旗舰模型，并强调其技术领先性。谷歌推出Gemini 4 Argon，称其在多个领域的复杂工作流中达到前沿水平；OpenAI发布GPT-6 Astra，宣称其在计算机操作、软件工程、网络安全及专业工作等领域达到最先进水平；Anthropic则推出Claude Fable 5.1和Mythos 5.1，将其定位为全球领先的编程与知识工作模型。

Meta推出Muse Wonder，也是在这一背景下重新强调自身的技术竞争力。**经历约14个月的大规模招聘扩张后，公司希望借助新模型证明自己仍处于AI前沿。不过，当各家厂商都在强调性能领先时，“前沿”本身越来越难以成为差异化优势。**

据报道，Meta计划将Muse Wonder用于支持其个人智能体产品Muse。但新模型的技术表现能否转化为用户可感知的体验提升，以及这种提升是否足以支撑更高的使用成本，仍有待验证。

低成本模型崛起，用户更看重性价比

OpenRouter的数据揭示了需求端的变化：高性能模型的使用占比大幅下降，反映出用户正在重新权衡模型能力与调用成本。随着低成本模型不断进步，许多日常任务已不再需要最昂贵的模型。

企业尤其倾向于根据任务难度分配模型：常规工作交给价格更低的模型，只有复杂推理、专业分析等高要求任务才调用顶级模型。这种做法既能满足实际需求，也能控制AI支出。

消费者市场也面临类似变化。对普通用户而言，模型能否准确回答问题、顺利完成任务，往往比其是否达到行业性能榜单的顶端更重要。当“足够好用”的模型能够以更低价格满足大部分需求时，顶级模型即使持续刷新性能纪录，也未必能获得相应的使用增长。

对Meta等科技巨头而言，挑战已不只是推出更强的模型，还在于证明性能提升能够带来真实的用户需求。在AI竞争从追逐性能转向衡量性价比的过程中，技术领先与商业成功之间的关系正在

发生变化。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

84 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

人才留不留得住、模型能不能保持领先、AI能不能真金白银变现……这些问题，越来越取决于手里还剩多少算力。

没招了！硅谷为了争夺AI算力已经**彻！底！疯！狂！**

就连A社CEO Dario Amodei也低声下气求到了对家Meta门前：

老铁，给点**算力**吧。。。

结果你猜怎么着，小扎婉拒，马斯克坐收渔利：

SpaceX充当英伟达GPU二道贩子，给Anthropic倒卖算力，赚得那叫个盆满钵满——

8月首份财报长势喜人，光季度AI业务收入就高达**25.61亿美元**，同比增长247%，环比更是翻了两倍之多。

好家伙！为了算力，硅谷这是拼了，**大连横时代**堂堂来袭。

甭管以前在网上互喷有多狠，台下还是要为了GW弯腰。

不弯不行啊，你看隔壁掉队的**谷歌**。

豪掷27亿美元请回来的顶级科学家Noam Shazeer，因为**差算力**，没两年就托马斯回旋跳去了OpenAI。

别人砸钱还要听个响，你谷歌纯纯做慈善来的。（doge）

反正硅谷现在是咂摸出味儿了：

人才留不留得住、模型能不能保持领先、AI能不能真金白银变现……这些问题，越来越取决于手里还剩多少算力。

GPU成硅谷硬通货

以前缺钱缺人，现在冒头的是**算力经济**。

即便强如谷歌这样的科技巨头，也无法保证明星研究员能获得足够的GPU资源。

提起**Noam Shazeer**，最先想到的是Transformer八子之一，他于2021年离开谷歌创立Character.AI，致力于开发生成式AI聊天机器人。

2024年，谷歌斥资**27亿美元**，通过交易促成Shazeer回归，并担任Gemini联合负责人。

这样的研究员，本该是巨头争相保障资源的人。

但根据外媒最新报道，他的团队同样遭遇了算力被重新分配的艰难处境，Shazeer被迫转投对家**OpenAI**。

无独有偶，此前**哈萨比斯**也曾长期对项目算力不足表达过不满，在一定程度上也影响了他卸任DeepMind CEO的决定。

目前谷歌内部，关于资源分配存在较大分歧，**谢尔盖·布林**有时会直接介入，将资源重新调配给自己认为重要的项目。

但归根结底还是算力资源不够，只能开源节流。

公司外部的竞争，则让行业关系变得愈加复杂。

OpenAI、Anthropic这些顶尖初创不仅要拼模型能力，还要争夺数据中心、服务器和供电能力。

以**Anthropic**为例，其模型的算力需求已经大到，需要与另一家模型公司讨论供货。

今年5月与SpaceX的合作协议规定，将在当月收获超300兆瓦的新容量，涉及22万块英伟达GPU，同时提高Claude Code和API的使用额度。

换句话说，这样做的目的就是**让后端拿到更多算力供给前端**。算力有了，模型强了，用户也留下来了。

于是模型公司的竞争开始出现两套同时运行的逻辑：

产品层面，大家还是争用户、争开发人才；**基础设施层面**，谁能及时提供资源，谁都可能成为潜在合作对象。

那么在夹缝中生存的小型AI创业公司呢？

它们的情况更具戏剧性。

这些公司难以自建数据中心，但过去，它们可以靠灵活租用AWS等云平台的GPU，**按需付费**。

然而随着头部AI实验室大量锁定算力资源，部分云服务商开始要求多年合约，预付款高达合同金额的**30%**，甚至要求创业公司寻找付款担保方。

以上种种，都让初创公司陷入了两难境地。

算力买太多，如果未来用户增长不及预期，持续消耗的现金就打了水漂；买太少，则可能因为没有计算资源处理需求而错失增长机会。

这样的情况反而催生出了一门新生意：**全球算力淘金**。

也就是寻找全球各地尚未充分利用的AI服务器资源，再将这些算力出租给需要的企业。

比如代表性的San Francisco Compute公司就曾跑到美国乡村旧鸡舍里收服务器，**马斯克也和台积电**讨论起了进一步的算力合作。

硅谷的顶级VC也开始亲自囤GPU，YC在7月为旗下创业公司推出专供的GPU集群，Radical Ventures还会帮助被投公司协调供应商合同。

这对于正在训练或部署模型的小型团队，稍微解决了燃眉之急。

AI算力争夺战失控

但**堵不如疏**，算力会出现这种短缺情况，其实个中原因相当复杂。

OpenAI、Meta乃至谷歌都在积极建设新的数据中心，承诺**未来**会提供海量GPU资源。

但模型快速增长的需求等不及，这中间的时间差，或者说画的大饼，就是公司还得继续四处找算力的原因之一。

用户使用AI的方式，也在无形之中加码了供给压力。

从今年开始，**Agent**开始代替一问一答成为用户使用的核心范式，连续长时的工作任务迫使服务器承担起更多的并行计算。

需求增加之后，连同芯片的租赁行情都发生了翻天覆地的变化。

SemiAnalysis今年4月公布的数据显示，**H100**一年期租赁合约价格，从2025年10月低点的每GPU每小时1.70美元，上涨至2026年3月的2.35美元，涨幅接近**40%**。

GPU堪比黄金的说法，并非空穴来风。

真正能即时交付、稳定运行的算力不足，新的算力还遥遥无期，共同造就了算力市场的困境。

于是**算力霸权**变得具体。

初创公司挑战行业巨头的叙事将日益凋零，即使有人有路线，计算资源不够也完蛋。

肉眼可见的是，**算力正在成为AI时代的准入门槛**，并强化拥有自建基础设施的大公司的优势。

可谓是算力我有，实力在手。

做AI产品的，要考虑的也变多了。既要担心产品没人用，也要担心用户增长速度超过自身算力扩张。

但困境亦是机遇，**卖铲子的中间层**乐开了花。

你说是吧，老黄？

本文来源：量子位

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

27 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

特朗普单方面宣布俄乌“能源停火”，但停火承诺尚未得到俄方确认。隔夜417架无人机朝莫斯科地区方向飞行，俄军同期打击乌克兰军工、物流及港口等目标。乌方虽表示支持停火，但以俄方采取对等行动为前提，欧洲多国也对停火能否落实持怀疑态度。

特朗普单方面宣布俄乌"能源停火"，但战场上的炮火与无人机并未停歇，这场停火外交与实地冲突之间的落差，令市场对局势走向的判断愈发复杂。

据央视新闻13日报道，俄罗斯莫斯科市长索比亚宁通报称，莫斯科时间10月12日20时30分至13日7时，**417架无人机朝莫斯科地区方向飞行，**大部分在远端被压制，65架在接近该市时被摧毁。

与此同时，据新华社报道，俄罗斯国防部10月13日在社交媒体发布通报说，12日深夜至13日凌晨，**俄军使用陆基高精度武器和无人机对乌克兰部分军工设施、物流中心、铁路和港口基础设施，以及为乌军运送军用物资的船只实施集群打击。**

这一系列军事行动发生在特朗普宣布"能源停火"后不足48小时，令外界对停火协议是否真实存在产生强烈质疑。俄方迄今未正式确认任何协议，乌方则从"不知情"迅速转向"支持"，欧洲多国亦对停火的可信度持保留态度。

周二油价小幅回落，布油仍在100美元上方运行。

特朗普单方面宣布停火，各方表态分歧明显

据新华社报道，特朗普11日在社交媒体发文称，"即刻起，俄乌冲突进入'能源停火'状态，双方均已同意。"然而，乌克兰总统泽连斯基当天起初对此毫不知情，据央视新闻报道，他表示这一宣布对他而言是个"意外"，此前并未获悉相关安排。

面对外界追问，特朗普12日在离开白宫前对媒体表示，俄乌双方均已同意"能源停火"，并补充称，"**你知道为什么吗？因为我说他们同意了。**"他同时表示，普京比泽连斯基更希望达成协议，并称俄乌双方领导人必须坐下来谈判，结束这场"荒唐的战争"。

俄罗斯总统新闻秘书佩斯科夫12日则明确表示，俄方期待的是长久和平而非停战，并称关于"能源停火"，俄方"暂无可发布信息，相关接触仍在进行中"。克里姆林宫至今未确认任何协议的存在。

乌克兰迅速调整立场，但附加条件

据央视新闻报道，泽连斯基12日晚些时候明确调整立场，表示乌方支持特朗普提出的"能源停火"，乌克兰武装部队已收到相关命令，乌方"愿意不对俄罗斯能源设施发动打击，并期待俄罗斯采取同样行动"。

然而，泽连斯基同时设定了对等条件：如果俄方同意实施"能源停火"，乌方愿意采取对等行动；如果俄方拒绝，乌方将在今年冬季予以回应。这一表态意味着，乌克兰的停火承诺实际上以俄方行动为前提，并非无条件接受。

俄军集群打击乌克兰，战场行动与停火外交背道而驰

据新华社报道，俄罗斯国防部13日通报称，俄军12日深夜至13日凌晨使用陆基高精度武器和无人机，对乌克兰多处目标实施集群打击，包括：基辅市一处远程导弹和无人机生产车间、一处维修军用铁路车辆的机车库；尼古拉耶夫州一处物流中心、一处无人机仓库；以及布格河口一艘向尼古拉耶夫港运送军用货物的干货船。

据新华社报道，**俄防空部队同期在布良斯克州、莫斯科州等15处地区及亚速海水域上空，共拦截并击落604架乌克兰无人机。**

这一系列军事行动与特朗普宣布停火的时间节点高度重叠，令外界对"能源停火"的实质内容产生更大疑问。法国总统马克龙11日在社交媒体上表示，俄罗斯"现阶段仍拒绝这一提议，并在过去数小时进一步加强对乌克兰基础设施的袭击"。

欧洲盟友态度分化，对停火可信度存疑

欧洲多国对"能源停火"的反应并不一致。欧盟外交与安全政策高级代表卡拉斯12日表示，如果停火能够得到遵守，欧盟对此表示欢迎，但"目前尚未看到俄罗斯愿意遵守的迹象"，并强调停火安排不应仅局限于炼油设施。

英国首相伯纳姆11日表态"坚定支持"特朗普的呼吁，并称乌方已作好停火准备。法国总统马克龙则表示法国"完全支持"俄乌实现真正的"能源停火"，但同时指出俄方目前仍拒绝这一提议。

德国总理默茨的立场则更为强硬。他12日表示，德方已注意到美俄近期就柴油贸易达成的协议，但"德国和欧洲不予考虑此类决定"，德国将继续坚持对俄制裁。这一表态显示，欧洲内部在如何回应华盛顿主导的停火外交上，存在明显分歧。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

160 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

沃勒表示，美国长期国债收益率上升正在抑制房地产、汽车等利率敏感领域的需求，在一定程度上发挥了收紧货币政策的作用。与此同时，AI基础设施投资带来的需求增长短期内可能推高通胀，而生产率提升对供给的促进作用则需要数年才能显现。

美国长期国债收益率持续走高，正在通过收紧金融条件抑制经济需求。美联储理事沃勒表示，这一过程客观上发挥了部分货币紧缩作用。

10月13日，据彭博报道，沃勒周二在彭博新经济论坛新德里峰会上表示，**收益率上升正在“分担一部分”抑制需求的工作，尽管这并非美联储主动推动的结果。他指出，长端利率走高会影响房地产、汽车等对利率敏感的领域。**

据彭博数据，美国及其他主要发达经济体的债券收益率已升至数十年高位。自9月中旬以来，八大主要经济体掉期合约隐含的加息幅度累计下降近200个基点，市场对进一步加息的预期明显降温。

AI短期推升通胀，长期有望提高生产率

沃勒表示，研究显示，美国国债的“安全溢价”已经消失，实际收益率走高则反映了市场对实际经济增长的预期。人工智能基础设施建设带来的投资热潮，也正在影响债券收益率。

在通胀方面，沃勒指出，**AI基础设施建设所带来的需求增长，短期内可能推高通胀；但AI提升生产率、扩大供给的效果需要数年时间才能充分体现在通胀数据中。**他还表示，AI对生产率的潜在影响可能进一步拉大不同经济体之间的人均GDP差距。

沃勒称，目前通胀预期仍锚定良好。谈及美联储独立性面临的压力时，他表示，相关威胁“迄今尚未得逞”。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲 扫码 免费领取

限免

72 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

苏姿丰表示，智能体AI崛起将推动2026年进入“推理之年”（推理占比达60%），促使AMD将2030年CPU市场规模预测大幅上调至超2000亿美元（年复合增长率50%）。其AI加速器Helios已量产出货并部署于OpenAI等头部客户，同时发布的Helion机架系统将加速抢占智能体计算赛道。

AMD首席执行官苏姿丰（Lisa Su）对CPU市场前景表达了强烈信心，并将2026年定性为"推理之年"。她预计，受智能体AI工作负载驱动，CPU市场规模将在未来数年内实现爆发式增长。

在10月12日举行的OCP全球峰会主题演讲中，苏姿丰披露，**AMD在过去九个月内已三度上调CPU市场空间预测，目前预计该市场到2030年的年复合增长率约为50%，总规模将超过2000亿美元。相比之下，一年前整体CPU市场规模约为200亿美元，彼时市场普遍预期其年增速仅为个位数。**

与此同时，苏姿丰还宣布，AMD新一代AI加速产品Helios已于9月启动量产出货，首批系统已部署至OpenAI、Meta、微软、Oracle及Anthropic等头部客户。AMD还在峰会上发布了面向智能体AI计算的Helion机架系统，计划于11月26日起通过生态系统合作伙伴正式推出。

CPU市场空间预测大幅上调，智能体AI成核心驱动力

苏姿丰在峰会上表示，AMD预计数据中心AI加速器市场到2030年将接近1.5万亿美元，但她将更大的增长潜力指向CPU业务。

"我们在过去九个月内已三次上调这一市场空间预测，因为我们看到CPU整体需求出现了如此强劲的增长。我们目前认为，未来四到五年的年复合增长率约为50%，到2030年市场规模将超过2000亿美元，"苏姿丰说。

这一预测的核心逻辑在于智能体AI工作负载的兴起。苏姿丰指出，AI应用从训练向推理、再向智能体任务的持续演进，正在催生对CPU算力的新一轮需求，这一趋势超出了市场此前的预期。

2026年：推理工作负载占据市场主导

苏姿丰将2026年定性为"真正意义上的推理之年"，并预计推理工作负载将在未来占据约60%的市场份额。

"这一年，我们认为推理现在占市场的60%左右。而且不仅仅是推理，真正爆发的是智能体工作负载，"她表示。

这一判断对半导体行业的产品布局具有重要指向意义——随着AI部署从模型训练转向大规模推理与智能体任务，芯片厂商的竞争重心和客户需求结构正在发生结构性转变。

Helios量产落地，头部云厂商率先部署

苏姿丰透露，AMD已于今年9月启动Helios系列产品的量产出货，OpenAI、Meta、微软、Oracle及Anthropic均位列首批装机客户。

"我们的量产将持续在第四季度加速爬坡，并延续至明年上半年，"苏姿丰说。

Helios的顺利量产标志着AMD在高性能AI加速领域取得阶段性进展，其与头部科技及AI公司的深度绑定，也进一步巩固了其在数据中心市场的竞争地位。

Helion机架发布，押注智能体AI计算赛道

在Helios之后，AMD于峰会上进一步发布了Helion Agentic AI机架系统。苏姿丰将Helion描述为"Helios的近亲"，定位专门服务于智能体AI计算需求。

据苏姿丰介绍，Helion采用标准21英寸机架设计，支持液冷与风冷两种散热方式，搭载超过32000个Zen 6核心，较竞品机架多出40%，具备业内最高的计算密度。此外，该机架最多可容纳32块Instinct MI350 GPU，并集成大容量网络能力，整体基于开放计算标准（OCP规范）构建。

苏姿丰表示，市场对Helion机架的反响"非常积极"，生态系统合作伙伴将于11月26日起提供该产品，相关设计成果亦将贡献至OCP开放标准社区。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

49 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

手机端侧大模型的参数规模正在进一步扩大。

10月13日，华尔街见闻获悉面壁智能正式发布新一代端侧多模态大模型MiniCPM-V 4.7，包括35B-A3B和1B两个版本。

其中，35B-A3B采用MoE（混合专家）架构，总参数量达到350亿，单次推理仅激活约30亿参数。

面壁智能称，这是首个能够在端侧无损流畅运行的开源MoE模型。在其公布的测试中，该模型仅需约3GB运行内存，便可在iPad Pro上实现每秒15个以上Token的解码速度。

此前，受限于手机的运行内存、计算能力和功耗，大模型在端侧部署面临较多限制。尤其是随着模型参数规模扩大，如何在有限的硬件资源下兼顾模型能力与运行速度，成为行业需要解决的问题。

MoE架构的应用为这一难题提供了新的思路。

与每次推理都需要调用全部参数的稠密模型相比，MoE模型内部包含多个不同的“专家”，每次推理只激活部分专家。这使得模型可以在保持较大总参数规模的同时，减少单次计算量。

但新的问题随之出现。虽然每次只激活部分参数，模型仍需要存储完整的专家权重。手机运行内存有限，无法将所有专家权重都放入内存，频繁从存储设备读取数据又容易造成推理卡顿。

针对这一问题，面壁智能的解法是LES（前瞻专家调度）技术。

面壁智能的核心思路是提前预测模型接下来需要调用哪些专家，在当前计算尚未结束时，就将下一阶段可能使用的专家权重提前加载，让数据读取与模型计算同步进行。

相比传统的按需加载方式，这一技术减少了等待专家权重加载的时间，同时保留模型原有的专家选择机制，避免因减少专家调用而影响模型能力。

根据面壁智能公布的技术资料，结合权重量化、存储布局优化等方案，LES可将端侧推理速度提升约5倍。

值得注意的是，约3GB指的是特定部署方案下的运行内存占用，并不意味着350亿参数的完整模型只需要3GB存储空间。

除了35B-A3B版本，此次面壁智能还推出了1B轻量级版本，进一步降低端侧部署门槛，面向更多硬件配置有限的设备。

生态适配方面，MiniCPM-V 4.7已支持iOS、安卓和鸿蒙系统，并适配瑞芯微、Intel、Apple等芯片平台。面壁智能还同步开放端侧适配代码，支持开发者基于开源推理框架进行部署。

截至目前，面壁智能联合OpenBMB开源社区推出的MiniCPM系列开源模型，全球累计下载量已突破6000万次，覆盖文本、视觉、语音等多个领域。

面壁智能此次的突破也反映出端侧大模型技术路线正在发生变化。

过去，受限于手机的硬件条件，行业更多围绕小参数模型进行压缩和优化。如今，随着MoE架构、低比特量化和专家调度等技术逐步成熟，数百亿参数模型开始尝试进入移动终端，手机本地AI的能力边界正在进一步拓宽。

不过从模型跑通到真正进入普通消费级手机仍有一段距离。如何控制持续推理带来的功耗和发热，如何适配不同价位的芯片平台，以及更大的模型能否带来足够明显的体验提升，都需要进一步验证。

随着模型和芯片技术持续演进，手机端侧大模型有望承载更复杂的多模态理解和智能体任务，进一步减少对云端的依赖。谁能率先让数百亿参数模型从技术演示走向日常应用，或将成为下一轮端侧AI竞争的重要看点。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

25 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

标普500四年131%的累计涨幅令人瞩目，却难掩其内部深裂：84%的成分股已从高点回调超10%，42只AI概念股独揽67%涨幅，三巨头市值占比飙升至22%。高利率、债市动荡与极度集中的市场结构，令任何一次预期落空都几乎无缓冲余地。

本轮美股牛市，正站在一个微妙的十字路口。它经历了激进加息、银行业危机、地缘冲突与债券市场动荡，却依然屹立不倒，四年累计涨幅高达131%。然而，表面光鲜的指数之下，一个令人不安的结构性裂痕正在扩大——牛市的根基，正被越来越少的公司所支撑。

自2022年10月12日触底以来，标普500指数累计总回报达131%，折合年化约23.3%，约为市场历史均值的三倍。英伟达在此期间暴涨约1875%，Meta涨幅约488%。然而，据Ned Davis Research数据，**当前标普500指数市场宽度——即指数成分股中上涨股票占比——已跌至历史性低点，且此前每当市场宽度与指数走势出现背离，标普500往往在随后数月触顶。**

与此同时，债券市场的持续承压令风险资产前景蒙上阴影。美国国债收益率已升至24年高点。市场的核心矛盾已然清晰：AI盈利与投资仍构成增长支撑，但高利率、能源通胀风险与极度集中的市场结构，已令任何一次预期落空都难有缓冲余地。

AI浪潮主导牛市，但宽度创历史新低

这场牛市的最大驱动力，始终是市场对人工智能的狂热押注。然而这股热潮正在加速向少数公司集中。

据市场研究机构The Kobeissi Letter分析，自2024年初以来，**42只AI相关股票贡献了标普500指数约67%的价格回报——这42只股票为指数贡献了约22个百分点的涨幅，而其余458只成分股合计仅贡献了11个百分点。**

集中度的问题还在进一步恶化。苹果、微软与英伟达三家公司目前合计占标普500总市值约22%，较2022年底的约14%大幅攀升。与此同时，当前标普500中约84%的成分股较各自历史高点的跌幅超过10%，已处于技术意义上的回调区间——这一数据出现在指数本身仍处于历史高位之际，格外刺眼。

Nationwide首席市场策略师Mark Hackett将这种局面概括为"市场的核心张力"：**盈利与AI投资仍是增长股的强力支撑，但高长端利率、能源驱动的通胀风险以及极度收窄的市场宽度，已令市场几乎没有容错空间。**

牛市"年龄"并非风险根源

随着牛市步入第五年，部分投资者开始担忧其是否"老态龙钟"。但历史数据并不支持这一论断。

据Ned Davis Research统计，自1900年以来的38轮牛市中，有33轮的持续时间短于当前这轮。所有牛市的平均持续时间为25个月，中位数为22个月。这一数据乍看之下似乎令人警惕，但MarketWatch专栏作者Mark Hulbert援引研究指出，以"年龄"来预判牛市终结，是一种统计谬误——就如同因为黑夜跟随白昼而认为白昼导致了黑夜。

真正终结牛市的，**是经济衰退（1950年以来22次熊市中有13次伴随衰退）、投资者过度亢奋（如互联网泡沫），或外部冲击（如战争与疫情）。**CNBC主持人Jim Cramer则以投资者视角加

以印证："我们根本无法预测哪一次是真正的大跌，也无法预测反弹的时点。四年里我们有无数次可以出逃，但每一次都会让我们蒙受损失。"

涨幅131%，历史上并不罕见

这场牛市的涨幅是否已高处不胜寒？历史数据给出了相对乐观的答案。

据MarketWatch报道，圣塔克拉拉大学荣休教授Edward McQuarrie与EfficientFrontier.com创始人William Bernstein，对美国股市自18世纪末以来每个月的滚动四年总回报进行了统计，发现当前131%的四年累计涨幅并不构成历史异值——"这种情况经常发生……根本不算什么，远未到历史极端的程度，"两人写道。

即便将视野延伸至2009年3月全球金融危机低点，以17.5年为统计周期，美国股市的表现在历史上同样有过多次大幅超越当前水平的先例。这意味着，单凭涨幅本身来判断牛市即将终结，缺乏有力的历史依据。

利率与市场宽度：短期最关键的变量

当前市场的真正风险，或许不在于牛市的年龄与涨幅，而在于利率压力能否缓解，以及市场宽度能否得到修复。

摩根士丹利首席投资官Mike Wilson此前指出，**市场宽度的恶化与美联储鹰派基调密切相关——在联储鹰派立场的强化之后，利率预期上移，债券市场波动随之拉升美债收益率至24年高点，进一步压制了对权益资产的整体展望。他写道："如果债券波动率能够更快平息，市场宽度很可能追赶上指数价格，在近期推动两者共同走高。"**

汇丰多资产策略团队持有类似观点。据汇丰报告，若美国经济数据出现持续低于预期的信号，有望拖动整条美债收益率曲线下行，从而对各类资产的估值形成支撑，并有利于股市内部驱动力的扩散与再平衡。

汇丰策略师Max Kettner团队认为，在进入2027年后，若"金发女孩"组合得以实现，即增长稳健、通胀回落、利率下行，届时科技股与美股盈利或将重回强势，但届时的上涨仍可能是一轮集中度较高的结构性行情。

AI泡沫之争：分歧犹存，短期支撑仍在

市场另一个核心争论，是人工智能投资是否已步入泡沫阶段。

汇丰策略团队对此持明确的反驳立场。其报告指出，当前AI怀疑论的问题在于目光过于长远——以两至三年后的高度不确定性收入预测来否定当前价格走势，逻辑并不成立。

更重要的近期信号是：**超大规模云计算企业（hyperscalers）的自由现金流（FCF）下修速度已开始放缓，2027年FCF改善预期正在形成；半导体与存储器公司近期重新领涨；算力价格止跌回升，呈现出"杰文斯悖论"（Jevons' Paradox）的特征——即效率提升反而带动更大规模的需求扩张，对整个科技板块构成潜在正向催化。**

盈利面亦提供了支撑。据FactSet数据，当前已有创纪录数量的标普500成分公司对第三季度发布正面盈利指引。三星电子此前预告第三季度营业利润有望达到800亿美元，若实现，将创下科技企业史上最高单季利润纪录。

这在一定程度上解释了，为何在战争、利率高企与经济不确定性并存的环境下，指数仍能维持在历史高位——资金正在流向真正赚钱的地方。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

99 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

3 条评论

防御型投资者
2小时前 中国上海

只要美元是最大储备货币，美股就会一直涨下去。

0 回复

见闻用户
3小时前 中国上海

一点都不稳定，上窜上跳😠

1 回复

深蓝天蝎 2小时前 中国广东省

回复 **见闻用户：**

A股稳定，十年如一日

0 回复