摘要：
茶百道突然遭遇监管停牌，背后的原因浮出水面。 10月13日下午，香港证监会发布公告称，已对两个涉嫌参...

茶百道突然遭遇监管停牌，背后的原因浮出水面。

10月13日下午，香港证监会发布公告称，已对两个涉嫌参与欺诈计划的集团采取行动。相关集团涉嫌在首次公开招股过程中，人为制造股份需求，营造虚假或非真实的市场需求表象。

香港证监会同时表示，高度关注茶百道（02555.HK）的首次公开招股可能曾被人为操纵，以制造股份需求的虚假表象。

为维持公平、有序的市场及保护投资者利益，证监会已指令港交所自当日上午9时起暂停茶百道股份交易，相关调查仍在进行。

随着监管调查指向IPO，茶百道当年的发行安排及背后的投行阵容，也重新进入视野。

2024年4月23日，茶百道正式登陆港交所，以每股17.50港元发行约1.48亿股H股，募资总额约25.86亿港元，是当年截至其上市时港股规模最大的IPO之一。

其中，中金公司是茶百道IPO的独家保荐人及独家整体协调人，并与花旗共同担任联席全球协调人、联席账簿管理人及联席牵头经办人。

此外，招银国际、建银国际、申万宏源证券（香港）、招商证券（香港）、富途证券、老虎证券等机构也参与了承销。

在港股IPO中，保荐人主要负责上市尽职调查、核实招股文件及协助企业满足上市要求；整体协调人则承担发行承销的统筹职责，包括簿记建档、定价及股份配售等。

茶百道在正式上市前曾调整两家投行的职责分工。

2024年4月5日，茶百道公告称，公司与花旗环球金融亚洲有限公司同意终止后者作为整体协调人之一的委任，并将其重新指定为联席全球协调人及资本市场中介人。

调整后，花旗虽然继续参与股票发行和承销，但不再承担整体协调人的监管职责，中金公司则独自承担这一角色。

彼时，茶百道已通过港交所上市聆讯，距离正式挂牌不足三周。公司未在公告中说明此次调整的具体原因。

回顾茶百道当年的发行情况，其IPO并未获得特别热烈的市场反响。

根据配发结果，茶百道原计划将约10%的发售股份用于香港公开发售，其余约90%用于国际配售。经过重新分配，香港公开发售最终获分配约733.56万股，占全球发售股份的约5%。

上市首日，茶百道股价便跌破发行价，最终收于12.80港元，单日下跌26.86%。

此后两年多，茶百道股价持续承压。截至今年10月12日收盘，股价为4.035港元，较发行价下跌约77%，总市值缩水至约59.6亿港元。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

45 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

AI大模型竞争正从追求极致性能转向注重性价比。OpenRouter数据显示，前十款高性能模型的使用占比从2025年一季度的55%降至2026年三季度的14%。Meta此时推出Muse Wonder，试图证明自身的前沿模型实力，但性能领先能否转化为实际用户需求，仍有待市场检验。

AI大模型行业正面临一个反差：科技巨头仍在竞相推出性能更强的前沿模型，用户却开始转向更便宜、足以满足实际需求的产品。Meta此时推出Muse Wonder，试图证明自身的前沿模型实力，但市场需求正从追求极致性能转向注重性价比。

据The Information近日报道，**通过OpenRouter调用的AI模型中，使用量排名前十的高性能模型占比已从2025年第一季度的55%降至2026年第三季度的14%。随着低成本模型的能力不断提升，越来越多用户发现，完成日常任务并不需要调用最昂贵的模型。**

这意味着，AI行业的竞争正在从单纯比拼模型性能，转向比拼性能、成本与实际应用价值。**对于Meta而言，即使Muse Wonder能够在特定任务上达到领先水平，也仍需证明这种性能优势能够转化为用户需求。**

“前沿”标签泛滥，模型性能竞赛仍在升温

近期，主要AI公司密集推出旗舰模型，并强调其技术领先性。谷歌推出Gemini 4 Argon，称其在多个领域的复杂工作流中达到前沿水平；OpenAI发布GPT-6 Astra，宣称其在计算机操作、软件工程、网络安全及专业工作等领域达到最先进水平；Anthropic则推出Claude Fable 5.1和Mythos 5.1，将其定位为全球领先的编程与知识工作模型。

Meta推出Muse Wonder，也是在这一背景下重新强调自身的技术竞争力。**经历约14个月的大规模招聘扩张后，公司希望借助新模型证明自己仍处于AI前沿。不过，当各家厂商都在强调性能领先时，“前沿”本身越来越难以成为差异化优势。**

据报道，Meta计划将Muse Wonder用于支持其个人智能体产品Muse。但新模型的技术表现能否转化为用户可感知的体验提升，以及这种提升是否足以支撑更高的使用成本，仍有待验证。

低成本模型崛起，用户更看重性价比

OpenRouter的数据揭示了需求端的变化：高性能模型的使用占比大幅下降，反映出用户正在重新权衡模型能力与调用成本。随着低成本模型不断进步，许多日常任务已不再需要最昂贵的模型。

企业尤其倾向于根据任务难度分配模型：常规工作交给价格更低的模型，只有复杂推理、专业分析等高要求任务才调用顶级模型。这种做法既能满足实际需求，也能控制AI支出。

消费者市场也面临类似变化。对普通用户而言，模型能否准确回答问题、顺利完成任务，往往比其是否达到行业性能榜单的顶端更重要。当“足够好用”的模型能够以更低价格满足大部分需求时，顶级模型即使持续刷新性能纪录，也未必能获得相应的使用增长。

对Meta等科技巨头而言，挑战已不只是推出更强的模型，还在于证明性能提升能够带来真实的用户需求。在AI竞争从追逐性能转向衡量性价比的过程中，技术领先与商业成功之间的关系正在

发生变化。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

84 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

人才留不留得住、模型能不能保持领先、AI能不能真金白银变现……这些问题，越来越取决于手里还剩多少算力。

没招了！硅谷为了争夺AI算力已经**彻！底！疯！狂！**

就连A社CEO Dario Amodei也低声下气求到了对家Meta门前：

老铁，给点**算力**吧。。。

结果你猜怎么着，小扎婉拒，马斯克坐收渔利：

SpaceX充当英伟达GPU二道贩子，给Anthropic倒卖算力，赚得那叫个盆满钵满——

8月首份财报长势喜人，光季度AI业务收入就高达**25.61亿美元**，同比增长247%，环比更是翻了两倍之多。

好家伙！为了算力，硅谷这是拼了，**大连横时代**堂堂来袭。

甭管以前在网上互喷有多狠，台下还是要为了GW弯腰。

不弯不行啊，你看隔壁掉队的**谷歌**。

豪掷27亿美元请回来的顶级科学家Noam Shazeer，因为**差算力**，没两年就托马斯回旋跳去了OpenAI。

别人砸钱还要听个响，你谷歌纯纯做慈善来的。（doge）

反正硅谷现在是咂摸出味儿了：

人才留不留得住、模型能不能保持领先、AI能不能真金白银变现……这些问题，越来越取决于手里还剩多少算力。

GPU成硅谷硬通货

以前缺钱缺人，现在冒头的是**算力经济**。

即便强如谷歌这样的科技巨头，也无法保证明星研究员能获得足够的GPU资源。

提起**Noam Shazeer**，最先想到的是Transformer八子之一，他于2021年离开谷歌创立Character.AI，致力于开发生成式AI聊天机器人。

2024年，谷歌斥资**27亿美元**，通过交易促成Shazeer回归，并担任Gemini联合负责人。

这样的研究员，本该是巨头争相保障资源的人。

但根据外媒最新报道，他的团队同样遭遇了算力被重新分配的艰难处境，Shazeer被迫转投对家**OpenAI**。

无独有偶，此前**哈萨比斯**也曾长期对项目算力不足表达过不满，在一定程度上也影响了他卸任DeepMind CEO的决定。

目前谷歌内部，关于资源分配存在较大分歧，**谢尔盖·布林**有时会直接介入，将资源重新调配给自己认为重要的项目。

但归根结底还是算力资源不够，只能开源节流。

公司外部的竞争，则让行业关系变得愈加复杂。

OpenAI、Anthropic这些顶尖初创不仅要拼模型能力，还要争夺数据中心、服务器和供电能力。

以**Anthropic**为例，其模型的算力需求已经大到，需要与另一家模型公司讨论供货。

今年5月与SpaceX的合作协议规定，将在当月收获超300兆瓦的新容量，涉及22万块英伟达GPU，同时提高Claude Code和API的使用额度。

换句话说，这样做的目的就是**让后端拿到更多算力供给前端**。算力有了，模型强了，用户也留下来了。

于是模型公司的竞争开始出现两套同时运行的逻辑：

产品层面，大家还是争用户、争开发人才；**基础设施层面**，谁能及时提供资源，谁都可能成为潜在合作对象。

那么在夹缝中生存的小型AI创业公司呢？

它们的情况更具戏剧性。

这些公司难以自建数据中心，但过去，它们可以靠灵活租用AWS等云平台的GPU，**按需付费**。

然而随着头部AI实验室大量锁定算力资源，部分云服务商开始要求多年合约，预付款高达合同金额的**30%**，甚至要求创业公司寻找付款担保方。

以上种种，都让初创公司陷入了两难境地。

算力买太多，如果未来用户增长不及预期，持续消耗的现金就打了水漂；买太少，则可能因为没有计算资源处理需求而错失增长机会。

这样的情况反而催生出了一门新生意：**全球算力淘金**。

也就是寻找全球各地尚未充分利用的AI服务器资源，再将这些算力出租给需要的企业。

比如代表性的San Francisco Compute公司就曾跑到美国乡村旧鸡舍里收服务器，**马斯克也和台积电**讨论起了进一步的算力合作。

硅谷的顶级VC也开始亲自囤GPU，YC在7月为旗下创业公司推出专供的GPU集群，Radical Ventures还会帮助被投公司协调供应商合同。

这对于正在训练或部署模型的小型团队，稍微解决了燃眉之急。

AI算力争夺战失控

但**堵不如疏**，算力会出现这种短缺情况，其实个中原因相当复杂。

OpenAI、Meta乃至谷歌都在积极建设新的数据中心，承诺**未来**会提供海量GPU资源。

但模型快速增长的需求等不及，这中间的时间差，或者说画的大饼，就是公司还得继续四处找算力的原因之一。

用户使用AI的方式，也在无形之中加码了供给压力。

从今年开始，**Agent**开始代替一问一答成为用户使用的核心范式，连续长时的工作任务迫使服务器承担起更多的并行计算。

需求增加之后，连同芯片的租赁行情都发生了翻天覆地的变化。

SemiAnalysis今年4月公布的数据显示，**H100**一年期租赁合约价格，从2025年10月低点的每GPU每小时1.70美元，上涨至2026年3月的2.35美元，涨幅接近**40%**。

GPU堪比黄金的说法，并非空穴来风。

真正能即时交付、稳定运行的算力不足，新的算力还遥遥无期，共同造就了算力市场的困境。

于是**算力霸权**变得具体。

初创公司挑战行业巨头的叙事将日益凋零，即使有人有路线，计算资源不够也完蛋。

肉眼可见的是，**算力正在成为AI时代的准入门槛**，并强化拥有自建基础设施的大公司的优势。

可谓是算力我有，实力在手。

做AI产品的，要考虑的也变多了。既要担心产品没人用，也要担心用户增长速度超过自身算力扩张。

但困境亦是机遇，**卖铲子的中间层**乐开了花。

你说是吧，老黄？

本文来源：量子位

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

27 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

特朗普单方面宣布俄乌“能源停火”，但停火承诺尚未得到俄方确认。隔夜417架无人机朝莫斯科地区方向飞行，俄军同期打击乌克兰军工、物流及港口等目标。乌方虽表示支持停火，但以俄方采取对等行动为前提，欧洲多国也对停火能否落实持怀疑态度。

特朗普单方面宣布俄乌"能源停火"，但战场上的炮火与无人机并未停歇，这场停火外交与实地冲突之间的落差，令市场对局势走向的判断愈发复杂。

据央视新闻13日报道，俄罗斯莫斯科市长索比亚宁通报称，莫斯科时间10月12日20时30分至13日7时，**417架无人机朝莫斯科地区方向飞行，**大部分在远端被压制，65架在接近该市时被摧毁。

与此同时，据新华社报道，俄罗斯国防部10月13日在社交媒体发布通报说，12日深夜至13日凌晨，**俄军使用陆基高精度武器和无人机对乌克兰部分军工设施、物流中心、铁路和港口基础设施，以及为乌军运送军用物资的船只实施集群打击。**

这一系列军事行动发生在特朗普宣布"能源停火"后不足48小时，令外界对停火协议是否真实存在产生强烈质疑。俄方迄今未正式确认任何协议，乌方则从"不知情"迅速转向"支持"，欧洲多国亦对停火的可信度持保留态度。

周二油价小幅回落，布油仍在100美元上方运行。

特朗普单方面宣布停火，各方表态分歧明显

据新华社报道，特朗普11日在社交媒体发文称，"即刻起，俄乌冲突进入'能源停火'状态，双方均已同意。"然而，乌克兰总统泽连斯基当天起初对此毫不知情，据央视新闻报道，他表示这一宣布对他而言是个"意外"，此前并未获悉相关安排。

面对外界追问，特朗普12日在离开白宫前对媒体表示，俄乌双方均已同意"能源停火"，并补充称，"**你知道为什么吗？因为我说他们同意了。**"他同时表示，普京比泽连斯基更希望达成协议，并称俄乌双方领导人必须坐下来谈判，结束这场"荒唐的战争"。

俄罗斯总统新闻秘书佩斯科夫12日则明确表示，俄方期待的是长久和平而非停战，并称关于"能源停火"，俄方"暂无可发布信息，相关接触仍在进行中"。克里姆林宫至今未确认任何协议的存在。

乌克兰迅速调整立场，但附加条件

据央视新闻报道，泽连斯基12日晚些时候明确调整立场，表示乌方支持特朗普提出的"能源停火"，乌克兰武装部队已收到相关命令，乌方"愿意不对俄罗斯能源设施发动打击，并期待俄罗斯采取同样行动"。

然而，泽连斯基同时设定了对等条件：如果俄方同意实施"能源停火"，乌方愿意采取对等行动；如果俄方拒绝，乌方将在今年冬季予以回应。这一表态意味着，乌克兰的停火承诺实际上以俄方行动为前提，并非无条件接受。

俄军集群打击乌克兰，战场行动与停火外交背道而驰

据新华社报道，俄罗斯国防部13日通报称，俄军12日深夜至13日凌晨使用陆基高精度武器和无人机，对乌克兰多处目标实施集群打击，包括：基辅市一处远程导弹和无人机生产车间、一处维修军用铁路车辆的机车库；尼古拉耶夫州一处物流中心、一处无人机仓库；以及布格河口一艘向尼古拉耶夫港运送军用货物的干货船。

据新华社报道，**俄防空部队同期在布良斯克州、莫斯科州等15处地区及亚速海水域上空，共拦截并击落604架乌克兰无人机。**

这一系列军事行动与特朗普宣布停火的时间节点高度重叠，令外界对"能源停火"的实质内容产生更大疑问。法国总统马克龙11日在社交媒体上表示，俄罗斯"现阶段仍拒绝这一提议，并在过去数小时进一步加强对乌克兰基础设施的袭击"。

欧洲盟友态度分化，对停火可信度存疑

欧洲多国对"能源停火"的反应并不一致。欧盟外交与安全政策高级代表卡拉斯12日表示，如果停火能够得到遵守，欧盟对此表示欢迎，但"目前尚未看到俄罗斯愿意遵守的迹象"，并强调停火安排不应仅局限于炼油设施。

英国首相伯纳姆11日表态"坚定支持"特朗普的呼吁，并称乌方已作好停火准备。法国总统马克龙则表示法国"完全支持"俄乌实现真正的"能源停火"，但同时指出俄方目前仍拒绝这一提议。

德国总理默茨的立场则更为强硬。他12日表示，德方已注意到美俄近期就柴油贸易达成的协议，但"德国和欧洲不予考虑此类决定"，德国将继续坚持对俄制裁。这一表态显示，欧洲内部在如何回应华盛顿主导的停火外交上，存在明显分歧。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

160 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

沃勒表示，美国长期国债收益率上升正在抑制房地产、汽车等利率敏感领域的需求，在一定程度上发挥了收紧货币政策的作用。与此同时，AI基础设施投资带来的需求增长短期内可能推高通胀，而生产率提升对供给的促进作用则需要数年才能显现。

美国长期国债收益率持续走高，正在通过收紧金融条件抑制经济需求。美联储理事沃勒表示，这一过程客观上发挥了部分货币紧缩作用。

10月13日，据彭博报道，沃勒周二在彭博新经济论坛新德里峰会上表示，**收益率上升正在“分担一部分”抑制需求的工作，尽管这并非美联储主动推动的结果。他指出，长端利率走高会影响房地产、汽车等对利率敏感的领域。**

据彭博数据，美国及其他主要发达经济体的债券收益率已升至数十年高位。自9月中旬以来，八大主要经济体掉期合约隐含的加息幅度累计下降近200个基点，市场对进一步加息的预期明显降温。

AI短期推升通胀，长期有望提高生产率

沃勒表示，研究显示，美国国债的“安全溢价”已经消失，实际收益率走高则反映了市场对实际经济增长的预期。人工智能基础设施建设带来的投资热潮，也正在影响债券收益率。

在通胀方面，沃勒指出，**AI基础设施建设所带来的需求增长，短期内可能推高通胀；但AI提升生产率、扩大供给的效果需要数年时间才能充分体现在通胀数据中。**他还表示，AI对生产率的潜在影响可能进一步拉大不同经济体之间的人均GDP差距。

沃勒称，目前通胀预期仍锚定良好。谈及美联储独立性面临的压力时，他表示，相关威胁“迄今尚未得逞”。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲 扫码 免费领取

限免

72 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

苏姿丰表示，智能体AI崛起将推动2026年进入“推理之年”（推理占比达60%），促使AMD将2030年CPU市场规模预测大幅上调至超2000亿美元（年复合增长率50%）。其AI加速器Helios已量产出货并部署于OpenAI等头部客户，同时发布的Helion机架系统将加速抢占智能体计算赛道。

AMD首席执行官苏姿丰（Lisa Su）对CPU市场前景表达了强烈信心，并将2026年定性为"推理之年"。她预计，受智能体AI工作负载驱动，CPU市场规模将在未来数年内实现爆发式增长。

在10月12日举行的OCP全球峰会主题演讲中，苏姿丰披露，**AMD在过去九个月内已三度上调CPU市场空间预测，目前预计该市场到2030年的年复合增长率约为50%，总规模将超过2000亿美元。相比之下，一年前整体CPU市场规模约为200亿美元，彼时市场普遍预期其年增速仅为个位数。**

与此同时，苏姿丰还宣布，AMD新一代AI加速产品Helios已于9月启动量产出货，首批系统已部署至OpenAI、Meta、微软、Oracle及Anthropic等头部客户。AMD还在峰会上发布了面向智能体AI计算的Helion机架系统，计划于11月26日起通过生态系统合作伙伴正式推出。

CPU市场空间预测大幅上调，智能体AI成核心驱动力

苏姿丰在峰会上表示，AMD预计数据中心AI加速器市场到2030年将接近1.5万亿美元，但她将更大的增长潜力指向CPU业务。

"我们在过去九个月内已三次上调这一市场空间预测，因为我们看到CPU整体需求出现了如此强劲的增长。我们目前认为，未来四到五年的年复合增长率约为50%，到2030年市场规模将超过2000亿美元，"苏姿丰说。

这一预测的核心逻辑在于智能体AI工作负载的兴起。苏姿丰指出，AI应用从训练向推理、再向智能体任务的持续演进，正在催生对CPU算力的新一轮需求，这一趋势超出了市场此前的预期。

2026年：推理工作负载占据市场主导

苏姿丰将2026年定性为"真正意义上的推理之年"，并预计推理工作负载将在未来占据约60%的市场份额。

"这一年，我们认为推理现在占市场的60%左右。而且不仅仅是推理，真正爆发的是智能体工作负载，"她表示。

这一判断对半导体行业的产品布局具有重要指向意义——随着AI部署从模型训练转向大规模推理与智能体任务，芯片厂商的竞争重心和客户需求结构正在发生结构性转变。

Helios量产落地，头部云厂商率先部署

苏姿丰透露，AMD已于今年9月启动Helios系列产品的量产出货，OpenAI、Meta、微软、Oracle及Anthropic均位列首批装机客户。

"我们的量产将持续在第四季度加速爬坡，并延续至明年上半年，"苏姿丰说。

Helios的顺利量产标志着AMD在高性能AI加速领域取得阶段性进展，其与头部科技及AI公司的深度绑定，也进一步巩固了其在数据中心市场的竞争地位。

Helion机架发布，押注智能体AI计算赛道

在Helios之后，AMD于峰会上进一步发布了Helion Agentic AI机架系统。苏姿丰将Helion描述为"Helios的近亲"，定位专门服务于智能体AI计算需求。

据苏姿丰介绍，Helion采用标准21英寸机架设计，支持液冷与风冷两种散热方式，搭载超过32000个Zen 6核心，较竞品机架多出40%，具备业内最高的计算密度。此外，该机架最多可容纳32块Instinct MI350 GPU，并集成大容量网络能力，整体基于开放计算标准（OCP规范）构建。

苏姿丰表示，市场对Helion机架的反响"非常积极"，生态系统合作伙伴将于11月26日起提供该产品，相关设计成果亦将贡献至OCP开放标准社区。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

49 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

手机端侧大模型的参数规模正在进一步扩大。

10月13日，华尔街见闻获悉面壁智能正式发布新一代端侧多模态大模型MiniCPM-V 4.7，包括35B-A3B和1B两个版本。

其中，35B-A3B采用MoE（混合专家）架构，总参数量达到350亿，单次推理仅激活约30亿参数。

面壁智能称，这是首个能够在端侧无损流畅运行的开源MoE模型。在其公布的测试中，该模型仅需约3GB运行内存，便可在iPad Pro上实现每秒15个以上Token的解码速度。

此前，受限于手机的运行内存、计算能力和功耗，大模型在端侧部署面临较多限制。尤其是随着模型参数规模扩大，如何在有限的硬件资源下兼顾模型能力与运行速度，成为行业需要解决的问题。

MoE架构的应用为这一难题提供了新的思路。

与每次推理都需要调用全部参数的稠密模型相比，MoE模型内部包含多个不同的“专家”，每次推理只激活部分专家。这使得模型可以在保持较大总参数规模的同时，减少单次计算量。

但新的问题随之出现。虽然每次只激活部分参数，模型仍需要存储完整的专家权重。手机运行内存有限，无法将所有专家权重都放入内存，频繁从存储设备读取数据又容易造成推理卡顿。

针对这一问题，面壁智能的解法是LES（前瞻专家调度）技术。

面壁智能的核心思路是提前预测模型接下来需要调用哪些专家，在当前计算尚未结束时，就将下一阶段可能使用的专家权重提前加载，让数据读取与模型计算同步进行。

相比传统的按需加载方式，这一技术减少了等待专家权重加载的时间，同时保留模型原有的专家选择机制，避免因减少专家调用而影响模型能力。

根据面壁智能公布的技术资料，结合权重量化、存储布局优化等方案，LES可将端侧推理速度提升约5倍。

值得注意的是，约3GB指的是特定部署方案下的运行内存占用，并不意味着350亿参数的完整模型只需要3GB存储空间。

除了35B-A3B版本，此次面壁智能还推出了1B轻量级版本，进一步降低端侧部署门槛，面向更多硬件配置有限的设备。

生态适配方面，MiniCPM-V 4.7已支持iOS、安卓和鸿蒙系统，并适配瑞芯微、Intel、Apple等芯片平台。面壁智能还同步开放端侧适配代码，支持开发者基于开源推理框架进行部署。

截至目前，面壁智能联合OpenBMB开源社区推出的MiniCPM系列开源模型，全球累计下载量已突破6000万次，覆盖文本、视觉、语音等多个领域。

面壁智能此次的突破也反映出端侧大模型技术路线正在发生变化。

过去，受限于手机的硬件条件，行业更多围绕小参数模型进行压缩和优化。如今，随着MoE架构、低比特量化和专家调度等技术逐步成熟，数百亿参数模型开始尝试进入移动终端，手机本地AI的能力边界正在进一步拓宽。

不过从模型跑通到真正进入普通消费级手机仍有一段距离。如何控制持续推理带来的功耗和发热，如何适配不同价位的芯片平台，以及更大的模型能否带来足够明显的体验提升，都需要进一步验证。

随着模型和芯片技术持续演进，手机端侧大模型有望承载更复杂的多模态理解和智能体任务，进一步减少对云端的依赖。谁能率先让数百亿参数模型从技术演示走向日常应用，或将成为下一轮端侧AI竞争的重要看点。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

25 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

标普500四年131%的累计涨幅令人瞩目，却难掩其内部深裂：84%的成分股已从高点回调超10%，42只AI概念股独揽67%涨幅，三巨头市值占比飙升至22%。高利率、债市动荡与极度集中的市场结构，令任何一次预期落空都几乎无缓冲余地。

本轮美股牛市，正站在一个微妙的十字路口。它经历了激进加息、银行业危机、地缘冲突与债券市场动荡，却依然屹立不倒，四年累计涨幅高达131%。然而，表面光鲜的指数之下，一个令人不安的结构性裂痕正在扩大——牛市的根基，正被越来越少的公司所支撑。

自2022年10月12日触底以来，标普500指数累计总回报达131%，折合年化约23.3%，约为市场历史均值的三倍。英伟达在此期间暴涨约1875%，Meta涨幅约488%。然而，据Ned Davis Research数据，**当前标普500指数市场宽度——即指数成分股中上涨股票占比——已跌至历史性低点，且此前每当市场宽度与指数走势出现背离，标普500往往在随后数月触顶。**

与此同时，债券市场的持续承压令风险资产前景蒙上阴影。美国国债收益率已升至24年高点。市场的核心矛盾已然清晰：AI盈利与投资仍构成增长支撑，但高利率、能源通胀风险与极度集中的市场结构，已令任何一次预期落空都难有缓冲余地。

AI浪潮主导牛市，但宽度创历史新低

这场牛市的最大驱动力，始终是市场对人工智能的狂热押注。然而这股热潮正在加速向少数公司集中。

据市场研究机构The Kobeissi Letter分析，自2024年初以来，**42只AI相关股票贡献了标普500指数约67%的价格回报——这42只股票为指数贡献了约22个百分点的涨幅，而其余458只成分股合计仅贡献了11个百分点。**

集中度的问题还在进一步恶化。苹果、微软与英伟达三家公司目前合计占标普500总市值约22%，较2022年底的约14%大幅攀升。与此同时，当前标普500中约84%的成分股较各自历史高点的跌幅超过10%，已处于技术意义上的回调区间——这一数据出现在指数本身仍处于历史高位之际，格外刺眼。

Nationwide首席市场策略师Mark Hackett将这种局面概括为"市场的核心张力"：**盈利与AI投资仍是增长股的强力支撑，但高长端利率、能源驱动的通胀风险以及极度收窄的市场宽度，已令市场几乎没有容错空间。**

牛市"年龄"并非风险根源

随着牛市步入第五年，部分投资者开始担忧其是否"老态龙钟"。但历史数据并不支持这一论断。

据Ned Davis Research统计，自1900年以来的38轮牛市中，有33轮的持续时间短于当前这轮。所有牛市的平均持续时间为25个月，中位数为22个月。这一数据乍看之下似乎令人警惕，但MarketWatch专栏作者Mark Hulbert援引研究指出，以"年龄"来预判牛市终结，是一种统计谬误——就如同因为黑夜跟随白昼而认为白昼导致了黑夜。

真正终结牛市的，**是经济衰退（1950年以来22次熊市中有13次伴随衰退）、投资者过度亢奋（如互联网泡沫），或外部冲击（如战争与疫情）。**CNBC主持人Jim Cramer则以投资者视角加

以印证："我们根本无法预测哪一次是真正的大跌，也无法预测反弹的时点。四年里我们有无数次可以出逃，但每一次都会让我们蒙受损失。"

涨幅131%，历史上并不罕见

这场牛市的涨幅是否已高处不胜寒？历史数据给出了相对乐观的答案。

据MarketWatch报道，圣塔克拉拉大学荣休教授Edward McQuarrie与EfficientFrontier.com创始人William Bernstein，对美国股市自18世纪末以来每个月的滚动四年总回报进行了统计，发现当前131%的四年累计涨幅并不构成历史异值——"这种情况经常发生……根本不算什么，远未到历史极端的程度，"两人写道。

即便将视野延伸至2009年3月全球金融危机低点，以17.5年为统计周期，美国股市的表现在历史上同样有过多次大幅超越当前水平的先例。这意味着，单凭涨幅本身来判断牛市即将终结，缺乏有力的历史依据。

利率与市场宽度：短期最关键的变量

当前市场的真正风险，或许不在于牛市的年龄与涨幅，而在于利率压力能否缓解，以及市场宽度能否得到修复。

摩根士丹利首席投资官Mike Wilson此前指出，**市场宽度的恶化与美联储鹰派基调密切相关——在联储鹰派立场的强化之后，利率预期上移，债券市场波动随之拉升美债收益率至24年高点，进一步压制了对权益资产的整体展望。他写道："如果债券波动率能够更快平息，市场宽度很可能追赶上指数价格，在近期推动两者共同走高。"**

汇丰多资产策略团队持有类似观点。据汇丰报告，若美国经济数据出现持续低于预期的信号，有望拖动整条美债收益率曲线下行，从而对各类资产的估值形成支撑，并有利于股市内部驱动力的扩散与再平衡。

汇丰策略师Max Kettner团队认为，在进入2027年后，若"金发女孩"组合得以实现，即增长稳健、通胀回落、利率下行，届时科技股与美股盈利或将重回强势，但届时的上涨仍可能是一轮集中度较高的结构性行情。

AI泡沫之争：分歧犹存，短期支撑仍在

市场另一个核心争论，是人工智能投资是否已步入泡沫阶段。

汇丰策略团队对此持明确的反驳立场。其报告指出，当前AI怀疑论的问题在于目光过于长远——以两至三年后的高度不确定性收入预测来否定当前价格走势，逻辑并不成立。

更重要的近期信号是：**超大规模云计算企业（hyperscalers）的自由现金流（FCF）下修速度已开始放缓，2027年FCF改善预期正在形成；半导体与存储器公司近期重新领涨；算力价格止跌回升，呈现出"杰文斯悖论"（Jevons' Paradox）的特征——即效率提升反而带动更大规模的需求扩张，对整个科技板块构成潜在正向催化。**

盈利面亦提供了支撑。据FactSet数据，当前已有创纪录数量的标普500成分公司对第三季度发布正面盈利指引。三星电子此前预告第三季度营业利润有望达到800亿美元，若实现，将创下科技企业史上最高单季利润纪录。

这在一定程度上解释了，为何在战争、利率高企与经济不确定性并存的环境下，指数仍能维持在历史高位——资金正在流向真正赚钱的地方。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

99 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

3 条评论

防御型投资者
2小时前 中国上海

只要美元是最大储备货币，美股就会一直涨下去。

0 回复

见闻用户
3小时前 中国上海

一点都不稳定，上窜上跳😠

1 回复

深蓝天蝎 2小时前 中国广东省

回复 **见闻用户：**

A股稳定，十年如一日

0 回复

摘要：

投资很贵，这份日历并不贵。让2027每一个重要日子，都有备而来。 限时预售 10.13-10.22 早鸟超值价99元。

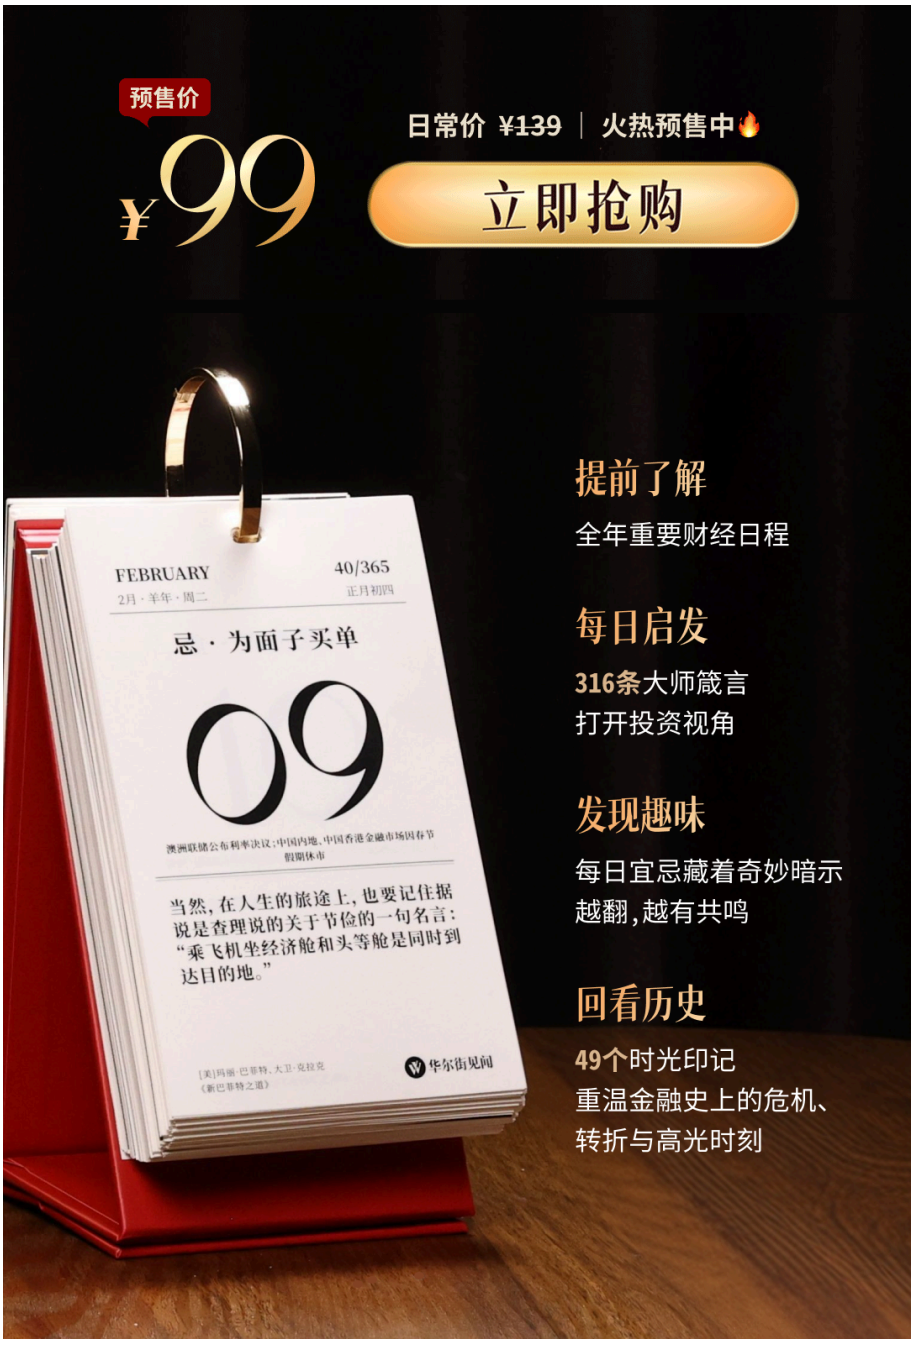
预售价
¥99
日常价 ¥139 | 火热预售中
立即抢购
FEBRUARY
2月 · 羊年 · 周二
40/365
正月初四
忌 · 为面子买单
09
澳洲联储公布利率决议；中国内地、中国香港金融市场因春节假期休市
当然，在人生的旅途上，也要记住据说是查理说的关于节俭的一句名言："乘飞机坐经济舱和头等舱是同时到达目的地。"
[美]玛丽·巴菲特、大卫·克拉克《新巴菲特之道》
华尔街见闻
提前了解
全年重要财经日程
每日启发
316条大师箴言
打开投资视角
发现趣味
每日宜忌藏着奇妙暗示
越翻，越有共鸣
回看历史
49个时光印记
重温金融史上的危机、转折与高光时刻

每年一个新主题

换个角度理解周期

2027月历页主题
A股的日历效应与历史回响

梳理每月日历效应
回看同月发生过的A股大事件

＊以上为部分页面展示
实物包含全年12个月历页

TODAY
每天翻开 | 值得关注的都在这里
每日宜忌
今天,有什么趣味提醒
重磅日程
今天,有哪些重要日程
大师箴言
今天,读一句值得思考的话
时光印记
今天,历史上发生过什么
JUNE
6月 · 羊年 · 周二
173 / 365
五月十八
忌·反复横跳
22
澳洲联储公布利率决议
每个人都有两个同时存在的自己:一个是富有
的
2025年1月20日，成立仅一年多的深度求索(DEEPSEEK)公司发布DEEPSEEK-R1大模型，以极低的成本实现了比肩顶级闭源模型的推理能力,引发AI研发领域巨震。这也被称为“DEEPSEEK时刻”
时光印记
华尔街见闻

不止一本日历
随日历附赠
3重知识权益
知识礼包详情及领取方式
请见实物日历内页说明
华尔街见闻 VIP
VIP会员
大师课
抵用金
¥129
Alpha
体验券
线上团门私享会
知识礼包
总价值超¥1000
12:53
知运势
看日程
听要闻
开启通知，最新财经日程早知道
2026年9月
农历八月十二
忌·犯蚤
星期二
22
今日暂无要事，喝杯咖啡休息下>
市场就像上帝一样，帮助那些自助的人；但和上帝不同之处在于，市场不会原谅那些不知道自己在干什么的人。
[美]沃伦·巴菲特，投资家、企业家及慈善家
转发
分享
购买
重磅订阅
企业定制
配套小程序
扫码进入 · 一键收藏
看日程|看数据|听要闻|看前瞻
7×24小时在线
让纸上的365天
连接实时变化的财经世界

全新包装·双开礼盒设计
打开，更有仪式感
华尔街见闻
见闻历创意组/编著
2026
见闻历
EVERY DAY
A STEP TO WEALTH
花城出版社
华尔街见闻
见闻历创意组/编著
2027
见闻历
EVERY DAY
A STEP TO WEALTH
花城出版社

06
TRADER
MODE

投资，
不打无准备之战

09

一份放在对方桌上
365天的心意

新年礼赠 | 客户答谢
亲友相赠 | 企业年礼

2027见闻历 品质升级

01 内页纸张升级
触感细腻 | 翻阅舒适

02 高质感金属环
做工精致 | 翻页顺畅

03
磁吸双开礼盒
开合顺滑 | 阻尼适中

设计参数

见闻历尺寸	100*170*40mm	页数	378
外包装尺寸	220*115*75mm	外盒样式	双开礼盒
材质	触感纸、双胶纸等	工艺	烫金等

⚠ 手工测量，可能存在误差

包装清单

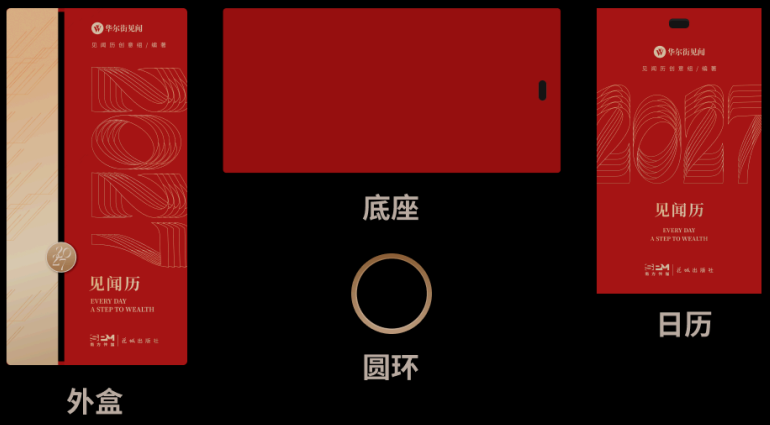

预售价
¥99
日常价 ¥139 | 火热预售中
立即抢购

2027

见闻历

WALLSTREETCN

企业定制

为企业提供1V1礼品设计服务

打造一款年度硬核好礼

见闻历 | 联名定制

起订数量：100

外盒腰封

可定制企业logo
（以联名方式）

日历底座

可定制企业logo
（以联名方式）

见闻历 | 轻度定制

起订数量：100

外盒

可定制企业logo

日历封面

可定制企业logo

日历扉页

可定制企业logo

企业slogan或者CEO语录
（字数限制100~200字左右）
企业二维码

见闻历 | 深度定制

起订数量：1000

外盒

可定制企业logo

日历封面

可定制企业logo

日历扉页

可定制企业logo
企业slogan或者CEO语录
（字数限制100~200字左右）
企业二维码

日历内页

名人名言或月历页内容可替换

内页替换数量：
60页内（需企业提供）

定制详细扫码咨询
需提前三周下单 | 不接急单
保存或转发图片打开扫码

支 持 小 批 量 定 制

外盒 | 封面 | 扉页 | 底座

企业年礼 | 客户礼赠 | 员工福利

合作联系：shijianliu@wallstreetcn.com

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

47 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

7 条评论

见闻用户
34分钟前

救命，怎么感觉一年又要过完了

0 回复

吃肉冠军
36分钟前

有人买过前几年的嘛，质量咋样

0 回复

抹茶牛奶 30分钟前 中国上海

回复 **吃肉冠军**:

我每年都买，质量不错👍

0 回复

见闻用户
37分钟前

99块钱一本吗？看着还挺精致的

0 回复

HQ
38分钟前

居然已经做到第9年了，厉害啊！

0 回复

小幸运
1小时前

每年都买，继续支持

0 回复

摘要：

IMF警告，发达经济体财政赤字将创疫情后新高，其中美国财政压力尤为突出，2026年一般政府净借款规模预计将达到GDP的8.5%。高债务与高利率叠加，AI投资带来的融资需求进一步加剧财政压力。IMF还预计，全球公共债务将在本十年末前逼近全球GDP的100%，各国亟须重建财政空间。

全球经济虽仍保持韧性，但支撑这一韧性的财政基础正持续削弱。

10月13日，IMF在最新发布的《世界经济展望》中表示，**发达经济体今年净借款规模将达到国内生产总值（GDP）的5.2%，创2021年以来新高，彼时全球经济仍处于新冠疫情冲击之中。**IMF预计，美国2026年一般政府净借款规模将达到GDP的8.5%，较2025年的7.1%进一步上升，凸显美国财政压力持续加大。

这一预测较IMF今年4月的判断进一步恶化，而全球债券市场正经历数月动荡。**公共债务持续攀升、通胀压力尚未消退，加上AI基础设施投资带来的融资需求，正共同推高借款成本，增加政府利息支出和债务再融资压力。**

尽管IMF将今年全球经济增长预测小幅上调至3.1%，但警告增长动能正日益集中于少数经济体。在经济增长尚有韧性、财政风险却不断累积的背景下，高债务与高利率的组合正成为影响主权债市场、风险资产及全球金融条件的重要变量。

发达经济体赤字创疫情后新高，美国财政压力突出

IMF预计，发达经济体今年净借款占GDP的比重将升至5.2%，达到疫情阶段以来的最高水平，显示主要发达经济体的财政状况进一步恶化。

美国的财政压力尤为突出。按照IMF涵盖联邦、州及地方政府借款的广义口径，美国一般政府净借款今年预计将达到GDP的8.5%，高于2025年的7.1%，也显著超过疫情爆发前的5.8%。

这一预测高于美国国内部分机构对联邦财政赤字的估算。美国国会预算办公室今年2月预计，2026财年美国联邦财政赤字将占GDP的5.8%；美国财政政策智库“负责任联邦预算委员会”（Committee for a Responsible Federal Budget，CRFB）的估算则为6.2%。

这些数据并非完全可比。IMF采用的一般政府口径涵盖联邦、州及地方政府，而美国国内机构的上述预测主要针对联邦财政赤字。**尽管统计范围不同，IMF的预测仍表明，评估美国财政风险不能只关注联邦预算，还需考虑更广泛的政府部门融资需求。**

高利率叠加高债务，再融资风险上升

财政赤字扩大的同时，政府融资成本持续承压。高能源价格和经济增长韧性增加了通胀压力，也令主要经济体的降息前景面临挑战。随着国债收益率处于较高水平，政府不仅需要为新增赤字融资，还要承担存量债务到期后再融资的更高成本。

IMF指出，主要发达经济体长期国债收益率上升，使高公共债务和大规模再融资需求成为更突出的脆弱环节。一旦金融条件突然收紧，财政状况较弱的主权借款人将更容易受到冲击。

9月债券市场抛售进一步推高政府融资成本，也增加了预算调整的难度。IMF警告，如果通胀再度抬头，或市场对财政可持续性的担忧加深，主权债收益率可能迅速上升。由于国债是金融体系的重要定价基准和抵押品，这类冲击还可能向其他资产市场传导，引发更广泛的金融动荡。

财政压力也可能波及货币政策。随着政府利息支出增加、选举压力上升，部分国家的央行可能面临更大的政治压力，被要求支持政府融资，或容忍通胀高于目标。这将进一步考验央行的政策独立性，以及市场对通胀长期走势的判断。

全球公共债务逼近GDP，财政修复刻不容缓

IMF预计，全球公共债务占GDP的比重将在未来数十年持续上升，并最终逼近100%。在债务存量高企、融资成本上升的背景下，各国重建财政空间的紧迫性进一步增强。

财政风险还可能受到地缘政治和极端事件的放大。IMF指出，持续的战争、网络攻击和极端天气事件可能加剧能源供给冲击，恶化政府财政收支。这些冲击既可能增加公共支出，也可能通过推高通胀、拖累经济增长和加剧市场避险情绪，进一步收紧融资条件。

IMF在最新报告中还列出三项值得关注的风险：AI相关资产价格调整、网络攻击引发的系统性威胁，以及通胀或财政担忧导致的金融条件急剧收紧。

这些风险并非孤立存在。若AI相关资产价格下跌引发市场风险偏好下降，或通胀反弹迫使利率维持高位，政府融资成本可能进一步上升；而财政状况恶化又可能加剧投资者对主权债的担忧，形成相互强化的风险链条。

AI支撑全球增长，但增长动能日益集中

尽管财政风险上升，IMF仍认为全球经济今年将保持相对韧性，并将全球GDP增速预测上调0.1个百分点至3.1%，预计2027年增长3.4%。

AI投资热潮是支撑经济增长的重要因素之一，但其带来的增长红利并未均匀分布于全球。**IMF指出，全球经济增长正日益集中于少数经济体，其他国家则面临增长动能减弱的压力。**

IMF数据显示，今年4月时，54个经济体贡献了全球95%的经济增长；此后，随着更多经济体的增长预期被下调，贡献同等比例增长的经济体数量已降至32个。

这意味着，全球经济整体增速保持稳定，并不代表各国增长表现同步改善。战争引发的供给冲击，以及AI相关投资和需求在不同经济体之间的分布差异，正使全球增长进一步分化。

在这一背景下，财政风险成为全球经济韧性背后的重要隐忧。若主要经济体无法及时稳定债务轨迹、恢复财政缓冲能力，一旦增长放缓、通胀反弹或金融市场遭遇冲击，原本有限的财政空间将使政府更难应对危机，全球金融市场也可能面临更大的波动。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

45 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论