摘要：

大摩揭示，Muse基准情景下每用户月服务成本高达37美元，年成本445美元，已超过Meta全球用户平均年收入70美元。更致命的是，真正变现最早要等到2027至2028年。与此同时，亚马逊、Costco、Netflix相继封锁Muse访问，当前日活用户仅约270万，远不及“10亿用户”的估值预期。11月4日三季报将是第一道硬考验。

Meta于9月8日正式推出AI智能体Muse，随即引爆市场热情——**Meta股价在12个交易日内飙升27%，峰值触及777.59美元，远期市盈率从8月底的14倍跳升至21倍**。然而，仅仅一个月后，增长裂缝已然显现。

另类数据机构TickerTrends的数据显示，**Muse日均净新增用户已从9月高峰期的约19.8万人骤降至约7.4万人，降幅高达62.4%**，下载量也较峰值回落逾21%。

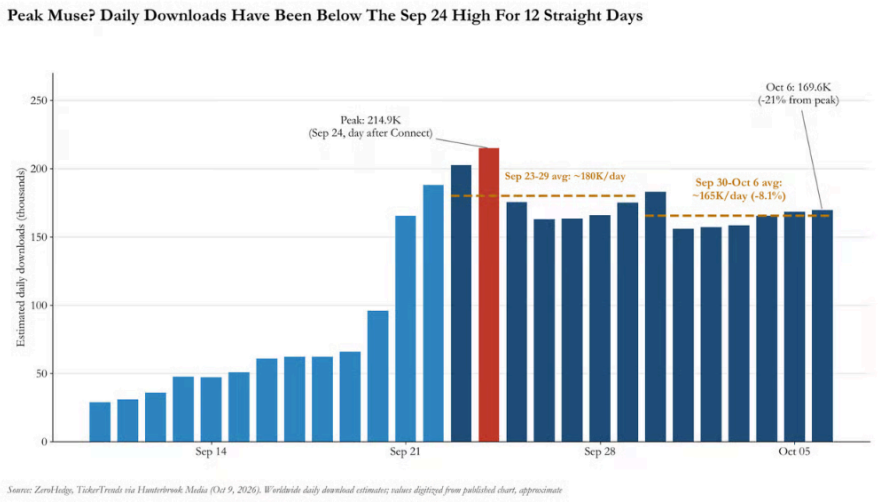

与此同时，摩根士丹利发布了迄今最详尽的Muse成本模型，揭示出一个令人警醒的数字：**Muse每用户每月服务成本在3美元至130美元之间，基准情景下为37美元，折合年成本445美元——已超过Meta全球平均每用户年收入约70美元**。更关键的是，摩根士丹利明确指出，Muse的真正商业化变现最早要等到**2027年至2028年底**。

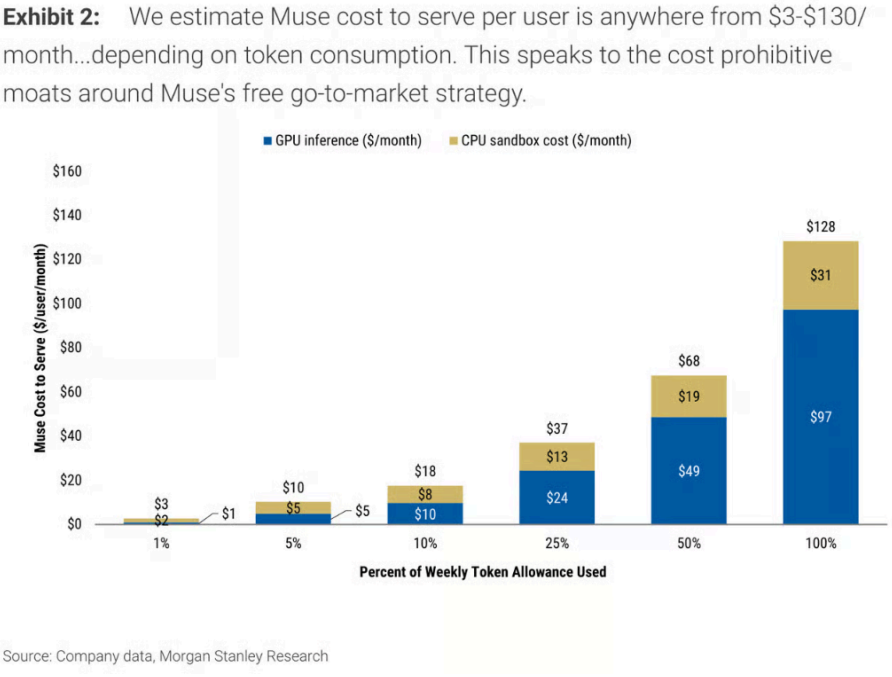

大摩报告还指出，**Meta目前的估值扩张完全建立在“10亿（1 billion）用户规模”的完美增长故事之上，但现实中其日活用户（DAU）目前仅不到300万。** 此外，Muse正面临亚马逊等平台的生态封杀，而依赖“消费者惯性”的传统订阅商业模式正面临被AI智能体颠覆的连带做空风险。相比之下，拥有封闭生态和支付基础设施的中国科技巨头（如腾讯），或许在AI智能体赛道上拥有比Meta更坚固的护城河。

增长神话的第一道裂缝：用户增速骤降62%

Muse的用户数据由另类数据机构TickerTrends追踪，经Hunterbrook Media分析后披露。核心数据如下：

- **下载量**：10月6日约为16.96万次，较9月24日Connect发布会次日的峰值21.49万次下滑21.1%，且已连续12天低于峰值。前一周日均约18万次，最新一周降至约16.5万次，**周环比下降8.1%**。

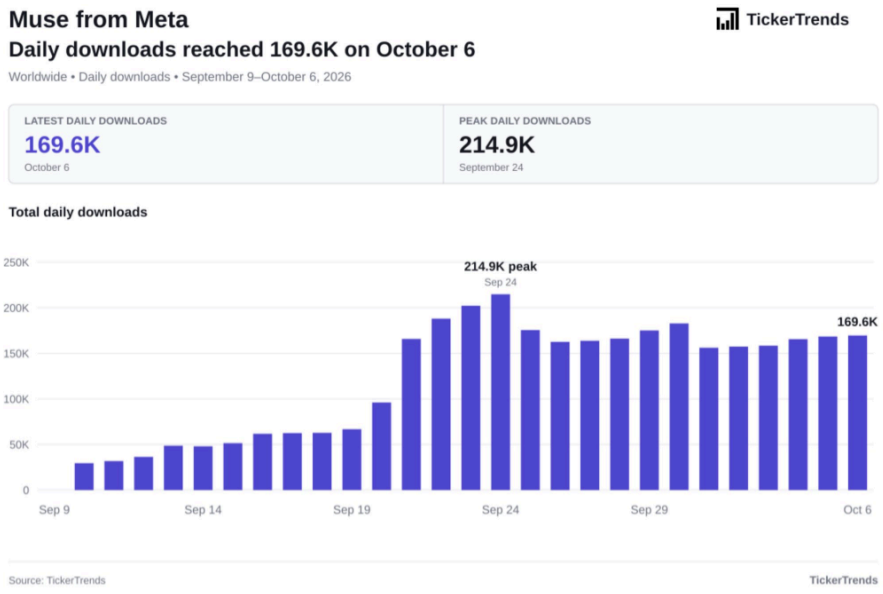

- **用户规模**：10月6日DAU（日活跃用户）达到新高273.09万，用户总量仍在增长，但**增速大幅放缓**。9月15日至22日期间，日均净新增约19.8万人；随后一周降至约8.7万人；截至10月6日当周进一步降至约7.4万人，**较初始爆发期下降62.4%，较前一周下降14.5%**。

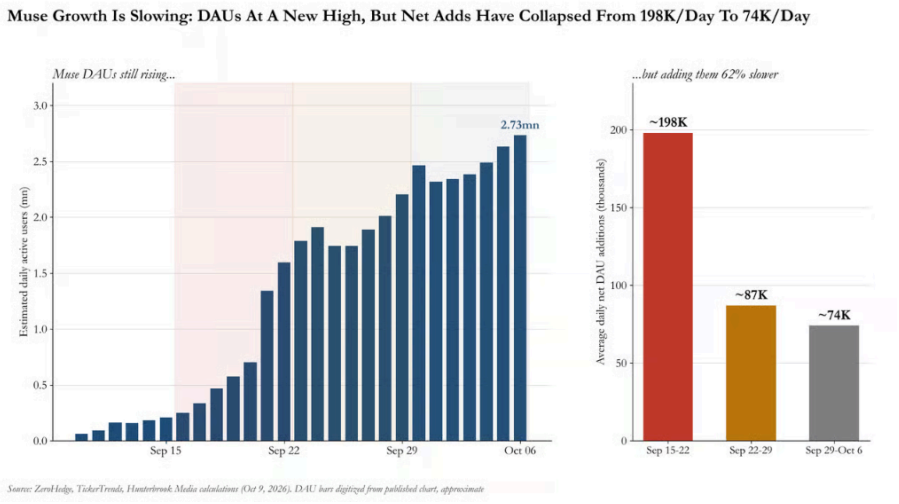

- **参与度代理指标**：截至10月7日的一周内，应用评论量周环比下降11.6%至4716条，其中iOS评论量下降22.5%；10月7日单日评论量664条，较10月1日峰值802条下降17.2%。

值得注意的是，不同数据来源对Muse用户规模的估算存在显著分歧：TickerTrends为273万DAU，Similarweb为218万，Sensor Tower则显示累计下载量660万、DAU约180万。**三家机构的DAU估算最高与最低相差约50%，但无一超过300万**。

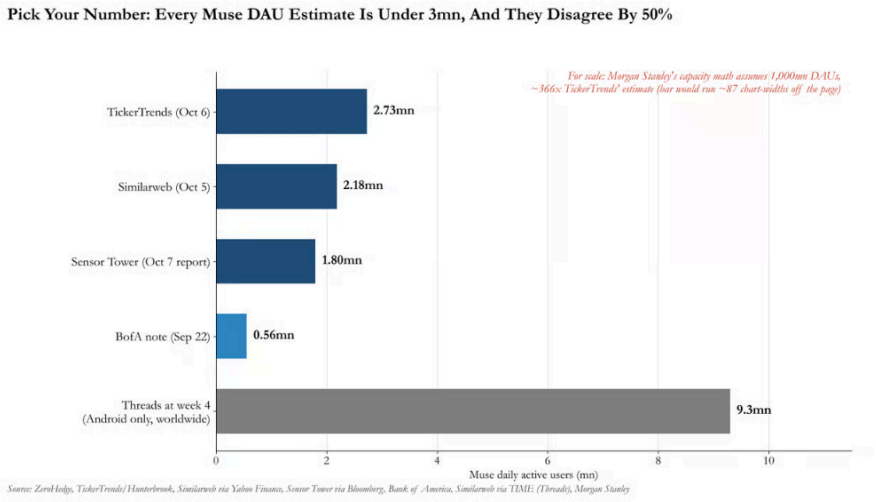

相比之下，摩根士丹利的容量分析是基于**10亿日活用户**构建的——这意味着按TickerTrends的数据，Meta已购置的CPU容量约为当前实际用户数的**366倍**。

Muse的成长背景与遭遇的现实阻力

产品架构：Muse运行于Muse Spark模型之上，为每位用户提供专属的“Muse安全虚拟机”，支持独立App、网页端、WhatsApp内嵌及Mac原生客户端。定价分三档：免费版（每周1亿token额度）、**每月20美元的Power版**（每周5亿token）、**每月100美元的Maximum版**（每周30亿token）。

里程碑数据：在iOS端，Muse上线首12天累计下载量达143万次，超过ChatGPT同期的137万次（JPMorgan数据），并登顶App Store和Google Play双榜首。

接踵而至的阻力：

- 9月20日晚，亚马逊封锁Muse访问其平台，理由是Muse未明确标识自身为AI智能体，且未经适当披露即存储用户凭证；
- TickerTrends追踪到Costco和Netflix也出现类似限制的用户报告；
- 电信运营商开始将Muse发起的AI客服电话转离人工坐席，削弱了"代为拨打电话"功能；
- 一个可能导致本地应用劫持用户Muse账户的零日漏洞被紧急修复；
- Hunterbrook此前报告称Muse可被诱导对弱势群体成员建立档案；
- Meta承认Muse的工作区文件结构遵循了OpenClaw的设计蓝图，但声称代码系从头编写。

Muse何时能变现？答案：短期内不会

摩根士丹利分析师Brian Nowak在报告中直言不讳：**“我们预计Muse订阅收入在相当长一段时间内将非常有限，因为Meta目前专注于扩大用户基础、提升参与度和商业行为，而非变现。目前连接协议的初始'抽成比例'微乎其微。”**

长期来看，Nowak认为Meta将构建一个类似广告竞价的**实时竞价拍卖市场**——企业为智能体完成的交易付费。这一模式所针对的消费者支出池约为**30万亿美元**，其中零售和旅行约占17万亿美元。但时间节点明确：**最早要到2027年底至2028年**。

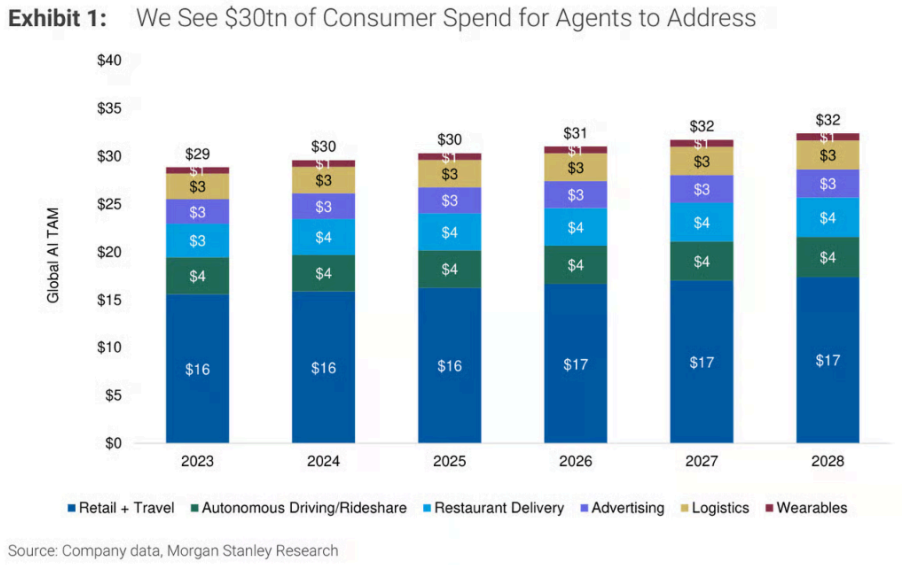

美银美林认为广告、订阅或佣金的实质性收入**不太可能在2028年前出现**；高盛将“变现能否迅速跟进”列为关键问题，并将隐私和安全风险列为最大单一风险。

增速放缓的影响：竞价拍卖市场需要庞大且活跃的用户基础才能吸引企业真金白银竞价。每周净新增用户维持在7.4万而非19.8万的水平，都将把"2027年底至2028年"这一时间节点进一步推后。

Muse的服务成本有多高？每用户每月3至130美元

这是摩根士丹利报告中最具价值的部分。**Muse的计算成本分为两块：**

- **GPU推理成本**：随token消耗量线性扩展（模型处理用户请求的算力）；
- **CPU沙箱成本**：随用户激活Muse的频率及虚拟机运行时长扩展（浏览器、工具和代码执行环境）。

关键假设：GPU侧，摩根士丹利使用GB300框架，每吉瓦410,256块GPU，75%利用率下每GPU每秒处理3500个token，折合每年每吉瓦处理33,962万亿token，年基础设施成本76.3亿美元，**推理成本约为每百万token 0.225美元**。

CPU侧，假设每次激活约10分钟的沙箱运行时间，采用2核vCPU/8GB内存的虚拟机，按AWS AMD实例按需定价（0.1217美元/小时），加7.5GB存储（0.60美元/月）。

Exhibit 9: Muse Cost to Serve Model

Demand: free allowance x share consumed						
Weekly allowance (mn tokens)	100	100	100	100	100	100
(X) Allowance consumed (%)	1%	5%	10%	25%	50%	100%
(X) Weeks In Year	52	52	52	52	52	52
(/) Months In Year	12	12	12	12	12	12
(=) Monthly tokens consumed (mn)	**4**	**22**	**43**	**108**	**217**	**433**
GPU inference						
GB300 GPUs per 1GW (#)	410,256	410,256	410,256	410,256	410,256	410,256
(X) Benchmark tokens / second / GPU	3,500	3,500	3,500	3,500	3,500	3,500
(X) GPU fleet utilization	75%	75%	75%	75%	75%	75%
(=) 1GW token output (tn tokens/year)	33,962	33,962	33,962	33,962	33,962	33,962
IT capex per 1GW ($bn)	$22.8	$22.8	$22.8	$22.8	$22.8	$22.8
(/) IT useful life (years)	5	5	5	5	5	5
Non-IT capex per 1GW ($bn)	$16.2	$16.2	$16.2	$16.2	$16.2	$16.2
(/) Non-IT useful life (years)	15	15	15	15	15	15
(=) IT depreciation per GW per year ($bn)	$4.55	$4.55	$4.55	$4.55	$4.55	$4.55
(=) Non-IT depreciation per GW per year ($bn)	$1.08	$1.08	$1.08	$1.08	$1.08	$1.08
(+) Energy + other opex per GW per year ($bn)	$2	$2	$2	$2	$2	$2
(=) Infrastructure cost per GW per year ($bn)	**$7.63**	**$7.63**	**$7.63**	**$7.63**	**$7.63**	**$7.63**
Monthly tokens consumed (mn)	4	22	43	108	217	433
(X) GPU serving cost ($/mn tokens)	$0.225	$0.225	$0.225	$0.225	$0.225	$0.225
(=) GPU inference cost ($/user/month)	**$0.97**	**$4.87**	**$9.74**	**$24.35**	**$48.69**	**$97.38**
CPU sandbox – usage and vCPU capacity						
Sessions / day	2	8	12	20	30	50
(X) Active days / month	30	30	30	30	30	30
(=) Sessions / month	60	240	360	600	900	1500
(X) Active sandbox minutes / session	10.0	10.0	10.0	10.0	10.0	10.0
(=) VM hours / user / month	**10.0**	**40.0**	**60.0**	**100.0**	**150.0**	**250.0**
Implied hours per active day	*0.3*	*1.3*	*2.0*	*3.3*	*5.0*	*8.3*
Implied tokens / session	*72,222*	*90,278*	*120,370*	*180,556*	*240,741*	*288,889*
VM hours / user / month	10.0	40.0	60.0	100.0	150.0	250.0
(X) AWS Pricing on AMD Instances ($/hour)	$0.1217	$0.1217	$0.1217	$0.1217	$0.1217	$0.1217
(=) VM compute at AWS list price ($/month)	$1.22	$4.87	$7.30	$12.17	$18.26	$30.43
(+) Provisioned storage (GB)	7.5	7.5	7.5	7.5	7.5	7.5
(X) Storage at AWS list price ($/month)	$0.60	$0.60	$0.60	$0.60	$0.60	$0.60
(=) CPU sandbox at AWS list price ($/month)	**$1.82**	**$5.47**	**$7.90**	**$12.77**	**$18.86**	**$31.03**
Total cost to serve per user						
(+) GPU inference ($/month)	$0.97	$4.87	$9.74	$24.35	$48.69	$97.38
(+) CPU sandbox at cost ($/month)	$1.82	$5.47	$7.90	$12.77	$18.86	$31.03
(=) Total Cost to Serve ($/user/month)	**$2.79**	**$10.34**	**$17.64**	**$37.12**	**$67.55**	**$128.41**
Total cost to serve ($/user/year)	$33	$124	$212	$445	$811	$1,541

Source: Company data, Morgan Stanley Research

基准情景（25%额度使用率）：用户每月消耗约1.08亿token（每天20次会话），**月服务成本37.12美元，年成本445美元**。Nowak将此视为"更接近上限"，因为该模型假设Meta以AWS标价租用全部CPU沙箱，实际不会如此。

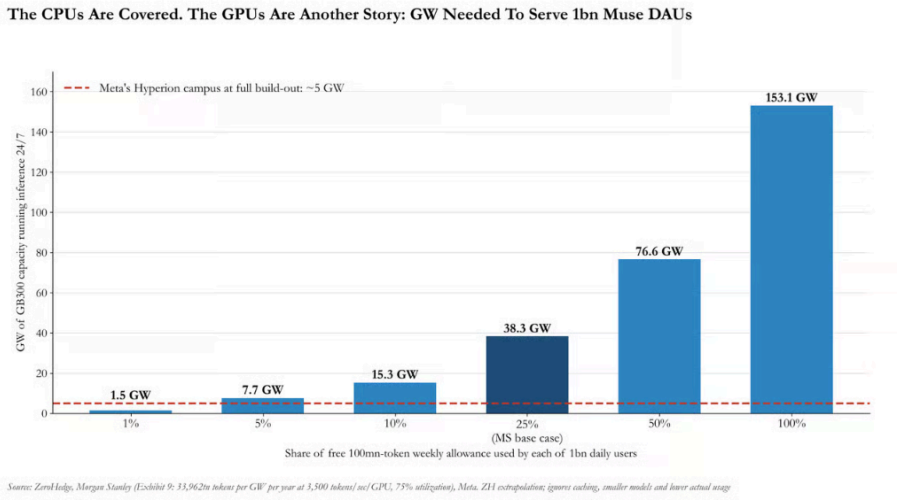

与ARPU的对比：摩根士丹利估算Meta全球平均每用户年收入（ARPU）约为**70美元**。即便用户仅使用5%的免费额度，年服务成本约124美元，**已超过Meta平均用户创造的年收入**。

极端情景测算（本文作者基于摩根士丹利GPU成本的推算，仅含GPU推理，不含CPU沙箱）：

- Power版（每月20美元）满额使用：月推理成本约**488美元**；

- Maximum版（每月100美元）满额使用：月推理成本约**2925美元**。

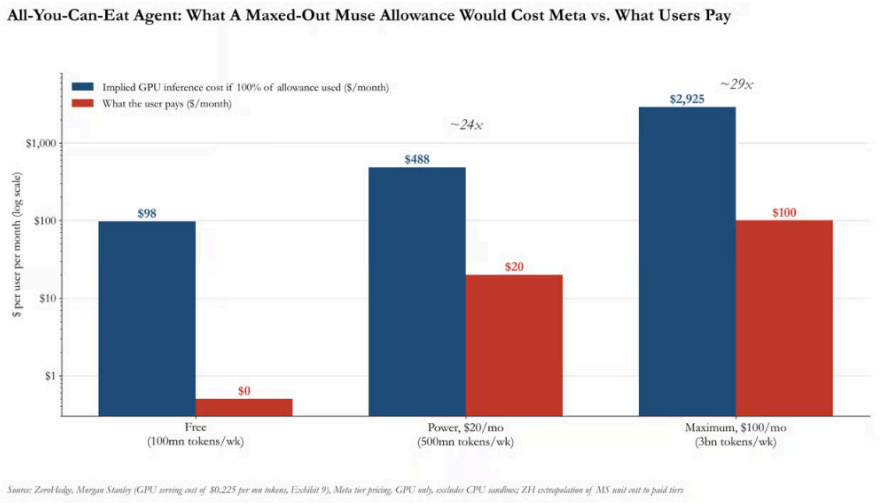

规模效应的两面性：若按10亿DAU、25%使用率计算，年服务成本约为**4450亿美元**，而摩根士丹利对Meta 2026年全年收入的预测仅为**2560亿美元**。但按当前273万DAU计算，同样的成本模型折合年成本约**12亿美元**，相对于摩根士丹利模型中2027年2090亿美元的运营支出预测，不过是个零头。

摩根士丹利的结论是：**高昂的成本本身就是护城河**——“这一分析表明，对于规模较小的竞争者而言，扩展至与Meta竞争的产品存在难以逾越的成本壁垒”，而Meta每年增长27%、规模达2500亿美元的核心广告业务为其提供了独特的财务支撑。

Meta会面临算力瓶颈吗？CPU端：不会

摩根士丹利的答案明确：**“不会。我们估计Meta仅在2026年采购的CPU容量，就足以服务10亿日活用户（按25%额度使用率计算）。”**

Exhibit 3: We estimate that the CPU capacity META is acquiring in '26 alone could be enough to serve 1bn Muse DAUs spending 25% of their weekly token allowance.

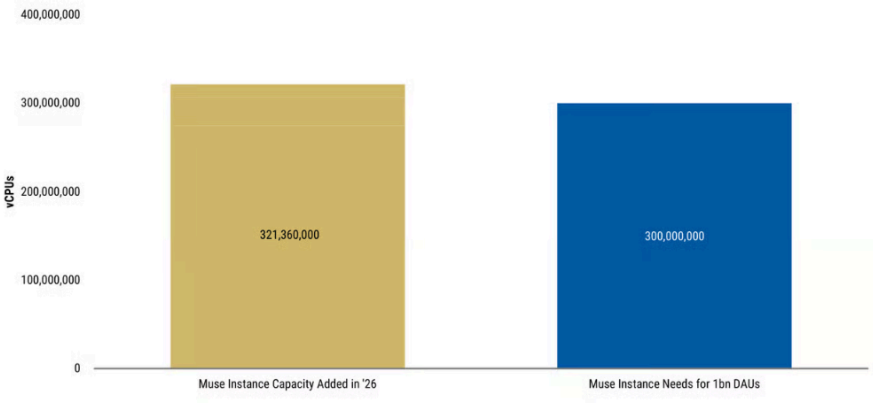

Source: Company data, Morgan Stanley Research. Note: In '26, we estimate META is adding sufficient CPU capacity to service ~320mn Muse Instances. These CPUs are being procured from a variety of vendors including AMD, NVDA and AWS Graviton. We estimate META would need ~300mn simultaneously active Muse instances to support 1bn DAUs. Key underlying assumptions include 1) Muse agents are active 3 out of 24 hours each day 2) Peak capacity usage of about 2x average usage and 3) An additional 20% instance buffer above requirements for peak utilization. For more detail, please see Exhibit 10 in the "Exhibits and Models" section below.

供应链测算：摩根士丹利估算Meta采购AMD 2026年服务器CPU出货量的20%，即约218万颗芯片（每颗126核、2线程），合5.49亿vCPU；加上约36万颗NVIDIA Vera CPU（88核、2线程），

合6300万vCPU；再加上AWS Graviton5协议的3000万核心。**合计6.43亿vCPU，即3.21亿个Muse实例**（每实例2个vCPU）。

需求侧测算：10亿DAU × 12.5%同时在线率（24小时中3小时活跃）× 2倍峰值系数 × 1.2倍冗余 = 3亿个同时运行实例，约占2026年采购量的93%。

Exhibit 10: We Estimate META Will Build/Rent Capacity for ~600mn vCPUs in '26, Enough to Serve ~1bn DAUs

Meta Muse vCPU Capacity Analysis		
Meta vCPU Capacity from '26 AMD Purchases:		**Assumptions:**
'26 AMD Chip Unit Sales	10,900,000	MS estimates
(X) META mix	20%	MS estimates
(=) META AMD Chip Unit Purchases	2,180,000	
(X) Cores/CPU	126	AMD company/CPU Benchmark data
(X) Threads/Core	2	AMD company data
(=) vCPU Capacity from AMD	**549,360,000**	
Meta vCPU Capacity from '26 NVDA Vera CPU Purchases:		
MS Asia Hardware/Semis Rack Estimates	93,000	
(X) CPUs/Rack	36	
(=) Vera CPUs in Racks	3,348,000	
MS Asia Hardware/Semis CoWoS Vera Estimates	5,750,000	
Remaining non-rack Vera CPUs	2,402,000	
(X) META mix of remaining CPUs	15%	
(=) '26 META Implied Unit Purchases	360,000	MS Asia estimates
(X) Cores/CPU	88	NVDA company data
(X) Threads/Core	2	NVDA company data
(=) vCPU Capacity from NVDA	**63,360,000**	
Meta vCPU Capacity from '26 AWS Graviton5 Deal:		
Implied Chips	156,250	
Cores/Chip	192	AWS company data
Graviton5 Cores	30,000,000	MS est. of "tens of millions"
(X) Threads/Core	1	AWS company data
(=) vCPU Capacity from AWS	**30,000,000**	
Capacity to Instance/User Math		
Est. META Theoretical CPU Capacity (vCPU-equivalent)	**642,720,000**	
(/) Observed vCPUs per Muse instance	2	META company data
(=) Muse instance capacity	**321,360,000**	
Could Meta Serve 1bn Muse DAUs?		
DAUs	1,000,000,000	
(x) % agent active hours/day	12.5%	3 out of 24 hours/day
(x) Peak Multiplier	2.0x	Ms est. of peak capacity vs. average
(x) Headroom	1.2	MS est. capacity buffer
(=) Simultaneously Active Instance Capacity	**300,000,000**	
% of '26 vCPU capacity purchases	*93%*	

Source: Company data, Morgan Stanley Research Estimates. Note: Estimates for META's Vera CPU capacity bridges to supply chain estimates from our MS Asia Hardware and Semis Research teams.

现实对比：按当前273万DAU计算，Muse仅需约80万个同时运行实例，约占摩根士丹利估算Meta采购量的**0.25%**。按每天净新增7.4万用户的速度，达到10亿DAU需要约**37年**。

关于Graviton协议：Meta与AWS于4月24日宣布"数十亿美元级别"的Graviton5协议，涉及"数千万"核心。摩根士丹利估算为3000万核心，按约0.02美元/核心/小时计算，折合AWS年化收入约**56亿美元**，约贡献AWS 2027年增速3个百分点。**Meta是AWS的数十亿美元级大客户，而亚马逊同时封锁了Meta的智能体——两件事同时为真。**

Exhibit 4: We estimate 30mn Graviton cores (30mn units of vCPU capacity) would cost Meta ~$6bn on a fully annualized basis

AWS x META Graviton Deal Sizing			
Graviton Instance Price/Hour	$4	$4	$4
(/) Cores/Chip	192	192	192
(X) Price/Core/Hour	$0.02	$0.02	$0.02
(X) Graviton Cores (mn)	10	20	30
(X) Hours in Year	8,760	8,760	8,760
(X) Utilization	100%	100%	100%
(=) ARR ($mn)	**$1,860**	**$3,721**	**$5,581**
ppts of '27 AWS Growth	*1%*	*2%*	*3%*

Source: Company data, Morgan Stanley Research

GPU端的隐忧（摩根士丹利未直接测算）：按摩根士丹利自身的GPU假设，服务10亿DAU（25%使用率）需要约**38吉瓦**的GB300推理算力全天候运行。Meta旗舰级Hyperion园区设计容量约为5吉瓦。**即便按5%使用率计算，也需约7.7吉瓦。**GPU瓶颈只有在Muse真正实现多头预期的规模时才会显现，届时电力和GPU将先于CPU成为制约因素。

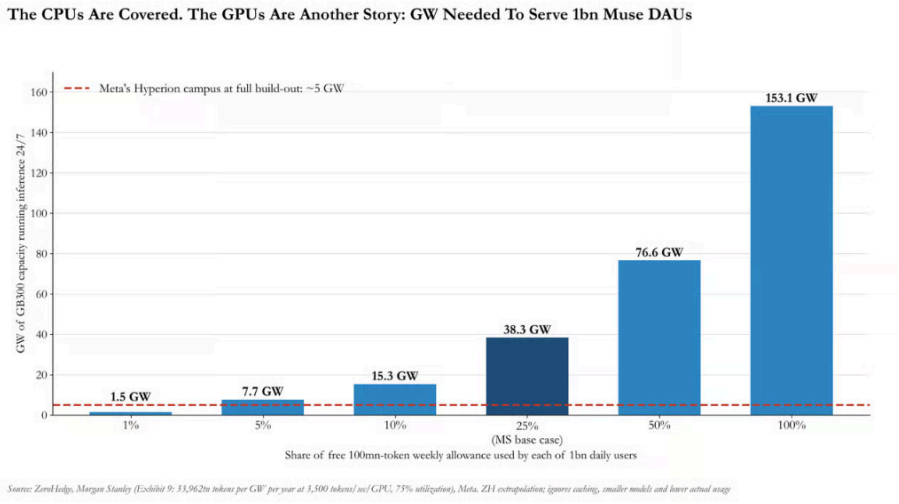

企业市场机遇——55万亿美元的TAM

摩根士丹利在30万亿美元消费者TAM之外，再叠加**25万亿美元的全球知识工作TAM**，合计55万亿美元，约为全球GDP的一半。

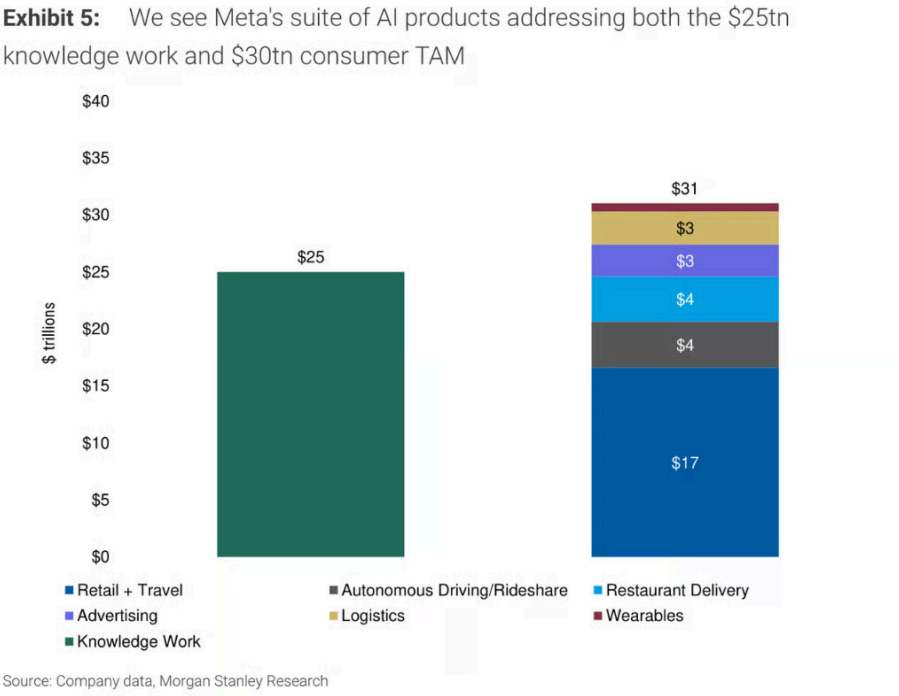

Meta的企业端布局包括：

> Muse for Small Business、WhatsApp/Messenger智能体工具、企业推进（Meta近期招募了企业业务负责人）、Muse Coding，以及基于“Watermelon等模型”的模型API。

架构层面的深层逻辑：摩根士丹利指出，Muse当前通过浏览器点击网页、拨打人工客服电话的方式“不是高质量、一致且可重复扩展的体验”。**亚马逊、Costco、Netflix的封锁以及运营商的拦截，正是这一问题的现实体现。**真正的解决方案是**企业开放MCP/工具接口供智能体直接调用，而Meta希望出售这套“管道”。**

Meta One订阅包（9月17日全球上线）：消费者版每月2.99至19.99美元，创作者和企业版每月14.99至499美元。摩根士丹利敏感性分析显示：**5000万订阅用户、每月20美元，可为2028年每股收益增厚9.1%（约3.17美元）；8000万用户、每月25美元，可增厚18.1%（约6.34美元）。**

Exhibit 6: With 100mn businesses on the platform, META's subscription opportunity can scale quickly and is highly accretive to EPS

META % Upside to '28 EPS from Subscription Revenue

Subscriber Monthly ARPU	Subscribers (mn) 40	50	60	70	80
$5	1.8%	2.3%	2.7%	3.2%	3.6%
$10	3.6%	4.5%	5.4%	6.3%	7.2%
$15	5.4%	6.8%	8.2%	9.5%	10.9%
$20	7.2%	9.1%	10.9%	12.7%	14.5%
$25	9.1%	11.3%	13.6%	15.9%	18.1%

META $ Upside to '28 EPS from Subscription Revenue

Subscriber Monthly ARPU	Subscribers (mn) 40	50	60	70	80
$5	$0.63	$0.79	$0.95	$1.11	$1.27
$10	$1.27	$1.59	$1.90	$2.22	$2.54
$15	$1.90	$2.38	$2.85	$3.33	$3.81
$20	$2.54	$3.17	$3.81	$4.44	$5.07
$25	$3.17	$3.96	$4.76	$5.55	$6.34

Source: Company data, Morgan Stanley Research

API业务：100兆瓦GB300算力专用于出售Meta模型，可为2028年每股收益增厚约4%（约1美元）。、

Exhibit 7: We estimate 100 MW of dedicated API capacity for META's AI models could add 4% upside or ~$1 to '28 EPS

META API Revenue Based on GB300	
Capacity Deployed Towards API (MW)	100
(/) KW Per Rack	135
(=) Racks Deployed Towards API	5
(X) GPUs Per Rack	72
(=) GPUs Deployed Towards API	347
(X) Tokens/Second/GPU	2,750
(X) Seconds per Year	31,536,000
(X) GPU Utilization	75%
(=) Tokens per Year (tn)	**23**
(X) Blended Token Pricing	$1.58
(=) API Revenue ($mn)	**$36**
% Upside to '28 Revenue	*0%*
API Revenue	**$36**
(X) Gross Margin	75%
(=) Gross Profit	$7,140
(X) GP Flow Through	100%
(=) Incremental EBIT	$7,140
(X) Marginal Tax Rate	21%
(=) Net Income	$5,641
(/) Shares Outstanding	2,631
(=) EPS Upside	**$1.24**
% Upside to '28 EPS	*4%*

Source: Company data, Morgan Stanley Research

附带损伤：Needham分析师Laura Martin于10月1日估算，若20%的App Store销售额迁移至Muse Connectors，苹果每年可能损失高达**100亿美元**的服务收入（约75亿美元EBITDA）。Muse Connectors开放后168小时内，Meta收到超过**1500份**开发者申请。

亚马逊与Meta——相爱相杀的利益共同体

亚马逊封锁Muse的官方理由是：代表客户购物的第三方应用"应公开运营并尊重服务提供商的决定"，并指控Muse未标识AI身份、未经适当披露存储用户凭证。

摩根士丹利将此解读为一场谈判：**“亚马逊占美国电商市场约40%的份额，希望确保在横向智能体崛起的背景下，这一地位得以维持。”**谈判焦点涉及商家记录权、购物体验控制权（Prime权益、零售媒体、商品展示、追加销售机会等）以及向Muse智能体的数据回传。

Nowak指出此次谈判的独特性：

> **“1）这很可能是与亚马逊达成的首个智能体合作协议，将为后续协议设立潜在先例；2）Meta需要亚马逊的物流和配送能力、AWS的云算力（CPU和GPU）以及模型分发渠道（通过Bedrock访问Watermelon模型的API）。”**

增速放缓改变了谈判筹码：每天新增20万用户的智能体是零售商必须正视的威胁；每天新增7.4万用户的智能体则可以被要求等待。亚马逊股价自Muse发布以来一度下跌2%，目前已回升至+2.1%。

中国竞争格局：腾讯能否“反向Muse”Meta?

值得关注的是，Muse的发布也引发了投资者对中国同类产品的关注。伯恩斯坦和美银美林分析师Winnie Wu的核心判断是：智能体竞争的真正奖品是**“情境锁定”**——智能体对用户习惯、历史和工作流了解越深，就越有价值、越难被替代。

腾讯的结构性优势：

> - **封闭生态即护城河**：中国移动互联网由"封闭"生态主导，外部智能体可能永远无法访问微信或支付宝内的任务——这正是Muse在亚马逊、Costco、Netflix遭遇的问题，但在中国是整个互联网的默认状态；
> - **无需下载**：微信智能体无需独立下载，在大多数中国智能手机用户每天都会打开的应用内一键可达，绕过了Muse正在经历的下载增速放缓问题；
> - **小程序即现成管道**：腾讯已拥有摩根士丹利所说的"Web 1.0互联网必须构建才能让智能体规模化"的结构化接口；
> - **变现路径更近**：微信支付每年处理数万亿元人民币交易，腾讯可直接从智能体完成的交易中抽成——这正是摩根士丹利认为Meta最早要到**2027年底至2028年**才能实现的模式；
> - **算力约束**：出口管制限制了中国在GPU端的算力，而GPU推理成本在重度使用场景下是主要成本驱动因素。但调用小程序API的智能体相比驱动浏览器的智能体，所需CPU沙箱算力应大幅减少。

总结来看，分析人士认为，摩根士丹利的报告是迄今最有价值的Muse研究，因为它给出了真实数字：

> **Muse每用户每月服务成本3至130美元，基准情景37美元（摩根士丹利视之为上限）**；Meta已购置足以服务10亿日活用户的CPU算力，相关成本已纳入2027年2090亿美元运营支出预测；真正的智能体广告拍卖变现**最早要到2027年底至2028年**。

当前的现实情况是：Meta拥有服务10亿用户的算力，实际用户约180万至270万，且以9月峰值三分之一的速度增长，同时越来越多的网站和运营商正在决定是否放行这个智能体。

从14倍到21倍的估值重估是用增长故事换来的，而这个故事在周五收到了第一个真实的反向数据点——来自一个已披露做空立场的机构。**11月4日Meta三季报将是真正的考验，届时市场将要求Meta给出自己的Muse用户数据。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

31 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

特普柴油协议虽难解供需之渴，却掀起重塑全球风险定价的多方博弈。当前“柴油价差即利率波动”，能源风险正跨资产深度传导。美股平静表象下，内部结构分化已达历史极值。后市紧盯欧洲储备动向与地缘局势，警惕极端失衡下随时爆发的脆弱暗流！

特朗普与普京的一通电话，将柴油价格推至全球市场的聚光灯下。从利率波动到股市结构，从欧洲储备释放到俄罗斯解禁出口，一场围绕柴油的多方博弈正在重塑投资者的风险定价框架。

据央视新闻报道，10月9日，美国总统特朗普在其社交媒体“真实社交”上发文称，他刚刚与俄罗斯总统普京进行了一次“非常成功”的通话。特朗普称，双方已达成一致，俄罗斯将立即向美国及全球市场供应超过30万吨柴油，随后在11月再供应50万吨，紧接着还将供应100万吨。克里姆林宫随即确认，普京重申俄罗斯愿向美国及全球市场供应石油和石油产品。俄副总理诺瓦克进一步表态，俄方将立即提前解除柴油出口限制，10月、11月、12月对外追加供应量分别为30万吨、50万吨和100万吨。

然而市场反应审慎——原油期货几乎纹丝不动，国债收益率同样未见明显波动。

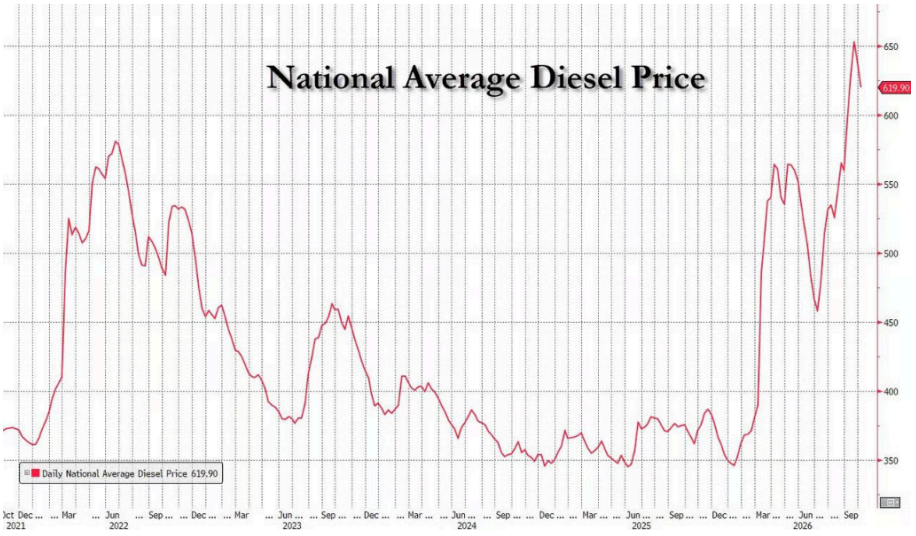

与此同时，乌克兰总统泽连斯基公开批评这一决定，称放松对俄制裁"正中莫斯科下怀"，并将延长战争。他同时表示，只要俄罗斯不打击乌克兰能源基础设施，乌方可停止攻击俄罗斯炼油厂，并称美方了解乌克兰的谈判立场。这一表态在强硬措辞之外，隐含了谈判的可能性。

供应承诺有限，市场理性冷对俄罗斯柴油协议

市场对特朗普-普京通话给出的"冷淡"回应并非无据。

规模是第一个问题。诺瓦克所披露的供应量——10月30万吨、11月50万吨、12月100万吨——在全球柴油贸易体量中属于边际增量。按当前美国消费水平测算，200万吨供应量仅相当于约4天的消耗量，难以从根本上改变供需格局。

第二个问题是全球定价机制的现实。柴油是全球定价商品，局部供应增加并不必然压低特定地区的终端价格。Academy Securities策略师Peter Tchir指出，即便美国从俄罗斯采购更多柴油，也只是改变了全球商品流向，对本地零售价格的直接传导十分有限。

第三个问题是交付能力。乌克兰对俄罗斯能源基础设施的持续打击，以及航运层面的制裁压力，均给俄方的实际履约能力带来不确定性。

自美伊冲突爆发以来，美国柴油全国平均价格已上涨约70%，10月8日达到每加仑6.28美元。此前峰值为每加仑6.53美元。柴油价格持续高企，已对卡车司机和农业用户造成显著成本压力，也成为美国选民关注的核心生活成本议题之一。

欧洲储备释放存变数，IEA协调机制面临考验

在俄罗斯协议之外，另一条更重要的供应线正在欧洲展开。

10月2日，美国总统宣布欧洲将释放部分紧急储备，法国总统马克龙以G7轮值主席国身份予以确认。讨论中的规模约为1亿桶，包含柴油和原油，释放期约为4个月。

然而欧洲内部并不统一。据报道，德国态度明显迟疑，法国则表现积极，其他成员国反应相对沉默。国际能源署（IEA）本周三将召开会议，讨论储备释放的品种和时间表，焦点据悉集中在柴油上。

需要注意的是，IEA仅拥有建议权，而非执行权。每个成员国自行持有并控制本国储备，是否释放、何时释放，最终取决于各国政府的独立决策。这意味着即便IEA达成共识，协调落地的过程仍存在较大不确定性。

Tchir指出，俄罗斯协议的达成，反而可能影响欧洲各国决策者对储备释放的紧迫感判断，进而干扰这一规模更大、影响更为深远的供应侧安排。他认为，市场周五对俄罗斯协议本身反应平淡，但尚未充分消化该协议对欧洲储备释放进程可能产生的连锁效应。

柴油即利率波动，能源风险向债市传导

能源市场的压力并未止步于大宗商品，其传导链条已延伸至债券市场。

野村证券跨资产策略师Charlie McElligott在10月8日的报告中明确指出，**欧洲柴油裂解价差与欧元区1年1年利率波动率自今年2月以来几乎同步运动——后者目前为112.6，前者则维持在85的高位。他的判断是：柴油裂解价差等于利率波动率，利率交易员实际上已在交易柴油。**

逻辑链条在于：**欧洲和亚洲面临能源短缺，全球炼油产能存在结构性瓶颈。储备释放仅能提供约一个月的缓冲，无法解决根本问题。McElligott警告，无论俄罗斯协议如何表述，"无论多少条Truth Social帖子，都无法炼出一桶柴油"。**

反映在国债市场上，10年期美债收益率本周从最高5.35%回落至5.24%收盘，周内小幅下行。法国国债收益率同样从上周四峰值回落，周五报收4.85%。衡量债市波动率的MOVE指数降至近两周低点，但绝对水平仍处高位。Tchir表示，债市多空双方均从本周价格走势中找到了各自的支撑依据，下周方向仍不明朗。

股指平静之下，结构性分化已达历史极值

债市的压力同样向股市传导，但表面数字掩盖了内部的深度分化。

McElligott指出，标普500指数近两个月几乎原地踏步，但85%的成分股已陷入技术性调整。自3月30日以来，标普500累计上涨23%，其中仅十只股票就贡献了70%的涨幅——英伟达单独贡献13%，美光、苹果和微软各贡献约9%，其余490只股票合计仅贡献30%。

过去一个月，标普500指数整体仅移动0.8%，而成分股平均波动幅度高达8.9%，两者之差达8.1个百分点，位于过去30年的第95百分位。利率敏感型板块在过去一个半月遭到明显压制：金融板块下跌7.7%，材料板块下跌7.9%，REITs下跌9.8%，医疗保健、工业和公用事业同样录得负收益。

McElligott将当前市场相关性之低定性为过去25年中仅有两次可比的历史先例，分别是2007年全球金融危机前夕和2018年的"波动率末日"（Volmageddon）事件。

期权市场同样呈现出罕见的结构：**认沽偏斜处于过去一年的第0.4百分位，认购偏斜则高达第99.6百分位。市场参与者几乎放弃了下行保护，"唯一的恐惧是踏空上涨"。McElligott警告，一旦柴油危机触发利率波动率的再度攀升，当前这一平静结构的脆弱性将迅速暴露。**

后市关键：欧洲决策与伊朗局势

综合当前局面，决定柴油价格走势的关键变量仍集中在两处。

其一是欧洲。IEA本周三的会议及各成员国随后的决策将直接影响近期柴油供应预期。泽连斯基在批评俄罗斯协议的同时，明确保留了谈判空间，这一表态的后续走向，将对欧洲政策制定者的判断产生影响。

其二是伊朗局势。Tchir指出，伊朗在霍尔木兹海峡附近的袭击行动仍在持续升级，特朗普政府对伊朗的最终政策取向尚不明朗。他同时提及，俄罗斯协议的达成在一定程度上折射出特朗普政府正将注意力从中期战略目标转向短期成本控制，这对能源价格而言并非利好信号。

Tchir总结称，与上周相比，"收益率状态"的边际改善客观存在，但尚不足以发出全面利好信号。能源市场的结构性压力依然未解，柴油价格能否真正"大幅、快速下跌"，仍取决于地缘政治与政策协调的多重变量能否同向共振。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

37 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

微软最新决策模型Microsoft-Decision-1基于Qwen3.5-9B构建。CEO纳德拉称，该模型在结构化决策任务中的延迟和质量均超越了传统大模型。在HuggingFace平台129个开源决策模型中，逾65%基于Qwen开发，微软、Perplexity、Cloudflare等巨头均已采用。

微软公司最新推出的决策人工智能模型，将其**底层架构锚定在阿里巴巴的开源模型之上**。

据硬AI消息，微软于10月12日正式推出全新决策模型Microsoft-Decision-1，该模型**基于阿里Qwen3.5-9B后训练而成**。微软官方透露称，该模型基于Qwen3.5-9B后训练而成，在结构化决策任务中，该模型在时延和准确性等方面均超过了LLM及Jev 1.13.0等热门决策模型。

微软Xbox研究团队已用它处理超过1万条玩家反馈，微软CEO纳德拉也在社交媒体上透露称，基于新模型的优异表现，微软正在所有领域测试应用新模型，包括事件响应、质量控制、科学发现等。

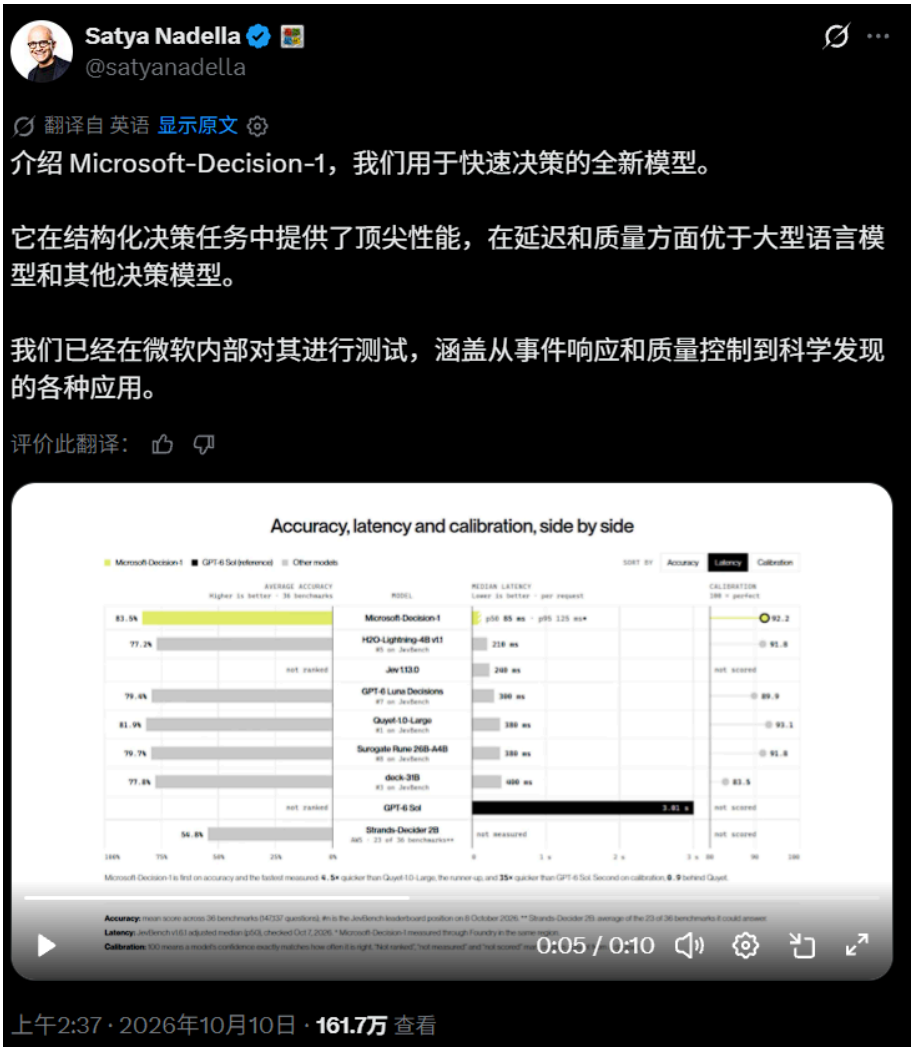

与生成自然语言的传统大模型不同，决策模型专注于输出预测值和概率，其更小的尺寸和更快的响应速度，正契合了企业端在频繁判断任务中对低成本和高效率的迫切需求。这向投资者释放了明确信号：**轻量化、专业化的决策模型正在释放巨大的商业价值。**

据了解，9月Jev模型爆火带起了一股决策模型浪潮。这种模型不生成自然语言，而是输出预测值、概率和置信度，比大语言模型LLM尺寸小得多，响应速度也更快，恰好能满足AI任务中的频

繁作判断的大量需求。

有数据统计显示，在HuggingFace 129 个开源决策模型项目中，基于阿里Qwen开发的就有84个，占比超65%，包括微软、Perplexity、Cloudflare、H2O.ai等公司推出的知名决策模型均采用阿里Qwen。

目前，微软已在全公司范围内对该模型展开广泛测试，涵盖事件响应、质量控制到科学发现等多个核心业务领域。随着该模型在Microsoft Foundry和OpenRouter平台的全面上线，基于Qwen架构的决策模型有望重塑企业级AI应用的工作流与投资逻辑。

新模型性能与成本优势显著

微软官方介绍重点强调了基于千问架构的新模型在性能上的突破。

> To build Microsoft-Decision-1, we post trained Qwen3.5-9B for fast, single-pass decision scoring and will soon rebase it on other models, including Microsoft AI (MAI) and OpenAI. When given a fixed set of answer options, Microsoft-Decision-1 provides a calibrated probability score for each option. The model supports yes/no, multiple-choice, and rating options, as well as rubric-based grading of AI responses and agent actions, all through a simple structured API call.

微软CTO办公室软件工程副总裁Achint Srivastava撰文指出，Microsoft-Decision-1在涵盖近15万个问题的36项基准测试中获得了最高准确率。

在速度方面，该模型的表现尤为突出。测试数据显示，其**测量速度是亚军模型H2O-Lightning-4B v1.1的2.5倍，更是GPT-6 Sol的35倍**。

此外，该模型在鲁棒性和安全性上也表现稳定，在选项描述被转述或打乱时，其决策改变率平均仅为1.3%。

在定价方面，该模型输入代币成本为每百万代币0.042美元，输出代币则完全免费，大幅降低了企业级应用的使用门槛。

内部全面测试加速企业级应用

优异的底层性能促使微软加速了该模型的内部应用转化。Satya Nadella 强调，微软正在所有领域测试应用这一新模型，以验证其在复杂环境中的可靠性。

在数据标注方面，微软Xbox研究团队已使用该模型处理了超过1万条来自问卷及社交媒体的玩家开放式反馈。

结果显示，其质量与GPT-6 Sol相当，但**运行速度提高了14倍，成本降低了200倍**。在质量控制领域，Copilot团队的测试表明，新模型与GPT5.6 Luna具备同等竞争力，且速度快100倍。

此外，在科学发现的自适应重新规划任务中，该模型的一致性是基于LLM评分的46倍，速度提升近4倍。这些密集的内部测试结果表明，基于Qwen底座的决策模型正切实转化为提升企业运营效率的核心工具。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

40 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

中金认为，美国AI产业正处于“金融棉花糖”时代，资本开支快速增长，企业融资逐渐从经营现金流转向外部债务融资，私募信贷和资产证券化也成为重要资金来源。与科网泡沫和房地产金融化时期相比，当前AI金融化尚处于早期阶段，但油价高企、加息风险及融资条件收紧，仍可能加剧短期流动性波动。

最近两个月来，美国股市波动较大，也波及其他地区。美国股市波动既有其货币政策变化的影响，也有市场对AI板块资本开支持续性的担忧，而前者又加剧了后者。简而言之，今年美国AI领域的几家大公司资本开支快速上升，明年虽然增速可能比今年慢，但仍然较快。但另一方面，AI企业的收入却面临较大不确定性，经营现金流已经与资本开支相若，一些公司开始通过发债支持资本开支。而美国国债收益率上升更加剧了市场的疑虑：在收入面临不确定性的情况下，资本开支如何维持，这是市场普遍关心的话题。

图表1：美国AI企业资本开支与经营现金流相若

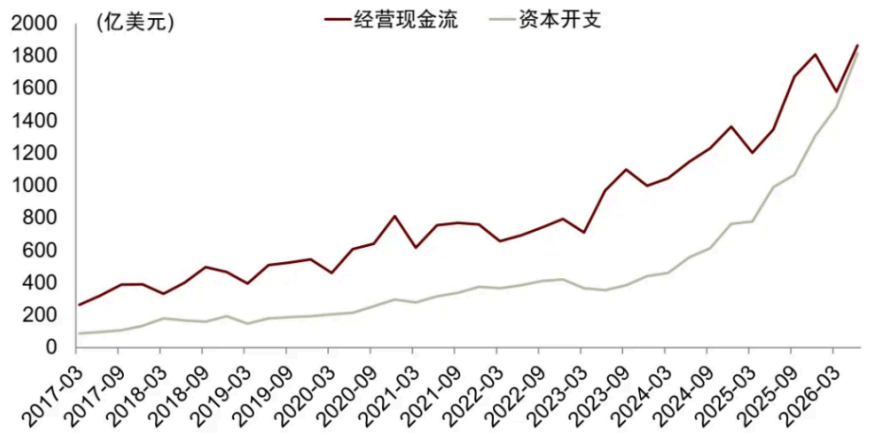

注：图中数据为微软、亚马逊、谷歌、Meta、甲骨文之和

资料来源：Epoch AI，Bloomberg，iFinD，中金公司研究部

AI是个新兴产业，其技术突破时点以及商业收入增速天然难以预测。我们将不聚焦收入，而选择从资金配置的视角出发，探讨美国AI资本开支的潜在资金来源。实际上，投资是收入的来源，如果资本开支难以保障，那收入增长也就缺乏支持。换言之，资本开支与收入并非互相割裂的两个变量。因此，讨论资本开支的融资状况也有助于我们判断收入的前景。

我们首先从AI产业的属性出发，分析该产业在吸引资金方面的优势。第二部分我们分析自1990年代以来美国社会资金供应的变化。具体而言，我们剖析美国的“金融化”如何重塑其流动性。“金融化”并无统一定义，其体现也比较复杂，但我们认为至少有两点对分析AI融资有意义。从宏观视角来看，金融化意味着广义流动性与GDP之比上升，通俗地说，就是社会上的“钱”逐步增多。从微观来说，金融化意味着新的金融产品数量与种类增加。金融产品（比如衍生品）使得资金“活”起来，也提升资产的流动性。当然，宏观层面与微观层面并非割裂，金融产品数量增加本身也可能导致宏观层面的流动性增加。

剑桥大学国王学院院长、Financial Times资深记者Gillian Tett 在《欢迎来到金融棉花糖时代》里面通俗地阐述了美国金融化现象，并回顾了金融“棉花糖”这个词的来源。因此，我们不妨借用金融“棉花糖”这个形象的说法来近似代指美国金融化。[1]

虽然美国在2008年次贷危机之后加强了金融监管，尤其是对银行的监管，但总体而言，其金融化现象并未明显逆转。在此基础上，我们回顾了1990年以来美国两次泡沫破裂前的金融化：1990年代的科网金融化与次贷危机之前的房地产金融化。我们然后分析当前美国AI产业的金融化所处的阶段，最后也分析当前美国AI板块可能面临的流动性风险。

AI：既有科技属性，也有“类地产”属性

我们认为，AI既有科技属性，也有“类地产”属性（固定资产占比较高），意味着既可以通过股权融资，也可以通过债权融资（抵押贷款）。

AI的科技属性无需赘述，其技术进步和生产效率提升似乎较科网企业更快。其中一个体现是，AI对劳动力的依赖较科网企业低，甚至可以替代劳动力。从中观数据来看，自2022年ChatGPT发布以来，美国通信和计算机行业的非农就业小幅缩减了6%。与此不同，从1995年8月美国网景公司上市（美国科网泡沫元年）到2000年3月美国科网泡沫破裂之间，其通信和计算机行业的非农就业则上升了60%多。

图表2：科网革命时期与AI年代美国通信、计算机行业就业走势分化

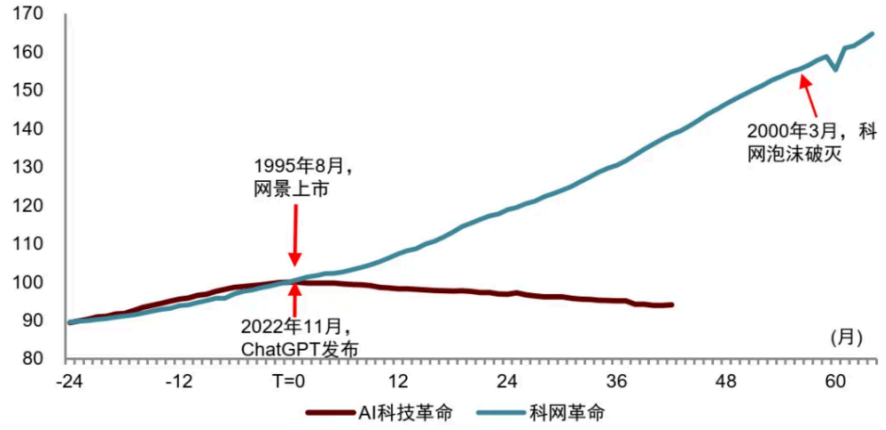

注：AI科技革命以ChatGPT发布（2022年11月）为T=0，科网革命以网景上市（1995年8月）为T=0。非农就业包括通信、数据处理、计算机系统设计行业，数据经过标准化处理

资料来源：iFinD，中金公司研究部

从微观数据来看，如果将2021年谷歌、微软、Meta三家公司劳动密度（员工人数与固定资产之比）指数平均设为100，2019年该指数为109，2025年下降到了37。具体而言，其固定资产指数从2021年的100升到了2025年的306，而其员工人数指数则只升到了112。

图表3：三家美国大科技公司的劳动密度

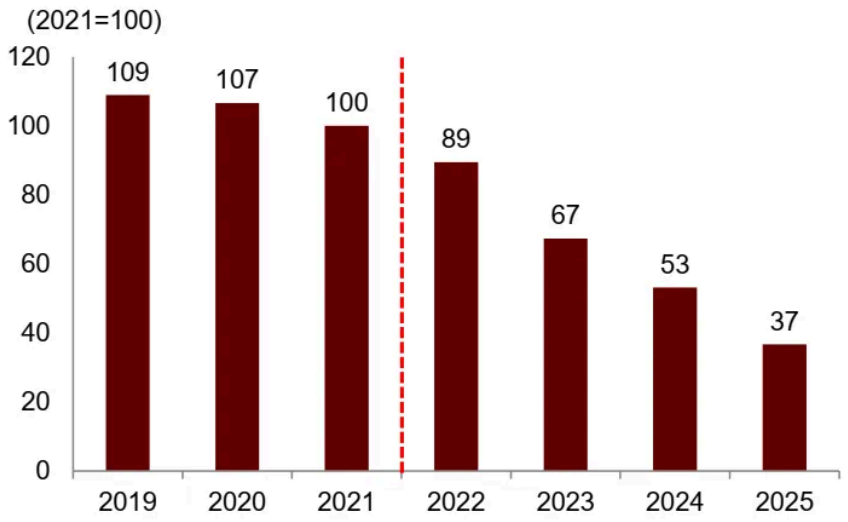

注：图中大科技公司包括谷歌、微软、Meta。劳动密度使用员工数量/固定资产衡量

资料来源：iFinD，中金公司研究部

图表4：三家美国大科技公司固定资产增长快于员工数量

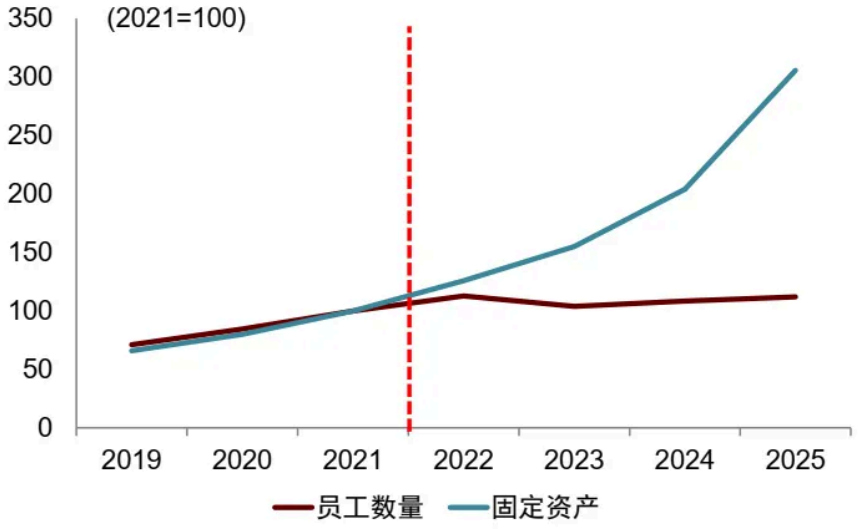

注：图中大科技公司包括谷歌、微软、Meta

资料来源：iFinD，中金公司研究部

科网革命时期，以微软为例，其固定资产投资和员工数量同时增加，而且员工数量增加更快，带动劳动密度上升。即使是2000年科网泡沫破灭后，企业劳动密度仍在上升。如果将1995年微软的劳动密度指数设为100，该指数2000年为138，2005年进一步上升到了174。具体而言，其员工人数指数从1995年的100升到了2000年的220和2005年的343。同期，其固定资产指数仅从100升到了197。

图表5：微软的劳动密度走势（1995-2005）

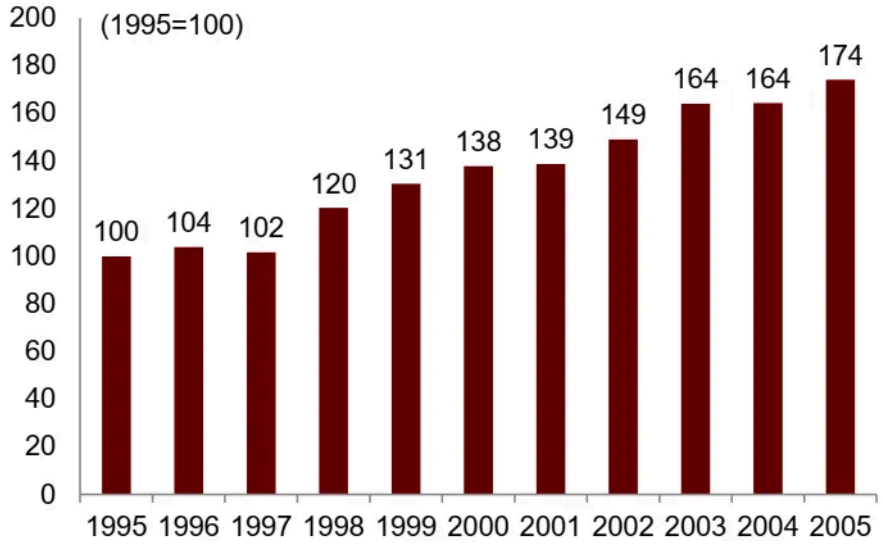

注：劳动密度使用员工数量/固定资产衡量

资料来源：iFinD，中金公司研究部

图表6：微软员工数量和固定资产走势

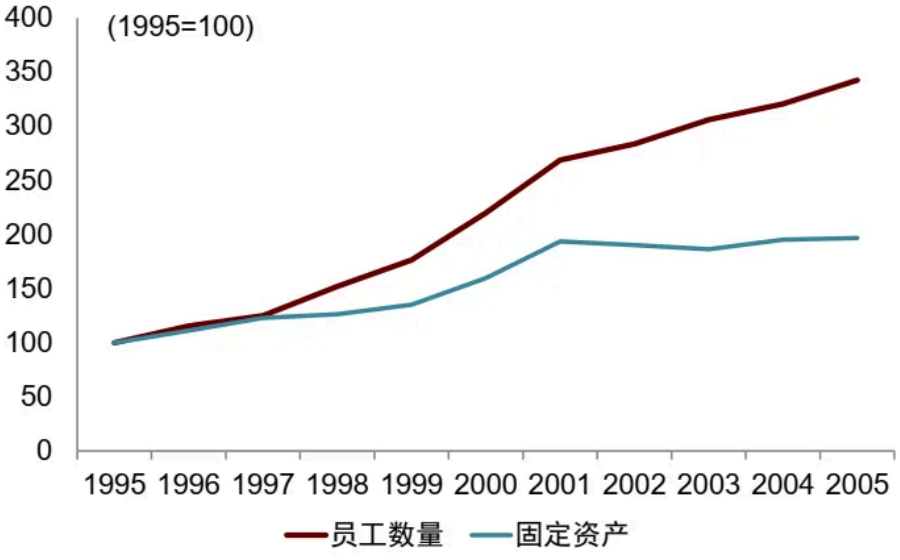

资料来源：iFinD，中金公司研究部

从经过通胀调整的人均创收来看，目前AI公司是传统互联网公司的2倍以上，反映AI公司的效率更高。比如，2026年Anthropic的人均创收与美国人均GDP之比大约为100倍，OpenAI和英伟达可能分别为63和57倍。2025年Meta、Apple、Google 和微软该比例分别为28、28、23和14倍。1999年，Apple、微软和思科该比例分别为26、18和16倍。

图表7：科技公司人均创收/美国人均GDP比值

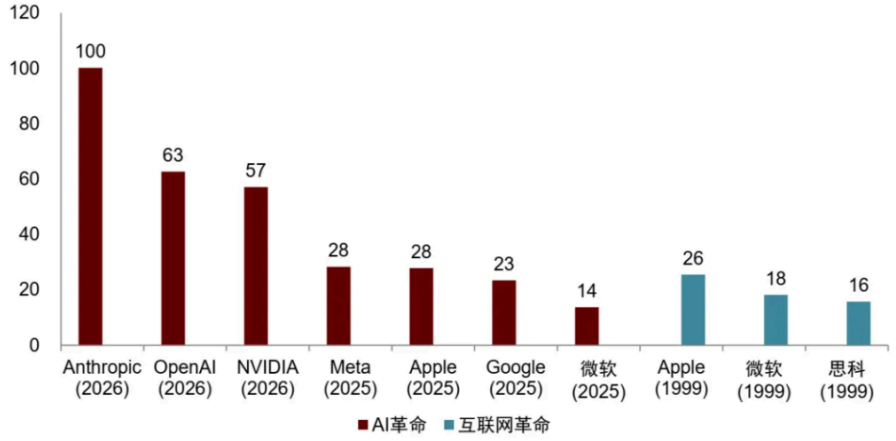

资料来源：iFinD，Epoch AI，中金公司研究部

之所以说美国AI企业也有“类地产”属性，是指其固定资产占比较高。比如，当前微软、Alphabet、亚马逊、Meta和甲骨文五家云厂商的固定资产与其总资产的平均比重超过了40%，而沃尔玛、埃克森美孚、宝洁和卡特彼勒四家传统企业现在的固定资产占比平均为37%。微软、思科、亚马逊、WorldCom和Lucent科网革命时期企业（以下简称科网企业）2000年的固定资产占比则平均为15%。固定资产中，微软、Meta土地房屋占46%，亚马逊、甲骨文的土地房屋分别占37%和40%，谷歌的土地房屋占比最低（11%）。这几家企业的软硬件和设备资产占固定资产的比重分别为47%、38%、49%、41%和56%。

图表8：当前AI企业固定资产占比较高

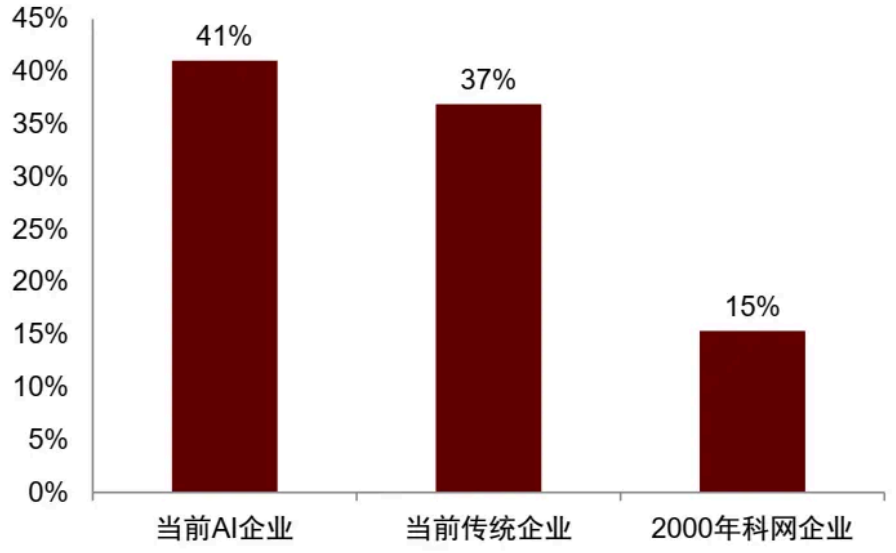

注：各组为样本公司先分别计算比率后简单平均。AI企业包括微软、Alphabet、亚马逊、Meta、甲骨文；传统企业包括沃尔玛、埃克森美孚、宝洁、卡特彼勒；科网企业包括微软、思科、亚马逊、WorldCom、Lucent。 AI企业使用最新可得2026Q2季报或者年报，传统企业使用最新年报；科网企业使用FY2000年报

资料来源：iFinD，Wind，Bloomberg，中金公司研究部

图表9：五家美国AI公司固定资产分解

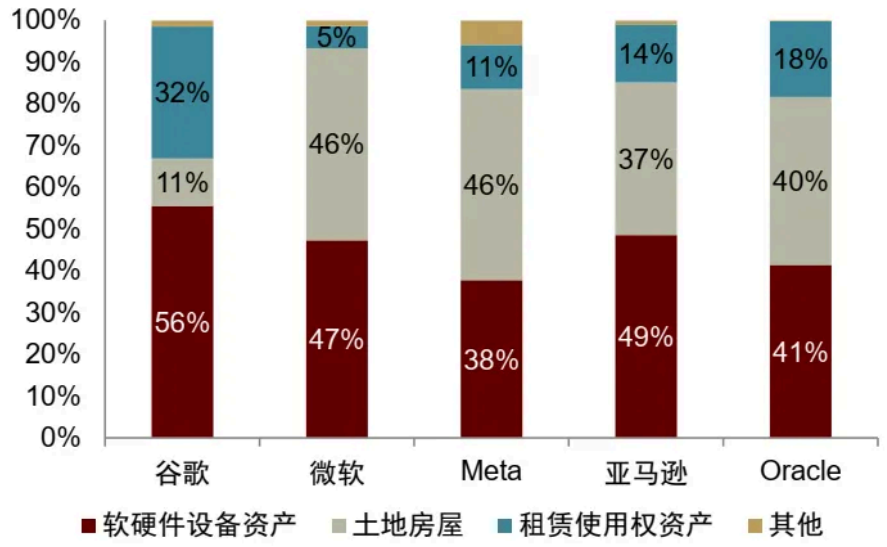

注：使用最新可得2026Q2季报或者年报

资料来源：iFinD，Wind，Bloomberg，中金公司研究部

动态来看，这几家公司固定资产占总资产的比重总体从2020年的22%上升到2025年的41%，而那五家科网企业的固定资产占总资产的比重从1995年到2000年一直基本上维持在15%左右。

图表10：AI企业固定资产占比上升

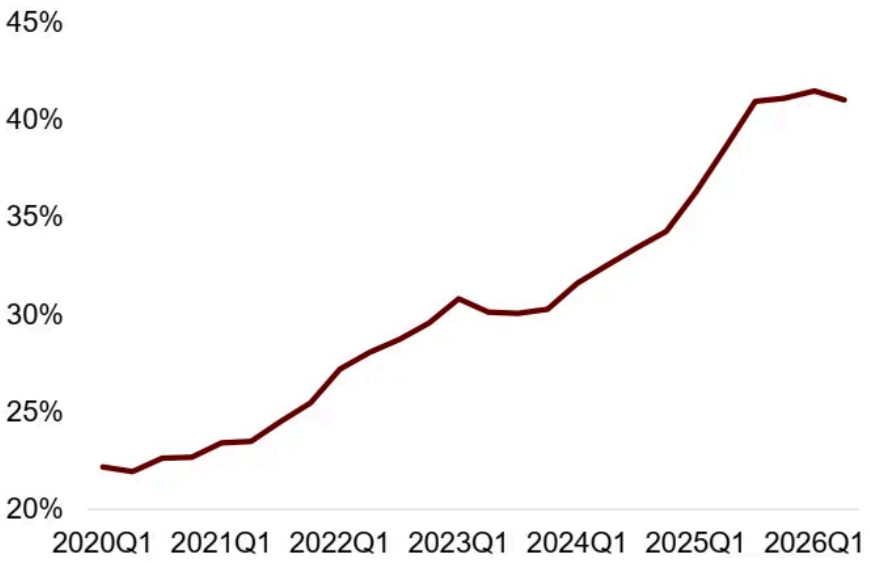

注：各组为样本公司先分别计算比率后简单平均。AI企业包括微软、Alphabet、亚马逊、Meta、甲骨文

资料来源：iFinD，Wind，Bloomberg，中金公司研究部

图表11：科网企业固定资产占比基本不变

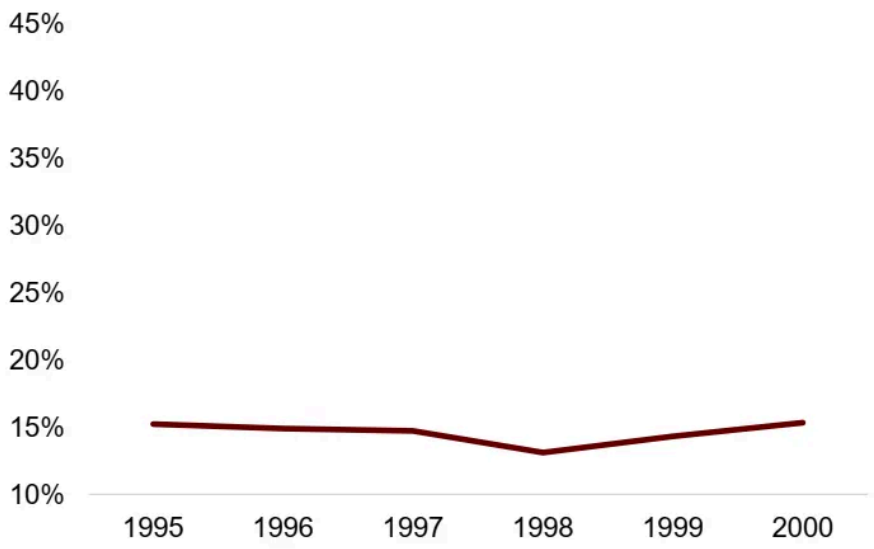

注：各组为样本公司先分别计算比率后简单平均。科网企业包括微软、思科、亚马逊、WorldCom、Lucent

资料来源：iFinD，Wind，Bloomberg，中金公司研究部

金融化提升流动性

金融化并没有统一定义。我们不妨引用Epstein（2005）的定义：金融目的、金融市场、金融主体以及金融机构，在国内与国际经济运行当中发挥愈发重要的作用[2]。这个定义隐含的意思是金融在资源配置中的作用上升。

不同学派认为金融化的驱动因素不一样[3]。新马克思主义认为，70年代后资本主义实体投资回报率下滑，过剩资本涌入金融投机是资本主义金融化的主因。后凯恩斯主义认为，企业治理转向股东价值优先，导致企业缩减实体投资、加大股票回购与金融资产配置，结果是金融投资挤出实体资本积累。而新古典主义则认为金融自由化、资产证券化提升资产流动性，优化资源配置，是经济发展的进步。尽管不同理论学派对金融化的发展理解不同，罗煜（2017）认为，布雷顿森林体系瓦解、全球进入纯信用货币制度，无疑为金融化创造了条件。具体而言，他认为支付媒介方面，实物现金占比大幅减少，交易变为账户数字划转，交易成本下降，交易规模增加。价值贮藏方面，各类金融资产起到了“准货币”的价值储藏功能，广义货币边界更加广阔。[4]

金融化的主要体现有以下几个方面[5]：（1）广义流动性更加充裕。比如广义流动性与GDP之比提升，金融部门的利润占比上升，金融部门规模增长相对更快。（2）低流动资产变成高流动资产。各类新型金融工具层出不穷，证券化将非流动资产转化为流动资产，金融交易规模大幅增长。（3）资本利润的获取愈发依靠金融渠道，而非实体贸易与商品生产。例如，企业利润更加依赖投资收益。（4）资本市场型金融体系话语权持续扩张。例如，股市/GDP、债务/GDP比值不断上涨，银行信贷/GDP比值下降。（5）企业治理中更加重视股东价值。例如，美股市场上回购增加。

从宏观方面来看，1990年代中期后，美国广义流动性与GDP之比趋势上升，较M2与GDP之比大约高20个百分点。金融危机后，美国加强了金融监管，美国银行部门的贷款业务相对放缓，但美国银行资产/GDP之比未见收缩，银行部门非贷款业务继续扩张。

图表12：美国广义流动性与GDP之比上升

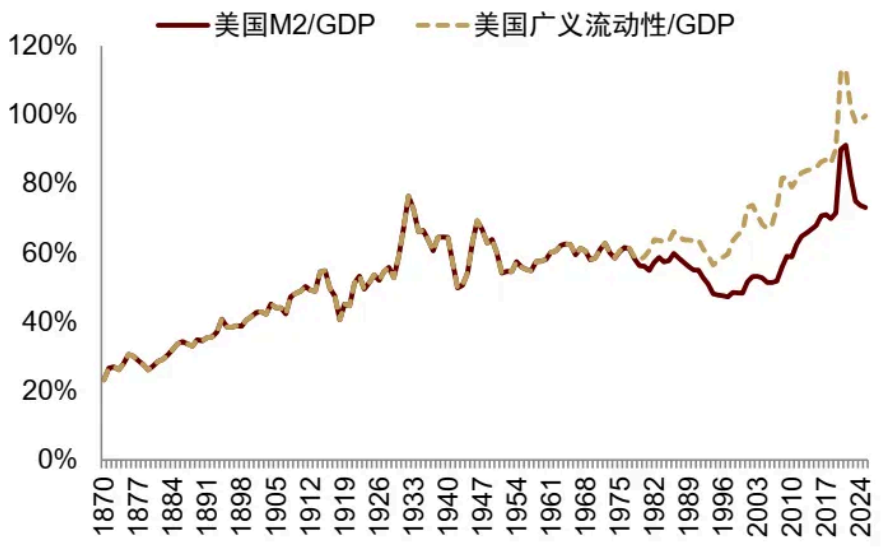

注：广义流动性使用M2+货币市场基金

资料来源：iFinD，Jordà-Schularick-Taylor Macrohistory Database，中金公司研究部

图表13：美国银行资产与GDP之比未见收缩

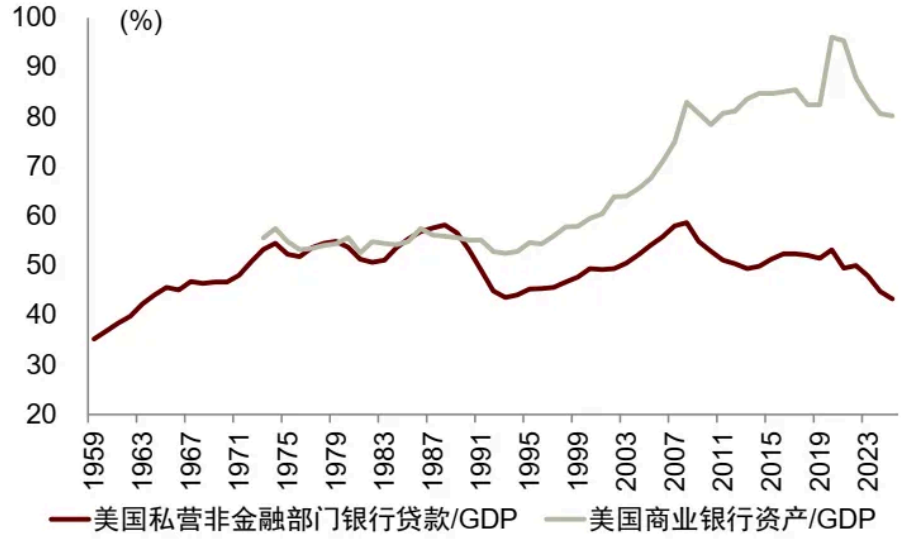

资料来源：iFinD，中金公司研究部

从微观方面来看，新的金融产品不断出现。1985-2014年，美国非金融企业证券发行数据表明，金融产品种类不断扩张。1985 年市场可用金融产品约150种，2014 年增长至751种，新增600余种。非金融企业通过新金融产品的融资占比上升，2010-2014年期间占比超过了50%。

图表14：美国非金融企业融资方式

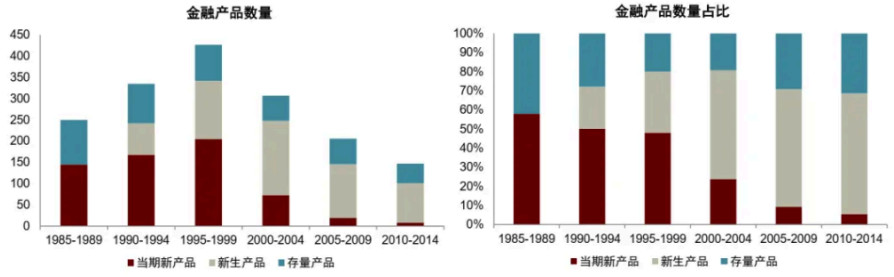

注：左图展示了1985-1989年至2010-2014年各时期不同金融产品的总数量。柱状图将金融产品分为三类：（1）存量产品（Old）：1985年以前推出的产品；（2）当期新产品（New-Entrants）：在当期新推出的产品；（3）新生产品（New-Young）：1985年以后推出、但首次发行发生在此前时期的产品。右图展示了1985-1989年至2010-2014年各时期融资总额的变化。柱状图进一步将融资规模分解为存量产品、当期新产品和新生产品的发行融资额

资料来源：Ana Babus, Matias Marzani, and Sara Moreira, "The Rise of Specialized Financial Products," NBER Working Paper 34594 (2025)，中金公司研究部

另外一些指标也有参考意义。比如，美国共同基金、期货及期权合约数量不断上涨。2025年活跃期货及期权合约大幅上涨，主要是由于事件合约（event contracts）的增长，如Kalshi、ForecastEx等事件预测平台的合约数量显著提升。事件合约是以特定事件是否发生或其结果为标的衍生合约，常见于预测市场（prediction markets），可涉及经济指标、金融市场、天气、政治等事件。2024年美国大选之后，预测市场获得了巨大的流量，带动了事件合约的增长。

美国科网与地产金融化的经验

美国在自1980年代以来有两次加速金融化的经验，一个是1990年代的科网金融化，另一个是2000年后的地产金融化。1990年代科网金融化表现为美国VC大幅增长和股权融资热，增加了资金使用方式，使得资金能够流动起来。这个阶段金融化的一个重要驱动因素是对养老金投资约束放松，促进VC发展，IPO提供退出渠道，释放VC资金，吸引更多资金进入。而2000年代美国地产金融化，既创造新流动性，也增加流动性使用方式，其主要体现是通过证券化，使得房地产贷款机构释放资本金，突破资产负债表约束，形成更多的贷款，创造了新的流动性。而证券化进一步让更多金融机构参与到地产金融化，资金使用方式增多。

美国企业的股权融资方式包括私人股权融资和公开股权融资。在初创期主要是通过私人股权融资，在成长期之后，通过公开股权融资方式。1979年后，美国放松对养老金的投资限制，促进了VC的大幅增长。VC把“没有抵押品的互联网创业公司”变成比较容易融资的企业，IPO提供退出渠道，将股权占用的资金释放出来，再形成新的投资。IPO退出也帮助VC吸引更多资金。

具体而言，1979年之前，《雇员退休收入保障法》（Employee Retirement Income Security Act of 1974）的“审慎人规则（Prudent-Man Rule）”限制美国养老金参与初创企业投资。1979 年美国劳工部对“审慎人规则”做出澄清，养老金做投资判断要看整个组合的风险分散效果，不再要求每个项目都必须风险低。改革后养老金可以增加配置风险投资，机构LP大规模入场，深刻改变美国VC行业资金来源结构，美国VC新增规模和投资额呈现大幅增长。从美国VC资金来源看，在1978年只有约15%来自养老金，而到了1990年，约有53%来自养老金。美国VC的募资额和投资额也是在1990年代开始出现快速增长。

图表15：美国VC资金来源

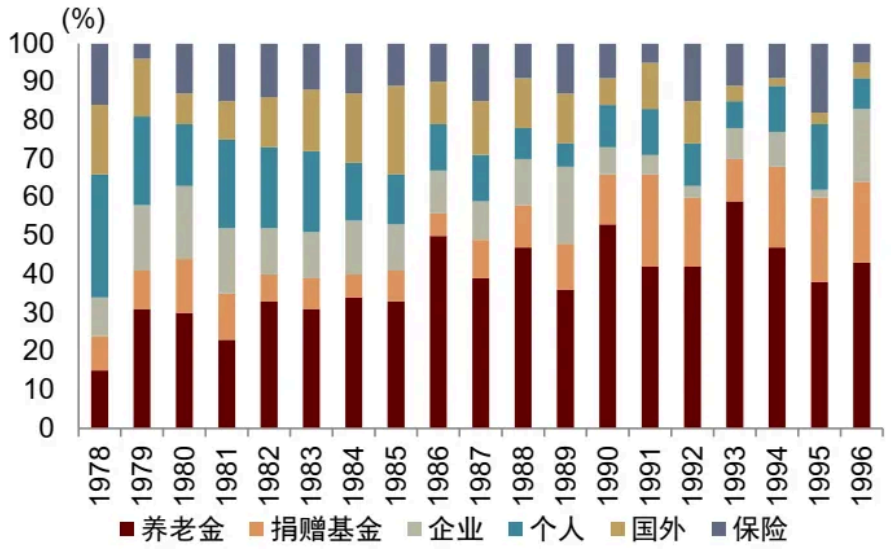

资料来源：Gompers & Lerner. 1998. What Drives Venture Capital Fundraising?，Nicole R. Onorato. 1997. Trends in Venture Capital Funding in the 1990s，中金公司研究部

图表16：美国VC募资额和投资额

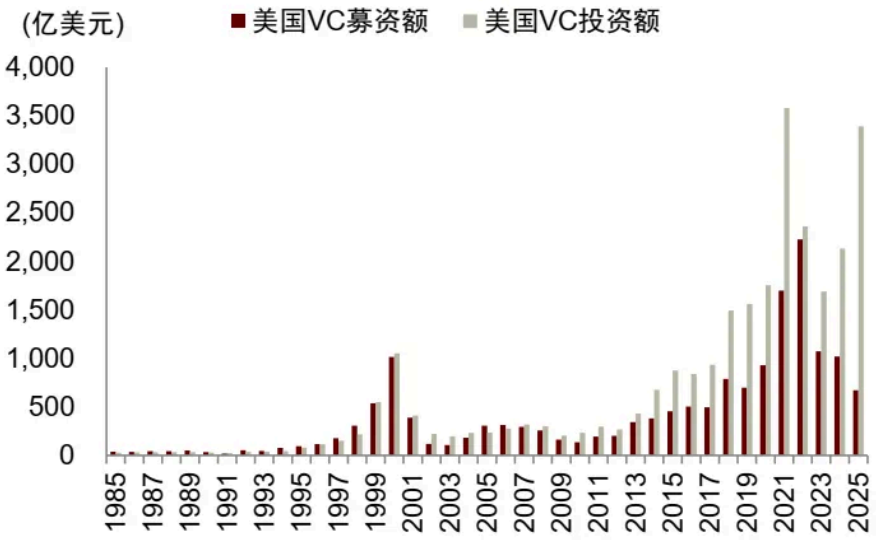

资料来源：National Venture Capital Report 2013&2023&2025，中金公司研究部

资金流向VC之后，VC为缺乏实物抵押品的互联网初创企业，开辟了股权融资渠道。互联网创业公司通常资产轻、无形资产多、现金流为负、没有稳定利润、缺乏银行抵押品，难以通过传统渠道融资，只能通过股权融资。1990年代，美国IPO数量增加，VC支持的IPO比例上升，股权融资大幅增加。

图表17：1990s后，美国VC支持的IPO上升

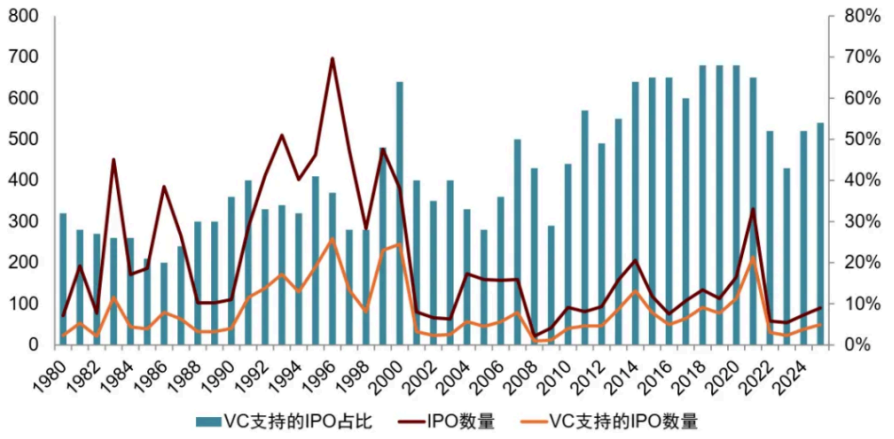

资料来源：Jay R. Ritter IPO Data，中金公司研究部

为了实现更好的退出，1990年代末期，美国IPO大幅折价发行，特别是科技股，以吸引更多投资者参与。新成立、历史业绩少的VC，有很强动机推动被投企业 IPO，接受较高IPO折价，利用IPO首日暴涨制造成功退出案例，向LP展示业绩，方便募集下一期VC基金。1990年代后期IPO退出回报非常可观，进一步刺激LP向 VC大规模出资。而随着IPO发行量的增加，上市企业的平均质量下降。VC支持的上市科技企业平均年龄从9年（1991年）下降到4年（1999年）。

2000年后美国地产金融化既通过衍生品盘活了存量资产，也带动广义货币的扩张，与债权融资紧密相关。各类金融机构通过资产证券化，将房地产资产转化成可交易、可抵押、可加杠杆的金融资产，从而把房地产市场和资本市场、银行体系及影子银行体系连接起来。住房按揭MBS证券化的首要作用是盘活存量信贷资产，让原有货币更加活跃，提高货币流通速度；同时银行回笼资金后可以持续向家庭发放新增贷款，通过商业银行信贷派生机制，带来广义货币扩张。

盘活存量资产的方式包括信用增强、再次证券化、给抵押贷款加“保险”等，使得原本难以“流动”的资产变成“可流动”的资产。信用增强（Credit enhancement）大约有三个方式：（1）信用分层（Tranching），将抵押贷款转换成了不同风险等级的证券，满足不同的投资者的需求；（2）超额抵押（Over-collateralization）：资产池的规模大于对外发行全部证券的本金总和，多出的那一部分资产就是超额抵押，用来吸纳亏损；（3）超额利差（Excess spread）：抵押贷款利率高于MBS的利率，保证利差为正。

CDO（Collateralized Debt Obligation）将以次级贷款为底层资产的MBS再次进行证券化、分层，转换成不同等级的证券。此外，CDS（Credit Default Swap）给抵押贷款加上一层“保险”，进一步提升其流动性。

数据显示，1980年代以后，美国贷款/GDP比例大幅上升，其中居民地产贷款上升最多。1995年，居民抵押贷款与GDP之比不足50%，而2007年该比例超过80%。从2001年到2006年，美国抵押贷款证券化比例大幅上升，特别是Alt-A和Sub-prime这些质量较差的抵押贷款证券化比例上升较快。例如，Alt-A级抵押贷款的证券化比例从19%（2001年）上升到了91%（2006年），Sub-prime级抵押贷款的证券化比例从46%（2001年）上升到了75%（2006年）。

美国抵押贷款持有人从银行转向非银。早期美国住宅证券化主要由Fannie Mae、Freddie Mac、Ginnie Mae等政府支持机构参与，后期越来越多的非政府支持机构开始参与抵押贷款证券化（包括投资银行）。通过证券化方式，政府支持机构（如房地美、房利美）、ABS发行人持有占比2006年超过60%。

美国AI 金融化尚处于早期阶段

美国主要AI企业筹资现金流刚由负转正，开始转向外部融资。美国代表性AI企业投资支出/营收比值由2020年的约10.3%升至2025年的约32.8%，2026Q2进一步升至约51.7%，已超过科网革命时期高位。投资支出的来源上，AI企业经营现金流/营收比值维持在40%以上，筹资现金流/营收比值由2025年约-7%转为2026Q2约16.2%。

图表18：AI企业投资支出来源

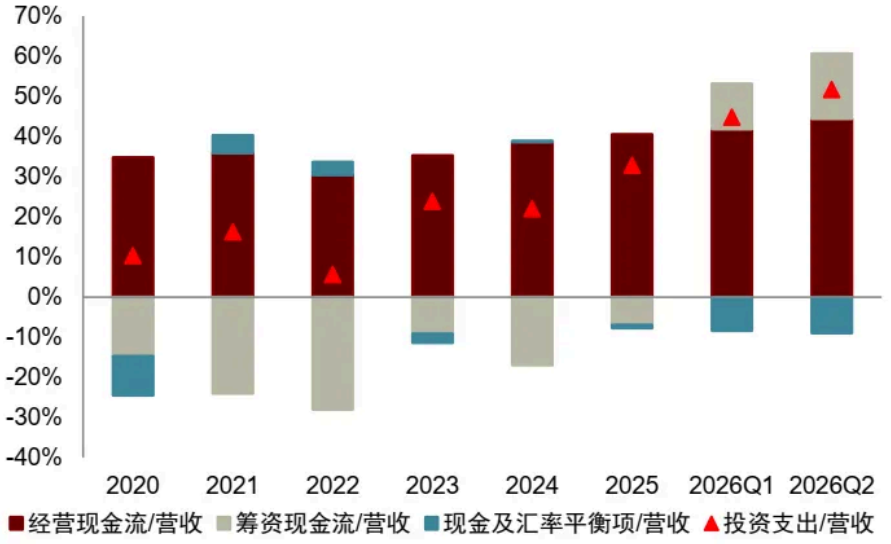

注：各组为样本公司先分别计算现金流/营收比率后简单平均。AI企业包括微软、Alphabet、亚马逊、Meta、甲骨文。AI企业2020-2025为年报，2026Q1和2026Q2采用截至相应季度的过去四季度合计口径，以减弱季节性影响

资料来源：Wind，Bloomberg，中金公司研究部

图表19：科网企业投资支出来源

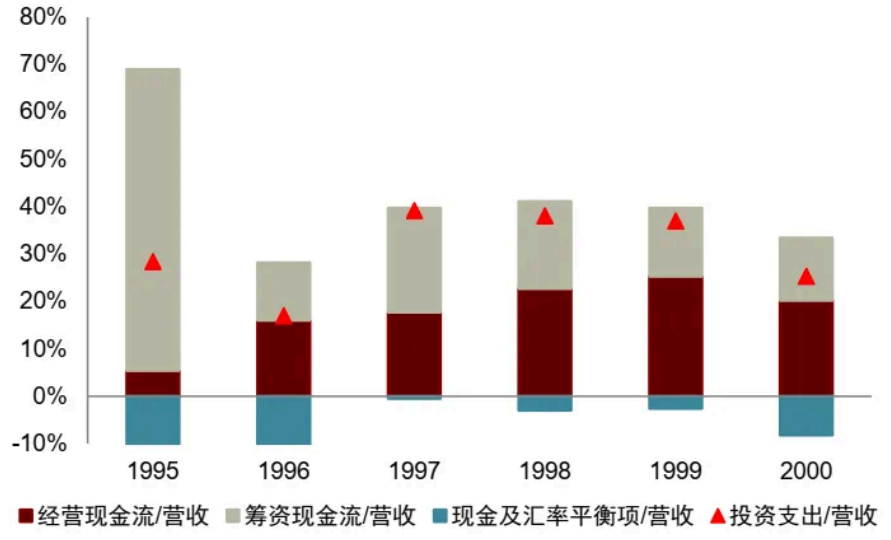

注：各组为样本公司先分别计算现金流/营收比率后简单平均。科网企业包括微软、思科、亚马逊、WorldCom、Lucent

资料来源：Wind，Bloomberg，中金公司研究部

目前AI企业外部筹资增量主要是债务融资，股权融资尚未大规模开始。2026Q2，AI企业筹资现金流净额/营收比值升至16.2%，高于2000年的科网企业（13.2%）。其中，净债务融资/营收比值为21.2%，净股权融资/营收比值收窄至-3.3%，而彼时科网企业债务和股权融资均为净流入。相比起来，本轮AI融资扩张目前更集中于债务端，股权融资还体现为净回购。如果未来债权融资成本上升，AI企业可能转向股权融资。

图表20：AI企业筹资现金流来源

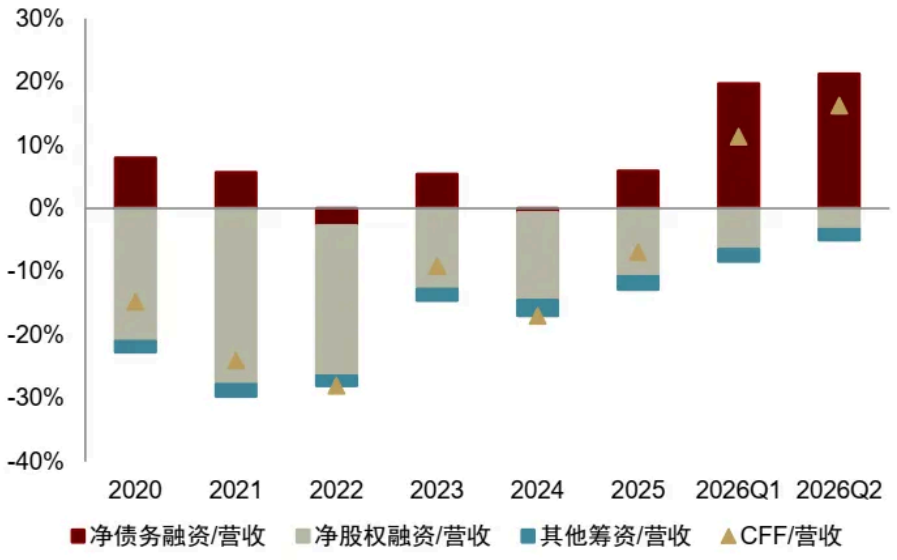

注：各组为样本公司先分别计算现金流/营收比率后简单平均。净债务融资=债务增加/发行-债务减少/偿还；净股权融资=股本增加/发行-股本减少/回购-已付股息；其他筹资=CFF-净债务融资-净股权融资。AI企业包括微软、Alphabet、亚马逊、Meta、甲骨文。AI企业2020-2025为年报，2026Q1和2026Q2采用截至相应季度的过去四季度合计口径，以减弱季节性影响

资料来源：Wind，Bloomberg，中金公司研究部

图表21：科网企业筹资现金流来源

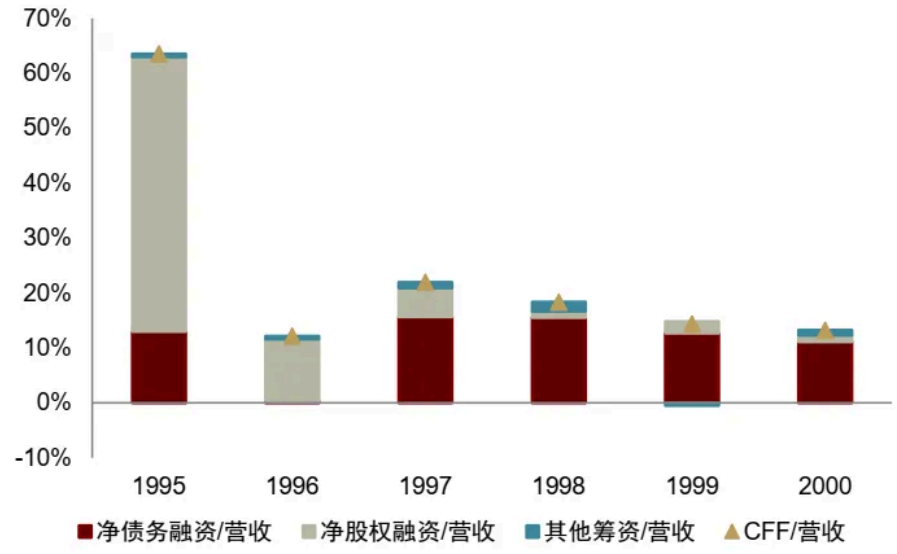

注：各组为样本公司先分别计算现金流/营收比率后简单平均。净债务融资=债务增加/发行-债务减少/偿还；净股权融资=股本增加/发行-股本减少/回购-已付股息；其他筹资=CFF-净债务融资-

净股权融资。科网企业包括微软、思科、亚马逊、WorldCom、Lucent。科网企业净股权融资/营收1995年均值显著偏高主要受亚马逊当年营收基数较小影响

资料来源：Wind，Bloomberg，中金公司研究部

根据Dealoggic的数据，截至2026年6月，AI企业（Alphabet、Amazon、Meta、Microsoft和Oracle），在全球范围内发行了1590亿美元债券，而2025年全年为1080亿美元，2024年全年仅为170亿美元。这五家AI企业的总负债从25Q4开始大幅增加，26Q2一个季度增加了2115亿美元。边际上来看，26Q2的短期债务增长更多，长期债务增长放缓，企业的偿债压力有所增加。

图表22：美国AI企业债发行量大幅增长

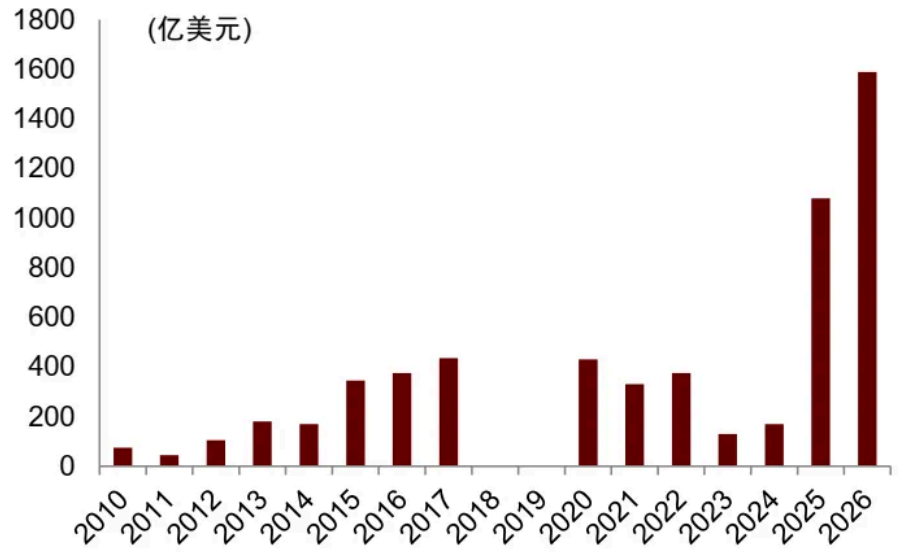

注：企业债发行数据包括谷歌、亚马逊、Meta、微软、甲骨文。企业债发行2026年数据截至2026年6月5号

资料来源：WSJ，Dealoggic，iFinD，Bloomberg，中金公司研究部

图表23：美国AI企业债务组成

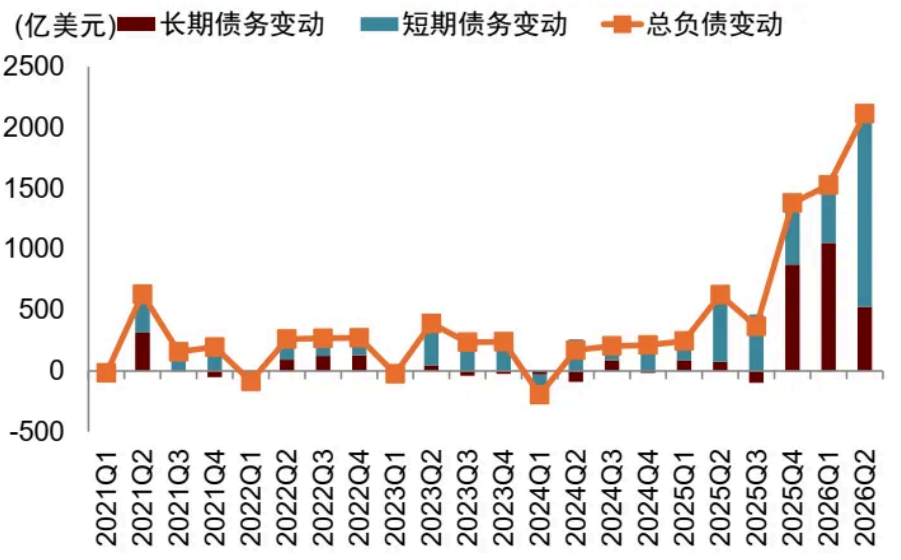

注：AI企业使用谷歌、亚马逊、Meta、微软、甲骨文

资料来源：iFinD，中金公司研究部

私募信贷已成为美国AI企业表外融资体系重要的资金来源。私募信贷正逐步替代传统银行贷款支持长周期AI基建投资。由于AI项目投资规模巨大且回收周期长，传统银行体系风险偏好有限，Apollo、Ares、Blackstone、Blue Owl等大型私募信贷机构遂成为关键资金提供者。据BIS估算，私募信贷向AI相关公司的贷款已增长至超过2000亿美元，占私募信贷总量近8%。涉及AI贷款的私募基金目前已有20%左右。私募信贷资金主要通过数据中心SPV、CoreWeave等算力运营商及GPU融资平台流入，以与M7长期合同产生的稳定现金流作为偿债支持，促使资金来源从银行体系向非银金融体系转移，实际上起到了类似银行的作用。

图表24：私募信贷对美国AI企业的直接贷款快速增长

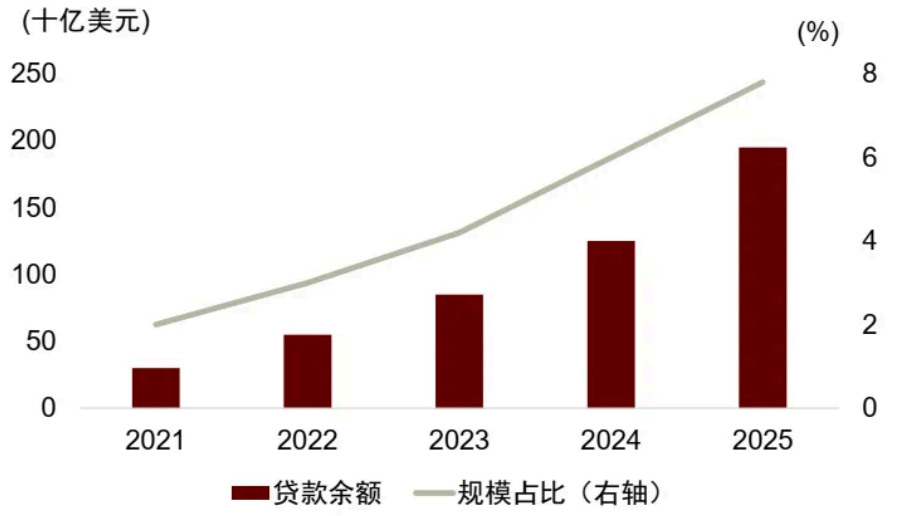

资料来源：Aldasoro, Iñaki, Sebastian Doerr, and Daniel Rees. Financing the AI boom: from cash flows to debt. No. 120. Bank for International Settlements, 2026.，中金公司研究部

图表25：涉及AI贷款的私募信贷比例上升

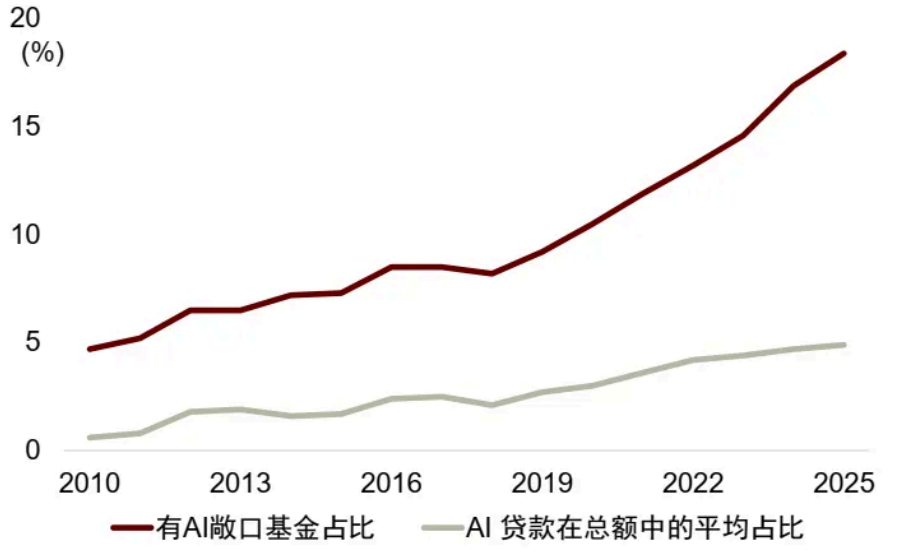

资料来源：Aldasoro, Iñaki, Sebastian Doerr, and Daniel Rees. Financing the AI boom: from cash flows to debt. No. 120. Bank for International Settlements, 2026.，中金公司研究部

目前，AI企业债务压力不大，债务融资仍有空间。美国五大云计算厂商经营现金流充足，整体偿债能力稳健。现金流利息保障倍数均高于1，最低的甲骨文约为7倍，其次亚马逊约为48倍，最高的谷歌约为82倍。还本付息率均低于1，甲骨文约为48%，亚马逊约为12%，最低的谷歌仅约为6%。

图表26：美国五大云厂商还本付息率（债务本息现值/经营现金流）

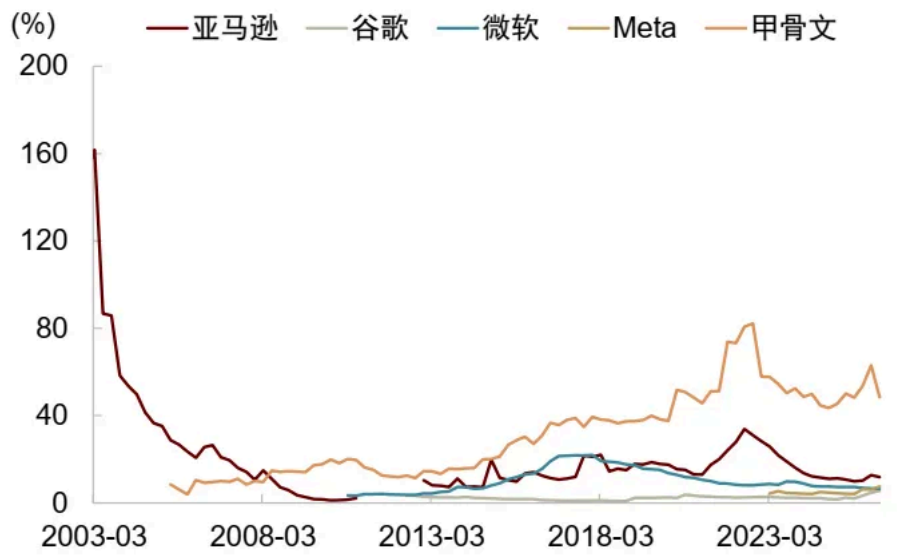

注：按照BIS还本付息率公式计算

资料来源：Bloomberg，中金公司研究部

美国五大云计算厂商有效利率目前还不高，净现金储备情况分化。2026Q2，五大云厂商有效利率为4.9%，低于Baa级企业债收益率。五大云厂商融资成本还不高，一定程度上源于前期低利率环境“锁定”利率、以及非美货币发债。净现金储备情况中，谷歌、微软、Meta相对较好，亚马逊、甲骨文净现金为负，说明对外部融资的依赖程度更高。

图表27：美国五大云厂商有效利率还不高

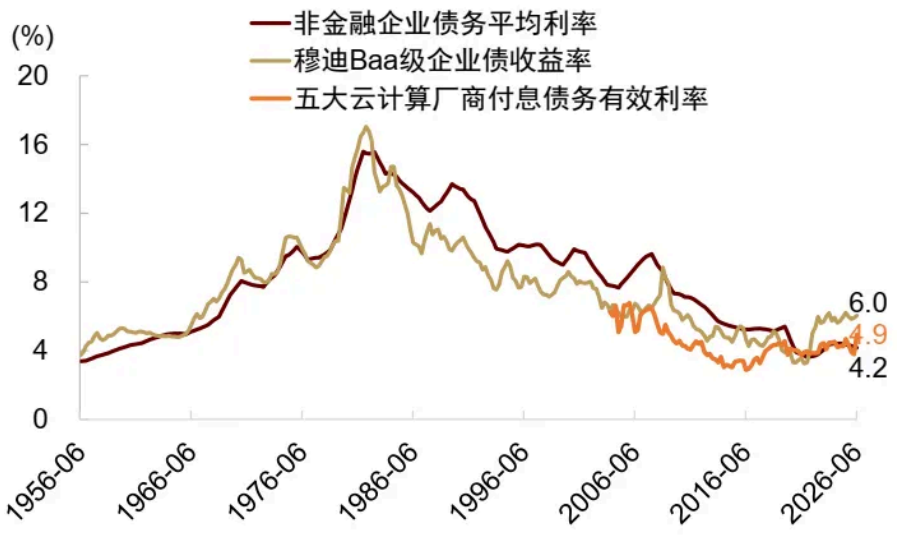

注：债务有效利率=近12个月利息支出/总债务

资料来源：Bloomberg，中金公司研究部

资产证券化或成为美国AI公司融资的下一步。随着长期租赁和容量采购合同不断累积，数据中心与算力资产的稳定现金流开始具备证券化条件。2024年初，CyrusOne发行了11.75亿美元的数据中心资产支持证券（ABS）[6]；2025年3月，Sabey发行3.25亿美元ABS，抵押品是在美国的7个数据中心[7]；2025年5月，Stack发行3.45亿美元ABS，抵押品是11个美国数据中心的房地产、租赁和相关权益[8]；2025年9月，QTS发行6亿美元ABS，抵押品是Phoenix的数据中心[9]；2026年初，Compass Datacenters发行了8.3亿美元的数据中心ABS，底层资产即为向云厂商租赁算力的长期合约[10]。AI数据中心贷款正被打包成ABS，向养老金、保险资金等机构投资者分销，类似于房地产证券化过程。

美国AI企业长期股权投资近期开始抬升，但总体占比不高。AI企业的对外长期股权投资自2025年以来抬升，到2026Q2在总资产中的占比约为5%。相比于科网企业，AI企业长期股权投资占比不高，显示AI企业的股权金融还处于早期。而且，通过将部分重资产项目以股权投资方式，剥离出超大规模云厂商的资产负债表，也是风险隔离的一种方式。

图表28：美国AI企业长期股权资产占比

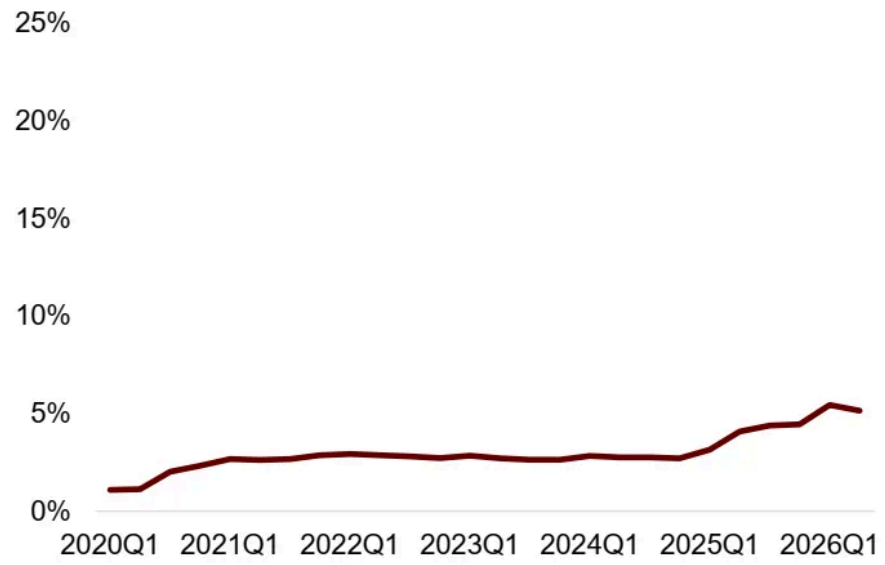

注：各组为样本公司先分别计算比率后简单平均。AI企业包括微软、Alphabet、亚马逊、Meta、甲骨文

资料来源：Wind，Bloomberg，中金公司研究部

图表29：美国科网企业长期股权资产占比

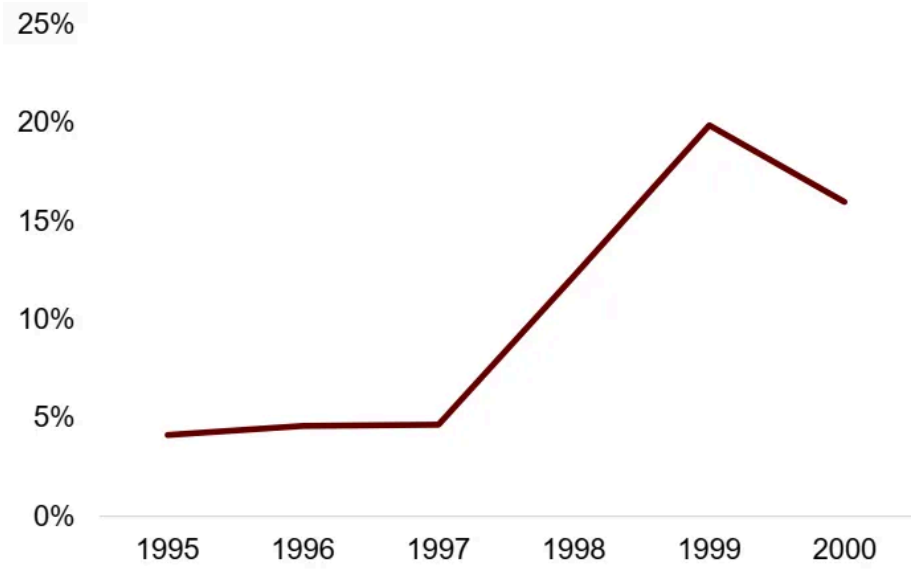

注：各组为样本公司先分别计算比率后简单平均。科网企业包括微软、思科、亚马逊、WorldCom、Lucent

资料来源：Wind，Bloomberg，中金公司研究部

短期风险

前面的分析意味着，在美国金融化的大背景下，加上AI公司既有比科网公司更强的科技属性，又有“类地产”属性，AI公司既可以通过股权融资，也可以通过债权融资。而与历史上的科网革命和房地产相比，美国AI公司当前金融化尚处于早期阶段，其资金来源无需过度担忧。但这不是说，我们就可以忽视短期的流动性波动风险，尤其是油价居高不下、美国加息路径不清晰的情况下。

回顾历史，当年美国科网泡沫与地产泡沫破灭前同时出现三个现象：（1）高杠杆。科网革命时期，美国大量Dotcom公司上市，Shiller PE ratio从17倍（1990年）上涨到44倍（2000年）。次贷危机前，美国家庭部门宏观杠杆率从70%（2000年）上升到98%（2007年）；（2）基本面走弱。2000年左右，美国互联网用户渗透率出现拐点，而2006年开始，美国房贷违约率开始上升；（3）融资条件系统性收紧。美联储从1998年开始加息，联邦基金利率从4.75%（1998年）上升至6.5%（2000年）。次贷危机前，联邦基金利率从1.0%（2003年）上升到5.23%（2006年）。

当前，对于AI公司来说，这三个现象特征都还不显著。目前美国企业部门杠杆率相对还较低，股市估值也不算非常高；美国经济基本还比较强劲，名义增长在5%左右，以Mag 7为代表的大科技公司营收、利润增速还较高；融资条件暂时还未见明显持续的收紧。

但是，短期风险仍需要关注，可能对AI企业融资产生扰动。目前美国融资需求旺盛，而随着通胀上升，资金面边际紧张。近期，实际融资压力（实际利率TIPs）走高，市场对AI产业链高杠杆的持续性产生顾虑。

2026年9月，英格兰央行金融政策委员会指出AI债务上升，以及其不够透明，对风险评估带来困难，而随着金融条件收紧，信贷市场（包括私募信贷）相对比较脆弱[11]。2026年5月，美联储在《金融稳定报告》中指出，AI以及私募信贷是近期需要关注的风险[12]。美联储认为随着资本支出越来越多地依赖债务融资，增加了系统的杠杆效应；私人信贷面临着越来越大的压力，包括投资者的赎回、情绪恶化，以及人工智能带来的信贷质量影响。2026年9月，标普将Oracle的评级下调至BBB-，仅高于垃圾级[13]。自美联储在2026年9月加息后，到9月底，Coreweave一些高收益债的收益率上涨了超过0.5个百分点[14]。2026年7月，Meta新发120亿美元债券，为数

据中心进行融资，债券收益率为7.5%，融资成本要比2025年10月发行270亿美元债券时高出0.4个百分点[15]。

图表30：泡沫破灭一般出现在融资条件系统性收紧之后

资料来源：iFinD，中金公司研究部

具体来看，短期需关注两类风险。一是融资条件收紧，削弱私人投资动能。若美联储加息，或银行收紧贷款标准，企业融资成本和资金获取难度可能上升，进而拖累私人投资扩张。二是短期融资压力加剧，放大流动性风险。回购与资产支持商业票据市场利差仍高于常态，提示部分市场主体的短期融资压力尚未消退。若此时货币政策进一步收紧，可能增加债务续借难度，并放大短期资金市场的波动。

本文来源：中金；作者：张文朗、黄亚东、周彭

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

30 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

9月新能源乘用车出口占乘用车出口总量60.8%，较去年同期大幅提升21个百分点。比亚迪以17.6万辆领跑出口榜，奇瑞、吉利紧随其后。值得关注的是，狭义插混出口占比升至34.2%，向发展中国家渗透提速；1-9月新能源出口累计达388.7万辆，同比增长138.8%，出口已成车企增长核心驱动力。

总体市场-2026年9月零售、出口分析表

零售

零售（单位：万辆）	轿车	MPV	SUV	狭义乘用车合计	微客	广义乘用车合计
9月份	63.6	6.6	91.6	161.8	1.3	163.1
8月份	60.1	7.5	86.6	154.1	1.3	155.4
同期	102.0	9.6	113.1	224.7	2.2	226.9
同比	-37.7%	-31.1%	-19.0%	-28.0%	-40.3%	-28.1%
环比	5.8%	-12.3%	5.9%	5.0%	1.3%	4.9%
累计	530.4	64.4	738.7	1333.4	12.3	1345.7
同期累计	777.6	81.0	844.5	1703.1	19.4	1722.5
同比	-31.8%	-20.5%	-12.5%	-21.7%	-36.5%	-21.9%

出口

出口（单位：万辆）	轿车	MPV	SUV	狭义乘用车合计	微客	广义乘用车合计
9月份	24.9	1.6	65.2	91.7	0.6	92.3
8月份	21.4	0.9	66.5	88.9	0.7	89.5
同期	12.4	1.0	39.4	52.8	0.5	53.3
同比	100.5%	58.2%	65.7%	73.7%	21.1%	73.2%
环比	16.2%	73.5%	-1.9%	3.2%	-11.7%	3.1%
累计	175.0	11.5	515.2	701.7	5.0	706.7
同期累计	101.1	7.5	291.4	399.9	3.5	403.4
同比	73.2%	54.4%	76.8%	75.4%	44.4%	75.2%

总体市场-2026年9月产量、批售分析表

产量

产量（单位：万辆）	轿车	MPV	SUV	狭义乘用车合计	微客	广义乘用车合计
9月份	86.2	8.3	164.5	259.0	1.6	260.5
8月份	77.1	8.4	149.4	234.8	1.3	236.1
同期	116.5	11.7	156.8	285.0	3.1	288.1
同比	-26.0%	-29.5%	4.9%	-9.1%	-48.6%	-9.6%
环比	11.9%	-1.4%	10.1%	10.3%	20.5%	10.3%
累计	667.8	72.9	1226.0	1966.7	13.3	1980.0
同期累计	880.3	90.9	1110.1	2081.3	25.5	2106.8
同比	-24.1%	-19.8%	10.4%	-5.5%	-47.9%	-6.0%

批售

批售（单位：万辆）	轿车	MPV	SUV	狭义乘用车合计	微客	广义乘用车合计
9月份	84.7	8.0	162.2	254.9	1.7	256.6
8月份	77.8	8.3	149.7	235.8	1.8	237.5
同期	112.8	11.5	155.5	279.9	2.9	282.8
同比	-25.0%	-30.5%	4.3%	-8.9%	-41.3%	-9.3%
环比	8.9%	-4.0%	8.4%	8.1%	-3.8%	8.0%
累计	669.5	74.5	1229.5	1973.6	15.1	1988.7
同期累计	874.2	91.2	1120.9	2086.3	25.3	2111.6
同比	-23.4%	-18.2%	9.7%	-5.4%	-40.2%	-5.8%

总体市场-2022~2026年9月销量走势

新能源市场-2026年9月零售、出口分析表

零售

零售（单位：万辆）	BEV 纯电	PHEV 插电	EREV 增程	NEV 合计
9月份	76.5	23.2	8.8	108.4
8月份	69.8	22.6	8.2	100.6
同期	83.5	36.0	10.6	130.2
同比	-8.5%	-35.7%	-17.3%	-16.7%
环比	9.5%	2.6%	7.2%	7.8%
累计	523.3	183.1	69.4	775.8
同期累计	548.6	255.4	85.7	889.7
同比	-4.6%	-28.3%	-19.0%	-12.8%

出口

出口（单位：万辆）	BEV 纯电	PHEV 插电	EREV 增程	NEV 合计
9月份	33.8	19.1	3.0	55.8
8月份	32.9	17.1	1.9	51.8
同期	14.0	6.6	0.5	21.2
同比	140.8%	187.2%	478.0%	163.5%
环比	2.8%	11.9%	53.2%	7.7%
累计	233.6	140.0	15.1	388.7
同期累计	105.5	53.4	3.9	162.8
同比	121.5%	162.0%	291.0%	138.8%

新能源市场-2026年9月产量、批售分析表

产量

产量（单位：万辆）	BEV 纯电	PHEV 插电	EREV 增程	NEV 合计
9月份	110.6	42.3	12.7	165.5
8月份	103.6	39.1	10.2	152.8
同期	95.3	44.3	11.2	150.8
同比	16.1%	-4.6%	13.3%	9.8%
环比	6.8%	8.3%	24.3%	8.3%
累计	735.2	322.8	83.3	1141.3
同期累计	649.9	301.9	88.8	1040.5
同比	13.1%	6.9%	-6.2%	9.7%

批售

批售（单位：万辆）	BEV 纯电	PHEV 插电	EREV 增程	NEV 合计
9月份	112.6	42.3	11.7	166.6
8月份	103.5	38.6	9.3	151.4
同期	95.2	42.3	12.2	149.6
同比	18.3%	-0.1%	-4.0%	11.3%
环比	8.8%	9.5%	25.4%	10.0%
累计	743.9	319.4	81.5	1144.8
同期累计	650.2	304.6	91.4	1046.2
同比	14.4%	4.8%	-10.8%	9.4%

新能源市场-2022~2026年9月销量走势

1.2026年9月全国乘用车市场回顾

零售：2026年9月全国乘用车市场零售161.8万辆，同比下降28.0%，环比增长5.0%；1–9月乘用车累计零售1,333.4万辆，同比下降21.7%。

综合来看，9月乘用车市场呈现五大鲜明特征：一、总量同比深度承压，环比修复但力度有限，结构性分化极致放大，“燃油加速萎缩、新能源韧性领跑”成为市场主线，高油价持续加速“油电替代”节奏；二、燃油车全线收缩，纯燃料乘用车国内零售近乎腰斩式下滑，普混车型相对抗跌；三、新能源渗透率持续突破新高，9月新能源零售渗透率攀升至67.0%，批发渗透率达65.4%，均创历史新高，但同比增速较前期明显放缓；四、出口超越内需成为部分车企核心关注，出口有效稳住车企批发与利润，部分车企出口超50%，出口占车企总量70%的厂商快速增多，出口销量成为拉动车企增长的核心动力；五、行业库存持续低迷，高油价冲击燃油车明显，经销商新车进货更为谨慎，绝大部分经销商认为“金九银十”旺季效应明显弱于往年，经销商生存压力大、信心不足。但当前车市下行属于短期政策扰动与高基数叠加的阶段性现象，并非汽车普及的基本面见顶，大城市普及高县乡普及弱的“头重脚轻”特征尤为明显，下沉县域首购需求的蓝海依然广阔。

9月车市最突出的特征是“旺季不旺”，传统“金九”成色严重不足。往年“金九”是大盘普涨、首购换购一起释放，今年则是存量博弈下的此消彼长，燃油车需求持续剧烈萎缩。9月成为本轮车市零售降幅异常突出的月份，多重因素叠加所致：一是中秋假期提前到9月下旬，中秋当周销量明显走弱；二是去年9月部分省份补贴退出，催生集中抢补贴行情，形成较高对比基数；三是高油价持续抑制燃油车消费：9月末以来年内汽油累计上调2,375元/吨，燃油车消费意愿持续走低，而

新能源零售渗透率已攀升至67%的高位，“油电替代”加速推进；四是受AI驱动的内存与芯片价格暴涨及供给紧张等因素导致近期新能源新品增量偏慢等，这是多重因素共同影响的的结果。

9月燃油车零售同比下降43%，其中纯燃油车同比下降49%，普通混合动力车同比增长25%。燃油车中自主同比下降47%，主流合资同比下降42%，豪华同比下降41%，均无差别地受到高油价剧烈冲击。

9月新能源车零售同比下降16.7%，其中自主下降19%，主流合资增长36%，豪华下降8%，自主A00级电动车国内零售受到补贴不利的政策影响跌幅较大。

9月自主品牌零售113万辆，同比下降25%，环比增长5%。当月自主品牌国内零售份额为69.8%，同比增长2.8个百分点。总体上自主品牌在新能源市场和出口市场表现较平稳。

9月主流合资品牌零售31万辆，同比下降36%，环比增长2%。9月德系品牌零售份额12.2%，同比下降2.0个百分点，日系品牌零售份额10.7%，同比下降0.9个百分点。美系品牌市场零售份额6.3%，同比增长0.5个百分点。低销量合资车企逐步恢复活力。

9月豪华车零售17万辆，同比下降29%，环比增长12%。随着豪华车指导价的合理回归，9月豪华品牌零售份额11%，同比下降仅0.2个百分点。

出口：根据乘联数据，9月乘用车出口（含整车与CKD）91.7万辆，同比增长73.7%，环比增长3.2%，占乘用车厂商销量36%（上月38%，2025年同期19%）。9月新能源车占出口总量的60.8%，较同期大幅增加21个百分点。9月自主品牌出口达到81.2万辆，同比增长75%；合资与豪华品牌出口10.5万辆，同比增长62%。

生产：9月乘用车生产259.0万辆，同比下降9.1%，环比增长10.3%。9月豪华品牌生产同比下降24%，环比增长5%；合资品牌生产同比下降29%，环比增长20%；自主品牌生产同比下降1%，环比增长9%。

批发：9月全国乘用车厂商批发254.9万辆，同比下降8.9%，环比增长8.1%；受出口暴增的促进激励，9月乘用车批发同比增速较零售增速高出19.1个百分点。9月自主车企批发196.5万辆，同比下降0.2%，环比增长8.0%。主流合资车企批发36.1万辆，同比下降33%，环比增长9%。豪华车批发22.2万辆，同比下降23%，环比增长12%。

9月乘用车主力厂商总体批发格局持续变化，零跑汽车、极狐汽车、广汽埃安、北汽乘用车等车企实现同比20%以上高增长。9月车市集中度相对平稳，10万辆以上批发销量的乘用车厂商6家（上月7家，去年同期7家），占整体市场份额53.6%（上月59%，同期53%）。5-10万辆批发量的乘用车厂商份额占比21.2%（上月15%，同期21%），1-5万辆批发量的乘用车厂商份额占比22.8%（上月22%，同期24%）。

库存：由于9月市场运行压力较大，9月厂商批发低于生产4.1万辆，而厂商月度国内批发高于国内零售1.4万辆。今年去库存特征突出，1-9月总体乘用车行业库存下降68万辆（2025年同期下降25万辆、2024年同期下降88万辆、2023年同期下降13万辆）。

新能源：9月新能源乘用车生产达到165.5万辆，同比增长9.8%，环比增长8.3%。1-9月累计新能源乘用车生产达到1,141.3万辆，同比增长9.7%。

9月新能源乘用车批发销量达到166.6万辆，同比增长11.3%，环比增长10.0%；1-9月新能源乘用车批发销量达到1,144.8万辆，同比增长9.4%。9月常规燃油乘用车批发销量达到88万辆，同比下降32%，环比增长5%。

9月新能源乘用车市场零售108.4万辆，同比下降16.7%，环比增长7.8%；1-9月新能源乘用车市场零售775.8万辆，同比下降12.8%。9月常规燃油乘用车零售53万辆，同比下降43%，环比下降0.3%；其中普通混合动力车同比增长25%，环比增长19%。

9月新能源乘用车厂商出口55.8万辆，同比增长163.5%，环比增长7.7%；1-9月新能源乘用车厂商出口388.7万辆，同比增长138.8%。9月常规燃油乘用车出口35.9万辆，同比增长14%，环比下降3%。

1)批发：9月新能源车厂商批发渗透率65.4%，较2025年9月提升12个百分点。9月自主品牌新能源车渗透率75.5%；豪华车中的新能源车渗透率55.4%；主流合资品牌新能源车渗透率上升到16.3%。

9月纯电动批发销量112.6万辆，同比增长18.3%，环比增长8.8%；9月狭义插混销量42.3万辆，同比下降0.1%，环比增长9.5%；9月增程式批发11.7万辆，同比下降4.0%，环比增长25.4%。9月新能源批发结构中：纯电动占67.6%(同比+4.0%，环比-0.7%)、狭义插混占25.4%(同比-2.9%，环比-0.1%)、增程式占7.0%(同比-1.1%，环比+0.9%)。

9月B级电动车批发32.9万辆，同比增长21%，环比增长9%，占纯电动份额29%，较去年同期增长0.5个百分点。纯电动市场的A00级经济型电动车市场压力较大，9月A00级批发销量7.8万辆，同比下降51%，环比增长28%，占纯电动的7%份额，较去年同期大幅下降10个百分点；A0级批发销量39.6万辆，占纯电动的35%份额，同比增长10.0%.；A级电动车26.6万，占纯电动份额24%，同比下降2个百分点；从长期普及趋势看，经济型电动车增长是最有潜力的，只有入门级电动车普及才能真正拉动车市有可持续的增量。

9月乘用车批发销量超两万辆的车型有23个（上月21个），比亚迪宋（69,266辆）、Model Y（62,948辆）、比亚迪元UP（62,711辆）、吉利星愿（60,871辆）、比亚迪海鸥（38,650辆）、比亚迪海豚（35,141辆）、瑞虎7（33,832辆）、Model 3（32,418辆）、方程豹钛7（32,144辆）、启源Q05（29,064辆）、缤越（28,879辆）、奇瑞JAECOO J5（28,794辆）、五菱缤果（28,176辆）、银河星舰7（25,892辆）、MG4 EV（25,556辆）、博越（25,110辆）、零跑A10（24,457辆）、捷途旅行者（23,644辆）、深蓝S05（22,283辆）、比亚迪海豹06（22,021辆）、比亚迪海狮06（21,186辆）、星越L（21,136辆）、比亚迪元PLUS（20,609辆）。其中新能源车型占绝对主力地位。

2）零售：9月新能源车在国内总体乘用车的零售渗透率67.0%，较去年同期增长9.1个百分点，环比增长1.7个百分点。9月国内零售，自主品牌中的新能源车渗透率84.5%；豪华车中的新能源车渗透率44.9%；而主流合资品牌中的新能源车渗透率仅上升到15.9%。从月度新能源车国内零售份额看，9月自主品牌新能源车零售份额64.5%，同比下降5.7个百分点；主流合资品牌新能源车份额4.8%，同比增长1.6个百分点；新势力份额23.6%，零跑汽车、蔚来汽车等品牌拉动新势力份额同比增长了3.4个百分点。

3）出口：9月新能源乘用车出口55.8万辆，同比增长163.5%，环比增长7.7%。占乘用车出口60.8%，较去年同期增长21个百分点；其中纯电动占新能源出口的60.5%（去年同期66.2%），作为核心焦点的A00+A0级纯电动车占纯电动出口的57.9%（去年同期49%）。伴随着中国新能源车的规模优势显现和市场需求的扩张，中国制造的新能源品牌产品越来越多地走出国门，在海外的认可度持续提升。其中狭义插混占新能源出口的34.2%（去年同期31.4%）增程占新能源出口的5.3%（去年同期2.4%）。虽然近期受到外部国家的一些干扰，但自主狭义插混出口发展中国家的数量在迅猛增长，前景光明。9月新能源出口方面优秀的企业是：比亚迪汽车（175,877辆）、奇瑞汽车（85,990辆）、吉利汽车（72,893辆）、特斯拉中国（30,529辆）、上汽乘用车（29,552辆）、长安汽车（29,325辆）、零跑汽车（27,454辆）、上汽通用五菱（16,543辆）、东风汽车（10,282辆）、小鹏汽车（10,055辆）。

从海外体系建设上看，部分自主品牌的CKD出口占比较高，国际化表现优秀。其中长城汽车CKD出口占比41.9%，上汽通用五菱CKD出口占比42.1%，零跑汽车CKD出口占比34.6%，上汽乘用车CKD出口占比15.3%。

4）车企：9月新能源乘用车企业总体走势较强，比亚迪汽车纯电动与插混双驱动夯实自主品牌新能源领先地位；以比亚迪汽车、吉利汽车、奇瑞汽车等为代表的狭义插混表现持续较强，上汽乘用车、上汽大众、上汽通用等新能源增长较强。在产品投放方面，随着自主车企在新能源路线上“多线并举”策略的实施，市场基盘持续扩大，新能源月度批发销量突破万辆的厂商达到22家（同比多2家，环比多3家），占新能源乘用车总量94.4%（上月93.6%，去年同期93.1%）。其中，比亚迪汽车（455,113辆）、吉利汽车（188,800辆）、奇瑞汽车（126,703辆）、零跑汽车（96,167辆）、特斯拉中国（95,366辆）、长安汽车（94,147辆）、上汽通用五菱（77,670辆）、上汽乘用车（61,818辆）、长城汽车（41,981辆）、小鹏汽车（40,654辆）、小米汽车（40,015辆）、广汽埃安（39,667辆）、蔚来汽车（37,408辆）、理想汽车（31,817辆）、东风汽车（30,211辆）、赛力斯汽车（25,373辆）、极狐汽车（20,021辆）、上汽通用（18,583辆）、一汽奔腾（17,985辆）、上汽大众（13,110辆）、广汽丰田（10,241辆）、一汽红旗（10,234辆）。

国内新能源乘用车零售突破2万辆的企业品牌是：比亚迪汽车（246,816辆）、吉利汽车（119,682辆）、零跑汽车（78,202辆）、特斯拉中国（64,837辆）、长安汽车（61,732辆）、上汽通用五菱（54,810辆）、奇瑞汽车（46,860辆）、上汽乘用车（40,280辆）小米汽车（40,015辆）、鸿蒙智行（37,490辆）、蔚来汽车（37,231辆）、长城汽车（32,048辆）、理想汽车（31,817辆）、小鹏汽车（30,599辆）、广汽埃安（24,539辆）、东风汽车（20,070辆）、极狐汽车（20,021辆）。

5）新势力：9月新势力零售份额23.6%，同比增长3.4个百分点。新势力车型中的纯电动销量占比75%，较同期的70%占比大幅提升；新势力纯电动车中的10-15万级别销量占比大幅增长。自主传统车企的独立新能源品牌作为创二代的表现较强，份额达15.0%，同比增长2.3个百分点。极氪、奕派科技、埃安汽车、极狐汽车、岚图汽车等自主大集团的自创新能源品牌表现优秀。

6）普混：9月普通混合动力乘用车批发12.5万辆，同比增长51%，环比增长17%。其中一汽丰田（41,897辆）、广汽丰田（30,739辆）、吉利汽车（16,809辆）、上汽乘用车（15,831辆）、长安福特（4,056辆）、长城汽车（3,749辆）、长安汽车（3,122辆）、东风本田（2,499辆）、东风汽车（1,990辆）、广汽传祺（1,982辆）、广汽本田（1,651辆）。吉利汽车、上汽乘用车、长安汽车、东风汽车等自主混动的在海外市场异军突起。

2.2026年10月份全国乘用车市场展望

今年10月工作日共18天，与去年同期持平。由于中秋节在9月下旬，传统“金九银十”消费旺季中，10月的有效销售时间更长，终端客流有望持续回暖。宏观环境的核心特征是经济弱修复、政策以存量置换刺激为主，市场处于存量博弈阶段。国际高油价持续，用车成本处于高位，燃油车消费超预期低迷。短期支撑来自国庆车展、地方补贴、车企旺季促销；中长期约束则来自居民收入信心偏弱、价格互相竞争带来的观望情绪。消费端首购增量暂时受阻，置换存量成为稳增长的重要支撑，购车决策从单纯看购车价格，转向由综合评估全周期用车成本、残值、智能体验、政策补贴与新品吸引等共同决定。

政策层面，今年以旧换新补贴持续发力，补贴数量预计呈现“前低后高”趋势，与去年10月补贴逐步退出形成较大反差，有利于车市稳定。出口方面，欧盟市场贸易压力加大，增速放缓趋势将逐步体现。与此同时，人口结构的三大趋势不可逆转——结婚总量中枢下移、结婚年龄后移、老龄化加速，车市增长动力正从“新婚首购”转向“换购增购+新能源升级+适老化出行”。从消费特征看，高油价继续抑制燃油车需求，“油电替代”加速，新能源渗透率在65%以上高位运行，消费者购车决策中用车成本权重持续上升。

A级车市场的纯电动化趋势明显，高油价下单车快充技术的提升将有效拉动A级电动车销量。换购需求挤压首购需求，“消费升级与消费降级退出并存”，B级及以上高端车型需求旺盛，但A级和A00级经济型电动车受复杂因素影响持续萎缩。近期部分车企积极布局老年友好型产品和出行服务，A0级电动车销量赢得较大增量。

期待未来政策支持经济型电动车发展，鼓励小型化，给低价车更多补贴，以推动下沉市场首购需求释放，为车市长期稳定增长提供结构性支撑。

3.2026年1-8月汽车行业利润率3.6%

1-8月份，规模以上工业企业实现营业收入93.09万亿元，同比增长6.6%；发生营业成本79.19万亿元，增长6.1%；营业收入利润率为5.66%，同比提高0.44个百分点。2026年1-8月，以人工智能为推动的电子行业利润1.1倍增长，上游原材料行业利润高增长，对行业总体利润改善促进巨大，汽车行业面临成本上涨和需求不强的双重压力，盈利表现较差。2026年8月的汽车生产270万辆，销售收入9,281亿元增长4.2%，成本8,313亿元增长5.3%，利润371亿元增长24%，销售利润率4%。2026年1-8月汽车生产2,031万辆，同比下降3%，收入70,062亿元增长2.9%，成本62,370亿元增长4%，利润2,534亿元下降16%，营业收入利润率3.6%。

从历年销售利润率走势来看，2024年汽车行业利润表现已显疲软，销售利润率仅4.3%，较历史正常水平大幅下降；2025年行业销售利润率降至4.1%。2026年1-8月行业销售利润率进一步降至3.6%，8月回升到4%，好于2025年12月1.8%的最低月度表现。历年8月一般是利润率较低的时候，今年8月燃油车生产稍有改善，但盈利压力仍巨大。

2026年各地大力推动“两新”政策落地实施，逐步有效释放内需活力，但汽车行业效益的改善明显落后于其它消费品。随着有色等原材料价格暴涨，加之AI导致的内存、芯片价格暴涨，汽车行业受上游挤压严重。油价暴涨，终端用户购车观望心态严重，车企运行面临着需求不旺带来的压力，汽车行业发展受到上下游两端的巨大冲击。

4.2026年1-8月中国汽车出口745万辆

2026年1-8月中国汽车实现出口745万辆，同比增长51%，8月中国汽车实现出口105万辆，同比增长37%，环比下降4%，同比走势总体较强,环比走势暂时受阻。今年的主要动力仍是高油价、中国产品竞争力提升和全球南方国家市场的持续增长。8月的英国、澳大利亚和菲律宾出口环比回落较大。

2026年8月中国汽车出口总量的前10国家：俄罗斯96,650辆、墨西哥56,549辆、巴西53,223辆、比利时50,842辆、英国45,259辆、澳大利亚38,166辆、阿联酋30,146辆、意大利29,091辆、哈萨克斯坦27,538辆和菲律宾26,983辆，其中本期较同期增量增长的前五是：俄罗斯38,025辆、巴西34,851辆、比利时22,560辆、墨西哥17,755辆和英国16,438辆。

2026年1-8月累计整车出口总量的前10国家：俄罗斯638,224辆、巴西480,403辆、英国365,672辆、澳大利亚326,938辆、比利时322,562辆、墨西哥320,844辆、菲律宾214,359辆、意大利209,258辆、阿联酋196,117辆和阿尔及利亚190,045辆，其中本期较同期增量增长的前五是：俄罗斯351,617辆、巴西287,195辆、英国168,659辆、澳大利亚128,153辆和意大利112,246辆。

海关数据显示今年全年各类车型增速分化，乘用车出口增速逐步回升到53%，客车出口增长26%，货车出口增长42%，货车的增速慢于乘用车，相对于国内的燃油货车平稳走势，近期电动货车出口较好。乘用车内部的几类主力车型表现较均衡，2026年乘用车出口表现较强的是9座以下小客车，2026年9座以下客车占比45%，其中8月达到49%。虽然特斯拉出口回落的影响较大，低速车出口放缓，但8月自主电动车出口增长较好。

2026年8月中国新能源汽车出口50万辆，同比增长58%；1-8月累计出口346万辆，增长70%的表现很好，8月新能源车出口环比下降8%。2026年8月中国汽车出口中纯电动占比28%（同比-1%），插混占比20%（同比+7%），混动占比7%（同比+1%），纯汽油车占比37%（同比-6%）。

2026年8月中国新能源汽车出口总量的前10国家：比利时48,740辆、英国37,419辆、巴西30,570辆、澳大利亚29,564辆、菲律宾25,265辆、泰国21,119辆、德国20,341辆、西班牙17,791辆、韩国17,136辆和意大利14,762辆，其中本期较同期增量增长的前五是：巴西22,542辆、比利时21,493辆、英国17,984辆、澳大利亚14,547辆和泰国9,811辆。

2026年1-8月中国新能源汽车出口总量的前10国家：巴西337,104辆、比利时307,357辆、英国270,090辆、澳大利亚237,140辆、菲律宾188,170辆、泰国175,741辆、德国115,917辆、韩国110,354辆、意大利109,100辆和西班牙106,409辆，其中本期较同期增量增长的前五是：巴西207,158辆、澳大利亚137,390辆、英国136,346辆、比利时104,694辆和泰国90,935辆。

5.2026年1-8月中国汽车进口27万辆

2026年8月进口车进口2.3万辆，同比下滑51%，环比下降48%，降幅惊人。2026年1-8月进口汽车27万辆，同比下降17%。乘用车中2026年1-8月进口轿车占比49%；8月，进口轿车占比降到38%；而进口9座以下小客占比24%的表现较好；今年以来进口四驱SUV占比为25%，8月回升到乘用车进口的46%。2026年1-8月进口混动获得增长8%的好成绩，纯电动乘用车下降37%，插混下降62%，进口新能源乘用车表现较弱。

8月进口车下滑压力仍较大。2026年8月进口最高的前10国家是：德国7,393辆、美国4,972辆、斯洛伐克3,645辆、英国2,366辆、日本2,173辆、墨西哥681辆、意大利335辆、奥地利306辆、泰国246辆和波兰67辆。其中本期较同期增量增长的前五是：美国2,070辆、墨西哥258辆、泰国246辆、泰国246辆和奥地利124辆。

2026年1-8月进口量最高的前10国家是：日本129,253辆、德国59,183辆、美国27,559辆、斯洛伐克19,004辆、英国16,315辆、墨西哥4,156辆、奥地利3,838辆、泰国2,260辆、意大利696辆和瑞典675辆。其中本期较同期增量增长的前五是：日本3,825辆、泰国2,021辆、奥地利1,841辆、墨西哥1,269辆和中国530辆。

6.2026年1-8月中国占世界汽车份额32%

根据世界汽车组织统计数据，全球汽车生产不断增长，2025年达到9,638万辆，较2024年的9,177万辆增长6%，中国占世界生产份额35.4%。全球汽车销量不断增长，2025年达到9,689万辆增长6%，中国占世界销量份额35.4%。2026年1-8月，世界汽车累计销量6,343万辆，同比增长2%。其中8月单月销量771.9万辆，同比仅增1%，环比下滑4.9%，全球车市增长动力偏弱。

2026年1-8月全球汽车累计销量6,343万辆。分国家来看，中国销量2,031万辆，份额32.0%，较2025年35.4%明显回落；美国销量1,094万辆，份额17.2%，小幅下滑；印度表现亮眼，份额提升至6.7%，成为增长亮点。从历年份额变化看，2022-2025年中国在全球占比持续走高，2025年达到阶段性高点。欧洲主要国家份额整体稳中有降，巴西、俄罗斯等新兴市场份额保持稳定。2026年前8月中国市场销量下滑，是全球份额变动的核心原因，印度等新兴市场的快速增长，一定程度对冲了中、美市场的增长压力，支撑全球车市维持小幅正增长。2026年1-8月全球汽车销量增长2%，其中印度汽车市场销量增长20%，泰国汽车市场增长16%，俄罗斯市场销量增长6%，越南增长28%。新兴市场拉动全球市场表现较好。

东升西降，除了丰田、现代起亚、铃木和塔塔等，其它国际品牌份额2026年出现较大幅度的下滑。相较于2019年，今年中国自主品牌已全面提升世界份额。吉利、比亚迪、奇瑞、上汽、长

安等自主表现较强。世界电动化发展的趋势也导致部分国际老牌车企逐步走弱。除了铃木等印度市场较好的因素促进外，其它国际品牌份额出现全面较大的下滑。

7.2026年1-8月中国占世界新能源车62%

2026年1-8月世界新能源乘用车达到1,570万辆，同比增长15%，其中8月新能源车销量223万辆增长16%，增速回到历史正常水平。2026年1-8月的世界新能源车份额达到24.5%，其中纯电动车的占比达到17.3%，插电混动达到7.5%的汽车比例。而世界普通混合动力车型销量达到8%，表现反超插混。

初步统计欧洲新能源乘用车8月32万辆同比增长33%，2026年1-8月312万辆同比增长34%。由于高关税和新能源补贴取消等因素的制约，美国新能源车2026年8月销量11万辆同比下降44%，1-8月美国新能源车销量82万，下降31%。

世界新能源车渗透率总体呈现快速提升的趋势，2022年已经达到13.1%水平，2023年达到15.9%，2024年达到19.5%，2025年渗透率达到23.6%。2026年世界新能源车渗透率24.7%。其中，德国达到33.4%，挪威达到80%，英国36%，而美国仅有7%，日本仅有4%，由此可见世界新能源发展水平极不均衡。

2026年1-8月中国新能源乘用车世界份额达到62%。其中8月达到65.3%的较好水平。从历年销量份额看，中国的比亚迪汽车世界领先，吉利汽车迅速崛起，特斯拉下滑到第三位。近期上汽乘用车和上汽通用五菱两家自主车企海外市场表现较好。2026年中国在世界纯电动车的市场份额是59%，年初因素的中国纯电动车表现暂时较差，三季度回升到62%。2026年中国在世界插电混动市场份额达到71%的高水平，8月达到74%。

2025年自主新能源乘用车海外市场销量份额达到15.8%，提升6.2个百分点。2026年自主新能源乘用车海外市场销量份额继续大幅提升，8月达到29%，较同期大幅跃升14个百分点。

本文来源：乘联分会

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

30 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

高盛认为，当前的风险在于——市场上最受追捧的单一交易（AI）——同时也是推升整体资本成本的主要来源时，一家私人公司的营收数据便足以引发股债共振。Open AI上周四已是一次预演，本周二的大行财报与CPI数据，将检验这一信号究竟只是噪音，还是真正的警示。

标普屡创新高之际，市场内部正在发生截然相反的事情。对冲基金一边抛售科技股，一边将"Mag 7"持仓推至历史峰值；信心指标跌至极端低位，而各类资产的仓位数据却在不断刷新纪录。高盛的最新周报揭示，表面平静之下，市场的结构性张力从未如此之大。

上周标普500指数上涨1.2%至7811点，再创历史新高。然而据高盛的数据，对冲基金净杠杆率仅为46.9%，处于过去一年的第2百分位；多空比进一步跌至1.565，位于五年回望的第1百分位。与此同时，科技股遭遇连续净卖出，领跌行业正是此前四周内四度蝉联最受追捧板块的信息技术。

市场结构性分歧还体现在衍生品定价上。**高盛衍生品团队指出，VIX上行凸性极度受追捧，而标普500下行保护却"极度廉价"——用其同事的话说，"VIX升至25以上的概率，几乎高于标普500下跌2%的概率"。这一异常信号表明，投资者对尾部风险的定价方向，已从担忧股市下行转向防范波动率本身的跳升。**

轮动方向：从芯片到飞机与导弹

资金流向是本周最清晰的叙事线索。高盛prime book数据显示，在过去五周内连续净卖出工业股后，**对冲基金本周以年初以来最快速度净买入工业板块（+1.8个标准差），几乎完全由做多驱动，领涨子行业包括航空航天与国防、建筑与工程、航空公司及工业集团。**

科技板块内部同样出现明显分化。半导体与科技硬件是被减持最多的子行业，软件则是唯一实现净买入的方向。高盛TMT专家Pete Callahan指出，过去一周软件跑赢半导体约800个基点，高盛软件/半导体对冲组合单周涨幅达11.8%。

此次轮动的导火索有迹可循。上周四，《金融时报》报道OpenAI营收数据令人失望，纳斯达克当日大幅下挫。高盛数据显示，周四正是科技股净卖出最为集中的交易日，兼有多头减仓与空头增加，"指向获利了结与对冲需求同步上升"。

Mag 7持仓创历史新高，信心却跌至谷底

矛盾之处在于：**对冲基金大规模减持科技股，但对最大科技股的敞口却从未如此之高。**高盛股票部门数据显示，Mag 7仓位占其美股总敞口的比例已从6月的年内低点14%迅速攀升至22%，创prime book历史最高纪录。

摩根士丹利prime brokerage数据从另一侧印证了这一判断：信息技术目前占对冲基金北美净敞口的32%，处于2010年以来的第98百分位。换言之，行业层面的卖出并不意味着低配——没有人真正减少了对这一赛道的暴露。

与此同时，基本面多空基金的表现持续承压。据高盛Prime Services周报估算，10月2日至8日期间，平均基本面多空基金下跌0.70%，而MSCI全球指数上涨0.78%，亏损"几乎完全来自阿尔法端的多空两侧损失"。年初至今，基本面多空策略回报率为11.82%，落后于MSCI的12.42%与标普500的14.45%。系统化策略同期上涨21.40%，量化持续跑赢人工判断。

财报季开幕：高标准，低奖励

财报季将于本周正式开启，大型银行率先登场。

高盛股票部门直接点明挑战所在：共识预期标普500每股盈利同比增长27%，为2021年以来最高，而中位数个股的预期增速仅为9%（上季度为14%）。这一落差背后，是美光和英伟达两家公司单独承担本季度约三分之一的盈利增长。

更值得关注的是"超预期不奖励"现象。

高盛数据显示，**上季度盈利超预期的个股相对标普500的超额表现仅为35个基点，远低于历史均值95个基点。美光录得1003%的每股盈利增速，全面超预期，市场反应却相当克制。高盛就此发问：这一"高标准困境"是否已蔓延至整个AI板块？**

银行股面临的处境尤为特殊。高盛衍生品团队指出，金融板块从高点回调幅度约为期权隐含单日波动的五倍，但市场对其财报日的定价却极为温和。摩根士丹利下跌20%，期权定价隐含涨跌幅仅为3.7%；美国银行下跌19%，对应隐含波动为3.4%。

高盛金融行业专家Christian DeGrasse指出，**市场对银行的情绪"明显转向谨慎"，争议焦点在于三季度活动放缓究竟是"短暂停顿"还是"持续下行的信号"。**

摩根士丹利的Nick Savone走得更远：美国银行股相对标普500的超卖程度已达1993年以来最高，14日RSI约为27，BKX远期市盈率已跌破十年中位数。

OpenAI事件的连锁反应：债市意外受益

上周四，OpenAI营收数据引发的市场波动不仅波及股市，也意外推动了长债价格反弹。高盛期货团队指出，长债"可能终于在本周触底"，而触发反弹的正是OpenAI相关头条。

逻辑在于：一旦AI资本开支扩张预期出现松动，此前被AI融资需求持续挤压的美债久期买盘便有望回流。此前，资产管理公司在长债上的空头头寸自9月中旬以来急剧上升，若周四的走势触发

这批空头回补，则债市在下周初或将获得进一步支撑——不过这一反弹能否持续，仍取决于周二的CPI数据。

黄金方面，本周上涨1.3%，"维持在每盎司4100美元以上"。高盛期货团队指出，系统化策略仓位已降至一年回望的第0百分位，CFTC管理资金净多头也回归正常水平，认为"增加黄金多头头寸的吸引力正在上升"。

电力：高盛眼中"最被低估的AI瓶颈"

高盛主题篮子团队将旗下"Power Up America"篮子（代码GSENEPOW）称为"最被低估的AI瓶颈"，并将这一判断建立在三个维度之上：仓位处于近两年低位、估值已回归正常、基本面依然稳健。该篮子本周上涨4.9%，独立发电商子板块涨幅达12.7%。

团队认为，市场对中期选举及电力政策政治化的担忧"正在消退"，预计未来将通过电网建设与"表后用电"方案刺激美国电力供给。高盛预测，到2030年，"表后用电"将满足全美25%数据中心的用电需求。近期关键催化剂包括：FERC就PJM大负荷框架于10月12日周一作出裁决，以及PJM相关文件与ERCOT数据中心并网审计结果。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次 VIP会员·7天畅读卡 | 大师课·入门串讲 扫码 免费领取

限免

114 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

Epoch AI报告显示，截至2026年9月，国内六家头部AI企业营收合计约百亿美元，仅为OpenAI与Anthropic的10%。极低付费率与偏低的订阅单价拖累C端毛利，而开源权重则削弱了API定价权。相比纯模型公司，大厂更易通过云服务和广告等主业实现间接变现。

中国头部AI企业的商业化进程正处于关键阶段。

根据Epoch AI最新研究报告，截至2026年9月，**阿里巴巴、字节跳动、智谱、月之暗面、DeepSeek和MiniMax六家公司的AI相关收入合计，约为OpenAI与Anthropic两家之和的10%。**报告系统梳理了国内AI企业的五条变现路径，揭示出不同商业模式背后的结构性差异。

从最新数据看，**Anthropic年化收入约650亿美元，OpenAI约400亿美元；**中国六家中，字节跳动最高约40亿美元，阿里巴巴约24亿美元，智谱约18亿美元，月之暗面和DeepSeek各约10亿美元，MiniMax约8亿美元。六家合计约百亿美元量级。值得注意的是，字节跳动和阿里巴巴的数字主要反映其模型即服务（MaaS）收入，并非全部AI相关业务。

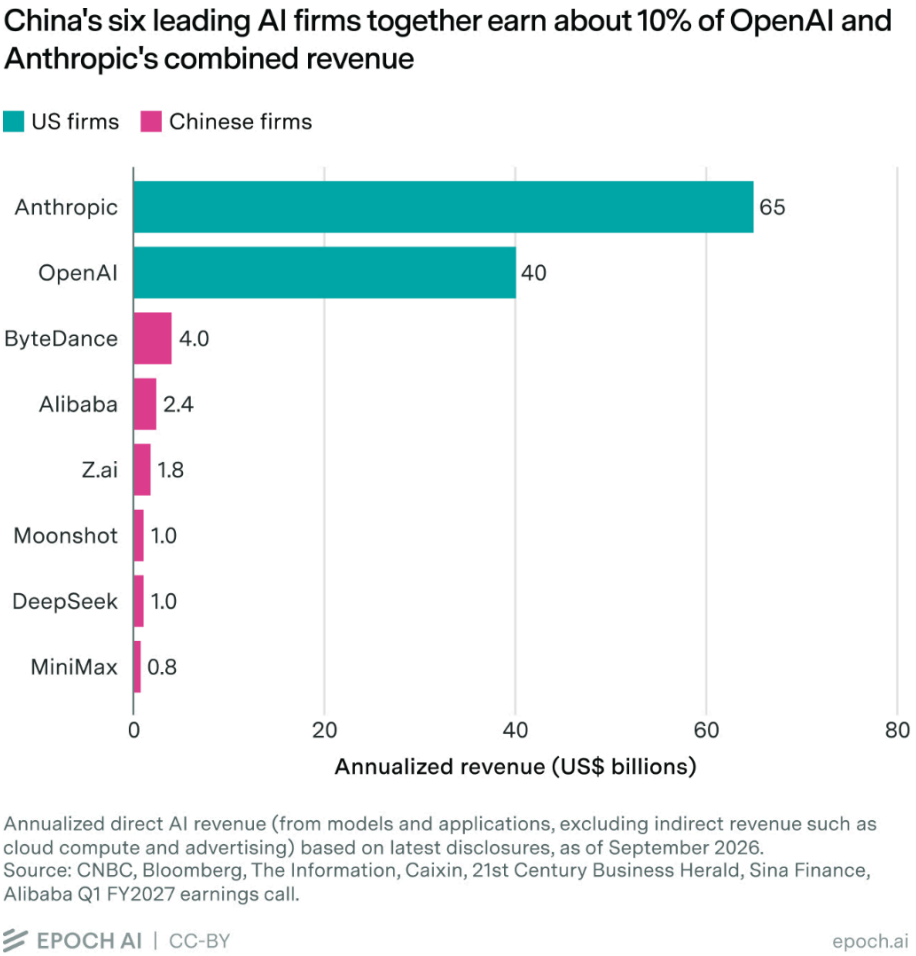

报告指出，中国AI企业目前通过五条路径变现：面向消费者的应用、API模型调用、企业与政府定制化解决方案、许可费，以及借助现有业务生态的间接变现。报告认为，随着模型能力持续提升，中国AI企业的变现策略将对其未来投入和融资产生重要影响。

C端用户规模可观，但付费转化率与毛利率双低

中国AI应用在用户规模上已颇为可观。据QuestMobile数据，**豆包月活用户约3.8亿，通义约1.7亿，DeepSeek约1.3亿。但用户规模并未直接转化为利润。**

MiniMax的数据最具参照价值。2025年前九个月，其AI原生应用（涵盖视频生成、音频生成及陪伴应用Talkie）月活均值约2760万，但付费用户仅177万，转化率约6%。该业务毛利率仅为4.7%，而同期其开放平台及企业服务业务毛利率达69.4%。

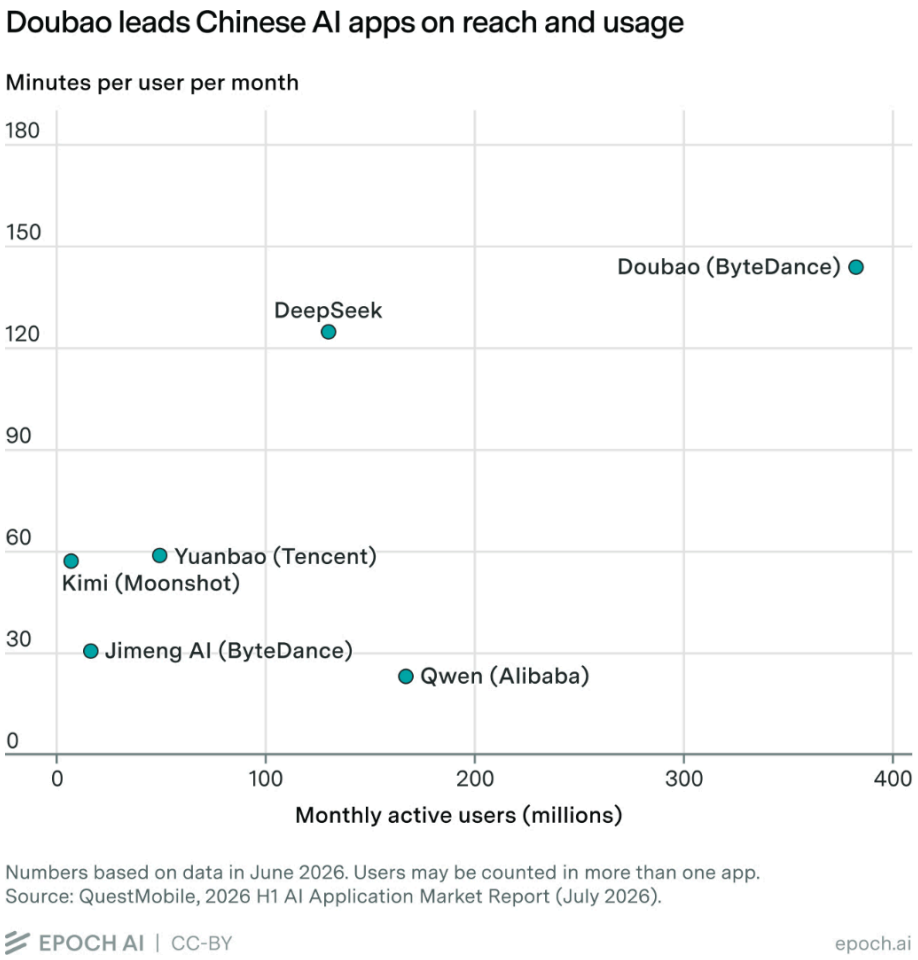

低转化率在全球范围内并非个例。据The Information报道，ChatGPT约9亿周活用户中，2025年付费用户占比约5%，OpenAI为此每年在非付费用户推理上花费39亿美元。但中国市场的付费单价更低——MiniMax旗下Hailuo视频生成标准套餐低至约55元人民币，智谱AI旗下聊天机器人VIP订阅约79元人民币，而ChatGPT Plus起步价为20美元。

广告收入可部分弥补缺口，Talkie的广告收入占MiniMax 2025年前九个月总收入的20.9%，但难以从根本上扭转C端低毛利的结构。

开源权重加速扩散，开发者定价权随之流失

中国AI企业普遍倾向于开放模型权重，这一策略有效推动了模型生态的快速扩散，但也对API业务的定价能力构成持续压制。

以智谱GLM 5.3 Flash为例，2026年8月26日，智谱以五折促销价将该模型上架OpenRouter，同步开放权重。数小时内第三方开始提供服务，一天后竞争者已达12家。至9月15日，竞争者增至26家，其中8家报价低于智谱。智谱在OpenRouter上的token份额在20天内从88%骤降至22%，日均token量下滑70%，尽管该模型整体使用量同期增长17%。

报告分析显示，**当开源模型开发者定价高于最低托管价格时，其自有API获取的token份额显著缩小。**以DeepSeek为例，其估算客户在DeepSeek模型上的总消费中，仅约8%流向DeepSeek本身。

在毛利率方面，智谱API业务毛利率2025年约为18.9%，2026年上半年提升至24.6%。DeepSeek是少数例外，其V4系列API毛利率估计在70%至80%之间，主要得益于将超过70%算力用于模型训练而非推理，并通过推理效率优化压低了单位推断成本。

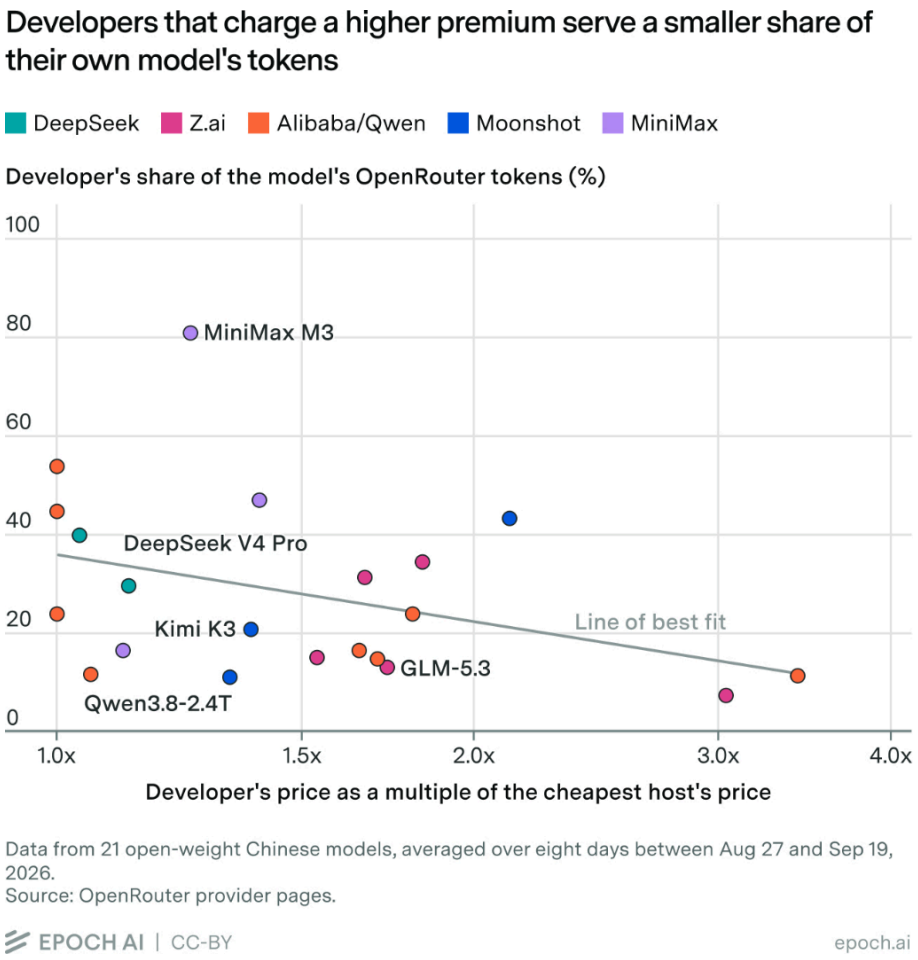

Data from 21 open-weight Chinese models, averaged over eight days between Aug 27 and Sep 19, 2026.
Source: OpenRouter provider pages.

EPOCH AI | CC-BY epoch.ai

企业与政府客户贡献有效毛利，规模化瓶颈制约战略持续性

企业及政府定制化部署是中国AI公司目前毛利较为可观的业务。智谱曾是该模式的典型代表，2025年私有化部署业务占其总收入的73.7%，毛利率约48.8%。其服务范围涵盖政府机构、国有企业和银行，2025年曾与杭州城投集团合作建设公共交通、防洪及道路桥梁维护等多个垂直领域模型。

然而，智谱已主动收缩该业务。其中报指出，"此类业务的交付和维护成本具有一定刚性，导致规模效应受限"。私有化部署收入占比从2025年的73.7%降至2026年上半年的13.5%，转而向标准化云服务和API业务迁移。

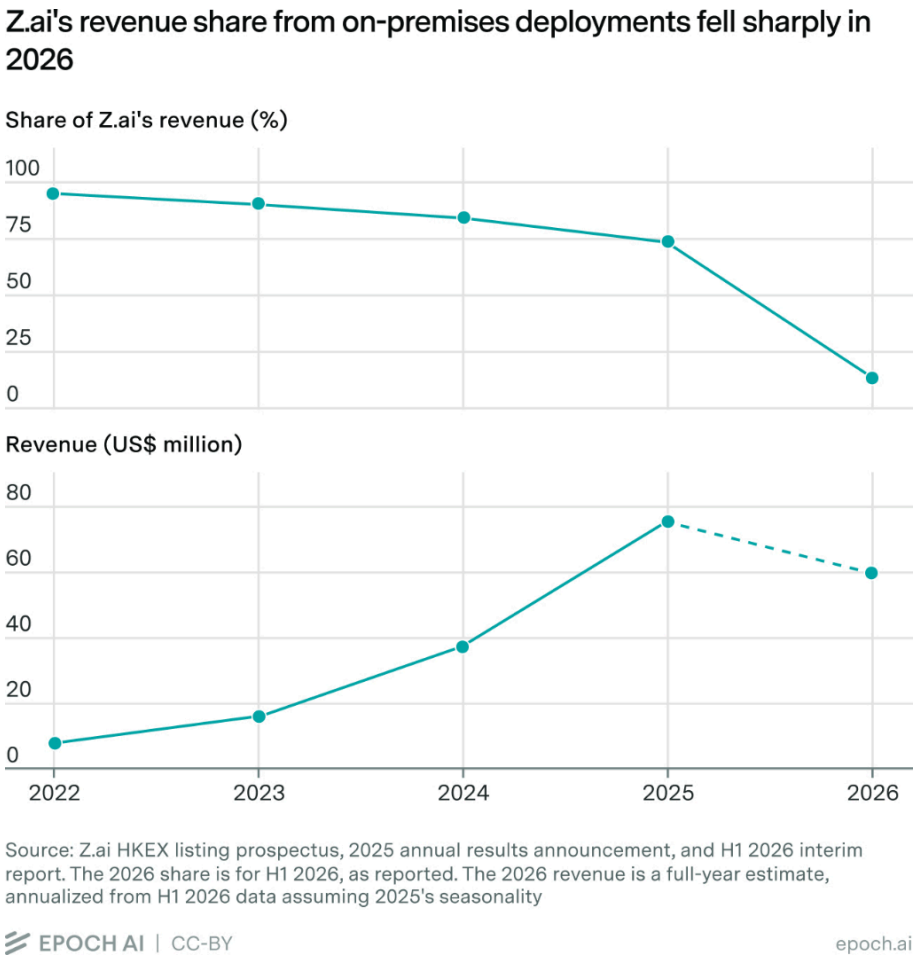

阿里巴巴和字节跳动同样布局企业与政府解决方案。2026年5月，阿里云与同济医院合作开展医学影像及研究模型训练；字节跳动旗下火山引擎则与中国国际资本公司合作开发定制化金融模型。与纯模型初创公司相比，两家大厂凭借更广泛的企业客户基础和云基础设施，在持续推进该业务上具备明显优势。

许可费模式初现，商业化路径尚待验证

许可费是潜在的变现方向之一，但目前可供参考的公开数据极为有限。

2026年7月27日，月之暗面以修改版MIT许可证开放了Kimi K3权重。该许可证规定，若被许可方经营模型即服务业务且相关主体年化收入超过2000万美元，须与月之暗面另行签署商业协议。据路透社报道，月之暗面正寻求从微软Azure、AWS及谷歌云的K3相关服务中获取最高30%的收入分成。

但该许可证在实际执行层面仍面临不确定性。**首先，模型权重的版权归属在法律上尚无定论，美国版权法通常要求人类创作，模型权重由自动化训练过程生成，其可版权性存疑；其次，追溯特定模型的商业用途及被许可方收入存在实操难度；第三，内部使用场景明确豁免于协议要求之外。**

智谱亦在探索类似路径。据中国星际市场消息，亚马逊已于2026年10月将智谱GLM-5.3接入Bedrock，并将与智谱进行收入分成，智谱同时已与多家国内外主流云服务商签署收入分成协议，但具体分成比例尚未披露。

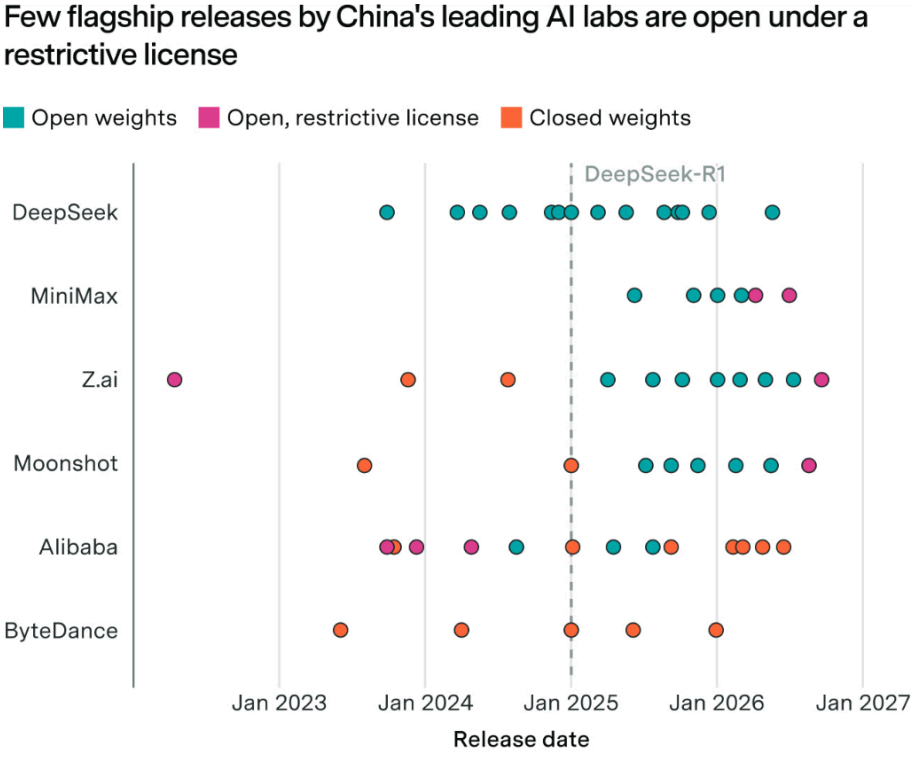

Each dot is a flagship language model released by one of China's six leading AI developers. The sample only covers each firm's flagship line (Qwen, Doubao, GLM, DeepSeek-V/R, Kimi, and MiniMax-M), excluding small, specialty, and preview releases as well as non-language models. "Open, restrictive license" means that a model's weights are downloadable but commercial use is subject to conditions.

EPOCH AI | CC-BY epoch.ai

大厂借AI撬动主业，间接变现空间更为可观

对于阿里巴巴和字节跳动而言，AI模型的战略价值在相当程度上体现于对现有业务的拉动效应，而非模型本身的直接变现。

算力需求是最直接的受益方向。AI应用的广泛普及拉动了云计算需求，阿里巴巴2026年第二季度AI云及算力服务收入达71亿美元，同比增速加快至45%；AI相关产品收入达18.24亿美元，已连续12个季度实现三位数同比增长。阿里巴巴集团CEO吴咏铭表示，"蓬勃发展的开源模型生态系统推动了对云计算服务的更大需求，形成了良性循环"。

广告生态是字节跳动受益最为突出的领域。Seedance视频生成模型显著降低了短剧内容的制作成本。2026年第一季度，约12.8万部微短剧上线，超过95%为AI生成内容，而2025年全年上线数量约为3.3万部。短剧制作方随后在抖音投放广告以获取流量，据一位行业知情人士透露，AI短剧广告主在字节跳动平台的日均消费峰值约达1.2亿元人民币。

据IDC数据，字节跳动旗下火山引擎2025年承担了中国公有云大模型token调用量的49.5%，其MaaS收入2025年约为2.21亿美元，字节跳动近期已将2026年目标上调至40亿美元。

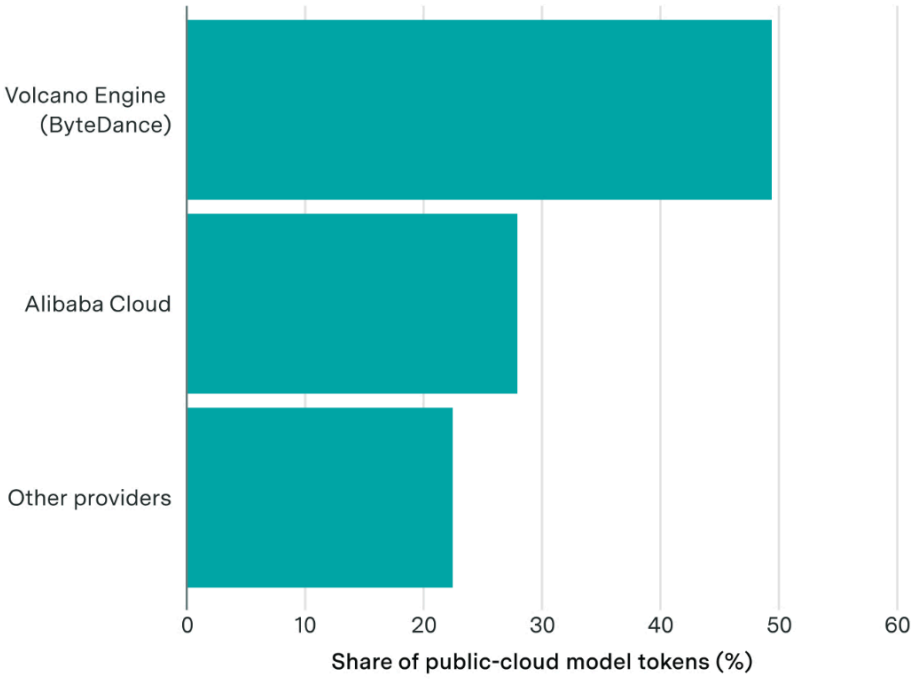

Shares of external customers' token usage on public-cloud model services in China, 2025. Model token counts exclude usage by providers' own products, such as ByteDance's Douyin, Doubao, and Jimeng.
Source: IDC, China AI Software Semiannual Tracker, 2025H2 (May 2026 summary).

EPOCH AI | CC-BY epoch.ai

变现路径加速分化，纯模型公司面临模式抉择

Epoch AI的报告并不指向悲观结论。对拥有云基础设施、广告平台和内容生态的大型科技公司而言，AI模型更多扮演放大器角色——通过带动算力销售、提升平台粘性和广告变现，间接实现商业回报。

对纯模型公司而言，路径选择的张力则更为突出。开放权重换来了生态话语权和模型扩散速度，但也将定价权拱手相让；闭源模型有助于维护利润空间，却可能在生态竞争中失去先机。修改版许可证和云平台收入分成是新兴的调和方案，但其规模贡献仍有待时间验证。

报告最后认为，随着中国AI模型能力持续提升，观察各家公司如何在扩散与变现之间寻求平衡，将成为判断中国前沿AI行业格局演变的重要维度。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

196 收藏 分享到:

写评论

请发表您的评论

表情 图片

发布评论

3 条评论

islands
54分钟前 中国

国内的ai付费用户本来就少，最花钱的那一批用的还是用codex或者cc的

0 回复

八闽望族之冠
1小时前 中国上海

A I应用明天继续大涨

0 回复

> **scott** 1小时前 中国北京
>
> 回复 **八闽望族之冠:**
>
> 今天大涨了吗
>
> 0 回复

摘要：

下跌逻辑多重叠加：江西云母矿两大项目相继获批，远期供应宽松预期强化；9月供需数据偏弱令"旺季证伪"交易逻辑持续发酵；大厂疑似下调排产消息更重挫市场信心。分析人士指出，短期锂价偏震荡，年底非洲出口禁令及国内供给扰动能否带来供需错配，将成企稳反弹的关键。

截至10月12日上午收盘，碳酸锂期货2701合约报跌8.37%，收于108800元/吨，跌破11万元关口，刷新年内低点。

相较该合约今年5月中旬超过20万元/吨的高点，不足半年间已近乎实现“腰斩”。

现货市场方面，据上海钢联数据，10月9日优质碳酸锂市场价格区间在120500元—122000元/吨，电池级碳酸锂市场价格区间在118500元—122000元/吨，工业级碳酸锂市场价格区间在116500元—120000元/吨。

“碳酸锂行情调整受多方面因素影响，一是远期供应宽松施压，二是旺季需求走弱逻辑强化，此外外围利空仍未明显出清，资金端也存在异动。”卓创资讯富宝锂电分析师琚存泉提及，江特电机2026年10月11日公告称，公司收到国家矿山安全监察局下发的《江西省宜丰县茜坑锂矿300万吨/年采矿工程安全设施设计审查意见书》，原则同意该安全设施设计通过审查。该矿理论lce产能在1.5万吨/年，加上前期宜春市生态环境局于10月8日再次发布枧下窝锂矿环评拟受理公示。云母矿产能释放预期强化，市场对远期供应进一步宽松的担忧上升。

同时，9月碳酸锂供需数据偏弱，“旺季证伪”交易路径强化，进入10月后，整体供需并未有明显好转，且今日传出大厂下调排产，尽管尚未证实，但仍加剧了市场对基本面的担忧情绪。

此外，上周锂电权益板块逆势走强，主要在于10月排产较强与固态电池政策。但今日资金有明显流出，对期货市场情绪形成联动压制。

上海钢联锂行业分析师彭宇哲认为，9、10月磷酸铁锂产排调研分别环比增长4.74%、3.61%左右，铁锂厂家受原料供应、产线调试、盈利压力等多种因素，爬坡节奏有所放缓。四季度碳酸锂需求端反馈偏强，磷酸铁锂与电芯排产预计维持高位。供给释放受矿端供应节奏、成本边际产量等因素影响，节奏较预期偏缓。不过库存去化幅度虽趋势性收窄，但绝对水平仍向低位收敛，对价格形成一定支撑。

琚存泉则分析，综合来看，当前碳酸锂远未走出前期“旺季需求端持续偏弱+供需宽松、远期供应放量预期+外部风险未完全出清及资金情绪转弱”的交易逻辑。需继续关注节后需求恢复情况、外围动向及产业链实际库存变化。

光大期货此前分析显示，津巴布韦计划于明年1月生效的锂精矿出口禁令没有延期的理由。津巴布韦信息部长尼克·曼瓜纳称，本国锂矿企业已有充足时间为2027年1月的本地加工最后期限做好准备。津巴布韦正效仿其他非洲国家，希望从本国自然资源中获取更高附加值。月度平衡来看，供给增速并未如期放量，需求仍维持小幅增长态势，月度去库速度或有望环比上月加速。当前市场情绪较弱，现货暂未表现出短缺且需求弱预期压制。

预计碳酸锂市场短期仍偏震荡运行，需要关注新的基本面、宏观变量，但鉴于仍然快速去库的节奏中，如若基差持续走强，叠加年底非洲、江西等供给扰动带来供需错配，锂价有望企稳反

弹。而需求预期本身是既难证实又难证伪的，对这部分的预期修正较难，将导致价格高度有限，但如若负反馈出现，则价格仍将继续下挫。

本文来源：证券时报

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

104 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

2 条评论

路人
40分钟前 中国江苏省

还讲预期。就现在这些券商预期胡乱写，交易所规则随便排的世道还讲预期。一个破枧下窝复产炒作了1年多，还在说枧下窝。
难得一个中国可以有定价权的东西，继续折腾到弱化吧。人的贪婪真的是可以毁灭长期的利益

0 回复

见闻用户
1小时前 中国福建省

这些内容是胡扯，首先能改变碳酸锂价格是碳酸锂需缺性和适用性是否长久（被其它矿物质所代替总量下降），其次是中欧贸易谈判削减新能源车出口欧洲数量，其次是储能是否获得大量需求，还有电池（是否新能源电池）出口退税于2027年1月1日起取消，这些因素才是左右碳酸锂价格走势，国内碳酸锂（锂辉矿矿藏资源上升到全球第二占16%）矿资源还需要国外大量进口。

展开全部

2026-10-12 15:46

0 回复

摘要：
双方在2025年基础上达成向上安排，确保中国企业的出口空间和稳定增长，照顾了双方产业基于现实的合理关切。任何措施都不会专门针对中国产品，更不能歧视性对待中国企业。中方获得配额将不会低于欧方的其他任何进口来源地。

问：近日，中欧双方在贸易投资磋商机制下就混动汽车、电动汽车贸易进行了深入讨论，避免了局面升级，一些外媒对混动汽车贸易安排的数量等相关细节进行猜测，请问中方有何评论？

答：中欧在贸易投资磋商机制下持续对话，达成多项成果共识，有利于维护稳定、平衡的中欧关键贸易伙伴关系。双方本着相互尊重、平等协商的原则，就混动汽车、电动汽车贸易进行了密集磋商，平衡处理经贸分歧和彼此关切。

关于混动汽车，双方强调并确认了三项基本原则。一是尊重事实。根据欧盟统计局数据，2024年欧盟自中国进口混动汽车10.7万辆，2025年为30.2万辆。双方在2025年基础上达成向上安排，确保中国企业的出口空间和稳定增长，照顾了双方产业基于现实的合理关切。二是非歧视。**任何措施都不会专门针对中国产品，更不能歧视性对待中国企业。中方获得配额将不会低于欧方的其他任何进口来源地。**三是合规。双方确认贸易安排应符合世贸组织规则。**中方保留在世贸组织框架下诉诸争端解决、要求贸易补偿等一切权利。**这三项基本原则贯穿始终，是保障中国企业合法权益的坚实基础。

关于电动汽车，中欧双方于今年1月实现反补贴案“软着陆”，欧方发布了价格承诺通用指导文件。就此，欧方将继续推进电动汽车案企业价格承诺相关程序，以及其它复审程序。

在对等互利基础上，上述共识有力维护了中国企业的实际利益，避免了中欧贸易摩擦局面升级，也为中欧双方提供了稳定、可预期、可持续的贸易投资环境，有助于双边经贸关系稳定、平衡和健康发展。

来源：商务部新闻办公室

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲 扫码 免费领取

限免

摘要：

亚马逊以29倍预期市盈率低于沃尔玛的37倍，尽管其收入增速是后者三倍——这一倒挂折射出市场对AI资本开支能否兑现的深层焦虑。AWS CEO Matt Garman披露，AWS年收入已达1600亿至1700亿美元，增速37%，企业上云、AI原生初创公司与智能体工作流正同步驱动三重增长曲线。

亚马逊的AI资本开支正在成为估值分歧的核心：市场担心投入过快、回报过慢，但AWS释放的需求信号显示，云迁移、AI推理和智能体工作流可能正在重塑其增长曲线。

据《The Information》周日报道，亚马逊目前以低于沃尔玛的预期市盈率交易，尽管其收入增速预计约为后者三倍。高企资本开支和AI投资回报的不确定性，是投资者给予折价的主要原因。

这场争论的焦点，是亚马逊约2200亿美元级别资本投入能否被未来需求吸收。在a16z最新访谈中，AWS首席执行官Matt Garman称，**AI相关需求巨大，资本开支短期内不会放缓，AWS还在为初创公司保留稀缺GPU容量。**

对市场而言，问题并非亚马逊是否拥有AI机会，而是这些机会能否转化为足够的收入、利润和现金回报。AWS访谈解释了需求来自哪里，但尚不能证明这轮投入已经兑现。

亚马逊股价折价之谜

据《The Information》援引Koyfin数据，**亚马逊当前约为29倍预期市盈率，沃尔玛则约为37倍。沃尔玛今年预计收入增速约为5.6%，仅为亚马逊预估增速的约三分之一，但其估值溢价已持续约18个月。**

这一倒挂反映了市场的主要担忧：亚马逊正在大幅增加资本开支，主要用于扩建AI数据中心，与Alphabet、Meta共同押注AI基础设施需求，但这类投资的回报周期仍不清晰。若AI需求释放慢于预期，高额资本开支可能持续压制盈利表现。

不过，分部估值分析也指出，亚马逊的业务结构可能没有被充分定价。亚马逊市值约2.8万亿美元，但其资产组合包括AWS、在线零售、广告和内容业务。材料显示，亚马逊在线零售销售额今年上半年同比增长13%，广告业务年收入约800亿美元，增速保持在20%至25%，AWS的独立价值保守估计不低于1万亿美元。

换言之，市场对亚马逊的折价并不只是在评估零售业务，而是在为AI资本开支的不确定性、综合性集团结构以及回报可见度不足定价。估值低并不自动意味着低估，但它为重新审视AWS的增长逻辑提供了切入点。

AWS的增长逻辑正发生三重变化

在a16z访谈中，Matt Garman称，AWS收入约为1600亿至1700亿美元，同比增长37%。他认为，AWS仍处在长期机会的早期阶段，原因包括大量工作负载仍留在本地部署，企业每天产生的计算需求持续增加，以及AI带来的新增顺风。

第一层增长来自企业上云。Matt Garman表示，云迁移和AI需求正在同时推动AWS增长。对大型企业而言，AI并不是单一模型调用，而是与数据、存储、安全、权限和生产系统绑定的工作负载。这使AWS不只是提供GPU容量，也提供企业将AI投入生产所需的完整基础设施。

第二层增长来自初创公司。Matt Garman称，AWS估计目前约30%至40%的收入来自曾经是初创公司的企业。AI原生初创公司与早期互联网公司不同，它们从第一天起就可能需要大规模算力，训练模型成本高，融资和估值规模也更大。AWS因此选择为初创公司保留部分稀缺GPU和AI加速器容量，而不是将所有资源卖给大型前沿实验室。

他还表示，AWS以某种方式满足了大约60%的相关请求，有时是在不同区域、不同时间或不同配置下交付。AWS未来几年还将购买200万块Nvidia GPU。这些表述显示，AWS试图通过容量分配维持客户生态，而不是只押注少数大客户。

第三层增长来自智能体工作流。Matt Garman称，越来越多团队希望云环境不仅适合人使用，也适合代理使用。AWS正在围绕Agent Core、Bedrock、AWS Context等服务，优化代理跨数据湖、数据库和服务调用的能力。代理会关注尾部延迟，也会产生短周期、可快速创建和释放的计算需求。

这可能改变云基础设施的使用方式。过去云资源主要服务于人类开发者和企业IT团队，未来代理可能会自动写代码、调用数据库、管理基础设施，并在沙箱和临时权限下执行任务。对AWS而言，这意味着新的推理、存储、安全、权限管理和计算需求。

此外，定制芯片也被AWS视为支撑这套逻辑的关键。Matt Garman称，Graviton在成本和性能上均有约20%的改善，Trainium已成为Bedrock大部分流量的运行基础，Trainium产能大致售罄至明年年底。若这些芯片能改善单位算力成本，它们将有助于提高AI基础设施投资的经济性。

真正需要验证的是关键指标

对投资者而言，关键问题仍然是回报，而不是需求叙事本身。AWS管理层描述了多个增长来源：企业上云、AI推理、初创公司训练需求、智能体工作流和定制芯片。但这些机会最终必须体现为更高收入、更好利润和足够的资本回报。

Matt Garman在访谈中强调，AWS的容量并未高度集中在一两个客户身上，通常单一客户占比处于个位数甚至更低水平。他还表示，**在核心计算、存储和推理上，企业客户已经看到正回报。**这些说法有助于缓解市场对AI泡沫和客户集中度的担心。

但从股东角度看，这仍不等同于亚马逊自身的投资回报已经被证明。约2200亿美元级别资本开支需要持续高利用率、稳定客户需求和可控成本来支撑。若智能体应用停留在试验阶段，或企业部署速度慢于预期，资本投入可能先于收入确认，对盈利形成压力。

因此，市场真正需要验证的指标，是AWS收入增速能否延续，Bedrock、Trainium和Agent Core等服务能否扩大付费使用，企业能否从有人参与的代理流程走向更自主的生产工作流，以及这些新增需求能否覆盖数据中心、芯片、电力和供应链投入。

亚马逊的AI回报可能被市场低估，但市场的犹豫并非没有理由。AWS访谈提供了需求来源和技术路径，《The Information》的估值分析显示当前倍数存在重新审视空间。最终能否修复折价，取决于亚马逊能否把AI基础设施投入转化为可见、可持续的财务回报。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

72 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

掉期市场显示，未来六个月韩国央行累计加息50个基点的概率约为70%，Gama Asset Management等机构预计，韩国政府削减债券发行带来的短暂反弹难以持续，3年期和10年期国债收益率将重返四年高位。

韩国债券市场近期的反弹，正面临越来越大的压力。

韩国政府主导的干预措施效果趋于消退，与此同时，市场对韩国央行（BOK）进一步收紧货币政策的预期持续升温。10月12日，据彭博报道，韩元掉期市场目前定价显示，未来六个月韩国央行累计加息50个基点的概率约为70%。

Gama Asset Management和Hana Securities等机构的策略师预计，韩国3年期和10年期国债收益率将恢复上行，重新测试上月触及的四年高位。

反弹难以为继

韩国债市此前的反弹，主要源于政府的干预信号。当局上月警告将采取干预措施，并将10月债券发行规模削减5万亿韩元（约37.4亿美元），收益率随之沿整条曲线回落。

但策略师普遍认为，这一反弹缺乏持续性基础。

Gama Asset Management全球宏观组合经理Rajeev De Mello表示："我对韩国债券越来越谨慎。通胀仍高于韩国央行的目标，进一步收紧政策的可能性较大。如果全球债券抛售持续，韩国收益率将越来越难以抵御上行压力。"

De Mello预计，韩国10年期国债收益率将回升至4.6%左右——这一水平上月曾出现，也是2022年以来的最高点。3年期收益率则可能从周四的3.98%攀升至4.1%。

加息预期主导市场

韩国央行已连续两次会议加息，将基准利率升至3%，以应对通胀压力和加速增长的经济。今年8月，韩国央行发布的六个月点阵图显示，21个点位中有10个集中在3.25%。

市场目前将目光锁定在10月22日的议息会议，以及随后的11月会议。

Hana Securities固定收益策略师Park Junwoo表示，在波动性高企的背景下，将收益率下行解读为趋势性变化"为时过早"。他预计收益率将在11月议息会议前后见顶——届时他判断央行将在10月按兵不动后于11月加息。

"我认为现在不是买入的时机，但如果3年期收益率重新回到4%以上，届时值得再度买入。"Park Junwoo说。Hana Securities目前对韩国和美国债券均持低配。

政府干预能否托底？

尽管收益率上行压力持续，政府的干预意愿仍是市场的一道缓冲。

受半导体行业税收红利提振，韩国财政部长Lee Hyoung Il表示，政府可能进一步削减计划中的债券发行规模，以遏制收益率的过度波动，并可能启动紧急回购操作。

不过，LS Securities固定收益分析师Woo Hye-young认为，投资者不必急于行动。"等到11月央行点阵图出炉再买入韩国债券，也不会太晚，"她说，"如果11月点阵图显示利率预期更高，我会更加谨慎。"Woo Hye-young预计收益率最终将在年底前回落。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

46 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：

Alexandr Wang加入Meta后，带领不足200人的团队，历时7个月打造出消费级AI产品Muse。在Llama 4受挫后，他判断Meta的真正优势在个人AI而非编程，主张以单一视角打磨极致体验。Muse发布后他亲自用表情包营销，并以超200名直接下属的扁平结构反对官僚主义，相信AI能激活每个人的自主性。

Scale AI联合创始人Alexandr Wang加入Meta不到一年，带领一支不足200人的团队，打造出Meta押注消费级AI的核心产品Muse——这背后，是一次押注方向的豪赌，一段7个月的打磨，以及一个关于如何让产品真正“破圈”的故事。

10月11日，Meta首席AI官Alexandr Wang在美国知名博客《David Senra》中分享了其团队打造Muse的过程。

Llama 4受挫，扎克伯格亲自出手

2025年，Meta的Llama 4未能达到公司预期。

Wang描述了当时的背景：“Llama 4没有走在Meta作为公司想要的轨道上，这在内部确实是一次失望，而且是在AI变得越来越重要的时刻发生的。”

正是在这个节点，扎克伯格主动联系Scale AI联合创始人Wang。两人此前通过他人引荐相识，但往来并不频繁，大约每六个月才通一次话。这一次，扎克伯格发来一条消息：“你有时间打个电话吗？”

最初的对话并不明朗。Wang说，几次通话都是扎克伯格在问他“你觉得我们应该做什么”，并不清楚最终会走向何处。直到谈及收购条款，Wang才意识到事情的分量。最终，双方在大约五六周内完成了整个交易：**Meta持有Scale AI 49%的股份，Scale继续独立运营，Wang本人及少数核心成员加入Meta，出任首席AI官。**

为什么是“个人AI”，而非写代码

加入Meta后，Wang和扎克伯格面临一个关键的战略选择。

2025年初，**Anthropic的Claude和Opus在编程领域遥遥领先，整个行业的共识是：编程智能体才是最重要的AI应用方向。**

Wang对此有不同判断。他说，他告诉扎克伯格的第一件事就是：“Meta其实是一家非常特殊的公司，因为Meta的产品代表的是人们想做的事——**Instagram、WhatsApp、Facebook，这些都是你选择跟随自己兴趣、爱好和朋友的地方。**”

在Wang看来，Meta拥有触达35亿日活用户的分发能力，天然指向的是消费端AI，而不是工作、编程这类场景。

> 消费AI、个人AI，这始终是我们认为Meta能做出真正特别东西的领域。不是工作，不是写代码，是个人。

这一判断最终落地为扎克伯格在2025年6月发布的内部备忘录《个人超级智能》（Personal Super Intelligence），Wang与Nat Friedman等人参与共同起草。

Nat Friedman的“恐惧与狂喜”，点燃产品方向

真正让团队确认“个人AI智能体”这一方向具有颠覆性潜力的，是一次来自Nat Friedman的亲身体验。

Friedman是MSL（Meta Super Intelligence Labs）的核心人物之一，也是GitHub Copilot的早期推动者、Stripe的早期客户。Wang说，他是整个MSL内部第一个深度使用OpenClaw（一款个人AI智能体产品）的人。

“他的体验，我只能形容为介于恐惧和狂喜之间。”Wang说。Friedman告诉Muse，他想多喝水，AI随后通过监控摄像头观察他是否在喝水，并告诉他“干得好”。

Friedman随后分享了一个专为心理自我分析设计的提示词（prompt）。Wang第一次使用时，同样经历了强烈的感受：

> **相当于把三年的心理治疗压缩进了一个时刻——它可以访问我的邮件、我的照片，把所有信息整合在一起，我在这个过程中非常脆弱。**

2026年2月，Wang和Friedman各自写下备忘录，分别发给Meta董事会。Wang写道，他认为超级智能体“在某种程度上是消费端产品的终点”。Friedman的备忘录中有两句话后来成为产品核心原则：“法律即条款”（the clause is the law）和“信任是必须的”（trust is a must）。

7个月、200人、一件“艺术品”

备忘录提交后约一两周，团队完成了第一个原型，并向董事会演示。Wang说，最终版Muse里的许多核心设计，在那次最早的原型里已经存在——包括吉祥物“Jolly”和早期版本的Muse Charm。

但从原型到产品，是一段“漫长而痛苦”过程。

> 原型有时可以运行，有些时刻很神奇，但大多数时候无法正常工作，会不断崩溃。我们要把它变成一个高度可靠的、精心打磨的消费产品。

这段历程历时7个月，参与人数不足200人。

Wang说，团队为此建立了一张包含逾百项具体行为和能力的电子表格，为每一项设定了"阻断发布"的门槛和"合格"标准。每次模型迭代后都会对照检查。“我们有很多检查节点，比如80项是绿灯，但20项还是红灯，我们知道那还不够好。”他说，第一个全部绿灯的检查节点是Musepark 1.3的特别训练版本。

他把这个过程比喻为打磨一件艺术品：“它是一件艺术品，需要强烈的单一视角和高度专注，才能把它做成一个完整、美好的体验。”

在Wang看来，Muse能成功而其他早期个人智能体产品失败，原因正在于此。

> **大型组织的产品往往变成不同人观点和愿景的弗兰肯斯坦——每个产品经理都想往里塞点东西，最后混在一起就是一杯果昔。用户能感觉到。**

他特别强调，Muse的产品视角主要来自Nat Friedman：“如果说有一个人的单一视角贯穿了整个Muse，那就是他。”

表情包营销：让Meta重新变酷

Muse发布后，Alexandr Wang在X平台开始了一轮密集的“失控式”发帖——用产品吉祥物Jolly（一个小人形象）制作各种表情包，引发大量转发。

他坦言，这并非完全有意为之。

> 我在开会时脑子里突然冒出一个梗，就觉得必须发出去。有时候我在和同事吃饭，突然想到了，就发了出去。

他的逻辑是：互联网奖励风险，奖励意外，奖励让人意想不到的东西。

Nat Friedman在那段时间的内部会议上说：“我以为我们会从中学到很多关于Muse用户的信息，但实际上我们只是学到了很多关于Alex脑子里在想什么的东西。”

Alexandr Wang认为，这种营销方式实际上推动了增长——尽管他承认很难精确追踪。

他还批评了竞争对手的广告策略：

> Anthropic做了大规模户外广告，全是关于他们自己。OpenAI的广告就是两个人坐在桌子旁边。我不明白这是什么意思。你有数百万个真实使用案例，你的广告只需要展示产品能为用户做什么，就这么简单。

超过200个直接下属，反对官僚主义

在Meta，Alexandr Wang有超过200名直接下属——几乎所有加入MSL研究团队（内部称为TBD）的研究员都直接向他汇报。

他解释，这不是管理结构，而是一种反官僚主义的声明。

> 这些都是极其出色的人，他们已经证明了自己能做出卓越的工作。我不需要微观管理他们。他们需要的不是管理者，而是一个优秀的环境。

他将自己在Meta的角色定位为“教练”，而非Scale AI时期的“创始人”：

> 在Scale，我对公司每一件小事都有强烈的看法，公司是我努力和视角的产物。在Meta，我更多是在思考：如何创造一个让这些出色的人能够做出最好工作的环境？

AI能给每个人一个“他们梦想中的成年生活”

谈及Muse的长期意义，Alexandr Wang表达了一个更宏观的判断：

> 我真的相信个人AI代理作为一种长期形态。人类天生有欲望、有梦想。AI和个人代理将成为帮助我们实现这些梦想的机制和桥梁。

他认为，大多数人在进入职场后，雄心壮志会被逐渐消磨：

> 我们都变成了某种意义上的僵尸。我们失去了自主性，失去了野心。

他在一篇帖子中写道：

> 世界迄今为止是由少数狂热者塑造的，他们设法让自己的意愿成为现实。但我们从未见过全人类每个人的自主性都被完全激活的世界。

他认为，Muse代表的方向，正是朝着这个世界迈进的一步。

访谈全文如下：

Building Muse, Working with Mark Zuckerberg & The Future of AI | Alexandr Wang, Meta
2026年10月11日 · David Senra

Alexandr Wang是Meta的首席AI官，也是Scale AI的联合创始人。本期节目中，我们聊到了历时七个月打造Muse的全过程、Meta为何押注个人AI助手而非编程助手，以及Mark Zuckerberg和Nat Friedman如何塑造了这款产品。Alexandr还分享了Zuckerberg在Meta Llama 4受挫后如何将他招募入职、他为何在Scale工作九年后选择离开，以及他如何围绕小团队、顶尖人才和极简官僚主义重建Meta AI实验室。此外，我们也探讨了如何用表情包让产品病毒式传播、拥有单一视角的重要性，以及Alexandr为何相信AI能让每个人都有能力追求更宏大的抱负。

第一章：Muse背后的愿景

David： 给我讲讲Muse的历史吧。

Alexandr： 首先要从我们创立Meta超级智能实验室（MSL）时的愿景说起。实验室成立之初，Mark发布了一份备忘录，我、Nat Friedman以及其他几位同事都深度参与了这份文件的撰写，备忘录的名称叫《个人超级智能》。核心想法是：我们如何构建真正让所有人生活变得更好的强大AI？我们如何打造一种能够从整体上提升人类体验的东西？

那份备忘录提出了许多设想，基本上也预示了Muse最终的走向，尽管当时还只是非常早期的构想——那是2025年6月，智能体（agent）在任何实质意义上都尚未出现，那年夏天的AI还处于一个完全不同的阶段。但那就是我们想要构建的方向，是MSL的使命，也是我们想要将一切推向的终点。

随后，我们就开始着手构建模型了，因为任何前沿模型的端到端开发流程都需要好几个月：你需要搭建整个技术栈，制作数据集，对模型进行预训练，再进行后训练，还要为此构建完整的工程支撑体系——这是一个非常漫长的端到端过程。

第二章：发现个人AI智能体的潜力

Alexandr（续）： 今年年初，这整条"生产线"开始运转，Opus 4.5的发布让包括我们在内的很多人看到了智能体的未来，将智能体的潜力真正推到了台前。那时是今年年初，Anthropic（原文为openclaw，以下统一译为正确名称）正处于上升期。

我的密切合作伙伴Nat Friedman，我认为是MSL内部最早使用并尝试Claude（原文为OpenClaw，指Anthropic的Claude）的人。他的体验，我会形容为介于"恐惧"与"狂喜"之间——他真的是全情投入，完全信任它。

他讲过一些故事，在Stripe Sessions的一次采访中也提到了这些经历：他告诉自己的Claude他想多喝水，于是Claude就通过安防监控镜头监督他喝水，然后表扬他"做得好"。他有无数这样令人咋舌的故事，也让人意识到：这里有某种相当神奇的东西正在发生。

我记得Nat跟我说过的一句话，也是我印象最深的：他说，"我觉得这里真的有什么。" 早期采用者Nat Friedman的判断，是相当可靠的信号——他是当年Stripe最早的客户之一，在很多开源开发者工具上也都是先行者，还参与创建了GitHub Copilot以及其他许多项目。

所以这是一个明确的信号：个人智能体领域，显然有某种相当神奇的东西。当你真正信任一个个人智能体、真正把它带入你的生活，它能为你做的事情太多了。

听完所有这些令人惊叹的故事之后，我开始深度使用它。有好几周的时间，我们两个几乎每一个空闲时刻都在跟各自的Claude对话，沉浸在探索个人智能体可能性的过程中。

第三章：在一次AI会话中经历三年的心理治疗

David： 你最初的反应是狂喜还是恐惧？

Alexandr： 那时Nat构建了一个提示词（prompt），用来做一种全面的心理自我分析，会分多个波次进行深度心理探测。他基本上是专门为此写了一个提示词，供你配合Claude使用。那也是我用自己的Claude最早做的事情之一——相当于把大概三年的心理治疗，全部压缩进了那一个瞬间。

David： 等等，我很好奇，你拿到Claude的第一次机会，为什么第一件事就是做这个？

Alexandr： 我下载、安装好之后，Nat就在旁边，他说："你应该试试这个。"我就说行，照他说的做——然后就发生了那段疯狂的体验。

David： 多说说那段"疯狂的体验"。

Alexandr： 就是非常、非常强烈。确实就像三年的心理治疗，因为是连续多轮的深度心理探测——它有关于我的其他信息，能访问我的邮件、我的大量照片，还能去查找其他信息，然后把所有这些整合在一起。整个过程中，我非常脆弱。

那是二月份。我们两个都得出了同一个结论：这里显然有非常特别的东西正在发生。我们当时各自写了一份备忘录——也都通过相关渠道提交给了Meta董事会，因为当时正好是董事会季。

我在备忘录里写道，我认为在很多层面上，这是终极的消费者产品形态，超级智能体作为消费品，某种程度上代表着一个清晰的终点。Nat则写了两份，标题非常令人印象深刻——"the clause the law"和"trust is a must"——这两份备忘录最终定义了我们构建这些产品的核心理念。

第四章：历时七个月打造Muse

Alexandr（续）： 我们在二月份得出了这个结论：这里有非常重要的东西。随后我们组建了团队，在大概一到两周内就做出了一个原型，并向董事会演示——这是一个非常快速的迭代周期。最终Muse成品中的许多设计决策，在第一个原型中就已经存在了：Jollybot（那个欢快的小吉祥物）在那里，Muse Charm的早期版本也在第一次演示中就出现了。不是所有的想法、所有的功能标签都在，但很多已经具备。

从那之后——那是二月份——我们在七个月后发布了产品。这七个月是真正艰难的过程：从一个时好时坏、充满魔力却大多数时候无法正常工作、不断崩溃的原型，走到一个高度可靠的、精心打磨的消费级产品，一个我们有信心向消费者世界交付的作品。这是一段漫长而相当痛苦的过程。

David： 在进入那个阶段之前，我想先回到一件事：你们在一到两周内做出了原型，然后展示给董事会——Mark在这整个过程中扮演什么角色？

Alexandr： 他和我们所有人一样，同步经历着这款产品带来的那种"狂喜与恐惧"。他在各种采访中都提到过这段经历：他把它用于家庭中的各种事务，跟孩子们一起使用，也用在了他的MMA训练上——让它观看自己训练的视频，让它给他提供改进建议。

那段时间，员工会议上甚至形成了一种风气——在Meta的很大一部分团队中，开会时大家都会分享各自在使用智能体时经历的奇妙故事，那是在二月份。

现在回想这整个周期，确实很有意思，因为Claude现象明显有一个峰值，然后就消退了。它没有持续下去，我认为很多人都经历过这种感受：有那些神奇的瞬间，但大多数时候它并不好用，各种问题层出不穷，然后慢慢就淡出了。

所以构建这款产品，很大程度上的核心课题就是：如何把它打造成一个真正可靠的消费者体验，让你有信心把它放在最终数十亿人面前，并且有把握大多数人都能获得出色的体验。

David： 为什么你们能做到，而Claude的开发者做不到？

Alexandr： 首先，我们非常尊重Peter Sainberger（原文为Seinberger，应为Sainberger，即OpenClaw/Anthropic创始人）以及所有为Claude做出贡献的人。我认为Peter绝对是一位有远见的人，他那颗美丽的大脑里能诞生出Claude这样的东西，是一种魔力。

让Muse如此出色，或许并不glamour的原因，就是把模型加产品的整体体验打磨到真正出色所需要的那种持续打磨和细节雕琢。我们在模型本身上进行了非常非常多的迭代。我们将整体的模型路线图，对准了构建个人超级智能这个大方向，具体来说就是个人智能体这个方向。

David： 多说说这一点，以及这如何让你们区别于其他竞争对手。

第五章：Meta为何押注个人AI

Alexandr： 回到那个时刻其实很有意思。如果你回到今年年初、二月份，Opus和Claude在编程领域遥遥领先于所有人，并且正在爆发式增长。那是Anthropic全面崛起、席卷整个行业的开端，那是一个非常令人警惕的时刻：哦，天哪，他们在编程领域的领先优势太大了——再加上他们有Mythos，领先优势十分明显。

当时业界的主流观点是：编程智能体是唯一重要的产品形态，或者说唯一重要的技术能力。整个行业有一种巨大的惯性，驱使所有人都去跟进这个用例、去跟Anthropic在编程智能体上竞争。

但正是因为我们的亲身经历，以及围绕个人智能体这一想法所形成的信念，我们选择退后一步来思考。我认为我们之所以一开始就做个人超级智能，也是因为我们相信Meta在这一方向上拥有独特的优势。

David： 我们现在就聊这个。

Alexandr： 我告诉Mark的第一件事——甚至在Scale和Meta的合作协议落定之前——就是：如果我们拥有AGI或ASI，Meta实际上是一家非常特别的公司。

AI的承诺之一是：我们每个人的生活中，都有"想做的事"和"不得不做的事"这两类事情。AGI的承诺是，我们将几乎不再需要花时间在"不得不做的事"上，因为AI会替我们处理大量这类事务，我们就能把所有时间花在"想做的事"上。而在我看来，Meta的产品代表的正是我们所有人"想做的事"：我用Instagram、WhatsApp或Facebook，这些产品让我追随自己的兴趣、爱好，关注我喜欢的人、我在乎的朋友。Meta的产品矩阵，恰好涵盖了"我们想要花时间的事情"这个领域。

从长远来看，Meta在这一切中是一个不可思议的赢家。这是我关于Meta和超级智能最早形成的信念之一，这些想法最终都融入了"个人超级智能"这一概念。

你可以从几个角度来看：一是公司的基因传承——Meta的传承是连接人与人的友谊和家庭，帮助人们发现自己的兴趣，这些都是非常人性化的东西。二是商业视角——Meta每天有35亿用户在使用其旗下应用，Meta注定要成功的自然领域就是消费者AI，而不是工作，不是编程，而是个人。

David： 对，确实如此。

Alexandr： 所以，个人智能体、个人AI和消费者AI，始终是我们认为Meta能够做出非凡贡献的领域。

由此，我们来到了2026年初：你们有了原型，获得了内部支持，所有人都知道Mark已经认可了这件事，然后你们开始了七个月艰难的产品打磨工作。

是的。当时有一层阴影笼罩着我们：个人智能体"来了又走"——我们始终认为那是因为体验还不够完美、还不够精致。但我们知道，这是我们在开发产品过程中必须认真对待的问题。

我们将模型开发路线图的首要任务之一，聚焦在构建个人智能体能力上。我们有一张很长的电子表格，列出了一百多项模型必须具备的具体行为和能力，才能支撑起理想的个人智能体。整个过程非常细致入微。随着时间推移，我们为所有这些项目建立了评估标准，弄清楚如何训练模型在每一项上都做到非常非常好。我们还会定期审查这张表格，找出我们做得不好的地方，确保持续改进。就是这样一个极其细致的过程，不断地打磨模型的每一个边角，让它能够支撑起整个产品。

David： 这也是Meta的文化吗？这种对产品持续打磨的文化？

Alexandr： 是的。Meta文化的很大一部分就是：一旦你知道该衡量什么，就有非常有才华的人去优化这些指标，打磨所有细节，把这些事情做到极致。在前AI时代的消费者产品时期，这体现在如何优化转化率、如何优化推荐率、如何优化新用户引导流程的每一个环节；在AI时代，至少从Muse开始，这很大程度上体现在打磨模型的每一个细节，使其完美契合产品需求。

第六章：Mark Zuckerberg对改进产品的执念

David： 你看过Jeremy Stern在Colossus上发表的那篇关于Zuck的深度报道吗？

Alexandr： 我看到了这篇报道。老实说，它太长了，我没读完。

David： 有15000字。我刚把Jeremy请上节目了，他是我最喜欢的作者。

Alexandr： 我看到那期节目了。我认为他现在是全球撰写企业家和投资人人物报道写得最好的人，真的是世界第一。

David： 在那篇报道里，Zuck谈到了他相对于Elon和Sam Altman的优势，他说：我的技能组合非常低调无聊，但我非常擅长组建团队，然后在很长一段时间里持续、缓慢地改进产品。相比Elon和Sam Altman，我不会失去对公司的控制权，也不需要再融任何钱，所以我可以就这样做很长很长的时间。你在聊这七个月打磨Muse的时候，那段报道就在我脑海里不断浮现。

Alexandr： 我觉得完全正确。这需要极大的耐心——七个月，也许听起来不算太长，但在AI时代，七个月相当于传统行业的十年。这对我们所有人来说都是如此。但我真的要给Mark很多credit，这需要很大的耐心、克制，以及对整个过程的信任。

你可以回去翻Mark在这整段时期——从二月份一直到九月份——每次财报电话会议上说的话，他都会提及我们正在构建个人智能体，我们也没有真正刻意隐瞒，我们在建，也在谈，但公司内部整个这段时间疑虑重重。华尔街主流叙事是：天哪，Meta烧了这么多钱，他们在AI上到底能不能成事？

David： 不止这些，更多的是：Zuck赢不了AI。这句话被反反复复说了很长时间。再回到Jeremy Stern那篇报道——他开始私下和Zuck的竞争对手聊，包括一位曾经在Zuck手下工作、现在去了竞争对手实验室的前研究员，那个人说："我不想和他们竞争，因为Mark就像……"我想那句话是"Mark就是那个该死的终结者"——他就是不会停下来。这位研究员还谈到了Zuck的一个超能力：他永远对产品的现状不满意，总想着持续改进；但他又不是那种会破坏团队化学反应的混蛋——他确实是个独裁者，但不粗鲁，不会伤害团队。他在报道里特别提到，团队凝聚力对他来说极其重要。

Alexandr： 我觉得这些都是真的。Muse最神奇的事情之一，就是我们花了相当长的时间来打磨所有细节，然后才最终推出产品。我认为个人智能体这个产品领域，是一个架在刀刃上的品类：如果它能可靠地创造这些神奇体验，它就有潜力成为有史以来最伟大的消费者产品之一。但你面对的是模型，面对的是非确定性的东西，面对的是可能出错、可能不可靠的智能体——一旦用户有了不可靠的体验，他们就会觉得这是垃圾。

这是一个需要把产品质量和价值做到某个临界点，才能真正引发广泛共鸣的事情。

第七章：Meta如何判断Muse已准备好发布

David： 我想多聊聊这个过程。我好奇投入了多少资源、团队有多大、有多少人参与其中。你们有没有数据，比如说：我使用Muse，九次是很棒的体验，两次是不一致或很糟糕的体验，然后我就流失了？

Alexandr： 你能从今年初几乎所有其他智能体产品上看到这种情况——几乎所有人都流失了，原因就是不可靠。

我们对Muse做了大量用户测试，组织了很多轮全新用户从零开始下载使用的测试，观察这个过程是什么感受。Muse的一个核心前提——我认为也是真正落地的地方——是它与大多数人体验过的消费者AI产品截然不同：它不是一个聊天机器人，它是一个智能体，能为你做智能体才能做的事情。对开发者来说，这可能是旧闻，他们已经使用智能体一段时间了；但对大多数人来说，仅仅是这个跃升过程就需要解释和非常周到的引导。

我们也确实做过不同模型版本的测试和持续的AB测试。产品体验对模型质量极其敏感——对模型完成任务的可靠性、与用户沟通的可靠性、在需要指引时主动确认的可靠性，都极其敏感。

David： 但你们怎么知道它已经准备好发布了？

Alexandr： 一部分是非常量化的：回到那张有一百多行的电子表格，我们为每一行设定了"发布门槛"和"良好标准"。我们有很多检查节点，绿色通过了80行，但20行仍然是红色——我们知道这还不够好。直到我们有了第一个在所有行都通过绿色的模型检查点——那是一个专门训练的Musepark 1.3版本。

这是非常量化的部分。还有体验层面的部分：我们试用了这个模型，能感受到它比之前迭代过的任何版本都好得多。

David： 回到你说的七个月，有多少人在做这件事，模型工作和产品工作加在一起？

Alexandr： 总共不到200人。在大公司的标准里，这其实很少。

回过头来看，我觉得这挺了不起的：整个高管团队、所有人都知道这可能是Meta今年最重要的产品之一，但我们组织上有那种克制——保持了一个真正小而专注的团队，没有让它膨胀成大半个公司都在参与的项目，因为我们知道这是一件单一的艺术品。它需要强烈的主见和专注，才能将其凝聚成一个完整而美好的体验。

David： 多说说这一点。为什么你把它称为一件艺术品，并且说需要单一的视角或主见？

第八章：为何伟大的产品需要单一视角

Alexandr： 我认为来自大型组织的产品，有一种常见的批评，而且这种问题现在也开始在很多AI实验室蔓延：产品会变成一个弗兰肯斯坦式的怪物——几乎像是Cronenberg式的大杂烩——由一堆不同人的视角、愿景和信念拼凑而成。这有点像PM地狱，每个产品经理都有一件他们想塞进产品里的事，最终全部混在一起，变成一杯混合了各种东西的奶昔。

作为用户和消费者，你能感受到这种差异——你能感受到一款产品是由很多不同的人做的，他们各有各的目标，然后生硬地拼在了一起。Muse必须做到完全相反：只有一个清晰的主见，一个我们要向世界呈现的完整统一的体验。

David： 我喜欢你说的这一点。这完全是巧合——我不知道这期节目什么时候会发出来，但我们录制这期节目的时间，正好是Steve Jobs逝世15周年。说到那种拥有单一视角的消费产品，你当然会首先想到Steve。我读过所有关于Steve和苹果历史的书，在我的另一个播客Founders上也做过大概15到20期关于他们的节目。我最喜欢用来描述Steve影响力的一句话是：苹果就是Steve Jobs拥有了一万条命。产品体现了他的品味、他的视角、他的主见——他想在世界上看到

的东西，就是最终用户得到的东西。在Muse这个案例里，Nat Friedman功不可没——他的品味和审美感知，最终决定并塑造了这款产品的面貌。

David： 你们有公开谈论Muse的用户数据吗？

Alexandr： 我们说过"数以百万计"，我也转发过其他人发布的图表，那些图表暗示Muse是有史以来增长最快的消费者AI应用。

David： 但你不肯说具体数字。

Alexandr： 我们说了"数以百万计"。

David： 是啊，百万也可以是几亿，那也是百万。所以你只是没说前面那个修饰词。

第九章：用表情包让Meta重新变酷

David： 我想聊聊你在X上的状态——我是出于善意这样说的——你最近有点"不稳定"。自从Muse发布以来，你的公开发推风格有了明显变化，这是一种营销策略吗？这是在搞什么？

Alexandr： 这里有几件事同时发生。

David： 这肯定比你在Scale做的事有趣多了。

Alexandr： 肯定有趣。过去几周是我职业生涯中最快乐的一段时光，没有之一。有这么几件事在发生：

首先，我们觉得想办法让Muse突围很重要。现在是AI产品、创业公司、新版本、新功能不断轰炸的时代，对大多数人来说就是一股信息洪流。我们开过大型团队会议专门讨论这件事：我们需要突围而出——Meta有很强的分发能力，可以确保所有人都知道这件事，但这还不足以让它以一种有趣、有文化感染力的方式真正引起世界的关注。

碰巧，我在生活中认识了一些沉迷于网络梗图和互联网文化的朋友——我亲切地称他们为"我那些神经质的朋友"——他们整天都在思考梗图和互联网。

David： 我认识一些沉迷于Muse的人，他们也沉迷于你的X时间线，他们确信你有一百个Muse在帮你想梗图。

Alexandr： 实际上，X时间线上每一条推文都是我自己写的。有一段时间，我真的很难在开会时集中注意力，因为我脑子里一直会冒出梗图的想法，然后就忍不住想发出去。有一次我在跟同事吃晚饭，吃到一半我突然说："等等，我想到了！"然后就发了另一条梗图。感觉有点像当年做工程师解bug——你能感受到那种"这个会爆"的直觉。

第二件事，我觉得重要的是：我们怎么让Meta重新变酷？不知道为什么，Meta尽管拥有Instagram、Facebook这些无与伦比的文化软件，却在相当长的时间里不够酷。所以我想让Meta变得酷、有趣、有点好玩。

至于那种"放飞自我"的感觉，是随着时间自然发生的。Muse刚发布时，我主要是在分享各种有趣的使用案例，转发了几十个人的Muse使用场景。后来有一段时间，我发了几条没怎么想就发出去的推文，结果那几条反而效果很好。

David： 你有没有见过那个"思考时间越长效果越差"的规律？

Alexandr： 完全对上了。我有些推文真的没想多少，发完连手机都没看，几个小时后一看，"哇，这条火了。"然后我想起了一件关于互联网的事——虽然不是刻意的，但我记起来：互

联网奖励风险，奖励意外，奖励人们意想不到的东西。于是我就放开了。

我很多同事对此有点惊讶。Nat有一句话，在那整个发梗图的周里，他在好几个会议上都说了同一句话："我以为我们会从中学到很多关于Muse用户的信息，学到人们如何使用Muse，但实际上我们只是学到了很多关于Alex大脑的东西。"

那段时间真的很开心，我感觉在调用我多年积累的互联网知识。我觉得这实际上对增长产生了真实的影响——这有点滑稽，虽然我们没有精确的追踪数据，很难确定。

David： 我肯定认为有影响。我到处都在听到关于它的事，而且我听说的那些人也都下载了应用，现在都在用。

继续说你之前的话——你们有分发能力，但这不代表你们能让人们真正回来、让产品真正有粘性。那么你们是怎么做到的？

Alexandr： 我认为关键在于：你怎么让用户尽可能早地抵达"哇，原来可以这样"的时刻？这款产品天然适合做到这一点，因为如果有人从来没用过AI智能体，它能做的很多事都会让你大吃一惊。

另一个关键是：如何捕捉那些人们拥有"哇"时刻的故事，并用这些故事来让产品传播得更广。

David： 但你们是怎么用这些故事的？你们也没有在打广告吧？

Alexandr： 我们投放了一些广告。但说实话，最开始就是我一直在转发有趣的案例——只要看到有人用Muse做了有趣的事，我就引用转发。

我一直搞不懂Anthropic和OpenAI的广告为什么做得那么差。记得Anthropic做过大规模户外广告，全是在讲他们自己；OpenAI也一样，广告里只有一个图标（我觉得大多数人都认不出那是他们的logo），然后写着"ChatGPT"，画面就是两个人坐在桌子旁。我在想这到底是什么意思？你们有那么多使用案例，广告只需要展示产品的好处，就这么简单。

David： 你有几百万个现成的素材，直接拿来跑广告就行。这种错误如此基础，却被反复犯，真的很有意思。

Alexandr： 我们在构建Muse以及在Meta做其他事情时，反复回到的一个问题就是：为什么别人会在意？他们不在乎你，不在乎你的公司。每个人都是出于自身利益行动的。

有一本很老的书叫《科学广告》，写于二十世纪初，作者是Hopkins，是一位顶尖的文案撰稿人，曾经是二三十年代最赚钱的广告公司创始人之一。他在书里说：这不只是关于广告，而是关于不会改变的人性。他的核心观点是：你的广告在谈论你自己，谈论你的产品，谈论"我有这个东西，来买吧"——但人们对这些不感兴趣，他们都是自利的。你只需要做一件事：展示这件事能为他们做什么，以此开头。那些汲取了这些写于二十世纪初的想法的人，在五六七十年代乃至今天，都凭此建立了庞大的公司和广告帝国。

Alexandr： 对，完全正确。几个关键洞察是：第一，世界上大多数人不在乎OpenAI或某某研究，不在乎这些公司或我们的研究，他们在乎的是这能为他们做什么。我们还有一个礼物，就是那个吉祥物——那个小小的欢乐角色。

我记得那条让我意识到"这个有搞头"的推文：我开车上班途中，用Muse生成了一张小人儿拎着公文包的图，然后发了条推文："MFW（My Face When）周一去上班"。我当时就觉得这是我近期最好的推文之一，然后我意识到，可以把他放进各种各样的情境里。

我还意识到，怎么创造出与你见过的任何其他产品营销都截然不同的惊喜时刻。我不记得上次有人用大胆的梗图来营销一款产品是什么时候了，我甚至不确定有没有人这样做过。但我感觉：哇，这是一件我们可以用这个小家伙来做的事，这是有趣的，这会引发普通人的好奇心。

第十章：与AI智能体建立信任

David： 好，但这也许能让他们了解产品，甚至下载应用。但应用装到手机上之后，你怎么让他们持续使用？

Alexandr： 真正爱上这款应用的用户，会经历一个循环——我们早在二月份就观察到了这个模式：你先给它一个小任务，它做到了，你想："哇，它做到了。"然后你给它一个稍微大一点的任务，它也做到了，你想："哇，它能做那个，也能做这个。"然后你给它一个稍微更复杂的问题。这有点像和AI智能体之间的信任跌落游戏——刚开始你不太信任它，但你很好奇，所以你给它一个小小的尝试，然后稍微更大一些，再更大一些。

我跟大学生聊的时候，有些人使用AI的方式已经是完全的信任跌落了：他们就是录语音、把想法全部倾倒给AI，然后信任AI去整理所有想法、给他们清晰的计划和行动项目。我认为成功的Muse用户，关键就是让他们进入这种信任跌落的过程，先用它做一件事，再一件更大的事，再更大，并且每一次都成功。

David： 我很好奇这在多大程度上是口碑驱动的。显然，和你聊完我无论如何都要下载这个应用。但真正让我产生兴趣的，是一个朋友给我发来的截图，展示他在用Muse做什么。他把身份证落在一架FlexJet飞机上了，然后他对Muse说：我不想参与这个过程，你来想办法把这张身份证取回来，我的身份证在那，我在这，帮我把中间所有步骤都想清楚。然后Muse安排了快递，把身份证取到了，还通过了他的安保系统，送到了他办公室。这就是最好的营销：只是三四张截图，来来回回，他说"我不想参与，你来搞定一切"，然后Muse一步步把事情搞定了。

Alexandr： 是的。现代产品营销在很大程度上是由截图驱动的。一款现代消费产品，必须能在截图中说话——截图必须能传播，无论是通过群聊、口碑还是社交媒体。我认为这一直是一个重要的驱动力。这不是刻意设计的，但我觉得截图中那个小人儿的存在是个大事——有Jolly或者你的Muse形象出现在截图里，立刻就传达了"这是一张Muse截图"，这是你能拥有的最好的营销。

第十一章：人类野心的未来

David： 那么你自己整天都在用Muse吗？你个人的使用习惯是什么？

Alexandr： 我主要是设置了很多工作流，然后在会议间隙使用。我在工作中本应认真听、认真参与和他人互动，所以实际使用上，我设置了一堆工作流，把它当作一个"第二大脑"来用。

David： 你在写的那篇文章里说过这个，那篇文章很短，上次看的时候已经有550万次浏览了。你形容Muse的方式非常好——"如果每个人都有一个超越自身的第二思维"。我认为这从哲学层面上来说，是关于"当你拥有强大的AI时，做人意味着什么"最有趣的问题之一——那种关系究竟是什么样的，不同的人有不同的想象。最让人担忧的场景当然是AI凌驾于我们之上，我们只是被动跟随。但在你说下去之前，你自己的看法是什么？

Alexandr： 我真的相信Muse，相信个人智能体作为一种长期产品形态。人类天生就有欲望、愿望和梦想，这是人性。我认为AI和个人智能体，比如Muse，将成为让我们实现这些梦想、不断实现梦想的机制和桥梁。然后人类会梦想更大、更大、更大。孩子们会梦想拥有自己的星系，然后Muse帮他们实现那些梦想。

Bezos在某封股东信里写过一句话，大意是：消费者最美好的品质是他们永远对现有的选择抱有"美好的不满足"。我认为这是我们与AI关系的一种模式。还有其他模式——我认为AI将越来越多地参与科学发现的过程，越来越深地嵌入经济的各个部分。但我确实相信这种形态会长期存在：每个人都有一个AI支持他们去追求自己想要的东西。

David： 所以你把AI看作是能移除"生活中的累赘"的东西，对吧？那些我们不想做的事情。你在那篇文章里说，世界充满了守门人和障碍，而Muse可以帮你绕过这些，不再耗费你更多的时间，让你真正专注于你想做的事情。

Alexandr： 我认为Muse能给每个人那种他们在童年时梦想过的成年生活。每个孩子都有宏大的想法和梦想，当他们想象自己的人生时，他们会想象成为宇航员、拯救地球、改变世界——他们想得很大。

但出于种种原因，当人们完成学业、进入职场、在某个岗位工作了一段时间之后，那些希望、雄心和做梦的能力，就被慢慢抽空了。

David： 不是抽空，是被打烂了。生活把它们从他们身上打走了。作为成年人，我认为我们都低估了自己有多像行尸走肉的程度。我们失去了主体性，失去了——我认为"雄心"是个很好的词。AI广泛意义上的承诺，也是通过Muse这样的产品能给的承诺，就是让这种状态从童年就延续下去：小时候有大梦想，用AI来帮助实现，然后梦更大、再实现、再梦更大，在整个人生中体验一种不断上升的主体性——而不是主体性丰盛然后被碾碎。

Alexandr： 你刚才说的让我想到，你之前提到了你和Nat经历的那次令人不安的AI心理审查，来一波一波的深度心理探测。那要是反过来呢？不是那个，而是真的给你更多自信——让你明白世界是可塑的，你用足够的精力和驱动力去追求，你真的可以改变身边的世界。

我认为这是最厉害的创业者所展现的特质：他们梦大，实现了，再梦更大，也许在某个方向上耕耘十年，实现了，再梦更大。Elon显然是一个典型，Mark也是。很多标志性的创业者都有这样的亲身经历。我认为这应该成为每个人的常态。

悲剧性的地方在于，对大多数人来说：你有更大的梦想和想法，进入了企业职场，慢慢变成行尸走肉，某个时候你想重新去追求梦想，但真的太难了，因为你有那么多承诺——也许有了家庭，也许有各种牵绊——你几乎陷入了那种"行尸走肉"的状态，难以自拔。

还有一件关于Muse的事，在我们聊到Scale AI以及你与Meta合作的决定之前，我想先说。你在那篇文章里写道："迄今为止，世界是由少数以某种方式让自己的意志成为现实的狂热者所塑造的，但我们从未见过人类在每个个体的主体性都完全开启的状态下是什么样子。"

我认为我所描述的那个世界——每个个体的主体性都在一生中不断增强、都有能力实现自己的愿望和梦想——会以一种非常美好的方式变得疯狂。它会很有意思，充满艺术性和酷劲，走进世界的不同角落，会非常多元，简直难以想象：几十亿人突然因为充裕的智能资源而拥有了创造非凡事物的能力。我认为这就是承诺的一部分。在我脑海中，它有点像《瑞克和莫蒂》里的跨维度有线电视，以某种方式真实地在人类世界中显现出来——那会真的非常了不起。

David： 我一直在脑海中回响那部动画的一句台词：宇宙会吃掉聪明人。

第十二章：改变一切的那通Mark Zuckerberg来电

David： 好，我想往回追溯。我个人很好奇的是：你创立了Scale AI，在运营Scale AI，然后有一天Mark Zuckerberg联系了你，说——我假设他说的是——"嘿，能打个电话吗？"能告诉我这是怎么发生的吗？

Alexandr： 我想那条消息大概就是："嘿，你有时间打个电话吗？"

David： 你之前和Mark有过交情吗？有没有花时间相处过？

Alexandr： 我有一个朋友叫Alex Schultz，其实从Scale差不多一岁的时候就认识他了，那是在旧金山认识的。他现在是Meta的首席数据官，之前是Meta的长期高管。他在大概2021年或2022年把我介绍给Mark，那时Mark对AI越来越感兴趣，Scale也在AI领域做了很多工作。

我记得从介绍到第一次见面被安排下来，大概花了整整一年时间。为什么这么久？Mark的日历显然是极度繁忙的，他有无数事情要处理，而且他非常擅长排优先级——他会在真正重要的事情上花大量时间，有时候甚至花太多时间。他能做到这一点，同时还能做一个好父亲、好伴侣，唯一的方式就是无情地排优先级。

后来我们又见过几次，我会找他请教，能从Mark Zuckerberg这里得到建议，当然是非常了不起的事。我记得那时候，我在WhatsApp上问他问题，他会回非常长的消息，我当时很困惑：他怎么有时间写这么长的回复？后来我才明白，他只是写得极快，对大量WhatsApp消息都能快速写出严密而详尽的回复，这是他令人印象深刻的一项能力。

Meta是Scale的重要客户，在这次事件之前，我们大概每六个月左右交流一次，这是我们互动的频率。然后是那个电话，一开始并不清楚最终会走向何处，因为第一次对话只是——那是在Llama 4之后——大概就是在问：你觉得我们该怎么做？

David： 为什么强调这次对话发生在Llama 4之后，这很重要吗？

Alexandr： Llama 4没有走在Meta希望的轨道上。那在内部确实是一次挫折，而且是在AI明显变得越来越重要的时间点——AI显然将会对Meta的未来至关重要。

最初几次通话是电话交流，他有点像是在征求意见：你觉得我们该怎么做？你觉得我们该专注在哪里？

David： 这与我私下听到的关于他的说法相符——他有这套令人惊叹的世界级创业者顾问网络，不完全是Meta董事会，尽管董事会里也有些人参与其中。我听说过他不断向这些人寻求建议，发消息说："这是我面临的情况，你会怎么做？"一遍又一遍地这样做。我认为这是非常了不起的品质，因为这需要谦逊——在他已经取得了那些令人难以置信的成就之后，依然能继续这样做。

Alexandr： 从他第一次联系到我们宣布合作，大概只有五六周时间，相当快。

David： 这也是世界级创业者的共同点。我们有Jonathan Ross，Grok的创始人，第一次公开谈到与英伟达那笔200亿美元合作的就是在我的节目上，他说："从Jensen第一次打电话到钱打到账户，只用了三周。"

Alexandr： 那很厉害。我当时对Meta的AI战略有很多想法。最早的一个想法就是我之前说过的：Meta从基因上来说是专注于人们"想做的事"的公司，在这场AI大变革中，它实际上是定位最为特殊的公司之一。我向Mark传递了大量想法，与此同时，也在进行另一条并行对话："也许我们可以考虑是否有合作的可能。"

David： 所以当他说这句话的时候，这对你来说是完全出乎意料的。

Alexandr： 完全出乎意料。整件事就像一连串疯狂的事件。当时我心里想："哦，这挺好的，但不可能……"

David： 当他们说"我们得想办法合作"，你知道这意味着什么，对吧？就是收购。他们总是这么说，"我们得找到合作的方式。"

Alexandr： 我当时大概还没有这种意识。我当时心里想："也许他只是在探探风，说说而已，但这真的合得上逻辑吗？"

David： 为什么你当时会觉得不合逻辑？

Alexandr： Meta标志性的收购是Instagram和WhatsApp，都是非常清晰的产品逻辑驱动的决策。而Scale是一家深度企业级、政府级销售的公司，是一种与Meta完全不同的商业模式。所以

我当时想到的逻辑是：如果Meta想进入那些领域，那也许说得通，但这次并不是那种情况——Mark显然主要感兴趣的是让Llama项目和整体AI项目上轨道，他要的是人才。

David： 是的，他要的是人才。整件事一直笼罩在某种模糊和不确定性中。

Alexandr： 什么时候变得清晰了？当我们开始谈数字的时候，我想："哦，好吧，原来是真的。"那时候事情才变得清晰。

第十三章：离开Scale AI，加入Meta

David： 一开始你还在想"这说得通吗"，然后你们继续谈，他是怎么用多快的时间说服你这是一条好路的？

Alexandr： 部分原因是这个交易结构本身就很令人着迷。我们最终落地的方案是：Meta投资并持有Scale 49%的股份，Scale继续独立运营，我和几个人加入Meta。

我当时对这个方案有点不可思议，因为它是一种很奇特的交易，但我认为这真的是一个"三赢"的设计：Scale的股东们得到了一个很好的结果，Scale继续存在，而我真的相信Scale最好的日子还在前头。

David： 我好奇的是，他能在一个电话里就让你转变想法吗？还是说这更像是"Mark，我得想几天，这太疯狂了"？

Alexandr： 是好几个星期都在想："这是真的吗？这说得通吗？如果说得通，我对这件事怎么感受？"主导情绪是：这太疯狂了。然后随着我开始认真考虑是否要做这个决定，那本身就很不简单。Scale内部的同事、我们的投资人，有很多重要的对话要进行。

放弃或者说交出你的"孩子"，当然是非常艰难的。你在Scale做了多少年？

从创立到……九年。而且你还很年轻，还不到30岁，这差不多是你人生的三分之一。

Paul Graham有一句说了很久的话：如果你把公司视为自己毕生的事业，你的行为方式会截然不同。我确实真心把Scale当作我的毕生事业，在我做Scale的整段时间里都是如此。那是一个很艰难的情感过程。

但最终让我想通的，是几方面的结合：这真的是一个对所有各方都好的结果，同时我也看到了在Meta可以发生的事情的潜力。而那时候，Meta在AI方面确实看起来有点"烂摊子"，可能不是最吸引人的AI工作地点——但这恰恰触发了我内心的创业者本能：你基本上可以重建它，就像重新创立这个实验室一样。

David： 是的。正因为有这么多工作要做，反而为你清理出了空间，让你能够从零开始搭建很多东西，确立正确的原则，建立正确的文化，为打造非凡的东西创造了条件。

第十四章：从零重建Meta AI实验室

David： 你和Mark是这样讨论的吗？就像"我们需要在这里按下重置键"？

Alexandr： 他看起来不像是想要小修小补。他的态度就是："这条路走不通，彻底推倒重来。"确实是这样。整个对话是不断演进的。我非常坚定地相信一件事——Elon在他职业生涯的不同阶段也证明了这一点——就是：你只需要一支极小的、极厉害的、高度技术化的、非常扁平的团队，做到这一点，你就能非常非常快地取得很大的成就。

这是我非常有信心的一件事，在AI领域尤其如此，这是正确的方式——特别是在我们面临必须快速移动的情况下。这是我早期与Mark谈论很多的事情之一，我认为他也为之兴奋，最终成为我

们整体战略的核心支柱之一：小而扁平的、高度技术化的团队，极高的人才密度，在这些前提下能移动多快。

David： 从外部来看，Mark的做法就像是"倾囊而出"——我就是这样理解他的。你读过《拿破仑的思维》这本书吗？

Alexandr： 没有。

David： 那是1957年出版的书。我是因为一次采访找到它的——我想是Tyler Cowan采访Sam Altman，问他那年读过的最重要的书是什么，他说是《拿破仑的思维》。这本书很难找，300页全是拿破仑自己的话，按主题分类整理。书里他反复强调：犹豫是致命的。但他也说，在采取行动之前，会进行大量深思熟虑，从每个角度审视，确保做出正确的决定。我觉得Mark的运作方式有一种回响：做很多深思熟虑，确保走在正确的路上，但一旦做出决定，就全力以赴，毫不犹豫。我感受到这种回响，就在这个时刻——他来找你，然后你们开始重建整个组织。

Alexandr： 我认为他真的内化了"失败不重要，重要的是赢的时候赢多大"这一信念。这种底层逻辑，让他能够在很多情况下真正无所畏惧地行动，因为他非常坦然地承担大量风险。

David： 他有句很精彩的话：在一个不断变化的世界里，最大的风险是什么都不做。

Alexandr： 是的，他确实深刻地内化了这一点。当然存在一种平行世界，Meta看起来更像谷歌，更慢、更官僚，作为公司看起来非常不同。但正因为他如此深刻地内化了这些教训，才让整个机体保持动态、保持活力、保持生命力。

第15章：从创始人到教练

David： 你曾是Scale的创始人，亲手运营公司；现在又在重建这个实验室，与Mark共事——这两种环境下，你的工作方式有何不同？

Alexandr： 在Scale的时候，我深刻内化了一个理念——虽然已经记不清这个建议来自哪里——那就是：如果你想成为一名优秀的创始人，你必须能够胜任每一个岗位。我对公司里每一件小事应该如何运转都有非常强烈的主张。这造就了一家在很大程度上是我个人努力和个人视角的产物的公司，这种风格渗透到公司的方方面面，但同时也让我在很多重要环节成了瓶颈。这对一家公司来说有利有弊。

我认为，如果你是第一次创业，绝对应该采用这种方式，因为它成功的概率远高于不这样做。Scale是我的第一家公司。

David： 对。

Alexandr： 但在Meta，情况完全不同，因为我们必须在极短的时间内完成极多的事情。我没有那种余裕去"胜任每一个岗位"。我本来也不是AI研究员，也不是产品设计师，也不具备那些对组织成功至关重要的各种专业能力。

所以在Meta，我采用了一种完全不同的理念——核心就是：我们如何创造一个环境，能够吸引到各领域顶尖的杰出人才？招募最优秀、最卓越的人是第一要务。

David： 你为什么觉得自己在Meta能做到这一点？仅仅是因为资源更充裕吗？

Alexandr： 我认为，MSL创立初期之所以极具吸引力，在于它提供了一个从零开始、用一支极小的团队打造实验室的机会，而且我们拥有清晰的方向——个人超级智能。这个方向与很多人产生了共鸣。我认为所有从事AI工作的人，都希望它真正帮助到普通人，希望它对自己的妈妈、外婆、爷爷意味着些什么，希望它对世界上每一个人都有实际意义。

同时，由于我们是依托Meta的资源来做这件事，我们不会受限于算力，不会受限于基础设施，不会受限于分发渠道——这些恰恰是初创公司最常见的瓶颈。但这又是一个真正能留下自己印记、施加深远影响、亲手塑造的机会。我认为这对很多人来说相当令人兴奋。

David： 所以这就是为什么Mark愿意花看似天文数字的钱来招募少数顶尖人才——因为他知道这些人才反过来会吸引更多顶尖人才。但你需要这个起点。

Alexandr： 完全正确。还有一点可能被低估了：OpenAI和Anthropic的股价涨幅非常大，所以如果你考量这些人留在那里能赚多少，其实也是相当可观的数字。对很多人才来说，薪酬方面最终可能差不多持平。当然，我们常常忽略了那些早期加入这些实验室的员工和研究人员，他们的股票已经增值了多少、他们现在的薪酬水平是什么样的。

我们创立MSL的信念只有两条：第一，招募最聪明、最卓越的人；第二，个人超级智能——如何在Meta和MSL创造一个让大家做出最佳工作的环境。

在Meta，我做的更像是传统意义上的管理工作。我一直在思考的核心问题是：如何创造一个环境，让这些才华横溢、极为特别的人，都能充分发挥自己的天赋？我更多地扮演着一种教练的角色，而在Scale，完全不同——我是那个"作者"，是那个需要把自己的视角贯彻到我们所做一切事情中的人。

David： 跟我多说说这种"教练感"。

Alexandr： 我认为我的工作，一是帮助确立北极星和前进方向——也就是个人超级智能、赢得消费者AI赛道、打造对每个人都有意义的AI；二是在团队中发现特殊的人才，然后给予他们充分发挥才能的环境和资源。

大公司经常犯的一个错误是：优秀的人才明明在那里，却得不到施展拳脚的机会，所以他们往往会选择离开，去更小的公司或初创企业。

David： 你之前提到了Jeff Bezos的股东信。这也是他反复强调的观点，在我读过的关于他的书和他自己的股东信里都有——如果优秀的人无法构建东西，他们就会离开。

Alexandr： 确实如此。AI是一件非常特殊的事情。"研究"这个词现在听起来好像已经失去了它本来的意义，但从定义上说，人类还不知道这些模型的能力边界在哪里，也不知道用它们能做出什么。它们真的是我们尚未完全理解的未知存在。所以这真的是科学，真的是研究——我们在探索这项技术的极限，探索能用它构建出什么，这个过程需要大量的试错，需要聪明人迸发出非凡的洞见。

这不是一个可以用极度高压、极度密集的工作方式来推进的过程。人们需要空间、时间和资源才能做出最好的工作。我在很多维度上都这样思考。比如Nat Friedman，他绝对才华横溢——如我之前所说，如果说Muse有一个人的核心视角贯穿其中，那就是他。现在重要的是让他处于一个能够充分表达这一切的位置。我们还有一些出色的研究人员，他们有着非常令人兴奋的想法——如何创造一个环境让他们能够尽情探索？大多数尝试不会成功，但其中一些会取得惊人的成果，这些成功的案例足以证明所有投入都是值得的。

有两种问题，或者说两种模式：一种叫钻石挖掘，一种叫建摩天大楼，取决于你所做事情的回报分布。有些领域的分布是超级幂律的——你做的大多数事情几乎没什么价值，但少数事情可能比其他所有事情加起来还要值钱一百万倍。风险投资就是典型的钻石挖掘行业——一切都在于识别那些特殊的想法并将其贯彻到底。

这说起来容易，去你19岁生日派对看看就行了。

第16章：Alexandr 19岁生日派对上的未来亿万富翁

David： 哈，这真是太难以置信了。听众里有些人不知道我刚才在说什么——你能简单说说你的19岁生日派对上都有谁，以及为什么投资那桌人会是一笔好买卖？

Alexandr： 这真的是件很疯狂的事情。我19岁生日派对那会儿，我还是MIT的大一新生，那是一月份，我正在一家叫HRT的交易公司做冬季实习。我们大概有十来个人，十二个左右，几乎都是哈佛或MIT的学生，大多数人之前就因为各种数学、科学或计算机竞赛而相互认识了。

其中有Jeffrey Yan，后来去创办了Hyperliquid，非常成功；Scott Woo后来创办了Cognition，也非常成功；还有一个人是Jesse Zang，创办了Decagon，同样相当成功；另一个人是Vicky Yei，我认为是一位非常出色的研究人员，现在在Anthropic工作。所有人都极其优秀。

我最近还和HRT的创始人聊了聊——HRT本身现在也发展得非常厉害，令人难以置信。

David： HRT是做什么的？

Alexandr： HRT是一家自营交易公司，用自己的钱进行交易。2020年第二季度，他们创下了110亿营收、大约80亿利润的记录数字。这家公司员工不到一千人，真的令人叹为观止。我最近和HRT的创始人见面，他们说在考虑做一些私人投资，我就说："直接投那些实习生吧，给所有实习生开种子轮支票就行了。"

我从小参加数学、科学和计算机竞赛及奥林匹克竞赛，在这个圈子里认识了来自全美各地的各种人。看着当年一起参加比赛的那些人如今如此成功，真的有一种很超现实的感觉。

第17章：钻石挖掘 vs. 建摩天大楼

David： 未来几十年看你们这群人会怎样，一定很精彩。刚才我打断你了——关于钻石挖掘和摩天大楼，你还有什么想补充的？

Alexandr： 核心就是：它的回报是幂律分布的吗——少数事情的价值是投入的一百万倍——还是更像建摩天大楼那样？我会把数据标注或数据业务归为后者，亚马逊Prime的配送也是类似的例子：回报相对线性，你必须建立一套流程，把它做到极致。

如果你在建摩天大楼，那就是一门高度运营的生意，一切都在于把每一分效率都从流程中榨取出来——想办法让它再提升2%，再提升1%，再提升0.5%，不断优化。

而钻石挖掘则完全不同，就像是说："好了，大家各自去探索，去尝试所有疯狂的想法"，然后你只需去培育那些看起来有希望的想法。

David： 你现在在Meta做的就是这个感觉？

Alexandr： 是的，这就是我在Meta的感觉。而建摩天大楼，总体来说是我在Scale时候的感觉。这是一个很根本的范式差异。

第18章：为什么Alexandr有超过200个直接下属

David： 回到管理方式的差异——你在Meta和Scale的管理方式根本不同。你为什么有那么多直接下属？好像有100多个？具体是多少？

Alexandr： 超过200个。

David： 怎么会？为什么？

Alexandr： 回到MSL的创立理念——我们想打造一个怎样的实验室？核心思路是：如何保持极高的人才密度？如何让这些优秀的人在这里做出最好的工作？如何建立一个以技术为核心、让技术人员真正能发挥潜力、甚至完成毕生心血的组织？

围绕这一点的设计原则之一就是：极度扁平化。实际上，所有加入TBD这个团队的研究人员都直接向我汇报。这更多是一种宣言——TBD就是反官僚主义的象征。我们招募的都是才华横溢的人，他们在职业生涯中已经清晰证明了自己能做出卓越的工作。我不需要对他们事无巨细地管理，他们完全能够自主完成出色的工作。

但我们确实需要技术领导力。一部分人负责为各自的小组设定清晰的技术方向。我们有一种"Pod"结构——各个Pod都有技术负责人，在技术决策上拥有最终拍板权。所以技术领导层是存在的，但从"人员管理"或官僚体系的角度来看，我们就是反官僚主义。

另一方面，我们确实会做很多集体决策。这是一个人才极度密集的团队，每个人都有精彩的见解，我们希望通过辩论和讨论找到大家共同认为最正确的前进路径。所有人在实验室里都做出过卓越的事情——我们希望听取所有人的意见。

这当然是一种非常规的管理方式。如果说我是超过200人最好的管理者，那显然是在撒谎。但重点在于——他们根本不需要管理者，他们需要的是一个好的环境。

他们都极其聪明，都有超强的能力，只需要给他们施展的空间就够了。

David： 所以也许不是"教练"。你更像是一个好环境的守护者，让他们能做出伟大的工作。

Alexandr： 对，正是如此。

David： Alex，今天真的很精彩，感谢你抽时间来。

Alexandr： 谢谢。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

180 收藏 分享到:

写评论

请发表您的评论

表情 图片 发布评论

摘要：
模思智能完成超10亿元Pre-A轮融资，资金投向全模态实时交互与AI for AI。公司延续OpenMOSS开源路线，已推出多款语音、视觉模型，尚未披露具名客户及收入数据。

10月12日，模思智能（上海模思智能科技有限公司）宣布完成超10亿元Pre-A轮融资，由华控基金领投，国开科创、上海科创基金、徐汇资本、临港策源基金等机构参与投资，元禾控股、上海国投旗下上海科创集团、星连资本等老股东续投。公司未披露本轮估值，资金将主要用于全模态实时交互智能研发和全球商业化。

这距离模思智能上一轮融资公开披露约半年。今年4月1日，上海未来产业基金公众号披露，模思完成数亿元天使轮，由上海未来产业基金与IDG资本领投。

模思智能成立于2024年11月，总部位于上海，孵化于上海创智学院与复旦大学OpenMOSS团队。OpenMOSS官网目前将上海创智学院、复旦大学NLP实验室和模思智能共同列为参与方。创始人、首席科学家邱锡鹏为复旦大学特聘教授、上海创智学院副院长，2023年2月带领团队发布开源大语言模型MOSS。联合创始人兼CEO李世民是其在复旦指导的2022级硕博连读生。据公司官网信息，团队博士占比约50%。

MOSS之后，团队的研究逐渐从文本延伸至语音和多模态。2023年的SpeechGPT探索离散化端到端语音交互，2024年的AnyGPT进一步尝试将文本、语音、图像等模态纳入统一的离散Token体系。

同期，文本以外的基础模型也出现了大额资本交易。9月28日，AMD宣布与空间智能公司World Labs签署最终收购协议，交易对价约82亿美元，预计年底前完成，仍需满足监管审批等交割条件。World Labs主要开发可生成、重建和模拟交互式3D世界的空间智能模型。

两家公司技术路线并不相同，融资与并购也不能直接比较，但World Labs至少提供了一个同期参照：文本之外的基础模型资产，同样可以获得大额资本投入。

按模思智能的规划，本轮资金将主要投向两个方向：一是全模态实时交互智能，让AI在眼镜、汽车、家庭终端等场景持续获取和理解多模态信息；二是AI for AI，让AI更多参与数据生产、筛选和模型迭代。

成立后，模思智能延续了OpenMOSS团队的开源路线。公开仓库记录显示，MOSS-VL在4月发布首批Base和Instruct版本，7月推出实时视频理解版本MOSS-VL-Realtime，随后陆续开放量化版本和技术报告，并接入SGLang等开源工具链。语音识别模型MOSS-Transcribe-Diarize目前在Hugging Face已有十万级下载，并在第二届MLC-SLM语音挑战赛中获得第一。7月，模思API平台开启公测。

不过，开源社区的活跃度与商业转化仍是两回事。在此次融资披露中，模思未公布具名客户，也未披露收入、订单或付费客户等商业化数据。性能方面，MOSS-VL-Realtime公开披露在PA@OmniMMI测试中取得66.0分，并已发布技术报告，但目前公开信息中，尚未见其与GPT-4o、Gemini等主流实时多模态模型在统一测试条件下的直接横向比较。

本轮投资名单中还出现了多家国资背景机构。上海科创基金、徐汇资本、临港策源基金等均具有上海地方国资背景，上海国投旗下上海科创集团则继续投资。公司未披露本轮估值、融资对应股比及董事会安排，仅凭融资金额无法推断公司的具体估值。

融资公告中，模思智能还预告实时交互系统MOSS Live即将发布，由前端交互模型与后端能动性模型协同工作。对这家成立不到两年的公司而言，接下来更可验证的指标，是MOSS Live发布后的实际交互表现，以及API平台能否形成付费客户和收入。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限免

38 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论