摘要：

Anthropic计划通过IPO及同步私募配售合计募资最高904亿美元，完全稀释估值约1.4万亿美元，有望刷新美国科技公司上市融资纪录。公司第三季度营收接近170亿美元，但运营支出激增至175亿美元，重返亏损。

Anthropic正以美国科技史上最大规模IPO叩关资本市场，**完全稀释估值目标高达1.4万亿美元，**意在成为首家公开上市的前沿人工智能实验室。

根据周二提交给美国证券交易委员会（SEC）的招股文件，Anthropic寻求通过IPO和私募配售合计筹资至多904亿美元。**其中基础IPO发行规模最高644亿美元，**低于此前撤回版本中所示的693亿美元；此外，包括谷歌母公司Alphabet、英伟达、AMD、博通、美光科技、微软及台积电在内的七家科技巨头，**将另行以私募方式合计投入260亿美元。**发行价区间定为每股70至78美元，拟发行约8.014亿股，部分现有股东另出售约2360万股。

按发行价上限78美元计算，**Anthropic估值约为1.02万亿美元**，略高于其9650亿美元的私募估值。股票预计在纳斯达克全球精选市场挂牌，代码为ANT，主承销商为高盛和摩根士丹利，另有20家银行参与。

此次上市计划于11月18日（周三）定价。若计入超额配售权，募资总额将逼近1000亿美元，超越SpaceX此前创下的865亿美元纪录。然而，AI相关股票上周刚经历一轮急跌，市场对数据中心监管收紧及成本上升的担忧尚未消散，Anthropic选择在市场情绪承压之际推进上市，其IPO表现也将成为检验投资者对AI商业化前景及高估值接受度的重要指标。

IPO结构：巨额私募锁定科技巨头阵营

Anthropic此次发行分两部分推进。公开发行部分，Anthropic将发行8.014亿股，部分现有股东出售2360万股，发行价区间对应市值约1万亿美元。若计入员工期权、限制性股票及公司慈善捐赠配对计划预留股份，完全稀释估值约达1.4万亿美元。

私募配售部分将另行筹资260亿美元，认购方涵盖AMD、博通、Alphabet旗下谷歌、美光科技、微软、英伟达及台积电。这一投资者名单与Anthropic的算力供应商高度重叠，折射出AI行业独特的"循环资本"结构——为Anthropic提供算力的科技巨头，同时也是其股东和客户。

高盛和摩根士丹利担任此次IPO联席主承销商，另有20家银行参与承销。

营收爆发式增长，但第三季度重返亏损

招股文件首次向公众披露了Anthropic的完整财务数据。**公司第三季度营收接近170亿美元**，而去年同期仅为14亿美元，同比增速极为可观。截至10月31日，公司年化营收已升至约810亿美元，较9月底增加约100亿美元。截至9月30日，过去12个月收入达到10万美元以上的客户已超过11900家。

然而盈利能力仍不稳定。公司第三季度总运营支出跳升至175亿美元，同比增长292%，从第二季度的9.74亿美元运营利润——也是连续至少五个季度亏损后的首次盈利——重新滑入-5.67亿美元的运营亏损。拖累第三季度业绩的主要因素包括：50亿美元的短期算力合同成本，以及20亿美元与公司慈善捐款匹配计划相关的非现金支出。

此外，AI定价压力正在侵蚀营收增速。招股文件显示，部分新模型降价及向客户提供合同折扣，令第三季度营收增长减少约6亿美元。Anthropic在9月推出的Opus 5.5等新模型时下调了售价，竞争对手OpenAI近期同样推出了低价模型。

承诺支出规模庞大，算力依赖构成核心风险

维持技术领先地位的代价极为高昂。招股文件显示，**Anthropic的总承诺支出达8950亿美元，主要用于算力和芯片采购；其中约700亿美元将在截至2027年9月的一年内支付**——这一数字已超过标普500指数约三分之二成分公司的个别市值。

与拥有广告等多元收入的科技巨头不同，Anthropic目前收入几乎完全依赖AI服务，必须让投资者相信，单一的AI业务可以产生远超基础设施成本的利润。这一逻辑尚待时间验证。

在技术应用层面，Anthropic正寻求将Claude嵌入专业服务场景，涵盖医疗保健、生命科学、法律及会计等行业。文件显示，目前Anthropic代码库中逾90%的代码贡献已由Claude完成。诺华首席执行官Vas Narasimhan出任Anthropic董事会成员，显示其在医疗领域的布局正逐步深化。周一，Anthropic发布了Mythos和Fable模型的新版本，两者速度均有提升，Fable定价也有所下调。

安全风险警示与治理结构引发关注

Anthropic的创始背景与众不同——核心团队由原OpenAI高管出走组建，起因正是对AI安全优先级的分歧。近六年后，公司以公益公司（Public Benefit Corporation）架构上市，治理结构中设有"长期利益信托"（Long-Term Benefit Trust），拥有选举和罢免公司董事会多数成员的权力，旨在平衡股东利益与社会利益。

然而，公司在招股文件中明确警告，若AI技术在缺乏充分保障和监督的情况下发展，可能对人类构成"灾难性或生存性风险"。监管机构、投资者乃至Anthropic内部员工均对人类失去对该技术控制权的重大风险发出警示，其中有人估计AI在未来十年内消灭全体人类的概率超过10%。首席执行官Dario Amodei也曾呼吁顶尖AI实验室“控制前沿技术的推进节奏”，以优先保障安全。

相比之下，**竞争对手OpenAI将IPO目标定于2027年，其CEO Sam AItman将2026年定性为上市的"不明智时机"，理由同样是AI安全顾虑。**据知情人士向彭博透露，OpenAI目前正以1.25万亿美元估值进行融资。

创始团队与机构股东阵容

Anthropic七位联合创始人各持股约1.4%，以当前估值衡量均已跻身亿万富翁行列。即便兑现将个人持股80%捐赠慈善事业的承诺，这一判断依然成立。

在机构股东层面，富达投资、Capital Group、贝莱德等资产管理机构旗下基金，以及Iconiq、Spark Capital、红杉资本等风险投资机构均在IPO前持有Anthropic股份。谷歌、亚马逊和微软则兼具投资者、客户与算力供应商三重身份。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领
* 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码
免费领取

限免

829 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

6 条评论

MobileUser6744
2小时前 中国河南省

已经接近2000年股市泡沫了

0 回复

tim
7小时前 中国广东省

大利空了

0 回复

小貔貅
7小时前 中国上海

AI不太行啊，应该是9650亿美元吧?

0 回复

MobileUser6678 VIP会员
7小时前 中国四川省

为了上市而上市，背后有啥目的?

0 回复

MobileUser6906
7小时前 中国广东省

我们不投一个吗?

0 回复

摘要：

阿里巴巴正式启动平头哥分拆上市，已于9月11日秘密向港交所递交A1申请，拟通过全球发售登陆港股。此次分拆旨在释放芯片业务独立估值、拓宽融资渠道。随着真武M890超节点加速商业化，平头哥正从集团内部芯片业务迈向独立资本市场，但上市规模及最终持股比例尚未确定。

阿里巴巴正式启动旗下芯片子公司平头哥的分拆上市计划，将其独立推向资本市场，为这家全栈数据中心芯片供应商开辟独立融资渠道，同时帮助集团释放被低估的资产价值。

周二阿里公布的文件显示，**平头哥已于2026年9月11日以保密形式向香港联交所递交A1上市申请表格，申请H股在港交所主板挂牌买卖。**

阿里巴巴

Alibaba Group Holding Limited

阿里巴巴集團控股有限公司

(於開曼群島註冊成立的有限責任公司)

(股份代號：9988(港幣櫃台)及89988(人民幣櫃台))

建議分拆平頭哥於
香港聯合交易所有限公司主板獨立上市

阿里巴巴集團控股有限公司(「**阿里巴巴**」、「**阿里巴巴集團**」或「**本公司**」)宣佈，其已根據上市規則第15項應用指引，向香港聯交所提交有關建議分拆本公司全資子公司平頭哥(上海)技術股份有限公司(「**平頭哥**」)獨立上市(「**建議分拆**」)的建議。

本公司欣然宣佈，香港聯交所已確認本公司可進行建議分拆，因此，於2026年9月11日，平頭哥以保密形式向香港聯交所遞交上市申請表格(A1表格)，以申請批准平頭哥的H股在香港聯交所主板上市及買賣。

建議分拆目前擬透過全球發售平頭哥的H股的方式進行，包括：(i)香港公開發售平頭哥的H股，以供香港公眾人士認購；及(ii)向機構及專業投資者配售平頭哥的H股。於本公告日期，平頭哥為本公司的全資子公司，並為中國一家領先的全棧數據中心芯片供應商，該等芯片可實現系統級算力解決方案。建議分拆完成後，預期平頭哥將繼續為本公司的子公司。

阿里在公告中表示，**香港联交所已确认其可进行建议分拆。此次分拆拟通过全球发售方式进行，包括面向香港公众的公开发售及向机构与专业投资者的配售。**分拆完成后，平头哥预计仍将维持阿里子公司地位。

与此同时，平头哥芯片业务正加速进入规模化商业阶段。**二季度财报显示，基于真武M890芯片的超节点实例已上线阿里云并开始销售，截至8月初已服务逾650家客户，Kimi K3、千问3.8 Max等主流大模型均已借助该实例提供推理服务。**商业化进展的提速，为此次分拆上市提供了更具说服力的基本面支撑。

价值重估与独立融资双重驱动

阿里巴巴在公告中列明了此次分拆的商业考量。

其一，分拆有助于投资者将平头哥的表现与潜力从集团整体业务中独立剥离加以评估，从而更准确地反映两者各自的价值；其二，独立上市将提升平头哥在客户、供应商及潜在战略合作伙

伴中的独立形象，增强其商业谈判地位；其三，上市后平头哥可独立进入股本及债务资本市场，并进一步拓宽银行信贷融资渠道，有助于更有效调配集团整体财务资源。

从集团层面看，分拆亦有利于阿里巴巴整体估值的重新梳理。阿里巴巴方面认为，芯片业务独立上市后，投资者可更清晰评价集团保留业务的价值，有助于缓解市场长期以来对混合业务结构折价估值的问题。

股东无保证配额，分拆体量较小

值得注意的是，香港联交所已批准阿里巴巴豁免向现有股东提供平头哥H股保证配额的规定。阿里巴巴援引的理由包括：美国证券法律要求将触发向美国证券交易委员会提交注册声明等繁琐程序，且中国法律对全球发售前已发行股份设有禁售限制，实物分派在操作层面并不可行。此外，公司亦指出，参照集团总资产、收入及净利润，此次分拆对阿里巴巴整体而言规模占比并不重大。

根据公告，由于预期建议分拆所涉最高适用百分比率将低于5%，此次分拆不构成上市规则下须予披露交易，亦预期不会影响阿里巴巴在港交所与纽交所的双重主要上市地位。全球发售的规模、架构及阿里巴巴持股比例的减少幅度目前均尚未确定。

全栈布局加速落地

平头哥目前已形成覆盖GPU、CPU及网络芯片的全栈自研芯片布局。其核心产品真武M890超节点能够支持超过2万亿参数的大模型推理，已于阿里云平台正式上线销售，下半年将持续放量。

阿里云方面表示，大型AI数据中心交付周期已压缩至100天，进一步提升了算力基础设施的部署效率。真武芯片商业化节奏的加快，意味着平头哥作为独立上市主体，拥有更具可见度的收入增长曲线，这将是此次发行过程中投资者重点审视的核心议题。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

457 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

3 条评论



浙海石 VIP会员

5小时前　中国浙江省

呵呵谁家的GPU?

0　回复



1560001506412 VIP会员

6小时前　中国广东省

这是今天跌的原因吗?

0　回复



希瑞公主

6小时前　中国北京

作死

0　回复

摘要：

在极端情景下，美国数据中心总容量会在 2028 年前后停在约 120 到 150GW，大约是今天的 2 到 2.5 倍，此后不再增长。两三百 GW 的规划被冻结，相当于数千万块最先进的 AI 芯片失去了机房。

2026 年 11 月 4 日，美国中期选举结果落定后的第二天上午，OpenAI 的高管们坐到了一起。

据外媒援引知情人士的消息，他们讨论的是要不要重设 2027 年的数据中心容量预期。讨论还没有形成决定，但焦虑已经摆上了台面。

过去几个月，美国各地的大型数据中心项目接连被按下暂停键。得州前任州长 Abbott 从 8 月起冻结了数据中心的并网和空气许可，要求审计到年底；新当选的州长 Gina Hinojosa 承诺，在州议会立法保护居民之前，暂停所有新数据中心审批，而议会会期要到 2027 年 5 月才结束。

俄亥俄新州长 Amy Acton 提出有条件暂停，要求新项目承担全部电力成本、只能建在旧工业用地上；佐治亚新州长 Keisha Lance Bottoms 则准备上任后直接签行政令，暂停全州新建。

据 Tokenpost 统计，今年 7 月到 11 月 4 日，美国至少有 21 个大型数据中心项目被取消，已经接近 2025 年全年的 23 个。Anthropic 在 10 月 26 日提交的招股书里，也把暂停令写进了风险因素：一些辖区正在考虑或已经批准暂停令，可能推迟或阻止它依赖的算力设施，而且反对数据中心的声音正在跨辖区变得更有组织。

如果我们把这股趋势推到极端，去设想这样一个场景，如果美国所有规划中的数据中心都建不成，对当下和未来的 AI，意味着什么？

01 潜在算力增长被砍掉 50%

为了把推演的边界划清楚，我们设定这样一个极端场景，它建立在三条假设上：

1，全美所有尚未开工的规划项目全部冻结，相当于把目前约 41% 的暂停范围推向全国；

2，已经在建的项目全部按期完工，这和德州等地暂停令只针对新审批的做法一致；

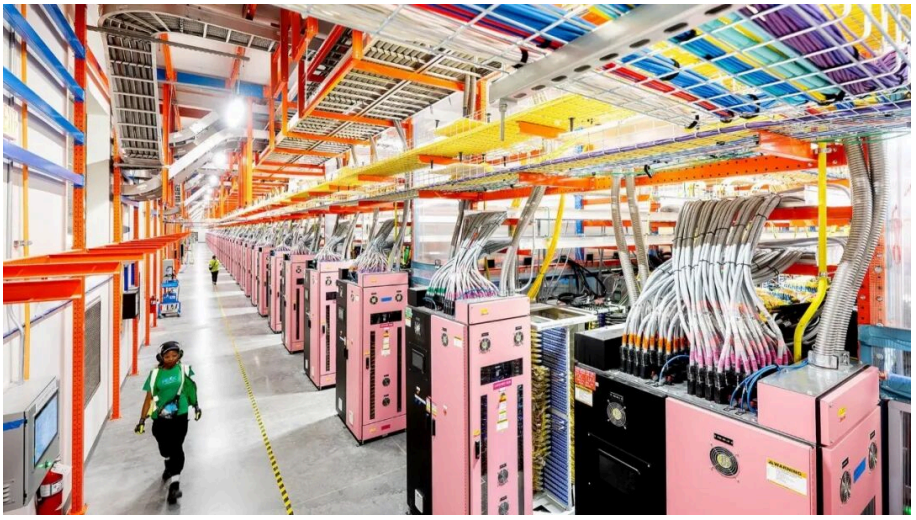
3，芯片照常供应，唯一的硬约束是电和地。我们只推演美国本土，暂不讨论算力外迁。

这个场景下，被卡住的算力规模有多大？据 Newmark 估计，美国数据中心当前用电约 60GW，这里包含所有数据中心，并非全是 AI。在建容量各家口径不同：Cleanview 约 57GW，Wood Mackenzie 约 80GW，DCMap 8 月的统计约 90GW。这部分项目在情景里会照常完工，构成未来几年美国算力的全部增量。

真正庞大的是「规划中、未开工」的部分，DCMap 8 月统计为 228GW，Wood Mackenzie 披露的累计管线超过 430GW，取一个约 230 到 340GW 的区间比较稳妥。

据此粗略推算，在极端情景下，美国数据中心总容量会在 2028 年前后停在约 120 到 150GW，大约是今天的 2 到 2.5 倍，此后不再增长。作为参照，Synergy 此前的预测是美国容量到 2029 年翻倍；而如果管线里的规划全部落地，这个数字本该是今天的 5 倍以上。极端场景砍掉的，是翻倍之后的那一大段增长。

换算成芯片会更直观。1GW 电力大约能带动数十万块 Blackwell 级 GPU：按单卡全口径功耗 1.8 到 2.3kW 理论计算，约 43 万到 55 万块；Abilene 这样的实际园区，约每 GW 27 万块。两三百 GW 的规划被冻结，相当于数千万块最先进的 AI 芯片失去了机房。



亚马逊为 Anthropic 建设的 Project Rainier 园区内部｜图片来源：Amazon

这个情景很极端，但不荒谬。据 Cleanview 测算，新州长承诺暂停的州里，规划容量合计 158.6GW，约占全国的 41%，其中德州 88.4GW、俄亥俄 21.9GW、佐治亚 20.2GW、新墨西哥 11GW、纽约 9.9GW。也就是说，情景 A 里接近一半的冻结，在现实中已经有了对应的政策承诺。2024 年以来被取消的 69 个大型项目里，有 33 个主要因为当地反对。参议员桑德斯还提出了全国性暂停法案，虽然通过的可能性很小。

有一点需要诚实说明，目前规划的数字水分很大。德州电网 ERCOT 的大负荷排队约 474GW、约 1800 个项目，相当于该电网峰值负荷的五倍左右，大部分是占位性质的投机申报。所以极端场景实际砍掉的有效算力，会小于账面数字。即便打掉水分，它依然是一次算力供给的急刹车。

这样一脚「算力刹车」踩下去后，会对 AI 产生怎样的影响?

02 当下照常，下一代 AI 受阻

如果极端情景明天发生，用户在一两年里其实感觉不到异样。2027 年之前的前沿模型，照常训练、照常迭代。

因为支撑这一代模型的训练基地，都已经建成或接近完工。据 Epoch AI 的数据库，目前已知最大的 AI 园区是 Anthropic 与亚马逊在印第安纳州的 New Carlisle，容量 1037MW；其次是 xAI 的 Colossus 2，946MW。OpenAI 在德州 Abilene 的园区规划 1.2GW，8 栋楼里的 6 栋截至 9 月已经交付，预计年底完工。



OpenAI 位于德州 Abilene 的 Stargate 园区卫星图｜图片来源：Epoch AI

被卡住的，是计划在 2028 到 2030 年登场、需要数个 GW 才能喂饱的下一代模型。

Epoch AI 的数据显示，前沿训练的电力需求每年增长 2.2 到 2.9 倍，目前的前沿训练已经超过 100MW。Epoch 预计，未来一年会有多个园区突破 1GW，大约两年后，最大规模的训练可能用到约 250 万块 H100 等效算力；照这个趋势，到 2030 年，最大单次训练需要 4 到 16GW。

作为对比，今天最大的园区刚刚超过 1GW。Epoch 也指出，数据中心的容量，实际上就是训练规模的上限：园区建多大，模型最多就能训多大。

而那些瞄准 2028 年之后的超级工程，已经有不少撞了墙。

OpenAI 的 Stargate 计划到 2029 年超过 9GW，美国 7 个站点中的多数原定 2027 到 2028 年大规模上线，主要集中在得州、新墨西哥和俄亥俄这几个暂停州。

其中，Abilene 旁原计划的扩建已被放弃；新墨西哥州 Doña Ana 规划 2.45GW 的 Project Jupiter，今年 3 月被州土地办公室否决了供气管道；俄亥俄州 Lordstown 站点，直到 4 月的卫星图像里还看不到大规模施工。

Meta 约 1GW 的 Prometheus 园区也在俄亥俄，只有路易斯安那州目标 5GW 的 Hyperion 避开了这一轮暂停。



新墨西哥州 Doña Ana 的 Project Jupiter 工地卫星图｜图片来源：Epoch AI

这就带出了接下来的疑问，下一代训练的算力基地搁浅之后，AI 的进步会慢多少？

03 降速，但不会停摆

要回答这个问题，需要把算力增长拆开来看。

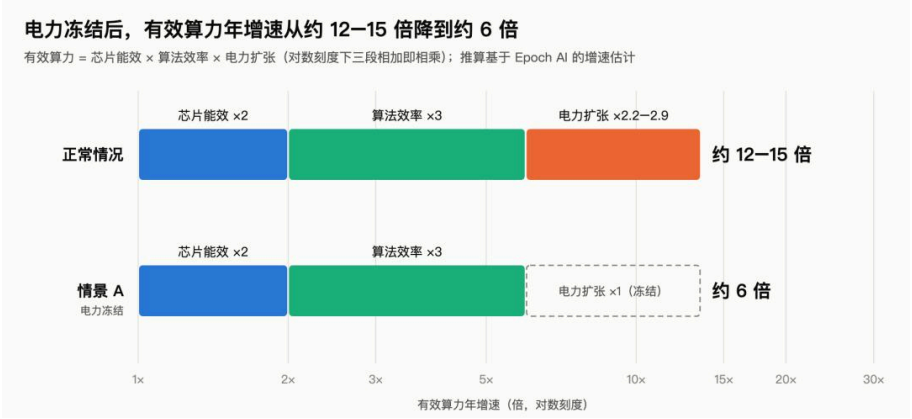
据 Epoch AI 统计，2020 年以来，前沿语言模型的训练算力每年增长约 4 到 5 倍。同期训练用电每年增长 2.2 到 2.9 倍。两者之间约 2 倍的差值，主要来自芯片能效的提升，也就是每瓦电能提供的算力在变多。

硬件之外，算法也在帮忙。常用的口径是算法效率每年提升约 3 倍（Ho 等人 2024 年的研究给出约 2.7 倍）。Epoch 后来把后训练也算进去，估计约每年 10 倍，但区间从 2 倍到 50 倍不等，这里采用更稳妥的 3 倍。

现在可以做一个粗略的推算。

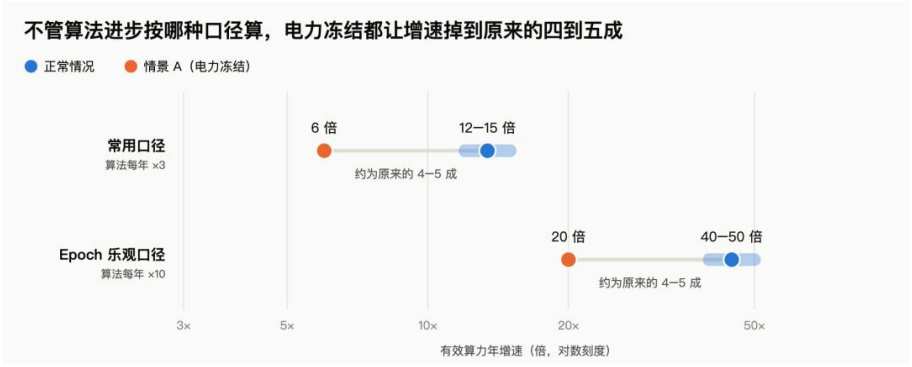
正常情况下，AI 每年获得的「有效算力」增长，等于物理算力增长（4 到 5 倍）乘以算法提升（约 3 倍），大约每年 12 到 15 倍。

在情景 A 下，2028 年之后新增电力归零，物理算力增长里最大的一根支柱被抽走，只剩芯片换代带来的能效提升，每年约 2 倍。再乘上算法的 3 倍，「有效算力」的年增速会从 12 到 15 倍，降到约 6 倍。



有效算力年增速拆解：正常情况与极端情景 A 对比（推算）｜图片来源：极客公园

如果换用 Epoch 更乐观的算法口径（每年约 10 倍），正常情况下的有效算力增速是每年 40 到 50 倍，情景 A 下约 20 倍。两种口径下，电力冻结都会让有效算力增速掉到原来的四成到一半左右。算法进步再快，也补不上电力扩张留下的那一块。



两种算法口径下，电力冻结前后的有效算力年增速（推算）｜图片来源：极客公园

这里还有一个隐患。芯片能效的红利，前提是新芯片能顺利装进机房。机房总电量锁死后，供电和散热改造的难度，可能让这 2 倍也打折扣。

即便如此，每年约 6 倍依然是可观的数字。推演下来，结论很清楚：

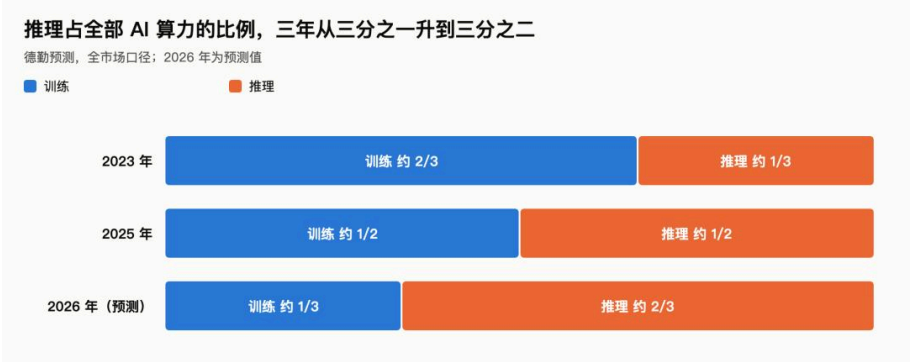
极端场景下，AI会明显减速，但不会停摆。

不过这笔账只算了训练需要的算力部分，把视野放到整个 AI 的运转上，电量锁死之后，还有一场争夺会立刻开始。

04 Token 限额时代来了

过去算力不够，就去圈地建新机房。在极端场景下，盘子里的电就这么多，分给训练的每一度电，都要从推理、智能体和后训练那里挤出来。

全市场的算力早已向推理倾斜。据德勤预测，推理占全部 AI 算力的比例，2023 年约三分之一，2025 年约一半，2026 年预计达到约三分之二。



推理与训练在全部 AI 算力中的占比变化｜图片来源：极客公园

AI实验室内部也在变。SemiAnalysis 基于 OpenAI 和 Anthropic 合计算力的估算显示，2024 年初，预训练占 67%，后训练和强化学习只占约 5%，推理约 29%；此后预训练占比逐季下滑，二季度 63%，三季度 57%，2025 年降到五成多，后训练占比持续上升，最新估计两者已经相当。有研究者提醒，这是占比变化，实验室总算力翻了很多倍，预训练的绝对量未必减少。

更大的压力，来自产品形态。推理模型在回答前会生成很长的思维链，用户看不到，但每一步都在耗电。Gartner 的数据显示，智能体完成一项任务消耗的 token，是普通聊天的 5 到 30 倍。

高盛预测，2026 到 2030 年，全球 token 总消耗将增长 24 倍。



智能体与 token 消耗的增长｜图片来源：极客公园

把这些数字放进极端情况下固定的电量里，每家实验室都会面对同一道选择题：每一兆瓦，要么拿去训练下一代更大的模型，要么拿去服务现有的用户和智能体。

想调几十万块卡训一个更大的基座模型，就得限制现有用户的调用量；优先保推理、保用户，下一代模型的进度就会落后。

增加电力这条路被堵住以后，剩下的问题，就是在固定的电量和算力下，继续发展 AI，还有什么路可走。

05 四条「补充路线」

在极端场景的压力下，那些过去因为「反正能加卡」而不受重视的省电技术，会变成主流方案：

把硬件的考核指标换成「每瓦电能产出多少 token」。

在电量固定的机房里，把旧芯片换成能效更高的新芯片，是唯一的扩容手段。

英伟达现在首选的指标，就是「每个全口径电力兆瓦每秒输出的 token」，分母里算上的是园区的全部用电，包括散热和网络。这个指标的流行本身就说明，芯片厂商已经默认客户的瓶颈在电，卡的数量反而是次要的。

按英伟达的说法，Vera Rubin 的每瓦性能是 Blackwell 的 10 倍，智能体场景下对比 GB300 最高可达 30 倍。独立测试也给出了接近的结果：CoreWeave 实测，在同一 DeepSeek R1 负荷、相同交互速度下，Vera Rubin NVL72 每兆瓦的 token 产出是 GB200 NVL72 的 10 倍。不过 Rubin 下半年才开始量产，多数客户要到 2027 年才能普遍用上。



英伟达 Vera Rubin NVL72 机柜｜图片来源：NVIDIA

跨机房分布式训练。

暂停令普遍针对的是动辄数百兆瓦的大型数据中心。一个自然的绕行思路，是把训练任务拆散，分到不同地区的中小机房里。政策压力会直接变成对分布式训练的技术需求。

这个方法，巨头们已经在尝试。谷歌说明过，Gemini 是在多个地点的集群上同步训练的；微软把威斯康星和佐治亚的机房连了起来；CoreWeave 与谷歌云宣布了跨云训练。谷歌的 DiLoCo 研究表明，训练可以在普通网络连接的远程设施之间进行，还能容忍硬件故障。

但这个方法的难度不小。DiLoCo 的作者也承认，这项技术目前只能补充超大集群，无法形成替代。2026 年的一项仿真研究发现，机房相距几十到几百公里时，网络延迟会明显削弱计算与通信的重叠，大量算力在等待数据中空转。

研发重心从预训练，转向后训练和强化学习。

预训练对单一超大集群的依赖最高，在极端下最先受限。数个 GW 的集群建不起来，工程师会把精力转向对集群规模要求没那么苛刻的后训练、强化学习，以及混合专家模型、低精度计算等架构改进。Cursor 就公开说过，其 Composer 1.5 模型在后训练上投入的算力，已经超过了预训练。

端侧和小模型给云端分流。

到 2026 年，蒸馏已经是做小模型的主流方法。量化后的小模型能直接在手机 NPU 上处理结构化任务，10 亿参数以下的模型大约每秒能跑 12 到 15 个 token。越来越多应用采用混合模式：本地小模型先处理大部分请求，少数复杂请求再交给云端大模型。

06 约束之下的机会

极端场景卡住的是美国本土的电。对另外两类玩家来说，这道约束反而打开了窗口：已经在效率路线上积累多年的模型公司，以及准备入场的 AI 创业者。

先看前沿和追赶者之间的距离。据 Epoch AI 今年 5 月的测算，最强的开源模型平均落后闭源前沿约 4 个月，大约相当于 GPT-5 和 GPT-5.5 之间的水平差。过去，前沿实验室靠每年十几倍的有效算力增长不断拉开代差；在极端情景下，这个速度降到约 6 倍，新的代差更难建立，追赶者需要追的距离会变短。

再看效率路线上的先行者。DeepSeek、Qwen、Kimi、GLM、MiniMax 等中国模型公司，一直以开源、低成本和混合专家架构见长，这条路线已经反映在使用数据上。

据 OpenRouter 与 a16z 的联合研究，中国开源模型在该平台的 token 占比，从 2024 年底的约 1.2% 涨到 2025 年的近 30%；进入 2026 年，多家统计给出的比例在五到六成之间。

a16z 合伙人 Martin Casado 还估计，使用开源技术栈的创业公司里，约八成在跑中国模型。OpenRouter 只是一个平台，不包含 ChatGPT 自家流量和企业私有部署，但趋势很清晰：

当整个行业都要回答「每度电能产出多少智能」这个难题，长期在这道题上下功夫的团队，手里的经验会更值钱。

来源：极客公园

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领 * 体验资格每人限申领一次
VIP会员·7天畅读卡 | 大师课·入门串讲
扫码 免费领取

限免

13 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论