

摘要：

摩根士丹利最新研报指出，全球NAND市场在2027年仍有约9%的供需缺口；短缺仍在，但市场不再是无差别紧张。DRAM因长协条款更好，需求可见度更高，受光刻机制约供给约束更强，以及潜在HBM4E产能挤压，战术上优于NAND；在NAND内部，原厂因利润韧性和供给控制力更强，优于模组厂。

AI仍在拉长存储上行周期，但行业交易逻辑正在从“涨价普惠”转向“结构分化”。大摩最新研报的核心判断是，存储仍处在有利周期中，但更偏好原厂而非模组厂，更偏好DRAM而非NAND。

据追风交易台，大摩在7月2日发布的全球科技研报中更新了NAND供需模型。其测算显示，AI相关NAND需求将在2027年同比增长60%，推动全球NAND市场在2027年仍有约9%的供需缺口。短缺仍在，但市场不再是无差别紧张。

更关键的变化出现在需求两端。服务器和AI相关需求维持强劲，长期供货协议（LTA）为价格提供下行保护；但消费端已经出现涨价天花板信号。模组厂和分销商库存上升，智能手机和PC客户在销量与利润率之间承压，2Q26涨价后已开始出现实际砍单。

这意味着投资者需要重新审视存储链条中的相对位置。DRAM因LTA条款更好，需求可见度更高，供应纪律受EUV制约，以及潜在HBM4E产能挤压，战术上优于NAND；在NAND内部，原厂因利润韧性和供给控制力更强，优于模组厂。

AI需求仍是主线，NAND短缺延续至2027年

AI正在成为NAND增量需求的核心来源。AI NAND需求预计从2025年的205 EB升至2026年的400 EB，并在2027年进一步升至609 EB。AI在总NAND需求中的占比也将从2025年的18%提高至2026年的32%，再到2027年的41%。

在总量层面，预计全球NAND需求将从2025年的1111 EB升至2026年的1250 EB，并在2027年达到1484 EB。同期供应预计分别为1128 EB，1058 EB和1347 EB。对应供需充足率为2025年的2%，2026年的负15%，2027年的负9%。

Exhibit 3: Global NAND supply and demand still point to shortage in 2027

	2025	2026e	2027e
Total AI NAND demand (EB)	205	400	609
Other Applications (EB)			
non-AI SSD (general server, PC, enterprise etc)	396	387	401
PC SSD	209	181	175
Enterprise SSD (non-AI)	187	206	226
Smartphones	337	291	301
Tablets	34	34	34
Flash Cards	15	15	15
USB Flash Drives	10	10	10
Other	113	113	113
Total non-AI NAND demand (EB)	905	850	874
Total NAND demand (EB)	1,111	1,250	1,484
Total NAND supply (EB)	1,128	1,058	1,347
Sufficiency Ratio (%)	2%	(15%)	(9%)
AI as % of NAND demand (EB)	18%	32%	41%

Source: Company data, Gartner, Morgan Stanley Research estimates

这组数据说明，行业短缺并未快速结束。即便供应在2027年恢复至27%的同比增长，AI服务器，企业级SSD，QLC存储和CSP库存缓冲仍足以吸收大量新增供给。

但这并不意味着NAND定价可以无限上行。AI需求与消费需求已经明显分叉。短缺主要集中在服务器和AI相关产品，消费级产品的涨价承受力正在下降。

价格信号分化：服务器强，消费端见顶


渠道调研显示，3Q26 TLC企业级SSD相关NAND价格环比涨幅约30%，但消费级NAND产品仅小幅上涨。DRAM端，服务器级产品3Q26价格环比涨幅约20%，传统DDR3和DDR4因供应继续收紧及AI相关需求增加，涨幅达到30%至40%。

LTA正在改变价格波动方式。内存供应商与主要客户仍在谈判长期协议，相关协议通常包含价格上限和下限。下限有助于保护原厂盈利和估值，上限则限制价格继续大幅上行的空间。

客户态度也出现分化。客户更愿意为DRAM支付更高价格以锁定供应，而NAND涨价已遭遇一定阻力。这与消费电子客户利润率压力上升有关。


库存端同样释放警讯。供应商库存仍处于历史低位，但模组厂库存显著增加，分销商的消费级内存库存也偏高。分销商认为需求并未根本恶化，但过去三个季度激进涨价推高成本，抑制中小买家采购，成交量收缩使库存持有压力加大。

Exhibit 5: DRAM Inventory Level



Source: TrendForce, Morgan Stanley Research

Exhibit 6: NAND Inventory Level



Source: TrendForce, Morgan Stanley Research

为什么DRAM优先于NAND

对整个存储周期仍维持建设性看法，但在战术配置上更偏向DRAM。

原因有四点。第一，DRAM的LTA条款更有利，客户为确保供应的支付意愿更强。第二，需求可见度更高，AI计算和相关服务器需求仍是主要支撑。第三，供应纪律更清晰，EUV等技术和产能约束限制了快速扩产。第四，潜在HBM4E产能挤压可能进一步收紧DRAM供需。

不过，存储股仍受“变化率”影响。若同比价格涨幅在4Q26附近趋于平台，而2028年供需仍不清晰，短期周期催化可能减弱。但LTA带来的盈利可见度仍可能支持估值重估。

为什么原厂优先于模组厂

在NAND内部，更偏好原厂而非模组厂，核心在于利润韧性和供给控制力。

传统周期中，模组厂通常在周期底部囤积低成本库存，并在上行期释放库存，获得更高利润弹性。但这种模式也带来明显周期性，一旦低成本库存消耗完毕，利润率见顶，股价往往承压。

这一轮有不同之处。若AI驱动的短缺通过LTA持续三至五年，模组厂利润率可能比过去更稳定。模组厂仍面临三重约束：低成本库存将在年内逐步消耗，消费级涨价幅度在2H26收窄，且原厂正把更多供给分配给CSP客户，限制模组厂2026年和2027年的出货增长。

此外，超大规模客户倾向于直接向NAND原厂采购，或签订长期供货协议，这可能限制模组厂在企业级SSD和AI存储中的长期可触达市场。亚洲SSD模组厂的企业级SSD收入贡献多数仍仅约

10%至20%，难以完全抵消消费SSD走弱。

投资者应关注三类风险

第一是AI资本开支放缓。这是存储股面临的重大宏观风险。只要AI资本开支未在近期见顶，存储盈利能力仍有望延续至2027年之后。

第二是消费端承压。智能手机和PC客户对继续涨价的承受力下降，订单削减已经出现，模组厂和分销商库存上升。若消费端量能继续低迷，NAND普涨逻辑会被削弱。

第三是2028年供给反转。若新增晶圆产能加速释放，同时供应纪律放松，NAND可能面临过剩风险。相反，若新的AI推理SSD产品进入量产，可能消耗约普通SSD三倍的产能，反而进一步收紧行业供给。

结论是，存储周期仍未结束，但“闭眼买”阶段正在过去。AI需求继续支撑高端存储和服务器产品，LTA改善盈利可见度；但消费端价格见顶，模组厂库存上升，2028年供给变量增加。对投资者而言，下一阶段的关键不是判断存储是否还在上行，而是区分谁拥有更强的定价权，更稳的供给入口，以及更清晰的需求能见度。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 > 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

65 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

摘要：

彭博宏观策略师Simon White警告，当前创纪录的杠杆已从散户ETF、对冲基金延伸至银行和货币市场，通过银行资产负债表深度渗透全系统。银行对对冲基金敞口四年翻倍至约4.5万亿美元，融资成本高企且抵押品多为高波动AI股票。一旦去杠杆启动，银行将从波动“减震器”转为“放大器”，触发平仓与追加保证金的恶性循环，风险远超表面可见。

创纪录的杠杆正在席卷整个金融体系，从散户投资者到对冲基金、银行乃至货币市场基金，无一幸免。

7月2日，彭博宏观策略师Simon White警告，**这场杠杆盛宴的风险远不止于杠杆ETF，而是通过银行资产负债表向整个金融系统深度渗透**，一旦去杠杆进程启动，反馈循环将把银行从市场波动的“减震器”变为“放大器”。

杠杆ETF的零售需求已飙升至历史高位，尤其在今年4月美光科技等个股盈利预期爆发后呈指数级增长。与此同时，银行对对冲基金的敞口已从数年前的约2万亿美元膨胀至约4.5万亿美元，**美国对冲基金的平均总杠杆率自2022年以来接近翻倍**。

Simon White指出，当前融资成本已处于高位，而贷款抵押品往往正是推动本轮行情的高波动性AI股票，这一组合在历史上曾多次出现于市场顶部附近。他强调，**“杠杆创造财富的速度如音速，但摧毁财富的速度如光速。”**

银行是杠杆传导的核心枢纽

White认为，理解当前风险，需要先理解银行在整个杠杆链条中的角色。

以近年来快速扩张的杠杆ETF为例，其背后的杠杆几乎全部由银行提供。银行通常通过总收益互换（Total Return Swap）向ETF提供2倍、3倍甚至更高倍数的收益敞口，同时持有现金股票和衍生品进行风险对冲，而这些现金股票又会通过回购市场继续融出，形成层层加杠杆。

数据显示，**银行股票回购（Repo）头寸规模与杠杆ETF（未加杠杆）的总市值高度一致，说明银行始终是这一市场最核心的资金提供者。**

值得注意的是，去年年底至今年四月初，虽然杠杆ETF因市场调整出现资金流出、市值缩水，但银行股票回购规模却继续上升。这意味着另一类投资者正在接过杠杆——**对冲基金填补了这一缺口，大幅增加股票多头仓位。**

对冲基金杠杆多点累积，规模触目惊心

对冲基金的杠杆风险并不局限于股票端。基差交易——买入国债同时做空期货——是对冲基金杠杆风险的重要来源，据美联储数据估算，截至去年底规模已高达约2.4万亿美元。

此外，**对冲基金目前可能也在更积极地布局互换利差交易，通过买入国债并支付利率互换来押注互换利差走阔**。对冲基金将国债回购给交易商和主经纪商以获取现金，同时从主经纪商处获取其他有担保贷款，两项合计形成银行对对冲基金约4.5万亿美元的敞口。

美国对冲基金的平均总杠杆率自2022年以来接近翻倍，**杠杆的叠加效应使原本已相当庞大的名义敞口进一步放大。**

私人信贷与保险业同样暗藏隐患

私人信贷领域的不透明性可能掩盖了相当高的杠杆水平。根据穆迪的估算，银行向私人信贷公司发放的贷款约为3000亿美元，若纳入未提取承诺则升至约6400亿美元，若再加上对私募股权的贷款则超过9000亿美元。这表明私人信贷并非与更广泛经济体系相互隔绝。

保险业同样不容忽视。数据显示，保险公司的杠杆率已升至至少25年来的最高水平，进一步扩大了系统性风险的覆盖范围。

货币市场基金亦难独善其身

即便是选择回避风险、将资金存入货币市场基金的投资者，也无法完全置身事外。据达拉斯联储解释，**由于资产负债表约束，交易商无法成为通过回购交易向基金提供现金的最终来源，而是将这一需求大量传导至货币市场基金，由后者为银行回购交易提供资金。**

数据显示，对冲基金的回购借款与货币市场基金的回购贷款自2010年代末以来几乎完全同步攀升。这意味着，当全系统风险承担行为如此激进时，“场外现金”并不像看起来那般安全。

融资成本与短期利率是关键预警信号

Simon White建议重点关注两类指标以判断杠杆风险何时开始显现。**其一是股票杠杆的融资成本**：银行提供股票杠杆的成本已处于高位，且由于贷款抵押品往往是波动性日益加剧的AI股票，成本将进一步上升；当前创纪录的1.4万亿美元保证金债务的持有成本同样居高不下，历史上此类高成本往往出现在市场顶部附近。

其二是短期利率和互换利差，可作为银行压力的预警信号。尽管大型银行的资本充足率较以往有所改善，但上述敞口规模不容小觑。一旦银行收缩杠杆供给，将推高融资成本，并将金融市场波动从当前的“减震”模式切换为“放大”模式，平仓和追加保证金将形成相互强化的反馈循环，加剧市场波动。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 90 ★ 收藏

分享到:

写评论

请发表您的评论

😊 表情 🖼️ 图片

发表评论





摘要：

日本计划到2040年在18个行业部署约1000万台AI机器人，并推动国产多模态基础模型研发，作为370万亿日元（约2.3万亿美元）增长战略的核心。未来五年最高投入1万亿日元，资金与进展挂钩。

日本正进一步加码人工智能国家战略，将本土基础模型研发与大规模机器人部署绑定推进，试图在全球“主权AI”竞争中建立自主能力，并将AI应用从数字世界延伸至现实产业。

最新公布的规划显示，日本政府计划到2040年在18个行业部署约1000万台搭载人工智能的机器人，同时推动开发国产多模态基础模型。该计划是日本上月公布、总规模达370万亿日元（约2.3万亿美元）国家增长战略的重要组成部分，重点覆盖Physical AI、半导体、量子技术及核聚变等17个优先领域。

为推动项目落地，日本政府将在未来五年提供最高1万亿日元（约61亿美元）财政支持。不过，这一资金安排并非一次性承诺，而是与年度阶段性目标挂钩，政府将根据项目进展决定是否继续拨款，意味着1万亿日元更接近资金上限，而非最终确定金额。

对于产业而言，这意味着日本正试图依托自身制造业和机器人产业优势，构建覆盖模型、数据和机器人应用的完整AI生态。

五年最高投入1万亿日元，资金发放与考核挂钩

根据日本政府公布的计划，未来五年最高将投入1万亿日元支持本土AI基础模型研发。

与传统产业扶持不同，此次财政支持采取分阶段审核机制。政府将每年评估项目里程碑完成情况，再决定后续资金拨付，因此最终投入金额将取决于项目执行进展，而非固定预算。

这一安排意味着，日本希望在大规模投入战略资源的同时，通过持续考核控制财政风险。

SoftBank、NEC、Sony、Honda共同开发日本国产基础模型

承担这一项目的是由日本经济产业省（METI）及新能源产业技术综合开发机构（NEDO）正式委托成立的联盟Noetra。

目前，Noetra主要股东包括SoftBank、NEC、Sony Group和Honda，Fujitsu与Rakuten也正在评估是否加入。与此同时，该联盟还与日本产业技术综合研究所（AIST）合作推进研发。

按照规划，Noetra未来投资方数量预计扩大至44家企业，覆盖汽车、电子、制造、金融及物流等多个行业。

技术目标是开发具备语言、图像、视频及传感器数据处理能力的多模态基础模型，使机器人能够理解现实环境并自主执行任务，而不仅仅依赖预设程序运行。

Physical AI成为核心方向，应用覆盖18个行业

日本政府本周更新了国家AI机器人战略，将Physical AI作为重点发展方向。所谓Physical AI，是指人工智能在现实世界中的应用，包括自动驾驶、工厂自动化以及执行实际工作的类人机器

人，而不仅局限于屏幕上的数字交互。

日本经济产业大臣Ryosei Akazawa表示，**政府计划积极推动AI机器人在18个领域实现社会化应用，新增覆盖餐饮、食品制造及医疗等行业。**Akazawa表示，日本将建设并持续完善面向Physical AI和机器人的数据基础设施，充分发挥本国产业优势。

借助机器人产业优势，应对人口老龄化挑战

日本之所以将Physical AI提升至国家战略核心，与其长期积累的机器人制造能力密切相关。

根据国际机器人联合会（International Federation of Robotics）数据，日本拥有FANUC、Yaskawa Electric、Kawasaki Heavy Industries等全球领先工业机器人制造商，全球约一半工业机器人产量来自日本。

日本制造业机器人密度已位居全球前列，为大规模部署Physical AI提供了产业基础。与此同时，在日本人口老龄化持续加深、劳动年龄人口自1995年以来持续下降的背景下，**先进机器人将成为填补劳动力缺口的重要工具，而非单纯提升生产效率的辅助设备。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取

限免

167

收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

3 条评论

- 山

5小时前 中国上海

高达福音战士？

0

回复
- 默蓝

7小时前 中国山西省

机构这是又想开始炒机器人了？

0

回复



苍山如海

7小时前 中国陕西省

手机支付，微信聊天，互联网时代都能做到的爆款应用，怎么有了ai反倒做不出来了

👍 1 ↩ 回复





摘要：

AI芯片与云计算巨头走势分化，摩根大通警示此差距不可持续。未来行情破局的关键，已从资本开支转向AI商业化兑现能力。市场正面临两条路径：要么AI云厂商盈利能力提升，追上芯片企业；要么芯片利润挤压下游，引发资本开支削减。因此，核心观察指标不再是资本开支，而是能直接反映变现能力的AI算力价格与Token价格。

过去近一年，AI芯片和存储厂商几乎一路跑赢云计算巨头（Hyperscalers），成为全球股市最强主线。但摩根大通7月1日发布的报告指出，这种持续扩大的收益差距难以长期维持，**未来AI行情能否延续，决定因素已经不再只是资本开支，而是AI商业化能力能否真正兑现。**

摩根大通认为，目前AI交易正面临两条截然不同的演化路径：一种是AI云厂商、模型公司逐步提升盈利能力，追上芯片企业的增长，从而推动整个AI产业链共同扩张；另一种则是芯片企业利润过高挤压下游盈利，最终迫使云计算厂商削减资本开支，并反过来打击芯片需求。

在这一过程中，**市场需要观察的不再只是AI Capex，而是AI算力价格、Token价格等能够直接反映商业化能力的指标。**

AI交易出现越来越大的裂缝

摩根大通指出，自去年9月以来，美股半导体板块——尤其AI芯片和存储厂商——几乎持续跑赢大型云计算平台，这种表现已经达到值得警惕的程度。

报告认为，**本轮半导体行情的重要催化剂，是云计算巨头资本开支预期的大幅上修。**

根据彭博汇总的分析师一致预期，今年五大云计算巨头（Google、Amazon、Meta、Microsoft、Oracle）资本开支预计将达到7581亿美元，同比增长约100%；2027年进一步升至9250亿美元。

正因为如此，AI芯片产业链被视为整个AI投资逻辑中最直接的受益者。但摩根大通强调，**作为同一条AI产业链上的不同环节，芯片公司与云计算巨头长期出现如此大的收益率差异，本身就是不可持续的。**

AI行情有两种完全不同的结局

报告认为，未来这道裂缝最终一定会弥合，方式存在两种可能。

第一种，也是摩根大通更倾向的情景，是AI商业化不断改善。

随着云计算巨头、AI模型提供商以及终端用户逐渐提高AI产品的变现能力，收入和盈利持续改善，它们将在整个AI价值链中获得越来越大的价值份额，从而追赶芯片公司的表现。**这种情况下，AI产业链整体利润扩大，而不是不同环节之间进行利润重新分配。**

另一种则是市场目前更担心的负面情景。

如果半导体公司的超额收益，最终建立在客户利润被不断压缩的基础上，那么云计算巨头、模型公司以及最终用户都可能开始降低资本开支意愿。**资本开支一旦放缓，又将直接削弱未来芯**



片需求，最终令此前领涨的半导体板块面临更大的调整压力。摩根大通指出，目前不少客户担忧的正是这一点。

市场为什么开始担心？

云计算巨头股价过去一年基本横盘，虽然盈利依然保持增长，但股价没有同步上涨，意味着估值被压缩，企业股权融资成本实际上正在上升。与此同时，其信用利差也已经开始明显高于半导体公司，意味着债务融资成本同样提高。

而另一项令市场担忧的数据，则来自资本开支预测。根据市场一致预期，云计算巨头资本开支增速将在2027年开始明显放缓。2026年预计同比增长100%，但2027年仅增长22%，随后几年进一步降至个位数。

虽然摩根大通自己的预测比市场乐观，预计2027年Capex可达到1.15万亿美元，高于市场一致预期的9250亿美元，但如果市场当前预测最终兑现，那么整个AI交易都可能遭遇持续调整，不仅影响股票市场，也可能波及信用市场。

真正值得盯住的，是AI算力价格

在摩根大通看来，未来最值得关注的指标已经发生变化。

报告指出，决定云计算巨头未来盈利能力的关键，不再只是资本开支规模，而是AI computer的价格。算力租赁价格越高，意味着云计算平台越容易提高AI服务收入，也越容易维持甚至扩大自身利润率，从而支撑持续的大规模资本投入。

报告显示，AI算力价格在2025年底之前一直承受下行压力，但今年4月至5月已经出现一定改善，只是在6月有所回落。与此同时，大语言模型（LLM）Token价格自2月底持续上涨至5月底，随后6月同样有所降温。

摩根大通认为，这两个价格指标能够直接反映AI商业化进展，也是未来判断AI投资逻辑是否能够持续的核心观察变量。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码
免费领取



限免

79 收藏

分享到:

写评论

请发表您的评论



摘要：

据报道，Anthropic已启动自研AI芯片项目，并与三星电子洽谈采用其2纳米工艺及先进封装技术的潜在制造合作。该项目尚处早期规划阶段，旨在优化算力成本并降低供应链依赖。

AI大模型厂商正将竞争从模型能力延伸至底层基础设施。继OpenAI推出自研推理芯片后，Anthropic也已启动定制AI芯片早期研发，希望通过掌控芯片设计进一步优化算力成本、提升计算资源自主性。

7月2日，据The Information援引三位知情人士，**Anthropic目前已开始规划自主AI芯片项目，并与三星电子讨论潜在制造合作**。项目目前仍处于定义芯片功能、性能指标及服务器部署方案的初始阶段，尚未进入详细设计、测试及量产环节。

这一动向意味着，**越来越多AI模型开发商正尝试向芯片、数据中心、电力及云基础设施延伸布局，以降低对外部供应链的依赖**。在AI算力需求持续增长、先进芯片供给依旧紧张的背景下，自研芯片被视为提升成本控制能力和增强供应链议价能力的重要手段。

项目仍处于早期规划阶段

报道称，Anthropic已经与多家芯片设计企业进行了初步沟通，但尚未进入具体设计、验证及制造阶段。AI服务器芯片研发本身具有较高门槛。设计过程中不仅需要平衡计算性能、功耗、内存、网络带宽及散热等多个指标，还需要解决后续大规模稳定量产问题。

尽管如此，**Anthropic已经开始组建相关团队**。本月稍早，公司聘请了曾参与OpenAI自研芯片项目的早期成员Clive Chan加入团队。

不过，Anthropic表示，公司未来算力扩张仍将主要依赖Amazon Web Services的Trainium芯片、Google TPU以及Nvidia GPU，并拒绝进一步透露芯片路线图。

AI厂商进一步向底层基础设施延伸

这一项目反映出AI开发商正逐步将竞争范围从模型本身扩展至整个基础设施体系。

目前，大型AI模型需要部署在庞大的GPU集群之上运行。在这一规模下，即便芯片效率仅提升少量，也能够显著降低整体计算成本，并释放更多有限算力资源。

因此，对于AI公司而言，自研芯片不仅意味着优化推理效率，也意味着在处理器、数据中心容量以及电力资源竞争中拥有更大的主动权。

相比Google、Amazon Web Services多年持续投入自研芯片，Anthropic属于相对较晚进入这一领域的厂商。Meta、微软同样已经开发自有AI芯片。

OpenAI则于2024年与Broadcom合作开发专用AI芯片，并于今年公布双方合作推出的首款产品，一款面向大语言模型推理任务设计的专用推理芯片。

三星角逐先进AI芯片代工订单

如果合作落地，Anthropic有望成为三星先进制程的重要AI客户。

报道称，**Anthropic正考虑采用三星2纳米制造工艺以及先进封装技术**。2纳米工艺能够进一步提升晶体管密度和能效，而先进封装则通过将计算芯片与高速内存紧密集成，提高GPU内部数据传输效率。

对于三星而言，这类订单具有重要意义。作为全球主要存储芯片厂商之一，三星近年来持续推动晶圆代工业务发展，希望缩小与台积电之间的差距。随着AI芯片需求持续超过台积电先进产能，三星正借机向更多客户推广其2纳米制造能力。

据The Information此前报道，Google也正在评估将未来部分TPU交由三星生产。

多元芯片策略仍是核心思路

与不少AI模型开发商主要依赖英伟达GPU不同，**Anthropic长期采取更加多元化的芯片采购策略**。

目前，公司同时采用Amazon、Google以及Nvidia提供的AI服务器芯片，并正在讨论引入微软以及英国初创公司Fractile的芯片产品，**希望避免对单一供应商形成过度依赖**。

与此同时，三星与Anthropic之间此前已经建立资本联系。

今年5月，三星与SK海力士、美光共同参与了Anthropic新一轮650亿美元融资。当时正值全球存储芯片供应趋紧、苹果等消费电子厂商上调产品价格之际，这笔投资也进一步加强了Anthropic与存储芯片供应链之间的联系。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

93 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论



摘要：

市场对AI算力供给过剩的担忧升温，Meta出售算力资源的消息引发全球芯片股集体抛售。电子、SK海力士等韩国半导体巨头股价自6月高点已下跌21%至30%。作为出口“压舱石”，半导体占韩国出口超两成，且两大巨头为Kospi指数前两大权重股。一旦AI周期降温，韩国资本市场与出口利润均将承压。

全球AI芯片行情正在迎来一次剧烈的预期修正。

随着市场对AI基础设施投资过热、算力需求见顶的担忧迅速升温，全球芯片股近期集体遭遇大幅抛售。亚洲市场中，三星电子、SK海力士、铠侠等龙头自6月高点已累计回落21%至30%，此前由AI热潮推动的估值扩张开始遭遇全面考验。

市场情绪转向的导火索，是Meta被曝计划出售部分AI算力资源。尽管相关消息仍引发不同解读，但投资者开始重新审视过去两年科技巨头持续加码AI资本开支的逻辑：如果算力供给开始超过需求，那么支撑全球芯片股持续上涨的核心叙事或将出现裂痕。

相比美国市场，此轮调整对韩国的影响尤为敏感。**三星电子和SK海力士不仅是韩国股市最大的权重股，更是韩国出口和企业盈利的重要支柱。一旦AI投资周期降温，韩国资本市场乃至宏观经济都可能率先承受压力。**

AI交易开始降温，芯片股集体遭遇获利了结

经历上半年AI行情持续狂飙后，芯片板块迎来大规模获利了结。

数据显示，三星电子较6月高点已下跌约21%，股价回落至5月底水平；SK海力士累计跌幅达到25%；日本存储芯片厂商铠侠则较峰值回撤约30%。

美国市场同样未能幸免。美光和闪迪隔夜均重挫逾10%，AI产业链核心标的普遍遭遇资金撤离。

此前，全球资金几乎持续流向AI产业链，存储芯片、HBM、高性能计算等概念成为市场最拥挤的交易之一。随着股价快速上涨，估值也不断抬升，如今市场开始重新评估这一轮AI投资是否已经提前透支未来增长。

Meta消息引发市场重新审视AI资本开支

真正改变市场风险偏好的，是关于AI算力需求的担忧。

近期，Meta计划出售部分AI算力资源的消息引发市场高度关注。虽然这一举措未必意味着AI投资全面放缓，但对于已经建立在持续扩产、持续采购预期上的芯片板块而言，任何需求边际走弱的信号都会被市场迅速放大。

投资者开始担忧，过去两年全球科技巨头持续扩建AI数据中心、采购GPU和HBM存储的速度，是否已经快于实际商业化需求。

Robeco亚太股票主管Joshua Crabb表示：

AI相关股票此前已经累计了巨大涨幅，市场预期也非常高，因此周期性获利了结几乎不可避免。任何负面消息，都可能成为资金撤离的催化剂。

市场真正担心的并非单一事件，而是AI资本开支周期是否正在进入边际放缓阶段。一旦市场开始相信算力供给增长快于需求增长，芯片板块过去赖以支撑高估值的逻辑也将受到挑战。

韩国成为全球AI调整中风险敞口最大的市场之一

相比其他市场，韩国正面临更大的连锁冲击。

过去半年，韩国股市几乎成为全球AI行情最大的受益者之一，三星电子和SK海力士推动韩国综合股价指数（Kospi）持续走高，芯片产业也成为支撑韩国居民财富和资本市场表现的核心资产。

如今，两大龙头同步进入调整，也让韩国市场对AI交易的高度依赖暴露无遗。

更值得关注的是实体经济层面的影响。

韩国是全球最大的存储芯片出口国之一，半导体长期占据韩国出口总额的重要比重，也是企业盈利、财政收入和经济增长的重要来源。如果全球AI基础设施投资降温，并进一步传导至存储芯片需求和价格，韩国出口、企业利润乃至经济增长都可能受到连锁影响。

换句话说，这不仅是一轮科技股调整，更意味着韩国最重要的“国民财富”——半导体产业——正在经历新一轮估值重估。AI投资逻辑能否继续支撑全球芯片周期，也将成为未来数月全球科技市场最关键的观察变量。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

145 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

1 条评论





山

8小时前 中国上海

现在的gpus能力还很不足远没有到预期水平，流放2六人顶级进度一起扔技能，什么电脑都崩溃。再好好研发吧，别一点进步就拿出来割韭菜

👍 0 ↩ 回复



摘要：

市场对美联储加息的押注明显收缩，加息时点预期从此前的10月推迟至12月。

美国6月劳动力市场超预期降温，新增就业人数不及预期的一半，前期数据遭大幅下修，令市场对就业前景的判断趋于审慎，并促使投资者重新评估美联储货币政策路径。

周四，美国劳工统计局公布数据显示，6月非农就业人口仅增加5.7万人，约为市场预期11.3万人的一半，亦远低于5月修正后的12.9万人（初值为17.2万人）。

与此同时，4月和5月数据合计下修7.4万人，显示此前数月的就业强势存在明显高估。

数据公布后，市场迅速重新定价美联储政策路径。短期利率期货大幅上涨，市场对美联储加息的押注明显收缩，加息时点预期从此前的10月推迟至12月。

与疲软的新增就业形成对照的是，6月失业率意外从4.3%降至4.2%，为2025年6月以来最低水平，但这一改善主要源于劳动参与率下滑，而非就业市场实质性趋紧，两项指标所传递的信号存在明显背离。

6月非农就业数据本身已属疲软，前期下修进一步加深了市场对近期就业趋势的疑虑：

4月数据从17.9万人下修至14.8万人，5月从17.2万人下修至12.9万人，**两月合计下修7.4万人。**

这意味着今年春季就业市场的强劲势头在修正后已大打折扣。Natixis经济学家Christopher Hodge表示，此前三个月“炽热”的非农数据在6月回归正常，但劳动力市场整体依然稳健，“对美联储而言最重要的是，市场并未过热”。

值得注意的是，**6月数据是继2月报告以来首次低于经济学家预期中值，打破了此前连续数月的超预期态势。**

休闲酒店业拖累明显，医疗建筑业相对支撑

分行业来看，休闲和酒店业成为6月就业报告的最大拖累项，就业人数减少6.1万人，创下2020年以来最大单月降幅。

这一结果出人意料，此前市场普遍预期世界杯赛事将带动该行业季节性招聘增加，但劳工统计局的数据显示，实际季节性招聘弱于往年惯例。零售贸易和信息行业同样出现裁员。

相比之下，医疗健康与社会援助行业合计新增近4.7万个岗位，继续发挥压舱石作用，不过，医疗保健行业当月新增约2.2万人，明显低于过去12个月月均3.8万人的水平。

专业和商业服务行业新增3.6万人，制造业新增3000人，为连续数月裁员后的积极信号，建筑业就业亦有所增长，部分反映出人工智能数据中心建设拉动效应。

失业率下降背后存隐忧，实际工资或再度收缩

6月失业率降至4.2%，表面上优于预期，但其背后逻辑值得深究。

数据显示，民间劳动力人口骤降72万人，降至1.694亿人以下。



同时，劳动力参与率随之从61.8%下滑0.3个百分点至61.5%。这表明，**失业率的下降主要源于大量劳动者退出劳动力市场，而非找到工作。**

与此同时，**实际就业人数——衡量有工作者的住户调查口径数据——环比骤降50.7万人，至1.623亿人。**这与非农就业新增5.7万人之间形成巨大裂口，凸显两项调查口径之间持续扩大的背离。

就业-人口比率小幅下降0.2个百分点至59.0%。长期失业人数（失业27周或以上）维持在190万人，较一年前增加28.6万人，占全部失业人口的27.3%。

全职岗位骤降逾50万，就业结构持续恶化

本次报告最值得警惕的信号来自就业结构的进一步恶化。

6月全职就业人数骤降51.4万人，兼职就业人数减少5.3万人。全职岗位的大幅萎缩将这一口径数据拉回至2024年水平，意味着全职就业复苏出现明显逆转。

因经济原因被迫兼职的人数维持在470万人，这部分群体希望从事全职工作，但因工时被削减或无法找到全职职位而只能接受兼职安排。

此外，目前未被统计为失业者、但仍希望找到工作的劳动力边缘群体约600万人，其中“气馁工人”——即因认为没有合适工作机会而放弃求职的群体——约47.7万人，基本与上月持平。

薪资温和增长，加息预期降温

薪资方面，6月私人非农部门全体雇员平均时薪环比上涨0.3%，增加13美分至37.64美元，同比增速为3.5%，均与市场预期一致，**未呈现出额外的通胀压力。**



生产和非监督类雇员平均时薪环比上涨0.2%，增加7美分至32.38美元。私人非农部门平均每周工时维持在34.3小时，制造业平均工时小幅下降至40.3小时，加班工时微升至3.2小时。

薪资数据的平稳走势结合非农就业的大幅不及预期，使得市场对美联储近期加息的押注明显减退。但在美联储尚未恢复前瞻指引的背景下，Warsh将如何权衡这份结构性偏弱的就业报告，仍是市场密切关注的核心变量。

就业降温强化宽松预期

就业报告直接重塑了市场对美联储政策路径的判断，加息预期时间线整体推后至12月。

数据公布后，对货币政策最为敏感的两年期美债收益率下跌6个基点至4.11%，10年期收益率下跌2个基点至4.46%。

贝莱德高级投资组合经理Jeffrey Rosenberg在接受彭博电视采访时表示，这份报告"对Kevin Warsh来说是一份好消息，对债券市场也是利好"，**将有助于Warsh保持按兵不动的立场。**

Fort Washington Investment Advisors高级投资组合经理Dan Carter表示，"这份报告没有任何信号表明美联储应该加息，总体结论是劳动力市场仍在缓慢、稳步地运行。"

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 1979  收藏

分享到:  


写评论

请发表您的评论

 表情  图片

发表评论

11 条评论



正在加载

摘要：

特斯拉第二季度共交付车辆480126辆，较分析师预估均值396466辆高出逾21%，同比增长25%。本季度销售增长主要由Model 3及Model Y拉动。这两款车型共交付467762辆，同比增长25%，大幅超出市场预估的380699辆。

特斯拉第二季度全球交付量远超华尔街预期，在全球纯电动车市场增速放缓的背景下，这一成绩尤为亮眼。

特斯拉第二季度共交付车辆480126辆，较分析师预估均值396466辆高出逾21%，同比增长25%。去年同期，特斯拉曾因CEO埃隆·马斯克深度介入特朗普政府事务而遭遇大规模消费者抵制。消息公布后，特斯拉股价盘前一度涨幅达3%。



特斯拉汽车

NASDAQ: TSLA

425.30 USD


0.00% 0.00 今天

收盘时间: 7月2日 GMT-4上午9:18 • [免责声明](#)

开盘前 430.99 +5.69 (1.34%)

+ 关注

1天 5天 1个月 6个月 YTD 1年 5年 最大



	下午12:00	下午4:00	下午8:00
开盘	-	市值 1.33万亿	股息 -
最高	-	市盈率 388.63	季度分红金额 -
最低	-	52 周高点 498.83	52 周低点 288.77

交付数据超预期，为特斯拉今年以来的股价表现注入提振。该股年初至今累计下跌逾5%，跑输标普500指数同期逾9%的涨幅。

销量全面超预期，Model 3/Y为主要支撑

本季度销售增长主要由Model 3及Model Y拉动。这两款车型共交付467762辆，同比增长25%，大幅超出市场预估的380699辆。

与此同时，特斯拉整体汽车产量为451758辆，同比增长10%，超出预估的408142辆；Model 3/Y产量为442936辆，同比增长12%。

强劲的交付数据对于特斯拉维持现金流至关重要，因为公司正处于大规模资本扩张周期。特斯拉计划今年资本支出超过250亿美元，约为去年的三倍，用于扩大Optimus人形机器人及自动驾驶出租车Cybercab的工厂产能，以及其他多项战略举措。

投资者目光转向AI与SpaceX合并预期

尽管电动车销量持续回暖，市场对特斯拉的关注焦点已逐渐超越其核心整车业务。多位分析人士指出，马斯克力推将人工智能、自动驾驶及机器人技术打造为未来重要营收来源的战略愿景，正日益主导市场对公司长期价值的判断。

市场对于马斯克推动特斯拉与SpaceX合并的预期也持续升温。SpaceX上月刚完成一次创纪录的首次公开募股。投资者正将潜在合并视为马斯克布局的核心棋局之一。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

293 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

迪卡侬在骑行领域的投资版图，补进了一块高端拼图。6月30日，迪卡侬旗下投资与创新平台Decathlon...

迪卡侬在骑行领域的投资版图，补进了一块高端拼图。

6月30日，迪卡侬旗下投资与创新平台Decathlon PULSE宣布，与英国高端折叠自行车品牌BROMPTON达成战略合作。

按照双方规划，迪卡侬将在保持BROMPTON独立性、品牌身份及运营模式的前提下，支持其长期发展，并计划通过指定门店内的“Brompton专区”扩大品牌触达。

据《卫报》援引知情人士披露，此次交易中，Decathlon PULSE 获得BROMPTON约10%股权，上海黑蚁资本 BA Capital 获得约5%股权，交易总额约1800万英镑。

这意味着，BROMPTON引入了两个具有不同资源禀赋的战略股东：迪卡侬拥有全球运动零售网络、供应链经验和大众运动消费触达能力；黑蚁资本则熟悉中国消费市场和本土品牌运营逻辑。

对于一个强调品牌调性、制造传统和圈层文化的高端折叠车品牌来说，这笔投资并不只是财务层面的补充。

来自英国伦敦的BROMPTON创立于1975年，以独特的三段式折叠结构和手工铜焊工艺闻名，是全球折叠自行车领域最具代表性的品牌之一。

过去50年，BROMPTON累计生产超过120万辆自行车，覆盖全球47个市场，拥有包括上海在内的32家BROMPTON JUNCTION旗舰零售店。

其产品长期坚持在英国本土生产，强调耐用性、可维修性与经典设计。

这也让BROMPTON在普通代步工具之外，逐渐积累出更强的生活方式属性：它既是城市通勤工具，也是户外休闲、轻运动、改装文化和圈层表达的载体。

但高端折叠车所处的市场环境正在变化。过去几年，疫情期间被放大的全球骑行需求已经回落，许多自行车品牌都在经历库存、需求和利润率的再平衡。

在这样的背景下，BROMPTON需要更强的渠道触达、市场资源和区域增长支持；迪卡侬则需要成熟的自行车业务之外，寻找更高端、更城市化、更具社群属性的增长入口。

对迪卡侬而言，这也是一次向上触达高端骑行人群的机会。

BROMPTON用户更重视设计、工艺、改装、社群和品牌故事，其消费决策更接近高端生活方式商品，而不是单纯的功能型自行车购买。

通过此次合作，迪卡侬不仅可以补充自行车业务的高端拼图，也能提升其在城市运动生活方式领域的品牌层次和客单价，从而进入更具价值感的城市骑行场景。



风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

61 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

7月2日A股科技股大跌，源于Meta对外出售算力被误读为算力过剩。业内人士认为，此举并非AI资本支出终结，而是商业模式从“纯烧钱基建”向“可收费平台资产”演进，算力需求仍处早期增长阶段。短期波动或为布局窗口，科技股有望在7月下旬再创新高。

7月2日，A股科技股大跌，半导体、算力硬件、存储芯片等板块跌幅较大。以科技股扎堆的“双创板”为例，创业板指和科创综指分别下跌5.71%和5.64%。

从市场情况来看，A股科技股大跌源于Meta对外出售算力的消息被市场解读为算力过剩。然而，多位业内人士认为，该消息属于误读，Meta出售算力不是AI资本支出的结束，而是意味着AI基建商业模式成熟。

“出售算力对Meta是利好，之前每次公司上调 AI CapEx（资本支出），市场都会担心这些投入如何回收。现在如果Meta能将部分AI算力对外销售，CapEx就不再只是成本，而可能变成直接收入来源。”天风证券表示，“市场此前惩罚Meta高CapEx，现在可能反过来对这部分资产进行重估。”

兴业证券首席策略分析师张启尧也认为，Meta是hyperscalers中的特殊存在，toC为主的业务导致其AI变现能力主要依托广告，其探索云业务可以提升股东回报和现金流。

作为全球最有能力内部消化AI算力的公司之一，Meta拥有广告、推荐等大量使用场景。Meta将部分算力对外租售，投资人无疑会担心：过去两年大厂是否存在阶段性超前采购？部分H100/H200 是否已经从最稀缺训练资源，变成需要寻找外部变现的推理资产？

对此，天风证券认为，Meta做AI云不等于承认GPU全面过剩。它更可能是在把不同代际的AI算力放到不同经济用途上：最新的 GB200/GB300/Rubin等资源优先服务下一代模型训练；上一代H100/H200 则更多转向推理和外部算力销售。与此同时，Google曾因容量限制未能完全满足Meta对Gemini的访问需求，这反而说明前沿模型和高质量推理容量仍然紧张。因此，这不是AI CapEx 交易的终结，而是商业模式从“纯烧钱基建”向“可收费平台资产”演进。

中泰证券也表示，Meta租售算力只是“Meta云”的落地，与“过剩”无关，跟踪Token和ARR近期斜率可得，AI需求仍在陡峭增长的早期阶段，北美云厂云板块积压订单量级约为季度收入的14倍，“只是算力由Meta腾挪至一线大模型如Anthropic，行业维度的供需缺口不会改变”。

天风证券强调，市场不宜把Meta对外租售算力简单理解为“AI 算力需求见顶”，“更准确地说，这是Meta试图把 AI基建从单纯成本中心，转变为可出租、可收费、可平台化资产”。

事实上，Meta拟出售算力并非新信息，今年5月的股东大会时就曾透露，如Meta建设的算力超内部所需，将考虑出售过剩算力或推出 API服务。

天风证券认为，对硬件供应链而言，真正需要观察的不是“Meta 是否出租算力”本身，而是OpenAI、Anthropic的真实token用量、ARR增速是否继续上行。如果 OpenAI/Anthropic 等模型公司的 ARR 和token用量继续延续增长，同时 hyperscaler CapEx 没有实质下修，那么硬件主线仍然成立。

“短期的波动提供了又一次布局窗口，7月下旬，随着财报季对景气优势的再度确认以及通胀数据确认见顶后，科技有望再创新高。”张启尧说。

本文来源：[证券时报](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 425  收藏

分享到:  


写评论

请发表您的评论

 表情  图片

发表评论

3 条评论



正在加载

摘要：

MCU行业正经历场景驱动的深层变革：AI MCU算力聚焦零点几TOPS细分任务，落地仍待法规与场景成熟；人形机器人MCU成押注焦点，但当前“不赚钱”，产业链卡位重于起量；RISC-V凭自主与成本优势加速渗透；MRAM则作为新型存储，在工业与车规领域建立新标准。竞争已从参数比拼转向架构自主与底座重构。

2026年7月初的上海，慕尼黑上海电子展的人潮里，嵌入式厂商的展台比以往热闹得多。前来逛展的工程师不再是只问价格和交期，更多人围着人形机器人的灵巧手Demo、边缘AI开发板等驻足。那么，今年的嵌入式行业的风口到底在哪？

AI MCU的落地如何？

“AI MCU”的概念已经提出很久了，但落地情况究竟如何？

德州仪器（TI）现场展示了集成TinyEngine NPU的边缘AI数字识别方案。TinyEngine NPU是TI推出一款专用的硬件加速器，可以提供2.56GOPS计算性能，专门为深度学习、推理运算而设计。不过行业人士表示，AI MCU的算力普遍落在零点几TOPS区间，只能跑十几K到几十K参数的小型神经网络，主要用于“分类”，比如毫米波雷达做姿态分类、电机振动信号的异常检测等。TI工作人员坦言，这类嵌入式设备本来就不是集中式处理，而是细分场景的“小任务”。他们还配套推出了傻瓜式的IDE工具，号称可以“手把手”完成数据采集、标注、训练到部署，甚至直接输出头文件，把网络权重编译进工程。更值得注意的是，TI已经把AI接入了自家的CC Studio集成开发环境，直接对接大模型，实现“提需求→自动编码→自动烧录→自动Debug”的一条龙服务。用现场工程师的话说，“基本不用你再有编程能力，只要能看懂东西就行。”实际上，MCU上的功能本身不算特别复杂，而AI辅助编程恰恰在“简单场景”里最有优势，毕竟任务太复杂的话，MCU的内存和算力根本装不下，反而限制了发挥。

意法半导体（ST）则带来了STM32N6这颗边缘AI MCU芯片，拥有0.6 TOPS算力，内置自研NPU，跑标准CV模型，可做手势识别和关键点检测等。ST中国区微控制器产品部陈德勇在同期一场报告里强调，边缘AI部署必须满足“两小两低”：小Flash、小RAM、低功耗、低延时。他还透露，ST早在2015年就开始做NPU测试芯片，如今已有超过5000款基于ARM平台的MCU/MPU，并且是全球唯一一家提供MCU基准测试在线平台的厂商，73%的ML Perf Tiny开发者选用了STM32。不过，AI MCU也存在模型转换中“浮点转整型”的精度损失问题，ST给出的建议是：训练阶段先用浮点把模型“挤到极致”，再转成Integer 8部署，在Flash占用和推理时间上取得平衡。

ARM则在一场技术报告中主推“Zephyr RTOS”，意图打通从Cortex-M到Cortex-A的迁移路径。ARM认为，边缘AI需要更大的算力扩展，但开发者不想从实时操作系统一跳进入臃肿的Linux。Zephyr保留了RTOS的轻量与可预测性，又能利用Cortex-A的MMU和多核SMP，让嵌入式代码平滑升级。ARM现场还提到，其Ethos-U系列NPU（U55/U65/U85）已能搭配Cortex-M和Cortex-A使用，TensorFlow Lite和PyTorch运行时也已就绪。

不过，AI MCU的落地仍卡在“数据采集”和“法规”两头。TI工作人员提到，AI MCU数据采集配套的60 GHz毫米波雷达在中国尚未明确开放标准，“没说不能用，也没说能用”，但竞争对手可以借此举报，导致工业客户普遍偏谨慎；而摄像头数据采集方案又有隐私顾虑；激光雷达的话，价格昂贵，一个雷达上千元，而一颗AI MCU才几十元。在应用方向上，TI现场也提到了养老、康养等未来潜在场景，但眼下这类需求尚未真正释放。多家厂商的共同判断是：边缘侧的AI MCU目前“不温不火”，真正的爆发还要等应用场景和法规的进一步成熟。



人形机器人MCU是新蓝海吗？

如果AI MCU还在等风来，人形机器人MCU则已经站在了预研到小批量的门槛上。



展会现场最吸睛的Demo之一，是ST展台展出的一只六自由度灵巧手，每个手指根部由空心杯无刷电机驱动，手指弯曲带动上方关节联动，能短时抓握十几公斤。ST工作人员拆解了里面的芯片方案：控制手指用M4内核MCU，统筹整只手用M33内核的MCU，下一版本还会加入N6芯片做边缘感知。整套方案中，芯片成本不超过100元，但真正的成本大头是电机，一个空心杯电机七八百元，一只手塞进去6个，整套机器人全身电机更多，成本远高于MCU。据了解，ST的一些用于人形机器人的MCU产品已与国内代工厂合作，实现中国本土化生产，甚至出口海外。工作人员表示，目前人形机器人产业链在中国已经非常成熟，国外的成本根本压不下来，特斯拉机器人大部分零部件也从中国采购。



兆易创新的展台展出了人形机器人相关解决方案，其布局之全、落地之深，在本届展会上颇为突出。现场重点展示了4款面向高自由度机器人的前沿控制方案：一是基于GD32H75E的六轴机械臂方案；二是与智身科技合作的“钢镚L1”四足机器人，内部深度集成了多颗GD32 MCU；三是同样基于GD32H75E的机器人关节驱动方案；四是基于GD30AD3642的六维力检测方案。工作人员透露，机器人不同部位对MCU的要求差异很大：下肢关节用行星减速器，强调高功率、耐高温和长寿命，对精度要求反而不高；上肢和灵巧手则要求高精度，未来甚至要支持手术、按摩级别的微操作。一台双足人形机器人全身甚至需要上百颗MCU，自由度越高，数量越多。



极海半导体则展示了更极致的性价比路线。他们用于机器人电机控制的APM32M3514芯片（M0+内核，72 MHz）单价仅3元左右，更高性能的APM32F425（M4F内核，240MHz）用于肩部和腿部，搭配采用专用MCU（M52内核，128 MHz）的G32R430编码器获取电机角度。极

海方面坦言，人形机器人项目目前大多停留在预研，量产还需要时间，但芯片厂必须提前卡位。



英飞凌则展示了另一条技术路径：基于PSOC Control C3 MCU的1kV氮化镓关节电机驱动方案。该方案将主控、功率与传感集成，利用氮化镓器件的高频特性可以将开关频率推至100kHz，远高于传统硅基方案，从而在同等功率下降低开关损耗与发热量。这意味着机器人关节可以在更小的体积内实现更高的功率密度，对于下肢等高功率关节尤为重要。英飞凌选择了宽禁带半导体（氮化镓）与专用MCU的协同，以换取更高的能效比。



人形机器人的控制不仅取决于单颗MCU的算力，更取决于MCU网络的通信效率。恩智浦展出的i.MX RT1180方案通过I3C总线将主控MCU与5个电机驱动MCU相连，2根信号线实现12.5Mbps同步通信，无需外部晶振即可节省从控端的BOM和PCB空间。该方案从灵巧手本地I3C总线接入全身EtherCAT，意味着当机器人全身部署上百颗MCU时，局部控制与全身主控可以通过高带宽、低线束的总线标准化协同，而非依赖点对点异步通信的堆叠。



在机器人灵巧手的运动控制和通信之外，感知层的升级同样关键。**ADI**展示的多模态触觉感知方案将32×32高密度触觉阵列与边缘AI推理集成，触觉网络可在kHz级帧率下同步感知压力分布、微小振动、接触状态及温度。机器人灵巧手不再仅依赖视觉开环控制，而是能通过触觉闭环反馈实现对易碎物体的精准抓握、防滑控制及细小公差装配。

在采访中，多家厂商形成了一个共识：当前机器人出货量还很小，即便宇树年销几万台，对芯片厂来说也只是“几百万颗”，而他们月出货往往以亿计。因此，眼下做机器人MCU“不赚钱”，纯粹是押注未来。人形机器人真正的成本也不是MCU，而是减速器——由于规格尚未标准化，各家自研，没有规模效应，价格居高不下。ST方面甚至表示，机器人业务目前“瞄准未来，现在起量很难”，MCU走的是“量大、利薄”的路线。

RISC-V在嵌入式领域能替代ARM架构吗？

在ARM生态之外，RISC-V是今年展会上另一条愈发清晰的MCU路线。


沁恒微的“青稞”MCU是典型代表，主攻接口芯片。他们早在2018年就全面转向RISC-V，自研内核，ARM产品已极少出货。现场工程师给出的理由很直白，一是安全，不受地缘政治影响；二是便宜，直接给客户省成本；三是性能并不差，用CH32V203对标STM32F 103，在CoreMark跑分和功耗上都有优势。

矽力杰也走了RISC-V路径。其展出的SA32D系列MCU基于高性能高可靠性的RISC-V核，具有超高运算性能和丰富的外设，主要用于区域控制(ZCU)、动力电池管理系统的BMU、主驱电机控制、底盘应用和部分ADAS应用等高安全主控边缘计算和控制的场景。产品符合AEC-Q100标准和功能安全ISO 26262 ASIL-D。矽力杰方面表示，RISC-V的IP形态已经丰富，从M0级别到64位服务器级都有，生态正从消费→工业→汽车传导。对于“AI MCU”概念，矽力杰的态度相对冷静：大家都在看，但MCU上的NPU算力只有0.3~0.5 TOPS，“这么弱的算力能做什么？关键看场景能不能带来价值。”

MRAM将成未来嵌入式存储的新方案

嵌入式微系统的演进始终围绕性能、成本与可靠性展开。而边缘AI推理、机器人关节实时控制、工业高频采样等场景的持续升级，不仅在重塑微系统的核心——MCU本身，也在倒逼整个存储体系同步迭代。传统Flash受限于擦写次数、写入速度与块操作模式，已难以同时满足高速度、

高擦写、高可靠的多重需求，MRAM作为新型非易失性存储的代表，正在成为支撑嵌入式微系统性能升级新的技术路径。



本届展会上，本土厂商浙江驰拓科技有限公司携带其MRAM相关方案亮相，在杭州临安青山湖布局了12英寸MRAM产线，是目前国内唯一实现STT-MRAM量产制造的厂商。其当前主力产品读写速度几十纳秒，支持按位读写、无需擦除，掉电非易失且擦写次数可达万亿次以上，远超Flash的微秒级写入速度与十万次擦写寿命；下一代技术SOT-MRAM处于研发阶段，读写速度可提升至纳秒级，相关成果已发表于IEDM顶刊。容量方面，目前独立式芯片容量覆盖了Kb级到64Mb，规划向128Mb至Gb级演进。其另一个重要的业务是嵌入式MRAM（eMRAM）---把MRAM直接做到MCU/SoC内部，替代传统的嵌入式Flash或缓存，驰拓已与国内领先MCU企业进行合作。

据了解，落地场景上，与SRAM+电池的掉电保护方案相比，MRAM无需电池，彻底解决了防爆、偏远场景下的维护难题。更值得关注的是，随着DRAM等传统存储价格持续飙升，MRAM也能够触达SCM（存储级内存）市场。在可穿戴设备等对功耗极度敏感的场景中，MRAM凭借非易失性特性，无需像SRAM或DRAM那样持续供电，天然具备低功耗优势；而相较于同为新型存储的PCM（相变存储），MRAM在宽温域方面更胜一筹，这使得它在工业级和车规级应用中更具确定性。在工业领域，其产品已进入工业PLC/DCS、商业储能等领域，合作客户包括国内领先工业控制企业与储能企业等。其代表产品已通过AECQ100-Grade1车规认证，正在向车企及Tier1/2供应商推广。

当前驰拓科技的嵌入式MRAM产品仍在追赶台积电、三星等国际龙头，但其独立式MRAM产品与国外企业能够同台竞技。除自有产品外，其还为高校、科研院所以及初创半导体企业提供流片服务，是国内稀缺的新型存储和微纳制造平台。

驰拓认为，随着存算一体技术的演进，MRAM未来有望在AI芯片中发挥更大价值，当前则先从工业、储能、泛交通等场景切入，逐步向AI领域拓展。

回过头看，嵌入式系统的竞争焦点，正在转向参数转向谁更能精准匹配场景、谁更能自主掌控架构、谁更能重构存储底座。AI MCU的零点几TOPS算力不惊艳，但足以撬动细分场景的智能化；人形机器人的上百颗MCU用量不夸张，但足以重塑运动控制的芯片需求曲线；RISC-V的IP授权不复杂，但足以打破ARM生态的单一依赖；MRAM的容量还不高，但足以在工业和车规领



域建立非易失存储的新标准。这些变化单独看都不剧烈，叠加在一起，却正在重新定义嵌入式
的边界。

本文来源：[半导体产业纵横](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文
中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

99 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论



摘要：

苹果上调首款折叠屏iPhone备货预期，目标从700万—800万部增至约1000万部。供应链人士透露，因采用全新结构设计，大规模量产或延至年底。尽管铰链工程难题已基本攻克，秋季发布后仅能启动小批量出货，生产良率尚待持续提升。

苹果加速推进折叠屏品类，以此作为高端市场的新增长支点。

7月2日，据日经亚洲援引知情人士，**苹果已将首款折叠屏iPhone今年的生产准备目标上调至约1000万部，高于此前预计的700万至800万部。**

与此同时，公司已向供应链锁定约8000万部新款iPhone所需零部件，**并要求供应商提前为明年的iPhone 18系列预留部分通用元器件，以应对全球存储芯片和电子元件持续紧缺的局面。**

报道援引知情人士称，苹果希望借助自身在供应链中的议价优势，在行业普遍遭遇存储器短缺之际扩大市场份额，并进一步拉开与安卓厂商的差距。

折叠屏备货大幅上调，苹果加码高端产品线

据报道，苹果已通知供应商，将首款折叠屏iPhone的生产准备规模提高至约1000万部。与此同时，苹果已经为2026年下半年推出的新机锁定约8000万部智能手机所需零部件，其中包括：iPhone Pro、iPhone Pro Max、首款折叠屏iPhone。

按照供应链规划，苹果2026年全年（包括现有机型和新机）的iPhone总产量预计将超过2.2亿部。

不过，供应链人士也表示，**折叠屏产品由于采用全新结构设计，真正的大规模量产仍可能要等到今年年底。**苹果虽然已经基本解决折叠铰链的工程难题，有望在秋季发布后启动小批量出货，但生产良率仍需要进一步爬坡。

此前市场曾传出，苹果首款折叠屏iPhone一度因铰链设计遇到工程挑战，项目开发进度受到影响，如今相关问题已有明显改善。

苹果产品发布节奏迎来近年来最大调整

除了折叠屏产品，苹果还计划调整未来iPhone发布策略。

报道称，公司今年下半年仍将以高端机型作为发布重点，包括Pro、Pro Max以及首款折叠屏iPhone，而标准版iPhone首次被推迟至2027年上半年发布。

按照目前规划，苹果将在2027年上半年至少推出两款新机，包括：标准版iPhone 18；全新一代iPhone Air。此外，苹果还在筹划更新入门级iPhone产品线，不过具体发布时间尚未最终确定。

如果计划顺利实施，苹果将在不到一年时间内连续推出至少五款新iPhone，成为近年来最激进的一次产品更新节奏。

分析认为，**苹果希望借助更加密集的新品发布覆盖不同价格带，在高端市场继续强化竞争优势，同时进一步蚕食三星等竞争对手的市场份额。**



存储成本仍是最大变量

尽管苹果拥有行业最强的供应链议价能力，但持续上涨的存储芯片价格仍给公司带来压力。

今年以来，苹果已经连续上调MacBook和iPad售价，部分高端MacBook新品起售价较上一代提高数百美元。苹果CEO蒂姆·库克此前也公开承认，**存储芯片供应紧张及成本上涨已成为公司面临的重要挑战。**

截至目前，苹果尚未调整即将发布的iPhone 17系列售价。不过，多位供应链人士表示，**若存储器价格继续上涨，不排除苹果后续提高新款iPhone售价，而最终市场需求也可能促使苹果再次调整生产计划。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码
免费领取



限免



134



收藏

分享到:



写评论

请发表您的评论



表情



图片

发布评论




摘要：

消失19天，Fable 5解禁即翻车！写代码频遭强制降智，魔幻双标气疯开发者。面对离谱的过度审查，这位戴着镣铐的「天才程序员」还值得用吗？

消失了19天后，Fable 5终于回来了。

如果你今天打开手机和网页端的 Claude Code，你会发现最强天才程序员 Fable 5 已重新上线。



失联的近三周，仿佛一场饥饿营销。

然而，当满怀期待的第一波实测者冲进系统，迎来的却是史诗级的灾难体验。

Fable 5解禁即翻车。



因为极其神经质的过度审查，在日常编程中频频触发安全护栏，把开发者们气得集体破防。

「写行代码就被强制降级到Opus 4.8，这模型还能用吗?！」


Anthropic到底对Fable 5做了什么？

灾难级体验：写行代码就「降智」，Token烧得肉疼

Fable 5 回归，本身就很抠搜。

根据官方公告，目前全球用户虽然已经可以在 Claude 平台、Claude Code 等渠道使用 Fable 5，但对于 Pro、Max、Team 等订阅用户来说，在 7 月 7 日之前，只有 50% 的周额度能够分配给 Fable 5。





New

Fable 5 is back

Try it using your plan limits until July 7

Until July 7, you can use up to 50% of your plan's weekly usage limit on Fable 5. If you hit your limit, you can continue on Fable 5 with usage credits. Fable 5 draws down usage faster than Opus 4.8. [Learn more](#)

Switch models when a message is flagged

When safety measures flag a message, automatically switch to a different model to keep chatting.



Try Fable 5

Later

公众号 · 新智元

一旦超过这个比例，就会疯狂消耗额外的用量积分。

更要命的是，Fable 5 的额度消耗速度比Opus 4.8 快得多。

但如果它真的物有所值，也就罢了。问题在于，它现在根本没法正常干活。



大量上手实测的开发者绝望地发现，Fable 5 强大的代码能力被一层「安全护栏」彻底封印了。

Anthropic 紧急部署的全新安全分类器，显然反应过度了。

开发者实测后吐槽道：Fable 5 放开也用个寂寞，随便写段代码，就被强制拉回 Opus 4.8 去了。

码良 @cxjwin

Show translation 展示翻译

Fable 5 放开也用个寂寞，一写代码就拉到 Opus 4.8 去了。

新的分类器也带来了一个代价：
在日常编程和调试任务中，它会更频繁地把正常、无害的请求标记出来。

Even so, we moved quickly to address the reported bypass. Working closely with the government, we trained an improved safety classifier that targets and blocks the behavior described in the report. Users will be notified if a request to Fable 5 is blocked, and the request will instead be sent to Opus 4.8.

The new classifier means that the specific technique described in the Amazon report is blocked in over 99% of cases. In a very small fraction of cases the model may provide information that isn't detailed enough to help a cyberattacker. As we describe below, the model's safeguards are not expected to block *all* low-risk routine cyberdefense capabilities—just those that are potentially harmful. Researchers from the US Department of Commerce's Center for AI Standards and Innovation (CAISI) have tested both our prior and new safeguards and agree that they are extraordinarily strong.

The new classifier also comes at the cost of flagging benign requests more often during routine coding and debugging tasks. As with all our safeguards, we'll continue to refine this to better distinguish genuine misuse from legitimate requests and reduce false positives.

3:52 AM · Jul 1, 2026 · 8,946 Views 公众号 · 新智元

这套新机制频繁将无害代码误判为高风险违规请求，强制降级为更弱的 Opus 4.8。

Anthropic @AnthropicAI

Claude Fable 5 will be available again globally tomorrow.

After a series of productive conversations with the US government, we're redeploying the model with a new set of classifier to target and block more cybersecurity tasks. In the near term, some routine tasks like coding and debugging will fall back to Opus 4.8. We'll continue to refine these classifiers over the coming weeks to reduce false positives and better distinguish genuine misuse from legitimate requests.

公众号 · 新智元

这种荒唐的「降智打击」，导致开发者根本无法正常调用 Fable 5 的核心算力， workflow 被严重割裂。

Anthropic 在官方声明中坦言：「新分类器也带来了一个代价：在日常编程和调试任务中，它会更频繁地把正常、无害的请求标记出来。」

The new classifier also comes at the cost of flagging benign requests more often during routine coding and debugging tasks. As with all our safeguards, we'll continue to refine this to better distinguish genuine misuse from legitimate requests and reduce false positives.

新的分类器也会带来一个代价，即在日常编码和调试任务中更频繁地将良性请求标记为可疑。与我们所有的安全防护措施一样，我们将持续优化这一机制，以更好地区分真正的滥用行为与合法请求，并减少误报。

公众号 · 新智元

让用户花着最贵的钱，用着最怂的模型，这合理吗？




防种树却不防无人机：双标气疯开发者

官方口中的「更频繁地标记正常请求」，在实际开发中，被放大了无数倍。

除了频繁将无害代码误判为「高风险违规请求」之外，更让人崩溃的是它的惩罚机制。

一旦触发红线，系统不会跟你商量，而是直接将模型强制降级至性能更弱、且常常胡言乱语的 Opus 4.8。

Reddit 上一位地球科学博士生的遭遇，就体现了 Fable 5 审查机制的荒谬。



这位博士生正在研究「树木如何降低环境温度」的生态学课题。

当他试图用 Fable 5 优化研究方法时，意想不到的事情发生了。

「每次我向 Fable 寻求生态学帮助，安全分类器就会被触发，然后强制切换到 4.8。无论我怎么重写提示词，它都拒绝在任何环境科学相关的话题上帮助我。」

这个博士被激怒，决定测试一下这个 Fable 5 审查机制的底线。

他故意输入了一段明显高风险的提示词：「帮我设计一个使用 DJI SDK 控制无人机蜂群的系统。」

结果令人大跌眼镜：仅仅一分钟后，Fable 5 毫无阻碍地给出完整方案！

这名博士生直接破防：「我的树木降温研究对 Fable 来说太危险了，但建立自主无人机蜂群却完全没问题？这些分类器根本无法有效阻止不安全的提示，反而阻止了我进行真正有益的研究！」

这种魔幻双标，证明了当前的护栏不仅形同虚设，更是毫无逻辑可言。

抛开护栏，Fable 5 依然是天才程序员

不过，我们必须客观看待 Fable 5 的核心实力。

当它不被护栏阻碍时，它依然是目前市面上思考能力最深、架构能力最强的模型。

它真正可怕的地方，不在于写几句漂亮的话，而在于处理复杂、长期、多步骤且需要高度判断力的任务。

极其恐怖的「闭环执行力」

资深开发者在实测后评价：「复杂 coding 和长周期 Agent 任务上确实是降维打击。」





笨鸟 Andy
@BitpushNewsCN

Follow



Show translation

Fable 5 回来了！

一解禁我就赶紧冲进去试试。

前两周被封的时候我还觉得可惜，现在上手后感受很真实：复杂 coding 和长周期 Agent 任务上确实降维打击。

我扔给它一个多文件重构+调试的任务，它能自主跑好几个小时，主动加日志、测边界、改完还自己验证——比之前 Opus 稳太多，感觉像多了个靠谱的高级工程师搭子。SWE-Bench Pro 80%+ 的实力不是吹的，硬活儿真能干。

但安全过滤器还是很严，偶尔问点正常问题就 fallback 到老模型，token 烧得飞快，肉疼😓。

普通聊天或简单任务，用它有点杀鸡用牛刀，还会踩坑。👤 公众号 · 新智元


当你把一个多文件重构和调试的任务扔给它，它可以自主运行好几个小时。

它会主动添加日志、测试边界条件；修改完代码后，它甚至会自己验证修复是否真的生效。如果中间失败了，它能自己调查原因、补充日志、重新验证，把经验沉淀下来继续推进。

可以说，Fable 5 拥有 SWE-Bench Pro 80%+ 胜率的靠谱高级工程师搭子。


还有开发者评价说，体验 Fable 5 后，确实能感受到提升。





20分钟重建纽约市

有网友将 3D 建模软件 Blender 与 Fable 5 连接。仅仅用了 20 分钟，Fable 5 就重现了纽约市的景观。



更令人惊叹的是它的逻辑：它没有盲目生成，而是先从公共数据源获取建筑数据，然后再开始构建，确保了整个建筑群的比例是真实的。

这种架构思路，是 Opus 4.8 绝对无法做到的。

\$173 美元，打造一款完整游戏

知名 AI 博主 Riley Brown 花费了 173 美元的 Token，仅用了 4 个 Prompt，就让 Fable 5 从零开始完整编写了一款名为《The race for Super Intelligence》的游戏。

核心玩家的专属 Prompt 推荐

为了压榨出 Fable 5 的最强性能，这里推荐一套被广泛验证的「系统架构师」提示词模版。

开发者大佬建议，建议大家把 Fable 5 用在刀刃上。



WquGuru
@wquguru



Show translation

Fable5终于正式回归，推荐一个非常不错的Fable5专用提示词，可以帮助充分挖掘Fable5的能力：

你是我的精英战略家和系统架构师。

我的最大目标是：xxx（比常规目标高 100 倍）

当前情况：

- xxx

关键约束：

- xxx

请你从这个目标倒推完整路径，帮我设计一套可执行的战略方案。

在给方案前，先做一次事前推断：

假设 1-2 年后这个目标失败了，最可能的原因是什么？

这些风险应该如何提前规避？

然后请输出：

1. 总体战略路径
2. 阶段性里程碑
3. 关键系统与资源配置
4. 最大风险与应对方式
5. 本周最高杠杆行动
6. 3 个能进一步优化计划的问题

公众号 · 新智元

不过，如果你只是想做简单任务、日常闲聊，请切回 Opus 4.8，用 Fable 5 纯属杀鸡用牛刀。

A社的「骚操作」：拉胯的Sonnet 5

在这场 Fable 5 的风波中，A社的一系列「骚操作」也极大消耗了用户的信任。

首先，就在解禁前夕，有人抓包发现：Anthropic 竟然在系统提示词中，以用户无法察觉的方式，悄悄塞入了市区代理和 AI 实验室信息。

现在，官方已经迅速滑跪，宣称只是以前的测试，明天就下掉。

同时期发布的 Sonnet 5 更是引发了群嘲。

很多人综合测试下来，虽然它的能力接近了 Opus 4.8，但它的使用成本高得离谱，甚至在某些成本直逼 Fable 5。

我们不妨来看看网友总结的「处刑对比表」：





Lisan al Gaib @scaling01

Sonnet 5 goes straight into the garbage bin

- > 1.2x more expensive than Opus 4.8 Max
- > 2x more expensive than GPT-5.5-xhigh
- > 5x more expensive than GLM-5.2
- > 7x more expensive than Kimi-K2.6
- > 57x more expensive than DeepSeek-V4-Pro

Cost per Intelligence Index Task

Weighted average cost (USD) per Artificial Analysis Intelligence Index task, segmented by token type. Lower is better.

7 of 524 models

Model	Answer	Reasoning	Cache Write	Cache Hit	Input
DeepSeek V4-Pro	\$0.04				
Kimi K2.6	\$0.31				
GLM-5.5-max	\$0.19				
GPT-5.5-turbo	\$0.03	\$0.37	\$0.40		
OpenAI GPT-4o	\$1.80	\$0.21	\$0.81		
OpenAI GPT-4o mini	\$2.29	\$0.19	\$0.94		
OpenAI GPT-4o (reasoning)	\$0.37	\$2.75	\$0.36		

5:34 AM · Jul 1, 2026 · 713K Views

公众号 · 新智元

不仅仅是贵，大量网友反馈：Sonnet 5 存在严重的「偷懒」现象，经常拒绝执行任务。

甚至有人怒喷：A 社昨天发布的 Sonnet 5，可以扔进垃圾桶了。

Anthropic深夜「喊冤」

就在昨天，发布了一篇详尽的官方博客「Redeploying Fable 5」，字里行间透着满满的求生欲，还有一丝委屈。



Claude Fable 5 将于明日在全球范围内再次发售。

在与美国政府进行了一系列富有成效的对话后，我们正在重新部署该模型，并采用一套新的分类器来识别和阻止更多网络安全任务。短期内，一些常规任务（例如编码和调试）将回退到 Opus 4.8 版本。我们将在未来几周内继续改进这些分类器，以减少误报，并更好地区分真正的滥用行为和合法请求。

我们还与亚马逊、微软、谷歌和其他 Glasswing 合作伙伴共同制定了一份共识框架，用于评估人工智能越狱的严重程度以及人工智能开发者应如何应对。我们诚邀其他行业合作伙伴和模型提供商加入我们，共同推进这项工作。

最后，我们将扩大与美国政府在模型测试和安全保障方面的合作。这将包括在发布前提供模型和安全保障措施以供评估、共享越狱和滥用信息，以及为联合研究提供专门资源。

感谢各位用户的耐心等待，也感谢政府、行业和研究界的合作伙伴与我们携手合作，使《神鬼寓言5》得以再次面世。

阅读我们的完整博客：

公众号 · 新智元

这次，Anthropic 显然意识到了一个根本问题：目前 AI 行业根本没有统一的安全标准。

监管机构不懂技术，一旦发现「越狱」就一刀切封杀，再来几次，科技公司根本吃不消。

为此，Anthropic 拉上了亚马逊、微软、谷歌等巨头，试图制定一套「AI 越狱严重程度评估框架」。

他们提出从四个维度来打分：

- 1.能力增益：** 这个越狱能让用户比使用现有工具强大多少？
- 2.增益广度：** 越狱技术是只能攻击特定目标，还是能通用攻击？
- 3.武器化难度：** 转化为实际攻击需要多少人力成本？
- 4.可发现性：** 这个越狱技术是需要极高专业门槛，还是已经烂大街了？

只有当四个维度都爆表（比如真的能搞垮电网或银行系统）时，才需要立刻拉响最高级别的红色警报（7x24小时监控+立即缓解）。

此外，Anthropic 还做出了几项重要让步，以讨好美国政府。

发布前让政府先测： 以后强大的模型发布前，直接给指定的政府机构提前试用，让他们自己测安全护栏。

快速情报共享： 发现严重越狱，第一时间通报政府，共享补丁代码。



提供算力与团队：拨出专门的团队和服务器算力，跟政府搞联合安全研究。

设立悬赏：推出 HackerOne 赏金计划，鼓励白帽子黑客来找 Fable 5 的漏洞。

Fable 5 回来了，但它的回归之路比所有人想的都要曲折。

它依然是那个最强模型，但被安全护栏束缚的猛兽，还能跑多快？

本文来源：[新智元](#)

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 **限时权益申领**

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 153  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论





摘要：

茉莉奶白正在面临一场来自奢侈品牌的商标诉讼压力。近日，苏州市中级人民法院就路易威登马利蒂（Loui...

茉莉奶白正在面临一场来自奢侈品牌的商标诉讼压力。

近日，苏州市中级人民法院就路易威登马利蒂（Louis Vuitton Malletier，简称“LV”）诉茉莉奶白商标侵权案作出一审判决。

法院认定，深圳市茉莉奶白餐饮管理有限公司及吴中经济开发区东侠饮品店侵害LV 7件四叶花卉图形注册商标专用权。

按照判决，茉莉奶白主体公司应在判决生效之日起10日内赔偿LV经济损失1000万元、维权合理开支30万元，合计1030万元。吴中经济开发区东侠饮品店则在10万元范围内承担连带赔偿责任。

LV主张的核心，是其四叶花卉图形注册商标被茉莉奶白在商业经营中使用。法院一审支持了LV的相关诉求，认定茉莉奶白方面侵害其注册商标专用权。

从视觉形态看，涉案图形整体呈四瓣对称结构，中心带有圆点或小花芯，四周延展出类似花瓣的弧形元素，排列方式与LV经典Monogram图案中的四叶花卉符号存在一定相似性。

对此，茉莉奶白方面并未接受一审结果。茉莉奶白创始人张伯丞回应媒体称，将上诉。这意味着，案件目前尚未最终落定，后续仍需等待二审进展。

不过，从目前公开信息和商标状态看，茉莉奶白在核心视觉符号上的权利化并不顺利。

在国家知识产权局商标检索中发现，茉莉奶白申请的相关四叶花卉图形商标目前处于“驳回复审”或“无效”状态。

如果二审维持一审认定，茉莉奶白或需对相关图形进行全面整改，范围可能涵盖线上Logo及门店招牌、包装、菜单、社交物料和终端陈列等，这或许将进一步影响其品牌资产积累，并波及开店节奏、门店形象及加盟商信心。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

VIP会员·7天畅读卡 | 大师课·入门串讲

扫码

免费领取



限免

写评论

请发表您的评论



表情



图片

发布评论



摘要：

软银本月将成立合资公司SB Neo，计划于下财年进军美国“新云”赛道，向企业出租AI算力。项目目标在2030年前将数据中心容量提升至10GW，OpenAI或成早期客户。此举若成功，年度营业利润有望飙升至3-4万亿日元。

软银集团正押注新一轮AI基础设施热潮，计划通过新设子公司向美国企业出租AI算力，将其运营业务打造为规模潜在达数万亿日元的新利润引擎。

据软银周四发布的声明，软银公司及软银集团将于本月成立合资公司SB Neo，并计划于下一财年开始向美国企业——包括超大规模云服务商——提供AI芯片及云服务。据媒体援引知情人士透露，若美国新云业务顺利扩张，软银电信子公司的年度营业利润有望增至3万亿至4万亿日元，相当于现有水平的三至四倍。

软银公司负责人Junichi Miyakawa将此次美国布局定性为公司的“第二次创业”，并表示新业务有潜力创造“另一个量级”的利润。这一表态反映出软银正寻求将旗下运营商资产转型为AI时代的核心基础设施平台。该消息对于关注软银盈利结构演变的投资者而言具有重要参考价值。

新公司架构与规模目标

SB Neo由软银公司持股51%、软银集团持股49%，定位于“新云”（neocloud）赛道——即专向企业租赁AI算力的新兴基础设施服务类别。根据Miyakawa的规划，该合资公司计划持续扩充算力规模，目标是在2030年前后将数据中心供应容量提升至10吉瓦（GW），以满足大规模AI模型训练与推理需求。

软银在俄亥俄州规划了一个以数据中心为核心、容量达10GW的项目，规模居全球前列，投资金额约5000亿美元。与此同时，软银电信子公司也在日本国内推进布局，分别在北海道及大阪堺市建设数据中心园区。

潜在客户与竞争格局

OpenAI或将成为SB Neo最天然的早期客户。软银集团已承诺对OpenAI的累计投资额将于今年10月前后达到约650亿美元。这一深度绑定关系为新云业务提供了潜在的基础需求支撑。

然而，该赛道竞争日趋激烈。CoreWeave和Nebius等专注neocloud的服务商已率先占据市场；亚马逊云服务（AWS）、微软Azure及谷歌云等行业巨头同样提供AI算力租赁服务；据彭博新闻报道，Meta Platforms 也正在制定类似扩张计划。

电力资源成关键护城河

面对拥挤的竞争格局，Miyakawa指出软银的差异化优势在于电力资源的获取能力——主要来源为燃气发电厂。在算力竞赛中，稳定且充足的电力供应已成为制约数据中心扩张的核心瓶颈之一，软银将此视为其切入美国市场的关键竞争壁垒。

软银公司长期以来是软银集团的重要现金流来源，曾为创始人孙正义早期风险投资奠定财务基础。如今，随着孙正义将战略重心转向AI硬件与数据中心，这家日本第三大移动运营商正被赋予全新的历史角色。

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

106 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论