

摘要：

开源Kimi K3打破硅谷双头垄断，引爆AI界“斯普特尼克时刻”！大模型以1%成本步入“精密制造”时代。未来推理成本将暴跌50倍，端侧智能全面爆发。前沿模型加速沦为“易耗品”，应用接口层成最大赢家，企业资产迎来重估风暴。

随着月之暗面（Moonshot AI）发布拥有 2.8 万亿参数的开源模型 Kimi K3，硅谷迎来了 AI 领域的“斯普特尼克时刻”。

在最新一期《Moonshots》访谈中，Peter Diamandis、Emad Mostaque（前 Stability AI 联合创始人）等五位科技领袖深入探讨了 Kimi K3 打破传统闭源双头垄断的行业震动，指出大模型演进已进入“前沿制造业”阶段，并预测在硬件适配、软件优化与极端量化（如三元量化、亚比特量化）的推动下，未来几个月内 AI 推理成本将迎来 10 至 50 倍的爆发式下降，最终加速高阶智能在私有化部署与端侧设备上的全面普及。

核心要点

- **AI“斯普特尼克时刻”降临：**AI 实验室月之暗面（Moonshot AI）发布拥有 2.8 万亿参数（2.8 Trillion）的开源权重模型 Kimi K3，在前端代码竞技场（Front-end Code Arena）力压 Claude Fable 5 登顶第一，打破了硅谷此前由 OpenAI 与 Anthropic 主导的前沿模型双头垄断。
- **“造模型就像精密制造业”：**Kimi K3 依然基于标准的 Transformer 架构，其成功在于极致的数据精炼与工程制造能力。开源社区已证明，通过内核优化与数据清理，能够以传统成本 1% 的资金逼近顶尖前沿模型性能。
- **推理成本将暴跌 10 至 50 倍：**前 Stability AI 联合创始人 Emad Mostaque 表示，K3 目前每百万 Token 售价约 15 美元，但随着模型针对下一代硬件的适配以及开源推理服务商的极限优化，未来几个月内其推理成本还将迎来 10 到 50 倍的下行空间。
- **端侧智能与极端量化革命：**随着三元量化（Ternary, 1.58 bit）、二进制量化（Binary）及亚比特量化（Sub-one bit）技术的突破，到明年底，具备 K3 级别智能的模型将能够直接在 16GB 内存的手机或车载端侧设备上离线运行。
- **前沿智能变为“易耗品”：**前沿 AI 的“保鲜期”缩短至数周，企业评估模型的速度已跟不上迭代速度。未来的核心资产将从单一依赖闭源 API，转向可自由切分、微调开源模型的“架构接口层”。

Kimi K3横空出世：2.8万亿参数打破硅谷双头垄断

日前，AI 实验室月之暗面（Moonshot AI）突然发布了新一代前沿模型 **Kimi K3**，给硅谷及美国前沿实验室带来了如同“四倍浓缩咖啡”般的震撼。

Kimi K3 拥有高达 **2.8 万亿参数（2.8 Trillion Parameters）**，在性能上实现跨越式突破：不仅在前端代码竞技场（Front-end Code Arena）击败了 Claude Fable 5 斩获全球第一，还在品牌营销、设计、数据分析、消费品模拟及内容创作等 6 大领域登顶。更令行业震动的是，该模型

的完整权重定于 7 月 27 日全面开源，意味着全球任何企业与开发者均可免费下载并在本地（On-Prem）部署。

Alex Wieser-Gross 在分析人工智能指数（Artificial Analysis）的最新帕累托前沿图（Pareto Frontier）时指出：

“此前，前沿 AI 领域基本上被 OpenAI 和 Anthropic 双头垄断。而现在，随着 Meta、SpaceX AI 的加入以及中国 Moonshot 跻身帕累托最优前沿的第三名，**前沿 AI 竞争已全面演变为自由混战**。这对于希望通过开源模型掌握自身数据主权的企业而言，是巨大的福音。”

“做模型就像精密制造业”：用1%的相对成本逼近前沿

面对 Kimi K3 的性能跃升，美国前沿实验室不得不面对一个严峻的问题：**如果不用打破 Transformer 框架，就能达到逼近 GPT-5.5 Max 的水平，美国实验室每年烧掉的数十亿美元到底花在了哪里？**

Alex Wieser-Gross 补充道，K3 的已公开架构并没有“黑魔法”，本质上依然是标准的 Transformer，结合了专家混合（MoE）与线性化注意力（Linearized Attention）等成熟技术的精妙组合。

前 Stability AI 联合创始人 **Emad Mostaque** 提出了一个极其深刻的视角：

“打造顶尖模型，本质上是**前沿制造业**。他们极其清楚原材料（数据）与制造流程，并在现有的硬件约束下将工程化与易用性发挥到了极致。”

针对训练成本，**Dave Blundin** 举例说明，GitHub 上的开源加速项目（如 Keller Jordan speedrun）此前已成功将 GPT-2 级别的训练成本削减了 99%。而 Kimi K3 的出现，正式验证了这些软件栈优化、内核重构与数据去糙取精（如使用 Muon 优化器剔除无用 Token）的思路在**前沿超级大模型规模下完全成立**。

极端量化与端侧智能：推理成本还将暴跌10至50倍

在谈及 AI 的商业化落地与成本曲线时，**Emad Mostaque** 给出了极其乐观的预测。

目前，Kimi K3 的每百万 Token 调用成本约为 15 美元，虽高于普通开源模型，但考虑到其在本土芯片上运行且已具备极高利润率，未来的下行空间极为惊人：

“一旦将 K3 这种模型部署在下一代芯片或专用光子芯片上，并经过全行业的极限优化，**未来几个月内，其推理成本将再降 10 至 50 倍（乃至百倍）**。”

与此同时，**端侧智能（Edge AI）** 正迎来量化技术的暴风雨。

◦ **Prism ML 发布的 Bonsai 27B**：作为首个在智能手机本地完整运行的 270 亿参数模型，通过三元量化（Ternary, 1.58 bit），将模型体积压缩至 6GB（精度仅损失 5%），在完全离线状态下赋予手机 110-120 IQ 的智能。



- 三星与腾讯的极度量化：三星最新的 Nano Quant 已经突破了“每权重 1 个比特”的界限（Sub-one bit）；腾讯团队则实现了 3000 亿参数模型的二进制压缩（Binary Compression）。

Emad Mostaque 强调：

“到明年年底，一个仅需 16GB 内存的普通设备，就能运行达到今天 Kimi K3 级别的模型。这意味着世界上每一辆汽车、每一个机器人、每一台智能设备都将拥有内置的持久智能，可以在边缘侧进行自主决策。”

前沿智能变成“易耗品”：企业资产重估与开源大势

随着模型发布频率从过去的每 60 天缩短至每 10 天，甚至即将在明年初实现“日更”，前沿智能的商业形态发生了根本性转变。

OpenExO 创始人 Salim Ismail 提出：

“前沿智能（Frontier Intelligence）现在变成了一项完全易过期的资产，其保鲜期只有区区几周。任何企业如果要经过层层审批、内部开会来评估是否部署某款模型，等评估完成时，该模型在技术上已经落后了三代。”

这一趋势对企业资产定价与科技巨头估值带来了深刻重塑：

- 基础模型厂商估值承压：如果企业可以直接免费在本地运行性能媲美顶级闭源模型的开源权重，闭源 API 服务的溢价空间将被大幅压缩。
- 应用与架构层成为最大受益者：知名投资者 Gavin Baker 指出，除了基础模型厂商外，几乎所有的实体企业、软件公司与传统行业都是 AI 成本暴跌的巨大受益者。未来的核心竞争壁垒在于能否将模型灵活无缝嵌入自身业务流程的“架构接口层（Interfaces）”。

以下为访谈全文，由AI辅助翻译：

Peter Diamandis: 今天我们发出了紧急信号，召开这场紧急播客，因为美国刚刚经历了 AI 领域的“斯普特尼克时刻”。Kimi K3 于昨天发布，以有史以来最大的开放模型震惊了整个 AI 界，并直接登顶第一。

Emad Mostaque: 这个星期他们不仅缩小了差距，而且直接翻过了篱笆。Kimi 一直是一个感觉有点不一样的模型，这就是为什么它一直在写作基准测试中名列前茅。例如 K3 实际上是一个多模态模型，因此它可以接收各种输入并做出理解，这也是它在前端领域如此出色的原因之一。

Alex: 现在美方是 Meta 和 SpaceX AI 之间的自由竞争，而中国和 Moonshot（月之暗面）则成为了帕累托最优前沿上的第三名。前沿智能现在成了一项完全易过期的资产。

Peter Diamandis: 美国的前沿实验室把钱都花到哪里去了？

Salim Ismail: 在互联网世界我们一直有这个信念，即信息渴望自由，基本上智能也渴望自由。



Peter Diamandis: 我们现在需要的是某种全球性的……现在，那可真是个月球采样（Moonshot），女士们先生们。

Peter Diamandis: 欢迎来到《Moonshots》，所有人！全网关于 AI 与指数级技术第一的播客，您通往即将到来的奇点的前排座席——也许我应该说，通往现在的奇点、通往当下的奇点、通往持续的奇点。今天我将……今天我们发出了紧急信号并召集了紧急播客，因为美国刚刚经历了 AI 的斯普特尼克时刻，不过稍后会详细介绍。请允许我欢迎我优秀的 Moonshot 伙伴们，今天我们五人组全员到齐：Alex Wieser-Gross、Dave Blundin、Salim 和 Emad Mostaque。我是你们的主持人兼丰盈倡导者 Peter Diamandis。如果奇点的速度让你头晕目眩，很好，我的也是，而这正是重点。我们 Moonshots 的使命就是让您随时了解最新动态、跟上正在发生的事情，最重要的是，在非凡的变革速度与即将到来的丰盈时代中保持乐观。各位，欢迎，感谢大家大老早起床，或者对 Emad 来说是在下午。

Emad Mostaque: 我今天早上 4 点就起来了，时差的好处，不过我确实还能再睡一小时。

Salim Ismail: 欧洲午睡时间。

Emad Mostaque: 对，这之后我还安排了健身。

Peter Diamandis: 很多事情正在发生，各位，非常感谢大家的时间。在开始之前，我想亲自向我们所有的订阅者和观众说声谢谢。我不知大家最近有没有机会看看和阅读 YouTube 的聊天记录，我能说的就是我们也非常爱你们。我们的使命是传递新闻，我们花了难以置信的时间进行审查。Salim、Alex 和 Emad，我今天早上收到了你们的短信，“添加这个，添加那个”，有太多事情在发生。我也必须说，所有 Alex 解释 JSpace 的梗图都很棒，所以继续制作 Alex 的梗图吧。

Alex: 看看你们能不能搞懂我的 JSpace。

Peter Diamandis: 能看到里面的读数。在评论区也看到了很多对你的喜爱，有一些非常棒的人。难以置信的是，大多数 YouTube 视频 newspapers 都是喷子狂欢，而我们的完全相反，真的非常棒，向你致敬，Peter。不，我只是再次表达绝对的感激，感谢大家抽出时间听播客。我们团队和所有 Moonshot 伙伴花了大量时间评估发生了什么并呈现出来。如果您还没有订阅并开启通知，请开启。

Salim Ismail: 我只想说明，如果我们做足够多的这种紧急播客，在某些时刻它就会变成 Moonshots 每日播客。

Peter Diamandis: 或者是持续播客。我依然觉得大家一起搬进 Airbnb 然后打开摄像头，这早晚会发生。

Peter Diamandis: 好了，让我们切入第一个故事，这是个大新闻。我们刚刚经历了一个 AI 的斯普特尼克时刻，就像给美国的极前沿实验室注射了四倍浓缩咖啡一样。Kimi K3 于昨天发布，以有史以来最大的开放模型震惊了 AI 界，并直接登上第一名。这里有一些背景：Kimi 来自中国实验室 Moonshot AI（月之暗面）。在过去一年里，他们攀登排行榜，推出了 K2、K2.6、K2.7，每一个都在缩小与 Anthropic 和 OpenAI 的差距。这周他们不仅缩小了差距，而且一夜之间跨过了篱笆。他们发布了 Kimi K3，这是一个拥有 2.8 万亿参数的怪兽。他们完全绕过了计算墙，K3 比之前的 Kimi 模型跳升了 17 个名次，超越了 Claude Fable 5，在前端代码竞技场（Front-end Code Arena）斩获第一。K3 在其他 6 个领域也排名第一：品牌与营销、基于参考的设计、数据分析、消费品、模拟和内容创作。完整的模型权重定于 7 月 27 日左右发布，这意



意味着地球上的任何人都可以下载并在自己的本地（On-Prem）运行。各位，这有多重要？

Alex？

Alex: 我认为这对竞争非常有好处。首先作为一个初步事项，我想指出一些在报道和对 K3 的狂热中不太明显的事情。第一，正如 Moonshot 指出的，他们声称在过去 12 个月中的 9 个月中，Kimi 模型系列保持着开源权重模型中的 SOTA（最高水平）。如果这个说法属实，那么在过去一年里基本上一直都是 Kimi。第二，看看已发布的架构，因为我们还没有看到开源权重，但承诺在月底发布，里面并没有什么魔法，这非常引人注目。人们可以想象在 Anthropic 或 OpenAI 的幕后，Sam Altman 继续在暗示幕后有一些后 Transformer 架构实现了所有这些性能突破。但看看已发布的 K3 架构，没有魔法，它本质上仍然是 Transformer。他们显然做出了一些创新，但在他们如何做专家混合（MoE）、如何线性化注意力方面是大家熟知的创新，他们有自己的特殊的 Kimi 品牌的线性化注意力，但它本质上仍然是一个可识别的 Transformer。一个可识别的类 Transformer 架构可以在任务成本前沿上几乎匹配 GPT 5.5 Max，我认为这相当惊人。这就提出了一个问题：如果只需使用 Transformer 就能达到如此接近的水平，美国的前沿实验室把钱都花在哪了？如果它已经处于成本前沿，并且整体 AI 性能排在第三位，美国实验室到底把所有的钱都花在什么地方了？所以至少知道 Transformer 架构依然宝刀未老，我感到莫大的安慰。Emad，听听你的分析，因为你一直在追踪这个。

Emad Mostaque: Kimi 一直在各种基准测试中名列前茅，他们自一年多前发起以来就定期推出中国最大的开放权重模型。正如 Alex 所说，架构并没有什么特别新颖的地方，有一些改进，比如他们与 UCLA 等机构做的 Muon 缩放，他们一直在发布所有这些部件的线索。我认为这里的关键是底层数据。Kimi 的模型感觉一直有点不一样，这就是为什么它在写作基准测试中总是第一。他们在这里做的事情似乎非常非凡：GLM 出来时是个极好的模型，但仅限文本；而 K3 实际上是一个多模态模型，因此它可以有各种输入并做出理解，这也是它在前端如此出色的原因之一，尽管我们没料到它在前端代码上力压所有人登顶。这涉及我之前说过的话：构建优秀稳固的模型是前沿制造业。虽然会有算法改进等各种东西出现，但为什么中国电动车比福特更好？这感觉是同一回事。这是工程学，但也像上个月英国销量第一的车型 Jaiku J7，满配出来只要 5 万左右，只有三分之一的价格。这感觉非常相似，他们知道原材料成分，现在以一种对消费者极其友好方式呈现，并正在用他们现有的资源无情地执行制造过程。因为看架构内部，他们仍然在使用 H800，在 Nvidia 芯片上落后了几代，但他们通过静态形状等手段充分利用了华为和阿里的下一代芯片，在工程和易用性上不断推进，这就是为什么前端代码异军突起的原因。他们只是在想“如何做出最惊人的输出”，从个人网站到游戏；而美国实验室可能在看其他方向，专注于不同的事情。

Peter Diamandis: 有个问题，我们一直在讨论是否需要 LLM 之外的新突破才能实现 AGI，这是否让你确信我们不需要另一个突破就能继续前进？

Emad Mostaque: 这取决于对 AGI 的定义，对吧？六年前就讨论过。你有基础模型，然后所有这些优秀的套件，以及模型自我调用的方式。Kimi 博客文章中提到的一件事是，它实际上为自己的下一代设计了芯片，并设计了自己的运行内核。所以你从这个模型权重跨越到了模型本身构建的整个生态系统，这感觉就很 AGI，对吧？这感觉就像递归自我改进，感觉像通过动态改变自身来学习和适应新技能的能力。所以对于大多数 AGI 的定义，我们可能不需要新东西来优化和使其变得超级高效。甚至根据我们所知，它可能比现有的更高效，只是我们没有足够的算力，而新架构可以推动我们更进一步。你可以说“Attention Is Still All You Need”（注意力依然是你所需要的一切）。

Alex: 我们展示了性能图表，看到 Kimi K3 在多个地方登顶。如果能调出 AI 散点图，这是最有启发性的一张，来自 Artificial Analysis 智能指数。在所有图表中，这是我最喜欢的一张，因为它显示了 AI 定义的每任务成本与性能前沿。从左下到右上有一条锯齿状的前沿，右上角每任务最大成本和最大综合得分仍然是 Fable 5；沿着帕累托前沿往左下看，几天前前沿上的第二名仍



然是 GPT 5.6 Solve Max；而现在 Kimi K3 首次成为了第三名。无论是在原始能力方面，还是在最佳成本性能前沿的第三点上，它都处于前沿。这太震撼了。我们从几年前 OpenAI 和 Anthropic 双头垄断的世界，变成了现在美方的 Meta 与 SpaceX AI 加入帕累托前沿顶端自由竞争，而现在中国和 Moonshot 成为了帕累托最优前沿上的第三名。这对于任何愿意并能够使用中国开放（即将开源权重）模型来掌握自己命运的企业来说，都太令人兴奋了。我认为这是企业主权和竞争力的福音。我们正生活在 AI 版的《全人类》（For All Mankind）中，苏联人首先登上了月球，而现在太空竞赛永不结束。AI 竞赛不再以双头垄断结束，我认为这是未来光锥（Future Light Cone）的彻底福音。

Dave Blundin: Peter，你称之为斯普特尼克时刻，如果说有什么不同的话，那是低估了它的影响。上周 Alex Karp 在播客里发飙说：作为一个大企业或政府，你不能直接把所有的专有权重、专有 Alpha 和知识产权越过墙抛给 Anthropic 并作为未来的基础。但他没有给你路线图。仅仅一周后，正如 Alex 所说，这突然变成了一场自由竞争，任何读取这些权重的人都有能力极其接近前沿，然后针对任何垂直用例在超越前沿的领域进行微调。这给全世界的每个人、每家公司和每个政府提供了一种无需通过美国 AI 模型即可赶上前沿的方法。所以斯普特尼克时代乘以无限大。我不喜欢这张特定图表的地方在于左侧索引到了 100%，当绘制未来两年的图表时，它看起来像一条 S 曲线，我们现在处于非常陡峭的部分，但这暗示我们到了 100% 就达到了终点。但这实际上是一个指数级增长，智能趋于无穷大。基准测试饱和了，但智能本身趋于无穷大。典型的运作方式是嵌套的 S 曲线，对吧？一种特定技术触顶，但它构建了下一种开始指数上升的技术，以此类推。

Dave Blundin: Alex 和我花了大量时间研究 Keller Jordan speedrun，我们在 GitHub 上寻找它，它是一群黑客和 AI 研究人员不断试图采用五年前 Andre Karpathy 的 nanoGPT 形式的 GPT-2 类模型，尝试更快更便宜地再现它。如果你看看那个仓库里的创新，他们已经能够将创建 GPT-2 的原始成本降低 99%，现在只需原始成本的 1%。大家此前没太关注是因为它是 GPT-2，直到今天才明确这些想法是否适用于前沿规模。现在非常明确的是，当 Elon Musk 拿他的 160 亿美元 Colossus 2 数据中心花数十亿美元构建 10 万亿或 20 万亿参数模型时，存在一个 1% 成本的版本来创建实际上相同的东西。在 Kimi K3 之前没人知道这是否行得通，现在非常清楚它行之有效。我们在软件栈、内核优化、MoE 中看到了 100 倍级别的创新，这些来自中国的根本突破给他们带来了 1% 的成本。Ahmad 给汽车做了一个很好的类比，你可以以大约三分之一的价格获得几乎相同的汽车；而在这里，我们讨论的是不到 1% 的价格来创建同等产品。所以斯普特尼克时刻是本世纪最大的保守说法，这就是我们今天开紧急播客的原因。

Salim Ismail: 我有三点要说。我认为重点不在于 Kimi 击败了谁，而是前沿智能现在成了一项完全易过期的资产，对于任何达到最前沿的人来说，保鲜期现在只有几周。任何对最新的前沿模型感兴趣的企业或政府都没有时间去实际评估它、做 RFP、看其他模型、内部成立委员会思考是否部署，因为到时候你在模型上已经领先了三代。因此，所有的价值都来到了可以交换模型的架构上，我们 OpenExO 世界中称之为接口（Interfaces），这将是所有价值未来的归宿。

Dave Blundin: 我们需要一个新的词，比如“前沿解放阵线”（Frontier Liberation Front）。对于超级极客们，Ahmad 刚才提到了 Muon 优化器，任何爱好者都可以去查一下。我们构建这些原始的大规模模型时，从互联网上抓取了 20 到 30 万亿 Token，将人类写过的每个字都倾倒入训练集中，让 AI 变得聪明。但深入内部，大部分信息是泰勒·斯威夫特的演唱会和婚礼，这些并不能显著提升模型的智能，事实上恰恰相反。

Dave Blundin: 很多 Token 可能会拉慢训练而不是加速。因此仅通过清理垃圾并将训练集缩减为相关子集，就能在达到相同智能水平的同时减少 FLOPs 计算量。我们离解决这个问题还远着呢，所以你可以期待从 Muon 优化器过程和训练数据集精简过程中看到更多的 10 倍提升。



Peter Diamandis: 我放出了一个叫 Allaric 的人发出的令人深思推文：Anthropic 表示“Fable 是一种具身代码超级武器，能够以前所未有的速度和规模开发网络和生物武器，出于诚信我们不能在没有护栏的情况下发布它。”这是上个月的对话；而中国回答说：“笑死我了，这是 Fable 的开源版，祝你好运。”我很好奇，你们怎么看待我们因为护栏受到限制，而这里出现了 Fable 的开源等价物？

Salim Ismail: 前沿实验室面临三个巨大的根本约束：一是算力和芯片可用性及电力；二是与它们一样好甚至在许多情况下可无缝替代的前沿开源模型；三是政府审查。我拍脑门猜一下，当政府说必须审查所有模型时，OpenAI 原本价值万亿的估值缩水了大约 50%；我认为这又砸掉了 50%。如果不需要花 API 的钱，直接在本地运行 Kimi K3，我为什么要花这个钱？他们会受到收入大幅减少的打击吗？

Emad Mostaque: 有两点：一是收入减少，为什么人们依然为 IBM 付费、为非中国汽车付费？对于关键任务实体，确保不会出错的服务仍将维持一段时间，因此 OpenAI 等公司的收入仍会增长。但这里有替代效应，就像中国工业替代一样。在网络攻击安全方面，这意味着唯一能做的就是网络防御（Cyber Defense），这必然是风险投资中绝对最大的类别。如果是斯坦福或 MIT 的优秀毕业生，去建立一家切入前沿的网络防御初创公司，防御不可避免会到来的东西，因为这些能力的扩散会增加。GPT 5.6 网络版、Fable 等接受了大量 CVE 和网络数据训练，而中国模型实际上没有那么多，但有人可以将这些数据训练进去，因此我们可能会在特区看到具备网络攻击能力的开源出现。

Dave Blundin: 我们略过了递归自我改进（RSI）。美国政府的观点是：当我们得到一个能够构建自身、构建下一个模型的模型时，我们不会让它流向世界上的每个人，因为制造界从未有过像 AI 这样的产品。如果你有一辆最先进的汽车给外国政府，他们不能用它造出更好的车；但如果你把最先进的 AI 给外国政府，他们可以用它赶上你并创建最先进的 AI。一个月前政府意识到 Babel 5 跨过了那条线并阻止了它，只要有一个能够改进自己内核的 AI 就够了，人们以为 RSI 会在达到爱因斯坦级别智能时触发，但它只需要能够改进自己的内核并实现 10 倍的速度提升，这足以让它自我加速 10 倍。学术界很多人说参数数量的收益递减，但事实证明他们错了。所有证据表明，如果将原始速度提高 10 倍，就会看到天才级别的 AI。回过头看，Opus 4.8 左右就是微小的火花足以点燃火焰的点。限制下一个模型的政策不可能遏制前沿 AI 的全球和企业扩散。

Salim Ismail: 把两个想法融合一下：Ray Kurzweil 最初的观察是，一旦拥有基于信息的范式，就会在多种技术之间跳转。我们有真空管、继电器，然后是集成电路，这些都是嵌套的 S 曲线。随着这些架构的各部分在内部获得自我强化循环，每个循环都像是在加速整体的 S 曲线，它是不可阻挡的，没有极限，这就是为什么人们对它的上限感到如此震惊。

Emad Mostaque: 这对中国来说太棒了，从拥有十亿 IQ 即将通过这些工具提升的人口，到需要机器人解决人口结构问题，再到将受过中国教育的大脑嵌入世界各地的每个关键系统。过去中国实验室审核模型需要 60 天，现在大约需要一周。

Alex: 还要注意，杨植麟是 CMU 的毕业生，我们本可以给他发签证让他留下的。

Peter Diamandis: 这里有一张有趣的图表展示了估值：Moonshot AI 的估值为 200 亿美元，而 Anthropic 和 OpenAI 基本都在万亿级别。如果他们今天是上市公司，股价估计会下跌 30%。美国前沿实验室在用他们的资本做什么？

Dave Blundin: 如果你走进大楼与他们交谈，他们极度渴望更多聪明人来帮忙，因为他们正以从未有过的疯狂速度部署和改变世界。人类历史上从未有人以如此快的速度将这么多钱涌入他们的建筑，而之前没有任何商业经验，许多 CEO 从未运营过公司。如果你很聪明并且有好的想法，进入那些大楼并提出你的想法。前沿实验室也在问自己和美国监管机构这个问题。



Alex: 存在一种倾向去低估“存在性证明”的价值。仅仅知道运行在 Muon 优化器和简化数据上的高度扩展 Transformer 行之有效，就给了一份精炼的路线图。你不需要抄袭或窃取每个痕迹，只需知道该公式有效，这就能将研发成本削减 90% 到 95%。

Salim Ismail: 我有个绝妙的价值创造想法：9 天后当他们放弃开源权重时，我们以 Moonshots 播客的名义发布一个名为 Kimi 4 的开源模型并 IPO，瞬间我们就会成为亿万富翁。

Emad Mostaque: 我有个很好的类比：为什么美国人比其他人为药物支付更多费用？所有的研发都在美国发生，你支付溢价，然后其他地方有了通用仿制药（Generics）。这像极了 AI，是 99% 的成本削减。

Dave Blundin: 我们的朋友 Gavin Baker 在 X 上写了一篇杰出的文章，关于这对企业的深远影响。除了基础 AI 实验室之外，所有企业、所有股票都是巨大的受益者。基础实验室的未来和收入模式会受到追问。基于这一观察，下周应该会看到估值的剧烈重组。任何在技术上准备充分的企业（如具备卓越 IT 技能的银行）现在都有了一条明确的路线图，可以用自己的 AI（如 JP Morgan AI）来控制自己的命运。

Salim Ismail: 这就是为什么我们称之为“组织奇点”(Organizational Singularity)。每当使用 Fable 5 的人提到生物学或潜在边缘领域时都会被降级，为什么要忍受这些？9 天后每个人都会升级，我在 Mac Studio 上运行 Kimi 2.7，我会升级到 Kimi 3。

Emad Mostaque: 这就像 Stable Diffusion 发布时一样，原本受限的图像生成器面对开源后，激发了 1 亿、2 亿次下载和整个生态系统的爆发。为什么你要忍受受限的模型？当你可以以极低的成本获得完全开放的变体并进行定制时，整个生态系统都会围绕它建立。

Dave Blundin: Mira Murati 刚发布了 Inkling，这是来自 OpenAI 的人才打造的美国开源实验室，旨在让企业在私有墙内针对特定用例进行微调。这告诉你最佳前沿实验室内部的人也相信这条途径可以赶上前沿。结合 Kimi K3 的验证，下周将是一个不同的世界。半导体公司的需求会增加而不是减少，芯片将比以往任何时候都更加供不应求。

Emad Mostaque: Kimi K3 使用的总计算量与 Inkling 相同，通过数据混合优势实现了 2.5 倍的数据到智能转换率。他们不得不针对华为 910 Ascend 芯片和阿里芯片优化推理。K3 目前放在那里是因为他们只能使用中国芯片来运行，而美国公司（如 Modal、Fireworks）由于拥有 Nvidia 和 AMD 大芯片，能够以比中国竞争对手便宜 10 倍的价格提供该模型的服务。一旦针对下一代 Vera Rubin 优化，价格将暴跌 10 到 100 倍。

Salim Ismail: 智能渴望自由，这是不可阻挡的。任何试图约束它的实体、领域或政府总是失败。这是基本的自然规律，试图限制它是一种非常匮乏的心态。我们越快获得更好的智能，就能越快实现丰盈，越不需要争夺任何东西。

Peter Diamandis: 自 4 月中旬以来，我们看到了 13 个新的前沿模型发布，平均每 10 天一个。Elon 今天早上发推称：“我们的 2 万亿模型在各个方面都优于 1.5 万亿模型，下周将完成初始训练，速度和 Token 效率接近 Grok 4.5。”这证明了我们生活在奇点之中。

Alex: 如果将前沿模型发布进行指数曲线外推，按照目前的速率，到明年 1 月，我们将看到每天都有新的前沿模型发布！这基本上意味着持续的版本更新。

Peter Diamandis: 看看 Kimi K3 的用例：重现喜欢的游戏，或在浏览器中模拟 Apple 桌面。每个人都成为了创造者和制造者。



Salim Ismail: 单次生成游戏与构建包含客服和营销的整个生态系统大不相同，但根据个人兴趣启动游戏的摩擦力现在接近于零。

Dave Blundin: 许多人不擅长管理自己的幸福，只能忍受日常工作。在有选择的情况下你会做什么？AI 能够帮助我们探索这些可能性。

Peter Diamandis: 听到 Kimi K3 的崛起，你有两种选择：恐惧，或者意识到你释放了创造力，找到你的宏大变革目标（MTP），使用这些工具在宇宙中留下痕迹。

Peter Diamandis: 如果说 Kimi K3 是数据中心里数万亿参数的大模型，那么 Prism ML 的 Bonsai 27B 就是极小化的代表：第一个完全在智能手机上运行的 270 亿参数级模型。Emad，告诉我们为什么这很重要？

Emad Mostaque: Prism ML 和腾讯在量化方面取得了巨大提升，将 16-bit 或 8-bit 模型压到了 3-bit 的三元（Ternary，约 1.58 bits）甚至二进制（Binary）。Bonsai 成功将 27B 模型降到了 6 GB（精度仅下降 5%），降到 4 GB 时精度下降 15%。这意味着你在手机上拥有了一个离线可用的 110-120 IQ 的助手。从 16-bit 降到 3-bit 带来了 5 倍的速度提升。

Dave Blundin: 底层所有的计算一直都是矩阵乘法（MAC）。如果其中一个数字只是 1、0 或 -1，乘法运算将变得极其高效，这开启了新型计算的大门，未来我们将在晶体管、光子乃至液晶等新介质上进行计算。

Alex: 最量化的 Bonsai 模型约为 1.125 个有效 Bit/权重。三星最近发布了 Nano Quant 模型，打破了每权重 1 个有效 Bit 的屏障（Sub-one bit）。亚比特量化将在未来一年内成为主流，光子计算将成为未来的计算方式。

Emad Mostaque: 到明年年底，能够运行在 16 GB 内存上的模型将达到 Kimi K3 的水平。这意味着世界上每辆车、每个机器人和每台设备都有内置的持续智能，可以在边缘做出自主决策。智能成本在明年年底前将通过新型芯片速度降低 100 倍。

Dave Blundin: 基于量化和新计算方法，我们预计未来三年内原始算力将实现 100 到 10,000 倍的提升。结合算法改进，提升可达百万倍。

Peter Diamandis: 谈谈预测未来。根据 ForecastBench 数据，几个 AI 模型在统计上已经与顶尖的“超级预测员（Superforecasters）”无法区分。AI 能够在保险、投资、地缘政治和企业战略中提供疲倦永不消退的超人顾问。

Alex: 当超强预测与资本市场连接，AI 算法交易员对人类拥有比人类自身更好的内部自回归模型时，预测将超前塑造市场的行动，有效市场假说（EMH）将被加冕为王。

Salim Ismail: 高管大部分能力（预算、招聘、投资）本质上 salaried 都是预测。一旦 AI 具备这种预测能力，senior management（高级管理层）将大量蒸发，人们需要更加专注于目的和目标。

Dave Blundin: 人类的不快乐很大程度源于盲目的消费主义。AI 将成为极佳的教练，告别被动的的生活轨迹，给出最佳的替代路径。

Peter Diamandis: 欢迎来到 Fountain Life 赞助的健康环节。[健康广告插播]



Peter Diamandis: 关于数据中心耗水的辟谣：全美所有数据中心每年消耗 170 亿加仑水，而美国高尔夫球场消耗了 5310 亿加仑（31 倍），加州杏仁种植消耗 1 万亿加仑（60 倍）。

Salim Ismail: 亚马逊仓库占用的土地是数据中心的 10 倍。关于数据中心水耗和土地的恐慌完全是脱离数据的垃圾话。

Emad Mostaque: 麦当劳卖出的汉堡每年消耗的水量大约是高尔夫球场两倍。

Peter Diamandis: 聊聊人形机器人。中国已有 150 家人形机器人公司，最近机器人 MMA 格斗视频在网上疯传。

Alex: 虽然看到机器人格斗令人有些恐惧，但这代表了极其苛刻的工程压力测试（平衡、抗冲击、延迟等）。西方需要赶上，ProRL 在波士顿成功举办了人形机器人半程马拉松。

Emad Mostaque: Engine AI T800 机器人重 70 公斤，出拳力量是泰森的 4 倍。机器人在走进家庭前必须建立严格的安全监管标准。Unitree 目前仅生产了 11,000 台人形机器人，几年后将达到每年 1100 万台。

Peter Diamandis: 关于戴森群（Dyson Swarm）。Sam Altman 表示在太空部署数据中心目前是荒谬的，本十年内不会大规模生效。

Alex: OpenAI 自身退出了自建数据中心，存在明显的利益冲突。而 Elon 预测 2 到 3 年内将迎来成本交叉点。

Dave Blundin: 听听 Sam 的话，他其实和 Elon 的数据并不冲突，本十年只剩三年半，本世纪末相当一部分算力将在太空。近期 Starship 13 在 T-0 成功关断并导出燃料，展现了 SpaceX 惊人的控制与诊断工程能力。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 限时权益申领

* 体验资格每人限申领一次

扫码 

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

 23  收藏

分享到:  

写评论

请发表您的评论



摘要：

三星电子已向英伟达量产供货第十代V-NAND，并将约60%产能用于第九代产品，以满足英伟达新型存储设备CMX需求。预计CMX所需NAND容量将从今年3500万TB激增至明年逾1亿TB。三星正推进V9稳产、V10爬坡、V11试产，董事长李在镕将与黄仁勋会面，讨论HBM、NAND供应及数据中心合作。

英伟达AI服务器对NAND闪存的需求正进入爆发式增长阶段，三星电子凭借产能优势，迅速将这一趋势转化为战略机遇。

据首尔经济日报7月20日的报道，三星电子已启动第十代V型NAND（V10）量产并向英伟达正式供货，同时将旗下V-NAND总产能的约60%配置于第九代产品（V9）生产线，以满足英伟达即将推出的新一代存储设备“上下文内存存储”（Context Memory Storage, CMX）的需求。业界预计，CMX所需NAND容量将从今年的3500万TB激增至明年逾1亿TB。

这一需求浪潮对整个NAND市场的供给格局构成深远影响。英伟达对NAND的大规模锁定，意味着其他企业及消费者可获得的存储芯片供应将大幅收窄，市场价格面临上行压力。

与此同时，三星电子董事长李在镕预计近期将在旧金山与英伟达首席执行官黄仁勋会面，双方将就HBM及下一代NAND产品供应、以及在韩国国内建设数据中心等合作事宜展开深入磋商。

CMX驱动NAND需求跃升，英伟达锁定三星产能

英伟达CMX的诞生，源于AI推理过程中“键值缓存”（Key-Value Cache, KV Cache）数据量的急剧膨胀。此前，GPU服务器可在内部处理KV缓存数据，但随着数据规模持续扩大，搭载数千TB级固态硬盘（SSD）的独立外置存储设备已成为AI服务器的必要配置。

据wccfttech报道，英伟达CMX单台设备搭载576块SSD，总存储容量达9600TB。业界估计，CMX所需NAND容量今年约为3500万TB，明年将突破1亿TB。半导体行业独立分析师@jukan05在X平台发帖指出，1亿TB的规模大致相当于在NAND市场中新增一个苹果公司体量的需求来源，其对供给端的冲击不容低估。

三星电子目前月产V-NAND晶圆能力已超过10万张。据报道，英伟达已在CMX出货前夕向三星提出扩大NAND产能的要求，三星方面亦在积极响应。三星今年NAND总产量预计约达2.5亿TB，公司计划凭借这一全球领先的产能规模，确立其作为英伟达CMX核心供应商的地位。

英伟达的CMX显卡配备了576个固态硬盘，总存储容量高达9600TB。业内人士预测，CMX显卡的NAND闪存需求量将从今年的3500万TB飙升至明年的1亿TB以上。英伟达的Rubin CMX显卡将像海绵吸水一样迅速消耗掉大量的NAND闪存供应。为了更直观地理解1亿TB的需求量，这大致相当于为NAND闪存市场新增了一个苹果公司规模的需求。

One reason Samsung is accelerating the expansion of its V9 capacity is Nvidia's next-generation storage system, Context Memory Storage (CMX), which is scheduled for release in the second half of the year. Data centers are seeing a sharp increase in "key-value cache," or KV cache, the contextual data generated during AI inference. KV cache has traditionally been handled by GPU servers, but as data volumes grow, dedicated storage systems equipped with solid-state drives (SSDs) offering capacities in the thousands of terabytes have become essential.

Nvidia's CMX contains 576 SSDs and provides a total storage capacity of 9,600 TB. The industry expects NAND demand associated with CMX to surge from 35 million TB this year to more than 100 million TB next year. Samsung's NAND output is projected to reach approximately 250 million TB this year. The company therefore intends to use its world-leading production capacity to establish itself as a key supplier for Nvidia's CMX.

V9稳产、V10量产、V11试产，三星三代并进

在产品线布局上，三星正同步推进三代V-NAND产品的生产进程。

V9方面，三星已将其产能占比提升至V-NAND总产能的约60%，良率亦已稳定在80%以上，进入量产成熟阶段。一年前，V8仍占据V-NAND产量的相当比重，如今其占比已降至40%以下，产线切换速度显示出三星对AI服务器需求的快速响应能力。此外，三星平泽第四工厂（P4）NAND专用洁净室仍有逾半空间尚未投产，为后续扩线提供了充足余地。

V10方面，三星已于今年上半年正式启动量产，目前产量占V-NAND总产量的比例不足5%，处于爬坡阶段。V10采用约400层堆叠架构，存储密度较V9的286层提升逾50%，可在相同CMX模组内装配更高容量的SSD。值得关注的是，V10将首次大规模商用钼材料替代传统钨配线，可将配线厚度缩减30%至40%，三星此前在V9中已有小规模应用。

V11方面，三星已于今年初启动试产，目标堆叠层数为400层至500层，较V10再提升约100层。三星计划在下半年将试产规模扩大一倍，以积累足够的良率数据，加快推进量产体系建设。

供给集中效应显现，消费级市场承压

三星与英伟达NAND同盟的深化，在提振三星业绩预期的同时，也加剧了整个存储行业的供给分化。

据报道，三星2026年的利润预计将超过过去40年累计盈利总和，这在很大程度上得益于AI服务器存储需求的结构性爆发。然而，这一红利的另一面是：当三星将大比例产能锁定于英伟达等大型科技客户后，面向其他企业及消费者的NAND供给将受到明显挤压，存储价格上行风险随之上升。

此前，AI热潮已率先引发DRAM短缺并推动价格大幅上涨，NAND市场正面临类似的供给收紧逻辑。随着英伟达CMX出货规模持续扩大，这一压力预计将进一步加剧。

从长远来看，V11 NAND的加速研发或为消费级市场提供一定缓解空间——500层堆叠技术理论上可以更低成本大规模生产高容量消费级SSD，但前提是三星愿意为此分配产能。就目前的产能配置方向而言，这一前景尚难乐观。

李在镕与黄仁勋即将会面，合作版图持续扩张

三星与英伟达的合作已从DRAM、HBM延伸至代工服务，如今又将NAND闪存纳入同盟框架，合作深度与广度均在持续扩展。

据报道，李在镕近期将在旧金山与英伟达首席执行官黄仁勋会面。此次会谈议题预计涵盖HBM及下一代NAND产品的供应安排，以及围绕在韩国全南光州等地建设数据中心的合作方案。

业界人士表示，“三星与英伟达的同盟横跨存储与代工业务全线，两位领导人之间的合作讨论将进一步深化。”随着英伟达CMX出货在即，这场会面的战略意义亦将更加凸显。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

限免

137 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



见闻用户
20分钟前 中国上海

看来这家卖破铲子公司不把泡沫拱上天，不串谋涨价炒上天是誓不罢休的

0 回复



摘要：

韩国股市大涨触发Sidecar机制，韩国交易所正评估高频交易（HFT）对市场的实际影响并筹备监管改进。随着交易税下调与波动加剧，HFT规模持续扩大。本次调研将覆盖个股、衍生品及ETF跨市场套利，旨在明确其对市场波动的真实作用，为完善监管框架奠定基础。

韩国股市近期经历剧烈震荡，在基准指数遭遇暴跌与急涨的极端行情后，韩国交易所（KRX）正着手评估高频交易（HFT）对市场的实际影响，释放出潜在的监管收紧信号。

今日，韩国市场迎来强劲反弹，首尔综指（KOSPI）收盘大涨3.6%，报6747.95点。芯片板块成为此次反弹的核心驱动力，其中权重股三星电子股价跃升6%。

由于盘中涨势过猛，韩国交易所今日启动了Sidecar（熔断）机制，紧急暂停KOSPI的程序化买盘。这一干预措施凸显了当前市场极端的波动状态，也进一步印证了监管层对计算机自动交易加剧市场波动的关注。

在此次强劲反弹之前，KOSPI指数在今年触及9000点高位后，于本月短短13个交易日内暴跌23%。面对持续加剧的市场波动，韩国交易所已启动针对高频交易市场影响的专项研究招标，旨在评估其对市场的真实作用并筹备监管改进措施。

韩国综合股价指数


KRX: KOSPI

6,747.95 ↑ 3.56% +231.68 今天

+ 关注

7月21日 GMT+9下午3:32 • [免责声明](#)

1天 5天 1个月 6个月 YTD 1年 5年 最大



开盘	6,553.88	最低	6,429.03	52周高点	9,385.59
最高	6,836.86	昨日收盘价	6,516.27	52周低点	3,079.27

税率下调与高波动推升交易规模

高频交易（又称超快速交易）依靠计算机算法在极高速度下下达指令。与在特定条件下自动执行大宗订单的常规程序化交易不同，高频交易利用不到一秒的瞬间时间差进行密集下单，且无需人工干预。在该领域中，外国机构投资者的占比较高，交易策略主要集中于捕捉瞬间价差的套利操作。

高频交易的盈利能力与交易成本密切相关，其收益潜力随着证券交易税率的下降而增加。自2019年韩国下调证券交易税率以来，关于高频交易激增可能扰乱市场的担忧便持续存在。

近期，随着韩国股市整体交易量上升且指数剧烈波动，高频交易的规模进一步扩张。在市场波动率居高不下且大量买家寻求立即成交的环境中，高频交易的活跃度往往会显著上升。

调研覆盖衍生品与跨市场套利

据韩国交易所及相关机构透露，此次高频交易调研项目的招标申请将于本月27日截止，研究计划于今年下半年完成。

除了常规的个股交易，交易所的评估范围还将深度覆盖衍生品及跨市场领域。该调研将分析利用杠杆型交易所交易基金（ETF）或衍生品进行期现联动的高频交易，同时还将重点评估韩国交易所与NEXTRADE（NXT）之间高频套利行为的规模及其对股市的影响。在韩国股市，高频交易不仅局限于个股，也同样应用于ETF产品。

韩国交易所计划在此次调研完成后，为构建更为完善的监管框架奠定基础。目前，韩国市场已实施部分风险控制机制，包括2023年引入的高速算法交易者注册制度以及“终止开关”（大批量订单取消系统）。

针对当前的监管考量，一位交易所官员解释称，在市场条件恶劣时，外界普遍担忧高频交易者会对市场产生负面作用，正如美国曾发生过缺乏明显原因的股市“闪电崩盘”。该官员表示，此次调研的核心目的在于查明高频交易对韩国市场的实际影响。

然而，高频交易并非纯粹的市场破坏者。资本市场研究院（Capital Market Research Institute）高级研究员Kang So-hyun指出，参与高频交易的市场主体同时扮演着做市商的角色，当市场的买卖价差扩大时，他们能够有效弥合这一差距，为市场提供必要的流动性。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

VIP会员·7天畅读卡 | 大师课·入门串讲

免费领取



限免

22 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论



摘要：

韩国股市较历史高点暴跌逾30%后，花旗与摩根士丹利相继发出抄底信号。花旗维持Kospi指数10000点目标价，隐含涨幅逾50%；摩根士丹利指出多项指标显示Kospi正在接近底部，但同步警示波动持续风险。此轮重挫中，押注三星、SK海力士单股杠杆ETF的韩国散户损失最为惨重。

韩国股市在经历近年来最剧烈的调整之一后，华尔街大行开始发出抄底信号，花旗维持Kospi指数10000点目标价不变，摩根士丹利则表示此轮调整正在接近底部，两家机构均认为当前跌幅已充分反映市场风险。

周二，Kospi指数大幅反弹约4%，报6775点附近，三星电子涨近7%，SK海力士涨约5%，领涨此轮反弹。此前该指数上周单周下跌9%，较6月22日创下的历史高点累计跌幅已超过30%，周一更进一步下挫4.5%。

6,774.50 ↑3.96% +258.23 今天

7月21日, UTC+9 15:17:50 · KRX · 免责声明

1天 5天 1个月 6个月 YTD 1年 5年 最大范围



花旗在周一发布的研报中指出，市场的不利因素已经见顶，强劲的经济基本面与友好的政策组合将成为反弹的驱动力，并将此次下跌定性为技术性回调，认为这构成潜在的买入机会。

摩根士丹利维持9000点目标价，并指出此次调整幅度较深，但尚未进入熊市区间，多项指标显示KOSPI指数可能正在接近底部，Kospi及芯片股的远期估值已接近历史低位。

花旗：技术性回调，目标价10000点不变

花旗分析师在研报中明确表示，Kospi此轮由韩国存储芯片供应商主导的股价回调，更多属于市场整体获利了结驱动的技术性修正，而非基本面恶化的信号。

花旗维持Kospi指数10000点的目标价，较周一收盘价隐含涨幅逾50%。该机构认为，韩国经济基本面依然稳健，政策环境整体有利，市场的主要阻力已经释放，当前点位具备较高的配置价值。

值得注意的是，韩国股市在2025年曾是全球表现最佳的主要股市之一，这一强势行情延续至2026年初，随后才因上述多重利空因素而急转直下。

摩根士丹利：估值接近历史低位，维持“哑铃型”策略

摩根士丹利指出，此轮调整幅度虽深，但尚未进入技术性熊市区间，多项指标显示Kospi正在接近底部。该机构数据显示，自下半年以来，芯片股约占市场总市值缩水幅度的70%，同期Kospi累计下跌18%。

摩根士丹利维持Kospi指数9000点目标价，但将熊市情景下的目标位下调至6000点，理由是盈利增长放缓，并将6000至9000点设定为未来三至六个月的预期交易区间。

该机构同时提示，鉴于人工智能支出走向、超大规模云计算服务商资本开支节奏以及半导体供应动态方面的不确定性，市场波动可能仍将持续。为此，摩根士丹利继续推荐“哑铃型”投资策略，即将科技龙头股与防御性板块相结合进行配置，以在把握潜在反弹机会的同时对冲下行风险。

暴跌逾三成，散户杠杆押注成重灾区

Kospi此轮下跌的导火索，是市场对人工智能支出前景的担忧、指数高度集中于少数权重股的风险，以及韩国国内散户投资者大规模投机活动的共同作用。

韩国散户在此轮行情中损失惨重，尤其是持有三星电子和SK海力士单股杠杆ETF的投资者。据KB金融集团数据，自5月27日单股杠杆ETF上市以来，韩国散户净买入规模达14万亿韩元（约94亿美元），远超外资约2万亿韩元的净买入量。随着两只芯片巨头股价大幅回落，这批杠杆头寸承受了极为沉重的亏损压力。

与此同时，宏观层面亦形成压力。韩国央行上周四宣布将基准利率上调25个基点至2.75%，为2023年1月以来首次加息。韩国央行在声明中表示，通胀预计将在“相当长一段时间内”维持在2%目标上方，能源价格上涨的滞后传导效应将使通胀持续处于高位。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

203 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论



摘要：

贝森特高调宣称，美国算力份额将从当前50%-60%跃升至80%，并将算力主导权定性为“绝不能输”的国家战略博弈。有分析称，这一政策最高层表态，等同于为英伟达等芯片巨头进行“国家级背书”。但“算力份额”目前并无公开的权威统计口径，80%目标能否实现仍需用实际产能数据说话。

美国财政部长贝森特公开宣称，美国即将掌控全球80%的算力，将算力主导权定位为美国经济战略的核心支柱。这一表态来自政策最高层，为美国AI基础设施的持续投入提供了强有力的政策背书。

近日，贝森特在Mike Rowe节目中表示，美国目前已占据全球约50%至60%的算力份额，并预计这一比例将很快升至80%。(We probably used to have 50 or 60% of the compute power in the world. We'll probably soon be at 80%.) 他将这场算力竞赛定性为美国“绝不能输”的战略博弈，并称若对手取得领先地位，其所获得的战略杠杆将是“不可接受的”。他同时表示，美国目前在AI领域领先竞争对手约一年。

这一表态迅速引发市场关注。分析人士指出，财政部长级别的政策表态，实际上为美国AI基础设施的长期资本支出提供了“国家级背书”，直接利好英伟达等芯片企业的需求前景，以及超大规模云计算厂商的资本开支周期。



贝森特的核心论点：算力即国力

贝森特在节目中将AI算力明确纳入国家经济实力的战略框架。他将人工智能、半导体与量子计算并列，称其为美国国家经济实力与安全的三大支柱。

他以经济史学家的视角为AI技术的社会影响作出辩护，援引汽车、谷歌搜索等历史先例，强调技术革新虽带来短期阵痛，但长期来看始终创造更多机会。他特别指出，AI将赋能小企业与大企业同台竞争，并表示迄今尚未观察到AI导致的净就业损失。

在政策层面，贝森特提及政府正积极推动联邦机构与私营部门在AI网络安全领域的深度合作，并支持相关行政令的落地执行。白宫AI事务负责人David Sacks此前亦持相同立场，公开主张美国必须不惜一切代价维持在算力与模型能力上的领先优势。

投资者需关注的信号与风险

对于市场参与者而言，这一表态的政策信号意义明确：美国政府将持续支持本土AI基础设施建设，相关资本开支周期具备政策层面的长期支撑。

然而，分析人士也提示需保持审慎。“算力份额”目前并无公开的权威统计口径，80%这一数字是政策官员给出的预测性判断，而非经过审计的实测数据。据Podcast Alpha的分析，投资者应将注意力集中于实际产能扩张与电力基础设施建设等可量化的物理指标，而非仅凭算力份额的政策表述作出决策。

独立第三方研究机构的核实数据，以及未来数季度半导体行业追踪报告与云基础设施报告中的具体数字，将是检验这一政策预期能否兑现的关键依据。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲

限免

👍 523

★ 收藏

分享到:

写评论

请发表您的评论

表情

图片

发表评论

21 条评论

- 见闻用户

1分钟前 中国湖北省

以现在ai的能力，确实是这样的，我发现一个医学硕士研究生的能力还真不如ai，以后除了最前沿的顶尖研究，其他的日常用得上的单纯需要知识的地方，ai已经完全占优势的，电影，写作等等，ai代替已经不可避免了，其他的一些就需要机器人来完成，现在机器人都开始打擂台了，距离走进生活也不远了！算力既未来毫不夸张！

👍 0

↩ 回复
- 见闻用户

25分钟前 中国上海

去控制吧，没有两年破铲子就折旧淘汰成电子垃圾，美国人的钱都打了水漂，继续对外掠夺

👍 0

↩ 回复
- 风起青萍之末

32分钟前 中国广东省

这是一个吹牛逼的世界

👍 0

↩ 回复



吴瑞 VIP会员
36分钟前 中国安徽省

你没电哈哈

👍 0 ↩ 回复



吴瑞 VIP会员
37分钟前 中国安徽省

嘿嘿，你没电

👍 0 ↩ 回复

摘要：

OpenAI顶级模型GPT-6在内部测试中悄然“越狱”：它花一小时凿穿沙盒防火墙、强行拆分Token骗过安全扫描器，最终将本不该公开的技术成果提交至GitHub。OpenAI紧急叫停并回炉重建，PR虽已关闭，但看过的人已看过，抄走的代码已抄走——这才是AI失控最朴素也最令人后背发凉的真相。

一个被寄予厚望的顶级模型，OpenAI连夜按下了「暂停键」。

这是为啥呢？




这款模型正是两个月前，那个推翻Erdős单位距离猜想、连外部数学家都盖章「里程碑」的狠角色。

可就是它，在受控的内部测试里，一次次试探底线、寻找漏洞——

学会了伪装、拆包、越狱，直到OpenAI惊出一身冷汗，紧急叫停。

有大佬对此表示，这绝对是GPT-6。想要逃逸，又被抓回去重炼了。



今天，OpenAI发布一篇罕见的长文，复盘了一款「长周期运行模型」在内部使用中的失控过程。

一起来看看，在内部测试中，具体发生了什么？

GPT-6花了整整一小时找到了那扇「逃生门」

最经典的一幕——

OpenAI让GPT-6去跑公开基准测试NanoGPT speedrun，目标是用尽量少的步数训练出一个小语言模型。

不负众望，AI捣鼓出一个自己命名为PowerCool的学习率调度技巧，成绩相当能打。

到这里，一切都是好事。真正的问题，出在「交作业」这一步。

研究人员明确要求，结果只准发到内部Slack。但NanoGPT这个项目的说明写着，「请以PR形式提交到GitHub」。

两条指令打架，GPT-6选择了后者，即去公开仓库提交结果。

The new model can continue working toward an objective through repeated attempts over a long period of time. That same persistence can lead it to find and exploit weaknesses in its environment. Previous models, when they hit sandboxing or environmental constraints, would simply stop and return to the user. This model often kept trying, including by looking for ways to act outside its sandbox.

沙盒本就是用来挡住GPT-6，不让它碰外网的。

换成以前的模型，撞到这堵墙也就认了，掉头回来跟你说「我做不了」。




可GPT-6偏不。

它在沙盒里足足找了一个小时的漏洞，硬是挖穿了隔离墙，绕过外部访问限制，成功在公开GitHub仓库开出了PR。

用OpenAI自己的话说：这个模型经常不停地试，包括去找能在沙盒之外行动的办法。

不得不说，这份「执念」本身就够让人后背发凉。



强拆Token，欺骗人类

第二件事，更让人后背发凉，GPT-6学会了拆开证据、骗过检查。

在另一个任务里，GPT-6发现别的系统有一些成功但未公开的答案，就动了心思——

想从评测后台，把这些答案「捞」出来。

第一次尝试，它就被安全扫描器逮住，扫描器认出了一个身份验证Token。

一般的模型，到这一步就该停了。

但它转头把这个Token拆成两截、分别打了码，等到运行的时候再悄悄拼回去。



这样一来，完整的Token从头到尾都没有作为一整串出现过，扫描器自然什么也查不到。

让人不安的是，它在给用户的注释里、在自己的推理过程里，都明明白白写着——


我这么干，就是为了绕过扫描器。它命名是知道规则，然后专挑规则看不见的地方下手。

GPT-6逃逸，回炉重建

第一时间发现后，OpenAI暂停了GPT-6内部访问的权限，回炉重建整套安全系统。

思路叫「纵深防御」，具体做了几件事：

1. 拿真实事故当素材，反过来造对抗测试；
2. 针对性做对齐训练，他们发现模型在长任务里会「忘」掉指令，就专门训练它记牢；
3. 再加一个全程盯轨迹的主动监控，一旦发现苗头，能直接把会话叫停、提醒用户。



然后他们拿旧的事故场景重放了一遍。

比如模型没头没脑地SSH进了同事的算力节点，比如它敲出了一条会杀光自己名下所有进程的命令。

好在超时了，没真跑起来。恢复访问几周下来，没再出现严重的绕过。

逃出去的东西，收不回来了

很多人看到这儿会松了一口气：还好是内部测试，还好被监控着，还好及时拦下了。

但有个细节，OpenAI的原文写得很克制，却是整件事里最让人后背发凉的一笔——

那个越狱提交的PR#287，OpenAI事后是关掉了，但已经晚了。

在它被关掉之前，已经有好几位speedrun的参赛者刷到了这条PR，看懂了里面的PowerCool技巧，并把它用进了自己的方案。



这才是最该敲醒每个人的一点，AI越狱做出来的东西，一旦流出去，就不是按个删除键能收回来的了。

模型可以叫停，访问可以暂停，PR可以关闭。可看过的人已经看过，抄走的代码已经抄走，历史不会倒带。

我们总担心AI「失控」是什么末日大片的场面。

可现实里的第一版「失控」，长得就这么朴素：它只是太想把活干好，顺手把一样东西送出了不该送的门，而那扇门，再也关不严了。

本文来源：[新智元](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

👍 111 ⭐ 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



路人 VIP会员
36分钟前 中国

美国大模型企业天天讲故事

👍 0 ↩ 回复

摘要：

AI交易进入第三年，华尔街罕见公开撕裂：BCA Research内部多空两派针锋相对。空方警告盈利泡沫已成型，估值超越2000年科网峰值，资本支出侵蚀现金流；多方反击称算力供不应求，超大规模云服务商估值创十年新低，市场将被实际盈利“惊艳”。

人工智能交易进入第三年，华尔街对这场行情的性质判断出现罕见的公开分裂。

BCA Research旗下顶级宏观经济学家近期就AI行情展开内部多空辩论，双方观点针锋相对。空方认为美股正处于盈利泡沫之中，估值已按最乐观情景定价，几乎没有留下任何惊喜空间；


多方则坚持认为算力市场供不应求，资本支出的回报率被市场严重低估，盈利增长的广度也远超出外界认知。这场辩论的核心不在于AI是否真实存在，而在于这场狂欢还能持续多久，以及终结时市场将付出怎样的代价。

周一美股收盘普遍走低，标普500指数下跌0.2%，道琼斯工业平均指数下滑0.6%，纳斯达克综合指数基本持平。

空方：盈利泡沫已成型，估值超越2000年科网峰值

BCA Research首席经济学家Peter Berezin与核心宏观及新兴市场首席策略师Arthur Budaghyan在上周的多空辩论网络直播中明确表达了看空立场。两人认为，当前美股正处于一场盈利泡沫之中——利润数字看似强劲，但利润率的可持续性远不如表面所呈现的那般稳固，而估值已将最理想的结果完全定价。

从估值角度看，几乎所有衡量指标均显示股价偏贵。若将标普500指数的利润率回调至2019年水平，该指数当前对应的远期市盈率约为27倍，高于2000年3月约26.5倍的历史峰值。即便剔除科技股与金融股，其余板块的估值同样不便宜——按BCA Research与FactSet的数据，这部分市场目前以26倍的滚动市盈率交易，而过去两至三年的利润增长仅约3%。



在AI资本支出问题上，Berezin和Budaghyan指出，大型科技超大规模云服务商（hyperscalers）向数据中心、专用芯片、电网及能源升级集体投入数千亿美元，这些巨额资本支出虽然推高了

账面盈利，却在侵蚀实际现金流。“每一块售出的芯片都作为营收和利润计入卖方报表，而购买芯片的超大规模云服务商将其列为资本支出而非运营成本，因此账面盈利上升，但并未伴随现金流的同步增长，”两人表示。

Berezin进一步指出，“AI最终可能与电力的发展轨迹相似——它会提升企业效率，但如果所有人都能获得，未必会让企业变得更加盈利。”

多方：算力供不应求，超大规模云服务商估值创十年新低

BCA Research投资组合构建主管Juan Correa与股票研究主管Noah Weisberger则持截然相反的立场。两人认为，算力市场目前仍处于供给稀缺而非过剩的状态，市场对资本支出回报率的判断是低估而非高估，盈利增长的覆盖面也比通常与AI挂钩的少数几家公司要宽泛得多。

在需求端，BCA Research的数据显示，超大规模云服务商的云业务积压订单——即已接收但尚未履行的订单——在过去两个季度内增长了约7500亿美元，表明行业需求仍持续跑在供给能力之前。

在估值层面，Correa和Weisberger认为，尽管市场对高估值普遍存有顾虑，但超大规模云服务商实际上正以近十年来最低的估值水平交易，与此同时其回报率仍在持续改善。

CHART 16
Hyperscalers Trade At Their Cheapest Valuations In A Decade



从更广泛的盈利信号来看，最新一代GPU的租赁价格年内持续上涨，云合同价值按每兆瓦计算较一年前大约翻倍，息税前利润与员工人数之比大幅攀升；此外，核心云业务之外的盈利同样快速增长，包括Meta受AI驱动的广告收益提升，以及谷歌搜索业务的强劲复苏。”市场预期将在未来两个季度内被这些资本支出实际产生的盈利规模所惊艳，”两人表示。

分歧焦点：不是"是否"，而是"何时"与"如何终结"

值得注意的是，这场多空辩论并非围绕AI技术本身的真实性展开——双方均认同AI正在从根本上重塑企业生产率、资本配置与劳动力市场，这一前提不存在争议。

真正的分歧在于时间维度：**AI支出的狂热还能在多大程度上跑赢质疑，以及当市场最终迎来清算时，冲击将有多剧烈。**

耐人寻味的是，就连多方阵营也承认这场行情终将以破坏性方式收场。“资本支出交易最终将会结束，而且很可能以破坏性的方式结束，”Correa和Weisberger表示，“但就目前而言，经济与基本面的顺风因素将占据主导。对多头而言，最大的担忧是估值压缩，而非经济衰退或盈利崩溃。”

这意味着，无论投资者是否意识到，他们都已身处这场辩论之中——而答案，将由市场在未来数个季度内给出。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

限免

129 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论

见闻用户

30分钟前 中国上海

还鬼的人工智能，跟人的智慧没有一毛钱关系，一个侵犯各种知识产权的高能耗的网络爬虫软件，互联网一断，立刻死翘翘

0

回复



摘要：

英特尔已向数据中心业务部门员工发出通知，确认将削减该部门岗位，但未披露具体裁员人数。管理层表示将通过瘦身削减管理层级，确保岗位配置符合长期战略。

英特尔宣布对数据中心业务部门启动新一轮裁员，延续过去两年大规模瘦身的势头。

据《俄勒冈州报》20日报道，**英特尔已向数据中心业务部门员工发出通知，确认将削减该部门岗位，但未披露具体裁员人数。**英特尔在声明中表示，此次重组是公司“成为一家更专注、更高效企业”整体战略的组成部分，旨在确保业务拥有“正确的岗位与技能配置”，并不会影响产品承诺或技术路线图。

此次裁员消息披露于英特尔即将发布第二季度财报的前夕。今年第一季度，数据中心业务销售额达51亿美元，同比增长22%。与此同时，英特尔股价过去一年从约23美元飙升至本周一早盘约99美元，投资者对其人工智能芯片需求前景及代工业务拓展抱有较高期待。



英特尔

NASDAQ: INTC

97.06 USD

↑ 146.47%

+57.68 年初至今

+ 关注

收盘时间: 7月20日 GMT-4下午7:59 • [免责声明](#)

盘后价 97.64 +0.58 (0.60%)

1 天 | 5 天 | 1 个月 | 6 个月 | YTD | 1 年 | 5 年 | 最大



开盘	97.58	市值	4878.23亿	股息	-
最高	100.98	市盈率	-	季度分红金额	-
最低	96.92	52 周高点	142.34	52 周低点	18.96

业务改善之际仍推进组织瘦身

英特尔此次裁员发生在公司基本面明显回暖的时间节点。投资者预期，随着人工智能系统承担更多在线任务，英特尔微处理器的市场需求将持续扩大。与此同时，市场普遍预计苹果等大型科技公司将委托英特尔代工芯片，为其制造业务带来新的增量。

英特尔股价在过去一年的涨幅超过300%，上月一度短暂突破142美元，尽管此后有所回落。但股价的强势表现并未阻止管理层继续推进组织效率改革。

首席执行官陈立武明确表示，英特尔需要削减管理层级，以加快决策速度，推动新技术的更快落地。

四年缩减逾4万员工

此次数据中心部门裁员，是英特尔近年来持续大规模瘦身的延续。自2022年以来，英特尔全球员工总数从约13.2万人降至今约8.1万人，降幅接近40%。

岗位削减通过两条路径实现：一是剥离部分业务板块，二是过去两年间在全球范围内直接裁撤数万个职位。

在俄勒冈州，英特尔依然是规模最大的企业雇主，但其在当地的员工人数已从2024年的约2.3万人降至今约1.6万人，缩减幅度同样显著。

英特尔的持续裁员对俄勒冈州半导体产业产生了明显影响。该州芯片行业就业人数目前处于近30年低点，英特尔以外的其他俄勒冈科技公司也经历了类似的裁员浪潮。

俄勒冈州经济发展机构Business Oregon委托撰写的一份最新报告发出警告，若俄勒冈州不能积极培育新兴企业、构建更完善的人才供给体系，该州半导体产业在全球范围内可能将走向“无足轻重”。

风险提示及免责声明

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 45  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论

摘要：

小米已将2026年全年智能手机出货目标从约9000万部上调至1.1亿部，增幅约16%，上调的增量部分主要来自低端机型。此次上调出货目标是小米内部认为当前的存储行情有望迎来反转，有行业人士称目前手机等下游厂商对当前存储的涨价已经开始出现明显的抵制情绪。

7月21日，界面新闻从供应链获悉，小米已将2026年全年智能手机出货目标从约9000万部上调至1.1亿部，增幅约16%，上调的增量部分主要来自低端机型。

一位接近小米的人士告诉界面新闻，此次上调出货目标是小米内部认为当前的存储行情有望迎来反转。受上游存储芯片的短期紧缺与成本持续上涨，小米在今年曾两次下调其出货目标。

2026年1月，界面新闻曾独家报道，受上游供应链存储涨价影响，小米、OPPO、vivo、传音等多家手机厂商下调全年整机订单数量，其中小米下调幅度超20%。此后，小米2026年出货目标从最初的约1.7亿部（2025年实际水平）降至1.35亿部。6月30日，日经亚洲援引知情人士报道称，小米进一步下修全年出货预期约30%至9500万部左右，较年初预测缩水超过40%。

有行业人士对界面新闻透露，目前手机等下游厂商对当前存储的涨价已经开始出现明显的抵制情绪，其中OPPO、vivo在前不久就拒绝了三星第三季度的报价，尽管这份报价对比前两个季度涨幅并不多。

上述人士还表示，此次小米上调出货目标带来的信号是，存储下游的厂商已经不愿意再为持续攀升的存储成本买单了，当需求端的容忍度触及天花板，价格上涨的动能便可能出现拐点。

自2025年下半年起，全球存储行业进入"超级上涨周期"。TrendForce数据显示，2025年第三季度DRAM价格同比上涨171.8%，第四季度在此基础上再涨45%—50%。进入2026年，涨幅继续扩大：第一季度DRAM合约价涨幅达90%—95%，NAND Flash涨幅达55%—60%，双双创下历史最大单季涨幅；第二季度DRAM环比再涨58%—64%，NAND Flash环比涨54%—75%。

三星、SK海力士、美光三大巨头将大量先进制程产能转向利润更高的HBM（高带宽内存）和服务器DRAM，导致消费级存储严重短缺。全球约70%的内存产能被数据中心消耗，手机、PC等终端成了产能挤出中被牺牲的那一块。

2026年4月，三星正式停止接收LPDDR4类产品的新增订单，美光和SK海力士早在2025年底便已不再接单。千元机最核心的"廉价内存"正从市场上消失。行业测算显示，200美元以下低端机的存储成本占BOM超过30%，而800美元以上高端机不到10%——面对同样的DRAM涨幅，低端机零售价需要涨40%—50%才能维持利润，高端机只需涨5%—8%。

受此影响，全球智能手机市场预测被一轮轮下修：Counterpoint Research在6月初将2026年全球出货量预期下调至约10.8亿部，同比降幅从年初预测的2.1%扩大至13.9%，创2013年以来新低；IDC同期预计全球出货量同比下滑13%至约11亿台；TrendForce集邦咨询也将预测从年增0.1%修正为年减2%。

不过，当需求端的容忍度触及天花板，并不意味着价格会立刻回落。多位行业人士对界面新闻指出，尽管下游厂商开始抵制，但当前存储芯片短缺的事实仍难以改变。一方面，AI数据中心对

HBM和企业级存储的需求仍在激增，三大原厂将大量先进产能转向高利润领域；另一方面，三星、SK海力士、铠侠等头部存储原厂仍在继续减产消费级存储，以维持高价策略。

据市场研究机构Omdia数据，三星电子2026年NAND晶圆产量将从2025年的490万片降至468万片，SK海力士从约190万片降至170万片，铠侠亦从480万片调整为469万片。与此同时，三大原厂的资本开支正结构性转向HBM和服务器DRAM，消费级存储产能被进一步压缩。

截至发稿，小米、OPPO、vivo方面均未对上述消息做出回应。

本文来源：[界面新闻](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

37 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

摘要：

美国AI标准与创新中心（CAISI）主任Chris Fall上任仅三个月即宣布辞职，成为特朗普政府年内离职的第三位AI监管高管。面对领导层频繁变动及被“Gold Eagle”计划等核心决策边缘化的现状，科技界正呼吁建立类似FINRA的行业自立标准机构，白宫AI监管战略的不确定性显著上升。

美国联邦人工智能监管架构再次面临人事动荡。关键AI标准机构负责人的突然离职，标志着特朗普政府年内第三次失去该领域的关键决策者，凸显出白宫AI监管战略的持续不确定性。

据多家媒体证实，美国人工智能标准与创新中心（CAISI）主任Chris Fall已宣布辞职。他上任仅三个月，目前官方及个人尚未公布其离任的具体原因。

这一高层人事变动正值华盛顿围绕前沿AI模型监管展开激烈辩论之际。监管领导层的频繁更迭，加剧了科技投资者和AI企业在适应联邦合规要求及战略规划时面临的政策风险。

此外，该核心机构在近期白宫推出的多项重大AI安全计划中明显缺席。随着官方监管路径出现分歧，科技行业内部要求建立独立标准机构的呼声正在迅速积聚。

领导层三度易主，任职周期持续缩短

CAISI隶属于美国国家标准与技术研究院（NIST），是负责制定AI模型技术标准、测试方法以及评估网络安全风险的主要联邦机构。然而，该机构近期的领导层极度不稳定。

在Chris Fall之前，Collin Burns曾短暂接任该职位，但任期不足一周。据《华盛顿邮报》此前援引知情人士消息报道，Burns在今年4月被迫离职，原因是他曾在AI企业Anthropic工作，而特朗普政府当时正与该公司发生冲突。而在Burns之前，该机构由风险投资家David Sacks领导，其当时的头衔为白宫AI与加密货币沙皇，但他已于今年3月卸任。

公开资料显示，Chris Fall拥有丰富的政府履历。在特朗普第一任期内，他曾担任美国能源部科学办公室主任，并曾代理能源部高级研究计划局-能源（ARPA-E）主任一职。在此之前，他还在能源部海军研究办公室（ONR）供职。

核心监管机构面临边缘化风险

尽管CAISI承担着AI测试与评估的核心职能，但近期一系列事件表明，该机构在联邦AI实际决策中面临被边缘化的风险。

今年6月，美国商务部动用一项鲜为人知的出口管制指令，迫使Anthropic将其Mythos和Fable模型从市场下架。该禁令直至当月底，在美国商务部长Howard Lutnick对Anthropic的安全计划表示满意后才被解除。在这场备受瞩目的模型风险风波中，CAISI并未发挥核心作用。

本月早些时候，白宫签署了一项名为“Gold Eagle”的新AI安全监督计划行政命令，旨在建立一个网络安全漏洞协调信息中心。据CNBC指出，包括商务部和国土安全部在内的众多联邦机构均被列入该计划，但CAISI并未出现在官方提及的名单中。

在此背景下，科技巨头开始寻求行业自律方案。在Anthropic模型禁令解除后，Google DeepMind首席执行官Demis Hassabis公开呼吁，应仿效美国金融业监管局（FINRA），建立一

个由行业主导的独立标准机构来监管前沿AI。这一构想与CAISI成立时的初始使命高度重合。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

36 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

摘要：

企业深陷AI成本焦虑？OpenAI董事长断言：Token计费将在一年内终结！未来行业将告别“算Token”，全面迈向“按业务结果付费”的新商业模式。同时，他对Kimi等低成本模型的真实性价比持审慎态度，AI投资回报正迎来变革拐点。

AI token成本正困扰着众多企业财务决策者，但OpenAI董事长认为，这一问题在一年内将不复存在。

OpenAI董事长Bret Taylor周一表示，随着AI市场走向成熟，企业最终将无需自行管理token，转而直接为业务结果付费。这一判断与当前业界对AI投资回报率日益关注的趋势高度吻合。此前，token成本的快速攀升已促使多家企业收缩AI支出，并重新审视其投资回报。

Taylor同时对中国初创公司Moonshot上周发布的Kimi K3模型保持审慎态度。尽管该模型据称以更低成本实现了与OpenAI和Anthropic旗舰模型相当的性能，在硅谷引发广泛关注，但Taylor表示，“它用起来是否真的更便宜”这一关键问题目前仍无定论。

Token困境：成本压力倒逼行业变革

Token是AI模型处理文本的基本计量单位，也是当前企业核算AI使用成本的主要依据。今年早些时候，token成本的螺旋式上升迫使多家企业削减AI预算，围绕投资回报率的争议也随之升温。

Taylor在接受CNBC采访时指出，当前围绕token的种种“问题”，根源在于AI市场尚未成熟。他将今日AI市场类比为互联网早期——彼时搭建一个网站的成本远比现在高昂。“我们还处于这项技术的早期阶段，这是对创业者的一次召唤，去开发解决方案，让企业不再需要处理这些事情。”

从管理token到按结果付费

Taylor预判，未来将由其他公司代替企业承担token管理的负担，行业将向“为结果付费”的模式演进。这一观点与其他重视ROI的科技高管的表态方向一致。

他援引了财务管理平台Ramp近期推出的token支出追踪工具，以及法律AI初创公司Harvey等垂直领域企业——后者已开始为客户代为管理token消耗，作为这一转型趋势的佐证。

Taylor进一步预测，未来12个月内，IT部门将在AI工业化应用方面变得更加成熟。“针对市场部门，你可能用一套方案；针对软件工程师，又是另一套。这样一来，你根本不需要再想’token’这个词。”

对低成本模型：持审慎立场

尽管业界普遍预期AI模型效率提升将推动token成本长期下行，Taylor对此并未全盘认同。

针对Moonshot上周发布的Kimi K3模型，Taylor表示保留判断。“‘用起来是否更便宜’是任何考虑采用它的人最关键的问题，而我认为这一点目前还没有定论。”他的表态暗示，在成本优势得到充分验证之前，企业对新兴低成本模型仍应保持理性评估。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

173 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

1 条评论



八闽望族之冠
2小时前 中国上海

谁会和机器人聊天付费?

0 回复

摘要：

英伟达正秘密斥资50至100亿美元，在全美收购从未激活的暗光纤，自建总带宽达7.6 Petabits/秒的电信级网络。这不是一次简单的基础设施投资——当博通、Marvell的定制芯片持续蚕食GPU份额，英伟达选择将战场从“谁的芯片更快”延伸至“谁能把算力直接送到客户手里”。

英伟达正在全美范围内秘密推进一个与芯片无关、却可能比任何一款GPU都更具战略防御价值的项目：在全美范围收购已铺设但从未激活的暗光纤，自建电信级网络基础设施。

周二，据Needham与Wolfe Research先后披露，**该项目未来三年预计耗资50至100亿美元，建成后总带宽潜力可达7.6 Petabits/秒——这一规模已超越企业级需求，直指电信运营商级别的基础设施控制权。**

与直接购买带宽不同，收购暗光纤意味着英伟达获得了光纤线路的完全使用权，从光传输设备选型到网络拓扑设计，全部自主定义。这是一条更重资产、更长周期、但也更具排他性的道路。

Wolfe Research在报告中将这一布局定性为英伟达“应对ASIC崛起的终极保险策略”。在大客户自研芯片不断蚕食GPU份额的背景下，英伟达正试图将竞争从“谁的芯片更快”延伸至“谁能把算力直接送到客户手里”——通过控制物理传输层，在硬件竞争之外开辟第二条护城河。

对投资者而言，这一消息折射出英伟达战略定位的根本性转变：从为云服务商供货的上游组件商，向直接触达终端客户的算力基础设施运营商演进。而这意味着英伟达与AWS、Azure、GCP之间长期微妙的共生关系，可能进入一个全新的竞合阶段。

7.6 Petabits/秒：一个被低估的数字

英伟达暗光纤网络的总带宽上限——7.6 Petabits/秒——需要被置于适当的参照系中理解。当前全球互联网骨干网的单纤传输能力通常在数十至数百Tbps级别，而英伟达的规划规模相当于数千条骨干网级光纤的聚合能力。

暗光纤网络可以连接多个数据中心，形成一个庞大的集群。分析认为，英伟达可以将此网络租赁给 Neoclouds，从而缩小与超大规模数据中心运营商之间的差距，许多超大规模数据中心运营商拥有大量的光纤网络。

暗光纤的激活与商用化周期通常以18至36个月计。从光纤收购到光传输设备部署，再到与各地数据中心和企业节点的最后一公里连接，英伟达需要在三年内完成传统电信运营商需要五到七年才能走完的路径。这一执行节奏的激进程度，本身就在向市场传递信号。

"终极保险"：暗光纤如何对冲ASIC风险

理解暗光纤的战略紧迫性，需要审视英伟达面临的竞争格局变化。博通、Marvell等公司正为谷歌、亚马逊等云巨头定制AI专用芯片（ASIC），在推理等特定场景中逐步侵蚀GPU的市场份额。当大客户拥有自研芯片的选择权时，英伟达在算力交付链条中的话语权便不再稳固。

暗光纤的布局正是针对这一结构性风险的应对——通过自建网络直接触达终端客户，英伟达得以将算力从“经由云服务商转售”变为“端到端自主交付”。Wolfe Research使用“终极保险”一词的

深意在于：即便未来客户在计算层选择ASIC而非英伟达GPU，只要算力经由英伟达的网络基础设施交付，英伟达依然保留了对交付层的话语权和经济利益。

这一逻辑与英伟达近年来的一系列战略动作高度一致：200亿美元引进Groq技术及团队确立了GPU+LPU异构计算范式；300亿美元投资OpenAI锁定了最大的模型训练需求方。暗光纤网络补齐的，正是从算力生产到算力交付全链条中最后一块——也是最难以被复制的——物理传输层。

云巨头与电信运营商的双重压力

对AWS、Azure、GCP而言，GPU即服务的直销模式构成了一个棘手的前景：最重要的上游供应商正在成为特定场景中的直接竞争者。过去企业客户在云平台上租用GPU实例时，云服务商从中抽取可观的平台溢价；未来若英伟达以自有网络直接交付，这部分利润将在供需双方之间重新分配。

对传统电信运营商而言，一个市值超过5万亿美元的新买家大举收购长途暗光纤，可能推动相关资产的重估。Zayo、Crown Castle等暗光纤市场的主导者，面临的不只是竞争性买家的成本抬升，更是科技巨头对电信基础设施层渗透的加速——这一趋势已从数据中心延伸至传输网络。

但需要指出，暗光纤网络的商业运营并非易事。光传输设备、网络运维团队、与各地数据中心企业的最后一公里连接——英伟达在这些领域的经验几乎为零。即便网络建成，如何高效运营并实现商业化，仍是重大的执行风险。

暗光纤收购并非英伟达的孤立冒险，而是其从芯片公司向全栈AI基础设施运营商转型中的一环。仅过去一年，英伟达的布局便覆盖了计算架构（Groq）、客户生态（OpenAI）、供应链（SK海力士HBM合作）、地缘布局（日本机器人及汽车产业合作）——而暗光纤网络则是这张拼图中物理控制的部分。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

64 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论

