

摘要：

Google DeepMind副总裁John Jumper于上周五宣布将离职并加入Anthropic；Jumper因在AI领域的贡献荣获2024年诺贝尔化学奖。谷歌最知名的研究人员之一Noam Shazeer上周也宣布离职，转投OpenAI。分析指出，OpenAI和Anthropic与谷歌、Meta和xAI的模型差距日益加大。

在又一位重量级人工智能领军人物转投竞争对手后，谷歌股价周一大幅下挫。

谷歌一度下跌7.2%，创下自2月以来最大盘中跌幅。此前，Google DeepMind副总裁John Jumper周末表示将离职加入Anthropic。而就在上周，谷歌最知名的研究人员之一Noam Shazeer也宣布离职，转投OpenAI。



Jumper是谷歌AI编程开发团队的核心成员之一。他的离开正值谷歌在向企业客户推广AI编程工具方面遭遇困难之际，多名前员工透露了这一情况。

与此同时，AI编程工具已成为Anthropic和OpenAI近几个月增长势头的重要推动力。

新闻通讯《Vital Knowledge》创始人Adam Crisafulli周日写道：

“OpenAI和Anthropic正日益成为美国AI前沿领域的主导公司，并且似乎正在与谷歌、Meta和xAI的模型及编程工具拉开差距。”

他表示，Jumper的离职“对谷歌没有任何帮助”。

谷歌股价的下跌也正值其他超大型科技股普遍走弱之际。周一，追踪所谓“科技七巨头”的彭博指数一度下跌2.2%。其中，亚马逊盘中一度下跌4.9%，而Meta和微软的跌幅均超过2%。

Jumper曾与DeepMind首席执行官Demis Hassabis一同荣获2024年诺贝尔奖，原因是他开发了一款名为AlphaFold、能够预测蛋白质结构的人工智能模型。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 134  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发布评论



摘要：

美财政部发布有效期60天许可证，允许伊朗原油进口至美国。万斯称美伊谈判为最终协议奠定良好基础，建立了确保霍尔木兹海峡持续保持畅通的机制；伊朗同意国际原子能机构人员入伊核查。特朗普：伊朗将同意接受重大武器的核查，确保长期保持“核诚信”。伊外交部称，瑞士谈判未接受任何新承诺，伊美将继续在专家和技术层面磋商；伊方将按现行机制继续与国际原子能机构合作。

在美伊高层会谈释放积极信号后，美国政府迈出了近年来最具突破性的对伊政策调整一步。

当地时间22日周一，美国财政部海外资产控制办公室（OFAC）发布一项一般许可证，授权在8月21日前，允许涉及伊朗原产原油、石化产品及石油产品的生产、运输、销售以及相关金融、保险和物流服务，甚至允许相关产品进口至美国。这意味着华盛顿暂时放宽了长期以来针对伊朗能源出口的部分限制。

美国放松对伊朗石油交易限制的举动发生在美伊开始进行围绕落实谅解备忘录条款的技术性谈判时。

上周日，美伊代表团完成在瑞士举行的首轮技术性谈判。据新华社，美国副总统万斯本周一表示，美国和伊朗在瑞士的谈判取得了很多好的进展，为达成最终协议奠定了非常好的基础，伊朗已同意邀请国际原子能机构（IAEA）核查人员再次访问伊朗。几小时后，美国总统特朗普又在社交媒体称，伊朗将同意接受重大武器的核查。

除了伊朗已同意恢复IAEA核查，万斯还在瑞士透露，伊朗与美国就霍尔木兹海峡航运安全等问题达成初步共识。美国财长贝森特也在社交媒体发帖称，伊朗已承诺确保霍尔木兹海峡自由开放通行，并允许IAEA的核查人员进入该国。

据央视新闻，卡塔尔和巴基斯坦作为调解方表示，会谈“在积极和建设性的氛围中举行”，并取得“令人鼓舞的进展”，双方已建立进一步技术性谈判机制。

不过，央视还提到，伊朗外交部发言人巴加埃强调，此次会谈并未涉及核问题，也未接受任何新的承诺。他表示，伊朗与IAEA的合作与互动将按照现行机制继续进行，并遵循伊朗议会相关法律以及最高国家安全委员会作出的决定。

美国财政部发放60天一般许可证 覆盖伊朗能源交易全链条

根据美国财政部发布的“伊朗一般许可证X（General License X）”，授权范围不仅包括伊朗原油、石化产品和石油产品的生产、交付和销售，还涵盖运输、保险、银行结算、港口服务、船舶管理等配套活动。

媒体援引上述文件称，该许可证有效期为60天，是美伊日前签署谅解备忘录后的配套措施之一。美国财长贝森特在社交媒体提到，基于美伊达成的谅解备忘录框架，财政部签发了授权生产、运输和销售伊朗石油的临时许可证。

据央视新闻，美国财政部发布的一般许可证有效期至8月21日，授权涉及伊朗原产原油、石化产品及石油产品的生产、运输与销售，并允许相关交易进入美国市场。这被视为美伊缓和进程中的关键一步。

值得注意的是，许可证明明确允许伊朗能源产品进口至美国，这意味着美国数十年来针对伊朗石油贸易的部分禁令被暂时松绑。不过，古巴等部分受制裁地区实体仍被排除在许可范围之外。

万斯：伊朗同意国际核查人员入伊 特朗普：伊朗将同意接受重大武器核查 确保长期“核诚信”

在瑞士伯尔根施托克举行的美伊会谈后，美国副总统万斯对谈判结果表达乐观态度。他表示：“这是伊朗问题上非常好的一天，我们为最终协议奠定了良好基础。”

他透露，伊朗方面同意重新允许国际原子能机构检查人员进入该国，并已就被冻结资产管理机制以及霍尔木兹海峡航运安全建立沟通渠道。

对于允许伊朗恢复石油出口的决定，万斯辩称，制裁执行难度一直很高，即使在冲突爆发前，伊朗原油出口依然维持较高水平，因此通过有限放松制裁换取核查和地区稳定具有现实意义。

在离开瑞士时，万斯告诉记者，他对“我们所取得的进展”感到“非常满意”。他说：

“我们达成的根本性成果在于：第一，我们建立了一项机制，不仅能确保霍尔木兹海峡保持畅通，还能确保其持续保持畅通。”

接着，万斯提到了第二项成果：“第二，我们确实建立了一项恰当的机制，确保实现地区停火，从而管控未来不可避免会出现的冲突。”

在万斯宣布伊朗同意允许国际核查人员入境后，特朗普在社交媒体发帖称，伊朗必须同意在很长一段时间内接受针对重大武器的核查。他的帖子写道：

“大家都完全清楚，伊朗将必须同意接受针对重大武器的核查，以此确保未来长期保持‘核诚信’。”

美伊协议进入技术谈判阶段 伊朗称未作出新承诺

据伊朗媒体报道，自22日起，由伊朗外交部副部长加里巴巴迪率领的伊朗团队在瑞士与美国代表举行技术性会谈。

据报道，美国和伊朗上周日在瑞士举行的首轮高层会谈持续约18小时，在巴基斯坦和卡塔尔斡旋下，双方同意建立为期60天的路线图，以推动达成最终协议。

除恢复IAEA核查外，双方还讨论了被冻结资金使用机制、霍尔木兹海峡自由通航以及黎巴嫩停火协调机制等议题。

虽然最终协议仍需进一步技术磋商，但美国财政部此次放宽能源交易限制，被市场视为双方互释善意的重要信号。

伊朗方面对外释放的信息更加谨慎。

据央视新闻，伊朗外交部发言人巴加埃22日表示，伊朗和美国在瑞士举行的谈判并未涉及核问题，也没有接受任何新的承诺。

巴加埃当天在社交媒体发表声明称，伊朗代表团在完成有关落实伊美谅解备忘录条款的谈判后已经启程回国，双方将继续在专家和技术层面展开磋商。

声明称，此次会谈重点讨论了谅解备忘录第1、第5、第10和第11条。根据卡塔尔和巴基斯坦两个调解国与伊美协商后发表的联合声明，各方已就监督落实谅解备忘录内容的执行机制作出安排，并决定继续在专家和技术层面进行磋商，以推动谅解备忘录有效落实。

声明还表示，根据谅解备忘录第13条，启动最终协议谈判的前提，是第1、第4、第5、第10和第11条开始并持续得到执行，此次达成的共识有助于推动各方履行相关承诺。

调解方称取得“令人鼓舞的进展”

卡塔尔和巴基斯坦作为伊美谈判调解方22日发表联合声明称，双方会谈在“积极和建设性的氛围中举行”，并取得“令人鼓舞的进展”，包括建立进一步技术性谈判机制。

声明显示，目前各方重点仍是推动现有谅解备忘录落实，而最终协议谈判尚未正式启动。

这意味着，美伊关系虽然出现明显缓和，但距离全面协议仍有相当距离，双方目前仍处于执行机制和技术细节磋商阶段。

国际油市迎来潜在增量供应

分析人士认为，如果临时许可证最终转变为长期安排，伊朗原油出口有望进一步恢复，为全球市场带来新的供应来源。

此前，霍尔木兹海峡局势及中东冲突一度推动国际油价大幅上涨。随着以色列和黎巴嫩真主党停火、美伊关系缓和以及美国暂时放宽伊朗能源交易限制，市场对于供应中断的担忧有所减弱。

对于全球能源市场而言，这项为期60天的临时许可，不仅意味着美国对伊政策出现阶段性调整，也显示出美伊关系正在从军事对抗逐步转向执行层面的接触与协调。不过，从伊朗方面释放的信息来看，双方距离涉及核问题和最终协议的实质性谈判，仍有一段距离。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码

免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

70 收藏

分享到:

写评论

请发表您的评论



😊 表情

🖼️ 图片

发布评论



摘要：

雪佛龙与微软签署20年协议，将在美国得州建设2.67GW天然气电站，直供微软数据中心园区，预计2028年投产，投资约70亿美元。该项目避开公共电网，依托当地丰富的天然气资源，将原本可能浪费的能源转化为算力电力。这反映了AI算力竞赛下，科技巨头与能源企业深度绑定、自建电源以确保长期稳定供应的新趋势。

随着AI算力需求持续爆发，科技巨头与能源巨头之间的合作正不断深化。

据彭博，当地时间6月22日，**雪佛龙宣布与微软签署一项为期20年的长期电力供应协议**，将为微软计划在美国得州西部建设的大型数据中心园区提供天然气发电支持。**该项目总装机容量预计达267万千瓦**，足以满足超过53万户家庭的用电需求，有望成为美国规模最大的AI数据中心配套电力项目之一。

在电网资源日趋紧张的背景下，科技公司正越来越多地采取“自建电源+数据中心”的模式，锁定长期稳定能源供应，以应对人工智能时代不断攀升的算力需求。这一趋势不仅反映出AI基础设施对能源的巨大渴求，也标志着传统能源企业与科技产业之间正在形成更深层次的共生关系。

AI算力竞赛推动“能源争夺”

微软正加速扩张全球数据中心版图，以应对生成式AI带来的算力需求激增。

微软此前表示，未来两年将把数据中心规模扩大一倍以上，以保持AI领域与谷歌和亚马逊的竞争优势。**而数据中心的快速扩张也使电力成为AI产业链最关键的资源之一**。根据Bloomberg预测，**到2030年，美国数据中心总用电规模将较当前水平翻倍，达到77GW**。

面对日益增长的电力需求，美国多个地区已开始出现电网容量紧张、电价上涨等问题，引发监管机构和消费者担忧。在此背景下，微软选择直接与能源生产商合作，以获得长期、稳定且可预测的电力来源。

2.67GW天然气电站直供数据中心

根据协议，雪佛龙将与投资机构Engine No.1联合开发名为“Project Kilby”的发电项目。**该项目位于得州佩科斯附近，预计于2028年投产，并逐步扩容至2.67GW**。项目将采用GE Vernova的燃气轮机，依托二叠纪盆地丰富的天然气资源进行发电。

与传统模式不同，**该电站将专门为微软的数据中心园区供电，不接入公共电网，也无需通过当地公用事业公司进行输配电**。雪佛龙新能源业务负责人Jeff Gustavson表示：“消费者已经感受到电力需求增长带来的影响，而这个项目从设计之初就是为了避免对当地电网造成额外压力。”这种“源网荷”一体化的安排，既规避了电网瓶颈，也缓解了公共资源的紧张局面。

二叠纪盆地不仅是美国最大的页岩油产区，也是全球最重要的天然气产区之一。由于天然气产量过于庞大，当地管道运输能力长期不足，部分天然气甚至只能被直接燃烧处理。雪佛龙认为，这恰恰构成了项目的重要竞争优势。

Gustavson指出：“**这里拥有美国乃至全球最丰富的天然气资源。通过将数据中心直接建在产区附近，我们可以把原本可能被浪费的天然气转化为有价值的电力供应**。”这一模式不仅降低了能源运输成本，也显著提升了天然气资源的利用效率，实现了能源与算力的就地结合。

锁定设备、押注70亿：雪佛龙在得州抢先卡位算力能源

据报道，雪佛龙与Engine No.1已联合预订了7台GE Vernova天然气发电机组。在当前燃气轮机供应持续紧张、普遍面临数年交付周期的背景下，这一提前锁定的设备订单，为项目的如期推进提供了关键保障。

尽管雪佛龙尚未对外披露具体投资金额，但报道援引知情人士，**该项目的整体投资规模预计约为70亿美元**。按照计划，雪佛龙将在今年晚些时候作出最终投资决定。而Engine No.1则拥有未来收购该项目50%股权、并承担相应资本开支的选择权，为后续资本结构保留了灵活空间。

近年来，越来越多能源企业将AI数据中心视为新的增长引擎，得州目前规划中的数据中心配套电力项目规模已达33GW，位居全美第一，甚至超过了传统数据中心重镇弗吉尼亚州。**对于石油巨头而言，AI带来的不仅是电力消费的激增，更是天然气长期需求的新出口。**

雪佛龙高管Gustavson表示，尽管许多同行仍在讨论类似构想，雪佛龙已率先迈入执行阶段，并视其为一项重要的差异化竞争优势。随着AI产业持续扩张，科技公司与能源企业的深度绑定正从核电、天然气到储能设施全面铺开，一场围绕算力与能源的基础设施竞赛已在美国各地加速上演。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

61 收藏

分享到:

写评论

请发表您的评论

表情 图片

发布评论



摘要：

Reflection AI宣布与SpaceX签约，自今年7月起至2029年，每月付款金额为1.5亿美元，使用SpaceX田纳西州Colossus 2数据中心硬件资源。Reflection AI当前估值达250亿美元，由两位前谷歌DeepMind研究员创立，专注于开源方向的大模型研发。

SpaceX正加速将自身打造成AI算力基础设施提供商。继与谷歌、Anthropic签署大规模算力租赁协议后，SpaceX又将一家新兴AI初创企业纳入客户名单。

据Reflection AI周一宣布，该公司将向SpaceX旗下AI部门SpaceXAI支付算力费用，自今年7月起至2029年，每月付款金额为1.5亿美元。Reflection AI将使用SpaceX位于田纳西州孟菲斯市Colossus 2数据中心的硬件资源。

此次交易是SpaceX近期一系列大型算力销售协议中的最新一笔。SpaceX已先后与Alphabet旗下谷歌及Anthropic PBC签约：谷歌承诺在2029年中前支付约300亿美元，Anthropic则在相近期限内承诺支付450亿美元。

密集落地的合同表明，SpaceX正将出售算力容量视为一项核心战略业务，以期在AI基础设施这一市场中确立领导地位。

周一SpaceX股价一度跌超10%，随后小幅反弹，截至发稿下跌9.25%。



SpaceX

NASDAQ: SPCX

167.90 USD ↓ 9.25% -17.10 今天

+ 关注

6月22日 GMT-4上午11:35 • 免责声明



协议细节：月付1.5亿美元，锁定Colossus 2算力

根据Reflection AI披露的信息，该公司将从今年7月起向SpaceXAI支付算力租赁费用，合约期延续至2029年，月付金额达1.5亿美元，协议总额将达数十亿美元级别。

Reflection AI将调用的算力来自SpaceX位于田纳西州孟菲斯的Colossus 2数据中心。双方在协议中均设置了灵活退出机制——提前90天发出通知即可终止合作，这与SpaceX此前同谷歌及Anthropic签署的合同条款结构类似。

"更多算力意味着更大的空间，让我们能够大规模构建全球最优秀的开放模型，"Reflection AI发言人在声明中表示。

SpaceX的算力版图：从火箭公司到AI基础设施提供商

尽管马斯克在AI模型研发领域的竞争中尚难占据优势，SpaceX却凭借大规模囤积芯片及持续扩建多处大型数据中心，积累起可观的算力储备。

近期密集签约的三笔大单——谷歌约300亿美元、Anthropic约450亿美元、Reflection AI数十亿美元——共同勾勒出SpaceX在AI基础设施领域的商业路径：向外部AI企业出租自身数据中心的计算能力，将重资产转化为持续性收入来源。

值得注意的是，谷歌和Anthropic均被视为SpaceX在AI生态中的竞争对手，此次却成为其付费算力客户，凸显出当前市场对高质量算力资源的迫切需求。

Reflection AI：前DeepMind研究员创立，估值达250亿美元

Reflection AI由两位前谷歌DeepMind研究员创立，定位为开放AI模型构建商，专注于开源方向的大模型研发。

在资本层面，Reflection AI获得了英伟达等机构的背书。据媒体报道，该公司已就新一轮融资展开谈判，计划以250亿美元估值融资25亿美元。

此次与SpaceX的长期算力绑定协议，为Reflection AI持续推进大规模模型训练奠定了基础。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码 免费领取



限免

59 收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

摘要：

端侧AI的竞争，正在从比拼参数规模和压缩比例，转向模型、芯片、系统、应用之间的整体配合。

2026上半年，端侧大模型走到了一个新阶段：模型将继续变小、变轻，但光靠压缩已经不够了。接下来的关键，是让模型和底层框架、芯片、具体设备场景配合起来，从“能跑起来”走向“更好用”。

这样的转变，正在头部厂商身上集中发生。在6月9日的苹果全球开发者大会（WWDC2026）上，苹果发力端侧大模型，发布了AFM3系列。

苹果的思路是，从根本上为端侧设计出省算力的结构，推出约200亿参数的端侧主力AFM 3 Core Advanced，把模型本体做大，通过稀疏架构，每次推理只激活其中一部分参数。

这是苹果的解法。不过从整个行业看，在端侧的落地路径上，仍然面临不同取舍和分化。

一些公司走“蒸馏路线”：让能力强的大模型迁移给体量更小的模型，再把这个小模型装进设备里跑，以更低的成本逼近先进大模型的效果。

Google的Gemini Nano就是典型代表。早期Gemini技术报告中提到，Gemini Nano由更大的Gemini模型蒸馏而来，面向端侧部署，直接跑在Pixel、三星Galaxy等安卓手机本地上。

还有一类厂商则选择从端侧约束出发，重新设计模型本身。在有限的算力、内存和功耗条件下，尽可能提高端侧模型单位参数能够承载的能力密度。

这条路线押中是端侧大模型的“小而强”：模型体积要足够小，才能进入更多手机、PC、车机、机器人等终端；能力又要足够完整，才能支撑端侧 Agent、实时交互和本地智能体验。

以国内聚焦端侧大模型的面壁智能为例，长期强调模型压缩和能力密度提升。从MiniCPM系列开始，希望用更小的参数规模，尽量承载更强的模型能力。

到目前，面壁智能选择沿着低比特路线继续压缩模型，并联合清华大学、OpenBMB开源社区发布的BitCPM-CANN，已经在华为昇腾平台上验证了1.58-bit三值大模型的训练方案。

面壁智能的思路是，以前大模型的每个参数在计算机里通常要占用更多存储空间和计算资源，现在改成只用极少的位数就能表示，这样模型可以更省算力、也更省存储。

并且，这一步的压缩，使得端侧大模型的升级不再只停留在模型算法层面，也开始进入芯片适配层面。

在近日和面壁智能的一次交流会上，面壁智能CEO李大海表示：“今年以来，随着行业整体把推演转移到国产芯片上，我们也在逐步把训练工作转移到国产芯片和国产集群”。

这也指向端侧大模型的一个共同趋势：**模型越往终端走，就越依赖软硬协同。单纯把模型做小还不够，模型需要贴合芯片的计算方式，芯片也需要围绕大模型推理继续优化。**

行业中，类似的动作已经越来越多。无论是苹果围绕Apple Silicon芯片推出Core AI，还是高通、联发科、英特尔等厂商，都在搭建自己的端侧AI平台。

端侧AI的竞争，正在从比拼参数规模和压缩比例，转向模型、芯片、系统、应用之间的整体配合。

不过，端侧大模型的共识正在形成，分歧也随之浮现。

当模型真正进入手机、汽车、PC、机器人等真实设备后，行业讨论的焦点开始更加聚焦在端侧能力的核心能力拓展和边界上：端侧模型应该承担哪些核心任务？本地智能与云端智能如何分工？端侧模型从“能跑”走向“好用”，还要跨过哪些门槛？

围绕这些问题，面壁智能CEO李大海分享了他对端侧大模型进入落地阶段后的判断与思考。

苹果加码端侧：一场迟到的“系统工程”

问：苹果2026年继续加码端侧大模型，推出的端侧大模型AFM3 Core Advanced，也让端侧AI再次成为行业焦点。你怎么看苹果这一路线的落地进展？如何看待苹果通过“稀疏路线”切入端侧的方式？对安卓手机厂商来说，会带来怎样的竞争压力？

李大海：我觉得可以从几个角度看。

第一，苹果的端云协同战略其实在2024年6月就已经公布了，到现在逐步落地，某种程度上已经晚于行业预期。这说明端侧大模型不是一个简单的模型问题，而是涉及芯片、系统、软件生态和具体场景定义的系统工程。

第二，苹果切入端侧大模型，也进一步说明这个方向本身是成立的。端侧模型的价值，不只是把一个小模型放到手机里，而是要真正改变人与设备的交互方式。手机是用户最常使用、也最贴近个人数据和个人场景的终端，因此非常适合承载一部分高频、实时、隐私敏感的智能能力。

第三，这件事并不完全是苹果和安卓之间的竞争。关键不在于操作系统阵营，而在于谁能找到更合适的芯片、更高效的模型，以及更清晰的产品场景定义。

其实，国内手机厂商很早就在关注这个方向，也在和模型公司、芯片公司进行深度合作。就我的观察，大家对端侧智能的理解都相当深入，差距并没有外界想象中那么大。从面壁的角度看，我们从2024年起就提出了端侧战略，并持续与国内终端厂商合作。

问：苹果正在加码端侧大模型，高端安卓手机厂商也在寻找自己的端侧AI路线。端侧大模型真正形成体验差异，关键取决于哪些能力？

李大海：从面壁智能的经验看，手机厂商评估端侧模型，通常会看几个很具体的问题。

首先是模型本身的能力和部署成本。端侧模型不能只看参数大小，也不能只看某个榜单分数。它最终要跑在手机这样的设备上，所以必须同时考虑能力、速度、功耗和内存占用。模型太弱，用户感知不到价值；模型太重，又会带来耗电、发热和体验不稳定的问题。

其次是和端侧芯片的适配能力。手机里的AI能力最终要落到芯片上运行，模型公司不能等硬件确定之后再做简单适配。比较理想的方式，是在更早阶段就和芯片厂商一起看模型结构、推理方



式、内存占用和功耗表现。比如面壁和包括高通在内的一些端侧芯片厂商都有合作，也会在部分方向上做更前置的联合优化。

第三是推理效率。手机和汽车这类终端设备，对功耗和稳定性的要求很高。用户不会接受一个看起来能力很强，但一用就明显耗电、发热或者响应不稳定的 AI 功能。所以在效果接近的情况下，谁能用更低功耗、更低延迟把体验做出来，谁就更有优势。

苹果进入端侧大模型，会加速整个生态成熟。对高端安卓手机来说，压力会变大，但机会也仍然存在。未来真正决定竞争力的，还是芯片、模型、系统和场景能否形成高效协同。谁能把这些环节打通，谁就更有机会把端侧AI变成用户真正可感知的体验。

端侧落地的瓶颈：模型与芯片的结合

问：进入2026年后，端侧模型的落地进展到了什么阶段？目前制约端侧模型进一步规模化应用的关键瓶颈是什么？

李大海：2025年，面壁智能的端侧模型已经在汽车场景中实现量产，这是一个很重要的标志；今年则进入了落地的第二年，端侧模型的增长速度其实非常快。

但端侧模型真正向下落地，最大的制约还是刚提到的——模型与芯片的结合。

端侧场景和云端不一样，它对功耗、算力、带宽、成本和实时性都有很高要求。模型能力本身很重要，但如果没有合适的端侧AI芯片支撑，很多能力就很难以低成本、低功耗的方式进入真实设备。

所以我们非常期待接下来一批国产存算一体端侧AI芯片的量产。目前已经有一些相关芯片正在流片，一旦进入规模化应用，就有望在功耗、算力和带宽上提供更有竞争力的端侧 AI 能力。基于这些芯片，端侧应用会迎来更快爆发。

另外，我们认为端侧AI最合理的形态，并不是所有能力都放在端上，也不是完全依赖云端，而是端云协同。

比如，上下文管理应该尽可能放在端上，一些重要、高频、对隐私和实时性要求更高的推理任务，也应该优先在端上完成；而更复杂、更重的任务，则可以交给云端。

在这样的模式下，端侧模型会更自然地进入用户的日常生活。它未必一开始就以一个非常显性的“大模型产品”出现，而是会嵌入到汽车、手机、PC、可穿戴设备、智能家居等具体场景里，变成用户能直接感受到的智能体验。随着芯片、模型和应用生态进一步成熟，端侧模型的落地速度会明显加快，今年我们也会看到大量实际应用出现。

问：国产AI芯片过去更多被用于推理，但大模型训练对软件栈、集群稳定性、通信效率和精度一致性要求更高。站在模型公司的角度看，训练任务迁移到国产芯片上，面壁智能需要集中克服哪些难点？

李大海：我们现在主要沿着两个方向推进。

第一个方向，是在真实训练任务中与国产芯片厂商持续磨合。模型公司在训练过程中会遇到很多具体问题，比如算子性能、通信效率、集群稳定性、精度对齐等，这些问题只有在真实大模型训练中才会充分暴露出来。通过不断反馈、调优和验证，模型公司和芯片公司可以一起把国产 AI 软件生态打磨得更成熟。

第二个方向，是在更底层的软件适配上做一些配合。国产芯片的问题，不只是单块芯片性能怎么样，更大的挑战在于软件栈不够统一。不同芯片有不同的编译、算子、通信和调度体系，模型公司如果每接入一类芯片都要重新适配一遍，成本会很高，效率也很低。

所以我们会参与一些共性软件生态的工作，比如智源研究院牵头的FlagOS。其意义是希望把一部分重复适配的工作沉淀下来，让不同国产芯片在模型训练和推理时，能有更清晰的接口和协作方式。这项工作对于国产智算生态非常有价值，也在快速发展。

面壁智能本身既是大模型公司，也在算子适配和底层优化上有比较深的积累，所以我们在这两条路径上都有比较多的参与。一方面，我们通过真实模型训练任务帮助国产芯片和软件栈发现问题、解决问题；另一方面，我们也参与到更系统化的国产AI软件生态建设中。

此外，训练迁移到国产芯片上，比推理迁移更复杂。推理主要看吞吐、延迟和成本，训练还要验证数值精度、稳定性和长时间运行能力。

为此，我们用小模型实验预测大模型训练效果，并把华为等国产AI芯片上的测试结果与英伟达平台对齐，判断训练精度是否可靠。这类测试可以在大规模训练前，提前暴露芯片、算子和软件栈中的底层问题。

问：2026年的上半年，“豆包手机”等产品引发了外界对端侧智能体的关注。你怎么看端侧模型和端侧智能体对人机交互方式的改变？

李大海：这是一个非常自然发展的方向。

这背后是由端侧模型的分工优势决定的。相比完全依赖云端，端侧模型在隐私保护、实时响应和可靠性上更有优势，因此天然适合承担人机交互任务。因为人和设备之间的交互，对实时性和稳定性的要求非常高。

可以用云游戏来类比。移动互联网时代，很多公司都尝试过云游戏。理论上，云游戏把渲染放在云端，终端就不需要很强的算力，但这个方向一直没有真正大规模跑通。核心原因在于，用户对交互的帧率、延迟和稳定性非常敏感，不希望在没有预期的情况下突然卡顿。

也就是说，很多人会低估交互体验对实时性和可靠性的要求。只有在终端侧，才更有可能满足这种高标准。其实早在PC互联网时代，我们就已经看到过这一点的重要性。我最早任职的公司是Google，当时Google很早就发现，响应速度每提升100毫秒，对广告转化率都会产生很大影响。

所以回到豆包手机这类产品，端侧模型和端侧智能体结合，真正值得关注的是它可能带来新的交互层。

能不能做好端侧智能体，不只是看模型能力强不强，而是取决于三个因素的叠加：第一，芯片和算力能承受多大成本；第二，模型在能力、速度、功耗和稳定性上的综合表现；第三，具体场景是否成立。只有这三个圈真正重叠，端侧智能体才能进入大规模应用。

芯片决定能不能跑，模型决定能不能做，场景决定有没有人用。只有这三点重叠，端侧智能体才会走向大规模应用。

Agent落地后，更多任务会回到端侧



问：面壁智能已经把低比特量化探索到1.58bit。你怎么看模型量化继续往下压缩的空间？接下来的攻克和突破点主要在哪些方向？

李大海：从目前的技术判断看，1.58bit可能已经接近模型量化的极限了。继续往下压缩，理论空间会越来越小，真正的挑战也不只是把bit数降下来，而是在极高压缩比下，尽可能保持模型能力不出现明显损失。

对我们来说，更关键的是量化损失能不能足够低。模型压缩不是单纯追求参数占用更小，更重要的是在更低存储、更低算力、更低功耗的前提下，仍然保持足够好的推理效果。这也是端侧模型真正落地时最重要的问题之一。

在这方面，面壁智能采用的是从训练阶段就面向低比特量化进行优化的路线，也就是通过QAT，量化感知训练，让模型从训练一开始就持续适应低比特表示，而不是等模型训练完成后再做后处理压缩。

这种方式的好处是，模型从一开始就围绕低比特目标进行优化，可以更好地控制量化带来的性能损失。对面壁来说，极致量化的核心目标不是追求一个更低的数字，而是在接近量化极限的情况下，仍然让模型保持足够可用、足够稳定的能力。

问：这两末端侧模型进步很快。未来Agent的任务，会有多少能在本地完成？端和云之间会形成怎样的关系？

李大海：端云协同一定会扩展端侧模型的能力边界，但它并不意味着所有任务都要放在端上完成。更合理的方式是，把高频、实时、隐私敏感、需要稳定交互的部分尽可能放在端侧；而更复杂、更重的推理和规划任务，则由云端来承担。端和云最终会形成一种分工协作关系。

AI技术变化非常快，模型和Agent的进化速度也非常快。也许今天还做不了的事情，下个月就能做；这个月某个任务还有10%的错误率，再过一段时间可能就降到1%。所以现在很难用一个静态比例去判断未来有多少Agent工作可以在本地闭环完成。

但趋势是明确的：随着端侧模型能力提升、芯片性能增强，以及端云协同架构逐渐成熟，越来越多原本依赖云端的任务会被前移到本地。尤其是上下文管理、个人数据理解、高频交互和部分轻量级决策，都会更适合在端侧完成。

从长期来看，Agent会成为一个非常重要的趋势。AI作为新的生产要素，对社会和产业的影响会非常深远。今年可以说是Agent真正开始进入产业落地的第一年，很多东西还需要摸索，但从长期来看，它一定会成为常态。

问：过去一年，面壁智能的端侧模型已经进入汽车、手机、无人机等终端设备。这些场景的落地进展来看，不同设备对端侧模型的能力、功耗、稳定性和交互方式有哪些差异？

李大海：智能座舱是面壁端侧模型落地的重要场景之一。过去一年，我们在汽车场景中已经实现了量产落地，也获得了车企和用户的正向反馈。

比如吉利银河M9上搭载了相关功能，这个功能需要用户主动开启。从目前看到的车辆数据看，主动开启比例比较高，说明用户在实际使用中对这类座舱智能能力有需求。

从技术上看，座舱场景对端侧模型提出了比较具体的要求：响应要快，交互要稳定，也要能结合车内环境和用户指令完成任务。因此，仅有语言模型能力还不够，还需要多模态、语音交互、流式响应等能力配合。

除了汽车，端侧模型也在进入手机、无人机、潜水器等终端设备。不同设备对模型的要求并不一样，手机更关注功耗和系统体验，汽车更关注稳定性和交互安全，智能硬件则更看重体积、成本和本地响应。

所以现在我们更关注的是，端侧模型在不同设备里到底能承担哪些任务，哪些能力可以稳定运行，哪些场景用户真的会高频使用。端侧模型的落地，最终还是要回到具体设备和具体体验里验证。

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 47  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论

摘要：

英伟达推出Halos安全软件系统，脱胎于自动驾驶技术，赋予人形机器人实时环境感知与主动推理能力，打破“检测到人类即停机或降速”的安全逻辑。英伟达还宣布创建专属测试实验室，有望帮助合作伙伴加快认证节奏，缩短产品从实验室到客户现场的周期。

英伟达正将触角从AI数据中心芯片延伸至人形机器人领域，试图以软件和硬件的组合方案，破解机器人与人类协同作业的核心安全难题。

英伟达周一宣布推出Halos安全软件系统，该系统脱胎于自动驾驶技术，旨在赋予人形机器人更强的环境感知与实时决策能力，使其能够在人类身边安全行动，乃至与人发生肢体接触。

与此同时，英伟达还宣布建立专属安全测试实验室，协助机器人厂商在申请监管认证前完成预检和工程调试，直接打通商业化落地的关键环节。

根据巴克莱银行预测，人形机器人市场规模到2035年将达到2000亿美元。但当前安全系统的局限性——即一旦检测到人类靠近便强制停机或降速——严重制约了机器人的实际工作效率，也阻碍了人机协作场景的落地。

英伟达的方案若能有效解决这一痛点，将加速整个行业的商业化进程。该消息目前并未对股价产生明显影响，截至发稿，英伟达盘中下跌0.35%。



英伟达

NASDAQ: NVDA

209.96 USD ↓ 0.35% -0.73 今天

+ 关注

6月22日 GMT-4上午11:11 • 免责声明



传统安全模式不适用，人形机器人需要更高阶方案

现有工业机器人的安全逻辑较为简单粗暴：将机器人围入笼中隔离，或配备障碍物传感器，一旦检测到人类靠近即停机。英伟达产品管理高级总监Amit Goel表示，这套逻辑对于人形机器人而言远远不够。

人形机器人的核心挑战在于，它不能像传统工业臂那样依靠物理隔离来保障安全，而必须实时判断周围环境，识别哪些物体可以触碰、施力，哪些不能。

Agility Robotics首席技术官Pras Velagapudi指出，机器人也无法通过降低力量输出来“绕开”安全问题——一台力量不足以完成实际工作的机器人，本身也失去了部署价值。

"安全设计必须更加先进，因为你需要根据对环境的感知来推理哪些东西可以触碰、移动或施力，而这些力量的量级不能过小。你不能通过让机器人弱到只会轻轻碰一下人来回避问题，因为那样的机器人也无法完成有用的工作。"

Halos系统：软硬件协同，构建实时感知底座

英伟达的Halos软件将作为操作系统运行于其IGX Thor硬件平台之上，为机器人提供安全感知的底层支撑。

Agility Robotics旗下的人形机器人Digit是首批采用该方案的产品之一，该公司的机器人已被部署至丰田汽车在加拿大的制造工厂等客户现场。

Halos系统的能力不止于机器人本体。英伟达表示，机器人还将接入外部传感器网络。以仓库中的自动叉车为例，叉车可以调取仓库内摄像头的画面，提前“看”到转角处的情况，从而自主决定是保持全速前进还是减速规避碰撞。

这一架构的意义在于，安全决策从“被动停机”转变为“主动推理”，机器人得以在与人协作的场景中保持连贯作业，例如向同事递交物品或协助搬运重物。

自建认证实验室，降低监管准入门槛

除软硬件方案外，英伟达还宣布创建专属测试实验室，允许机器人制造商和客户在正式向监管机构申请认证之前，在该实验室内完成安全测试。

英伟达工程师将提供预检服务，并在必要时协助完成工程层面的调整优化。

这一举措直接瞄准了人形机器人走向大规模商业化的核心障碍之一——监管认证流程耗时长、成本高。通过提前介入测试环节，英伟达有望帮助合作伙伴加快认证节奏，缩短产品从实验室到客户现场的周期。

分阶段落地，仓储物流率先打开市场

与自动驾驶汽车相比，人形机器人的安全约束更为复杂。自动驾驶车辆通常只需规避与人或物体的接触，而人形机器人必须具备更高的灵活性和环境理解能力。尽管工程挑战依然存在，但行业普遍认为可以分阶段学习迭代。

Velagapudi表示，当前人形机器人的部署重心在于结构化程度较高的仓储与物流场景，该领域已具备数十亿美元量级的可寻址市场。

此后，行业将依次向零售、医疗、建筑等领域延伸，每个环节的难度递增，但每个市场本身都足够庞大，能够支撑大规模机器人部署。家庭护理场景则将建立在工厂机器人积累的经验之上，届时再行推进。

英伟达及其硅谷同行正竞相布局机器人赛道，将其视为AI的下一个重大市场。科技高管们预测，机器人最终将演变为规模达数十亿台设备的市场。

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。



限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

69 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论

摘要：

彭博策略师Simon White发文警告，美股正呈现背离：散户疯狂涌入半导体ETF，推动MSCI动能指数相对超额表现飙至历史极值（超五年标准差）；而机构期货净空头却创2023年来最高，对冲基金持续降仓。AI板块已占标普近四成权重，市场集中度、杠杆与追涨情绪同步触及极端区间。这一组合既可能是泡沫末段最丰厚的利润区，亦或是变盘前最危险的前夜。

美股市场正呈现出一个令人警惕的分化格局：散户资金将动能股推至历史性高位，而机构投资者则在悄然撤退——这一背离，往往被视为市场顶部的经典前兆。

据彭博宏观策略师Simon White撰文指出，**MSCI动能指数相对于MSCI美国指数的季度超额表现，已创下有记录以来最高水平**。与此同时，散户资金正大举涌入半导体ETF，相关资金流入上周刷新历史新高。

这一格局令市场观察人士警觉。散户历来是行情末段的最后入场者，往往将涨势推至高潮，但这种高潮通常难以为继。当前市场呈现出多项极端指标并存的局面，令部分分析人士认为市场正处于顶部形成过程之中。

动量行情进入历史极值区间

衡量市场追涨情绪的重要指标——MSCI Momentum指数，近期相对于MSCI美国指数的季度超额表现达到历史最高水平。


所谓动量策略，核心逻辑是“强者恒强”，即过去表现最好的股票往往会继续跑赢市场。在当前的动量指数成分股中，AI与半导体板块占据主导地位，包括美光、英特尔、AMD和博通等科技龙头，同时还包含卡特彼勒、埃克森美孚和强生等传统权重股。

历史数据显示，动量因子大幅跑赢市场本身并非利空信号。过去当动量因子相对于大盘高出一年均值三个标准差以上时，标普500指数在未来1个月、3个月和6个月通常仍能取得不错表现。

不过问题在于，本轮行情的极端程度已经远超历史经验。近期这一指标一度达到五个标准差以上，意味着市场资金正在以前所未有的速度向少数热门股票集中。

Momentum Is Showing Record Outperformance

■ MSCI US Momentum QoQ vs MSCI US QoQ



1

上

相
近
2

運

自
显

人
本

1

如

答

E
J

透白

附具

1

三

AI相关企业如今已占据标普500指数接近四成权重，资金流入仍然十分强劲。然而与此同时，越来越多的逆向指标开始发出警告。

例如，半导体ETF资金流入创纪录、对冲基金杠杆率升至四年来高位、投资者购买看跌保护的需求持续下降；与此同时，AI相关股票的技术指标已达到互联网泡沫时期罕见的极端水平。

市场情绪仍然亢奋，但越来越多的数据正在揭示同一个事实：这轮上涨越来越依赖少数热门板块和散户资金支撑，而机构资金则保持谨慎甚至逐步撤离。

对于投资者而言，这并不意味着牛市马上结束。事实上，历史上最疯狂的上涨往往发生在泡沫最后阶段。

但正如Simon White所警告的那样，**当动量、杠杆、散户参与度和市场集中度同时达到历史极值时，市场或许正在进入一个“利润最丰厚，同时风险也最高”的阶段。**

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

限时权益申领

* 体验资格每人限申领一次

扫码
免费领取

VIP会员·7天畅读卡 | 大师课·入门串讲



限免

69 收藏

分享到:

写评论

请发表您的评论

表情 图片

发表评论







摘要：

蔡崇信在VivaTech上抛出重磅论断：AI的“总盘子”高达50万亿美元。阿里全力投入AI，布局芯片、云基础设施、模型与应用四层以对冲不确定性。他认为，AI将解放人类生产力，让人们从工作中抽身，回归生活享受。

今年的VivaTech大会上，阿里巴巴董事长蔡崇信在一次“炉边对话”中，系统地阐述了阿里的长期AI远景，这是继5月末耶鲁大学峰会之后，蔡崇信再度公开复盘阿里。

“从宏观上看，我们正在全力投入AI，逻辑很简单。”

蔡崇信表示，全球GDP超过100万亿美元，其中至少一半将来自人类智能和人类生产力的贡献，**“这50万亿就是AI的总盘子，比任何公司的IT预算都大得多，也比软件市场大得多。”**

所有人在谈All in AI，蔡崇信也是如此，他把阿里巴巴布局的路径，概括为除了能源层以外的一切领域，包含芯片、云基础设施、模型与应用。

“我们主要布局了四个层级，但最底层的能源层我们不碰。因为中国的能源效率高、成本较低。”

在蔡崇信看来，近乎全栈的布局，源于未来的不确定性，因为现在没有人能准确定义最终价值将沉淀在芯片、云基础设施还是模型层。“我们选择全方位参与，不管价值最终落到哪一层，我们都在场。”

相比阿里，更激进的是美股云巨头，他们几乎全线布局基础设施，2027年资本支出合计8000亿美元，这也被空头们批评为“泡沫”。蔡崇信不仅不认同泡沫论，更强调中国公司需要追加在基础设施方面投入。

“投资数字确实惊人，”蔡崇信说，“我们要回到那个50万亿美金的总盘子来看，这是让人保持乐观的理由。”

谈及开源，蔡崇信先提到了特朗普政府最近叫停Anthropic最强模型的事，直言这就是把“鸡蛋放在一个篮子里”的后果。在他看来，谷歌、OpenAI、Anthropic的模型已经全部闭源，而开源这条路现在是中国公司在走。

“你确实不能把信任建立在第三方政府永远不会做对你不利的事上。”

以下为蔡崇信访谈精炼版：

50万亿的“盘子”

问： 阿里巴巴这些年变化很大，比如在开源大模型方面的成就。但很多人还以为你们只是个B2B、B2C平台。能讲讲整个集团的发展过程吗？

蔡崇信： 阿里巴巴1999年起步时，确实是个B2B平台。当时的想法很简单，就是把中国那些小制造商和贸易公司搬到网上，让他们把东西批发卖给全世界。后来我们进了B2C领域，做了淘宝，现在是中国最大的消费电商平台。

问： 这项服务面向多少消费者？



蔡崇信： 8.2亿中国消费者，而且这个平台每年帮欧洲公司和品牌向中国消费者卖差不多300亿欧元的货物。但故事不止这些，我们还大力投资AI和云。

我们17年前就开始投资云技术，但那是被逼出来的。当时电商业务每天产生海量数据，如果一直依赖别人的数据库和存储技术，到头来赚的钱全得交给技术供应商。所以我们决定自己搞一套专有技术来管理这些数据，云业务由此起步。

从宏观上看，我们现在全力投入AI，逻辑很简单。

如果你问我AI市场有多大，我会说，它比任何公司的IT预算都大得多，也比软件市场大得多。因为AI本质上是在生产人类智能和生产力。如今全球GDP超过100万亿美元，其中至少一半（50万亿）是关于人类生产力和人类智能的，这就是AI的总盘子。所以我们必须全力投入。

问： 你真觉得AI能提升生产力？很多人投了很多钱却还没看到结果。

蔡崇信： 很多企业CEO会告诉你，工程师消耗了大量token，成本在上升。但我想说，我们正处在生产力真正爆发的前夜。

拿我们公司来说，有些工程师是AI的超级用户，他们不光用编程工具完成本职工作，还会用它探索各种新用途。给工程师一个玩具，他们就会玩出更多用法，甚至没意识到公司在为这些消耗买单，这是当前的真实状态。

但我内心笃定，**这更像一种信念，相信人工生产的智能单元能为人类智能增加价值。这接近一种信仰，我不想说服你们相信这一定会发生，但我们自己对此坚信不疑。**

All in AI的逻辑

问： 回到阿里巴巴的布局，你们在AI的哪一层投资最多？基础设施、模型还是云服务？

蔡崇信： 我们主要布局了四个层级，但最底层的能源层我们不碰。因为中国的能源效率高、成本却很低。

我们真正入场是从芯片层开始的，这是第一层；第二层是基础设施层，对应我们的云业务；第三层是模型层，比如Qwen，它目前已经是全球最热门的开源模型之一；第四层是应用层，我们有完整的数字生活生态——电商、外卖、本地生活、旅行、地图等，这些场景都可以直接嵌入AI能力，服务用户。

这么做的好处在于，我们不赌单一赛道。

今天大家看到纯模型公司估值很高，好像价值都在模型层，但未来五年、十年，价值到底是沉淀在芯片、云基础设施、模型还是应用，没人说得准。我们选择全方位参与，不管价值最终落到哪一层，我们都在场。

问： 说到AI基础设施，当你看到如此巨大的投资，认为存在泡沫吗？我们真的需要这么多算力吗？毕竟有些模型效率更高，不需要那么多资源。

蔡崇信： 我认为不是泡沫。投资数字确实惊人。单看美国的超大规模云厂商，四五家头部公司明年的资本支出加起来超过8000亿美元，后年可能过万亿。这种量级的投入自然会让人担心会不会产能过剩。



但我们要回到那个50万亿美金的总盘子来看，这是让人保持乐观的理由。

而且在中国，我们在AI基础设施和供应链方面的投资其实还不够，理论上中国所有公司都应该加大投入。当然，我们不会达到美国超大规模厂商的投资水平，但我们的投资力度已经非常可观。

问：为什么达不到美国的水平？

蔡崇信：有时候会受到资金的限制，取决于你能产生多少自由现金流。幸运的是，阿里巴巴是少数拥有核心电商业务的公司之一，这块业务每年带来约250亿美元自由现金流，可以支持我们在AI上的投资。所以，我们的处境算比较好的。

问：目前电商平台业务仍占阿里巴巴总营收的80%到85%？

蔡崇信：对，电商平台收入依然占80%以上，这块能产出稳定现金流，让我们能对未来进行投资，主要投资AI和云。

开源与第二个篮子

问：Qwen属于开源模型，你们主要面向哪些客户？怎么帮助他们？

蔡崇信：我最近几周在欧洲和不少公司高管、CEO、科学家交流，这里出现频率最高的一个词是“主权”。

但什么是主权？

问十个欧洲人，可能得到十二种答案。对我而言，核心就是两条。

第一，技术独立性。大家都担心那种“一键关停”式的风险，害怕过于依赖某个国家的技术，他们随时可以把开关关掉。最近几天我们就看到了一个活生生的例子。

第二是数据隐私。人们想要使用AI技术，但希望数据完全归属自己，在自己的环境里使用，建一道防火墙来保护数据。

我认为开源正好能解决这两个问题。它本质上是免费软件，你可以下载到自己的数据中心里，甚至可以把模型下到笔记本电脑上。这时它跟原始制造商就没什么关系了，我们连怎么收费都想不出来。这就实现了独立性。

更重要的是，利用开源模型，你可以用自己的数据去做进一步训练、微调、后训练，整个过程和所有数据都完全保密在你的防火墙内。这一点对欧洲公司至关重要。

但我想强调的是，开源不是万能药，也不是唯一路径，但它是实现某种程度主权的一条现实途径。

有意思的是，如今开源运动实际是由中国公司在推动，美国主要玩家都把模型闭源了。他们想让你通过API调用，你根本不知道数据去了哪里。你跟聊天机器人对话，那些最私密的问题和想法全进了他们的数据池，用来继续训练模型，数据的流向对你完全是完全不透明的。

问：说实话，欧洲主权现在是一个巨大的担忧，我们刚刚意识到对美国技术过于依赖。我认可开源有好处，但依然会担心，未来被切断模型访问权限，这对欧洲来说是很大的风险。

蔡崇信：你说得对，这种担忧无法完全消除。简单来说，你确实不能把信任建立在第三方政府永远不会做对你不利的事上。但问题在于，现在你所有鸡蛋都放在一个篮子里。

为什么不选择第二个篮子，把鸡蛋分开放呢？即使欧洲长远看可能发展出自己的篮子，但至少眼下你有了两个篮子。

工厂里的AI

问：这倒是。你们怎么跟德国公司合作，帮助他们做什么？

蔡崇信：这些德国制造企业非常有意思。在中国市场，他们都是阿里云的客户。我们在制造领域跟他们合作，覆盖设计、测试、质量控制等环节。

我认为未来这会是一个非常重要的领域。因为现在大多数AI应用，要么是ChatGPT这类消费者产品，要么是Copilot这类面向编程和知识工作者的工具。但将来，这些制造企业将极具价值，因为他们在生产过程中积累了自己独有的高质量数据，可以用来训练专属模型，改进制造流程。

我们与宝马、西门子以及博世等公司都有合作。上周，我参加了博世互联世界大会，他们正在用AI开发辅助驾驶和自动驾驶技术，需要大量算力。

制造业正在发生很多有意思的事。

问：我是不是可以这样理解：美国对高端芯片的出口管制，反倒为你们创造了机会？

蔡崇信：可以这么理解。这里有两条路径：

一是他们直接采用我们的开源模型，部署到自己的基础设施上，比如数据中心。但我们的基础设施是跟模型紧密结合开发的，效率很高，能帮助客户训练模型。如果他们用我们开源模型，也可以向我们采购算力，模型和基础设施之间是共生关系，这是一条路。

另一条路是，现在涌现出一些推理平台公司，可以向用户提供多模型选择。你不一定非用Qwen，只要模型方和平台之间有协议，在私有环境中开放权重，客户就可以上这些平台使用模型。

AI、Agent与人类

问：问个更哲学点的问题。你怎么看AI、大语言模型和人类之间的平衡，甚至人性的未来？未来十年人类会处于怎样的状态？

蔡崇信：今天，我和巴黎办公室的同事聊天。我们刚搬进新办公室，在一栋漂亮建筑的楼上。我望向窗外，那里有一家咖啡馆，天气很好，人们坐在户外喝咖啡，享受生活。

我指着窗外的场景对同事说，这就是AI的未来。

你可能觉得他们在喝咖啡、玩得很开心，好像没有在工作，但实际上，他们已经把智能体部署出去，在替他们干活了。在你睡觉的时候，智能体也在为你工作。想想这种生产力提升，你能7天24小时有“人”帮你做事。

问：这和硅谷某些人的想法很像，很多人可以不用工作，智能体和机器人会替他们完成。



蔡崇信： 我相信这一定会把人的时间解放出来，去享受生活、陪伴家人、参与更多娱乐。这也是我为什么非常看重现场娱乐的原因之一。当人们花更少时间在办公室，他们会想去哪儿？不可能只待在家里，会想去听音乐会、看足球、看篮球比赛。

问： 中国人以勤奋著称。中国工程师，即使有了智能体和AI，工作时间依然很长。

蔡崇信： 总会有人比别人工作更努力，但我相信大多数人内心是希望多享受一点生活，多花些时间陪家人的。

本文来源：[腾讯科技](#)

风险提示及免责条款

市场有风险，投资需谨慎。本文不构成个人投资建议，也未考虑到个别用户特殊的投资目标、财务状况或需要。用户应考虑本文中的任何意见、观点或结论是否符合其特定状况。据此投资，责任自负。

 102  收藏

分享到:  

写评论

请发表您的评论

 表情  图片

发表评论